

上海交通大学博士学位论文

条件非完备下的长尾学习方法研究

姓　　名:

学　　号:

导　　师:

院　　系: 集成电路学院（信息与电子工程学院）

学科/专业: 信息与通信工程

申请学位: 工学博士

2026 年 3 月 25 日

A Dissertation Submitted to

Shanghai Jiao Tong University for the Degree of Doctor

A STUDY ON LONG-TAILED LEARNING METHODS UNDER INCOMPLETE CONDITIONS

Author:

Supervisor:

School of Integrated Circuits (School of Information Science and Electronic Engineering)

Shanghai Jiao Tong University

Shanghai, P.R. China

March 25th, 2026

摘 要

近年来，深度学习在计算机视觉与内容生成等领域取得了显著进展，但其成功很大程度上依赖于高质量且分布均衡的理想化数据。然而，现实世界的泛在数据生成过程往往呈现出显著的长尾分布特征，并伴随着标签退化（如噪声、歧义）以及隐式结构（如属性偏差）等非理想偏倚。理想条件下的长尾学习方法普遍建立在标注准确、结构显式以及任务单一这三大理想化假设条件之上。本文将此类理想条件在现实场景中失效的状态定义为条件非完备，即学习系统面临监督信号退化、隐式结构失衡及目标任务异构等多重制约。当面临条件非完备的挑战时，现有方法表现出明显的局限性。首先，在监督信号退化的非完备条件下，传统重加权策略会错误地放大噪声信号。其次，当存在隐式结构时，粗粒度的类别监督掩盖了子群层面的失衡。最后，在生成式任务中，头部类别对模型容量的垄断导致尾部类别的生成质量严重退化。

针对上述局限，本文聚焦于条件非完备下的长尾学习这一核心问题，围绕数据分布校准、隐式结构挖掘以及模型容量解耦等关键维度展开研究。本研究旨在打破传统方法对理想化假设的依赖，构建适用于非完备场景的通用长尾学习框架，以解决监督信号退化、隐式结构失衡以及目标任务异构等难题。

具体而言，本文提出如下四项具有代表性的创新算法：

- **基于动量原型的动态校准算法（RECORDS）：**针对长尾偏标签这种由于监督信号不确定导致的非完备设定，本文提出一种动态校准机制。该方法在无需预知真实分布的前提下，利用动量更新的原型特征实时捕捉消歧过程中类别分布的演变，并通过参数化的动态分解实现消歧置信度与分布偏差的协同优化，有效解决了该设定下的冷启动与分布失配难题。
- **基于双粒度最优传输的统一鲁棒蒸馏框架（D-SINK）：**针对长尾噪声标签这种由于标注质量退化导致的非完备设定，本文构建了一种基于最优传输的蒸馏框架。该方法通过双粒度机制协同整合仅具单项鲁棒性的辅助模型，在分布粒度上利用长尾先验纠正全局偏差，在样本粒度上利用几何对齐过滤高损耗噪声，成功在极低信噪比条件下恢复了模型的泛化能力。
- **基于互信息最大化的无监督子群挖掘与平衡算法（SHE）：**针对显式监督无法覆盖隐式子群分布失衡这一结构非完备设定，本文提出一种遵循先解耦后平衡理念的无监督挖掘算法。该方法摒弃了对细粒度标签的依赖，利用信息论工具自

动识别语义一致但分布各异的隐式子群，并通过自适应聚合策略实现子群层面的预测平衡，显著提升了模型在弱势子群上的公平性与鲁棒性。

- **基于参数空间解耦的通用重平衡范式（CM）：**针对生成式任务中由于任务目标异构导致的模型容量分配非完备问题，本文提出一种底层参数解耦策略。通过将模型权重显式分解为通用共享与尾部专用模块，本研究不仅实现了零推理成本的分类精度提升，更从优化机制底层解决了扩散生成模型中尾部类别的模式崩塌问题，验证了通过容量重构实现跨任务通用性的可行性。

综上所述，本文系统构建了条件非完备下的长尾学习方法体系，在提升模型对退化监督信号容错能力的同时，兼顾了隐式公平性与跨任务通用性。研究成果为构建稳健、公平且高效的人工智能系统奠定了理论基础，并在多个视觉与生成基准任务中展现了应用价值。

关键词：长尾学习，标签噪声，偏标签学习，隐式子群，扩散模型

Abstract

In recent years, deep learning has achieved significant progress in fields such as computer vision and content generation. However, its success relies heavily on high-quality and class-balanced idealized data. In contrast, the ubiquitous data generation process in the real world often exhibits significant long-tailed distribution characteristics, accompanied by non-ideal biases such as label degradation (e.g., noise, ambiguity) and implicit structures (e.g., attribute bias). Long-tailed learning methods under ideal settings are generally established on three idealized assumptions: accurate annotation, explicit structure, and single task. This dissertation defines the state where these idealized assumptions fail in real-world scenarios as Condition Incompleteness, where the learning system faces multiple constraints such as degraded supervision signals, imbalanced implicit structures, and heterogeneous target tasks. When facing the challenges of condition incompleteness, existing methods exhibit obvious limitations. First, under non-ideal settings with degraded supervision signals, traditional re-weighting strategies erroneously amplify noise signals. Second, when implicit structures exist, coarse-grained category supervision masks the imbalance at the subpopulation level. Finally, in generative tasks, the monopoly of model capacity by head classes leads to severe degradation in the generation quality of tail classes.

To address these limitations, this dissertation focuses on the core problem of long-tailed learning under condition incompleteness, conducting research across key dimensions including data distribution calibration, implicit structure mining, and model capacity decoupling. This research aims to break the dependence of traditional methods on idealized assumptions and construct a universal long-tailed learning framework suitable for incomplete scenarios to resolve challenges such as supervision signal degradation, implicit structural imbalance, and heterogeneous target tasks.

Specifically, this dissertation proposes the following four representative innovative algorithms:

- **Momentum Prototype-based Dynamic Calibration Algorithm (RECORDS):** Addressing the incomplete setting of long-tailed partial labels caused by uncertain supervision signals, this dissertation proposes a dynamic calibration mechanism. Without

requiring prior knowledge of the true distribution, this method utilizes momentum-updated prototype features to capture the real-time evolution of category distributions during the disambiguation process. By achieving synergistic optimization of disambiguation confidence and distribution bias through parameterized dynamic decomposition, it effectively solves the cold-start and distribution mismatch problems under this setting.

- **Dual-Granularity Optimal Transport-based Unified Robust Distillation Framework (D-SINK):** Addressing the incomplete setting of long-tailed noisy labels caused by degraded annotation quality, this dissertation constructs a distillation framework based on optimal transport. This method synergistically integrates auxiliary models with only single-item robustness through a dual-granularity mechanism. It utilizes long-tailed priors to correct global bias at the distribution granularity and utilizes geometric alignment to filter high-loss noise at the sample granularity, successfully recovering the model's generalization ability under extremely low signal-to-noise ratios.
- **Mutual Information Maximization-based Unsupervised Subpopulation Mining and Balancing Algorithm (SHE):** Addressing the structural incomplete setting where explicit supervision cannot cover implicit subpopulation distribution imbalance, this dissertation proposes an unsupervised mining algorithm following the philosophy of "decoupling before balancing." This method abandons reliance on fine-grained labels and utilizes information-theoretic tools to automatically identify implicit subpopulations that are semantically consistent but distributionally distinct. Through an adaptive aggregation strategy, it achieves prediction balance at the subpopulation level, significantly improving the model's fairness and robustness on disadvantaged subpopulations.
- **Parameter Space Decoupling-based General Re-balancing Paradigm (CM):** Addressing the incomplete model capacity allocation in generative tasks caused by heterogeneous task objectives, this dissertation proposes an underlying parameter decoupling strategy. By explicitly decomposing model weights into universal shared and tail-specific modules, this research not only achieves classification accuracy improvement with zero inference cost but also solves the mode collapse problem for tail classes in diffusion generative models from the underlying optimization mechanism, verifying

the feasibility of achieving cross-task generality through capacity reconstruction.

In summary, this dissertation systematically constructs a methodological system for long-tailed learning under condition incompleteness. While improving the model's fault tolerance to degraded supervision signals, it also accounts for implicit fairness and cross-task generality. The research results lay a theoretical foundation for building robust, fair, and efficient artificial intelligence systems and demonstrate significant application value across multiple vision and generation benchmarks.

Key words: Long-tailed Learning, Label Noise, Partial Label Learning, Implicit Subpopulations, Diffusion Models

目 录

第 1 章 绪论 1
1.1 研究背景与意义 1
1.1.1 主流长尾学习范式在条件非完备下的局限性 2
1.1.2 研究价值 5
1.2 研究现状与挑战 6
1.2.1 问题描述 6
1.2.2 研究现状概述 9
1.2.3 主要挑战 11
1.3 主要贡献及组织结构 12
1.3.1 本文主要贡献 12
1.3.2 本文组织结构 13
第 2 章 研究现状 17
2.1 理想条件下的长尾学习方法研究 18
2.1.1 数据层面的重平衡与合成 18
2.1.2 模型层面的解耦与增强 19
2.1.3 目标层面的重加权与校准 20
2.2 面向退化监督信号的长尾学习方法 20
2.2.1 标签歧义下的长尾学习研究 21
2.2.2 标签噪声下的长尾学习研究 22
2.3 面向隐式属性的分布鲁棒与子群平衡学习 23
2.3.1 非本质属性的分布鲁棒性 24
2.3.2 无监督子群挖掘与平衡技术的演进 24
2.3.3 现有研究在条件非完备下的局限性 25
2.4 面向生成式任务的长尾学习研究 25
2.4.1 面向生成对抗网络的长尾学习 25
2.4.2 面向扩散模型的长尾学习 26
2.5 本章小结 27

第 3 章 基于动量原型动态校准的长尾偏标签学习 29
3.1 引言..... 29
3.2 预备知识..... 31
3.2.1 问题定义 31
3.2.2 自训练偏标签学习方法 32
3.2.3 面向长尾学习的 Logit Adjustment 技术..... 32
3.3 算法研究..... 33
3.3.1 动机：从静态到动态的范式转变 33
3.3.2 算法原理 34
3.3.3 基于动量原型的分布估计 35
3.3.4 动态重平衡与静态重平衡的理论联系 36
3.4 实验验证..... 41
3.4.1 仿真实验分析 41
3.4.2 实验设置 43
3.4.3 基准测试结果 45
3.4.4 进一步分析 48
3.5 本章小结..... 52
3.5.1 局限性与讨论 53
第 4 章 基于双粒度最优传输蒸馏的长尾噪声标签学习 55
4.1 引言..... 55
4.2 算法研究..... 56
4.2.1 问题描述 57
4.2.2 核心动机：粒度解耦与协同 57
4.2.3 双粒度蒸馏策略构建 58
4.2.4 基于 Sinkhorn 算法的优化求解..... 60
4.2.5 算法流程与复杂度分析 62
4.3 实验验证..... 63
4.3.1 实验设置 63
4.3.2 实验结果与分析 65
4.4 本章小结..... 74
4.4.1 局限性与讨论 75

第 5 章 基于互信息最大化的隐式子群均衡学习 77
5.1 引言 77
5.2 算法研究 80
5.2.1 问题描述 80
5.2.2 研究动机：从混合分布到子群解耦 80
5.2.3 SHE 算法原理与分析 83
5.2.4 算法实现与优化 91
5.3 实验验证 93
5.3.1 实验设置 93
5.3.2 隐式子群不平衡下的性能评估 94
5.3.3 在更复杂不平衡场景下的性能评估 96
5.3.4 消融实验与深入分析 99
5.4 本章小结 103
5.4.1 局限性与讨论 104
第 6 章 基于参数空间解耦的跨任务通用长尾学习 107
6.1 引言 107
6.2 扩散模型在长尾数据上的局限性分析 108
6.2.1 问题定义 108
6.2.2 实证动机：性能退化与容量敏感性 110
6.2.3 理论洞察：梯度主导与容量垄断 110
6.2.4 定理 6.1 的证明 111
6.3 算法研究 113
6.3.1 模型容量预留 113
6.3.2 模型容量分配 116
6.3.3 讨论与分析 118
6.4 实验验证 119
6.4.1 实验设置 120
6.4.2 实验结果与分析 122
6.4.3 进一步分析 125
6.5 本章小结 132
6.5.1 局限性与讨论 133

第 7 章 总结与展望 135
7.1 全文总结 135
7.2 未来工作展望 136
参考文献 139
附录 A 引理 3.3 的证明 (Liu 等人[91]) 155
学术论文和科研成果目录 157

插 图

图 1.1 真实世界的长尾分布效应.....2
图 1.2 长尾分布引发的鲁棒性缺陷.....3
图 1.3 真实世界长尾数据面临的挑战.....4
图 1.4 条件非完备下传统长尾学习方法有待解决的关键研究问题.....5
图 1.5 传统长尾学习问题的隐含假设条件与对应的挑战.....8
图 1.6 条件非完备下的长尾学习近年来主要的代表性工作梳理时间线图.....9
图 1.7 本文组织结构示意图..... 14
图 3.1 RECORDS 算法与基线算法在训练过程中分类器平均预测结果的变化 30
图 3.2 RECORDS 算法整体流程示意图 35
图 3.3 RECORDS 算法的类别分布估计效果 41
图 3.4 RECORDS 算法仿真实验可视化结果 42
图 3.5 RECORDS 算法与基线算法各类别准确率的细粒度对比 47
图 3.6 RECORDS 算法与基线算法的线性探测性能评估 49
图 3.7 RECORDS 算法的动量系数 m 的消融实验 50
图 3.8 RECORDS 算法与基线算法图像特征表示的 t-SNE 可视化 51
图 4.1 D-SINK 整体示意图..... 60
图 4.2 D-SINK 算法超参数 α 的消融实验结果 72
图 4.3 D-SINK 算法与基线算法的噪声样本纠错率分析..... 72
图 4.4 D-SINK 算法与基线算法的特征 t-SNE 可视化..... 74
图 5.1 类别不平衡与隐式子群不平衡的对比及挑战..... 78
图 5.2 SHE 算法与基线算法的二维仿真实验可视化 82
图 5.3 SHE 算法训练过程中 NMI 分数的变化趋势..... 85
图 5.4 SHE 算法在 COCO 上学习到的子群可视化示例..... 86
图 5.5 SHE 算法在 COCO 上更多类别的子群可视化结果..... 86
图 5.6 SHE 算法在 Waterbirds 数据集上学习到的子群可视化结果..... 87
图 5.7 SHE 算法不同子群数量 K 消融实验.....100
图 5.8 SHE 算法的消融实验与分析图表 101
图 6.1 扩散模型在长尾分布下的生成质量与容量垄断现象.....109

图 6.2 扩散模型在长尾数据下逐类别原始损失……110
图 6.3 CM 算法概览 ……116
图 6.4 CM 算法与 DDPM 在 Imb. CelebA-HQ 上少数类的生成结果可视化……124
图 6.5 CM 算法与基线算法在 Imb. ArtBench-10 上少数类的生成结果可视化……126
图 6.6 CM 算法性能分析与消融实验 ……129

表 格

表 2.1 现有长尾学习研究现状与本文研究内容的对应关系 27
表 3.1 PASCAL VOC 数据集的基本特性 44
表 3.2 PASCAL VOC 数据集各类别样本分布 44
表 3.3 RECORDS 算法与基线算法在三个基准数据集上的 Top-1 准确率对比 46
表 3.4 RECORDS 算法与基线算法在 CIFAR-100-LT 上的细粒度性能分析 47
表 3.5 RECORDS 算法与不同动态重平衡策略的性能对比 48
表 3.6 RECORDS 算法与基线算法在非均匀歧义设定下的细粒度性能分析 49
表 3.7 RECORDS 算法与更多长尾学习基线的对比 50
表 4.1 D-SINK 算法与标准训练的训练时间对比（秒/Batch） 62
表 4.2 D-SINK 算法与基线算法在对称噪声下测试准确率 66
表 4.3 D-SINK 算法与基线算法在非对称噪声下的测试准确率 67
表 4.4 D-SINK 算法与基线算法在真实世界噪声数据集上的测试准确率 68
表 4.5 D-SINK 算法与基线算法在 CIFAR-100 上的多维性能指标 69
表 4.6 D-SINK 算法与基线算法结合后的性能提升（对称噪声） 70
表 4.7 D-SINK 算法与基线算法结合后的性能提升（非对称噪声） 71
表 4.8 D-SINK 算法组件消融及与朴素方法的对比 73
表 4.9 D-SINK 算法辅助模型选择的消融实验 73
表 5.1 不同类型不平衡问题的比较 79
表 5.2 SHE 算法与基线算法在各数据集上的总体性能对比 95
表 5.3 SHE 算法与基线算法在 COCO 数据集上的细粒度性能分析 97
表 5.4 SHE 算法与基线算法在子群不平衡与类别不平衡共存场景下的性能评估 ... 97
表 5.5 SHE 算法与基线算法在虚假相关性数据集上的性能评估 98
表 5.6 SHE 算法及其变体与 ERM 的性能对比 102
表 5.7 SHE 算法与基线算法基于预训练模型的 LoRA 微调结果 103
表 6.1 FID 指标对比：CM 与基线及低秩变体 120
表 6.2 CM 算法与 Overlap Optimization 的对比（IR=100） 122
表 6.3 CM 算法与基线算法在 Imb. CIFAR-10/100 上的性能对比 123
表 6.4 CM 算法与基线算法在 Imb. CIFAR-10/100 上的细粒度 FID 性能分析 124

表 6.5 CM 算法与基线算法在 Imb. CelebA-HQ 上的性能对比.....124
表 6.6 CM 算法与基线算法在 ImageNet-LT 和 iNaturalist 上的性能对比.....125
表 6.7 CM 算法与基线算法基于 Stable Diffusion 微调的 Imb. ArtBench-10 性能对比.....126
表 6.8 CM 算法与基线算法在 Imb. ArtBench-10 少数类上的人类感知评估结果....127
表 6.9 CM 算法与基线算法在 Imb. CIFAR-100 上的下游分类任务性能 127
表 6.10 CM 算法在 Imb. CIFAR-100 上不同参数网络的分子集与整体 FID 128
表 6.11 CM 算法的多样性损失与一致性损失的消融实验.....128
表 6.12 CM 算法在受限训练预算下的性能评估.....130
表 6.13 CM 算法与基线算法在长尾 CIFAR-100 判别式任务性能对比 130
表 6.14 CM 算法与基线算法在一致性模型上的 FID 结果 131
表 6.15 CM 算法与基线算法在 DPM-Solver 上的 FID 结果.....131
表 6.16 CM 算法与基线算法在细粒度文生图数据集上的 FID 结果 132

算 法

算法 3.1 RECORDS 算法流程 37
算法 4.1 D-SINK 算法流程..... 62
算法 6.1 CM 算法流程 119

第 1 章 绪论

近年来，深度学习技术取得了极大的发展，并被广泛应用到计算机视觉、自然语言处理、内容生成等多个领域。然而，现有深度学习的成功很大程度上依赖于高质量、分布均衡的理想化数据。大量研究表明，现实世界的泛在数据生成过程不仅呈现显著的长尾分布特征，更往往伴随着复杂现实场景下的多重偏倚。这些偏倚包括标签退化（如噪声、歧义）以及隐式结构（如属性偏差）等复杂因素。

尽管现有的长尾学习研究通过重采样或重加权等手段在单一的类别不平衡问题上取得了一定进展，但这些方法普遍建立在标注准确、结构显式以及任务单一这三大理想化假设条件之上。本文将此类理想条件在实际应用中失效的状态定义为“条件非完备”，即学习系统面临监督信号质量退化、隐式结构失衡以及任务目标异构等多重制约。当面对真实的条件非完备场景时，传统方法往往捉襟见肘。在判别式任务中，标签的退化会导致重加权策略错误地放大噪声，而隐式子群的失衡则被粗粒度的类别监督所掩盖；在生成式任务中，传统的损失调整策略难以直接迁移，无法解决头部类别对模型容量的垄断问题。这些鲁棒性缺陷给医疗诊断、自动驾驶等注重可靠性与公平性的高风险应用场景带来了严峻挑战。

为了突破现有长尾学习范式的局限，本研究从数据分布校准、隐式结构挖掘以及模型容量解耦等多个维度提出条件非完备下的长尾学习方法，旨在构建面向泛在场景的通用鲁棒学习框架。本章将首先介绍研究背景与意义，重点剖析现有长尾学习方法在非完备条件下的局限性，随后详述研究现状与关键科学问题，最后概括本文的研究内容、主要贡献以及组织结构。

1.1 研究背景与意义

随着面向深度学习优化的专用计算硬件（例如 GPU、TPU、NPU 等）性能的不断提升以及海量互联网与人工标注数据资源的积累，深度学习技术得以利用大规模参数的模型和大数据学习并归纳真实世界数据分布的内在规律[1-3]。特别是自 Transformer 架构[4]提出以来，基础模型的参数量与训练数据量呈指数级增长[5-6]，并在计算机视觉[7-13]、自然语言处理[4,14-17]、多模态内容生成[18-20]等多个领域取得了卓越的表现。

在过去的几年中，深度学习已逐渐走出实验室，被广泛应用于自动驾驶[21-22]、医疗影像诊断[23-24]、安防监控[25]以及人工智能生成内容创作[19]等实际场景中。然而，这

些成就很大程度上建立在训练数据服从理想化分布（即独立同分布且类别平衡）的假设之上[2]。现实世界的数据生成过程往往遵循齐普夫定律（Zipf's Law）[26]，呈现出显著的长尾分布特征[27-28]。如图 1.1 所示，在自然界与社会生活中，少数头部类别占据了绝大多数样本，而承载着丰富信息量的尾部类别却面临样本极度匮乏的困境。

这种数据分布的极度不平衡在众多领域中普遍存在，打破了经典经验风险最小化原则的假设基础，导致模型在训练过程中被头部类别的梯度所主导，严重牺牲了在尾部类别上的预测性能与泛化能力[29-30]。如图 1.2 所示，长尾分布引发的鲁棒性缺陷在多个真实应用中普遍存在，具体体现在自动驾驶中的极端事故与复杂路况[31-32]、人脸识别中的种族与年龄不均衡[33-34]、智慧医疗中的罕见病诊断不足[35]、自然语言处理中低资源语言性能退化[36]、推荐系统中的流行度偏置[37]、以及图像生成中复杂结构的失真问题[38]。

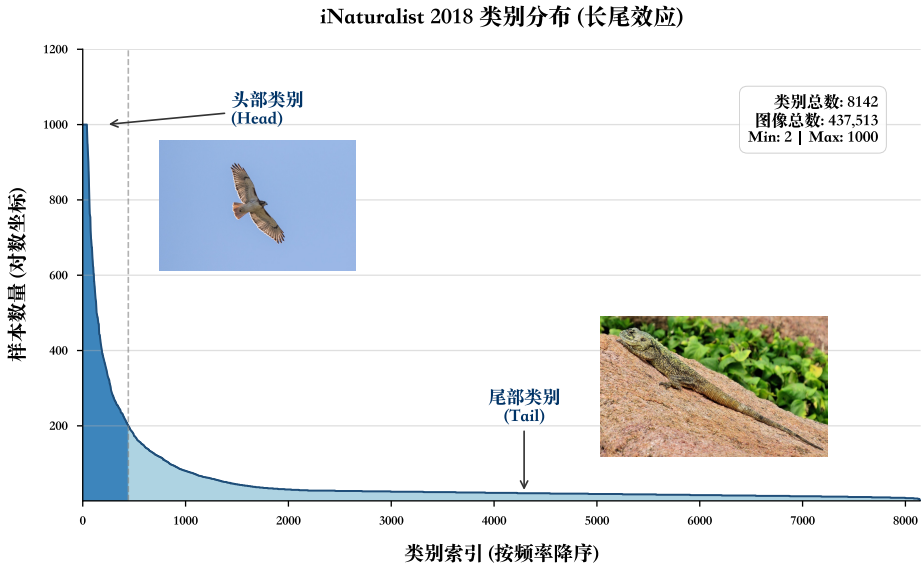


图 1.1　真实世界的长尾分布效应，以 iNaturalist 2018 数据集为例[39]。

Figure 1.1　Illustration of the long-tailed distribution in real-world data, exemplified by the iNaturalist 2018 dataset[39].

1.1.1　主流长尾学习范式在条件非完备下的局限性

针对长尾分布问题，学术界发展出了一系列经典的长尾学习方法，主要包括重采样（Re-sampling）、重加权（Re-weighting）以及 Logit 调整（Logit Adjustment）等。这些方法主要聚焦于标准分类任务设定，即在一个封闭且受控的环境下，通过调整模型对不同类别的关注度来缓解样本量不平衡带来的负面影响。这些方法的核心逻辑



图 1.2 长尾分布引发的鲁棒性缺陷在多个真实应用中普遍存在：自动驾驶中的极端事故与复杂路况[31-32]；人脸识别中的种族与年龄不均衡[33-34]；智慧医疗中的罕见病诊断不足[35]；自然语言处理中低资源语言性能退化[36]；推荐系统中的流行度偏置[37]；以及图像生成中复杂结构（如手部）的失真问题[38]。

Figure 1.2 Pervasive robustness issues caused by long-tailed distributions across real-world AI applications, including autonomous driving corner cases[31-32], demographic bias in face recognition[33-34], rare disease diagnosis in healthcare[35], low-resource languages in NLP[36], popularity bias in recommender systems[37], and structural failures in image generation models[38].

在于显式分布对齐，通过人为修正训练目标函数，迫使模型在参数更新时向尾部类别倾斜。

然而，本研究认为上述主流范式过度依赖于标准分类任务中的理想化设定。具体而言，传统长尾学习范式隐含了标注准确、结构显式以及任务单一这三大理想化假设条件。本研究将这些理想化假设在现实泛在数据中失效或无法完全满足的状态定义为**条件非完备**，即学习系统在监督信号质量、数据内部结构以及任务建模目标上处于信息欠对称或资源受限的状态。在面对此类开放且动态的场景时，基于实验室环境设计的补丁式修复策略展现出明显的脆弱性。具体而言，传统长尾学习范式隐含的三大理想化条件为：

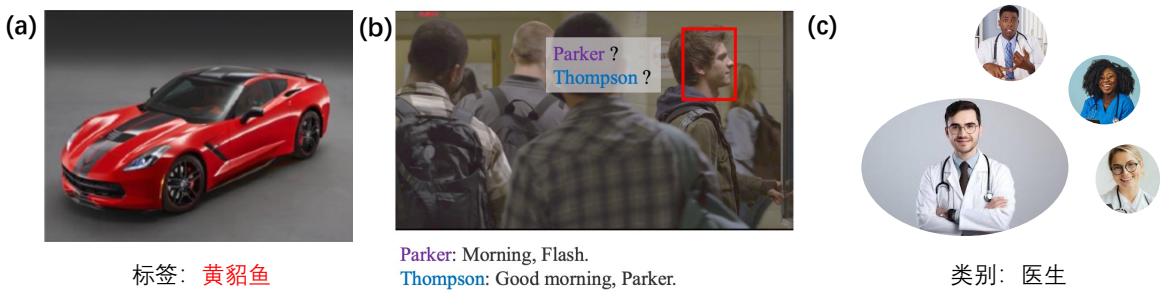


图 1.3　真实世界长尾数据面临的挑战：(a) 噪声标签，由语义多义性和网络爬取误差引起；(b) 标签歧义，源于弱监督或多模态场景中的对齐不确定性；(c) 类内隐式结构，粗粒度标签下存在高类内方差与隐含长尾子群体。

Figure 1.3　Key challenges in real-world long-tailed datasets: (a) Noisy labels caused by semantic polysemy and web-scale data collection; (b) Label ambiguity arising from uncertain alignment in weakly supervised or multimodal settings; (c) Implicit intra-class structures, where coarse-grained categories exhibit high variance and latent long-tailed subgroups.

第一是标注精确性条件。传统方法假设所有样本的类别标签均经过专家严格审定，不存在观测层面的误导。但在泛在场景下，长尾数据往往通过自动爬取或低成本众包获得，其中不可避免地混杂着噪声标签与歧义标签，如图 1.3(a,b) 所示。在这种监督信号退化的设定下，传统的重加权策略会产生严重的噪声放大效应。由于异常样本通常对应较高的损失值，盲目提升尾部权重会导致模型强行拟合错误的监督信号，从而引发性能崩塌。

第二是结构显性化条件。现有重平衡策略通常假设不平衡仅存在于显式的类别标签之间，而类内结构是同质且均衡的。然而在现实中，不平衡往往深入到由隐式属性定义的子群层面，如图 1.3(c) 所示。由于缺乏细粒度的子群标注，传统方法无法感知这种内部结构的非完备性。模型倾向于通过捷径学习来拟合头部子群的片面特征，导致尾部子群的泛化能力大幅受损，并由此引发算法公平性问题。

第三是任务单一化条件。目前长尾学习的研究重心长期局限于判别式分类任务，默认模型的目标是建模条件概率分布。随着人工智能向生成式范式演进，现有方法面临着无法直接迁移的困境。在长尾分布下，头部类别占据了绝大部分梯度空间，导致有限的模型容量被头部特征垄断。尾部类别由于缺乏有效的参数更新机会，无法建立准确的流形映射。这种模型容量分配不均的问题，本质上是任务建模条件在复杂生成需求下的非完备体现，无法通过简单的损失函数调整得到根本解决。

综上所述，现有的长尾学习范式在应对标签退化、隐式结构失衡以及生成式任务扩展时存在本质缺陷。如何打破上述理想化设定，构建面向条件非完备场景下的长尾

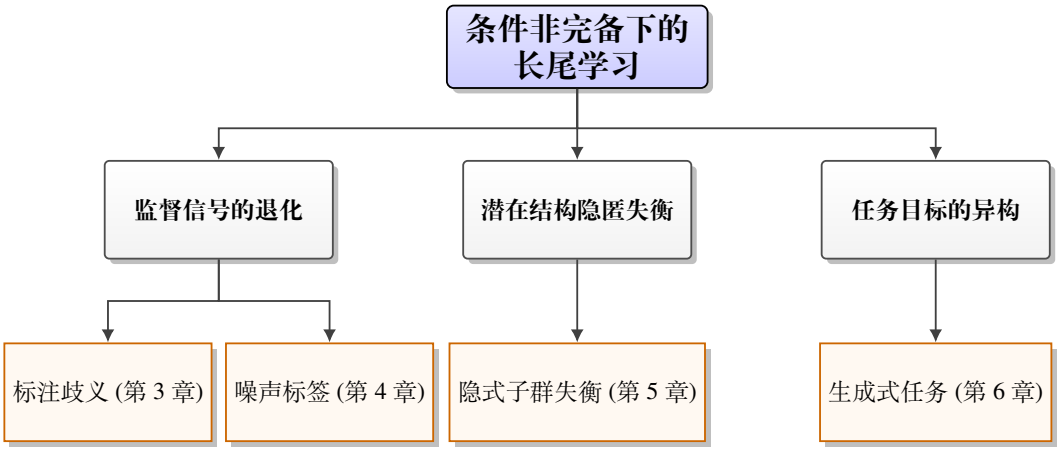


图 1.4 条件非完备下传统长尾学习方法有待解决的关键研究问题。

Figure 1.4 Key research challenges that remain unresolved for traditional long-tailed learning methods under incomplete conditions.

学习方法，是当前领域亟待突破的关键科学问题。

1.1.2 研究价值

本文针对条件非完备下的长尾数据环境开展深度学习算法研究，提出从数据分布校准到模型容量解耦的鲁棒学习方法。这是推动深度学习迈向通用化与可靠性研究的重要方向，具备显著的研究价值。

首先，条件非完备下的长尾学习算法可以提升模型在开放动态环境下的稳健性以及实际应用中的可靠性。随着人工智能技术的普及，其已广泛应用于医疗诊断、自动驾驶、金融风控等高风险领域。大量实践表明，现实世界的数据往往充斥着标签歧义、噪声干扰以及极端的不平衡分布，导致在理想离线环境下训练的模型在实际部署时面临严重的性能退化，对系统的安全性构成了潜在威胁。基于此，本研究提出的鲁棒学习算法能够显著降低深度学习系统对高质量标注数据的依赖，使其能够在含有噪声标签或偏标签的低质量数据中稳健学习。这不仅能够提升模型在处理自动驾驶极端边角案例或医疗罕见病诊断时的准确率，还能从策略上保障系统在面对未知分布时的稳定性，减少因尾部样本误判引发的安全事故。

其次，本研究可以加深学术界对于深度学习模型内部记忆与泛化机理的理解。在长尾学习被广泛关注之前，模型优化多集中于降低整体经验风险，往往忽略了模型内部的运作机制。例如，传统观点认为提升数据量即可解决问题，但本研究揭示了在长尾数据下，模型参数容量会被头部类别通过梯度主导效应所垄断，导致尾部特征无法被有效编码。这一发现促使研究视线从单纯的损失函数设计转向模型参数空间

的重构。此外，通过对隐式子群的挖掘研究，本研究发现仅通过显式类别标签进行监督是不够的，利用互信息等工具探索数据潜在结构对于提升模型的公平性至关重要。这些理论层面的探索揭示了深度神经网络在处理非均匀分布时的内在缺陷，为理解模型的容量分配机制与表征学习规律提供了新的思路。

最后，条件非完备下的长尾学习算法对于其他任务上模型的性能提升亦有裨益。最近的研究发现，通过鲁棒学习获得的特征表示具有更好的迁移泛化能力，能够更好地服务于预训练大模型的下游微调任务。此外，本文提出的参数容量解耦思想不仅适用于判别式模型，还可以扩展至生成式任务。在扩散生成模型中，长尾分布导致的模式崩塌一直是个难题，而基于容量操控的方法能够有效恢复生成内容的多样性与质量。沿着通用鲁棒性思路，诸多工作开始探索如何利用长尾学习技术解决多模态对齐、无监督学习以及算法公平性等问题，这已成为该领域的一个新的研究热点。

综上所述，本文提出的鲁棒学习算法在提升模型应对条件非完备偏倚能力的同时，还加深了对于深度学习参数分配与结构挖掘机理的理解，并且开阔了应用在生成式模型及大模型微调领域的新方法和新思路。

1.2　研究现状与挑战

1.2.1　问题描述

长尾学习的核心矛盾在于有偏观测与无偏期望之间的系统性错位。在理想的机器学习设定中，学术界通常假设训练数据与测试数据通过相同的机制采样。然而，条件非完备下的长尾学习要求模型完成一种类似反事实推断的任务，即模型必须根据在一个高度偏斜且可能被污染的分布 P_{train} 上观测到的有限样本，推断出在理想均匀分布 P_{ideal} 下的真实世界规律。

因此，本文的研究目标是构建一种鲁棒学习框架，使其能够从有偏、含噪且结构复杂的观测数据中，恢复出事物本质的语义结构与分布规律。

数据生成的因果建模。为了严谨地描述上述挑战，本研究首先定义数据生成的因果机制。设输入空间为 $\mathcal{X} \subseteq \mathbb{R}^d$，真实类别标签空间为 $\mathcal{Y} = \{1, \ldots, C\}$。本研究引入一个关键的潜在变量 $Z \in \mathcal{Z}$，代表数据内部的细粒度属性或隐式子群，例如物体姿态、背景环境等。现实世界的观测数据集 $\mathcal{D} = \{(x_i, \tilde{y}_i)\}_{i=1}^N$ 的生成过程可以由图 1.5（左上）所示的因果图描述。具体生成建模如下：

- **语义与属性采样**：自然界首先根据一个联合分布 $P(Y, Z)$ 采样出语义类别 y 和属性 z。长尾问题的根源在于该分布的先验极度不平衡，即对于某些 y 或 (y, z)

组合，采样概率 $P(y,z) \to 0$。

- **数据生成**：观测数据 x 由语义 y 和属性 z 共同决定，服从条件分布 $x \sim P(X|Y=y,Z=z)$。
- **观测退化**：标注者根据特征 x 给出的标签 $\tilde{y}$ 可能与真实标签 y 不一致。观测标签 $\tilde{y}$ 服从退化分布 $\tilde{y} \sim P(\tilde{Y}|X=x,Y=y)$。

传统理想化条件下长尾学习问题。传统长尾分类问题可以被视为上述因果模型的一个退化特例，如图 1.5 所示。它引入了三个强假设条件：

- **标注准确性条件**：$P(\tilde{Y}=y|X,Y=y)=1$，即观测标签 $\tilde{y}$ 恒等于真实标签 y。
- **结构显性化条件**：忽略潜变量 Z 的影响，假设 $P(X|Y)$ 足以描述数据特征，即 $P(X|Y=y,Z=z)=P(X|Y=y)$。
- **任务单一化条件**：仅关注判别式分类任务，即建模后验概率 $P(Y|X)$。

在此设定下，利用贝叶斯公式，判别模型的预测目标可以分解为：

$$\log P(Y|X) \propto \log P(X|Y) + \log P(Y) \tag{1.1}$$

其中 $P(X|Y)$ 为似然项，$P(Y)$ 为先验项。传统长尾算法如 Logit Adjustment 的通用解法在于修正先验项。由于训练集上的先验 $P_{\text{train}}(Y)$ 是有偏的，而测试集期望先验 $P_{\text{test}}(Y)$ 是均匀的，通过在对数概率上减去 $\log P_{\text{train}}(Y)$，即可实现从训练分布到测试分布的对齐。

条件非完备下的问题演进与本研究范畴。然而，在真实的开放环境中，传统长尾学习所依赖的标注准确、结构显性以及任务单一等理想化条件难以成立。本研究范畴不再局限于单一的类别分布对齐，而是深入探究当数据生成过程中的观测层面、结构层面以及任务层面发生本质质变时的鲁棒学习问题。这对应了三种更为通用的数学形式与更为严峻的科学挑战：

- **挑战一：观测层面的退化，标注质量的不确定性**。当观测标签 $\tilde{y}$ 不再可信时，首要挑战在于概率退化过程 $P(\tilde{Y}|Y)$ 的不可逆性。在现实数据集中，观测标签往往只是真实标签 y 的一个有偏估计，表现为候选集合对应的偏标签或错误类别对应的噪声标签。此时，传统的长尾先验修正方法将遭遇严重失效。这是由于传统方法假设观测分布能够反映真实的语义分布，从而依据观测频率对尾部样本进行重加权。然而，在存在噪声或歧义的场景下，尾部样本往往包含了大量高损耗的错误标注。盲目地基于观测频率提升尾部权重，实际上是在放大噪声信号的干扰，导致模型对错误标签过拟合。因此，本部分的核心难点在于如何在缺乏准确监督信号的条件下，同时推断真实标签的后验概率与真实的类别先验

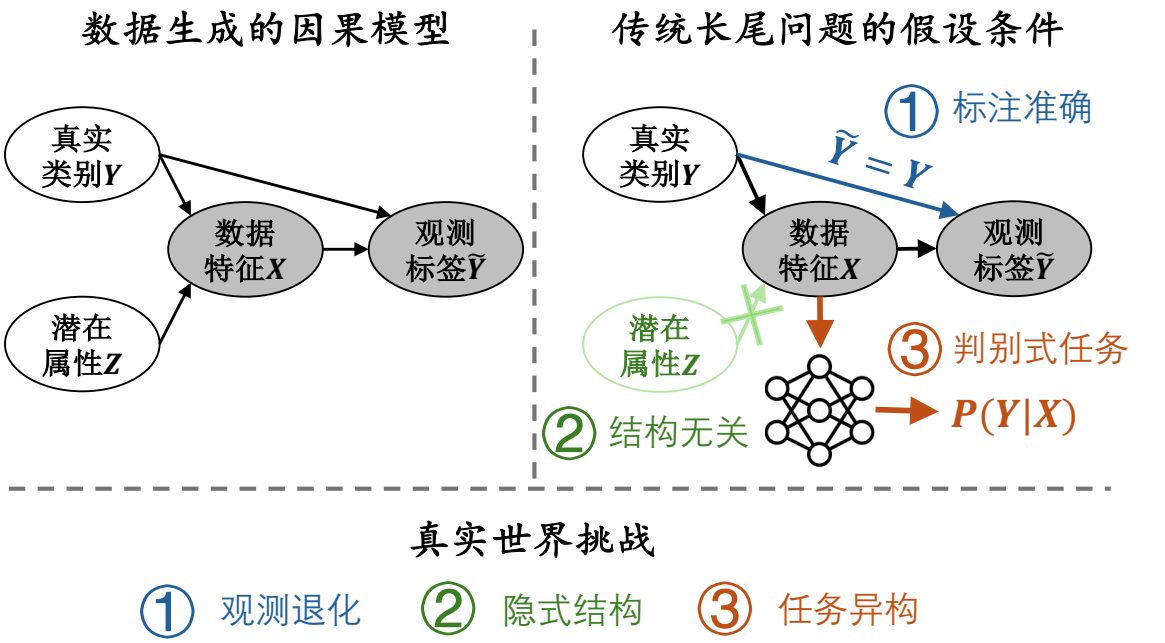


图 1.5　（左上）数据生成的因果模型。其中 Y 表示真实类别，Z 表示潜在属性，X 表示数据特征，$\tilde{Y}$ 表示观测标签。灰色节点表示可观测变量。（右上）展示了传统长尾学习方法隐含的三大理想化假设。（下方）列举了与之对应的真实世界挑战。

Figure 1.5　(Top-left) A causal model of the data generation process, where Y denotes the ground-truth label, Z the latent attribute, X the observed feature, and $\tilde{Y}$ the noisy label. Gray nodes indicate observable variables. (Top-right) Illustration of three key implicit assumptions underlying traditional long-tailed learning methods. (Bottom) The corresponding real-world challenges arising from these assumptions.

分布，从而在极低信噪比的环境中实现消歧与去偏的协同。

- **挑战二：结构层面的隐匿，隐式子群的分布失衡**。当不平衡深入到数据内部的潜变量 Z 时，核心挑战转变为隐式结构的挖掘与细粒度平衡。传统方法仅关注显式类别 Y 的分布，但在许多现实场景下，类别的粒度过粗，无法反映数据的真实流形结构。即使通过重采样使得显式类别分布达到均匀，条件分布 $P(Z|Y)$ 依然可能是极度长尾的，例如在医疗诊断数据中，特定种族或性别的子群样本可能远少于主导子群。这种隐式的结构失衡会导致虚假相关性的产生：由于潜变量 Z 在训练中不可观测，模型倾向于捕捉高频属性与标签之间的强相关性作为分类捷径，从而导致模型在低频属性子群上泛化失败。因此，本部分的核心难点在于如何在无监督条件下突破显式标签的限制，自动发现并逼近潜变量分布，将鲁棒性研究从类别级平衡推进到子群级平衡。

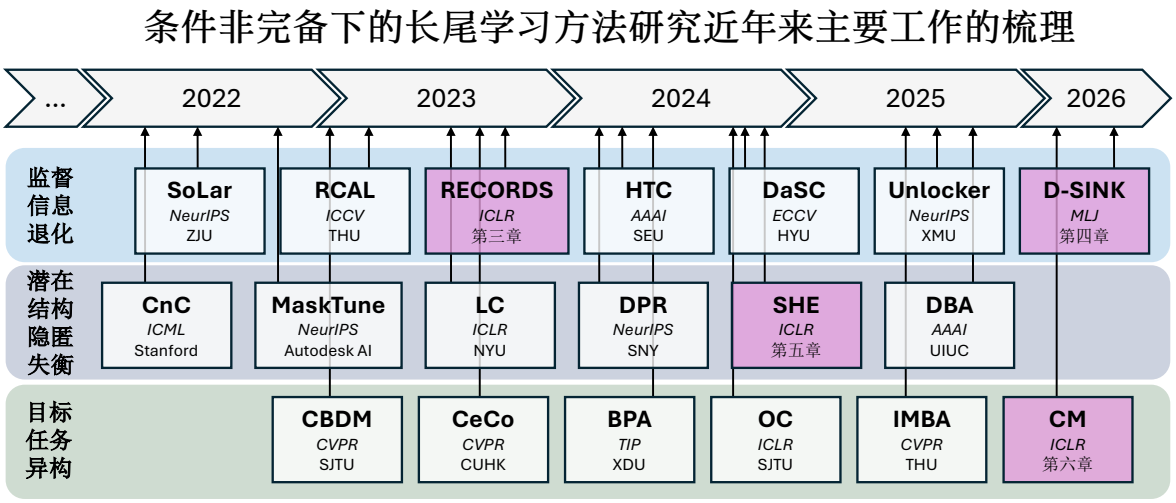


图 1.6 条件非完备下的长尾学习近年来主要的代表性工作梳理时间线图。

Figure 1.6 A timeline chart of the main representative works on long-tailed learning methods under incomplete conditions.

- **挑战三：任务层面的异构，构建从判别到生成的通用解**。当任务从判别式扩展到生成式时，面临的挑战是模型容量分配机制的失效。判别式任务主要建模后验概率 $P(Y|X)$，通过调整损失函数边界即可缓解偏差；而生成式任务旨在直接建模高维似然分布 $P(X|Y)$，这对模型特征覆盖能力提出了更高要求。在长尾训练数据下，由于头部类别的样本数量远多于尾部，模型参数的更新梯度会被头部数据所主导。这意味着模型的有限容量被头部的高频特征所垄断，导致模型无法有效编码尾部的低频特征。这不仅影响分类精度，更直接导致生成的图像在尾部类别上出现严重的模式崩塌或质量退化。仅仅调整先验分布无法改变参数被头部主导的事实。因此，本部分的核心难点在于如何提出一种跨任务的通用范式，在模型优化的底层机制上抵抗长尾分布带来的梯度主导效应，实现模型容量在头尾类别间的公平分配。

综上所述，本研究不仅是对传统长尾算法的修补，而是试图构建一个涵盖非确信监督、隐式结构推断以及跨任务通用的统一鲁棒学习框架。

1.2.2 研究现状概述

长尾学习作为解决真实世界数据分布不平衡问题的关键技术，在学术界与工业界得到了广泛探讨。从早期的重采样策略到如今面向条件非完备下的长尾学习，该领域的算法探索已历经显著演进。纵观其发展历程，相关研究主要沿着显式分布对齐、监督质量校准、潜在结构挖掘以及生成式范式拓展四个维度展开，形成了一个从基础

任务向条件非完备下逐步深入的技术体系。

首先，针对显式类别不平衡的通用长尾学习方法已建立起较为完善的理论基础。早期的研究主要聚焦于数据层面的重采样与目标层面的重加权思路。重采样方法通过过采样尾部或欠采样头部来平衡观测分布[40]，而重加权方法则通过赋予尾部样本更高的损失权重来校准优化目标[41]。然而，单纯的分布平衡往往导致深度模型在表征学习阶段出现退化。针对这一问题，已有工作发现了表征学习与分类器学习的解耦特性，并提出了双阶段训练范式[30]。此后，以 Logit Adjustment 为代表的统计校准方法通过在对数几率层面引入类别频率先验，实现了理论上的一致性补偿[42]。尽管此类方法在标准基准数据集上取得了进展，但其有效性高度依赖于标注准确且属性均衡的理想化假设，难以直接适配条件非完备下的观测偏倚。

其次，条件非完备下中普遍存在的标签退化问题，研究重心开始转向长尾分布下的抗噪与消歧学习。随着应用环境的真实化，研究者发现长尾数据往往伴随着严重的标签噪声或标签歧义。在这些条件非完备下，传统的长尾策略面临失效风险，例如盲目提升尾部权重会错误放大噪声信号，进而导致模型对错误监督信号的过拟合。针对长尾噪声学习任务，早期的尝试通常简单组合去噪与重平衡算法，但往往因目标冲突而难以取得理想效果。随后，基于样本筛选的方法尝试通过损失分布特征区分难样本与噪声样本[27,43]。对于具有歧义的偏标签学习任务，近期的工作探索了如何在长尾分布下进行渐进式消歧[44]。然而，如何在缺乏准确先验的情况下动态协调分布估计与标签校准，仍是当前研究的难点。

为了解决显式类别监督下的泛化局限，学术界开始关注隐式子群的结构失衡问题。随着对算法公平性与虚假相关性的深入研究，研究者发现即便实现了显式类别的平衡，模型仍可能对类内特定的属性子群产生偏见。分布鲁棒优化方法成为了该方向的基础，旨在提升模型在最差子群上的表现[45]。针对子群标签未知的挑战，部分研究提出了基于错误样本挖掘或环境推断的无监督子群发现算法[46-47]。这些工作标志着长尾学习的研究粒度从粗糙的类间平衡向精细的类内几何平衡演进。但在极度不平衡且缺乏细粒度先验的条件非完备下，如何精准定位并平衡隐式长尾子群依然具有挑战性。

最后，随着人工智能从判别式向生成式演进，长尾学习的研究范畴正迅速扩展。在扩散模型等生成范式中，长尾分布导致的模式崩塌与语义退化问题日益凸显。由于生成模型旨在拟合完整的数据流形，头部类别对模型容量的垄断效应比判别模型更为严重。近期的探索尝试将重加权策略迁移至去噪损失函数中[48]，或利用检索增

强手段补充尾部信息。然而，现有的改进多停留在损失函数的表面调整，尚未触及模型参数空间的容量分配机制。如何在统一的框架下打破头部类别对模型容量的垄断，实现对尾部概念的高保真生成，已成为条件非完备下长尾学习的新兴研究热点。

1.2.3 主要挑战

基于上述条件非完备下的问题演进，本研究在构建统一的鲁棒学习框架过程中，面临着三个维度下的具体技术挑战。这些挑战揭示了现有技术在处理耦合偏倚时的局限性，也是本文各个创新点的切入点。

（一）观测层面退化引发的优化目标冲突与过程失配

在处理标注质量不确定性时，核心挑战在于如何在长尾分布与标签不确定性的双重干扰下，找到一致的优化方向。

- 消歧过程与静态先验的失配。当监督信号退化为偏标签场景时，本研究面临长尾偏标签学习任务。标签消歧是一个随着训练进行且置信度逐渐提升的动态过程。然而，传统的长尾算法通常依赖于一个静态的、基于训练集统计的先验分布进行重加权。核心挑战在于，强行引入静态的偏置修正会破坏早期的消歧过程，导致模型在未能确认真实标签之前就过早地对尾部类别产生了错误的置信度，从而引发消歧崩塌。如何在缺乏真实分布先验的情况下动态地协同消歧进程与分布估计，是本文需要解决的首要问题。
- 长尾去偏与噪声过滤的目标冲突。当监督信号退化为噪声标签场景时，本研究面临长尾噪声标签学习任务。长尾学习与噪声学习的优化目标存在天然的对抗性。长尾方法倾向于提升高损失值的尾部样本权重以强化学习，而噪声学习方法倾向于降低高损失值的样本权重以过滤噪声。核心挑战在于，尾部样本与噪声样本在损失特征上呈现出高度的不可分性。盲目地应用长尾策略会放大噪声，而盲目应用去噪策略会抹杀尾部样本。如何在一个统一框架下同时实现对分布的去偏和对样本的去噪，是打破这一死循环的关键。

（二）结构层面隐匿导致的无监督挖掘难度与非语义关联

在处理隐式结构复杂性时，核心挑战在于如何在完全缺乏细粒度监督信号的前提下，打破主导性的非语义关联。传统细粒度鲁棒学习通常假设子群标签已知，但在现实中获取这些标签是不切实际的。当数据存在隐式属性偏倚时，模型极易通过捷径学习拟合高频的非语义特征，并忽略低频子群的关键特征。核心挑战在于，在没有细粒度标签指引的情况下，如何定义并挖掘出那些类别语义一致但属性分布各异的潜在子群。如何在挖掘过程中避免模型坍缩到平凡解，并针对挖掘出的隐式结构进行有

效的重平衡，是实现细粒度鲁棒性的核心难点。

（三）任务层面异构下的通用解法构建与底层机制重构

在将长尾学习的研究范畴从判别式任务扩展至生成式任务的过程中，核心挑战在于如何突破特定任务形式的束缚，构建一套能够跨越不同数学优化目标的通用鲁棒解法。长期以来，主流长尾算法遵循以损失值为中心的范式，试图通过重加权或边界调整来平衡梯度。然而，这种表层的修补策略在面对异构任务时往往失效，甚至在生成任务中引发训练震荡。为了克服这一局限，必须将视角落脚于深度学习优化的底层共性，即模型容量的分配机制。无论是判别还是生成，长尾学习的根本病灶均在于梯度主导现象，即头部类别的梯度更新长期垄断了有限的参数容量，导致尾部特征因缺乏独立的参数空间支持而被淹没。因此，本维度的最大挑战转化为，如何跳出对具体损失函数的依赖，设计一种结构化的参数容量解耦机制，在不增加推理成本的前提下显式地为尾部类别预留独立的特征表达空间，从而从参数优化的根源上构建适用于各类异构任务的通用鲁棒范式。

1.3　主要贡献及组织结构

基于上述对复杂场景下的鲁棒长尾学习中数据偏倚耦合、隐式结构复杂及任务目标异构等核心挑战的分析，本文旨在打破传统方法对理想化数据分布及固定任务形式的依赖，构建一套从分布校准到模型重构的通用鲁棒长尾学习框架。结合相关领域近五年来的代表性工作，图 1.6 从标注不确定性、隐式结构复杂性及任务拓展性三条并行的技术路线进行了梳理，并给出了本文中的工作在整个领域中的具体逻辑定位。

1.3.1　本文主要贡献

针对传统长尾学习范式在条件非完备下的局限性，本研究从观测层面的信号校准、结构层面的隐式挖掘以及任务层面的容量重构三个维度出发，构建了鲁棒长尾学习框架。本研究的主要贡献概括如下：

- **针对观测层面标注精确性假设失效引发的消歧崩塌挑战，提出了基于动量原型动态校准的长尾偏标签学习方法（RECORDS）**。传统方法依赖于标注准确的理想化条件，但在偏标签场景下，静态的先验分布统计会误导动态的消歧过程。本研究通过理论推导揭示了消歧置信度与分布偏差之间的动态耦合关系，并设计了无需预知先验的动态分布估计算法。该算法利用动量原型实时捕捉类别分

布的演变过程，实现了消歧与去偏的深度协同，有效解决了标签歧义带来的鲁棒性难题（第 3 章）。

- **针对观测层面标注精确性假设失效引发的噪声放大挑战，提出了基于双粒度最优传输蒸馏的长尾噪声学习方法（D-SINK）**。在长尾分布与噪声标签并存的条件非完备下，提升尾部权重的去偏目标与降低高损耗样本权重的去噪目标存在本质冲突。本研究摒弃了简单的损失调整思路，构建了基于最优传输技术的双粒度蒸馏框架。通过在分布粒度上引入全局长尾先验约束，同时在样本粒度上利用几何对齐机制过滤噪声信号，本研究在统一框架下实现了去偏与去噪的兼顾，显著提升了模型在含噪长尾数据上的泛化性能（第 4 章）。
- **针对结构层面结构显性化假设失效引发的捷径学习挑战，提出了基于互信息最大化的无监督子群挖掘与平衡算法（SHE）**。传统方法假设不平衡仅存在于显式类别间，忽略了由潜变量定义的隐式子群失衡。本研究打破了对显式标签的依赖，转而利用信息论工具探索数据的内在流形结构。通过最大化输入特征与划分变量之间的互信息，该算法能够自动发现语义一致但属性分布各异的隐式子群。通过在子群层面实施自适应重平衡策略，本研究成功抑制了模型对高频非语义特征的过度拟合，增强了模型在隐式结构失衡下的稳健性（第 5 章）。
- **针对任务层面任务单一化假设失效引发的模型容量垄断挑战，提出了基于参数空间解耦的通用重平衡范式（CM）**。传统长尾学习主要面向判别式任务，难以解决生成式任务中头部类别对模型参数容量的垄断问题。本研究跳出了以损失函数为中心的传统范式，从深度学习优化的底层机制入手，提出了通用的参数空间解耦策略。通过将模型权重显式分解为通用共享模块与尾部专用模块，本研究在不增加推理成本的前提下为尾部概念预留了独立的特征表达空间。该范式在判别式分类与生成式扩散模型中均表现优异，验证了通过容量重构实现跨任务通用鲁棒性的可行性（第 6 章）。

1.3.2 本文组织结构

本文围绕条件非完备下的长尾学习这一核心命题，遵循由表及里以及由具体到通用的逻辑思路，从数据观测层面的信号校准、潜在结构层面的隐式挖掘，逐步深入到模型范式层面的容量重构。全文共分为七章，各章节的具体安排与逻辑关系如下（如图 1.7 所示）：

- **第 1 章：绪论**。本章首先阐述了长尾学习在深度学习迈向通用化与可靠性过程中的研究背景与重要意义。随后，本章深入剖析了现有长尾学习范式在面对真

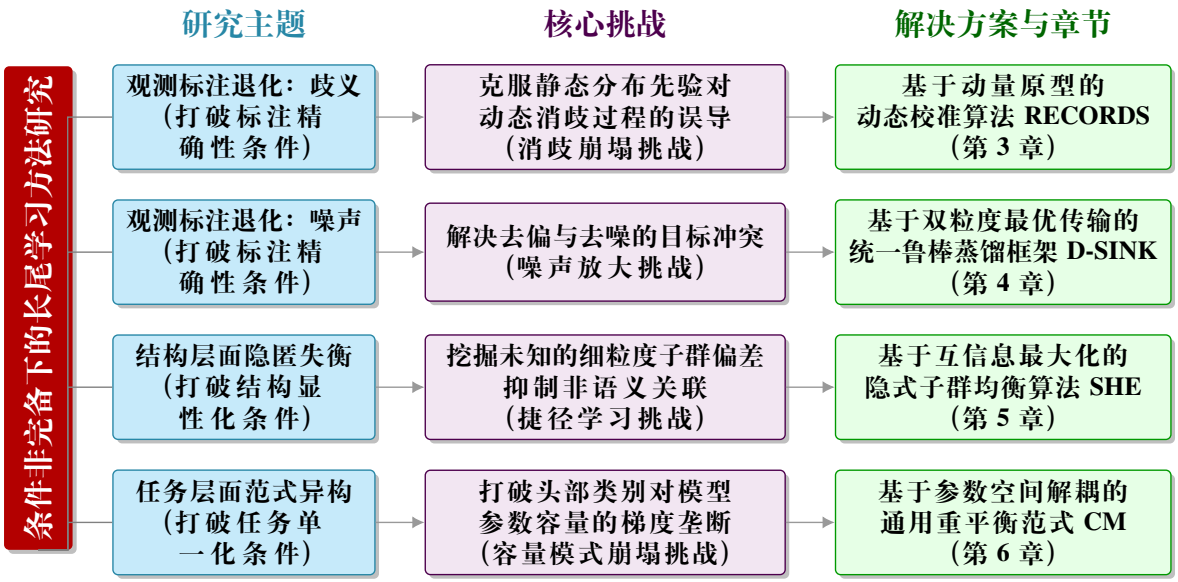


图 1.7　本文组织结构的梳理。具体从研究主题、面临的核心挑战以及提出的解决方案三个角度，展示各章节在条件非完备下长尾学习的逻辑关系。

Figure 1.7　Overview of the paper organization. The figure illustrates the logical progression across chapters from research themes and core challenges to proposed solutions under incomplete conditions.

实世界条件非完备下时，因标注退化、结构隐匿及任务异构而面临的局限性。在此基础上，本研究定义了条件非完备下长尾学习的关键科学问题，梳理了国内外研究现状，并概括了本文的研究内容、核心贡献及组织架构。

- **第 2 章：相关研究综述**。本章对长尾学习领域的研究现状进行系统梳理。本章首先回顾了数据重平衡、模型解耦及目标加权等通用长尾学习范式。随后本研究从标签退化、结构隐匿以及任务异构三个维度，深入剖析了现有方法在条件非完备下的局限性，从而明确了本文后续各研究章节的切入点与技术演进路径。
- **第 3 章：基于动量原型动态校准的长尾偏标签学习**。针对观测层面标注精确性条件失效导致的歧义场景，本章探讨了如何克服静态长尾先验对动态消歧过程的误导。本研究分析了传统方法导致的消歧崩塌现象，提出了一种基于动量原型的动态分布估计算法。该方法能够在无需预知真实分布的前提下实时捕捉类别分布的演变，解决了条件非完备下消歧置信度与分布偏差的协同难题。
- **第 4 章：基于双粒度最优传输蒸馏的长尾噪声标签学习**。针对观测层面标注精确性条件失效导致的噪声场景，本章探讨了如何解决长尾去偏与噪声过滤在优化目标上的内生冲突。本研究指出盲目提升尾部权重会引发噪声放大效应，并提出了基于最优传输的统一抗噪框架。该方法通过构建双粒度蒸馏机制，成功

在极低信噪比的长尾数据中恢复了模型的泛化能力。

- **第 5 章：基于互信息最大化的隐式子群均衡学习**。针对结构层面结构显性化条件失效导致的隐式偏差场景，本章探讨了如何在无监督条件下挖掘潜在的结构性失衡。本研究提出了一种基于互信息最大化的子群发现算法，利用信息论工具自动发现语义一致但分布各异的隐式子群。通过自适应聚合策略实现子群层面的平衡，本研究突破了传统方法仅能处理显式类别偏差的局限。
- **第 6 章：基于参数空间解耦的跨任务通用长尾学习**。针对任务层面任务单一化条件失效导致的任务异构挑战，本章旨在构建适用于判别式与生成式任务的通用解法。本研究从模型优化的底层机制入手，提出了一种参数空间解耦范式。通过显式重构模型容量分配机制，该方法有效解决了生成模型在长尾数据下的模式崩塌问题，验证了底层容量重构在解决梯度垄断方面的通用性。
- **第 7 章：总结与展望**。本章对全文的研究工作与创新点进行了系统总结。立足于当前人工智能发展的前沿趋势，本研究从开放世界持续学习以及大模型鲁棒对齐等角度，对条件非完备下的长尾学习未来的研究方向进行了深入展望。

第 2 章 研究现状

本章对长尾学习（Long-Tailed Learning, LTL）领域的研究现状进行系统梳理与深入探讨。随着深度学习在计算机视觉与模式识别领域的广泛应用，如何处理现实世界中普遍存在的长尾分布数据已成为学术界与工业界关注的焦点。理想条件下的长尾学习方法通常建立在标注准确、结构显式以及任务单一这三大理想化假设条件之上，通过显式的分布对齐策略在标准基准数据集上取得了显著成效。然而，当本研究将视野拓展至条件非完备下的现实应用时，数据生成过程往往伴随着多维度的退化与异构挑战，这使得传统范式面临着严峻的鲁棒性危机。

为了全面厘清条件非完备下的长尾学习技术的发展脉络，本章首先回顾理想条件下的经典长尾学习范式，随后分别从监督信号退化、潜在结构隐匿以及生成任务拓展三个维度，深入剖析相关领域的研究现状与未决挑战。本章的组织结构安排如下。

首先，第 2.1 节依据数据、模型、目标三个层面，简要回顾理想条件下的长尾学习经典方法，包括重采样与合成、解耦学习与专家集成、以及损失重加权与 Logit 调整等技术，确立长尾学习的基础理论框架。

随后，本章重点探讨现有方法在条件非完备下的演进与局限。

- **针对监督信号退化的研究**。第 2.2 节聚焦于标注退化场景。现实世界的长尾数据往往伴随着标签歧义与噪声干扰。本节分别综述偏标签学习与噪声标签学习在长尾分布下的研究现状，探讨现有方法在处理重平衡与去噪消歧双重目标时面临的内生冲突。
- **针对潜在结构隐匿失衡的研究**。第 2.3 节聚焦于结构隐匿场景。现实数据的不平衡往往深入到类内的隐式子群，例如属性偏倚或背景偏差。本节梳理分布鲁棒优化相关工作，重点分析在缺乏细粒度监督信号的条件下，现有无监督子群挖掘方法在长尾分布下的局限性。
- **针对生成任务拓展的研究**。第 2.4 节聚焦于生成式任务场景。随着人工智能从判别式向生成式演进，长尾分布对模型容量分配带来了新的挑战。本节探讨生成对抗网络与扩散模型在长尾数据下的失效模式，特别是头部类别对模型容量的垄断现象及现有的重平衡策略。

最后，第 2.5 节对本章进行小结。通过对比现有技术路线，系统性地指出当前研究在应对条件非完备下的耦合偏倚时存在的盲区，从而引出本文后续章节拟解决的

关键科学问题与技术路线。

2.1　理想条件下的长尾学习方法研究

长尾学习旨在解决训练数据服从长尾分布时的模型训练问题，即在保证头部类别性能的同时，显著提升尾部稀缺类别的识别精度[49-50]。在理想条件下，长尾学习的方法论可以从数据均衡、神经网络架构设计、特征增强、Logit 调整以及损失函数设计等多个维度进行分类[50]。本节依据这一分类体系，从数据、模型、目标三个核心层面，对现有的理想条件下的长尾学习方法进行梳理与回顾。

2.1.1　数据层面的重平衡与合成

数据层面的方法旨在通过改变训练样本的分布或数量，直接缓解长尾分布带来的极度不平衡问题。这类方法主要包括数据重采样、数据增强以及数据合成。

数据重采样是处理不平衡数据的经典策略，主要分为类级重采样[30]和实例级重采样[51]。类级重采样通常通过对尾部类别进行过采样或对头部类别进行欠采样来实现[52]。然而，简单的随机过采样容易导致尾部类别的过拟合，而随机欠采样则可能丢失头部类别的关键信息[30]。相关研究表明，当训练样本与目标标签高度语义相关时，类平衡采样有助于学习判别性特征；反之，在特征提取阶段，随机采样往往优于类平衡采样[53]。此外，为了进一步提升模型对难样本的学习能力，部分研究引入了难例挖掘机制，通过挖掘被误分类的尾部样本或被错分为尾部的其他样本来扩大类别间的决策边界[54-57]。

除了调整样本数量，数据增强技术通过变换操作扩充训练数据规模，在长尾学习中扮演着重要角色。除了传统的图像变换，基于混合的增强方法如 Mixup[58] 和 CutMix[59] 被广泛应用。为了适应长尾场景，研究者提出了偏向尾部的变体，例如 Remix[60] 通过向少数类分配更高的混合系数来生成标签，而 UniMix[61] 则采用逆采样策略鼓励头部与尾部样本的配对。此外，CMO 方法[62] 通过将尾部样本粘贴到富含上下文信息的头部样本背景上，有效丰富了尾部类别的语义多样性。有研究[63]指出，现有数据增强方法往往伴随一定的负面影响，可能导致部分类别性能下降。为此，相关学者提出了 DODA 方法，通过对比相邻两个周期中各类别被正确预测样本数量的变化，动态地为不同类别维护数据增强偏好策略。

在数据合成方面，相较于基础的增强技术，该类方法利用更复杂的生成模型或分布估计技术来构造全新的尾部样本。部分研究基于分布迁移的思想，假设头部和尾部

类别共享某些几何特征或分布属性。例如，RSG[43] 通过计算头部样本与其类中心的位移，并将该位移施加于尾部样本以生成新样本；LEAP[64] 则构建各类别的特征高斯分布，并将头部类别的平均方差迁移至尾部类别，从而扩充尾部特征空间的分布范围。近年来，随着大模型的兴起，利用预训练的基础模型[65-68]进行数据生成也成为一种新趋势。通过生成多样化的尾部图像并利用 CLIP[18] 等模型进行筛选，可以显著补充尾部数据的匮乏[69]。

2.1.2 模型层面的解耦与增强

在模型架构层面，研究发现特征表示学习与分类器学习在长尾分布下存在不同的最佳优化策略，从而推动了解耦学习、多专家集成以及特征增强等技术的发展。

解耦学习范式的核心观点在于，长尾分布主要损害分类器的决策边界，而非特征提取能力。经典工作[30] 提出将学习过程分为两个阶段。第一阶段利用实例均衡采样训练骨干网络以学习通用特征，第二阶段冻结骨干网络，利用类均衡采样微调分类器。为了平滑连接这两个阶段，BBN[70] 设计了双分支网络结构，通过累积学习适配器逐渐从学习全局特征的常规分支过渡到关注尾部数据的重平衡分支。类似地，Hybrid-SC[71] 结合了监督对比学习分支与常规分类分支，通过特定的课程学习策略实现特征与分类器的联合优化。

多专家集成学习通过训练多个模型并聚合其预测结果，以降低模型的方差并提升泛化能力。RIDE[72] 训练多个具有不同分布感知能力的专家，并引入路由机制以动态选择专家组合。ACE[73] 则采用分治策略，通过层级化地移除头部类别来训练一系列互补的专家分类器，使得中尾部类别在特定专家中占据主导地位，从而同时兼顾头部与尾部性能。此外，NCL[74] 和 SHIKE[75] 引入了知识蒸馏技术，促进不同专家之间的知识交互，使得浅层特征与深层特征能够协同提升模型对尾部类别的识别能力。SADE[76] 通过分化三种分别擅长头部类别、尾部类别和均匀分布的专家模型进行集成学习，从而增强模型对于所有类别的识别能力。

特征增强方法致力于直接改善尾部样本的特征表示质量。这类方法通常利用外部记忆模块或预训练模型来增强或补充特征。例如，RAC[77] 维护一个显式的视觉记忆库，在推理时检索相似的尾部特征以增强当前输入。OLTR[27] 则结合了常规特征与记忆特征，以诱导头部到尾部的知识迁移。此外，基于大模型的特征增强策略利用 CLIP 等多模态模型的丰富语义先验，通过提取图像的文本描述或深层语义特征，弥补尾部样本视觉信息不足的缺陷[78]。

2.1.3　目标层面的重加权与校准

设计合理的损失函数或调整 Logit 输出是缓解长尾偏差的直接手段，其核心在于重新平衡不同类别或样本在优化过程中的贡献。

损失重加权主要包括类级重加权和实例级重加权。类级方法如 CB Loss[41] 基于有效样本数而非绝对样本数来计算类别权重，以更准确地反映类别的不平衡程度。实例级方法则关注样本的学习难度，如 Focal Loss[79] 通过降低易分类样本的权重来关注难样本。针对长尾场景下的梯度统计特性，Seesaw Loss[80] 动态平衡正负样本的梯度，在对误分类样本施加惩罚的同时，减少对尾部类别的过度抑制。此外，EFL[81] 进一步考虑了正负梯度累积比率，以解决长尾目标检测中的前景背景不平衡问题。

Logit 调整与边界学习方法旨在通过修正神经网络的输出值来优化决策边界。研究表明，在长尾分布下训练的模型，其权重范数往往与类别频率呈正相关，导致决策边界偏向头部类别[82]。为了校准这种偏差，Logit Adjustment[42,83] 提出在训练或推理阶段根据类别的先验概率对 Logit 值进行修正，从理论上保证了 Fisher 一致性。LDAM Loss[84] 则通过在 Softmax 函数中引入与类别频率相关的边界，强制模型为尾部类别学习更紧凑的类内分布和更宽的类间边界。此外，EQL[85] 和 GCL[86] 等方法通过抑制头部类别的负梯度或引入高斯扰动，进一步平滑了不同频次类别间的 Logit 分布差异。

综上所述，现有的理想条件下的长尾学习方法在数据增强、模型解耦与目标函数设计等方面已取得了显著进展。然而，这些方法大多基于标注准确以及结构显式这两大理想化假设条件。在实际应用中，长尾数据往往伴随着标注退化以及隐式属性偏倚等条件非完备。现有的理想条件下的方法在面对这些复合挑战时，往往因缺乏针对性的鲁棒机制或细粒度挖掘能力而难以达到预期性能。

2.2　面向退化监督信号的长尾学习方法

前文所述的理想条件下的长尾学习方法，大多建立在训练数据拥有准确且确定的监督信号这一假设之上。然而，在真实世界的非完备条件下，数据采集与标注过程往往受到成本限制或专业知识匮乏的影响，导致获取的标签质量参差不齐，出现了标签退化现象。这种退化主要表现为标签的歧义性与噪声性。当长尾分布与标签退化发生耦合时，理想条件下的长尾学习方法因过度依赖准确的类别先验分布而难以奏效，同时，常规的弱监督学习方法也因忽视了尾部类别的极度稀缺性而导致性能崩溃。本节将分别从标签歧义与标签噪声两个维度，深入探讨相关领域的研究现状。

2.2.1 标签歧义下的长尾学习研究

偏标签学习（Partial Label Learning, PLL）是解决标签歧义问题的核心范式。在该设定下，每个训练样本对应一个候选标签集合，该集合包含真实的地面真值标签以及若干个干扰标签，但具体的真值标签对模型而言是不可见的[87]。

2.2.1.1 通用偏标签学习方法综述

通用的偏标签学习旨在从候选集合中消解歧义并恢复真实的监督信号。根据处理策略的不同，现有研究主要可分为基于平均的策略与基于辨识的策略[87]。

基于平均的策略采取一种直观假设，即同等对待候选集合中的所有标签，将其视为真值的可能性均等。早期的经典工作如 CLPL[88] 和基于近邻的方法[89] 均采用了此类思想，通过聚合候选标签的输出或近邻信息进行预测。尽管此类方法计算简便且在理论上具备一定的风险一致性[88]，但其最大的弊端在于无法有效抑制候选集合中干扰标签的负面影响。当干扰标签占比较高时，模型的预测结果极易被误导，导致判别能力显著下降。

相比之下，基于辨识的策略将真实的标签视为潜在变量，试图在训练过程中迭代地识别出唯一的真值标签。这一过程通常被称为消歧。早期的尝试主要基于最大似然准则或最大间隔准则。例如，Jin 等人[90] 引入了期望最大化算法来迭代估计潜在标签的分布，Liu 等人[91] 则通过变分推断来最大化似然函数。近年来，随着深度学习的发展，基于深度特征的消歧方法逐渐成为主流。这类方法通常利用图像特征的相似性或聚类特性来指导标签的筛选。例如，PRODEN[92] 和 LWS[93] 采用自训练机制，根据模型的实时预测置信度逐步更新候选标签的权重，PiCO[94] 则创新性地引入了对比学习框架，利用引入原型的对比损失来增强特征的判别性，从而辅助标签消歧。

2.2.1.2 条件非完备下的消歧与重平衡冲突

尽管通用偏标签学习在类平衡数据集上取得了显著进展，但在条件非完备的长尾分布场景下，其性能面临严峻挑战。这种挑战主要源于消歧与重平衡两个目标的内在冲突。

首先，长尾分布破坏了消歧过程的公正性。在偏标签设定下，由于缺乏明确的真值标签，模型无法直接统计各类别的真实样本数量，导致先验分布处于不可知状态。现有的消歧算法往往倾向于信任模型的高置信度预测，而在长尾分布下，模型天然对头部多数类表现出过度的自信。这导致尾部样本的真实标签极易被错误地消歧为头部类别，进一步加剧了数据的不平衡程度。

其次，现有的长尾重平衡策略难以直接迁移至偏标签场景。如前文所述，主流的重采样或 Logit 调整方法均依赖于精确的类别频率统计。在偏标签场景中，直接利用候选标签进行统计会引入巨大的偏差。针对这一问题，学术界的探索尚处于起步阶段。例如，Wang 和 Zhang[95] 曾尝试结合过采样策略来缓解不平衡问题，但其基于近邻的消歧方式在大规模高维数据上难以适用。

近年来，针对条件非完备下的深度偏标签长尾学习任务的研究开始涌现。SoLar[44] 提出了一种基于最优传输的解决方案，利用 Sinkhorn-Knopp 迭代算法在约束条件下估计类别先验并指导标签消歧。然而，该方法不仅引入了较高的计算复杂度，且需要引入额外的外部循环来迭代优化先验分布，训练过程不够端到端。此外，部分研究试图通过约束参数空间或引入特定正则化项来隐式缓解不平衡[96]，但在处理极端长尾分布时效果有限。综上所述，现有的研究仍存在显著局限，特别是缺乏对尾部类别的保护机制，导致模型容易陷入头部垄断的陷阱。

2.2.2　标签噪声下的长尾学习研究

除了标签歧义外，另一种更为普遍的条件非完备是标签噪声。在基于网络爬虫或众包平台的大规模数据集构建过程中，不可避免地会引入错误的标注信号。噪声标签学习旨在减轻这种标签腐败对模型训练的负面影响。当数据同时呈现长尾分布与标签噪声时，本研究面临着样本稀缺与标注错误的双重挑战。

2.2.2.1　通用噪声鲁棒学习方法

针对通用场景下的噪声标签问题，现有研究主要可以归纳为转移矩阵估计、鲁棒正则化以及样本筛选三大类技术路线。转移矩阵估计试图从统计学的角度对噪声进行建模，其核心思想是估计标签从真实类别翻转为噪声类别的概率。早期的经典工作[97] 率先提出了通过估计噪声转移矩阵来校正损失函数的方法。为了解决估计过程中的不稳定性问题，VolMinNet[98] 提出了一种体积最小化网络，通过约束转移矩阵的体积来从噪声数据中恢复潜在的真实标签分布。

鲁棒正则化技术旨在通过施加约束防止模型对噪声标签过拟合。由于深度神经网络具有极强的记忆能力，极易记住错误的噪声标签。为此，SURE[99] 结合了最大熵原理与锐度感知最小化[100]，有效提升了模型的泛化边界。样本筛选是目前处理噪声标签最为有效且主流的策略。该类方法通常基于小损失假设[101-102]，即模型倾向于优先拟合清洁样本，而噪声样本往往具有较高的损失值。DivideMix[102] 是一种具有代表性的方法，它利用高斯混合模型对训练样本的损失分布进行建模，将数据动态划分

为清洁集与噪声集。

2.2.2.2 去噪与重平衡的冲突

尽管上述方法在类平衡的噪声数据集中取得了显著成效，但在条件非完备的长尾场景下，理想条件下的重平衡逻辑与噪声标签学习的去噪逻辑之间存在着本质的目标冲突。

这种冲突主要源于对高损失样本的处理逻辑相互矛盾。在长尾学习中，尾部样本由于数量稀缺且模型难以拟合，通常表现为高损失的难例。理想条件下的方法通常主张保留并对这些难例进行重加权或过采样。然而，在噪声标签学习中，高损失样本通常被判定为噪声，相关方法倾向于将其丢弃或降低权重。当两者耦合时，若采用去噪策略，珍贵的尾部难例极易被误判为噪声而被剔除，导致尾部性能崩溃，反之，若采用重加权策略，真实的噪声样本会被赋予更高的权重，从而加剧模型对错误信号的过拟合。

针对这一棘手的耦合问题，近年来涌现了专门面向长尾噪声场景的研究。Lu 等人提出了一种两阶段的双维度样本筛选机制 TABASCO[103]，试图在不平衡的数据分布中定位噪声。HAR[104] 和 RoLT[105] 利用自适应正则化与原型误差检测技术，试图在缓解标签噪声的同时保留尾部特征。此外，MW-Net[106] 引入元学习思想，通过元网络动态学习样本权重，以期在去噪与均衡之间找到平衡点。RCAL[107] 则尝试利用对比学习获取鲁棒表征，并通过分布校准来恢复清洁数据的统计特征。

综上所述，现有的长尾噪声学习方法大多属于全新设计的复杂系统，往往构建了繁琐的端到端管道，缺乏对成熟去噪模块与重平衡模块的有机融合。更重要的是，如何在不依赖额外元数据的前提下，从根本上消解去噪与保尾之间的梯度冲突，仍是本研究拟重点解决的难题。

2.3 面向隐式属性的分布鲁棒与子群平衡学习

前文所述的长尾学习与噪声标签学习方法，主要关注显式的类别标签分布。然而，在真实世界的条件非完备下，不平衡往往不仅存在于类别之间，更隐匿于类别内部的属性或子群层面[108]。这种隐式的子群不平衡会导致模型在多数子群上表现优异，而在少数子群上性能显著下降，从而引发严重的泛化性问题。本节将深入探讨面向隐式属性的子群平衡学习研究现状，并指出现有方法在应对条件非完备时的局限性。

2.3.1　非本质属性的分布鲁棒性

当训练数据中存在与标签统计相关但无因果关联的非本质属性时，经验风险最小化模型倾向于利用这些容易学习的属性进行捷径学习，而非学习鲁棒的语义特征[109]。这种现象在子群分布不平衡时尤为严重，例如当某一背景属性与特定类别在训练集中高度共现时，模型会建立较强的统计关联。为了解决这一问题，分布鲁棒优化被提出以提升模型在最坏情况下的泛化能力[110-111]。

Group DRO[45] 是该领域的里程碑式工作。它假设训练数据可以被划分为若干个预定义的子群，并直接优化这些子群中风险最大的项。通过在训练过程中动态调整各子群的权重，该方法迫使模型关注那些高损失的少数子群。然而，其成功建立在一个苛刻的理想化假设条件之上，即训练数据必须具备完整且准确的子群属性标注。在实际应用中，获取这种细粒度的属性标注往往成本高昂。此外，过度关注最差子群可能会导致模型在平均性能上的妥协，且在长尾噪声并存的条件非完备下，最差子群可能被噪声主导[112]。

2.3.2　无监督子群挖掘与平衡技术的演进

鉴于获取子群标注的困难，近年来的研究热点转向无监督子群挖掘，即在缺乏显式属性标注的情况下，自动推断样本的子群归属并进行重平衡。

2.3.2.1　基于预测误差的启发式挖掘策略

这类方法通常基于一个核心假设，即模型倾向于优先拟合多数子群，而忽略少数子群，因此那些被错误分类或具有高损失的样本很可能属于少数子群[46,113]。代表性工作 JTT[46] 提出了一种简单的两阶段策略，首先训练一个短周期的识别模型，将其识别错误的样本定义为少数子群并在第二阶段进行重加权训练。LfF[113] 则通过同时训练一个有偏网络和一个去偏网络来实现端到端的学习，利用有偏网络的失败样本来指导去偏网络的优化。然而，深度神经网络具有强大的记忆能力，即使是少数子群样本也可能在训练初期被正确拟合，导致上述方法难以精准召回隐式的尾部样本。

2.3.2.2　基于不变性与聚类的特征挖掘策略

另一类方法试图从不变性学习的角度出发，寻找在不同环境下保持预测机制一致的子群划分。EIIL[47] 将子群标签视为可优化的参数，旨在找到一种数据划分使得在该划分下应用不变性风险最小化能获得最大的惩罚。ARL[114] 引入了一个对抗网络来生成样本权重，该网络试图最大化主分类器的损失，从而隐式地模拟最差子群分布。此外，部分研究利用特征的聚类特性来发现子群，例如利用预训练模型的特征聚

类结果作为伪子群标签[115-116]。

2.3.3 现有研究在条件非完备下的局限性

尽管上述方法在处理属性偏倚方面取得了一定进展，但在面向更加通用的隐式长尾子群问题时，仍存在显著的局限性。首先，现有的无监督挖掘方法假设存在一个强干扰属性导致模型预测错误，但在通用的条件非完备中，少数子群可能仅仅是因为样本量少而被忽略，并不一定包含强烈的偏倚信号。其次，现有的环境推断方法通常涉及复杂的双层优化问题，计算开销巨大且难以收敛。最后，现有方法大多在类级别进行校准，忽视了不同子群可能需要依赖完全不同的特征进行预测这一异质性事实。如何建立一种能够从数据内在结构出发，自适应地最大化预测信息增益的子群挖掘与平衡机制，是本研究后续章节拟解决的关键课题。

2.4 面向生成式任务的长尾学习研究

随着人工智能任务从判别式向生成式演进，长尾分布带来的挑战也从单纯的分类边界偏移延伸至数据分布拟合的深层维度。生成式任务旨在学习数据生成的潜在概率分布，当训练数据处于长尾分布时，模型往往难以同时兼顾头部类别的生成质量与尾部类别的多样性。本节将从生成对抗网络（GANs）与扩散概率模型（Diffusion Models）两个主流生成范式出发，探讨长尾数据下的生成建模困境与现有解决方案。

2.4.1 面向生成对抗网络的长尾学习

在扩散模型兴起之前，生成对抗网络是生成式建模的主流方法[117]。然而，这类网络的训练过程本质上是不稳定的，且极易发生模式崩塌。在长尾训练数据上，这一问题被进一步放大：判别器倾向于依据头部类别的特征来判断真伪，导致生成器为了满足判别器的判别准则，会逐渐放弃生成尾部类别的样本，或者生成的尾部样本缺乏多样性，甚至产生严重的伪影。

针对这一问题，早期的解决方案主要借鉴了理想条件下的重平衡思想。例如，CB-GAN[118] 利用一个预训练的分类器来估计类别分布，并在训练过程中对尾部类别的损失进行重加权，试图平衡生成器对不同类别的关注度。然而，单纯的重加权在生成对抗网络的极小极大博弈中往往难以收敛。进一步的研究表明，长尾生成性能的下降主要源于尾部类别在条件参数矩阵上的谱爆炸现象。为此，Rangwani 等人[119] 提出了一种组谱正则化器，通过约束条件参数的谱范数来缓解尾部类别的模式崩塌。尽管这些方法在一定程度上改善了生成质量，但生成对抗网络本身的训练不稳定性限制了其

在长尾数据下的进一步应用。

2.4.2　面向扩散模型的长尾学习

近年来，受非平衡热力学启发的扩散概率模型凭借其卓越的生成质量和训练稳定性，已逐渐取代生成对抗网络成为图像生成领域的新范式[19,38,120]。尽管扩散模型通过逐步去噪的过程规避了模式崩塌问题，但在长尾数据集上，其依然面临着严重的性能退化。具体表现为头部类别的生成图像逼真且多样，而尾部类别的生成图像往往模糊不清、语义混淆或缺乏细节[48]。

2.4.2.1　基于损失优化与知识迁移的改进尝试

为了提升扩散模型在长尾训练数据上的鲁棒性，现有的研究主要集中在损失函数的设计与知识迁移上。CBDM 率先指出了标准扩散模型在长尾数据上的缺陷，并引入了一种分布调整正则化器，通过在训练过程中显式地增强尾部类别的梯度贡献来平衡生成质量[48]。Yan 等人则引入了对比学习正则化损失，试图增强尾部类别特征的判别性[121]。此外，OC 提出了一种基于迁移学习的思路，利用头部类别学习到的高质量特征分布来指导尾部类别的生成过程，通过校准尾部样本的去噪路径来提升其生成保真度[122]。

2.4.2.2　数据重加权与混合优化策略

除了针对长尾分布设计的特定损失外，通用的数据重加权与混合优化策略也被应用于改善生成模型的训练偏差。例如，在大型语言模型预训练中广泛使用的 DoReMi 和 RegMix 通过优化数据域的权重来提升模型效率[123-124]。在扩散模型领域，Kim 等人提出了重要性加权方法，旨在从有偏数据集中训练出无偏的扩散模型[125]。Li 等人则结合了结构化剪枝与数据重加权，试图在降低计算开销的同时保持生成性能[126]。

2.4.2.3　模型容量分配的结构性盲区

尽管上述方法在一定程度上缓解了生成模型的长尾数据问题，但其大多忽略了一个更为本质的结构性因素，即模型容量的分配问题。在神经网络的训练过程中，梯度更新的方向和幅度往往被样本数量庞大的头部类别所主导。这意味着模型的大部分参数实际上被头部类别的特征知识所垄断，而尾部类别只能通过极其微弱的梯度更新来竞争剩余的非关键参数空间。

这种容量垄断现象导致尾部类别的表征极为脆弱。相关实证研究发现，即使尾部样本的训练损失已经收敛，其依赖的参数往往具有较小的范数，极易在模型剪枝或微

表 2.1 现有长尾学习研究现状与本文研究内容的对应关系

Table 2.1 Mapping between existing long-tailed learning research and the contributions of this paper

场景维度	核心挑战	现有方法的局限	本文研究内容
理想条件 (第 2.1 节)	类别样本极度不平衡，导致分类边界偏向头部。	建立在标注准确、结构显式、任务单一这三大理想化假设条件之上。	作为基础理论组件，支撑后续条件非完备下的框架构建。
监督信号退化 (第 2.2 节)	标注退化引发消歧困难与去噪冲突，头部过自信加剧了尾部信号的湮灭。	在处理重平衡与消歧去噪双重目标时面临内生冲突，缺乏统一消解机制。	**第 3 章**：针对标注歧义的动态校准长尾学习。 **第 4 章**：针对标注噪声的冲突消解长尾学习。
潜在结构隐匿 (第 2.3 节)	子群属性不可见，导致尾部子群被非本质关联掩盖，产生严重的属性偏倚。	无监督挖掘策略易受模型记忆效应干扰，且缺乏特征层面的解耦建模。	**第 5 章**：针对隐式属性的异质性挖掘长尾学习。
生成任务拓展 (第 2.4 节)	生成式任务中存在严重的容量垄断现象，头部类别占据了绝大部分参数空间。	现有的损失重加权策略未能从模型结构的层面解决参数分配失衡问题。	**第 6 章**：针对扩散模型的容量操控长尾学习。

调过程中被破坏[122]。理想条件下的重加权方法虽然试图通过增加尾部样本的梯度权重来对抗这种趋势，但并未从模型结构的层面显式地为尾部类别预留或分配独立的存储空间。如何在不增加推理成本的前提下，打破头部类别对模型容量的垄断，实现头尾类别知识的解耦与公平存储，是当前长尾生成式建模领域亟待解决的关键难题。这也构成了本论文第 6 章提出容量操控机制的直接动机。

2.5 本章小结

本章系统梳理了条件非完备下的长尾学习方法的研究现状。本研究以理想条件下的长尾学习范式为基准，深入剖析了当长尾分布与监督信号退化、潜在结构隐匿以及任务形式拓展相互耦合时，现有技术面临的严峻挑战。表 2.1 详细总结了本章讨论的核心科学问题、现有方法的局限性以及本文后续章节拟采取的技术路线。

综上所述，尽管长尾学习领域已积累了丰富的研究成果，但在应对条件非完备下的现实挑战时，仍存在显著的理论与技术盲区。具体而言：

- 在监督信号维度，缺乏处理长尾分布与标签歧义及噪声相互耦合的鲁棒机制，导致模型在消歧去噪与保尾重平衡之间进退维谷。
- 在数据结构维度，缺乏在无监督条件下精准挖掘隐式长尾子群的能力，使得模

型难以克服非本质关联的误导。

- 在任务拓展维度，缺乏针对生成式模型的参数容量分配策略，限制了长尾数据生成的保真度与多样性。

针对上述未决问题，本文将在后续章节中展开深入研究。本研究将分别提出针对性的解决方案，以期构建更加鲁棒且高效的条件非完备下的长尾学习系统。

第 3 章 基于动量原型动态校准的长尾偏标签学习

3.1 引言

在第 1 章中，本文指出真实世界的监督信号往往面临着“退化”的挑战，其中一种典型的形式是标签歧义，对应于学术界普遍研究的偏标签学习问题。偏标签学习起源于广泛的现实应用场景，例如带有多个用户标签的新闻网站[127]、包含多个角色的视频片段[128]，以及来自多个标注者的众包数据[129]。在这些场景中，每个样本的标注不再是单一确定的真实类别，而是一个包含了真实类别与其他干扰类别的候选集合。

传统的偏标签学习研究通常建立在一个理想化的条件之上，即收集到的数据在类别分布上是近似均匀的。然而，正如本文在 图 1.2 中所分析的，现实世界的数据生成普遍遵循齐普夫定律，呈现出显著的长尾分布特征。这就构成了一个更为实际但极具挑战性的场景——长尾偏标签学习。在此场景下，模型不仅需要克服监督信号的歧义性，从候选集合中消除歧义识别出真实标签，还需要克服数据分布的不平衡性，防止模型被头部类别主导。

现有的研究工作主要将“偏标签学习”与“长尾学习”视为两个独立的问题进行处理，难以应对两者的耦合挑战。

- **偏标签学习方法的局限：**标准的偏标签学习方法[130]（如 PRODEN[92], LW[93], CAVL[131] 和 CORR[132] 等）主要致力于设计标签置信度估计机制，通过隐式或显式地重加权分类损失来实现消歧。然而，这些方法大多忽略了类别的先验分布，默认数据是均衡的。在长尾分布下，这种忽略会导致模型迅速向头部类别过拟合，将模糊的候选标签错误地消歧为头部类别。
- **长尾学习方法的局限：**长尾学习的核心在于消除由类别不平衡引起的固有偏差[40,133]，其中一个简单且有效的方法是 Logit Adjustment（LA）[42,83]。然而，大多数性能优异的长尾学习方法（如 LA）需要预知准确的类别分布先验。在偏标签学习中，由于真实标签被淹没在候选集合中，真实的类别分布是未知的，这使得标准长尾方法无法直接适用。

更关键的是，本研究发现即便假设拥有上帝视角，已知真实的类别先验分布并应用长尾方法（如 LA）重平衡，模型的表现依然不尽如人意，甚至在某些情况下会导致训练崩溃。如 图 3.1 所示（参考 PRODEN + Oracle-LA 曲线），在训练早期，直接引入静态的准确类别先验进行重平衡会导致模型对尾部类别产生极其严重过度矫正。

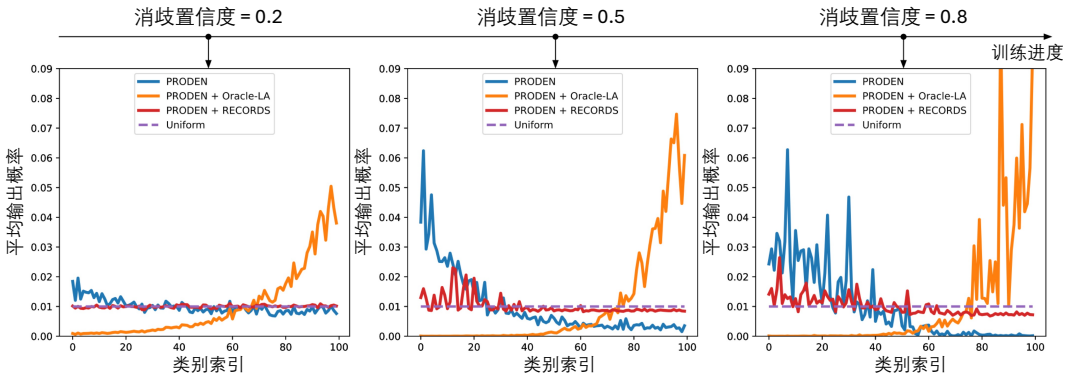


图 3.1　RECORDS 算法与基线算法在训练过程中分类器的平均预测结果（在 CIFAR-100 测试集上评估，训练集为长尾部分标签学习数据集 CIFAR-100-LT，不平衡比率 IR = 100，歧义度 $q = 0.05$）。其中，“PRODEN”[92] 是一种经典的偏标签学习（PLL）方法；“PRODEN + Oracle-LA” 表示在（实际不可知的）准确类别先验分布条件下，将常用的长尾学习 logit adjustment 方法[42,134] 应用在 PRODEN 方法框架上；“PRODEN + RECORDS” 表示在 PRODEN 基础上引入本文提出的校准方法；“Uniform” 表示均匀分布作为参考。

Figure 3.1　Average classifier prediction (on the CIFAR-100 test set) of different methods during training (on the LT-PLL training set CIFAR-100-LT with imbalance ratio IR = 100 and ambiguity $q = 0.05$). “PRODEN”[92] is a representative partial label learning (PLL) method. “PRODEN + Oracle-LA” denotes PRODEN equipped with state-of-the-art logit adjustment[42,134] for long-tailed learning under the oracle prior. “PRODEN + RECORDS” refers to PRODEN with our proposed calibration method. “Uniform” characterizes the expected average confidence over different classes.

这一现象揭示了长尾偏标签问题的核心矛盾：消歧过程的动态性与分布校准的静态性之间的失配。在偏标签学习中，监督信息并非一成不变，而是随着标签消歧的进行，从高度不确定逐渐走向确定。在训练初期，模型对真实标签的判断极度模糊，此时如果利用静态的长尾先验强行提升尾部类别的权重，只会加剧分类器的混淆，导致模型在未看清真相之前就盲目地偏向尾部。这种“拔苗助长”式的校准不仅无法解决不平衡，反而破坏了标签消歧的基石。

基于上述分析，本研究认为解决长尾偏标签学习问题的关键在于从静态重平衡（Constant Rebalancing）转向动态重平衡（Dynamic Rebalancing）。理想的校准机制应当与模型的消歧进程相适应：在训练初期保持温和，避免干扰消歧；在训练后期随着标签逐渐清晰，逐步逼近真实分布以消除长尾偏差。

为此，本章提出了一种名为 RECORDS 的动态校准算法。该方法并不依赖任何预设的分布先验，而是通过在特征空间维护一个动量更新的原型特征，实时地对当前的类别分布进行参数化估计。通过从模型输出中参数化地分解出动态偏差项，RECORDS 能够根据当前的训练状态自适应地调整校准强度。

本章的主要贡献总结如下：

1. **问题揭示：**本研究深入探索了更具实用价值的长尾偏标签场景，并指出了直接组合现有长尾与偏标签方法的失效机制——即静态分布先验会对早期的动态消歧过程产生严重的负面干扰。
2. **方法提出：**本研究提出了一种无需先验的动态重平衡框架 RECORDS。该方法利用动量原型特征实时估计参数化类分布，实现了分布校准与标签消歧的动态协同。理论分析证明，该动态分布在训练过程中能够非对称地逼近真实分布，且对优化过程更加良性。
3. **实验验证：** RECORDS 具有轻量级与即插即用的特性，可以轻松嵌入现有的偏标签框架中。在 CIFAR-10-LT、CIFAR-100-LT 以及真实数据集 Pascal VOC 上的广泛实验表明，该方法显著优于现有的基准方法。特别是在 Pascal VOC 上，相比于性能最好的基线方法 CORR，RECORDS 实现了高达 32.03% 的性能提升。

3.2 预备知识

本节将首先对长尾偏标签学习（Long-Tailed Partial Label Learning, LT-PLL）进行形式化定义。随后，简要回顾本章算法所基于的两类基础技术：用于解决标签歧义的自训练偏标签学习方法，以及用于解决类别不平衡一个常用技术 Logit Adjustment。

3.2.1 问题定义

令 $\mathcal{X} \subset \mathbb{R}^d$ 表示 d 维输入特征空间，$\mathcal{Y} = \{1, 2, \ldots, C\}$ 表示包含 C 个类别的标签空间。定义候选标签集合空间 $\mathcal{S}$ 为 $\mathcal{Y}$ 的幂集（除去空集），即 $\mathcal{S} = 2^{\mathcal{Y}} \setminus \emptyset$。一个长尾偏标签训练集可以表示为 $\mathcal{D}_{\text{train}} = \{(\boldsymbol{x}_i, S_i)\}_{i=1}^{N}$，其中 $\boldsymbol{x}_i \in \mathcal{X}$ 为第 i 个样本，$S_i \in \mathcal{S}$ 为该样本关联的候选标签集合。对于每个样本，存在一个不可见的真实标签 $y_i \in \mathcal{Y}$，且满足 $y_i \in S_i$。在长尾设定下，设 N_c 为类别 c 的样本数量，所有类别按照样本数量降序排列（即 $N_1 \geq N_2 \geq \cdots \geq N_C$），且呈现显著的长尾分布特征（$N_1 \gg N_C$）。

设 $f(\boldsymbol{x}; \theta)$ 为由参数 θ 定义的深度神经网络骨干，用于将输入 $\boldsymbol{x}$ 映射为特征向量。模型的最终输出 Logits 由 $z(\boldsymbol{x}) = g(f(\boldsymbol{x}; \theta); \boldsymbol{W}) = \boldsymbol{W}^{\top} f(\boldsymbol{x}; \theta)$ 给出，其中 g 为参数矩阵为 $\boldsymbol{W}$ 的线性分类器。$\boldsymbol{\Theta} = [\theta, \boldsymbol{W}]$ 表示深度网络的所有可学习参数。在评估阶段，为了公平地衡量模型对所有类别的泛化能力，通常使用一个类别平衡的测试集 $\mathcal{D}_{\text{uni}} = \{(\boldsymbol{x}_i, y_i)\}$[135]。简而言之，长尾偏标签学习的目标是在长尾偏标签数据集 $\mathcal{D}_{\text{train}}$ 上学习参数 $\boldsymbol{\Theta}$，以最小化在平衡测试集 $\mathcal{D}_{\text{uni}}$ 上的平衡错误率（Balanced Error Rate,

BER）：

$$\min_{\Theta} \mathrm{BER}(\Theta) \overset{P_{\mathrm{uni}}(y)=\frac{1}{C}}{=} P_{(\boldsymbol{x},y)\in\mathcal{D}_{\mathrm{uni}}}\left(y \neq \operatorname*{argmax}_{y'\in\mathcal{Y}} z^{y'}(\boldsymbol{x})\right). \tag{3.1}$$

3.2.2　自训练偏标签学习方法

自训练（Self-Training）是解决偏标签学习问题的主流范式之一。该类方法通常为每个训练样本维护一个类别级的置信度权重向量 $\boldsymbol{w} \in [0,1]^C$，并将损失函数形式化为由 $\boldsymbol{w}$ 加权的分类损失。在每一轮训练中，$\boldsymbol{w}$ 会根据模型当前的输出进行更新，并期望随着训练的进行逐渐收敛至真实标签的 One-hot 形式，从而将偏标签学习问题转化为普通的监督分类问题。

不同的自训练方法主要区别于损失函数的形式以及权重的更新策略。在本章中，下列代表性方法将作为基础框架或对比基线：

- **PRODEN**[92]：假设真实标签在模型输出中具有较大的 Logit 值，因此赋予高 Logit 对应的标签更高的置信度权重。
- **LW**[93]：在考虑偏标签损失的同时，额外引入了非偏标签（Non-partial labels）的负监督信息，并赋予其相应的置信度权重。
- **CAVL**[131]：基于类激活图（CAM）的思想设计了一种鉴别策略，并向标签分配硬置信度权重（即 0 或 1）。
- **CORR**[132]：在标签消歧策略中引入了一致性正则化（Consistency Regularization），以提高模型对噪声的鲁棒性。

3.2.3　面向长尾学习的 Logit Adjustment 技术

Logit 调整（Logit Adjustment, LA）[42,134] 是监督长尾学习中一种简单而有效的技术。其核心思想是利用贝叶斯公式，通过在输出 Logit 上施加一个与类别频率相关的偏移项，以此消除类别不平衡带来的负面影响。

具体而言，根据贝叶斯公式，后验概率 $P(y|\boldsymbol{x})$ 满足：

$$P(y|\boldsymbol{x}) \propto P(\boldsymbol{x}|y) \cdot P(y). \tag{3.2}$$

在训练集 $\mathcal{D}_{\mathrm{train}}$ 上直接最小化交叉熵损失所得到的模型，其输出 Logit $z^y(\boldsymbol{x})$ 本质上拟合的是训练集的分布 $P_{\mathrm{train}}(y|\boldsymbol{x})$，即：

$$\mathrm{softmax}(z^y(\boldsymbol{x})) \approx P_{\mathrm{train}}(y|\boldsymbol{x}). \tag{3.3}$$

然而，长尾学习的目标是最小化平衡错误率，这等价于要求模型拟合一个类别均匀的测试分布 $P_{\mathrm{uni}}(y|\boldsymbol{x})$，其中先验分布 $P_{\mathrm{uni}}(y) = 1/C$。此时，目标 Logit z_{uni} 与训练得到的 Logit z 之间存在如下关系：

$$\begin{aligned} P_{\mathrm{uni}}(y|\boldsymbol{x}) &\propto P(\boldsymbol{x}|y) \cdot P_{\mathrm{uni}}(y) \\ &\propto P(\boldsymbol{x}|y) \quad (\text{因为} P_{\mathrm{uni}}(y) \text{ 为常数}) \\ &\propto \frac{P_{\mathrm{train}}(y|\boldsymbol{x})}{P_{\mathrm{train}}(y)} \\ &\propto \mathrm{softmax}\left(z^y(\boldsymbol{x}) - \log P_{\mathrm{train}}(y)\right). \end{aligned} \tag{3.4}$$

这意味着，如果通过标准交叉熵训练得到了 Logit $z^y(\boldsymbol{x})$，则可以通过减去一个偏移项 $\log P_{\mathrm{train}}(y)$ 来获得平衡测试分布下的最优 Logit $z^y_{\mathrm{uni}}(\boldsymbol{x})$。这种方法被称为 Logit Adjustment，它在统计意义上消除了由训练集先验 $P_{\mathrm{train}}(y)$ 引入的偏差，同时保留了模型对特征 $P(\boldsymbol{x}|y)$ 的判别能力。

3.3 算法研究

本节将首先分析传统静态重平衡方法在长尾偏标签学习（LT-PLL）中的局限性，进而引出动态重平衡的设计动机。随后，详细阐述所提出的 RECORDS 算法的数学原理与具体实现。

3.3.1 动机：从静态到动态的范式转变

现有的长尾学习技术通常基于一个隐含假设：监督信号是清晰且确定的。因此，它们仅关注由训练集固有的长尾分布 $P_{\mathrm{train}}(y)$ 引起的模型偏差，本研究将这类方法统称为**静态重平衡（Constant Rebalancing）**。然而，正如第 3.2 节所述，直接将静态重平衡（如 Logit Adjustment）应用于长尾偏标签学习场景会导致严重的性能下降（见图 3.1 中的 Oracle-LA 曲线）。

这种失效的根源在于长尾偏标签学习任务的特殊性：模型偏差不仅受偏斜的训练数据分布影响，更受到动态变化的监督信号的制约。具体而言，标签消歧是一个随着训练进行、置信度从不确定逐渐走向确定的动态过程。在训练初期，模型对真实标签的预测往往比较均衡（甚至略微偏向头部）。此时，如果强行引入高度偏斜的静态训练集分布 $P_{\mathrm{train}}(y)$ 进行重平衡，会导致模型对尾部类别产生过度的自信，从而将候

选集合中原本属于头部的样本错误地消歧为尾部类别。这种早期的消歧错误会随着训练过程被累积和放大，最终导致模型训练崩溃。

因此，一种符合直觉的解决方案是采用**动态重平衡（Dynamic Rebalancing）**机制。理想的重平衡强度应当与标签消歧的进程相适应：在训练初期保持温和以避免干扰消歧，在训练后期随着标签逐渐清晰，逐步逼近真实分布以消除长尾偏差。

3.3.2　算法原理

基于上述分析，本研究指出 Logit Adjustment 在长尾偏标签学习中失效的数学本质在于：标签消歧的动态性导致模型学到的分布 $P_{\text{train}}(y|\boldsymbol{\Theta})$ 与静态的统计先验 $P_{\text{train}}(y)$ 之间存在时变性的不匹配（Mismatch）。为了调和这一冲突，本研究提出对原始的 Logit Adjustment 范式进行参数化分解。

根据贝叶斯准则，模型对训练数据的拟合可以分解为：

$$\begin{aligned} P_{\text{uni}}(y|\boldsymbol{x};\boldsymbol{\Theta}) &\propto P(\boldsymbol{x}|y;\boldsymbol{\Theta}) \\ &\propto \frac{P(\boldsymbol{x}|y;\boldsymbol{\Theta})\cdot P_{\text{train}}(y|\boldsymbol{\Theta})}{P_{\text{train}}(y|\boldsymbol{\Theta})} \\ &\propto \frac{P_{\text{train}}(y|\boldsymbol{x};\boldsymbol{\Theta})}{P_{\text{train}}(y|\boldsymbol{\Theta})} \\ &\propto \text{softmax}\left(z^y(\boldsymbol{x}) - \log P_{\text{train}}(y|\boldsymbol{\Theta})\right), \end{aligned} \tag{3.5}$$

其中，$P_{\text{uni}}(y|\boldsymbol{x};\boldsymbol{\Theta})$ 表示在均匀类先验假设下的参数化后验概率，即期望的去偏后验概率；$P_{\text{train}}(y|\boldsymbol{x};\boldsymbol{\Theta})$ 是模型当前在有偏训练集上学到的后验概率（即 Softmax 输出）；而 $P_{\text{train}}(y|\boldsymbol{\Theta})$ 则代表模型当前参数 $\boldsymbol{\Theta}$ 下隐含的**动态类别分布**。

公式 (3.5) 揭示了动态重平衡的核心思想：需要利用一个适应训练动态的参数化分布 $P_{\text{train}}(y|\boldsymbol{\Theta})$，而非固定的统计先验 $P_{\text{train}}(y)$，来对模型输出 Logit 进行校准。令校准后的 Logit 为 $z^y_{\text{uni}}(\boldsymbol{x})$，则有：

$$z^y_{\text{uni}}(\boldsymbol{x}) = z^y(\boldsymbol{x}) - \log P_{\text{train}}(y|\boldsymbol{\Theta}). \tag{3.6}$$

这种动态校准机制具有良好的正交性。现有的偏标签学习方法主要致力于优化似然项 $P(\boldsymbol{x}|y;\boldsymbol{\Theta})$，使其更接近真实的 $P(\boldsymbol{x}|y)$；而 RECORDS 则专注于消除先验项 $P_{\text{train}}(y|\boldsymbol{\Theta})$ 的影响。因此，RECORDS 可以作为即插即用的模块，与现有的偏标签学习方法结合以进一步提升性能（详见第 3.4.3 节实验部分）。

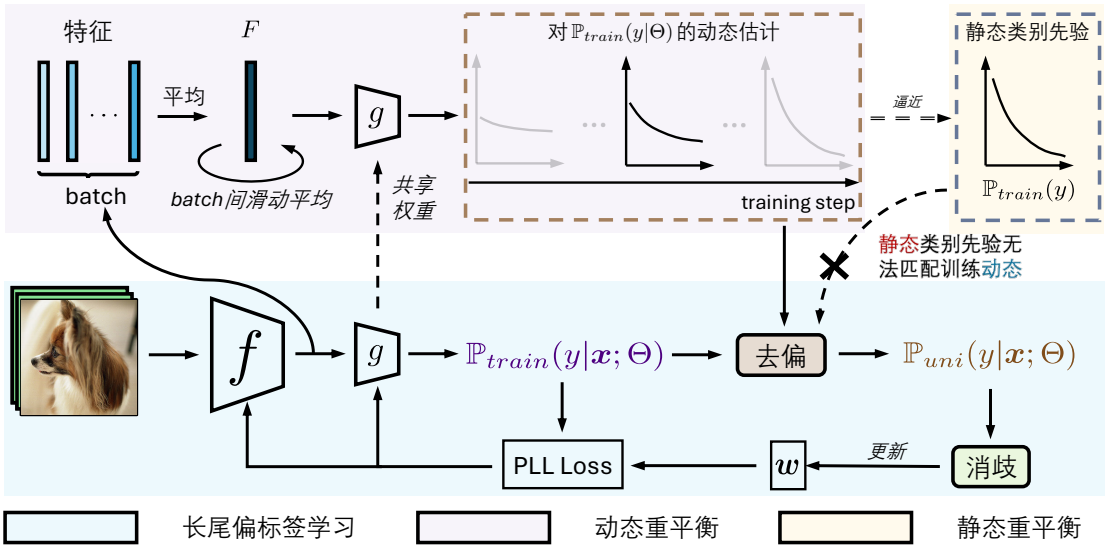


图 3.2　RECORDS 算法流程示意图。类级置信度权重 w 由“消歧”模块更新，并作为软/硬伪标签用于偏标签学习损失（PLL Loss）的计算。“去偏”模块通过公式 (3.10) 对 $P_{\text{train}}(y|\boldsymbol{x};\Theta)$ 进行动态重平衡，从而得到 $P_{\text{uni}}(y|\boldsymbol{x};\Theta)$。重平衡后的概率有助于尾部样本实现更准确的标签消歧，避免被头部类别主导。通过动量更新得到的原型特征用于估计 $P_{\text{train}}(y|\Theta)$，该分布对标签消歧过程更加友好，并在训练过程中以非对称方式逐步逼近真实的类别先验分布 $P_{\text{train}}(y)$。

Figure 3.2　Overview of the RECORDS algorithm. The class-level confidence weights w are updated by the disambiguation module and are used as soft/hard pseudo-labels to compute the partial-label learning (PLL) loss. The debiasing module dynamically rebalances $P_{\text{train}}(y|\boldsymbol{x};\Theta)$ via Eq. (3.10) to obtain $P_{\text{uni}}(y|\boldsymbol{x};\Theta)$. The rebalanced probabilities facilitate more accurate label disambiguation for tail samples, preventing them from being overwhelmed by head classes. Prototype features updated with momentum are employed to estimate $P_{\text{train}}(y|\Theta)$, which is more suitable for label disambiguation and asymmetrically approaches the true class prior $P_{\text{train}}(y)$ during training.

3.3.3　基于动量原型的分布估计

实现 RECORDS 的关键在于如何准确且高效地估计动态类别分布 $P_{\text{train}}(y|\Theta)$。理论上，该分布可以通过在整个训练集上对模型后验概率求期望得到，即 $P_{\text{train}}(y|\Theta) = \mathbb{E}_{\boldsymbol{x}_i \in \mathcal{D}_{\text{train}}} P_{\text{train}}(y|\boldsymbol{x}_i;\Theta)$。

为了提高估计的稳定性和计算效率，RECORDS 方法引入了归一化加权几何平均（Normalized Weighted Geometric Mean, NWGM）近似[136]。NWGM 允许将期望操作移动到 Softmax 函数内部，从而利用特征层面的统计信息来近似输出层面的分布：

$$\begin{aligned} P_{\text{train}}(y|\Theta) &= \mathbb{E}_{\boldsymbol{x}_i \in \mathcal{D}_{\text{train}}} \text{softmax}(z^y(\boldsymbol{x}_i)) \\ &\overset{\text{NWGM}}{\approx} \text{softmax}\left(\mathbb{E}_{\boldsymbol{x}_i \in \mathcal{D}_{\text{train}}} z^y(\boldsymbol{x}_i)\right) \\ &= \text{softmax}\left(g^y(\mathbb{E}_{\boldsymbol{x}_i \in \mathcal{D}_{\text{train}}} f(\boldsymbol{x}_i;\theta);\boldsymbol{W})\right), \end{aligned} \tag{3.7}$$

其中 $f(\cdot)$ 是特征提取器，$g(\cdot)$ 是线性分类器。这一近似背后的直觉是：特征层面的统计量通常比输出层面的概率值随训练变化更平滑、更稳定。

然而，直接计算全数据集的特征期望 $\mathbb{E}_{\boldsymbol{x}_i \in \mathcal{D}_{\text{train}}} f(\boldsymbol{x}_i; \theta)$ 需要遍历所有样本，计算成本高昂。为此，本研究设计了一种**动量更新的原型特征（Momentum Prototype）**机制，维护一个全局原型向量 F，用于近似全数据集的特征期望。在每个训练批次（Batch）中，利用当前批次的特征均值对 F 进行动量更新：

$$F \leftarrow mF + (1-m)\mathbb{E}_{\boldsymbol{x}_i \in \text{Batch}} f(\boldsymbol{x}_i; \theta), \tag{3.8}$$

其中 $m \in [0, 1)$ 是动量系数。利用更新后的原型特征 F，可以实时计算当前的动态类别分布估计：

$$P_{\text{train}}(y|\boldsymbol{\Theta}) \approx \text{softmax}(g^y(F; \boldsymbol{W})). \tag{3.9}$$

最终，RECORDS 算法的校准公式为：

$$z^y_{\text{uni}}(\boldsymbol{x}) = z^y(\boldsymbol{x}) - \log \text{softmax}(g^y(F; \boldsymbol{W})). \tag{3.10}$$

图 3.2 展示了 RECORDS 的整体流程。作为一个轻量级模块，RECORDS 被嵌入在每次迭代的“消歧”模块之前，通过公式 (3.10) 将有偏的后验概率 $P_{\text{train}}(y|\boldsymbol{x}; \boldsymbol{\Theta})$ 转换为去偏的 $P_{\text{uni}}(y|\boldsymbol{x}; \boldsymbol{\Theta})$，进而辅助后续的标签消歧和参数更新。我们在算法 3.1 中总结了 RECORDS 方法的完整流程。

3.3.4　动态重平衡与静态重平衡的理论联系

前一节中展示了参数化的类别分布 $P_{\text{train}}(y|\boldsymbol{\Theta})$ 来校准长尾偏标签学习的训练过程。一个关键的理论问题是：该动态分布与真实的静态先验 $P_{\text{train}}(y)$ 之间存在何种联系？本节将从理论上阐明二者的一致性关系。

首先，定义 Oracle 先验分布为 $P_{\text{train}}(y_j) = \mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})} \mathbb{1}(y = y_j)$。考虑假设空间 H，其中每个 $h_{\boldsymbol{\Theta}} \in H : \mathcal{X} \to \mathcal{Y}$ 是由 $\boldsymbol{\Theta}$ 参数化的多分类器。定义分类器 $h_{\boldsymbol{\Theta}}$ 的参数化类别分布为 $P_{\text{train}}(y_j|\boldsymbol{\Theta}) = \mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})} \mathbb{1}(h_{\boldsymbol{\Theta}}(\boldsymbol{x}) = y_j)$。设训练过程中样本 $(\boldsymbol{x}, S)$ 的消歧标签为 $\tilde{y}(\boldsymbol{x}, S) \in S$。则基于消歧标签的经验风险定义为 $R^{\mathcal{D}_{\text{train}}}(\boldsymbol{\Theta}) = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}(h_{\boldsymbol{\Theta}}(\boldsymbol{x}_i) \neq \tilde{y}(\boldsymbol{x}_i, S_i))$。

受偏标签学习可学习性理论[91]的启发，本研究提出如下命题来刻画动态重平衡与静态重平衡之间的收敛关系：

算法 3.1 RECORDS 算法流程

Input: 训练数据集 $\mathcal{D}_{\text{train}}$；深度模型 f；分类器 g；自训练 PLL 算法 $\mathcal{A}$；训练轮数 T
Output: 模型 f 的参数 θ；分类器 g 的参数 $\boldsymbol{W}$

```
初始化均匀权重 w;
将 F 初始化为 0;
for t = 1, 2, ..., T do
    将训练集 D_train 随机打乱并划分为 B 个 mini-batches;
    for k = 1, 2, ..., B do
        计算 mini-batch D_k 的输出 z;
        根据公式 3.8 更新 F;
        根据算法 A 计算损失 L_A;
        根据公式 3.10 计算去偏输出 z_uni;
        根据算法 A 使用 z_uni 更新 w;
        通过最小化 L_A 更新 θ 和 W;
    end
end
```

命题 3.1　令 $\eta = \sup_{(\boldsymbol{x},y)\in\mathcal{X}\times\mathcal{Y},y_j\in\mathcal{Y},y_j\neq y} P_{S|(\boldsymbol{x},y)}(y_j \in S)$ 表示标签歧义度，d_H 为假设空间 H 的 Natarajan 维度。设 $\tilde{h} = h_{\tilde{\Theta}}$ 为基于消歧标签的最优分类器，其中 $\tilde{\Theta} = \arg\min_{\Theta} R^{\mathcal{D}_{\text{train}}}(\Theta)$。如果满足小歧义度条件[91,137]，即 $\eta \in [0,1)$，那么对于任意 $\delta > 0$，在概率至少为 $1-\delta$ 的情况下，$P_{\text{train}}(y)$ 与 $P_{\text{train}}(y|\tilde{\Theta})$ 之间的 L_2 距离满足如下上界：

$$L_2\left(\tilde{h}\right) < \frac{4}{(\ln 2 - \ln(1+\eta))N}\left(d_H(\ln 2N + 2\ln C) - \ln\delta + \ln 2\right),$$

其中 N 为样本数量，C 为类别数量。

命题 3.1 揭示了一个重要结论：在小歧义度条件下，随着标签消歧的优化过程，动态估计的类别分布 $P_{\text{train}}(y|\Theta)$ 将在理论上逐步逼近真实的类别分布先验 $P_{\text{train}}(y)$。

3.3.4.1　命题 3.1 的证明

本节将详细证明命题 3.1。证明需要引入引理 3.1、引理 3.2 和引理 3.3。

引理 3.1　令 $L_2(h)$ 表示 $P_{\text{train}}(y)$ 与 $P_{\text{train}}(y|\Theta)$ 之间的 L_2 距离，其中 h 由 Θ 参数化。可以得出：

$$L_2(h) \leq 2\mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})}\mathbb{1}(h(\boldsymbol{x}) \neq y)).$$

证明　根据 L_2 距离的定义：

$$\begin{aligned} L_2(h) &= \sqrt{\sum_{y_j=1}^{C} \left|\mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})}(\mathbb{1}(y=y_j)-\mathbb{1}(h(\boldsymbol{x})=y_j))\right|^2} \\ &\leq \sum_{y_j=1}^{C} \mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})} \left|\mathbb{1}(y=y_j)-\mathbb{1}(h(\boldsymbol{x})=y_j)\right| \end{aligned} \tag{3.11}$$

对于任意实例 $(\boldsymbol{x}, y)$，如果 $h(\boldsymbol{x}) = y$，即 h 正确分类了 $\boldsymbol{x}$，那么对于任意 $y_j \in \{1, 2, \ldots, C\}$，可以得出 $\left|\mathbb{1}(y = y_j) - \mathbb{1}(h(\boldsymbol{x}) = y_j)\right| = 0$。否则，如果 $h(\boldsymbol{x}) \neq y$，可以得出：

$$\left|\mathbb{1}(y=y_j)-\mathbb{1}(h(\boldsymbol{x})=y_j)\right| = \begin{cases} 1, & y_j = y \text{ 或 } y_j = h(\boldsymbol{x}) \\ 0, & \text{其他} \end{cases} \tag{3.12}$$

因此，可以将 $L_2(h)$ 的上界放缩为：

$$L_2(h) \leq 2\mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})}\mathbb{1}(h(\boldsymbol{x}) \neq y)) \tag{3.13}$$

■

引理 3.2　定义 R 为所有存在 ϵ-L_2 距离且经验风险为零的假设 h 的训练集 $\mathcal{D}_{\text{train}}$ 的集合：

$$R = \{\mathcal{D}_{\text{train}} \in (\mathcal{X}, \mathcal{Y}, \mathcal{S})^N : \exists h, L_2(h) \geq \epsilon, R^{\mathcal{D}_{\text{train}}}(h) = 0\}.$$

引入另一个同分布的训练集 $\mathcal{D}'_{\text{train}} \in (\mathcal{X}, \mathcal{Y}, \mathcal{S})^N$。定义 M 为所有满足特定条件的训练集对 $(\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}})$ 的集合：存在一个假设 h，其在 $\mathcal{D}_{\text{train}}$ 上经验风险为零且具有 ϵ-L_2 距离，但在 $\mathcal{D}'_{\text{train}}$ 上至少产生 $\frac{\epsilon N}{4}$ 个分类错误。即：

$$M = \left\{(\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in (\mathcal{X}, \mathcal{Y}, \mathcal{S})^{2N} : \exists h, L_2(h) \geq \epsilon, R^{\mathcal{D}_{\text{train}}}(h) = 0, \sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4}\right\}.$$

如果 $N > \frac{16 \ln 2}{\epsilon}$，则有：

$$P(\mathcal{D}_{\text{train}} \in R) < 2P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M).$$

证明　利用概率的链式法则：

$$
\begin{aligned}
&P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M) \\
=&P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M | \mathcal{D}_{\text{train}} \in R) \cdot P(\mathcal{D}_{\text{train}} \in R) \\
=&P\left(\exists h, L_2(h) \geq \epsilon, R^{\mathcal{D}_{\text{train}}}(h) = 0, \sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4} \middle| \mathcal{D}_{\text{train}} \in R\right) \cdot P(\mathcal{D}_{\text{train}} \in R) \\
\geq&P\left(\sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4} \middle| L_2(h) \geq \epsilon, R^{\mathcal{D}_{\text{train}}}(h) = 0\right) \cdot P(\mathcal{D}_{\text{train}} \in R)
\end{aligned}
\tag{3.14}
$$

给定 $L_2(h) \geq \epsilon$，由引理 3.1 可知 $\mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})}\mathbb{1}(h(\boldsymbol{x}) \neq y) \geq \frac{\epsilon}{2}$。利用切诺夫界（Chernoff bound），当 $N > \frac{16 \ln 2}{\epsilon}$ 时，可以得出：

$$
\begin{aligned}
&P\left(\sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4}\right) \\
=&1 - P\left(\sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') < \frac{\epsilon N}{4}\right) \\
\geq&1 - P\left(\sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') < \left(1 - \frac{1}{2}\right) \mathbb{E}_{(\boldsymbol{x}',y')\sim(\mathcal{X},\mathcal{Y})} \sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y')\right) \\
\geq&1 - e^{-\frac{N\mathbb{E}_{(\boldsymbol{x},y)\sim(\mathcal{X},\mathcal{Y})}\mathbb{1}(h(\boldsymbol{x})\neq y)}{8}} \\
\geq&1 - e^{-\frac{N\epsilon}{16}} > \frac{1}{2}
\end{aligned}
\tag{3.15}
$$

因此，可以得到 $P(\mathcal{D}_{\text{train}} \in R)$ 的上界：

$$
P(\mathcal{D}_{\text{train}} \in R) < 2P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M). \tag{3.16}
$$

■

此外，需要引入 Liu 等人[91] 的引理：

引理 3.3 (Liu 等人[91])　如果假设空间 H 具有 Natarajan 维度 d_H 且 $\eta < 1$，则：

$$
P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M) < (2N)^{d_{\mathcal{H}}} C^{2d_{\mathcal{H}}} \left(\frac{1+\eta}{2}\right)^{\frac{\epsilon N}{4}}. \tag{3.17}
$$

证明可以参照 Liu 等人[91] 。本文在附录 A 中也给出了引理 3.3 的详细证明。这里给出思路综述。其证明主要采用了统计学习理论中经典的对称化技术。首先利用

Natarajan 维度对假设空间进行容量限制，将无限假设空间的泛化问题转化为有限样本集上的组合计数问题。通过引入影子样本并定义作用于索引对的交换群，在给定样本特征的条件下，利用随机交换的对称性，将目标概率转化为在样本扰动下分类错误分布的期望。最后结合候选集标注机制中的噪声参数，计算在特定错误数量下经验风险为零的概率。通过对交换产生的组合情况进行求和，最终导出随样本量和误差界指数衰减的概率上界。

命题 3.1 的证明主体：

证明　基于上述引理，现在可以证明命题 3.1。回顾 R 的定义：

$$R = \{\mathcal{D}_{\text{train}} \in (\mathcal{X}, \mathcal{Y}, \mathcal{S})^N : \exists h, L_2(h) \geq \epsilon, R^{\mathcal{D}_{\text{train}}}(h) = 0\} \tag{3.18}$$

需要证明 $P(\mathcal{D}_{\text{train}} \in R) \leq \delta$ 的充分条件。引理 3.2 给出了界限 $P(\mathcal{D}_{\text{train}} \in R) < 2P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M)$。引理 3.3 进一步给出了 $P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M)$ 的界限。将其代入引理 3.2，可以得出：

$$P(\mathcal{D}_{\text{train}} \in R) < 2P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M) \leq 2(2N)^{d_{\mathcal{H}}} C^{2d_{\mathcal{H}}} \left(\frac{1+\eta}{2}\right)^{\frac{\epsilon N}{4}} \tag{3.19}$$

令该概率小于等于 δ，求解 ϵ 的充分条件为：

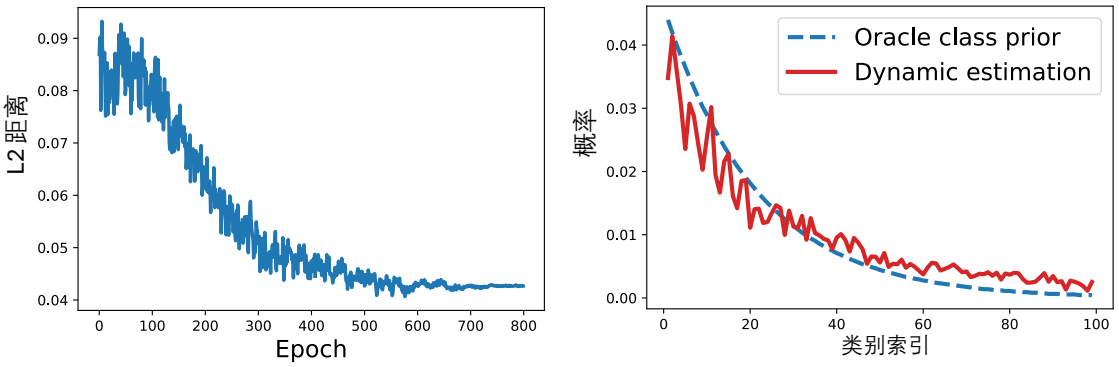
$$\begin{aligned} P(\mathcal{D}_{\text{train}} \in R) \leq \delta \quad &\Longleftarrow \quad \ln 2 + d_{\mathcal{H}}(\ln 2 + \ln N) + 2d_{\mathcal{H}} \ln C - \frac{\epsilon N}{4} \ln\left(\frac{1+\eta}{2}\right) \leq \ln \delta \\ &\Longleftrightarrow \epsilon \geq \frac{4}{(\ln 2 - \ln(1+\eta))N} \left(d_H(\ln 2N + 2\ln C) - \ln \delta + \ln 2\right) \end{aligned} \tag{3.20}$$

这意味着，当 ϵ 取上式右侧的值时，有 $L_2\left(\tilde{h}\right) < \epsilon$ 以至少 $1-\delta$ 的概率成立。

■

3.3.4.2　理论分析的实证观察

命题 3.1 具有重要的理论启示：在满足小歧义度条件下，随着标签消歧的进行，动态估计的分布将逐渐逼近（不可知的）先验类别分布。为了验证这一点，本研究追踪了训练过程中 $P_{\text{train}}(y|\Theta)$ 与先验类别分布 $P_{\text{train}}(y)$ 之间的 L_2 距离，并将其可视化于图 3.3a。可以观察到，两个分布之间的距离逐渐减小，即所提出的参数化类别分布逐渐收敛于统计 Oracle 先验。此外，如 图 3.3b 所示，最终估计的类别分布与 Oracle 先验非常接近。综上所述，图 3.3 表明，所提出的动态重平衡策略不仅在早期对标签消歧是良性的，而且最终能够趋近于静态重平衡的效果。



(a) 训练中估计类别分布与真实先验的 L_2 距离　　(b) 最终估计的类别分布

图 3.3　(a) 训练过程中，模型估计的类别分布与真实类别先验之间的 L_2 距离变化。(b) 训练结束时得到的最终类别分布估计结果。实验在 CIFAR-100-LT 数据集上进行，类别不平衡率为 IR = 100**，歧义比例为** $q = 0.03$。

Figure 3.3　(a) L_2 distance between the estimated class distribution and the oracle class prior during training. (b) Final estimated class distribution. The experiment is conducted using CORR + RECORDS on CIFAR-100-LT with imbalance ratio IR = 100 **and ambiguity** $q = 0.03$**.**

3.4　实验验证

本节将通过一系列实验来验证所提出的 RECORDS 算法在长尾偏标签学习任务中的有效性。首先，本研究设计了一个直观的二维仿真实验（Toy Study），以可视化地展示不同重平衡策略对标签消歧和决策边界的影响。随后，本研究在标准的基准数据集（CIFAR-10-LT, CIFAR-100-LT）以及真实世界数据集（Pascal VOC）上进行了广泛的定量对比实验。

3.4.1　仿真实验分析

为了直观地揭示长尾分布与标签歧义对模型训练的耦合影响，以及验证动态重平衡机制的有效性，本研究构建了一个包含 4 个类别的二维仿真数据集。

3.4.1.1　实验设置

在二维平面上模拟了一个四分类任务，各类别的样本分布在不同的区域中。

- **长尾分布设置：**训练集呈现显著的类别不平衡，四个类别（分别用红色、黄色、蓝色、绿色表示）的样本数量分别为 30, 100, 500 和 1000。红色为极少数类（尾部），绿色为多数类（头部）。
- **偏标签设置：**对于训练集中的每个样本，除了其真实标签外，以 0.6 的概率从其他类别中随机采样负标签加入候选集合，从而构造出标签歧义。

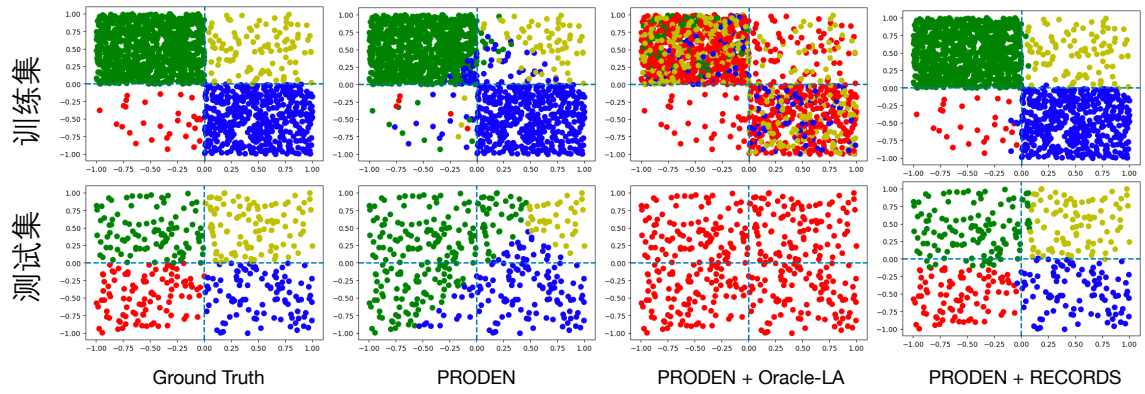


图 3.4　RECORDS 算法仿真实验可视化结果。第一列展示了训练集（不平衡）和测试集（平衡）中四个类别的真实分布，不同颜色代表不同类别（红/黄/蓝/绿分别对应样本数 30/100/500/1000）。右侧三列分别展示了三种不同方法（PRODEN, PRODEN + Oracle-LA, PRODEN + RECORDS）在训练集上的标签消歧结果（第一行）以及在测试集上的分类预测结果（第二行）。

Figure 3.4　Visualization of the toy study. The first column illustrates the ground truth distribution of four classes on the training set (imbalanced) and the test set (balanced), marked by different colors. The right three columns exhibit the label identification results on the training set (first row) and the prediction results on the test set (second row) regarding three methods.

- **测试集设置：**测试集在四个类别上是平衡的，且样本均匀分布在各类别对应的区域内。

本研究对比了三种方法的表现：基线方法 PRODEN、引入静态 Oracle 先验校准的 PRODEN + Oracle-LA，以及引入本文动态校准的 PRODEN + RECORDS。图 3.4 展示了可视化的实验结果。

3.4.1.2　结果分析

从图 3.4 中可以观察到以下现象：

- **基线方法的局限（PRODEN）：**如第三列所示，在没有重平衡机制的情况下，PRODEN 在训练集上的标签消歧结果严重偏向头部类别。少数类（红色）几乎完全被多数类（蓝色和绿色）“淹没”，甚至次少数类（黄色）也大部分被错误识别为多数类。这导致在测试集上的分类边界极度向头部类别扩张，无法正确识别尾部样本。
- **静态重平衡的失效（PRODEN + Oracle-LA）：**如第四列所示，当直接引入静态的 Oracle 类别先验进行 Logit Adjustment 时，模型表现出了极端的“过矫正”现象。在测试集上，模型几乎将所有样本都预测为少数类（红色）。这证实了本研究之前的分析：在消歧早期强行提升尾部权重，会干扰模型对真实标签的判断，导致模型在未学到有效特征之前就盲目偏向尾部，最终导致训练崩溃。

- **动态重平衡的有效性（PRODEN + RECORDS）：**如最后一列所示，RECORDS 方法展现出了最优的性能。在训练集上，它能够从模糊的候选集合中准确地恢复出各类别样本的真实标签（消歧结果与 Ground Truth 高度一致）。在测试集上，它成功学习到了清晰且合理的决策边界，既没有被头部类别主导，也没有对尾部类别过拟合。

这一仿真实验直观地证明了：在长尾偏标签学习中，静态的重平衡策略往往适得其反，而 RECORDS 提供的动态校准机制能够有效地协同标签消歧与分布去偏，是解决此类耦合问题的正确范式。

3.4.2 实验设置

3.4.2.1 数据集介绍

本研究在三个具有代表性的数据集上评估了 RECORDS 算法的性能，包括两个基于 CIFAR 构建的长尾偏标签数据集（CIFAR-10-LT, CIFAR-100-LT）以及一个源自真实世界的长尾数据集（PASCAL VOC）。

- **CIFAR-10-LT 和 CIFAR-100-LT**：原始的 CIFAR-10 和 CIFAR-100 数据集分别包含 10 个和 100 个类别的 32×32 图像，其中 CIFAR-100 的 100 个类别可归类为 20 个超类（Superclass）。为了模拟长尾分布，本研究参照文献[27] 的方法，通过指数衰减的方式对各个类别的样本数量进行降采样。不平衡比率（Imbalance Ratio）定义为样本数最多的类别与最少的类别的比值，记为 $\mathrm{IR} = N_1/N_C$，其中 N_c 为按降序排列后的第 c 个类别的样本数。在实验中设置 $\mathrm{IR} \in \{50, 100\}$。

  对于偏标签的生成，采用了两种设定：

  1. **均匀翻转（Uniform）**：遵循文献[92-93] 的设定，对于每个训练样本，除了真实标签 y 外，其他任意负标签 $\bar{y}(\neq y)$ 以相等的概率 q 被选入候选标签集合 S，即 $P(\bar{y} \in S | \bar{y} \neq y) = q$。设置歧义度 $q \in \{0.3, 0.5, 0.7\}$（针对 CIFAR-10-LT）和 $q \in \{0.03, 0.05, 0.07\}$（针对 CIFAR-100-LT）以模拟不同程度的标签噪声。
  2. **非均匀翻转（Non-uniform）**：针对 CIFAR-100-LT，本研究进一步引入了更具挑战性的非均匀设定（记为 CIFAR-100-LT-NU）。在此设定下，属于同一超类的负标签比其他负标签有更高的概率被选入候选集合。具体而言，若负标签 $\bar{y}$ 与真实标签 y 属于同一超类（$D(\bar{y}) = D(y)$），则其入选概率为 $8q$；否则为 q。这种设定更贴近现实，因为语义相近的类别往往更容易产生混淆。

为了进行细粒度分析，参照文献[30]将数据集划分为三个部分：Many-shot（样本数 > 100）、Medium-shot（样本数 20 ~ 100）和 Few-shot（样本数 < 20）。

- **PASCAL VOC**：为了验证算法在真实场景下的有效性，本研究基于 PASCAL VOC 2007[138] 构建了一个真实世界的长尾偏标签学习数据集。具体构建方式为：将图像中的物体裁剪出来作为独立实例，并将同一张原始图像中出现的所有物体类别作为该实例的候选标签集合 S。这种构建方式模拟了现实中的共现标签歧义。该数据集包含 20 个类别，共计 11,706 张训练图像和 4,000 张测试图像。如表 3.1 所示，数据集表现出极高的不平衡性，不平衡比率高达 IR ≈ 118.8，平均每个样本拥有 2.46 个候选标签。如表 3.2 详细列出的各类别样本分布所示，头部类别“Person”拥有 5,702 个样本，而尾部类别“Aeroplane”仅有 48 个样本，呈现出显著的长尾分布特征。值得注意的是，这是偏标签学习领域首次基于深度神经网络在真实视觉数据集上进行的基准测试，填补了以往仅在表格数据上验证浅层模型的空白。为了保证评估的公平性，本研究手动构建了一个类别平衡的测试集。

表 3.1　PASCAL VOC 数据集的基本特性。包含类别数、训练/测试集大小、不平衡比率以及平均候选标签数。

Table 3.1　Characteristics of the PASCAL VOC dataset, including the number of classes, training/test set sizes, imbalance ratio, and the average number of candidate labels.

类别数量	训练集数量	测试集数量	不平衡比例	平均候选标签数
20	11,706	4,000	118.8	2.46

表 3.2　PASCAL VOC 数据集各类别样本分布详情。数据呈现显著的长尾分布，头部类别（如 Person）与尾部类别（如 Aeroplane）样本量差异巨大。

Table 3.2　Sample size distribution for each class in the PASCAL VOC dataset. The data exhibits a significant long-tailed distribution, with a large disparity between head classes (e.g., Person) and tail classes (e.g., Aeroplane).

类别	person	chair	car	bottle	sofa	bicycle	horse	pottedplant	diningtable	motorbike
样本数	5,702	1,285	884	452	364	354	333	319	304	300
类别	tvmonitor	dog	bus	cow	boat	bird	cat	train	sheep	aeroplane
样本数	277	251	193	134	125	117	111	87	66	48

3.4.2.2　对比基线与评估指标

将 RECORDS 与四种最先进的偏标签学习（PLL）算法进行了对比，包括：

- **PRODEN**[92]：基于分类器输出的渐进式消歧方法。
- **LW**[93]：利用非偏标签负监督信息的加权方法。
- **CAVL**[131]：基于类激活图的标签鉴别方法。
- **CORR**[132]：引入一致性正则化的鲁棒消歧方法。

为了验证重平衡策略的有效性，引入了常用且性能优越的长尾学习方法 Logit Adjustment (LA)[42] 的两种变体作为对比：

1. **Oracle-LA**：在训练过程中，假设已知真实的类别先验分布（Oracle Prior），并利用 Logit Adjustment 对偏标签学习的过程进行实时重平衡。
2. **Oracle-LA post-hoc**：在偏标签学习模型训练完成后，利用实的类别先验分布对其输出使用 Logit Adjustment 进行后处理（Post-hoc）调整。

需要强调的是，本文提出的 RECORDS 方法直接嵌入上述偏标签学习基线中，且**不需要**任何预知的类别先验信息。主要实验使用 Top-1 分类准确率（Top-1 Accuracy）作为评价指标。

3.4.2.3 实施细节

所有方法均采用 18 层 ResNet 作为骨干网络。数据增强策略遵循文献[139] 的标准设置。模型训练采用 SGD 优化器，动量设置为 0.9，权重衰减为 0.001。批次大小（Mini-batch size）设为 256。初始学习率设为 0.01，并采用余弦退火策略（Cosine Scheduling）衰减。总训练轮数设置为 800 Epochs。对于 RECORDS 中的超参数，动量原型更新系数 m 固定设置为 0.9。

3.4.3 基准测试结果

3.4.3.1 总体性能对比

表 3.3 总结了不同方法在三个基准数据集上的 Top-1 准确率。实验结果表明，RECORDS 在所有数据集和不同实验设置下均取得了显著优于对比方法的性能。

具体而言，与性能最好的偏标签学习基线方法 CORR 相比，RECORDS 实现了全面提升：

- 在 CIFAR-10-LT 上，准确率提升了 **6.45%** ~ **25.68%**；
- 在 CIFAR-100-LT 上，准确率提升了 **3.86%** ~ **7.60%**；
- 在真实数据集 PASCAL VOC 上，准确率提升高达 **32.03%**。

值得注意的是，当标签歧义度 q 增加导致偏标签学习基线性能严重下降时，RECORDS 仍能帮助模型维持相对稳健的表现，展现了极强的鲁棒性。

表 3.3　RECORDS 算法与基线算法在三个基准数据集上的 Top-1 准确率对比。加粗字体表示最优结果，“vs. Baseline”表示 RECORDS 相比于原始偏标签学习基线的提升幅度。

Table 3.3　Top-1 accuracy on three benchmark datasets. Bold indicates the superior results.

	CIFAR-10-LT						CIFAR-100-LT						PASCAL VOC
不平衡比率 IR	50			100			50			100			
歧义度 q	0.3	0.5	0.7	0.3	0.5	0.7	0.03	0.05	0.07	0.03	0.05	0.07	
CORR	76.12	56.45	41.56	66.38	50.09	38.11	42.29	38.03	36.59	38.39	34.09	31.05	24.43
+ Oracle-LA post-hoc	80.70	58.49	43.44	72.96	54.64	41.66	46.94	40.76	39.07	41.49	36.79	33.32	34.12
+ Oracle-LA	36.27	17.61	12.77	29.97	15.80	11.75	22.56	5.59	3.12	11.37	3.32	1.98	52.51
+ RECORDS	**82.57**	**80.28**	**67.24**	**77.66**	**72.90**	**57.46**	**48.06**	**45.56**	**42.51**	**42.25**	**40.59**	**38.65**	**56.46**
vs. CORR	+6.45	+23.83	+25.68	+11.28	+22.81	+19.35	+5.77	+7.53	+5.92	+3.86	+6.40	+7.60	+32.03
PRODEN	73.12	54.45	41.37	63.55	47.37	38.06	39.23	35.45	33.90	34.52	32.04	29.40	22.39
+ Oracle-LA post-hoc	77.41	57.14	42.91	70.71	48.79	41.38	43.40	38.64	35.82	38.40	35.20	31.92	31.53
+ Oracle-LA	27.18	16.97	11.52	19.51	14.11	11.17	12.37	4.09	2.64	6.79	2.73	1.98	48.33
+ RECORDS	**79.48**	**76.73**	**65.31**	**72.15**	**65.22**	**52.26**	**44.56**	**41.31**	**39.26**	**39.13**	**37.23**	**35.26**	**52.65**
vs. PRODEN	+6.36	+22.28	+23.94	+8.60	+17.85	+14.2	+5.33	+5.86	+5.36	+4.61	+5.19	+5.86	+30.26
LW	70.11	37.67	22.73	64.78	39.57	23.54	35.54	29.50	27.86	31.58	28.09	24.65	19.41
+ Oracle-LA post-hoc	74.34	40.27	25.34	69.60	42.34	27.35	35.47	28.80	27.27	31.03	26.96	23.20	21.06
+ Oracle-LA	41.90	21.36	15.28	25.75	20.35	14.24	30.37	14.43	4.79	30.30	5.08	2.70	51.53
+ RECORDS	**76.02**	**57.39**	**40.28**	**71.18**	**57.23**	**41.24**	**36.56**	**31.67**	**29.39**	**33.00**	**28.85**	**25.64**	**53.09**
vs. LW	+5.91	+19.72	+17.55	+6.40	+17.66	+17.70	+1.02	+2.17	+1.53	+1.42	+0.76	+0.99	+33.68
CAVL	56.73	40.27	18.52	54.28	38.97	17.28	29.63	17.31	8.34	28.29	25.39	8.20	17.25
+ Oracle-LA post-hoc	55.23	39.76	18.34	51.37	37.28	14.58	29.65	14.86	5.76	28.34	26.27	5.80	22.27
+ Oracle-LA	22.16	14.97	11.50	18.29	14.23	10.67	17.31	4.36	2.83	7.24	2.55	2.03	50.78
+ RECORDS	**67.27**	**61.23**	**40.71**	**64.35**	**58.27**	**37.38**	**42.25**	**36.53**	**29.13**	**36.93**	**31.49**	**24.98**	**53.07**
vs. CAVL	+10.54	+20.96	+22.19	+10.07	+19.30	+20.1	+12.62	+19.22	+14.27	+8.64	+6.10	+16.78	+35.82

对静态重平衡失效的分析：对比两种 LA 变体可以发现，Oracle-LA 在 CIFAR 数据集上往往导致严重的性能退化（甚至低于原始 Baseline），而在 PASCAL VOC 上则有提升。这印证了本研究的理论分析：Oracle-LA 在训练早期会过度调整（Over-adjustment），干扰标签消歧。相比之下，Oracle-LA post-hoc 由于不影响训练过程中的特征学习和消歧，往往能缓解长尾偏差，但无法解决“有偏消歧”的根本问题。与之形成鲜明对比的是，RECORDS 通过训练过程中的动态重平衡，成功解决了消歧与去偏的冲突，在所有基线（CORR, PRODEN, LW, CAVL）上均取得了最佳且一致的改进。

3.4.3.2　细粒度性能分析

为了更深入地分析模型在不同样本频次类别上的表现，本研究进行了细粒度分析。

类别级准确率可视化：图 3.5 展示了在 CIFAR-10-LT (IR = 100) 上各具体类别的准确率。不出所料，基线方法 CORR 在头部类别（索引 0-2）上表现尚可，但在尾部类别（索引 7-9）上性能急剧下降。Oracle-LA post-hoc 虽然提升了中等类别的性能，但在高歧义度下对尾部类别的改善有限。而 Oracle-LA 甚至损害了头部类别的性能。相比之下，RECORDS 在保留头部性能的同时，系统性地提升了稀有类别的准确率。

头部-中部-尾部划分：表 3.4 展示了 CIFAR-100-LT 上基于 Many（样本数 > 100）、Medium（样本数 20 ~ 100）和 Few（样本数 < 20）划分的准确率。可以看到：

- CORR 在头部类别（Many）上表现良好，但在尾部类别（Few）上几乎失效（例如 $q = 0.07$ 时 Few 准确率仅为 0.07%）。
- Oracle-LA 由于严重的过矫正，导致 Many 类别的准确率崩塌至接近 0，这解释了其总体性能低下的原因。
- RECORDS 在结合 CORR 后，在 Medium 和 Few 类别上实现了显著且一致的增长（例如 $q = 0.07$ 时 Few 准确率提升了 4.30%，Overall 提升了 7.60%），同时在 Many 类别上也保持了相当的竞争力。

这表明 RECORDS 成功缓解了长尾学习中常见的“头尾权衡（Head-to-tail Tradeoff）”问题，在提升尾部性能的同时未牺牲头部性能。

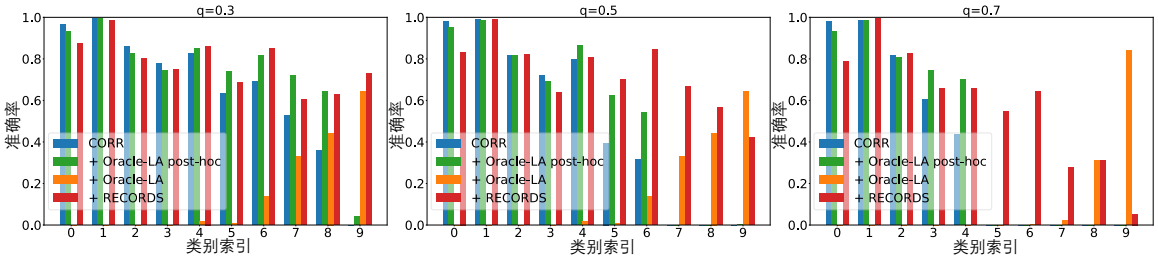


图 3.5　RECORDS 算法与基线算法在 CIFAR-10-LT (IR = 100) 上各类别准确率的细粒度对比，歧义度 $q \in \{0.3, 0.5, 0.7\}$。基线 CORR 在头部类别上表现出强烈偏置，而 CORR + RECORDS 在稀有类别（Rare Classes）上取得了显著提升。

Figure 3.5　The per-class accuracy on CIFAR-10-LT with IR = 100 and $q \in \{0.3, 0.5, 0.7\}$.

表 3.4　RECORDS 算法与基线算法在 CIFAR-100-LT (不平衡比率 IR = 100) 上的细粒度性能分析。Many/Medium/Few 分别对应长尾分布中的头部、中部和尾部类别划分。

Table 3.4　Fine-grained analysis on CIFAR-100-LT with IR = 100. Many/Medium/Few corresponds to three partitions on the long-tailed data.

算法名称	歧义度 $q = 0.03$				$q = 0.05$				$q = 0.07$			
	Many	Medium	Few	Overall	Many	Medium	Few	Overall	Many	Medium	Few	Overall
CORR	68.43	37.40	4.50	38.39	67.51	29.60	0.33	34.09	68.86	19.80	0.07	31.05
+ Oracle-LA post-hoc	70.37	41.89	7.33	41.49	70.46	33.40	1.47	36.79	69.77	24.86	0.67	33.32
+ Oracle-LA	11.03	12.34	10.63	11.37	0.34	4.46	5.47	3.32	0.00	0.71	5.77	1.98
+ RECORDS	66.37	42.54	13.77	**42.25**	68.49	40.20	8.50	**40.59**	69.97	36.71	4.37	**38.65**
vs. CORR	-2.06	+5.14	+9.27	+3.86	+0.98	+10.60	+8.17	+6.50	+1.11	+16.91	+4.30	+7.60

3.4.4　进一步分析

为了全面评估 RECORDS 的有效性与鲁棒性，本节进行了多维度的深入分析，包括与其他动态策略的对比、特征表示质量的评估、与更多长尾学习基线的比较，以及超参数敏感性分析。

3.4.4.1　其他动态重平衡策略对比

表 3.5　RECORDS 算法与不同动态重平衡策略在 CIFAR-10-LT 和 CIFAR-100-LT 上的 Top-1 准确率对比。Temp Oracle-LA 采用线性退火策略，Epoch RECORDS 采用基于 Epoch 的分布估计。
Table 3.5　Comparison with other dynamic strategies on CIFAR-10-LT and CIFAR-100-LT.

	CIFAR-10-LT						CIFAR-100-LT					
不平衡比 IR	50			100			50			100		
歧义度 q	0.3	0.5	0.7	0.3	0.5	0.7	0.03	0.05	0.07	0.03	0.05	0.07
CORR	76.12	56.45	41.56	66.38	50.09	38.11	42.29	38.03	36.59	38.39	34.09	31.05
+ Temp Oracle-LA	81.37	43.62	18.10	76.09	25.88	16.11	47.44	43.46	29.75	41.78	39.19	33.69
+ Epoch RECORDS	75.43	70.27	59.50	69.38	63.12	47.85	46.54	43.07	38.28	41.58	37.14	34.38
+ RECORDS	**82.57**	**80.28**	**67.24**	**77.66**	**72.90**	**57.46**	**48.06**	**45.56**	**42.51**	**42.25**	**40.59**	**38.65**

为了验证 RECORDS 设计的优越性，本研究构建了两种直观的动态重平衡替代策略作为对比：

1. **Temp Oracle-LA**：在训练过程中，利用温度缩放（Temperature Scaling）机制，将用于 Logit Adjustment 的先验项 $\log P_{\text{train}}(y)$ 的系数从 0 线性增加到 1。这是一种显式的人工动态策略。
2. **Epoch RECORDS**：不使用动量原型，而是直接利用上一轮（Epoch）所有样本预测结果的平均值来估计当前的类别分布，并用于本轮的重平衡。

表 3.5 展示了不同动态策略在 CIFAR-10-LT 和 CIFAR-100-LT 上的性能对比。结果显示，虽然 Temp Oracle-LA 和 Epoch RECORDS 相比于静态策略有一定改善，但 RECORDS 依然显著优于它们。这表明，简单的人工动态规则（如线性退火）难以完美匹配复杂的消歧过程，而基于动量原型的实时估计能够更平滑、更准确地捕捉训练动态。

3.4.4.2　非均匀标签歧义场景

现实世界中的标签歧义往往发生在语义相似的类别之间。为了评估 RECORDS 在更贴近实际场景下的性能，本研究在 CIFAR-100-LT 上引入了**非均匀翻转（Non-uniform）**设定（即 CIFAR-100-LT-NU）。在此设定下，负标签更有可能来自与真实标签属于同一超类（Superclass）的类别。

表 3.6 展示了在非均匀设定下的细粒度性能分析。可以看到，在所有歧义度设置下，结合 RECORDS 的 CORR 方法均取得了显著的性能提升。这证明了 RECORDS 具有良好的泛化能力，能够有效应对具有语义结构的复杂标签噪声。

表 3.6　RECORDS 算法与基线算法在 CIFAR-100-LT-NU (非均匀设定, IR = 100, $q \in \{0.03, 0.05, 0.07\}$) 上的细粒度性能分析。

Table 3.6　Fine-grained analysis on CIFAR-100-LT-NU with IR = 100 and $q \in \{0.03, 0.05, 0.07\}$.

算法名称	$q = 0.03$				$q = 0.05$				$q = 0.07$			
	Many	Medium	Few	Overall	Many	Medium	Few	Overall	Many	Medium	Few	Overall
CORR	66.71	34.57	3.13	36.39	70.23	21.57	0.13	32.17	65.37	16.11	0.13	28.56
+ Oracle-LA post-hoc	69.80	40.43	4.57	39.95	71.20	28.77	1.30	35.38	68.71	20.17	1.10	31.44
+ Oracle-LA	3.26	9.97	13.10	8.56	0.86	5.34	12.27	5.85	0.00	0.25	16.87	5.92
+ RECORDS	65.60	41.26	11.77	**40.93**	66.40	38.71	8.57	**39.36**	62.09	37.40	7.47	**37.06**
vs. CORR	-1.11	+6.69	+8.44	+4.54	-3.83	+17.14	+8.44	+7.19	-3.28	+21.29	+7.34	+8.50

3.4.4.3　特征表示质量评估

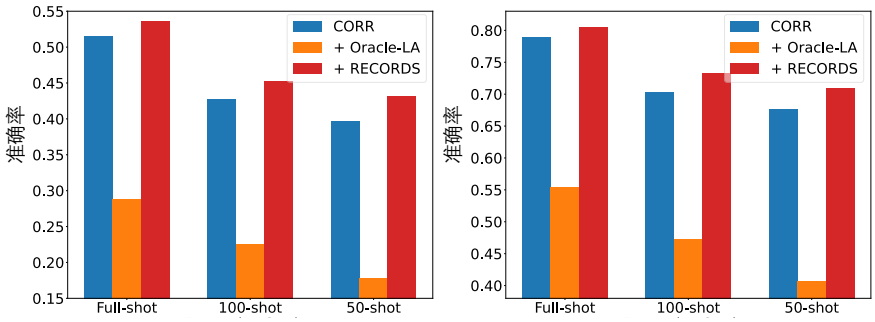


图 3.6　RECORDS 算法与基线算法的线性探测（Linear Probing）性能评估。在 CIFAR-100-LT (IR = 100, $q = 0.05$) 上预训练模型，并评估其特征在平衡数据集上的线性分类能力。

Figure 3.6　(a) Top-1 accuracy (left) and top-5 accuracy (right) under different shots of linear probing for different methods pretrained on CIFAR-100-LT (IR = 100, $q = 0.05$).

为了定量评估不同方法学到的特征表示质量，本研究采用了自监督学习领域常用的**线性探测（Linear Probing）**评估方案。具体而言，首先在在 CIFAR-100-LT (IR = 100, $q = 0.05$) 上预训练模型，固定其特征提取器参数，并在一个类别平衡的数据集上训练线性分类器。

图 3.6 展示了不同训练样本量（Shots）下的线性探测准确率。结果表明，RECORDS 在 Top-1 和 Top-5 准确率上均一致优于基线方法。这说明动态重平衡不仅改善了最终的分类性能，还帮助模型学习到了更具判别性、质量更高的特征表示。

3.4.4.4　更多长尾学习基线对比

除了 Logit Adjustment，本研究还将 RECORDS 与其他两类长尾学习方法进行了对比：1. 基于对比学习的 SOTA 长尾方法：BCL[140] 和 PaCO[141]（均使用准确的类别先验分布）。2. 专门针对偏标签学习中不平衡问题的正则化方法：LDD[96] 和 SFN[96]。

如表 3.7 所示，RECORDS 在所有指标上均显著优于这些方法。这进一步证实了简单地迁移长尾方法（如 BCL, PaCO）或使用简单的正则化（如 LDD, SFN）无法解决 LT-PLL 中的动态耦合问题，而 RECORDS 提供的动态重平衡机制才是关键。

表 3.7　RECORDS 算法与更多长尾学习基线的对比，包括对比学习方法（Oracle-BCL, Oracle-PaCO）和正则化方法（LDD, SFN）。

Table 3.7　Comparison with more baselines for imbalanced learning.

	CIFAR-10-LT						CIFAR-100-LT					
不平衡比率 IR	50			100			50			100		
歧义度 q	0.3	0.5	0.7	0.3	0.5	0.7	0.03	0.05	0.07	0.03	0.05	0.07
CORR	76.12	56.45	41.56	66.38	50.09	38.11	42.29	38.03	36.59	38.39	34.09	31.05
+ Oracle-BCL	43.76	25.24	17.34	33.23	18.34	15.72	27.23	10.34	8.34	14.34	5.82	4.10
+ Oracle-PaCO	42.45	26.34	16.23	34.21	18.23	14.23	27.37	11.23	7.23	15.82	5.62	4.72
+ LDD	75.23	58.02	42.14	67.59	51.38	39.28	42.91	39.05	36.98	39.20	34.87	32.15
+ SFN	75.98	57.13	41.77	66.91	50.23	38.71	43.14	38.62	37.03	39.31	33.91	31.67
+ RECORDS	**82.57**	**80.28**	**67.24**	**77.66**	**72.90**	**57.46**	**48.06**	**45.56**	**42.51**	**42.25**	**40.59**	**38.65**

3.4.4.5　动量系数 m 的敏感性分析

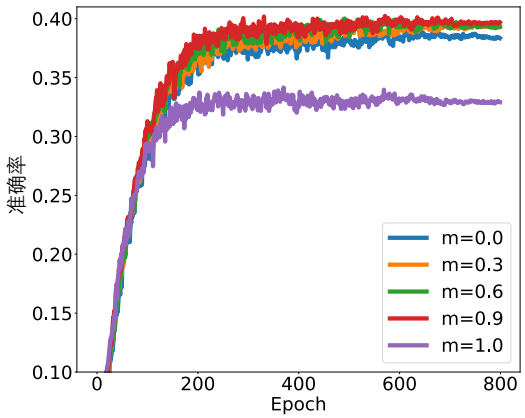
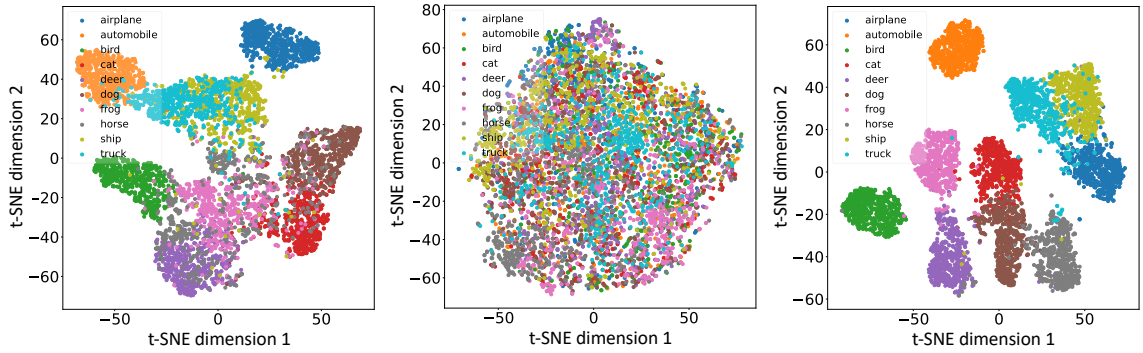


图 3.7　RECORDS 算法的动量系数 m 对性能的影响 (CIFAR-100-LT, IR = 100, q = 0.05)。

Figure 3.7　Performance of CORR + RECORDS with varying m on CIFAR-100-LT (IR = 100, q = 0.05)**.**

动量系数 m 控制着原型特征更新的平滑程度。图 3.7 展示了在 CIFAR-100-LT



(a) PRODEN　(b) PRODEN + Oracle-LA　(c) PRODEN + RECORDS

图 3.8　RECORDS 算法与基线算法在 CIFAR-10-LT (IR = 100, q = 0.5) 上图像特征表示的 t-SNE 可视化对比。PRODEN + Oracle-LA 由于过强的静态校准导致特征学习失败，而 RECORDS 产生了最具判别性的特征分布。

Figure 3.8　t-SNE visualization of image representations on CIFAR-10-LT with IR = 100 **and** q = 0.5**. Note that PRODEN + Oracle-LA post-hoc shares the same feature space as PRODEN since it only adjusts logits during inference.**

(IR = 100, q = 0.05) 上，不同 m 取值对模型性能的影响。可以看到：

- 最佳性能出现在 m = 0.9 附近，这与大多数动量更新算法的经验设置一致。
- 即使在 m = 0（即完全依赖当前 Batch 的统计量）时，RECORDS 依然保持了具有竞争力的性能，显示了较强的鲁棒性。
- 当 m = 1.0 时，原型特征不再更新，RECORDS 退化为原始的 CORR 方法，性能随之下降。

3.4.4.6　特征可视化分析

为了直观地评估模型学到的特征表示的判别能力，本研究利用 t-SNE 技术[142] 对 CIFAR-10-LT 数据集（IR = 100, q = 0.5）上的图像特征进行了降维可视化。图 3.8 展示了 PRODEN、PRODEN + Oracle-LA 以及 PRODEN + RECORDS 三种方法学到的特征分布。

从图中可以观察到：

- **PRODEN（图 3.8a）：** 受限于严重的长尾不平衡和标签歧义，基线方法学到的特征分布较为混乱。不同类别的特征簇之间存在明显的重叠（Overlap），且边界模糊，表明模型难以有效区分不同的语义类别。
- **PRODEN + Oracle-LA（图 3.8b）：** 由于在训练早期引入了强硬的静态重平衡（Constant Rebalancing），该方法不仅未能改善特征质量，反而导致特征表示进一步坍塌。特征簇变得更加松散且难以区分，这与其在分类准确率上的崩塌表

现一致。

- **PRODEN + RECORDS (图 3.8c):** 相比之下, 引入动态重平衡机制的 RECORDS 产生了类间分离度最高、类内紧凑度最好的特征表示。各类别形成了清晰独立的簇结构，这直观地解释了 RECORDS 在分类性能上的显著优势。

需要说明的是，Oracle-LA post-hoc 仅在推理阶段调整 Logit，并不改变特征提取器的参数，因此其特征分布图与原始 PRODEN 相同，此处未重复展示。

3.5 本章小结

本章针对“监督信号退化”这一复杂偏倚场景下的子问题——**长尾偏标签学习 (LT-PLL)** 进行了深入研究。在此场景中，模型同时面临着数据分布的长尾不平衡与监督信号的标签歧义双重挑战。

首先，本研究通过理论分析与实证观察揭示了直接组合现有技术所面临的核心困境：传统的长尾重平衡方法（如 Logit Adjustment）依赖于静态的、有偏的训练集先验分布，而偏标签学习中的标签消歧是一个动态的、从模糊到清晰的过程。在训练初期强行引入静态长尾先验进行重平衡，会严重干扰标签消歧的进程，导致模型产生“过度自信”的错误判断，进而引发训练崩塌。这一发现指出了解决 LT-PLL 问题的关键在于实现**消歧动态与校准策略的协同**。

基于此，本研究提出了一种通用的动态重平衡算法，RECORDS（REbalanCing fOR Dynamic biaS）。该算法包含两个核心创新点：

1. **参数化动态分解：** 本研究在贝叶斯框架下对传统的 Logit Adjustment 进行了参数化重构，提出利用模型当前参数下隐含的动态类别分布 $P_{\text{train}}(y|\Theta)$ 替代静态统计先验 $P_{\text{train}}(y)$ 进行实时校准。这种机制使得重平衡强度能够自适应地随消歧进程而变化：在早期保持温和以保护消歧，在后期逼近真实分布以消除长尾偏差。
2. **动量原型估计：** 为了高效且稳定地获取动态分布估计，本研究设计了基于动量更新的原型特征（Momentum Prototype）机制。通过 NWGM 近似，利用特征空间的统计量实时估计类别分布，既避免了全数据集扫描的高昂开销，又增强了估计的鲁棒性。

理论分析证明，在满足小歧义度条件下，RECORDS 的动态估计分布能够以大概率收敛于真实的类别先验，从而在理论上保证了该方法与静态重平衡的一致性。在 CIFAR-10-LT、CIFAR-100-LT 以及真实世界数据集 PASCAL VOC 上进行的广泛实验

表明，RECORDS 能够显著提升各类偏标签学习基线的性能，特别是在面对高歧义度和极端长尾分布时表现出了卓越的鲁棒性。此外，可视化的仿真实验与特征分布分析直观地验证了该方法在纠正决策边界和优化特征表示方面的有效性。

综上所述，本章工作从动态演化的视角重新审视了长尾学习中的分布校准问题，成功解决了标签歧义与长尾分布之间的耦合冲突，为后续章节处理更复杂的监督信号退化问题（如噪声标签）提供了重要的思路启示。

3.5.1 局限性与讨论

本章针对长尾偏标签学习中的消歧失配难题，提出了基于动量原型的动态校准算法 RECORDS。通过理论分析与实证观察，本研究揭示了静态先验修正对动态消歧进程的干扰机制，并验证了动态重平衡范式在复杂偏倚场景下的优越性。

虽然本研究所提出的方法在多个基准中展现出显著的性能增益，但从研究范式的深度演化来看，本章工作仍有进一步探讨的空间。首先，基于动量原型的类别分布估计在本质上依赖于深度神经网络在训练过程中实时提取的特征表征质量。在模型参数随机初始化的训练初期，特征空间尚不具备良好的类间判别性，此时通过全局特征期望估算的动态分布可能存在一定范围内的偏差或瞬时扰动。虽然这种不确定性通过动量平滑机制得到了有效缓解，但在未来的研究中，社区可以探索如何通过引入自监督一致性约束或元学习初始化策略，来进一步增强早期分布估计的收敛速度与稳健性。

此外，本章提出的动态校准思想具备较强的泛化潜力，能够为学术界解决更深层次的监督信号退化问题提供方法论启示。在现实应用中，标签退化往往不仅限于本章探讨的歧义集形式，还可能伴随着随机标注错误或多模态场景下的对齐缺失。后续研究可以进一步探索将分布层面的动态感知机制推广至长尾噪声学习等更具挑战性的场景，通过实时监测分布演变来辅助样本层面的清洁度甄别，从而实现去偏与抗噪的高效协同。

第 4 章　基于双粒度最优传输蒸馏的长尾噪声标签学习

4.1　引言

在上一章中，本文探讨了监督信号退化的一种形式——标签歧义（偏标签），并提出了解决长尾偏标签学习问题的动态校准方法。然而，在更广泛的现实场景中，监督信号的退化往往表现为一种更为严峻的形式：标签噪声（Label Noise）[143]。与偏标签学习中包含真实标签的候选集合不同，噪声标签意味着样本被错误地标注为了其他类别，提供了完全错误的监督信息。这种现象在深度学习所依赖的大规模数据集[144]中普遍存在，无论是通过网络爬虫自动获取的数据[145]，还是在医疗诊断[24,146-147]等高难度领域由人工标注的数据，都难以避免标注错误。

更为复杂的是，正如第 1 章所述，真实世界的数据分布往往天然呈现出显著的长尾特征[28,49]。这就构成了“长尾噪声标签学习”（Long-Tailed Noisy Label Learning, LT-NLL）这一复合挑战。在此场景下，模型不仅要克服头部类别主导带来的分布偏差，还要抵御错误标注带来的误导，这对于自动驾驶、智慧医疗等注重可靠性的应用构成了巨大风险。

尽管学术界针对长尾分布[30,40-42,83,148-150]和噪声标签[101-102,151-153]分别发展了相对成熟的解决方案，但简单地将两者结合往往难以奏效，甚至适得其反[105]。其根本原因在于处理这两类问题时的优化目标存在内生冲突。长尾学习的核心策略通常是提升尾部类别的权重，迫使模型关注那些样本稀缺的类别。然而，噪声样本往往也表现为高损失值，这与难学的尾部样本特征极其相似。盲目提升高损失样本的权重，实际上会放大噪声信号，导致模型对错误标签过拟合。反之，噪声标签学习的主流策略倾向于信任低损失样本，而过滤或降权高损失样本。但在长尾分布中，尾部样本由于训练不足，天然具有较高的损失值。若盲目应用去噪策略，则容易将珍贵的尾部样本误判为噪声并加以丢弃，最终导致尾部类别的性能崩塌。

因此，该问题的核心难点在于：如何在缺乏清晰监督信号的情况下，有效区分由分布稀缺导致的难样本与由标注错误导致的噪样本。现有的研究[103,105,154]往往需要在“保留尾部”和“过滤噪声”之间进行艰难的权衡，难以兼顾。面对上述困境，与其试图从零开始设计一个复杂的端到端模型来同时解决两个冲突目标，本文提出了一个全新的研究视角：能否通过智能地协同利用多个“弱”辅助模型来突破复合场景的瓶颈？这里的辅助模型指的是仅擅长处理长尾问题或仅擅长处理噪声问题的单项专家。

这一视角的动机在于本文对问题粒度的洞察。长尾不平衡本质上是一个分布级（Distributional-level）的问题，关注的是类别层面的统计规律；而标签噪声本质上是一个样本级（Sample-level）的问题，关注的是单个实例的标注正确性。由于这两个问题作用于不同的粒度，针对它们的鲁棒性机制在原则上应当是互补而非冲突的。如果能够在一个统一的框架下，分别提取出抗噪专家在样本级的鉴别能力和长尾专家在分布级的平衡能力，就有可能实现协同增效。

基于上述视角，本章提出了一种名为 D-SINK (Dual-granularity Robust Distillation) 的统一抗噪蒸馏框架。该框架旨在通过知识蒸馏的方式，将分别具备单项鲁棒性的辅助模型的互补知识集成到目标模型中。具体而言，本研究并不要求辅助模型在复合场景下表现完美，而是利用它们各自的强项。为了解决蒸馏过程中的目标冲突，本研究设计了一种基于最优传输（Optimal Transport, OT）的替代标签分配机制。在样本粒度上，通过最优传输代价矩阵，迫使目标模型的预测与抗噪辅助模型的输出对齐，从而利用其样本筛选能力过滤噪声；在分布粒度上，通过最优传输的边际约束，迫使目标模型的类别预测分布与长尾辅助模型的先验分布对齐，从而利用其平衡能力消除偏差。

本章的主要贡献总结如下：

- 本研究提出并验证了一个新颖的观点，即长尾噪声学习的突破口不在于设计复杂的单一损失函数，而在于通过协同机制整合多个仅具备单项能力的“弱”辅助模型。
- 本研究提出了 D-SINK 框架，利用最优传输理论构建了双粒度蒸馏机制。该方法在样本级利用抗噪模型进行去噪，在分布级利用长尾模型进行去偏，有效地化解了优化目标的冲突。
- 在包含不同噪声模式、噪声比率和不平衡比率的基准数据集上的广泛实验表明，D-SINK 显著优于现有的前沿方法，证明了这种“分而治之、协同蒸馏”策略在处理复杂耦合数据时的鲁棒性。

4.2　算法研究

本节将详细阐述本文提出的基于双粒度最优传输的统一鲁棒蒸馏框架（D-SINK）。首先，本小节将对长尾噪声标签学习（LT-NLL）问题进行形式化的数学定义，明确输入空间、标签空间以及数据的分布特性。随后，后续小节将详细介绍 D-SINK 框架的核心组件，解释如何利用辅助模型构建双粒度蒸馏策略，并描述优化的具体过程及

计算复杂度分析。

4.2.1　问题描述

在长尾噪声标签学习任务中，设 $\mathcal{X}$ 表示输入特征空间（例如图像像素空间），$\mathcal{Y} = \{1, 2, \ldots, C\}$ 表示包含 C 个类别的标签空间。一个包含 N 个样本的长尾噪声训练数据集可表示为 $\mathcal{D} = \{\boldsymbol{x}_i, \hat{y}_i\}_{i=1}^{N}$，其中 $\boldsymbol{x}_i \in \mathcal{X}$ 为第 i 个样本的输入特征，$\hat{y}_i \in \mathcal{Y}$ 为该样本对应的观测标签（Observed Label）。值得注意的是，由于标注噪声的存在，观测标签 $\hat{y}_i$ 可能不等于样本潜在的真实标签（Ground Truth）y_i，且真实标签 y_i 在训练过程中是不可见的。

该训练数据集 $\mathcal{D}$ 在分布上同时呈现出长尾不平衡与标签噪声两个显著特征。对于长尾特征，若令 N_c 表示类别 $c \in \mathcal{Y}$ 的样本数量，并假设类别索引已按照样本数量降序排列（即 $N_1 \geq N_2 \geq \cdots \geq N_C$），则数据分布表现为头部类别样本充足而尾部类别样本极度匮乏。这种不平衡程度通常通过不平衡比率（Imbalance Ratio, IR）来量化，定义为最大类样本数与最小类样本数之比，即 $\mathrm{IR} = \frac{\max_c N_c}{\min_c N_c}$。在本文研究的场景中，IR 通常显著大于 1（即 $\mathrm{IR} \gg 1$），表明数据集存在严重的不平衡。

对于噪声特征，数据集中部分样本的观测标签是错误的。噪声强度通过噪声比率（Noise Ratio, NR）来衡量，定义为训练集中错误标注样本所占的比率，即 $\mathrm{NR} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{I}(\hat{y}_i \neq y_i)$，其中 $\mathbb{I}(\cdot)$ 为指示函数，当条件为真时取值为 1，否则为 0。

本研究的学习目标是利用上述有偏且含噪的训练集 $\mathcal{D}$，训练一个深度神经网络模型 $f : \mathcal{X} \to P(\mathcal{Y})$（其中 $p(\mathcal{Y})$ 表示在标签空间上的概率分布），使其具有良好的泛化能力。为了公平地评估模型性能，评估过程通常在一个标签清晰且类别平衡的测试集 $\mathcal{D}_{\text{test}}$ 上进行，旨在最小化模型在该测试集上的分类错误率。这一问题的核心挑战在于，训练数据的经验分布 $P_{\mathcal{D}}(\boldsymbol{x}, \hat{y})$ 与测试数据的理想分布 $P_{\text{test}}(\boldsymbol{x}, y)$ 在类别先验（$P(\hat{y})$ vs $P(y)$）和条件概率（$P(\hat{y}|\boldsymbol{x})$ vs $P(y|\boldsymbol{x})$）两个维度上均存在严重偏差。

4.2.2　核心动机：粒度解耦与协同

针对第 4.2.1 节中界定的长尾分布与标签噪声双重挑战，本研究从问题的内在机理出发，捕捉到了一个关键的差异：这两个问题实际上作用于完全不同的粒度层面。

具体而言，长尾不平衡本质上呈现为一种数据集级别的分布属性（Distributional Property），它关乎全局的类别结构失衡；相比之下，标签噪声则表现为具体的样本级别的实例属性（Instance-level Property），属于对个体数据的随机扰动。

正是这种作用粒度上的显著区别，为本研究提供了解题思路。与其试图用单一机

制强行应对复杂的混合场景，不如采用“分而治之”的策略。这一差异启发本研究去探索一种协同机制，旨在分别汲取针对长尾问题和噪声问题专用方法的优势，并将它们有机地结合起来。

在直观的实现层面，本研究可以引入两个辅助模型来分别充当这两个领域的“专家”。令 f_L 为利用成熟的长尾学习算法 A_L 在数据集 $\mathcal{D}$ 上训练得到的模型，它主要关注缓解分布差异；同时令 f_N 为利用噪声标签学习算法 A_N 训练得到的模型，它专注于识别并对抗样本噪声。本研究的核心策略，即是利用这两个辅助模型所蕴含的特定领域知识来增强目标模型 f 的学习能力。通过这种粒度解耦后的协同指导，本研究期望目标模型 f 最终能够具备双重鲁棒性，在长尾噪声数据上实现理想的泛化性能。

4.2.2.1　朴素蒸馏的局限性

为了同时利用长尾专家 f_L 和噪声专家 f_N 的优势，最直观的策略是构建一个多教师知识蒸馏框架，让两者共同指导学生模型 f 的训练。现有研究通常采用加权聚合的方式来融合来自不同教师的知识[155-157]。如果本研究采用最简单的均等权重策略，这种朴素蒸馏的目标函数可以定义为公式 (4.1) 所示的形式，即计算学生模型与两位教师模型输出分布之间的 Kullback-Leibler 散度之和：

$$\mathcal{L}_{\text{Dist}} = \sum_{i=1}^{N} \left[D_{\text{KL}}(f_L(\boldsymbol{x}_i) \| f(\boldsymbol{x}_i)) + D_{\text{KL}}(f_N(\boldsymbol{x}_i) \| f(\boldsymbol{x}_i)) \right], \tag{4.1}$$

其中 $D_{\text{KL}}(\cdot\|\cdot)$ 表示 Kullback-Leibler 散度。

虽然 f_L 和 f_N 在各自的领域内表现优异，但简单的直接叠加忽略了它们之间存在的内在逻辑冲突，这种矛盾在近期的多项研究中也得到了证实[103-104,158-159]。例如，对于一个具有高损失值的困难样本，f_L 倾向于将其视为尾部类别的样本，从而增加对其的学习关注度；相反，f_N 则倾向于将其视为噪声样本，从而减少甚至放弃对其的学习。如公式 (4.1) 所示的直接加权多教师蒸馏方法无法解决这种内在冲突，往往导致次优的结果。

4.2.3　双粒度蒸馏策略构建

D-SINK 方法的核心洞察在于根据辅助模型各自的鲁棒性机制，在不同的粒度上充分发挥其优势。本研究注意到，类别不平衡本质上属于数据集层面的分布属性，而标签噪声则具体对应到个别样本。基于这一区别，本研究提出了一种分层指导策略：应当让长尾专家模型 f_L 在分布粒度上把控全局，同时让抗噪专家模型 f_N 在样本粒度上提供具体指引。

为落实这一策略，本研究引入了一组几何代理标签（Geometric Proxy Labels）$Q = [\mathbf{q}_1, \mathbf{q}_2, \ldots, \mathbf{q}_N] \in \mathbb{R}^{C\times N}$。对于每一个样本 $\boldsymbol{x}_i$，其对应的代理标签 $\mathbf{q}_i$ 是一个位于 C 维概率单纯形 Δ^C 上的向量。这些标签并非固定不变，而是作为动态优化的学习目标来辅助训练最终的目标模型 f。这些代理标签的确定需要同时兼顾两个维度的约束：在样本微观层面上，$\mathbf{q}_i$ 需要尽可能贴近抗噪模型 $f_N(\boldsymbol{x}_i)$ 的预测结果；在分布宏观层面上，所有代理标签的聚合结果 $\sum_{i=1}^N \mathbf{q}_i$ 必须与抗不平衡模型预测的总体类别分布 $\sum_{i=1}^N f_L(\boldsymbol{x}_i)$ 保持一致。D-SINK 的整体思想如图 4.1 所示。

通过向这些兼具双重特性的几何代理标签 Q 学习，目标模型 f 就能同时获得对抗噪声标签和长尾分布的能力。基于此，本研究定义的蒸馏损失函数如下：

$$\begin{aligned}\mathcal{L}_{\text{D-SINK}} =& \frac{1}{N}\sum_{i=1}^{N}\Bigg[\underbrace{D_{\text{KL}}(\mathbf{q}_i \| f_N(\boldsymbol{x}_i))}_{\text{① } Q \text{ 与 } f_N \text{ 的样本级对齐}} + \underbrace{D_{\text{KL}}(\mathbf{q}_i \| f(\boldsymbol{x}_i))}_{\text{③ } f \text{ 向 } Q \text{ 学习}}\Bigg], \\ &\underbrace{\text{s.t.},\ Q\cdot\mathbf{1}_N = \sum_{i=1}^{N} f_L(\boldsymbol{x}_i), \quad Q^\top\cdot\mathbf{1}_C = \mathbf{1}_N\,.}_{\text{② } Q \text{ 与 } f_L \text{ 的分布级对齐}}\end{aligned} \tag{4.2}$$

其中，$\mathbf{1}_N$ 和 $\mathbf{1}_C$ 分别表示维度为 N 和 C 的全 1 列向量。公式 (4.2) 中的各项约束在指导模型学习时扮演着不同的角色。

第一项约束关注样本级对齐。它强制几何代理标签 $\mathbf{q}_i$ 在逐样本的基础上逼近抗噪模型 f_N 的预测。这一机制鼓励 Q 捕捉每个输入 $\boldsymbol{x}_i$ 的局部语义信息，并以具备噪声鲁棒性的方式进行编码。

第二项约束通过规范 Q 的全局行为来实现分布级对齐。具体而言，前半部分 $Q\cdot\mathbf{1}_N = \sum_{i=1}^N f_L(\boldsymbol{x}_i)$ 确保了 Q 的类别分布与长尾专家 f_L 保持一致，而后半部分 $Q^\top\cdot\mathbf{1}_C = \mathbf{1}_N$ 则保证 Q 的每一列都构成有效的概率分布。

最后一项则是针对模型 f 的知识蒸馏。本研究通过最小化 $\mathbf{q}_i$ 与 $f(\boldsymbol{x}_i)$ 之间的 KL 散度，促使目标模型 f 从结构化的监督信号 Q 中汲取知识。这一过程让 f 内化了 Q 中蕴含的鲁棒性和分布感知能力，从而显著提升泛化性能。这种设计使得 Q 能够作为一个原则性且可训练的中间监督信号，辅助模型 f 实现对抗标签噪声和类别不平衡的双重鲁棒性。

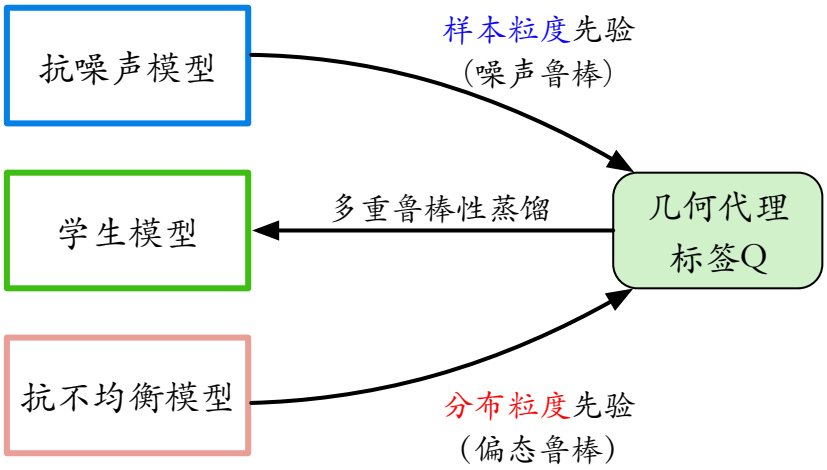


图 4.1　D-SINK 整体示意图
Figure 4.1　Overall Illustration of D-SINK

4.2.3.1　总体目标函数

本研究将上述定义的 $\mathcal{L}_{\text{D-SINK}}$ 融入整体优化框架中，借此将长尾学习和噪声标签学习领域的成熟方法有机结合。本方法的总体目标函数定义如下：

$$\min_{Q,f} \mathcal{L}_{\text{Overall}} = \mathcal{L}_{\text{Base}} + \alpha \mathcal{L}_{\text{D-SINK}}, \tag{4.3}$$

其中 $\mathcal{L}_{\text{Base}}$ 代表从训练集 $\mathcal{D}$ 学习分类任务的基础损失函数，而 α 是控制 $\mathcal{L}_{\text{D-SINK}}$ 权重的超参数。在实际应用中，本研究可以直接采用最常用的交叉熵损失作为基础损失，即 $\mathcal{L}_{\text{Base}} = \frac{1}{N}\sum_{i=1}^{N} -\hat{y}_i \cdot \log f(\boldsymbol{x}_i)$。此外，针对特定的不平衡噪声场景，本研究也可以灵活替换为其他变体损失函数，例如 Wei 等人[105]和 Lu 等人[103]提出的方案。

4.2.4　基于 Sinkhorn 算法的优化求解

公式 (4.3) 定义的目标函数包含两个待优化变量：模型参数 f 和代理标签分布 Q。由于 Q 受到严格的边缘分布约束，且与 f 存在耦合关系，直接使用常规的随机梯度下降算法难以对其进行联合求解。为此，本章采用双层优化策略，将原问题分解为两个交替进行的子过程来逐步逼近最优解。

首先处理内层子问题，即优化模型参数 f。在此阶段，本研究固定 Q 不变，将问题简化为最小化 $\mathcal{L}_{\text{Base}} + \alpha\mathcal{L}_{\text{D-SINK}}$。由于该目标函数关于 f 可微，本研究可以直接利用现有的梯度下降优化器（如 SGD 或 Adam）对 f 进行参数更新，使其拟合当前的代理标签。

问题的核心在于外层子问题，即在固定模型 f 的前提下优化 Q。本研究发现，这

一子问题本质上可以重构为一个最优传输（Optimal Transport, OT）问题。OT 理论旨在解决代价约束下的分布匹配问题，这与本研究的目标高度契合：本研究需要寻找一个代理分布 Q，使其在适应由模型预测 f_N 决定的传输代价的同时，严格满足由 f_L 确定的边缘分布约束。根据这一视角，关于 Q 的优化问题可以重写为如下形式：

$$\begin{aligned}\min_{Q} \mathcal{L}_{\text{D-SINK}} &= \min_{Q} \sum_{i=1}^{N} \mathbf{q}_i \cdot (2\log \mathbf{q}_i - \log f_N(\boldsymbol{x}_i) - \log f(\boldsymbol{x}_i)) \\ &= \min_{Q} \langle Q, P \rangle + 2\sum_{i=1}^{N} \mathbf{q}_i \cdot \log \mathbf{q}_i, \\ \text{s.t.} \quad & Q\mathbf{1}_N = \sum_{i=1}^{N} f_L(\boldsymbol{x}_i), \quad Q^\top \mathbf{1}_C = \mathbf{1}_N,\end{aligned} \tag{4.4}$$

其中，$P \in \mathbb{R}^{C\times N}$ 为代价矩阵，其元素定义为 $p_{ji} = -[\log f_N(\boldsymbol{x}_i)]_j - [\log f(\boldsymbol{x}_i)]_j$；$\langle \cdot, \cdot \rangle$ 表示矩阵的 Frobenius 内积。公式 (4.4) 实际上构成了一个熵正则化最优传输问题。式中的正则化项 $2\sum \mathbf{q}_i \cdot \log \mathbf{q}_i$ 来源于原始损失函数中的两个 KL 散度项，系数 “2” 即对应熵分量的权重。这种正则化不仅使目标函数变为严格凸函数，还使得利用 Sinkhorn-Knopp 算法进行高效求解成为可能。

为了求解该问题，本研究引入拉格朗日乘子法处理约束条件。该问题的拉格朗日函数包含传输代价、熵正则项以及分别对应行和列和约束的对偶项。令其导数为零，可得最优解具有 $Q_{ji} \propto e^{-P_{ji}/2}$ 的形式。这意味着最优传输方案 Q 可以分解为一个核心矩阵与两个对角缩放矩阵的乘积。具体而言，定义核矩阵 $M = e^{-P/2}$（指数运算为逐元素操作），则 Q 的解可表示为：

$$\begin{aligned} Q &= N \cdot \operatorname{diag}(u) M \operatorname{diag}(v), \\ u &\leftarrow \frac{1}{N}\left(\sum_{i=1}^{N} f_L(\boldsymbol{x}_i)\right) ./ (Mv), \\ v &\leftarrow \frac{1}{N}\mathbf{1}_N ./ (M^\top u). \end{aligned} \tag{4.5}$$

其中，$u \in \mathbb{R}^C$ 和 $v \in \mathbb{R}^N$ 为缩放系数向量，符号 ./ 表示逐元素除法。通过交替迭代更新 u 和 v，算法能够快速收敛，从而在满足边缘分布约束的前提下，获得使目标函数最小化的代理标签分布 Q。这种方法不仅保证了优化的理论收敛性，也避免了直接对高维矩阵进行投影操作带来的计算负担。

算法 4.1 D-SINK 算法流程

Input: 目标模型 f；训练数据集 $\mathcal{D}$；在 $\mathcal{D}$ 上通过算法 A_L 和 A_N 预训练的辅助模型 f_L 与 f_N；损失权重 α；Sinkhorn 迭代次数 T

随机初始化目标模型 f;
for *epoch* $= 1, 2, \ldots, E$ **do**
  for *mini-batch* $= 1, 2, \ldots$ **do**
    初始化缩放系数向量 $u \leftarrow \frac{1}{C}\mathbf{1}_C$，$v \leftarrow \frac{1}{N_B}\mathbf{1}_{N_B}$; // N_B 为当前 mini-batch 的样本数
    获取 f_L 和 f_N 对当前 batch 的预测; // 可在训练前对整个数据集预计算并存储
    获取 f 对当前 batch 的预测;
    计算 $M = e^{-\frac{P}{2}}$，$P = [p_1, \ldots, p_{N_B}]$，$p_i = -\log f_N(\boldsymbol{x}_i) - \log f(\boldsymbol{x}_i)$;
    for $t = 1, 2, \ldots, T$ **do**
      $u \leftarrow \dfrac{\sum_{i=1}^{N} f_L(\boldsymbol{x}_i)}{N} \,./\, (Mv)$;
      $v \leftarrow \dfrac{\mathbf{1}_N}{N} \,./\, (M^\top u)$; // Sinkhorn--Knopp 迭代
    $Q \leftarrow N_B \cdot \mathrm{diag}(u)\, M\, \mathrm{diag}(v)$; // 外层循环：优化 Q
    计算损失 $\mathcal{L}_{\text{Base}}$ 和 $\mathcal{L}_{\text{D-SINK}}$;
    通过最小化 $\mathcal{L}_{\text{Overall}} = \mathcal{L}_{\text{Base}} + \alpha\mathcal{L}_{\text{D-SINK}}$ 更新模型 f; // 内层循环：优化 f

表 4.1　D-SINK 算法与标准训练的训练时间对比（秒/Batch）：D-SINK vs. 标准训练，以及 D-SINK 的计算开销（Overhead）

Table 4.1　Training time comparison (seconds per batch): D-SINK vs. standard training, and the computational overhead of D-SINK

算法名称	CIFAR-10	CIFAR-100	Red Mini-ImageNet	Clothing1M
标准训练	1.271	1.274	3.888	3.951
D-SINK	1.426	1.418	4.317	4.263
额外开销	0.155	0.144	0.429	0.312

4.2.5　算法流程与复杂度分析

算法 4.1 给出了 D-SINK 的完整训练流程。需要指出的是，考虑到现代深度学习模型普遍采用 Mini-batch 机制进行优化，代理标签 Q 的更新以及预测分布统计量的估计均在 Mini-batch 级别上进行。这种基于局部批次的近似虽然无法完全复现全数据分布，但在实践中能够稳定刻画类别预测结构，并已被大量工作证明在大规模训练场景下是有效且高效的。此外，相关统计量的计算可以与常规前向传播过程紧密耦合，不会引入额外的数据访问或显著的实现复杂度。

需要强调的是，D-SINK 仅在训练阶段依赖辅助模型 f_L 和 f_N 以提供必要的先验信息和分布参考；在测试或推理阶段，算法完全退化为标准的单模型推理流程，仅使

用目标模型 f 进行预测。因此，该方法不会引入任何额外的推理开销，也不会影响模型在实际部署场景中的响应延迟或资源消耗。

在计算复杂度方面，D-SINK 的额外开销主要来源于 Sinkhorn 迭代过程。具体而言，设 Mini-batch 大小为 N_B，模型参数规模为 P_{param}，类别数为 C。标准训练过程中，每个 Mini-batch 的时间复杂度约为 $O(N_B P_{\text{param}})$。相比之下，D-SINK 在算法 4.1 的第 8–11 行中引入了额外的 Sinkhorn 归一化迭代，其时间复杂度为 $O(N_B TC)$，其中 T 表示迭代次数。在实际实现中，本研究发现当 T 取较小常数（实验中设为 $T = 50$）时即可保证迭代过程的稳定收敛。

鉴于现代深度学习模型的参数规模通常达到数千万甚至更高量级，上述额外项 $N_B TC$ 相较于 $N_B P_{\text{param}}$ 可以忽略不计，因此 D-SINK 相对于标准训练的时间复杂度增量是极其有限的。此外，算法 4.1 第 5 行中涉及的分布统计操作可以在训练前通过推理模式、使用更大的批次进行离线计算，从而进一步减轻在线训练阶段的计算负担。实验结果如表 4.1 所示，在多个数据集上，D-SINK 相较于标准训练仅带来了极小的训练时间开销，验证了该方法在保持有效性的同时具备良好的计算效率。

4.3 实验验证

为了验证 D-SINK 框架的有效性，本章在多个基准数据集上进行了广泛的定量实验，并与当前最先进的方法进行了对比。本节首先介绍实验的具体设置，包括数据集的构建细节、对比基线以及实现细节。

4.3.1 实验设置

4.3.1.1 数据集

为了全面评估本研究提出方法在长尾噪声分布下的鲁棒性，实验选取了多组数据集进行验证。这些数据集涵盖了合成噪声环境与真实世界噪声环境，能够从不同维度反映模型在复杂场景下的性能表现。

针对合成噪声实验，本章以通用的 *CIFAR-10* 和 *CIFAR-100* 数据集[160]作为基础构建测试数据。参照 Lu 等人[105]和 Wei 等人[103]确立的实验标准，数据的构建过程主要分为两个阶段。第一阶段构建长尾分布，本研究遵循 Cui 等人[41]的方案，利用指数采样方法对原始清洁数据集进行重采样，从而生成具有不同不平衡比率的长尾版本。第二阶段注入合成噪声，在上述长尾数据集中引入特定比率的标签噪声。噪声类型包含对称噪声和非对称噪声[106]。其中，对称噪声模拟了标签在类别空间中随机发生错

误的均匀分布；非对称噪声则引入了结构化的标签偏移，模拟现实场景中易混淆类别间的错误标注。本研究在实验中组合了不同的噪声类型、不平衡比率以及噪声比率，以覆盖广泛的测试场景。关于不平衡比率（IR）和噪声比率（NR）的具体定义，请参阅第 4.2.1 节。

除了合成数据，本研究还在包含真实标签噪声的四个数据集上验证了方法的有效性。这些数据集分别是 *CIFAR-10N*[161]、*CIFAR-100N*[161]、*Red Mini-ImageNet*[162] 以及 *Clothing1M*[163]。为了适配长尾学习的设定，本文同样采用指数采样方法处理这些数据集，将其构建为不平衡比率为 10 的长尾分布形式，从而在真实噪声场景下进一步评估模型的鲁棒性。

4.3.1.2　对比基线方法

为了全面评估 D-SINK 框架的有效性，本章选取了多个相关领域的代表性算法进行对比实验。首先，本节采用基于交叉熵损失（CE）的经验风险最小化方法作为最基础的参照。针对标签噪声问题，实验选取了噪声标签学习（NLL）领域的典型方法 DivideMix[102] 和 UNICON[152]。而在长尾分布方面，本研究对比了 Logit Adjustment (LA)[42]、Influence-Balanced Loss (IB)[164] 以及 LDAM[84] 等主流的长尾学习（LTL）算法。更为关键的是，为了直接评估方法在长尾与噪声共存场景下的竞争力，本节重点涵盖了该领域（LT-NLL）的最新进展。具体的对比方法包括 TABASCO[103]、MW-Net[106]、Focal-Rebalance (FR)[158]、HAR[104]、RoLT[105] 以及 RCAL[107]。通过涵盖上述各类主流及先进方法，本章旨在确保评估结果具有广泛的代表性与公正性。

4.3.1.3　实现细节

实验统一采用 18 层 ResNet 作为骨干网络，并应用了标准的数据增强策略。Mini-batch 大小设定为 64。所有方法均使用 SGD 优化器进行训练，动量设置为 0.9，权重衰减设置为 5×10^{-4}。为了保证公平对比，所有方法的模型均训练 300 个 Epoch。初始学习率设定为 0.02，并在第 100 个 Epoch 后，每隔 50 个 Epoch 衰减 10 倍。对于本研究提出的 D-SINK 方法，除非另有说明，公式 (4.3) 中的基础损失 $\mathcal{L}_{\text{base}}$ 采用 Lu 等人[103] 提出的目标函数（即 TABASCO 的损失函数），在此基础上利用 D-SINK 框架进一步提升模型对噪声标签和长尾分布的鲁棒性。为了确保基础损失 $\mathcal{L}_{\text{base}}$ 与蒸馏损失 $\mathcal{L}_{\text{D-SINK}}$ 处于大致相同的数量级，公式 (4.3) 中的超参数 α 设定为 10^{-3}。在辅助模型的选择上，除非另有说明，本研究分别选用 IB 算法和 DivideMix 算法作为长尾算法 A_L 和抗噪算法 A_N，以训练并获取相应的辅助模型 f_L 和 f_N。

4.3.2　实验结果与分析

本小节将详细展示并分析 D-SINK 在合成噪声数据集和真实世界噪声数据集上的实验结果。通过与各类 SOTA 方法的横向对比，验证 D-SINK 在处理长尾分布与标签噪声耦合问题上的有效性与优越性。

4.3.2.1　合成噪声实验分析（CIFAR-10/100）

本节首先在引入合成噪声的长尾 CIFAR-10 和 CIFAR-100 数据集上考察各方法的有效性。实验设计涵盖了对称噪声（如表 4.2 所示）和非对称噪声（如表 4.3 所示）两种典型模式，并通过设置不同的不平衡比率（IR）与噪声比率（NR）组合，对各方法进行了全方位的压力测试。

纵观对比基线方法的表现，现有的主流算法在面对长尾分布与噪声标签的双重挑战时，表现出明显的局限性。在选取的 11 种对比基线中，绝大多数方法（包括经典的 LDAM、DivideMix 等）都难以在所有设定下稳定超越基础的交叉熵（CE）模型。虽然部分针对性方法如 UNICON、TABASCO 和 RoLT 在特定指标上有所建树，但没有任何一种基线方法能够在所有场景中保持优势。即便是表现相对稳健的 TABASCO 方法，其性能也存在波动。例如在 CIFAR-10 非对称噪声（IR=10, NR=0.2）的特定条件下，TABASCO 的准确率甚至不及简单的 Logit Adjustment (LA) 方法。这一现象深刻揭示了长尾噪声学习场景的复杂性：现有的单一策略，无论是侧重去偏还是侧重去噪，或者是简单的模块堆叠，都难以有效解耦并处理这两个高度耦合的问题，从而导致次优的性能。

相比之下，本章提出的 D-SINK 框架展现出了极强的鲁棒性和适应性。在总计 16 种涵盖不同数据集、噪声类型及干扰强度的实验设定中，D-SINK 均取得了最优的测试准确率。特别是在高噪声（NR=0.6）或高不平衡（IR=100）这类极端困难的场景下，D-SINK 相比次优方法的性能优势更为显著。例如在 CIFAR-100 对称噪声（IR=100, NR=0.6）设定下，D-SINK 达到了 30.42% 的准确率，大幅领先于次优算法。

此外，实验结果还揭示了一个值得深入探讨的现象，即“弱教师”构建“强学生”的蒸馏机制。与传统知识蒸馏范式通常依赖高性能教师模型不同，本研究中使用的两个辅助模型（f_L 和 f_N）在许多设定下的单独表现并不突出，部分指标甚至仅与 CE 基线持平。然而，D-SINK 却能基于这些并不完美的辅助模型，最终训练出一个性能远超教师模型的“强”目标模型。这一反差有力地印证了本章的核心观点：解决长尾噪声问题的关键，不在于追求单一维度的完美模型，而在于如何通过双粒度蒸馏机制，有效地从具备特定领域专长的“偏科”模型中提取互补知识，从而实现整体性能

表 4.2　D-SINK 算法与基线算法在 CIFAR-10 和 CIFAR-100 数据集在对称标签噪声下的测试准确率 (%)。表格对比了不同不平衡比率 (10, 100) 和噪声比率 (0.4, 0.6) 下各方法的性能。最优结果加粗显示。

Table 4.2　Test accuracy (%) on CIFAR-10 and CIFAR-100 under symmetric label noise. The table compares various methods across different class imbalance ratios (10, 100) and noise ratios (0.4, 0.6). Best results are highlighted in bold.

噪声模式 (Noise Mode)		对称噪声 (Symmetric)							
数据集 (Dataset)		CIFAR-10				CIFAR-100			
不平衡比率 (Imbalance Ratio)		10		100		10		100	
噪声比率 (Noise Ratio)		0.4	0.6	0.4	0.6	0.4	0.6	0.4	0.6
CE		71.67	61.16	47.81	28.04	34.53	23.63	21.99	15.51
NLL	DivideMix	80.20	79.94	32.42	34.73	47.93	41.65	36.20	26.29
	UNICON	80.81	77.20	64.72	54.37	52.34	44.87	34.01	27.33
LTL	LA	72.32	64.23	52.05	42.64	34.28	24.07	22.59	16.40
	LDAM	74.59	68.17	49.79	36.46	32.29	26.60	18.81	12.65
	IB	72.66	62.19	41.93	34.17	34.85	22.81	20.34	12.10
LTNLL	TABASCO	85.47	84.83	62.76	55.49	56.89	45.68	36.92	28.50
	MW-Net	70.34	58.48	45.54	40.03	32.29	21.71	20.76	14.27
	FR	70.19	60.86	49.36	30.15	30.24	16.99	22.56	15.07
	HAR	74.11	60.92	51.61	37.96	36.53	24.68	20.41	15.03
	RoLT	81.75	79.67	60.21	44.36	43.08	32.57	24.11	16.59
	RCAL	83.43	79.89	61.78	55.31	57.20	43.36	33.36	20.08
D-SINK		**89.00** ±0.28	**86.93** ±0.33	**66.43** ±0.37	**57.80** ±0.45	**58.96** ±0.31	**48.26** ±0.41	**38.66** ±0.27	**30.42** ±0.31

的质变。

4.3.2.2　真实世界噪声实验分析

本章进一步在四个包含真实世界噪声的数据集上评估了模型性能，具体包括 *CIFAR-10N*[161]、*CIFAR-100N*[161]、*Red Mini-ImageNet*[162] 以及 *Clothing1M*[163]。表 4.4 详细展示了各方法在上述数据集上的测试结果。

这些真实数据集中的噪声主要源于人工标注错误或网络爬取偏差，通常具有复杂的实例依赖（Instance-dependent）特性。相比于合成噪声配置，这种更加贴近现实的噪声分布对模型的鲁棒性提出了更为严峻的挑战。实验结果令人振奋：即便在如此复杂的场景下，本文提出的 D-SINK 方法依然保持了强劲的性能，在所有四个数据集上均一致地超越了对比方法。特别是在 CIFAR-100N 和大规模的 Clothing1M 数据集

表 4.3　D-SINK 算法与基线算法在在非对称标签噪声下的 CIFAR-10 和 CIFAR-100 数据集的测试准确率 (%)。表格对比了不同不平衡比率 (10, 100) 和噪声比率 (0.2, 0.4) 下各方法的性能。最优结果加粗显示。

Table 4.3　Test accuracy (%) on CIFAR-10 and CIFAR-100 under asymmetric noise. The table compares various methods across different class imbalance ratios (10, 100) and noise ratios (0.2, 0.4). Best results are highlighted in bold.

噪声模式 (Noise Mode)		非对称噪声 (Asymmetric)							
数据集 (Dataset)		CIFAR-10				CIFAR-100			
不平衡比率 (Imbalance Ratio)		10		100		10		100	
噪声比率 (Noise Ratio)		0.2	0.4	0.2	0.4	0.2	0.4	0.2	0.4
Baseline	CE	79.90	62.88	56.56	44.64	44.45	32.05	25.35	17.89
NLL	DivideMix	80.12	74.73	41.12	42.79	54.83	41.95	36.46	29.69
	UNICON	75.01	72.89	44.48	32.64	57.19	45.43	37.78	30.56
LT	LA	84.92	76.17	58.26	50.30	49.78	36.24	29.07	27.58
	LDAM	78.74	68.68	56.29	38.83	44.43	31.02	23.22	21.04
	IB	70.88	60.32	50.04	31.37	47.48	33.81	27.85	20.05
LTNLL	TABASCO	82.13	80.57	60.35	51.19	59.45	50.43	38.43	32.15
	MW-Net	78.46	64.82	59.37	45.21	43.36	31.25	27.56	20.04
	FR	82.23	69.13	56.62	45.12	47.01	36.09	25.27	20.46
	HAR	78.75	70.23	58.89	49.97	49.36	35.98	27.90	20.03
	RoLT	80.38	78.39	54.79	50.41	50.62	39.32	33.16	25.73
	RCAL	81.65	78.78	56.60	49.85	56.29	42.86	36.15	26.90
D-SINK		**87.09** ±0.32	**84.36** ±0.29	**61.98** ±0.24	**53.06** ±0.46	**61.69** ±0.31	**51.56** ±0.41	**40.10** ±0.34	**34.06** ±0.38

上，D-SINK 均取得了最优的准确率。这种稳健的表现突显了该方法在同时应对真实标签噪声与长尾类别不平衡问题上的卓越能力，充分证明了 D-SINK 框架在实际应用中的潜力和实用价值。

4.3.2.3　头部-中部-尾部细粒度性能分析

为了具体分析不同方法在长尾噪声分布下对各类别的鲁棒性，表 4.5 展示了在 Many（头部）、Medium（中部）和 Few（尾部）类别划分上的细粒度指标。具体而言，本研究在 CIFAR-100 数据集（对称噪声，不平衡比率 10，噪声比率分别为 0.4 和 0.6）上进行了实验。Many、Medium 和 Few 分别对应 CIFAR-100 中样本数最多的 30 个类别、样本数适中的 40 个类别以及样本数最少的 30 个类别。

除了交叉熵（CE）基线外，对比方法还包括分别代表噪声标签学习（DivideMix）、

表 4.4　D-SINK 算法与基线算法在真实世界噪声数据集（CIFAR-10N, CIFAR-100N, Red Mini-ImageNet 和 Clothing1M）上的测试准确率 (%) 对比。最优结果加粗显示。

Table 4.4　Test accuracy (%) comparison on real-world noisy datasets (CIFAR-10N, CIFAR-100N, Red Mini-ImageNet, and Clothing1M). The best results are highlighted in bold.

真实世界噪声标注 (Real-world noisy annotations)							
数据集 (Dataset)		CIFAR-10N		CIFAR-100N		Red Mini-ImageNet	Clothing1M
不平衡比率 (Imbalance Ratio)		10	100	10	100	10	
噪声比率 (Noise Ratio)		≈ 0.4				0.4	≈ 0.4
Baseline	CE	63.44	49.86	38.1	29.26	31.46	46.41
NLL	DivideMix	70.35	55.48	46.87	38.73	41.64	71.09
	UNICON	75.62	<u>62.75</u>	<u>55.32</u>	40.02	38.48	72.34
LT	LA	70.47	60.69	38.67	30.83	35.52	53.28
	LDAM	61.94	51.68	38.37	30.59	32.48	54.01
	IB	62.56	52.06	42.34	32.69	34.56	52.46
LTNLL	TABASCO	<u>80.73</u>	62.47	53.67	<u>40.70</u>	<u>49.68</u>	<u>75.26</u>
	MW-Net	69.73	53.69	44.67	34.40	40.26	58.74
	FR	67.15	49.02	39.44	30.37	33.27	47.04
	HAR	75.87	59.18	44.69	33.96	38.71	55.28
	RoLT	74.84	58.37	47.02	36.21	47.37	63.79
	RCAL	76.74	60.62	48.35	37.23	46.40	69.33
D-SINK		**82.89** ±0.28	**66.12** ±0.33	**55.43** ±0.27	**42.51** ±0.35	**51.46** ±0.26	**76.94** ±0.32

长尾学习（IB）和长尾噪声学习（TABASCO）的三种基线方法。从表 4.5 中可以观察到：

- **噪声标签学习方法（DivideMix）：**由于强调丢弃高损失的“困难样本”，该类方法往往错误地丢弃了大量本身就难以学习的尾部样本，导致 Few 类别的性能极差（例如在噪声比率 0.4 时仅为 9.52%），反而加剧了不平衡问题。
- **长尾学习方法（IB）：**专注于平衡头部与尾部类别的预测，但缺乏对噪声样本的鉴别能力。这导致模型为了提升尾部性能而牺牲了头部类别的准确率（例如在噪声比率 0.6 时 Many 类别的准确率仅为 27.90%）。
- **长尾噪声学习方法（TABASCO）：**作为当前的 SOTA 方法，TABASCO 在各部分之间取得了相对均衡的性能。
- **D-SINK（本研究）：**在 TABASCO 的基础上实现了进一步的提升。D-SINK 在 Medium 和 Few 类别以及整体准确率、Macro-F1 和 AUC 等各项指标上均表现

表 4.5　D-SINK 算法与基线算法在 CIFAR-100（不平衡比率 10）在不同对称噪声比率（0.4 和 0.6）下的多维性能指标。展示了 Many、Medium、Few 划分下的准确率以及整体准确率（%）、Macro-F1 和 AUC。本研究提出的 D-SINK 方法在各项指标上均表现领先。

Table 4.5　Multiple metrics on CIFAR-100 (imbalance ratio 10) under different symmetric noise (ratio 0.4 and 0.6). Performance is detailed for Many, Medium, and Few splits, along with the overall accuracy(%). We also report Macro-F1 and AUC. Our method (D-SINK) demonstrates leading performance, particularly in Medium, Few, overall accuracies, Macro-F1 and AUC.

噪声比率 (Sym)			0.4			
划分 (Split)	Many Acc	Medium Acc	Few Acc	Overall Acc	Macro-F1	AUC
CE	46.77	31.43	16.93	34.53	0.29	0.85
DivideMix	**74.02**	55.58	9.52	47.93	0.46	0.94
IB	42.77	34.77	26.48	34.85	0.34	0.88
TABASCO	66.03	55.12	41.24	56.89	0.53	0.95
D-SINK	68.03	**57.82**	**44.11**	**58.96**	**0.56**	**0.97**
噪声比率 (对称)			0.6			
划分 (Split)	Many Acc	Medium Acc	Few Acc	Overall Acc	Macro-F1	AUC
CE	35.29	17.21	6.93	23.63	0.21	0.79
DivideMix	**65.94**	45.95	9.76	41.65	0.44	0.93
IB	27.90	22.57	17.69	22.81	0.23	0.82
TABASCO	57.26	46.65	35.52	45.68	0.45	0.94
D-SINK	59.45	**47.98**	**36.59**	**48.26**	**0.49**	**0.96**

出一致的优越性，证明了其在兼顾去噪与去偏方面的卓越能力。

4.3.2.4　作为通用框架的兼容性验证

为了验证 D-SINK 作为通用框架的潜力，本研究将其与不同的基线方法（包括 CE, HAR, RoLT 和 TABASCO）进行了集成。具体而言，本研究将这些基线方法的目标函数作为公式 (4.3) 中的基础损失 $\mathcal{L}_{\text{Base}}$，并叠加 D-SINK 的蒸馏损失进行训练。

表 4.6 和表 4.7 分别总结了在对称噪声和非对称噪声设定下的实验结果。可以清晰地看到，无论基础方法是简单的交叉熵还是复杂的长尾噪声专用算法（如 TABASCO），D-SINK 的引入均能显著提升其在长尾噪声分类任务上的性能。这一结果表明，由于 D-SINK 提供了与现有方法正交的优化视角（即通过辅助模型进行双粒度蒸馏），它能够持续地从未来可能出现的更先进的基础方法中获益，具有极强的通用性和扩展性。

表 4.6　将 D-SINK 与不同基线方法（CE, HAR, RoLT, TABASCO）集成后的测试准确率 (%)。实验在 CIFAR-10/100 对称噪声环境下进行，不平衡比率为 10 和 100，噪声比率为 0.4 和 0.6。
Table 4.6　Test accuracy (%) demonstrating the performance improvement achieved by integrating D-SINK with various baselines (CE, HAR, RoLT, TABASCO). Experiments are conducted on CIFAR-10/100 under symmetric noise, with imbalance ratios of 10 and 100, and noise ratios of 0.4 and 0.6.

噪声模式	对称噪声 (Symmetric)							
数据集	CIFAR-10				CIFAR-100			
不平衡比率	10		100		10		100	
噪声比率	0.4	0.6	0.4	0.6	0.4	0.6	0.4	0.6
CE	71.67	61.16	47.81	28.04	34.53	23.63	21.99	15.51
+ D-SINK	**76.09**	**64.17**	**53.85**	**41.83**	**42.74**	**29.13**	**24.69**	**17.23**
HAR	74.11	60.92	51.61	37.96	36.53	24.68	20.41	15.03
+ D-SINK	**76.32**	**65.03**	**53.20**	**39.49**	**38.43**	**26.12**	**22.05**	**16.52**
RoLT	81.75	79.67	60.21	44.36	43.08	32.57	24.11	16.59
+ D-SINK	**87.20**	**85.99**	**64.29**	**50.87**	**51.24**	**38.57**	**29.86**	**22.11**
TABASCO	85.47	84.83	62.76	55.49	56.89	45.68	36.92	28.50
+ D-SINK	**89.00**	**86.93**	**66.43**	**57.80**	**58.96**	**48.26**	**38.66**	**30.42**

4.3.2.5　对比朴素蒸馏与直接集成

为了证明 D-SINK 在协调和协同利用辅助模型方面的有效性，本研究将其与两种直观的基线策略进行了对比：

1. **朴素蒸馏（Naive Distillation）：** 使用标准的加权蒸馏损失 $\mathcal{L}_{\text{Dist}}$（见公式 (4.1)）替代 D-SINK 的蒸馏损失。
2. **直接集成（Direct Ensemble）：** 直接平均两个辅助模型的输出作为预测结果。值得注意的是，直接集成在部署时需要保留两个辅助模型，因此会带来额外的推理开销。

如表 4.8 所示，D-SINK 显著优于朴素蒸馏和直接集成。这表明，D-SINK 成功地协调了各自具备单项鲁棒性的模型，并通过双粒度机制有效地融合了它们的洞见，从而实现了优于简单组合的性能提升。

4.3.2.6　噪声样本预测与纠错能力

为了分析模型在长尾分布下对噪声标签的鲁棒性，图 4.3a 和 4.3b 展示了各方法对训练集中噪声样本的预测准确率（即纠错率，指模型能够正确预测出被错误标注

表 4.7　将 D-SINK 与不同基线方法集成后的测试准确率 (%)。实验在 CIFAR-10/100 非对称噪声环境下进行。

Table 4.7　Test accuracy (%) demonstrating the performance improvement achieved by integrating D-SINK with various baselines. Experiments are conducted on CIFAR-10/100 under asymmetric noise.

噪声模式	非对称噪声 (Asymmetric)							
数据集	CIFAR-10				CIFAR-100			
不平衡比率	10		100		10		100	
噪声比率	0.2	0.4	0.2	0.4	0.2	0.4	0.2	0.4
CE	79.9	62.88	56.56	44.64	44.45	32.05	25.35	17.89
+ D-SINK	**82.46**	**65.56**	**58.15**	**47.43**	**52.34**	**38.06**	**27.03**	**19.68**
HAR	78.75	70.23	58.89	49.97	49.36	35.98	27.9	20.03
+ D-SINK	**80.72**	**72.11**	**60.49**	**51.62**	**51.04**	**37.58**	**29.44**	**21.55**
RoLT	80.38	78.39	54.79	50.41	50.62	39.32	33.16	25.73
+ D-SINK	**86.09**	**83.78**	**60.40**	**54.83**	**59.64**	**42.87**	**38.42**	**29.15**
TABASCO	82.13	80.57	60.35	51.19	59.45	50.43	38.43	32.15
+ D-SINK	**87.09**	**84.36**	**61.98**	**53.06**	**61.69**	**51.56**	**40.10**	**34.06**

样本的真实标签的比率)。结果显示，无论是在对称噪声还是非对称噪声下，D-SINK 的纠错能力均显著优于其他基线方法。这突显了 D-SINK 在训练过程中有效识别并纠正噪声标签的能力。

4.3.2.7　超参数 α 的敏感性分析

本研究对公式 (4.3) 中控制 $\mathcal{L}_{\text{Base}}$ 与 $\mathcal{L}_{\text{D-SINK}}$ 权重的超参数 α 进行了消融实验。本研究将 α 在 $\{0, 0.1, 0.2, 0.5, 1, 2\}\times 10^{-3}$ 的范围内进行变化。图 4.2 的结果表明，D-SINK 对 α 的变化表现出极高的鲁棒性：在较宽的取值范围内，模型性能保持稳定且处于高位。这种对超参数的不敏感性降低了 D-SINK 在实际部署中进行繁琐调参的需求。

4.3.2.8　基础损失与辅助模型的消融实验

在表 4.8 中，本研究对 $\mathcal{L}_{\text{Base}}$ 和辅助模型 f_L 进行了消融分析，以验证它们各自的贡献。$\mathcal{L}_{\text{Base}}$ 赋予了模型基础的分类能力，而 f_L 对于解决长尾分布中的类别不平衡至关重要。实验结果显示，缺少任一组件都会导致性能显著下降，从而确认了它们在框架中的不可或缺性。

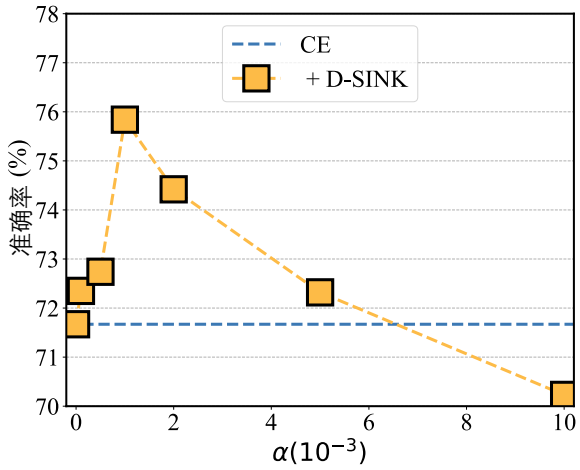
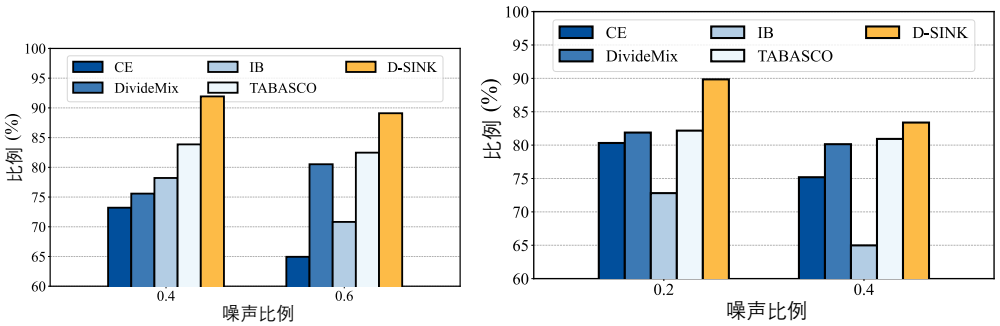


图 4.2　超参数 α 的消融实验结果。
Figure 4.2　Ablation on hyperparameter α.



(a) CIFAR-10 对称噪声　　(b) CIFAR-10 非对称噪声

图 4.3　(a) CIFAR-10（IR=10，对称噪声）上的噪声标签纠错率（即模型预测出真实标签的比率）。(b) CIFAR-10（IR=10，非对称噪声）上的噪声标签纠错率。
Figure 4.3　(a) Percentage of noisy training labels corrected on CIFAR-10 with imbalance ratio 10 and symmetric noise. (b) Percentage of noisy training labels corrected on CIFAR-10 with imbalance ratio 10 and asymmetric noise.

4.3.2.9　辅助模型选择的鲁棒性分析

为了验证 D-SINK 在辅助模型选择上的通用性，本研究测试了多种 f_L 和 f_N 的组合。具体而言，本研究选取了三种长尾学习模型（LA, IB, LDAM）作为 f_L，以及两种噪声学习模型（DivideMix, UNICON）作为 f_N，共构成了六种组合配置。

表 4.9 展示了在 CIFAR-100（对称噪声）上的实验结果。结果表明，无论采用何种具体的 f_L 或 f_N 策略，D-SINK 均能表现出强劲的性能并实现显著提升。这证明了 D-SINK 框架对辅助模型组件的选择具有很强的鲁棒性，能够灵活集成各种现有的单项技术。

表 4.8　针对 D-SINK 中 $\mathcal{L}_{\text{Base}}$ 和 f_L 的消融实验。对比了 D-SINK 与朴素蒸馏及直接集成的性能。表格下方的 "Margin" 行量化了 D-SINK 相比各基线的绝对性能提升。

Table 4.8　Ablation study of $\mathcal{L}_{\text{Base}}$ and f_L for D-SINK. Results are presented on CIFAR-10 and CIFAR-100 with an imbalance factor of 10. Results of Naive Distillation and Direct Ensemble are also presented. The subsequent "Margin" rows quantify the absolute performance improvement of our D-SINK over various baselines.

噪声模式	对称噪声 (Symmetric)				非对称噪声 (Asymmetric)			
数据集	CIFAR-10		CIFAR-100		CIFAR-10		CIFAR-100	
噪声比率	0.4	0.6	0.4	0.6	0.2	0.4	0.2	0.4
CE	71.67	61.16	34.53	23.63	79.90	62.88	44.45	32.05
DivideMix (f_N)	80.20	79.94	47.93	41.65	80.12	74.73	54.83	41.95
IB (f_L)	72.66	62.19	34.85	22.81	70.88	60.32	47.48	33.81
TABASCO	85.47	84.83	56.89	45.68	82.13	80.57	59.45	50.43
w/o $\mathcal{L}_{\text{Base}}$	10.00	10.02	4.25	5.01	10.13	10.05	5.12	4.65
w/o f_L	81.50	80.95	53.21	42.23	81.77	76.67	58.39	48.95
朴素蒸馏 (Naive Distillation)	83.43	82.52	54.60	43.81	80.26	79.13	57.38	48.92
直接集成 (Direct Ensemble)	80.67	80.68	50.44	39.99	80.89	76.35	59.52	43.80
D-SINK	**89.00**	**86.93**	**58.96**	**48.26**	**87.09**	**84.36**	**61.69**	**51.56**
D-SINK 提升幅度 (Margin vs.)								
IB (f_L)	+16.34	+24.74	+24.11	+25.45	+16.21	+24.04	+14.21	+17.75
DivideMix (f_N)	+8.80	+6.99	+11.03	+6.61	+6.97	+9.63	+6.86	+9.61
直接集成	+8.33	+6.25	+8.52	+8.27	+6.20	+8.01	+2.17	+7.76
朴素蒸馏	+5.57	+4.41	+4.36	+4.45	+6.83	+5.23	+4.31	+2.64

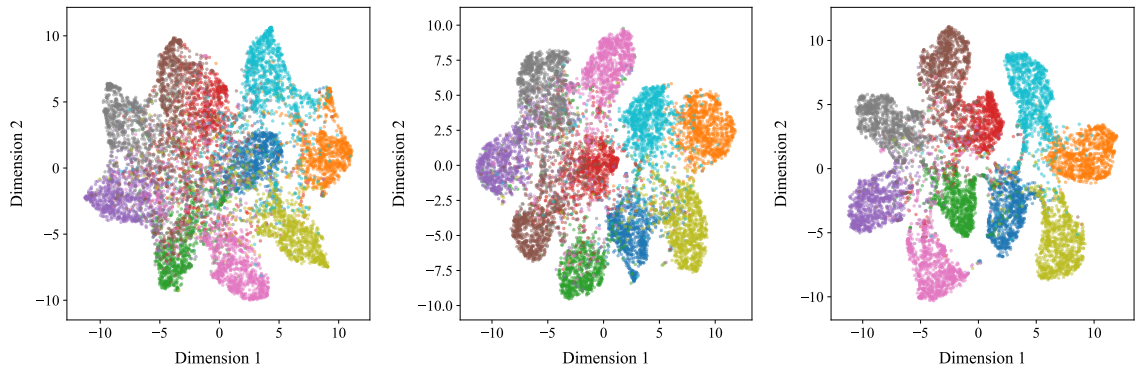
表 4.9　针对 D-SINK 中不同辅助模型选择的消融实验。包含 6 种 f_L (LA, IB, LDAM) 与 f_N (-D 代表 DivideMix, -U 代表 UNICON) 的组合。结果基于 CIFAR-100 (IR=10, 对称噪声)。

Table 4.9　Ablation study of different Auxiliary Model selections for D-SINK with six combinations of an f_L component (LA, IB, or LDAM) and an f_N component, where -D signifies f_N using DivideMix and -U signifies f_N using UNICON. Results are presented on CIFAR-100 (imbalance ratio 10) with symmetric noise.

噪声比率	CE	TABASCO	D-SINK					
			LA-D	LA-U	IB-D	IB-U	LDAM-D	LDAM-U
0.4	34.53	56.89	57.82	58.32	58.86	**58.96**	57.88	58.03
0.6	23.63	45.68	49.14	**49.57**	48.26	48.56	48.35	48.79

4.3.2.10　特征表示质量可视化

为了直观对比特征表示的质量，本研究利用 t-SNE 技术[142] 对 CE、TABASCO 和 D-SINK 学到的特征进行了可视化。图 4.4 展示了在 CIFAR-10（IR=10, 对称噪声 0.4）上的结果。



(a) CE　　(b) TABASCO　　(c) D-SINK

图 4.4　CE、TABASCO 和 D-SINK 在 CIFAR-10（IR=10, 噪声比率 =0.4）上学到的特征的 t-SNE 可视化。

Figure 4.4　T-SNE visualization of the features learned by CE, TABASCO and D-SINK on CIFAR-10 with imbalance ratio of 10 and noise ratio of 0.4.

可以观察到，基础的 CE 方法学到的特征分布较为混乱，不同类别的样本严重混杂，表明在长尾噪声共存的场景下学习判别性特征极其困难。TABASCO 虽然改善了特征的可分性，但类间边界仍有模糊。相比之下，D-SINK 通过有效的双粒度鲁棒蒸馏，学到了类内更紧凑、类间分离度更高的特征表示。这直观地解释了 D-SINK 在分类准确率上的显著优势。

4.4　本章小结

本章针对现实世界中长尾分布与标签噪声共存（LT-NLL）的严峻挑战，提出了一种名为 D-SINK 的统一鲁棒蒸馏框架。本研究首先揭示了现有方法在处理复合场景时面临的核心困境：长尾学习的去偏目标（提升高损耗样本权重）与噪声学习的去噪目标（抑制高损耗样本权重）存在内生冲突。

为了解决这一难题，本研究创新性地提出了一种“双粒度”解决方案，即在不同粒度上利用辅助模型的能力。D-SINK 并不试图从零训练一个完美的模型，而是通过最优传输理论，协同整合了仅具备单项鲁棒性的“弱”辅助模型。具体而言，该框架在样本粒度上利用抗噪模型进行噪声过滤，在分布粒度上利用长尾模型进行类别平衡。

在包含合成噪声（CIFAR-10/100）和真实世界噪声（CIFAR-N, Clothing1M 等）的多个基准数据集上的广泛实验表明，D-SINK 在各种不平衡比率和噪声比率下均取得了显著优于现有 SOTA 方法的性能。此外，深入的分析验证了该框架在纠错能力、特

征学习质量以及辅助模型选择上的鲁棒性。本章的研究成果证明，通过合理的粒度解耦与协同机制，可以有效地化解复杂数据偏倚中的优化目标冲突，为构建高可靠的鲁棒学习系统提供了新的思路。

4.4.1 局限性与讨论

本章针对长尾分布与标签噪声共存的条件非完备场景，提出了一种基于双粒度 Sinkhorn 蒸馏的鲁棒学习方法。通过结合全局分布对齐与局部样本关联，本研究有效缓解了长尾类别在噪声干扰下的表征退化问题。

虽然本章提出的算法在多个基准数据集上均取得了显著的性能提升，但在实际应用与学术深度上仍存在值得进一步探讨的方向。首先，关于最优传输机制在极大规模类别分布下的计算效率问题，学术界未来可以探索更具轻量化的近似计算方案，以提升算法在大规模工业级场景中的部署速度。其次，本章主要聚焦于判别式任务中的特征提纯，社区后续研究可以尝试将双粒度蒸馏的思想推广至生成式任务或多模态学习领域，利用跨模态的互补信息进一步增强模型对长尾噪声数据的抗干扰能力。最后，对于长尾分布与噪声演化之间的内在理论联系，建立更具普适性的数学模型将为该领域的长远发展提供更坚实的理论支撑。

综上所述，本章的研究成果为解决复杂现实环境下的长尾学习问题提供了新的视角。通过深入分析双粒度信息的协同作用，本研究不仅提升了模型的鲁棒性，也为后续针对条件非完备下表征学习的研究提供了有益的启发。

第 5 章 基于互信息最大化的隐式子群均衡学习

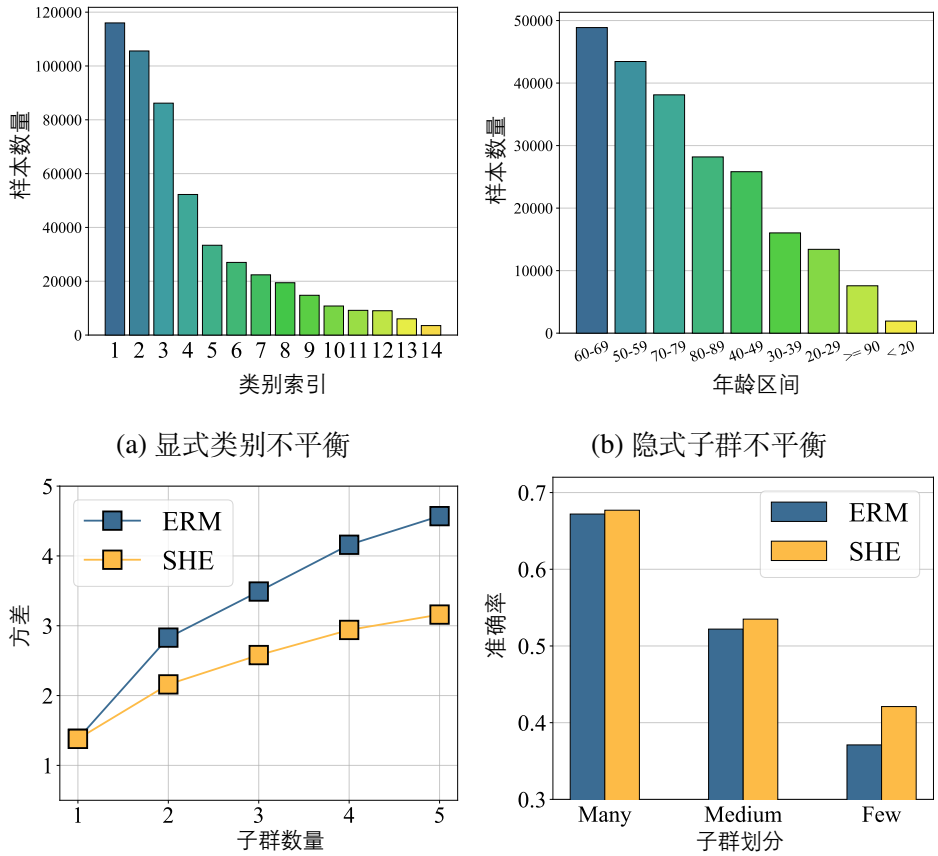
5.1 引言

在第 1 章中，本文指出了真实世界数据普遍存在的长尾分布特性，及其对算法鲁棒性构成的严峻挑战。前两章分别针对“监督信号退化”这一维度，探讨了在标签存在歧义（偏标签）和噪声（噪声标签）情况下的鲁棒学习方法。然而，数据的不平衡性并非仅仅体现在显式的类别标签（Class Labels）上，更深层次地，它往往隐匿于数据内部的潜在结构（Latent Structure）之中。

传统的不平衡学习主要聚焦于显式类别不平衡，即利用已知标签分布来平衡头部与少数类别的性能。然而，这种策略在面对更复杂的隐式子群不平衡（Implicit Subpopulation Imbalance）时往往捉襟见肘。即使类别分布平衡，模型在医疗诊断中的少数族裔、自动驾驶中的罕见天气等“少数子群”上的表现仍可能出现断崖式下跌。这里的“子群”是指贡献类内变异的隐式属性（如背景、环境或人口统计特征）。由于缺乏细粒度的子群标注，这种不平衡具有极强的隐匿性（Concealment），很难通过常规的统计手段查验。当这些隐式属性与性别、种族等敏感特征关联时，这种被忽视的偏差不仅会损害模型的泛化能力，更会引发严重的算法公平性与伦理风险。

尽管现有不平衡学习研究已较为深入，但其通常关注显式的类别不平衡设定（如图 5.1a），通过利用显式类别分布来校准头部和尾部类别的训练，无法处理如图 5.1b 所示的隐式子群不平衡。另一方面，关于虚假相关性（Spurious Correlations）的研究虽然也涉及子群问题，但其侧重点不同。虚假相关性通常源于特定属性在不同类别间分布的差异（例如“骆驼”常出现在“沙漠”中，而“牛”常出现在“草地”中），导致模型学习到非因果的捷径特征。相关研究旨在通过因果推断等手段剔除这些非因果属性[113,167-169]。虽然本研究针对隐式子群不平衡的目标与上述工作有着相似的“重平衡”精神，但在底层问题定义和作用机制上存在本质区别（详见表 5.1 中的对比）。

应对隐式子群不平衡问题的核心挑战主要体现在以下两个方面：首先是**混合分布导致的预测困难**。相比于单一分布，多个子群混合而成的复杂分布使得预测任务更加困难。传统的分类模型倾向于将同一类别的所有训练样本映射到相同的特征表示[166,170]。然而，当类内存在显著的子群差异时，强行将它们映射为同一特征会面临巨大阻碍（如图 5.1c 所示），并损害模型的泛化能力[171]。例如，对于“交通工具”这一类别，要求“自行车”子群和“飞机”子群共享完全相同的视觉特征是不合理的。



(a) 显式类别不平衡　　(b) 隐式子群不平衡

(c) 类内特征方差　　(d) 各子集上的准确率

图 5.1　(a) CheXpert[165] 数据集中各类别的样本数量分布。类别索引按样本数降序排列，显示出明显的类别不平衡现象。(b) CheXpert 数据集中针对疾病预测任务的年龄子群分布，呈现出显著的隐式不平衡。(c) 不同子群数量下的类内特征方差（Within-class Feature Variance）。实验在 CIFAR-100 (IR=100) 上进行，方差计算参照 Papyan 等人的工作[166]。相比于在混合分布下训练的 ERM，本研究提出的方法显著降低了类内方差。(d) ERM 与 SHE 在 COCO 数据集上的 Many/Medium/Few 子群准确率对比。ERM 在少数子群上性能较差，而本研究方法有效缓解了这一现象。

Figure 5.1　(a) Sample distribution per category in CheXpert[165], sorted by sample size, highlighting explicit class imbalance. (b) Imbalanced age subpopulation distribution in CheXpert for disease prediction. (c) Within-class feature variance across different numbers of subpopulations on CIFAR-100 (IR=100). Our method yields significantly lower variance compared to ERM trained on mixed distributions. (d) Accuracy on Many/Medium/Few splits for ERM and SHE on COCO dataset. SHE effectively mitigates the poor performance on minority subpopulations observed in ERM.

其次是**子群的隐匿性与不平衡性**。不同的数据子群可能依赖于不同的特征机制进行预测，机器学习算法倾向于忽略少数子群，导致在这些数据上的性能退化（如图 5.1d 所示）。更关键的是，子群的不可观测性（Unobservable Nature）使得我们无法像处理显式类别不平衡那样，直接利用标签统计信息来进行重平衡。这些困难限制了现有方

表 5.1　不同类型不平衡问题的比较，涵盖了类别级偏移、子群级偏移、问题的潜在假设以及可能的负面影响。对于类别不平衡，训练数据的类别分布是偏斜的，即 $p_Y(y) \gg p_Y(y')$。对于虚假相关，假设子群和类别在因果上是独立的，但在训练中存在与类别伪相关的变量。对于子群不平衡，训练数据的子群分布是不平衡的，即 $p_Z(z) \gg p_Z(z')$。

Table 5.1　A comparison of different types of imbalance problems. For class imbalance, the training class distribution is skewed. For spurious correlation, subpopulations and classes are causally independent but spuriously correlated in training. For subpopulation imbalance, the subpopulation distribution of training data is imbalanced.

不平衡类型	子群偏移	类别偏移	假设	对预测的负面影响
类别不平衡 (Class Imbalance)	–	$p_Y(y) \gg p_Y(y')$	–	将少数类预测为多数类
虚假相关 (Spurious Correlation)	$p_{Y\|Z}(y\|z) \gg p_Y(y)$	–	$Z \perp\!\!\!\perp Y$	依赖无关特征进行预测
子群不平衡 (Subpopulation Imbalance)	$p_Z(z) \gg p_Z(z')$	–	–	忽略少数子群的特征

法在隐式子群不平衡问题上的有效性。

为了解决上述挑战，本章提出了一种名为 **SHE** (Scatter and HarmonizE) 的新型算法。本研究的核心直觉在于：**将复杂的混合分布数据“散射（Scatter）”分解为多个简单的子群，使得每个子群内部的预测机制保持一致，然后再进行子群层面的“协调（Harmonize）”与平衡**。具体而言：首先，引入最优数据划分（Optimal Data Partition）的概念，将其定义为能够带来最大额外预测能力的训练数据划分方式（定义 5.1）。接着，提出了一种经验风险函数，证明其在理论上与追求最优数据划分的目标是一致的（定理 5.1）。这为无监督地发现隐式子群提供了理论支撑。针对子群的不平衡特性，本研究提出通过对输出应用简单的 LogSumExp 操作，即可基于学习到的数据划分实现子群平衡的预测（定理 5.2）。最后，提供了一种实用的实现方案，该方案可以在不增加模型容量的前提下进行端到端的优化。

本章的主要贡献总结如下：

- **问题探究：**本研究深入探讨了极具实用价值但尚未被充分研究的“隐式子群不平衡学习”问题。指出了现有方法无法有效解决该问题的局限性，并识别出其核心挑战在于：如何在无监督条件下挖掘隐式子群以促进预测性能和子群平衡。
- **方法提出：**本研究提出了一种新颖的 SHE 算法。该算法通过优化预测能力来自动发现隐藏的子群（Scatter），并通过简单的 LogSumExp 操作实现子群平衡的预测（Harmonize）。理论分析表明，SHE 在处理隐式子群不平衡方面具有良好的理论性质。
- **实验验证：**本研究进行了广泛的实验，以全面理解 SHE 的特性。在多种设置下的实验结果验证了该方法在提升子群不平衡鲁棒性方面的显著优势。

5.2　算法研究

本节将详细阐述 SHE 算法的理论基础与实现细节。首先，在第 5.2.1 小节中，我们对隐式子群不平衡学习问题进行形式化的数学定义。

5.2.1　问题描述

设 $\mathcal{X}$ 为输入空间，$\mathcal{Y} = \{1, 2, \ldots, C\}$ 为包含 C 个类别的标签空间。我们定义一个潜在的子群空间（Space of Subpopulations）为 $\mathcal{Z} = \{1, 2, \ldots, K\}$。总体数据分布可以被形式化为多个潜在子群分布的混合，即联合概率密度函数表示为 $p(\boldsymbol{x}, y) = \sum_{z \in \mathcal{Z}} p(z) \cdot p(\boldsymbol{x}, y|z)$。

基于此，训练数据集可以表示为 $\mathcal{D} = \{(\boldsymbol{x}_i, y_i, z_i)\}_{i=1}^{N} \in (\mathcal{X}, \mathcal{Y}, \mathcal{Z})^N$。其中，每个输入样本 $\boldsymbol{x}_i$ 不仅关联了一个显式的分类标签 y_i，还关联了一个不可观测（Unobserved）的子群标签 z_i。本研究聚焦于隐式子群不平衡（Implicit Subpopulation Imbalance）问题，即子群的先验分布 $p(z)$ 是偏斜的（Skewed）。

本研究假设各个子群是异质的（Heterogeneous），具有不一致的预测机制。具体而言，数据分布 $p(\boldsymbol{x}, y|z)$ 在不同子群之间存在差异，且条件概率 $p(y|\boldsymbol{x}, z)$ 在某些子群之间也可能不同。

为了在评估阶段公平地衡量模型对所有子群的性能，参照不平衡学习领域的惯例[42,84]，我们采用一个子群平衡（Subpopulation-balanced）的测试分布 $p_{bal}(\boldsymbol{x}, y) = \sum_{z \in \mathcal{Z}} p_{bal}(z) p(\boldsymbol{x}, y|z)$ 进行评估，其中 $p_{bal}(z) = \frac{1}{K}, \forall z \in \mathcal{Z}$，即假设测试时各子群出现的概率均等。

简而言之，本研究的目标是在训练集 $\mathcal{D}$ 上学习一个深度神经网络模型 $f : \mathcal{X} \to p(\mathcal{Y})$，使其最小化如下定义的子群平衡错误率（Subpopulation-Balanced Error Rate, SBER）：

$$\min_{f} \mathrm{SBER}(f) = \mathbb{E}_{(\boldsymbol{x}, y) \sim p_{bal}(\boldsymbol{x}, y)} \mathbb{I}\left(y \neq \arg\max_{y' \in \mathcal{Y}} f^{y'}(\boldsymbol{x}) \right). \tag{5.1}$$

其中 $\mathbb{I}(\cdot)$ 为指示函数。在实验环节，我们使用一个子群平衡的测试集作为 SBER 的无偏估计量。

5.2.2　研究动机：从混合分布到子群解耦

为了直观地阐释隐式子群不平衡问题的本质以及本研究提出 SHE 算法的核心动机，我们构建了一个二维仿真实验（Toy Example）并进行了可视化分析。

5.2.2.1 仿真实验设置

该实验构建了一个简单的二分类任务，预测目标是区分“圆形”（半透明点）和“三角形”（不透明点）。数据生成过程模拟了包含两个潜在子群（Subpopulation 1 和 Subpopulation 2）的混合分布场景：

- **子群定义：**
  - **子群 1（Subpopulation 1，蓝色）：** 包含类别 1 和类别 2。类别 1 的数据采样自正态分布 $\mathcal{N}([1,3],[0.2,0.2])$，类别 2 的数据采样自 $\mathcal{N}([2,3],[0.2,0.2])$。
  - **子群 2（Subpopulation 2，红色）：** 同样包含类别 1 和类别 2。类别 1 的数据采样自 $\mathcal{N}([1.5,1],[0.2,0.2])$，类别 2 的数据采样自 $\mathcal{N}([1.5,2],[0.2,0.2])$。
- **训练集分布（隐式不平衡）：** 训练数据从上述两个子群中采样，样本数量分别为：子群 1 的类别 1 和类别 2 各 200 个样本；子群 2 的类别 1 和类别 2 各 10 个样本。这意味着训练集呈现显著的子群不平衡（不平衡比率 IR = 20），子群 2 为极少数群体。
- **测试集分布（子群平衡）：** 为了评估模型对所有子群的泛化能力，测试集从上述四个分布中各采样 100 个样本，即实现了子群平衡。
- **模型设置：** 采用包含 5 个隐藏神经元的两层多层感知机（MLP）作为分类模型。训练采用 SGD 优化器，动量为 0.9，初始学习率为 0.2，训练 60 个 Epoch。

5.2.2.2 可视化分析与洞察

图 5.2 展示了该仿真实验的结果，从中可以获得以下关键洞察：

1. **特征依赖的异质性：** 如图 5.2 左列所示，对于子群 1（蓝色），特征 x_1（横轴）在类别区分中起主导作用；而对于子群 2（红色），特征 x_2（纵轴）则是更有效的分类特征。这验证了前文所述的“子群异质性”，即不同子群可能依赖不同的特征机制进行预测。
2. **ERM 的局限性（混合分布的危害）：** 图 5.2 中列展示了经验风险最小化（ERM）模型在训练集上的预测结果。由于训练数据中子群 1 占据绝对主导地位，ERM 模型倾向于学习子群 1 的特征规律（即主要依赖 x_1），而忽略了子群 2 的关键特征 x_2。结果导致模型在子群 2 上的表现极差，决策边界未能正确区分红色子群中的类别。这表明，在混合分布下直接训练，模型会被多数子群主导，导致少数子群被“淹没”。
3. **SHE 的优势（子群发现与解耦）：** 图 5.2 右列展示了本研究提出的 SHE 算法的效果。首先，SHE 成功地在无监督条件下发现并分离了训练数据中的两个潜在

子群（如右列上图所示，模型准确地将数据点划分为了不同的簇）。其次，基于这种子群划分，原先复杂的混合分布分类问题被转化为两个相对简单的线性分类子问题。这使得模型能够分别针对每个子群学习最有效的特征（即在子群 1 中利用 x_1，在子群 2 中利用 x_2）。最终，如右列下图所示，SHE 在测试集上实现了对两个子群均准确的预测，显著提升了泛化性能。

综上所述，缓解隐式子群不平衡的关键在于：**挖掘训练数据中能够促进预测的潜在子群结构，并利用该结构进行子群层面的重平衡**。这一发现构成了本章 SHE 算法设计的核心逻辑起点。

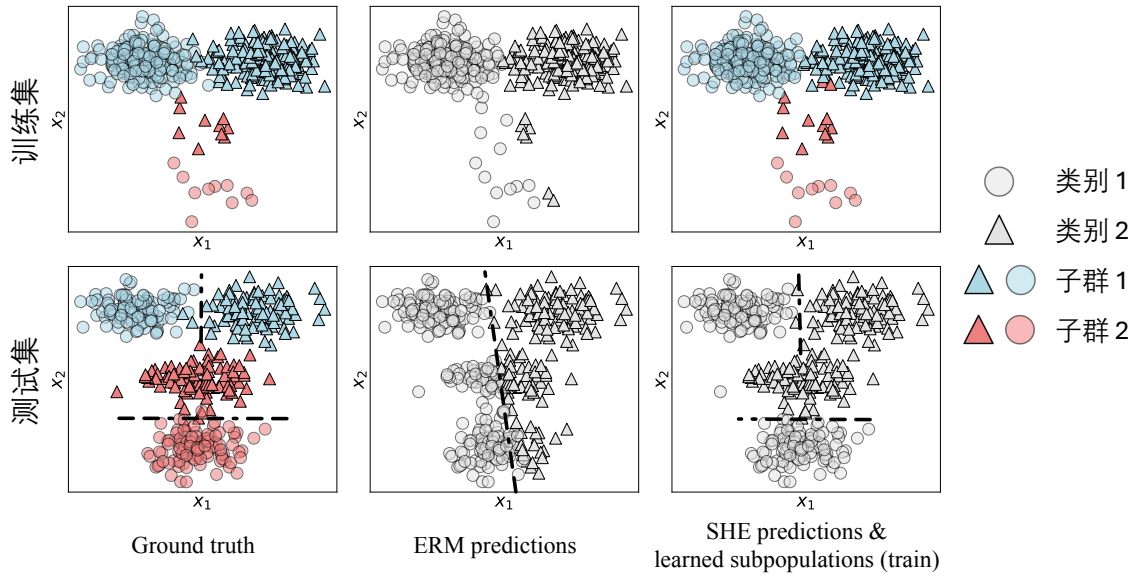


图 5.2　SHE 算法与基线算法的二维仿真实验可视化，展示了一个二维空间中的隐式子群不平衡学习问题。左列：展示了包含 2 个类别、2 个子群的训练集（高度子群不平衡，IR=20）和测试集（子群平衡）的数据分布。蓝色代表子群 1，红色代表子群 2；半透明圆点代表类别 1，不透明三角形代表类别 2。中列：展示了基线方法 ERM 的模型预测结果。ERM 被多数子群（蓝色）主导，无法正确学习少数子群（红色）的分类边界。右列：展示了 SHE 在训练集上的子群划分结果以及在测试集上的最终预测结果。SHE 成功挖掘出了潜在子群，并据此实现了更准确的预测。

Figure 5.2　Visualization of a toy motivating example, which is a 2D subpopulation-imbalanced learning problem. The left column illustrates the data distribution of the training set (highly imbalanced, IR=20) and the test set (balanced) under 2 classes consisting of 2 subpopulations. The middle column exhibits the model prediction of ERM. The right column shows the predictions and the learned subpopulations of SHE on the training set and predictions on the test set.

5.2.3 SHE 算法原理与分析

5.2.3.1 最优数据划分（Optimal Data Partition）

正如前文分析所述，解决隐式子群不平衡问题的关键在于发现训练数据中潜在的异质性结构，从而对模型训练进行校准。对于具有隐式异质结构的数据，本研究提出通过适当的数据划分（Data Partition），使得每个划分内部具有一致的预测机制。这种方式不仅能提升整体的预测能力，还有助于保护易被忽略的弱势子群。

首先，本研究引入“最优数据划分”的概念，旨在学习如何将样本合理地分配到不同的子群中。

定义 5.1（**（最优）数据划分**） 令 X 和 Y 为取值于 $\mathcal{X}\times\mathcal{Y}$ 的随机变量，服从固定的联合分布 $p_{X,Y}$。数据划分定义为一个将训练数据及其标签映射到子群空间 $\mathcal{Z}$ 的映射函数 ν，即 $\nu:\mathcal{X}\times\mathcal{Y}\to\mathcal{Z}$。因此，$\nu(X,Y)$ 是一个取值于 $\mathcal{Z}$ 的随机变量，且子群数量 $|\mathcal{Z}|=K$。基于信息论，本研究定义最优数据划分 ν^* 为：

$$\nu^* = \arg\max_{\nu} I(X;Y;\nu(X,Y)) = \arg\max_{\nu} I(X;Y|\nu(X,Y)) - I(X;Y), \tag{5.2}$$

其中 $I(X;Y;\nu(X,Y))$ 表示 $X,Y,\nu(X,Y)$ 的交互信息（Interaction Information）[172]，$I(X;Y)$ 表示 X 和 Y 的互信息，而 $I(X;Y|\nu(X,Y))$ 表示在给定划分 ν 条件下 X 和 Y 的条件互信息。

在信息论中，互信息 $I(X;Y)$ 可以刻画从输入 X 到类别标签 Y 的预测能力[173]。交互信息 $I(X;Y;\nu(X,Y))$ 则代表了在给定数据划分 ν 的情况下，X 和 Y 之间相关性的增益。$I(X;Y;\nu(X,Y))$ 的值越大，意味着划分 ν 对从输入 X 到标签 Y 的预测能力的提升越大。

由于语义具有层级性（Hierarchical Nature）[144]，数据划分通常存在多种可能性。定义 5.1 帮助本研究寻找最优的数据划分 ν^*，以最大化训练数据的预测能力。直观上，最优数据划分将复杂混合分布中的预测问题分解为由 ν^* 划分出的多个简单分布中的分类问题。

此外，本研究指出了最优数据划分的一个重要性质：

命题 5.1 最优数据划分至少不会抑制预测能力，即 $I(X;Y;\nu^*(X,Y))\geq 0$。

证明 考虑任意一个与随机变量 (X,Y) 独立的数据划分 ν'，即满足 $\nu' \perp\!\!\!\perp X,Y$。在该条件下，划分变量不引入任何额外的信息，因此有

$$I(X;Y \mid \nu'(X,Y)) = I(X;Y), \tag{5.3}$$

从而可得

$$I(X;Y;\nu'(X,Y)) = I(X;Y) - I(X;Y \mid \nu'(X,Y)) = 0. \tag{5.4}$$

另一方面，根据最优数据划分的定义（见定义 5.1），ν^* 在所有可行的数据划分中最大化三元互信息 $I(X;Y;\nu(X,Y))$，因此必然满足

$$I(X;Y;\nu^(X,Y)) \geq I(X;Y;\nu'(X,Y)) = 0. \tag{5.5}$$

由此完成证明。 ■

命题 5.1 表明，最优数据划分有助于提升预测能力，即使在最坏情况下也至少不会产生负面影响。

5.2.3.2　目标函数与一致性分析

在引入上述概念与分析之后，本研究探索如何结合最优数据划分的思想来提升预测能力并实现子群平衡的模型。为此，本研究提出了如下关于训练集 $\mathcal{D}$ 的经验风险函数，其与最优数据划分的关系将在后续定理中进行讨论。

$$\hat{\mathcal{R}}(f,\nu;\mathcal{D}) = -\frac{1}{N}\sum_{i=1}^{N}\sum_{z\in\mathcal{Z}} \mathbf{1}(\nu(\boldsymbol{x}_i,y_i)=z)\cdot \log f_z^{y_i}(\boldsymbol{x}_i) - \hat{H}_{\mathcal{D}}(Y \mid \nu(X,Y)). \tag{5.6}$$

其中，$\mathbf{1}(\cdot)$ 为指示函数，当条件为真时取值为 1，否则为 0；$f_z(\boldsymbol{x})$ 表示子群 z 对样本 $\boldsymbol{x}$ 的预测，即 $f_z : \mathcal{X} \to p(\mathcal{Y})$；$\hat{H}_{\mathcal{D}}(Y|\nu(X,Y))$ 表示在训练集 $\mathcal{D}$ 上，给定数据划分 ν 条件下的标签经验熵。

本研究通过定理 5.1 讨论了公式 (5.6) 与最优数据划分的一致性。

定理 5.1　令

$$f^\dagger = \arg\min_f \hat{\mathcal{R}}(f,\nu;\mathcal{D})$$

为给定任意 $\mathcal{D}$ 和 ν 时，公式 (5.6) 中经验风险 $\hat{\mathcal{R}}(\mathcal{D})$ 的最优解。假设假设空间 $\mathcal{H}$ 满足：对于任意 $\boldsymbol{x}\in\mathcal{X}$, $y\in\mathcal{Y}$, $f\in\mathcal{H}$，均有 $\log f^y(\boldsymbol{x}) > -m$，其中 $m>0$。定义映射族

$$G = \left\{ g : \mathcal{X}\times\mathcal{Y} \to \mathbb{R} \;\middle|\; g(\boldsymbol{x},y) = \log f^y(\boldsymbol{x}),\ f\in\mathcal{H} \right\},$$

且 $R_N(G) = O(\frac{1}{\sqrt{N}})$ 表示样本量为 N 时 G 的 Rademacher 复杂度[174]。那么，对于任意 $\delta\in(0,1)$，以下不等式以至少 $1-\delta$ 的概率成立：

$$\left| I(X;Y;\nu(X,Y)) - \left(-\hat{\mathcal{R}}(f^\dagger,\nu;\mathcal{D}) + B\right)\right| \leq \frac{m}{\sqrt{N}}\sqrt{-2\log\delta} + 4K\cdot R_N(G),$$

其中 $B = -I(X;Y)$ 为常数，K 为子群的数量。

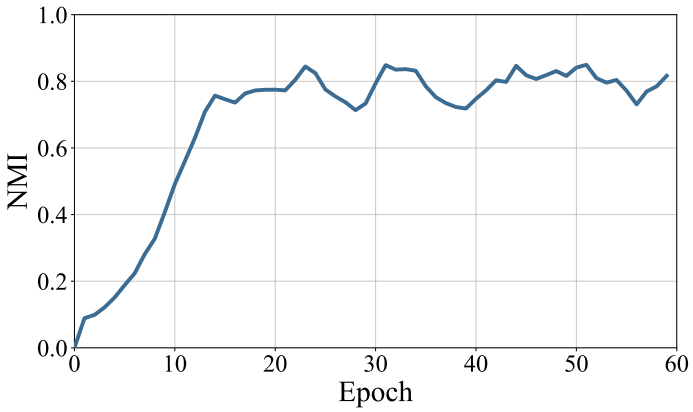


图 5.3 图 5.2 中仿真数据集训练过程中，SHE 学习到的子群划分与真实子群标注之间的归一化互信息（NMI）分数变化曲线。

Figure 5.3 NMI scores between the learned subpopulations and the true annotations on the toy dataset in 图 5.2 during training.

定理 5.1 给出了一个重要的理论启示：**最小化公式 (5.6) 中的经验风险 $\hat{\mathcal{R}}$ 在统计一致性的意义上，渐进地等价于最大化定义 5.1 中的交互信息** $I(X;Y;\nu(X,Y))$。这意味着通过优化该经验风险，SHE 算法能够自动地朝向最优数据划分的方向收敛。

为了进一步验证上述理论结论，本研究在训练过程中追踪了每一轮（Epoch）模型所学习到的子群划分与真实子群标注之间的归一化互信息（Normalized Mutual Information, NMI）分数[175]，并将其变化过程可视化于图 5.3。可以清晰地观察到，随着训练的推进，SHE 学习到的子群结构与真实标注之间的相关性持续提升，表明模型逐步捕获了数据中潜在的子群语义结构。

除了定量指标上的验证，我们进一步从定性角度分析了 SHE 所学习到的子群结构的语义一致性。图 5.4 展示了 SHE 在 COCO 数据集上学习到的子群可视化结果。为便于分析，这里将子群数量设置为 $K = 2$，并在训练完成后，从 COCO 中的“apple”和“banana”类别中分别随机抽取若干样本进行展示。可以观察到，模型所划分的两个子群具有清晰且一致的语义差异：例如，一个子群主要对应“被切开的苹果或香蕉”，而另一个子群则对应“完整的苹果或香蕉”。这种划分并未依赖显式的人工标注，而是由模型在训练过程中自发学习得到，体现了 SHE 在挖掘样本内在结构方面的能力。

为了进一步验证这一现象在更多类别上的普适性，图 5.5 展示了 SHE 在 COCO 数据集上更多类别的子群可视化结果，包括“apple”、“banana”、“pizza”、“hotdog”以及“person”。可以看到，即使在同一类别内部，不同子群之间依然呈现出显著的

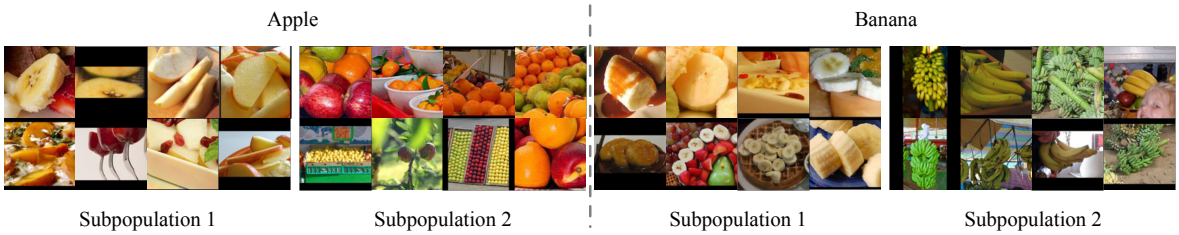


图 5.4　SHE 算法在 COCO 数据集上学习到的子群可视化示例。为便于分析，设置子群数量 $K = 2$，并从 “apple” 与 “banana” 类别中随机选取样本进行展示。

Figure 5.4　Visualization of learned subpopulations on COCO. We set the number of subpopulations to $K = 2$ and randomly selected samples from the classes “apple” and “banana” after training.



图 5.5　SHE 算法在 COCO 数据集上更多类别的子群可视化结果。设置子群数量 $K = 2$，并从多个类别中随机选取样本进行展示。

Figure 5.5　More visualizations of learned subpopulations on COCO. We set the number of subpopulations to $K = 2$ and randomly selected samples from multiple classes.

语义差异，例如姿态、场景或物体状态上的系统性变化。这些结果进一步表明，SHE 能够在复杂真实场景数据中挖掘出具有稳定语义含义的潜在子群结构。

此外，我们还在 Waterbirds 数据集上对 SHE 学习到的子群结构进行了可视化分析，如图 5.6 所示。Waterbirds 数据集中的群体标注通常由类别（land bird / water bird）与背景（land / water）共同构成，其中类别与背景之间存在显著的虚假相关性：大多数陆地鸟出现在陆地背景中，而水鸟多出现在水域背景中。如果仅依据背景进行子群划分，则每个子群内部仍然存在严重的类别不平衡问题，模型容易继续依赖虚假相关特征进行预测。

值得注意的是，SHE 并未简单复现这种基于背景的群体划分，而是将训练数据自适应地划分为两类更具判别意义的子群：一类包含具有明显虚假相关性的样本，



图 5.6　SHE 算法在 Waterbirds 数据集上学习到的子群可视化结果。展示了 land bird 与 water bird 类别中由 SHE 学习到的两个子群。

Figure 5.6　Visualization of learned subpopulations on the Waterbirds dataset. We show two learned subpopulations for the land bird and water bird classes.

另一类则对应弱或不含虚假相关性的样本。这种划分方式与原始的群体标注并不完全一致，却更有利于缓解虚假相关性带来的影响。其原因在于损失函数中的第二项 $\hat{H}_{\mathcal{D}}(Y|V)$（见公式 (5.20)），该项鼓励每个子群内部的类别分布更加均衡，从而抑制模型在子群内对单一类别或虚假特征的过度依赖。结合后续的子群重平衡策略，这种自适应子群划分机制能够有效降低模型对虚假相关特征的依赖，提高模型的泛化能力。

定理 5.1 的证明。　为了证明定理 5.1，我们需要先引入以下关于熵与交叉熵下界关系的引理。

引理 5.1　对于条件熵 $H(Y|X)$，成立如下等式：

$$H(Y|X) = \inf_{f} \mathbb{E}_{\boldsymbol{x},y} \left[-\log f^{y}(\boldsymbol{x}) \right], \tag{5.7}$$

其中下确界（infimum）在 $f^{y}(\boldsymbol{x}) = p(y|\boldsymbol{x})$ 时取到。

证明　利用 Kullback-Leibler (KL) 散度的非负性，我们有：

$$\begin{aligned}
\inf_{f} \mathbb{E}_{\boldsymbol{x},y} \left[-\log f^{y}(\boldsymbol{x}) \right] &= \inf_{f} \mathbb{E}_{\boldsymbol{x}} \mathbb{E}_{y|\boldsymbol{x}} \left[\log \frac{p(y|\boldsymbol{x})}{f^{y}(\boldsymbol{x}) p(y|\boldsymbol{x})} \right] \\
&= \inf_{f} \mathbb{E}_{\boldsymbol{x}} \left[\sum_{y} p(y|\boldsymbol{x}) \log \frac{p(y|\boldsymbol{x})}{f^{y}(\boldsymbol{x})} - \sum_{y} p(y|\boldsymbol{x}) \log p(y|\boldsymbol{x}) \right] \\
&= \inf_{f} \mathbb{E}_{\boldsymbol{x}} \left[\mathrm{KL}(p(Y|\boldsymbol{x}) \,||\, f(\boldsymbol{x})) + H(Y|\boldsymbol{x}) \right].
\end{aligned} \tag{5.8}$$

由于 KL 散度 $\mathrm{KL}(\cdot||\cdot) \geq 0$，当且仅当两个分布相同时取 0，因此当 $f^{y}(\boldsymbol{x}) = p(y|\boldsymbol{x})$ 时取到下确界，且此时式子等于 $\mathbb{E}_{\boldsymbol{x}}[H(Y|\boldsymbol{x})] = H(Y|X)$。 ■

基于引理 5.1，我们可以直接得到以下关于不同形式熵的推论：

推论 5.1　类似地，以下关系成立：

1. $H(Y) = \inf_f \mathbb{E}_{\boldsymbol{x},y}[-\log f^y(\mathbf{0})]$，其中 $\mathbf{0}$ 表示空输入，最优解为 $f^y(\mathbf{0}) = p(y)$。
2. $H(Y|X;\nu(X,Y)) = \inf_f \mathbb{E}_{\boldsymbol{x},y} \sum_{z\in\mathcal{Z}} -1(\nu(\boldsymbol{x},y) = z) \log f_z^y(\boldsymbol{x})$，最优解为 $f_z^y(\boldsymbol{x}) = p(y|\boldsymbol{x};z)$。
3. $H(Y|\nu(X,Y)) = \inf_f \mathbb{E}_{\boldsymbol{x},y} \sum_{z\in\mathcal{Z}} -1(\nu(\boldsymbol{x},y) = z) \log f_z^y(\mathbf{0})$，最优解为 $f_z^y(\mathbf{0}) = p(y|z)$。
4. $\hat{H}_{\mathcal{D}}(Y|\nu(X,Y)) = \inf_f \sum_{i=1}^N \sum_{z\in\mathcal{Z}} -1(\nu(\boldsymbol{x}_i,y_i) = z) \log f_z^y(\mathbf{0})$，最优解为经验分布频率。

下面是定理 5.1 的主证明

证明　定义关于训练集 $\mathcal{D}$ 的差值函数 $T(\mathcal{D})$ 如下：

$$T(\mathcal{D}) = \left| I(X;Y;\nu(X,Y)) - \left(-\hat{\mathcal{R}}(f^\dagger,\nu;\mathcal{D}) + B\right)\right|. \tag{5.9}$$

根据交互信息的定义 $I(X;Y;\nu) = I(X;Y|\nu) - I(X;Y)$ 以及引理 5.1 和推论 5.1，我们可以将 $T(\mathcal{D})$ 展开。注意到 $B = -I(X;Y)$，该项与交互信息中的常数项抵消。我们有：

$$\begin{aligned}
T(\mathcal{D}) &= \left| I(X;Y|\nu(X,Y)) - \frac{1}{N}\sum_{i=1}^N \sum_{z\in\mathcal{Z}} \mathbf{1}(\nu(\boldsymbol{x}_i,y_i) = z) \log f_z^{\dagger y_i}(\boldsymbol{x}_i) - \hat{H}_{\mathcal{D}}(Y|\nu(X,Y))\right| \\
&= \Bigg| - \inf_f \mathbb{E}_{\boldsymbol{x},y} \sum_{z\in\mathcal{Z}} -1(\nu(\boldsymbol{x},y) = z) \log f_z^y(\boldsymbol{x}) \\
&\quad + \inf_f \mathbb{E}_{\boldsymbol{x},y} \sum_{z\in\mathcal{Z}} -1(\nu(\boldsymbol{x},y) = z) \log f_z^y(\mathbf{0}) \\
&\quad + \inf_f -\frac{1}{N}\sum_{i=1}^N \sum_{z\in\mathcal{Z}} \mathbf{1}(\nu(\boldsymbol{x}_i,y_i) = z) \log f_z^{y_i}(\boldsymbol{x}_i) \\
&\quad - \inf_f \sum_{i=1}^N \sum_{z\in\mathcal{Z}} -1(\nu(\boldsymbol{x}_i,y_i) = z) \log f_z^y(\mathbf{0})\Bigg|.
\end{aligned} \tag{5.10}$$

利用不等式 $|\inf_f A(f) - \inf_f B(f)| \le \sup_f |A(f) - B(f)|$，我们将上述差值放缩为关于

函数 f 的上确界。定义 $Q(\mathcal{D})$ 如下：

$$\begin{aligned} Q(\mathcal{D}) \triangleq \sup_f \Bigg| & \mathbb{E}_{\boldsymbol{x},y} \sum_{z\in\mathcal{Z}} -1(\nu(\boldsymbol{x},y)=z)\log f_z^y(\boldsymbol{x}) \\ & - \frac{1}{N}\sum_{i=1}^{N}\sum_{z\in\mathcal{Z}} \mathbf{1}(\nu(\boldsymbol{x}_i,y_i)=z)(-\log f_z^{y_i}(\boldsymbol{x}_i)) \\ & - \mathbb{E}_{\boldsymbol{x},y} \sum_{z\in\mathcal{Z}} 1(\nu(\boldsymbol{x},y)=z)(-\log f_z^{y}(\mathbf{0})) \\ & + \frac{1}{N}\sum_{i=1}^{N}\sum_{z\in\mathcal{Z}} \mathbf{1}(\nu(\boldsymbol{x}_i,y_i)=z)(-\log f_z^{y_i}(\mathbf{0})) \Bigg|. \end{aligned} \tag{5.11}$$

显然 $T(\mathcal{D}) \le Q(\mathcal{D})$。接下来我们利用 McDiarmid 不等式分析 $Q(\mathcal{D})$ 的集中性。假设两个数据集 $\mathcal{D}$ 和 $\mathcal{D}'$ 仅在第 j 个样本点不同（分别为 $(\boldsymbol{x}_j, y_j)$ 和 $(\boldsymbol{x}'_j, y'_j)$）。根据假设，$\log f^y(\boldsymbol{x}) > -m$，则单点变化对 $Q(\mathcal{D})$ 的影响有界：

$$\begin{aligned} Q(\mathcal{D}) - Q(\mathcal{D}') \le \sup_f \Bigg| & \frac{1}{N}\log f^{y_j}_{\nu(\boldsymbol{x}_j,y_j)}(\boldsymbol{x}_j) - \frac{1}{N}\log f^{y_j}_{\nu(\boldsymbol{x}_j,y_j)}(\mathbf{0}) \\ & - \frac{1}{N}\log f^{y'_j}_{\nu(\boldsymbol{x}'_j,y'_j)}(\boldsymbol{x}'_j) + \frac{1}{N}\log f^{y'_j}_{\nu(\boldsymbol{x}'_j,y'_j)}(\mathbf{0}) \Bigg| \\ \le & \frac{2m}{N}. \end{aligned} \tag{5.12}$$

根据 McDiarmid 不等式，对于任意 $\delta \in (0,1)$，以至少 $1-\delta$ 的概率成立：

$$Q(\mathcal{D}) \le \mathbb{E}_{\mathcal{D}}[Q(\mathcal{D})] + \frac{m}{\sqrt{N}}\sqrt{-2\log\delta}. \tag{5.13}$$

最后，我们需要界定期望项 $\mathbb{E}_{\mathcal{D}}[Q(\mathcal{D})]$。利用 Rademacher 复杂度的对称化技巧，引入独立同分布的 Rademacher 变量 $\sigma_i \in \{-1,+1\}$ 和影子数据集 $\mathcal{D}'$：

$$\begin{aligned} \mathbb{E}_{\mathcal{D}}[Q(\mathcal{D})] &= \mathbb{E}_{\mathcal{D}} \sup_f \left|\mathbb{E}_{\mathcal{D}'}[\hat{A}_{\mathcal{D}'}] - \hat{A}_{\mathcal{D}}\right| \quad (\text{令 } \hat{A} \text{ 为经验风险项}) \\ &\le \mathbb{E}_{\mathcal{D},\mathcal{D}'} \sup_f \left|\hat{A}_{\mathcal{D}'} - \hat{A}_{\mathcal{D}}\right| \\ &\le \mathbb{E}_{\mathcal{D},\mathcal{D}',\sigma} \sup_f \left|\frac{1}{N}\sum_{i=1}^{N}\sigma_i(\dots)\right| \\ &\le 2\mathbb{E}_{\mathcal{D},\sigma} \sup_f \left|\frac{1}{N}\sum_{i=1}^{N}\sigma_i \log f^{y_i}_{\nu(\boldsymbol{x}_i,y_i)}(\boldsymbol{x}_i)\right| \\ &\quad + 2\mathbb{E}_{\mathcal{D},\sigma} \sup_f \left|\frac{1}{N}\sum_{i=1}^{N}\sigma_i \log f^{y_i}_{\nu(\boldsymbol{x}_i,y_i)}(\mathbf{0})\right|. \end{aligned} \tag{5.14}$$

假设空输入 $\mathbf{0}$ 的复杂度不高于一般输入 $\boldsymbol{x}$ 的复杂度，我们可以将上式统一放缩为：

$$\begin{aligned}\mathbb{E}_{\mathcal{D}}[Q(\mathcal{D})] &\leq 4\mathbb{E}_{\mathcal{D},\sigma}\sup_{f}\left|\frac{1}{N}\sum_{i=1}^{N}\sigma_i \log f^{y_i}_{\nu(\boldsymbol{x}_i,y_i)}(\boldsymbol{x}_i)\right| \\ &\leq 4\sum_{z\in\mathcal{Z}}\mathbb{E}_{\mathcal{D},\sigma}\sup_{f}\left|\frac{1}{N}\sum_{i=1}^{N}\sigma_i \log f^{y_i}_{z}(\boldsymbol{x}_i)\right| \\ &= 4K\cdot R_N(G).\end{aligned} \tag{5.15}$$

结合公式 (5.9), (5.13) 和上述 Rademacher 复杂度界，定理得证。 ■

5.2.3.3　基于子群平衡的预测机制

在前文中，本研究通过最大化交互信息来推断潜在的子群结构。在此基础上，本小节进一步探讨如何利用学习到的子群来实现子群平衡的预测（Subpopulation-balanced Prediction）。

设 $s_z(\boldsymbol{x}) \in \mathbb{R}^C$ 为输入 $\boldsymbol{x}$ 针对任意子群 $z \in \mathcal{Z}$ 的输出 Logits 向量，其对应的分类预测概率为 $f_z(\boldsymbol{x}) = \mathrm{softmax}(s_z(\boldsymbol{x}))$。本研究提出，通过对各子群的 Logits 进行 LogSumExp 聚合，可以得到针对整体数据的平衡预测结果。

定理 5.2　假设对于任意子群 $z \in \mathcal{Z}$，其 Logits 输出 s_z 能够完美拟合给定子群 z 的数据分布，即 $p(\boldsymbol{x}, y|z) \propto e^{s_z^y(\boldsymbol{x})}$。那么，通过聚合公式 $s(\boldsymbol{x}) = \log\sum_{z\in\mathcal{Z}} e^{s_z(\boldsymbol{x})}$ 得到的整体 Logits $s(\boldsymbol{x})$ 能够完美拟合子群平衡的整体分布，即 $p_{bal}(\boldsymbol{x}, y) \propto e^{z^y(\boldsymbol{x})}$。

定理 5.2 的证明

证明　若 s_z 能够完美拟合给定子群 z 的数据分布，即满足 $p(\boldsymbol{x}, y|z) \propto e^{z_z^y(\boldsymbol{x})}$。设比率系数为 $w > 0$，则有 $p(\boldsymbol{x}, y|z) = w \cdot e^{z_z^y(\boldsymbol{x})}$。由此可得子群 z 内的条件概率为：

$$p(y|\boldsymbol{x}; z) = \frac{p(\boldsymbol{x}, y|z)}{\sum_{y'} p(\boldsymbol{x}, y'|z)} = \mathrm{softmax}(z_z^y(\boldsymbol{x})). \tag{5.16}$$

对于子群平衡的分布，其各子群先验概率相等，即 $p_{bal}(z) = \frac{1}{K}, \forall z \in \mathcal{Z}$。根据全概率公式，整体分布可以表示为：

$$\begin{aligned}p_{bal}(\boldsymbol{x}, y) &= \sum_{z\in\mathcal{Z}} p(\boldsymbol{x}, y|z)p_{bal}(z) \\ &= \frac{1}{K}\sum_{z\in\mathcal{Z}} p(\boldsymbol{x}, y|z) \\ &= \frac{1}{K}\sum_{z\in\mathcal{Z}} w\cdot e^{z_z^y(\boldsymbol{x})} \\ &\propto \sum_{z\in\mathcal{Z}} e^{z_z^y(\boldsymbol{x})}.\end{aligned} \tag{5.17}$$

令 $z^y(\boldsymbol{x}) = \log \sum_{z \in \mathcal{Z}} e^{z_z^y(\boldsymbol{x})}$，代入上式即得 $p_{bal}(\boldsymbol{x}, y) \propto e^{z^y(\boldsymbol{x})}$。最终，整体的条件概率预测为：

$$p(y|\boldsymbol{x}) = \frac{p_{bal}(\boldsymbol{x}, y)}{\sum_{y'} p_{bal}(\boldsymbol{x}, y')} = \text{softmax}(z^y(\boldsymbol{x})). \tag{5.18}$$

证毕。 ■

定理 5.2 表明，在追求最优数据划分的同时，通过对学习到的各子群 Logits 执行 LogSumExp 操作，可以直接聚合得到一个子群平衡的预测结果。相比之下，普通的学习方法倾向于拟合混合分布 $p(\boldsymbol{x}, y) = \sum_{z \in \mathcal{Z}} p(z) \cdot p(\boldsymbol{x}, y|z)$，由于真实的子群先验 $p(z)$ 往往是高度不平衡的，这种方式对子群不平衡缺乏鲁棒性。

定理 5.2 的扩展　进一步地，本研究可以将定理 5.2 扩展，使 SHE 能够处理任意指定的潜在子群目标分布 $p_{test}(\boldsymbol{x}, y) = \sum_{z \in \mathcal{Z}} p_{test}(z) p(\boldsymbol{x}, y|z)$。其形式为加权版本的 LogSumExp。

命题 5.2　假设对于任意子群 $z \in \mathcal{Z}$，s_z 能够完美拟合给定子群 z 的数据分布，即 $p(\boldsymbol{x}, y|z) \propto e^{s_z^y(\boldsymbol{x})}$。那么，通过加权聚合公式 $s(\boldsymbol{x}) = \log \sum_{z \in \mathcal{Z}} p_{test}(z) e^{s_z(\boldsymbol{x})}$ 得到的整体 Logits 可以完美拟合目标分布，即 $p_{test}(\boldsymbol{x}, y) \propto e^{z^y(\boldsymbol{x})}$。

该命题的证明逻辑与定理 5.2 的证明完全一致，此处不再赘述。

与相关技术的对比讨论　在此简要讨论 SHE 算法与一些相关技术的核心区别。经典聚类方法（如 K-means[176] 或深度聚类[177-178]）将输入空间 $\mathcal{X}$ 划分为若干不相交的簇，其目标是使簇尽可能匹配目标类别。相比之下，本研究提出的方法是在**子群层面（Subpopulation Level）**而非类别层面划分数据，其目标是通过划分最大限度地干预从输入到类别的预测过程。针对虚假相关性的部分工作[115-116,168]利用 ERM 的预测结果或特征聚类结果作为子群，这基于一个潜在假设：来自同一子群的数据将具有相同的 ERM 预测或特征。然而，这一假设可能并不成立，特别是在训练过程中未捕获到足够多虚假关联的情况下。此时，这些方法学习到的聚类仍然停留在类别层面，因为 ERM 模型使用的是给定的类别监督。相比之下，SHE 在理论上和实证上都致力于学习具有明确语义意义的子群结构。

5.2.4　算法实现与优化

本小节将介绍 SHE 算法的具体实现方案，包括数据划分的优化策略、多头分类器架构以及最终的损失函数。

5.2.4.1　数据划分 ν 的优化

本研究使用一个子群权重矩阵 $V \in \{V \mid V \in \mathbb{R}_{+}^{N\times K}, \text{s.t.} \sum_{z=1}^{K} v_{is} = 1, \forall i = 1, \ldots, N\}$ 来表示公式 (5.6) 中针对训练集 $\mathcal{D}$ 的数据划分 ν。矩阵中的元素 v_{is} 表示第 i 个数据点采样自子群 z 的概率，即 $v_{is} = p(\nu(\boldsymbol{x}_i, y_i) = z)$。

为了加速 V 的优化并防止不同子群坍塌到同一模式，本研究进一步引入了一个多样性正则化项（Diversity Regularization Term）：

$$\text{Div}(\boldsymbol{x}) = \sum_{z_1, z_2 \in \mathcal{Z}, z_1 \neq z_2} \| f_{z_1}(\boldsymbol{x}) - f_{z_2}(\boldsymbol{x}) \|_2. \tag{5.19}$$

该项旨在最大化不同子群输出之间的差异。增加输出之间的多样性能够迫使模型学习更丰富的特征以辅助预测，这一思想在集成学习等领域已得到验证[179-181]。

结合经验风险项与正则化项，本研究方法的最终损失函数形式化如下：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{z \in \mathcal{Z}} v_{is} \cdot \log f_z^{y_i}(\boldsymbol{x}_i) - \hat{H}_{\mathcal{D}}(Y|V) - \beta \frac{1}{N} \sum_{i=1}^{N} \text{Div}(\boldsymbol{x}_i), \tag{5.20}$$

其中 β 是控制多样性正则化权重的超参数。

5.2.4.2　多头分类器策略（Multi-head Strategy）

一个经典的参数化分类模型 $f(\cdot;\theta)$ 通常包含深度特征提取器 ψ 和参数矩阵为 W 的线性分类器 g。最终预测表示为 $f(\boldsymbol{x}) = \text{softmax}(s(\boldsymbol{x}))$，其中输出 Logits $s(\boldsymbol{x}) = g(\psi(\boldsymbol{x})) = W^{\top}\psi(\boldsymbol{x})$。

由于在公式 (5.20) 中需要获得每个子群的独立预测结果，本研究参考 Transformer 等架构中的设计[4,182]，采用了一种**多头策略（Multi-head Strategy）**。具体而言，我们将特征通道和分类器权重均等地划分为 K 组：

$$\psi(\boldsymbol{x}) = [\psi_1(\boldsymbol{x}), \psi_2(\boldsymbol{x}), \ldots, \psi_K(\boldsymbol{x})], \quad W = [W_1, W_2, \ldots, W_K]. \tag{5.21}$$

对于任意子群 $z \in \mathcal{Z}$，其输出 Logits 表示为 $s_z(\boldsymbol{x}) = W_z^{\top}\psi_z(\boldsymbol{x})$。

基于定理 5.2，最终的子群平衡预测可以通过聚合操作获得：

$$f(\boldsymbol{x}) = \text{softmax}(s(\boldsymbol{x})), \quad \text{其中} s(\boldsymbol{x}) = \log \sum_{z \in \mathcal{Z}} e^{s_z(\boldsymbol{x})}. \tag{5.22}$$

需要特别指出的是，与不考虑子群不平衡的普通网络相比，本研究采用的多头策略**并不引入任何额外的参数**。换言之，该策略仅仅是将倒数第二层的输出特征和最后一层的分类器权重在逻辑上划分为不同的组，并利用它们生成对应于多个子群的预测结果。这种设计保证了 SHE 算法在模型容量和计算开销上的高效性。

5.3 实验验证

在本节中，本研究将通过一系列实验来验证所提出的 SHE 算法的有效性。首先介绍实验的具体设置，随后在多个基准数据集上与现有的先进方法进行对比，并进一步验证 SHE 在处理其他类型不平衡数据时的泛化能力。最后，通过全面的消融实验和深入分析，探讨算法各组件的作用及超参数敏感性。

5.3.1 实验设置

5.3.1.1 数据集构建

为了全面评估 SHE 在隐式子群不平衡场景下的性能，本研究在三个广泛使用的基准数据集上进行了实验：**COCO**[183]、**CIFAR-100**[160] 以及 **tieredImageNet**[184]。

- **COCO**：对于 COCO 数据集，本研究遵循 ALT 协议（Attribute-wise Long-Tailed protocol）[185] 来构建具有子群不平衡特性的训练集以及子群平衡的测试集。在该协议下，数据集中天然存在的某些属性（如物体的大小、遮挡程度等）被视为潜在的子群划分依据，并在训练集中人为制造属性分布的偏斜。
- **CIFAR-100**：CIFAR-100 包含 100 个细粒度类别，这些类别被归为 20 个超类（Superclasses）。本研究将这 20 个超类作为分类任务的目标类别，并通过在每个超类内部对其子类（Subclasses）进行非均匀采样来生成子群不平衡。具体而言，遵循 Cui 等人[41] 的方法，本研究采用指数采样策略，设置不平衡比率（Imbalance Ratio, IR）为 $\mathrm{IR} \in \{20, 50, 100\}$。此处不平衡比率定义为子群样本数量的最大值与最小值之比，即 $\mathrm{IR} = \frac{\max_{z \in \mathcal{Z}} \sum_{(\boldsymbol{x}_i, y_i, z_i) \in \mathcal{D}} \mathbf{1}(z_i = z)}{\min_{z \in \mathcal{Z}} \sum_{(\boldsymbol{x}_i, y_i, z_i) \in \mathcal{D}} \mathbf{1}(z_i = z)}$。这种设置模拟了现实中同一类别下不同子概念（如“水生生物”类别下的“海狸”与“海豚”）出现频率极不均衡的情况。
- **tieredImageNet**：tieredImageNet 是 ImageNet 的一个更大规模子集，包含 34 个超类。本研究将这 34 个超类作为分类目标，并通过对每个超类下的 10 个子类进行不平衡采样（设置不平衡比率 IR = 100）来构造隐式子群不平衡。

5.3.1.2 对比基线方法

本研究将 SHE 与三类具有代表性的方法进行了广泛对比。为了公平起见，这里仅考虑那些**在训练和验证阶段不需要子群标注（Subpopulation Annotation）**的方法：

1. **经验风险最小化（ERM）：** 作为最基础的基线，仅使用标准交叉熵损失进行训练。
2. **不平衡学习方法（Imbalanced Learning Methods）：** 选取了当前最先进的长尾学

习算法，包括 PaCO[141]、BCL[140]、IFL[185]、DB[186]、TDE[182] 以及 ETF-DR[187]。需要特别指出的是，一些经典的不平衡学习方法，如 Logit Adjustment (LA)[42]、LDAM[84] 和 Class-Balanced Loss (CB)[41]，在类别层级（Class-level）平衡的情况下会退化为普通的 ERM，因此在处理隐式子群不平衡（且显式类别平衡）的任务中效果有限。

3. **针对虚假相关性的方法（Spurious Correlation Methods）：**选取了无需子群标注的去偏算法，包括 LfF[113]、Focal Loss[79]、EIIL[47]、ARL[114]、GRASP[188]、JTT[46] 以及 MaskTune[169]。这些方法旨在通过识别难样本或学习不变特征来缓解模型对虚假相关性的依赖。

此外，本研究还在附录中提供了 SHE 与更多结合了聚类和重平衡策略的启发式基线方法的对比结果，以进一步验证本方法的有效性。

5.3.1.3　实现细节

所有实验均采用 18 层 ResNet 作为骨干网络。数据增强策略遵循文献[139] 的标准设置，包括随机裁剪和水平翻转等。训练过程使用 SGD 优化器，动量设置为 0.9，权重衰减为 0.005。Mini-batch 大小设定为 256。

对于 SHE 算法的特有参数，除非特别说明，预定义的子群数量 K 默认设置为 4。公式 (5.20) 中控制多样性正则化强度的超参数 β 设置为 1.0。初始学习率设定为 0.1，并采用余弦退火策略（Cosine Scheduling）进行学习率衰减。模型总共训练 200 个 Epoch。

5.3.2　隐式子群不平衡下的性能评估

在本小节中，本研究对 SHE 算法在隐式子群不平衡任务上的性能进行了全面评估。通过与一系列先进基线方法的横向对比，验证了 SHE 在无监督子群挖掘与平衡预测方面的有效性。

5.3.2.1　总体性能对比

表 5.2 总结了各方法在 COCO、不同不平衡比率（$\mathrm{IR} \in \{100, 50, 20\}$）下的 CIFAR-100 以及 tieredImageNet 三个基准数据集上的 Top-1 测试准确率。

实验结果表明，本研究提出的 SHE 算法在所有基准设定下均一致地优于所有对比基线。具体而言：

- 在 COCO 数据集上，SHE 相较于表现最好的基线方法（BCL）提升了 **1.73%**；
- 在 CIFAR-100 数据集上，针对 $\mathrm{IR} = 100, 50, 20$ 三种不平衡比率，SHE 分别取得

表 5.2　SHE 算法与基线算法在 COCO、CIFAR-100（不平衡比率 IR $\in \{100, 50, 20\}$，分别标记为 CIFAR-IR$\underline{\text{IR}}$) 以及 tieredImageNet 上的 Top-1 测试准确率（均值 ± 标准差）。最优结果加粗显示。

Table 5.2　Performance (Mean ± Std) of methods on COCO, CIFAR-100 with the imbalance ratio IR $\in \{100, 50, 20\}$ (marked as CIFAR-IR$\underline{\text{IR}}$), and tieredImageNet. Bold indicates the best results.

算法名称	COCO	CIFAR-IR100	CIFAR-IR50	CIFAR-IR20	tieredImageNet
ERM	62.52 ± 0.32%	52.49 ± 0.27%	55.20 ± 0.41%	58.92 ± 0.62%	48.23 ± 0.27%
PaCO	62.59 ± 0.24%	52.89 ± 0.39%	55.47 ± 0.29%	59.15 ± 0.44%	48.72 ± 0.45%
BCL	62.83 ± 0.42%	53.02 ± 0.26%	55.50 ± 0.33%	59.07 ± 0.23%	48.56 ± 0.61%
IFL	62.57 ± 0.15%	52.45 ± 0.33%	55.16 ± 0.42%	59.07 ± 0.51%	48.64 ± 0.18%
DB	62.72 ± 0.48%	52.96 ± 0.21%	55.52 ± 0.27%	59.19 ± 0.37%	48.52 ± 0.13%
TDE	62.64 ± 0.27%	52.67 ± 0.12%	55.34 ± 0.17%	59.10 ± 0.22%	48.36 ± 0.54%
ETF-DR	62.45 ± 0.37%	52.43 ± 0.18%	55.27 ± 0.13%	58.87 ± 0.17%	48.51 ± 0.66%
LfF	62.06 ± 0.83%	52.13 ± 0.52%	54.78 ± 0.64%	58.54 ± 0.52%	47.87 ± 0.23%
Focal	61.67 ± 0.53%	51.77 ± 0.63%	54.64 ± 0.62%	58.33 ± 0.73%	47.68 ± 0.62%
EIIL	62.61 ± 0.33%	52.82 ± 0.17%	55.55 ± 0.32%	59.02 ± 0.35%	48.56 ± 0.33%
ARL	62.48 ± 0.22%	52.67 ± 0.36%	55.32 ± 0.17%	59.03 ± 0.24%	48.55 ± 0.38%
GRASP	62.73 ± 0.25%	52.92 ± 0.41%	55.62 ± 0.30%	59.12 ± 0.27%	48.37 ± 0.24%
JTT	62.32 ± 0.75%	52.37 ± 0.48%	55.02 ± 0.32%	58.61 ± 0.64%	48.04 ± 0.39%
MaskTune	60.23 ± 0.73%	51.63 ± 0.31%	54.35 ± 0.49%	58.03 ± 0.36%	47.56 ± 0.54%
SHE	**64.56 ± 0.24%**	**54.52 ± 0.35%**	**56.87 ± 0.17%**	**60.72 ± 0.41%**	**50.14 ± 0.18%**

了 **1.50%**、**1.25%** 和 **1.53%** 的性能增益；

- 在 tieredImageNet 数据集上，SHE 相比最佳基线（PaCO）提升了 **1.42%**。

通过对比可以发现，现有的不平衡学习方法（Imbalanced Baselines）通常仅能带来边缘性的提升，甚至在某些情况下与基础的 ERM 表现相当。这些方法的增益主要来源于对比表征学习（如 PaCO）、不变特征学习（如 IFL）或鲁棒分类器设计（如 ETF-DR）等技术，但由于缺乏对隐式子群结构的显式建模，它们难以彻底解决子群层面的偏差。

另一方面，针对虚假相关性的基线方法（Spurious Correlation Baselines，如 LfF, JTT 等）通常假设模型倾向于拟合强虚假特征。然而，当训练数据中并未呈现出明显的单一主导虚假相关性时（例如在复杂的自然图像数据集中），这些方法的性能往往会出现退化。

相比之下，SHE 通过追求最优数据划分（Optimal Data Partition）并实施子群层面的预测重平衡，成功地解决了隐式子群不平衡问题，在所有实验设置中均取得了最佳且稳定的改进。

5.3.2.2　细粒度性能分析

为了深入剖析 SHE 性能提升的来源，表 5.3 展示了 COCO 数据集上的细粒度评估结果。根据训练集中的样本数量，测试集被划分为 Many（头部子群）、Medium（中部子群）和 Few（尾部子群）三个部分。这种划分能够直观地反映模型对不同频次子群的泛化能力。

从表中数据可以观察到：

- **基线方法的偏差：**正如预期的那样，大多数基线方法（如 ERM, PaCO, ARL 等）在主导子群（Many）上表现较好，但在稀缺子群（Few）上性能急剧下降。这证实了隐式子群不平衡确实会导致模型忽略少数群体。
- **SHE 的尾部提升：** SHE 在 Few 子群上取得了显著的性能飞跃，准确率达到了 **42.09%**，相比表现最好的基线（BCL 的 37.67%）提升了 **4.42%**。这表明 SHE 的子群重平衡机制有效地保护了弱势子群。
- **无损头部性能：**值得注意的是，SHE 不仅在 Few 子群上表现出色，同时在 Many 和 Medium 子群上也取得了最佳结果（分别为 67.71% 和 53.50%）。这体现了 SHE 的一个重要优点：它能够在不牺牲头部子群性能的前提下，显著增强少数子群的表现，从而实现了整体性能的帕累托改进。

5.3.3　在更复杂不平衡场景下的性能评估

为了进一步验证 SHE 算法的通用性与鲁棒性，本小节将评估其在两种更为复杂和现实的场景下的表现：一是子群不平衡与类别不平衡共存的复合场景，二是存在虚假相关性（Spurious Correlation）的场景。

5.3.3.1　子群不平衡与类别不平衡共存场景

在现实应用中，数据往往同时面临着显式的类别不平衡和隐式的子群不平衡。探究 SHE 在这种双重不平衡条件下的表现具有重要的实践意义。

实验设置：本研究遵循文献[185] 的方法构建了同时包含类别不平衡和子群不平衡的训练集。具体而言，对于 CIFAR 和 tieredImageNet 数据集，通过非均匀采样构造训练集，使得类别分布和子群分布的不平衡比率均为 IR = 100。测试集则保持类别和子群的双重平衡，以公平评估模型对所有群体的泛化能力。

结果分析：表 5.4 展示了各方法在 COCO、CIFAR-100 (IR = 100) 以及 tieredImageNet 上的实验结果。从表中可以观察到：

- **不平衡学习基线的提升：**相比于基础的 ERM，现有的不平衡学习基线方法（如

表 5.3　SHE 算法与基线算法在 COCO 数据集上的细粒度性能分析。头部、中部和尾部分别对应基于训练数据子群不平衡程度划分的三个测试集子集。总体表示完整测试集上的准确率。SHE 在大幅提升尾部子群性能的同时，未牺牲头部子群的表现。

Table 5.3　Per-split accuracies on COCO. Many, Medium, and Few are the three splits of the test set based on the training imbalancedness. Overall means the full test set.

算法名称	头部子群 (Many)	中部子群 (Medium)	尾部子群 (Few)	总体 (Overall)
ERM	67.21%	52.22%	37.10%	62.52%
PaCO	67.45%	53.33%	36.23%	62.59%
BCL	66.89%	53.21%	37.67%	62.93%
IFL	**67.71%**	52.17%	36.82%	62.57%
DB	67.35%	52.11%	37.47%	62.72%
TDE	66.32%	53.23%	37.02%	62.64%
EIIL	66.87%	52.79%	37.06%	62.61%
ARL	67.32%	53.34%	37.18%	62.48%
GRASP	67.13%	53.26%	37.29%	62.73%
JTT	66.93%	51.24%	36.48%	62.32%
MaskTune	64.48%	50.11%	33.27%	60.23%
SHE	**67.71%**	**53.50%**	**42.09%**	**64.56%**

表 5.4　SHE 算法与基线算法在子群不平衡与类别不平衡共存场景下的性能评估（均值 ± 标准差）。最优结果已加粗显示。

Table 5.4　Performance evaluation of SHE and baselines under the coexistence of subgroup imbalance and class imbalance (mean ± standard deviation). The best results are highlighted in bold.

设置：子群与类别双重不平衡 (Mean ± Std)			
算法名称	COCO	CIFAR-IR100	tieredImageNet
ERM	63.57 ± 0.34%	59.24 ± 0.46%	53.65 ± 0.46%
LA	66.47 ± 0.27%	59.73 ± 0.27%	54.12 ± 0.35%
LDAM	66.32 ± 0.33%	59.66 ± 0.26%	54.01 ± 0.51%
CB	66.17 ± 0.21%	59.45 ± 0.36%	53.78 ± 0.21%
PaCO	66.78 ± 0.41%	59.87 ± 0.51%	54.15 ± 0.39%
BCL	66.92 ± 0.26%	59.78 ± 0.37%	54.23 ± 0.27%
IFL	65.34 ± 0.52%	59.44 ± 0.41%	53.88 ± 0.43%
DB	66.43 ± 0.15%	59.81 ± 0.29%	54.14 ± 0.30%
TDE	66.12 ± 0.44%	59.63 ± 0.34%	53.91 ± 0.28%
ETF-DR	65.92 ± 0.26%	59.71 ± 0.18%	54.07 ± 0.31%
SHE$_{\text{w/LA}}$	**68.11 ± 0.27%**	**61.67 ± 0.31%**	**55.73 ± 0.22%**

表 5.5　SHE 算法与基线算法在虚假相关性数据集上的性能评估。表中分别报告了最差群组准确率（Worst Acc）和平均准确率（Mean Acc）。“群组信息”一列表示是否在训练集或验证集上使用了群组标注。

Table 5.5　Performance evaluation on spurious correlation datasets. The table reports the Worst-Group Accuracy (Worst Acc) and the Mean Accuracy (Mean Acc). The “Group Information” column indicates whether group annotations are used in the training or validation set.

设置：虚假相关性 (最差群组准确率 / 平均准确率)			
算法名称	群组信息是否可见 (训练集 / 验证集)	CelebA	Waterbirds
GDRO	是 / 是	**88.3%** / 91.8%	**91.4%** / 93.5%
LfF	否 / 是	77.2% / 85.1%	82.1% / 94.3%
SD	否 / 是	**83.2%** / 91.6%	**87.3%** / 90.3%
JTT	否 / 是	81.1% / 88.0%	86.7% / 93.3%
CIM	否 / 是	81.3% / 89.2%	77.2% / 95.6%
ERM	否 / 否	47.2% / 95.6%	74.9% / 98.1%
LfF	否 / 否	24.4% / 85.1%	67.5% / 87.5%
JTT	否 / 否	40.6% / 88.0%	71.8% / 92.3%
MaskTune	否 / 否	**78.0%** / 91.3%	80.7% / 92.1%
SHE$_{\text{w/GDRO}}$	否 / 否	77.9% / 91.7%	**81.9%**/ 91.3%

LA, LDAM, PaCO 等）在面对类别不平衡时确实能够一致地提升测试准确率。

- **SHE 的进一步增益：**当将 SHE 与经典的长尾学习基线 Logit Adjustment (LA)[42] 相结合时（记为 SHE$_{\text{w/LA}}$），模型性能得到了显著提升。具体而言，与表现最好的基线方法相比，SHE$_{\text{w/LA}}$ 在 COCO 上提升了 1.19%，在 CIFAR-100 上提升了 1.80%，在 tieredImageNet 上提升了 1.50%。

这一结果表明，SHE 能够有效地与处理显式类别不平衡的方法互补，展现了其解决更复杂、多层次不平衡问题的潜力。

5.3.3.2　虚假相关性场景

虚假相关性是隐式子群不平衡的一种特殊表现形式，通常源于某些非因果属性与类别标签之间的强相关性。为了验证 SHE 在消除虚假相关性方面的有效性，本研究将其直接应用于分布鲁棒优化框架 GDRO[45] 中（记为 SHE$_{\text{w/GDRO}}$）。具体做法是利用 SHE 学习到的子群划分替代 GDRO 中通常需要的先验群组（Group）标注。

实验设置：实验在两个经典的虚假相关性基准数据集上进行：CelebA[189] 和 Waterbirds[45]。评估指标包括最差群组准确率（Worst Acc）和平均准确率（Mean Acc）。

结果分析：表 5.5 展示了 $\text{SHE}_{\text{w/GDRO}}$ 与一系列基线方法的对比结果。

- **与无监督方法的对比：**在不使用任何群组标注的设定下，$\text{SHE}_{\text{w/GDRO}}$ 取得了极具竞争力的性能。特别是在 Waterbirds 数据集上，其最差群组准确率达到了 81.9%，优于 MaskTune 等先进方法。这证明了 SHE 在缺乏先验信息时，能够有效地挖掘并缓解虚假相关性。
- **与有监督方法的对比：**值得注意的是，表中还列出了一些需要训练集或验证集群组标注的方法（如 GDRO, SD, JTT 等）作为参考。虽然 $\text{SHE}_{\text{w/GDRO}}$ 未使用任何显式群组信息，其性能依然接近甚至超过了部分半监督或全监督方法。

定性分析：更有趣的是，图 5.6 中的可视化结果显示，SHE 所学习到的子群划分具有明确的物理意义：它倾向于将训练数据划分为“包含虚假相关性”和“不含虚假相关性”两类子群。这种数据驱动的划分方式实际上与人工定义的先验群组标注并不完全一致，但对于提升模型的鲁棒性却更为有效。这进一步印证了 SHE 在无监督条件下挖掘数据内在结构的能力。

5.3.4 消融实验与深入分析

为了全面理解 SHE 算法各组件的作用、超参数的敏感性以及算法在不同设定下的行为，本小节进行了多维度的深入分析。

5.3.4.1 潜在子群数量 K 的消融分析

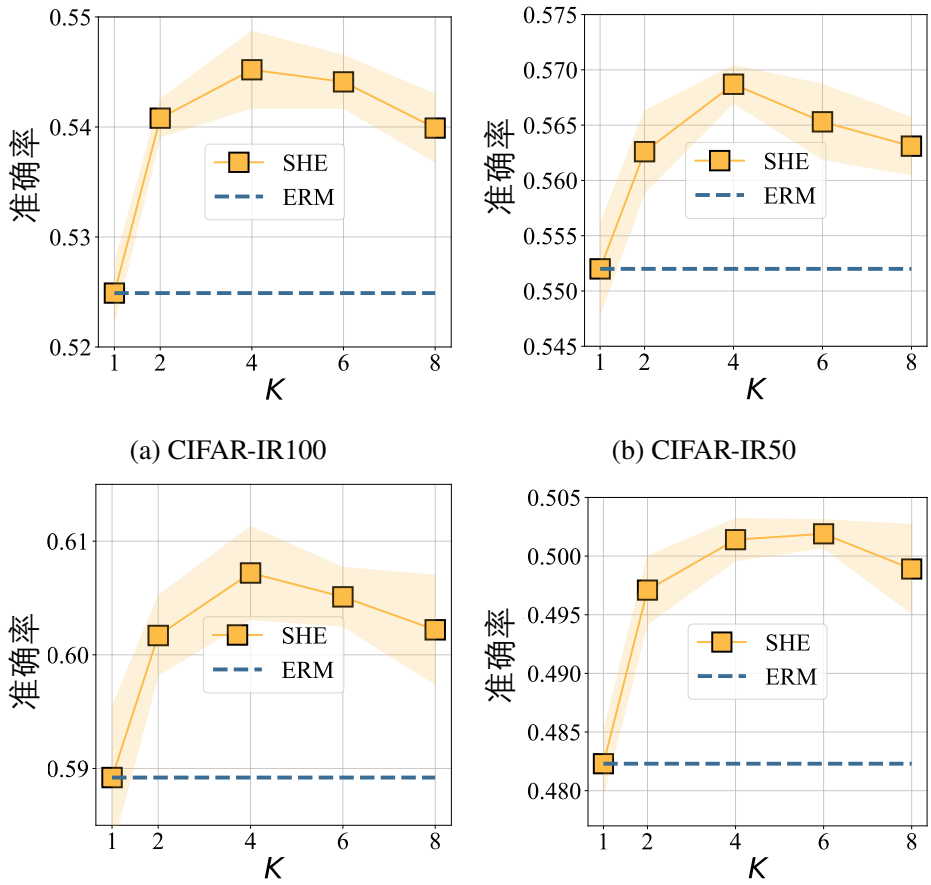
本研究首先探究了预定义的潜在子群数量 K 对 SHE 性能的影响。图 5.8a 展示了在 COCO 数据集上，随着 K 值变化，SHE 的 Top-1 测试准确率变化情况。

- 当 $K = 1$ 时，SHE 的损失函数退化为标准的交叉熵损失，此时其性能与 ERM 基线相当。
- 当 $K > 1$ 时，SHE 展现出了显著优于 ERM 的性能提升，这证实了引入子群建模的必要性。
- 此外，算法对 K 的选择表现出较强的鲁棒性。在 $K = 4$ 时，SHE 取得了最佳的平均性能。

在 CIFAR 和 tieredImageNet 数据集上也观察到了类似的现象（详细结果参见图 5.7）。这表明 SHE 对 K 的具体取值不敏感，只要引入了多子群结构，即可获得性能增益。

5.3.4.2 多样性正则化项与熵项的影响

本研究进一步分析了公式 (5.20) 中多样性正则化项 $\text{Div}(\boldsymbol{x})$（由超参数 β 控制）以及条件熵项 $\hat{H}_{\mathcal{D}}(Y|V)$ 的作用。



(a) CIFAR-IR100　　(b) CIFAR-IR50

(c) CIFAR-IR20　　(d) tiredImageNet

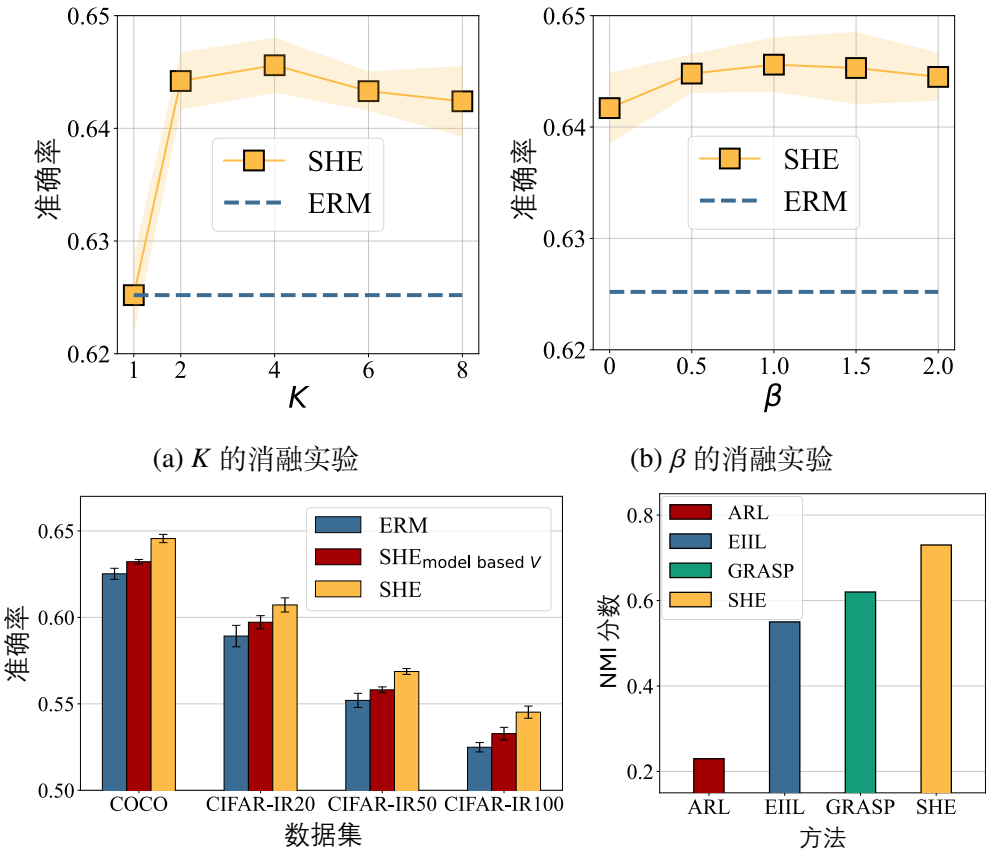
图 5.7　在 CIFAR-IR100、CIFAR-IR50、CIFAR-IR20 以及 tiredImageNet 数据集上，SHE 算法在不同子群数量 K 设置下的性能对比

Figure 5.7　Performance of SHE with varying subpopulation number K on CIFAR-IR100, CIFAR-IR50, CIFAR-IR20, and tiredImageNet.

多样性正则化项 β 的影响：图 5.8b 展示了在 COCO 数据集上不同 β 取值下的性能表现。

- 即使在没有多样性正则化项（即 $\beta = 0$）的情况下，SHE 依然显著优于 ERM 基线，这说明核心的子群发现与平衡机制本身是有效的。
- 随着 β 的增加，模型性能持续提升，并在 $\beta = 1.0$ 时达到最佳。这验证了鼓励子群预测多样性有助于模型学习更丰富的特征表示。
- 总体而言，SHE 对 β 的选择较为鲁棒，在较宽的范围内均能保持高性能。

熵项的影响：表 5.6 中对比了去除熵项 $\hat{H}_{\mathcal{D}}(Y|V)$ 的变体（记为 $\text{SHE}_{\text{w/o entropy}}$）与完整 SHE 的性能。结果显示，熵项的引入一致且有效地提升了模型性能，证实了其



(a) K 的消融实验　　(b) β 的消融实验

(c) V 优化策略对比　　(d) NMI 分数对比

图 5.8　(a) COCO 数据集上 SHE 性能随子群数量 K 的变化。(b) COCO 数据集上 SHE 性能随多样性正则化系数 β 的变化。(c) ERM、$\text{SHE}_{\text{model based } V}$ 与 SHE 在 COCO 及不同不平衡率 CIFAR 数据集上的性能对比。(d) Waterbirds 数据集上各方法学习到的子群与真实标注之间的 NMI 分数。

Figure 5.8　(a) Performance of SHE and ERM on COCO with varying subpopulation number K. (b) Performance of SHE and ERM on COCO with varying β. (c) Performance comparison of ERM, $\text{SHE}_{\text{model based } V}$, and SHE on COCO, CIFAR-IR20, CIFAR-IR50, and CIFAR-IR100. (d) NMI scores between the learned subpopulations and the true annotations on Waterbirds dataset.

在约束子群内部类别分布、防止坍塌方面的关键作用。

5.3.4.3　追求最优数据划分与子群平衡预测的作用

SHE 算法的核心思想包含两个方面：一是追求最优数据划分（Scatter），二是实现子群平衡的预测（Harmonize）。为了验证这两个方面的必要性，表 5.6 对比了以下变体：

- **ERM**：标准经验风险最小化。
- **$\text{ERM}_{\text{multi-head}}$**：仅使用多头网络架构，但不进行子群划分优化（即随机或均匀划

表 5.6　SHE 算法及其变体与 ERM 在 COCO 和 CIFAR-100 数据集上的性能对比。
Table 5.6　Performance of ERM, SHE, and some of their variants on COCO and CIFAR-100.

算法名称	COCO	CIFAR-IR100	CIFAR-IR50	CIFAR-IR20
ERM	62.52 ± 0.32%	52.49 ± 0.27%	55.20 ± 0.41%	58.92 ± 0.62%
$\text{ERM}_{\text{multi-head}}$	62.47 ± 0.28%	52.53 ± 0.17%	55.16 ± 0.47%	58.88 ± 0.36%
SHE_{EIIL}	62.82 ± 0.27%	52.63 ± 0.22%	55.36 ± 0.37%	59.21 ± 0.48%
$\text{SHE}_{\text{w/o entropy}}$	64.15 ± 0.27%	53.96 ± 0.37%	56.31 ± 0.23%	60.03 ± 0.38%
SHE	**64.56 ± 0.24%**	**54.52 ± 0.35%**	**56.87 ± 0.17%**	**60.72 ± 0.41%**

分）。其性能与 ERM 相当，说明仅增加网络容量（多头）而无有效的子群指导并不能带来提升。

- **SHE_{EIIL}**：保留子群发现目标，但移除多头网络架构，转而采用类似 EIIL[47] 的方式利用学习到的子群（即基于子群重加权的单头网络）。

实验结果表明：1. SHE 显著优于 ERM 和 $\text{ERM}_{\text{multi-head}}$，证明了追求最优数据划分（即挖掘潜在子群结构）对于提升预测能力的必要性。2. SHE 优于 SHE_{EIIL}，这确认了本研究提出的基于多头架构和 LogSumExp 聚合的子群平衡预测机制比简单的重加权策略更为有效。

5.3.4.4　子群权重矩阵 V 优化策略的分析

本研究还探讨了子群权重矩阵 V 的不同优化策略对性能的影响。为此，构建了一个变体 $\text{SHE}_{\text{model based } V}$，该变体采用基于模型的方法（即仅从输入图像特征 $\boldsymbol{x}$）来学习数据划分，而非像 SHE 那样同时利用输入 $\boldsymbol{x}$ 和标签 y（见定义 5.1 中的 $v(\boldsymbol{x}, y)$）。

如图 5.8c 所示，$\text{SHE}_{\text{model based } V}$ 的性能明显低于标准的 SHE。一个可能的原因是，最优数据划分应当是输入和标签的联合函数，仅依赖输入特征无法充分捕获输入与标签之间的交互信息，从而导致次优的子群划分。

5.3.4.5　恢复子群的质量评估

为了定量评估 SHE 在挖掘训练数据中潜在子群结构的能力，本研究将其与基于子群推断的基线方法（EIIL, ARL, GRASP）进行了对比。具体而言，我们在 Waterbirds 数据集上计算了各方法恢复出的子群划分与真实子群标注（Ground Truth）之间的归一化互信息（NMI）分数。

如图 5.8d 所示，SHE 取得了最高的 NMI 分数（0.73），显著优于对比方法（如 GRASP 的 0.62）。这表明 SHE 具备卓越的能力，能够准确地发现隐藏在训练数据中的潜在结构，从而为后续的子群平衡预测提供了坚实的基础。

表 5.7　在 COCO 数据集上，基于三个大规模预训练模型（CLIP, ALIGN, AltCLIP）进行 LoRA 微调后的性能对比。

Table 5.7　LoRA fine-tuning results of different methods under three popular pre-trained models on COCO.

算法名称	CLIP	ALIGN	AltCLIP
Zero-shot	76.59 ± 0.00%	78.45 ± 0.00%	82.55 ± 0.00%
ERM	84.32 ± 0.14%	83.38 ± 0.12%	84.85 ± 0.07%
PaCO	84.38 ± 0.11%	83.54 ± 0.15%	85.06 ± 0.16%
BCL	84.48 ± 0.06%	83.32 ± 0.11%	85.06 ± 0.05%
IFL	84.55 ± 0.06%	83.40 ± 0.05%	84.83 ± 0.06%
DB	84.46 ± 0.11%	83.14 ± 0.13%	84.14 ± 0.40%
TDE	84.37 ± 0.10%	83.42 ± 0.05%	84.51 ± 0.19%
ETF-DR	84.26 ± 0.15%	83.36 ± 0.09%	84.78 ± 0.05%
LfF	84.17 ± 0.05%	83.12 ± 0.07%	84.20 ± 0.02%
Focal	83.87 ± 0.10%	82.77 ± 0.12%	83.84 ± 0.14%
EIIL	84.23 ± 0.12%	83.21 ± 0.07%	84.34 ± 0.05%
ARL	84.02 ± 0.08%	82.97 ± 0.17%	84.07 ± 0.07%
GRASP	84.32 ± 0.16%	83.14 ± 0.04%	84.44 ± 0.13%
JTT	84.45 ± 0.09%	83.09 ± 0.02%	84.40 ± 0.15%
MaskTune	83.27 ± 0.10%	82.54 ± 0.13%	83.52 ± 0.20%
SHE	**85.39 ± 0.06%**	**84.23 ± 0.06%**	**85.69 ± 0.11%**

5.3.4.6　基于预训练模型的微调效果

近年来，基于大规模预训练模型（Foundation Models）进行下游任务微调已成为主流范式。为了验证 SHE 在这一新范式下的有效性，表 5.7 展示了在 COCO 数据集上，基于三个流行的多模态预训练模型——CLIP (ViT-B/32)[18]、ALIGN (EfficientNet-L2 & BERT-Large)[190] 和 AltCLIP (ViT-L)[191] 进行微调的结果。实验采用 LoRA[192] 技术进行微调，以加速训练并防止过拟合。

实验结果表明，尽管得益于强大的预训练表征，所有方法的性能相比从头训练（Training from scratch）都有了显著提升，但 SHE 依然一致地超越了所有基线方法。这证明了即使在特征表示已经非常强大的情况下，显式地解决隐式子群不平衡问题仍然能带来额外的性能增益，体现了 SHE 算法的普适性。

5.4　本章小结

本章针对不平衡学习中极具挑战性且容易被忽视的隐式子群不平衡问题展开了深入研究。与传统的类别层级不平衡不同，这种不平衡性隐藏在数据内部的潜在结构

中，由于缺乏细粒度的子群标注信息，现有的重平衡算法往往难以察觉并处理这类偏差。本文指出，机器学习模型在混合分布下容易被多数子群主导，从而忽略少数子群的特征，这不仅损害了模型的泛化能力，也带来了潜在的算法公平性风险。

为了解决上述问题，本章提出了一种名为 SHE (Scatter and Harmonize) 的无监督挖掘与重平衡算法。该算法的核心逻辑在于先通过解耦混合分布来发现潜在子群，再通过协调机制实现平衡预测。本研究的主要研究成果与贡献可以归纳为以下几个方面：

首先，本文从信息论视角出发，引入了最优数据划分的概念。通过最大化输入、标签与划分变量之间的交互信息，本文为无监督条件下的子群挖掘提供了理论判据。本章证明了最小化所提出的经验风险函数在统计一致性的意义下等价于追求最优数据划分。这种机制能够驱动模型自发地识别出具有一致预测规律的潜在结构，将复杂的混合分布分类问题转化为多个相对简单的子群分类问题。

其次，本研究设计了一种基于子群平衡的预测聚合机制。利用多头分类器架构，本文提出对各子群输出的 Logits 进行 LogSumExp 运算。理论证明显示，该操作能够使模型在推理阶段直接拟合子群平衡的目标分布，从而在无需先验标注的情况下实现对弱势群体的保护。这种多头策略在逻辑上拆分了特征空间与线性分类器，在不增加模型总参数量的前提下，有效提升了模型对异质性数据的处理能力。

最后，本章在 COCO、CIFAR-100 以及 tieredImageNet 等多个具有代表性的基准数据集上进行了广泛的实验验证。实验结果表明，SHE 算法在处理隐式子群不平衡问题时显著优于当前主流的长尾学习算法与去偏方法。细粒度性能分析进一步证实，本文提出的方法能够大幅度提升少数子群的预测准确率，且不会对多数子群的性能造成损害。此外，在子群与类别双重不平衡、虚假相关性消除以及大模型微调等复杂场景下，SHE 均展现出了优异的鲁棒性与广泛的适用性。

本章的研究工作从数据内部的隐式异质结构入手，为鲁棒不平衡学习提供了新的解决思路。通过将挖掘潜在结构与预测重平衡有机结合，本文为构建在复杂现实环境中具有高度泛化性与公平性的深度学习模型奠定了理论与技术基础。

5.4.1　局限性与讨论

本章提出了一种基于互信息最大化的无监督子群挖掘与平衡算法，不仅通过理论分析证明了该机制在统计一致性方面的优越性，还通过广泛的实验验证了其在应对隐式结构失衡时的鲁棒性。虽然本研究在提升模型泛化性能方面取得了显著进展，但在更广泛的学术视野下，仍有一些关键维度值得社区进一步探讨。

首先，本章目前的算法实现中涉及子群数量的预设。在真实世界的复杂场景下，不同类别的内在异质性往往呈现出不同的复杂度，采用统一的固定数值可能难以捕获所有类别的细微结构变化。未来社区的研究可以关注如何结合非参数化统计方法或自监督评估准则，实现在线数据流中的子群规模动态估计。

其次，本研究主要在视觉基准任务上进行了验证。随着大规模基础模型的广泛应用，如何将本文提出的子群解耦思想推广至多模态学习或自然语言理解等领域，将是极具前景的研究方向。例如，在视觉语言模型的预训练过程中，利用互信息工具挖掘语义空间中的隐式属性偏差，对于提升跨模态对齐的稳定性至关重要。此外，学术界可以进一步利用本研究所发现的潜在结构，构建具备可解释性的公平性约束机制，以推动人工智能系统在医疗与安全等高风险领域的可靠应用。

第 6 章 基于参数空间解耦的跨任务通用长尾学习

6.1 引言

回顾本论文第 1 章的论述，本研究将复杂场景下鲁棒长尾学习面临的挑战归纳为三个核心维度：监督信号的退化、潜在结构的隐匿以及任务目标的异构。在此前的章节中，本文已经针对前两个维度展开了深入探讨，分别提出了解决偏标签学习（RECORDS）、噪声标签修正（D-SINK）以及隐式子群不平衡（SHE）的针对性算法。这些工作主要着眼于判别式任务（Discriminative Tasks），其核心目标在于精准地学习条件概率分布 $P(Y|X)$ 以实现准确分类。

然而，随着人工智能技术的演进，生成式任务（Generative Tasks）已逐渐成为学术界和工业界的新焦点。与判别式任务建模 $P(Y|X)$ 不同，生成式任务旨在对数据分布 $P(X)$ 或条件分布 $P(X|Y)$ 进行建模，从而创造出全新的样本。本章将研究视野拓展至“任务目标异构”这一维度，以当前在图像生成领域展现出巨大潜力的扩散模型（Diffusion Models）为例[19,120,193]，探讨如何在生成式任务中实现长尾分布下的鲁棒学习。尽管扩散模型在 DALL-E 2[194] 和 Stable Diffusion[38] 等应用中取得了显著成功，但在面对现实世界普遍存在的长尾分布数据时，其性能瓶颈依然明显。研究表明，当训练数据存在显著的类别不平衡时，模型在少数类别（Minority Classes）上的生成质量会出现剧烈衰退[48,122]。如图 6.1a 所示，在处理稀有种族或特定属性时，生成的图像往往伴随着严重的失真，这严重限制了生成式模型在追求公平性和多样性的实际应用中的推广。

以往关于不平衡学习的研究大多集中在提升判别式模型的鲁棒性上，其技术路线难以直接迁移至生成式扩散模型。近期虽有工作尝试通过改进损失函数来缓解这一问题[48,122]，但本研究选择从一个更为底层的视角切入：模型容量分配（Model Capacity Allocation）。在此，模型容量被定义为神经网络用于捕获和存储数据特征的可用表征资源。本研究的动机源于一个深刻的实证观察：在长尾分布的训练过程中，多数类别（Majority Classes）倾向于垄断绝大部分的模型容量，导致少数类别可用的表征资源被极度压缩。这一观点得到了实证数据与理论分析的双重印证：一方面，视觉质量与参数敏感性分析（图 6.1b）表明，少数类别的生成质量对参数变动极度敏感，暗示其在模型中实际占据的有效容量极其微弱，处于一种“寄居”状态；另一方面，理论分析揭示由于多数类别样本数量庞大，其梯度主导权使得模型参数的演化方向几乎完

全被多数类所左右，实质上造成了对模型容量的“殖民”。

因此，解决长尾问题的关键不仅在于调整损失函数，更在于如何打破这种容量垄断。针对这一挑战，本章提出了一种通用的模型容量治理策略，称为 Capacity Manipulation (CM)。CM 的核心思想在于“预留”与“隔离”：通过技术手段为少数类别的专业知识（Expertise）预留专属的模型容量，防止其被多数类别的通用特征所侵占。在具体实现上，本研究利用低秩技术（Low-rank Techniques）将模型参数分解为两个正交的部分：一部分用于捕获多数类别及通用知识，另一部分则作为“特区”专门用于存储少数类别的特征信息（如公式 6.12 所示）。配合引入的容量操纵损失（Capacity Manipulation Loss），该框架能够强制模型在训练过程中将特定知识导向预留空间，从而实现对少数类别学习过程的有效保护。值得注意的是，尽管本章实验以扩散模型为主，但这种触及深度学习本质机制的容量治理思想具有跨任务的通用性。

综上所述，本章的主要贡献可概括为以下三点：

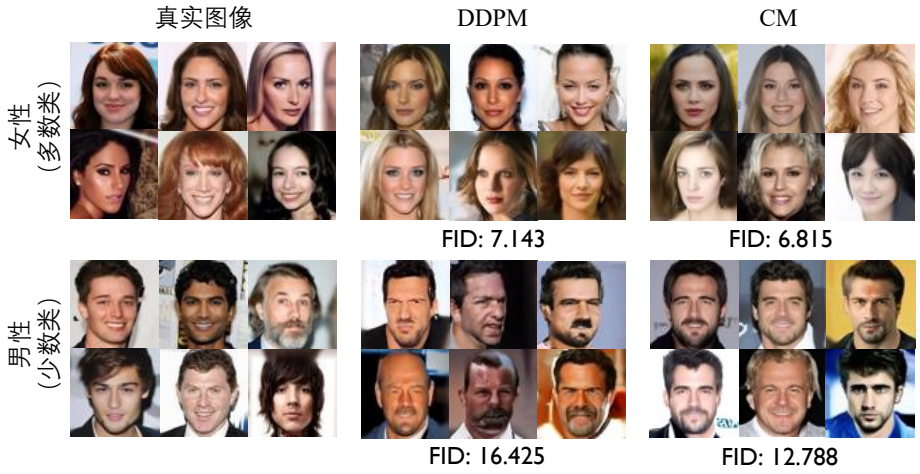
- **提出了一种基于模型容量分配的新视角**。不同于以往仅在损失函数层面做文章，本研究深入到参数空间的资源分配机制，揭示了长尾学习中性能失衡的更深层原因。
- **设计了通用的 CM 算法框架**。通过参数分解与容量预留，有效打破了多数类别的容量垄断。作为一种即插即用的策略，CM 既不需要增加推理开销，也能与现有的损失加权方法互补共存。
- **验证了方法的卓越性能与泛化潜力**。在多种数据集和架构上的实验表明，CM 在不牺牲多数类别质量的前提下大幅提升了少数类别的表现。该方法对底层资源的精细化控制能力，为解决更广泛的长尾学习问题提供了新思路。

6.2　扩散模型在长尾数据上的局限性分析

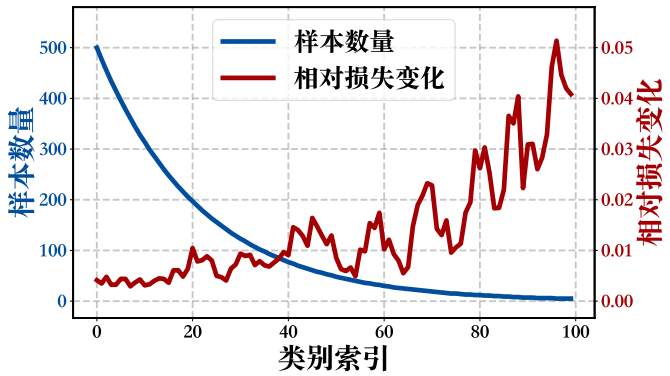
本节首先对长尾扩散模型的生成任务进行形式化定义，随后通过实证观察揭示现有扩散模型在长尾数据上的性能缺陷，最后通过理论分析深入剖析其背后的根本原因——模型容量的垄断。

6.2.1　问题定义

设 $\mathcal{X}$ 为图像空间，$\mathcal{Y} = \{1, \ldots, C\}$ 为标签空间，其中 C 为类别总数。本研究考虑一个包含 N 个样本的不平衡训练集 $\mathcal{D} = \{(\boldsymbol{x}^n, y^n)\}_{n=1}^{N} \in (\mathcal{X}, \mathcal{Y})^N$。各类别 $c \in \mathcal{Y}$ 的样本数量 N_c 按降序排列，呈现出显著的长尾分布特征。



(a) Imb. CelebA-HQ 可视化



(b) 剪枝后的损失变化

图 6.1　(a) Imb. CelebA 数据集（不平衡比率 IR = 100）中的真实图像，以及 DDPM 基线和本研究提出的 CM 方法生成的图像对比。图片均为随机采样。(b) 在 Imb. CIFAR-100 (IR = 100) 上训练的 DDPM 模型，当剪枝掉 L1 范数最小的 10% 参数后，各类别的相对损失变化。相对损失变化定义为 $(\mathcal{L}^c_{pruned} - \mathcal{L}^c_{raw})/\mathcal{L}^c_{raw}$。结果显示尾部类别的相对损失急剧增加，表明其对模型容量极其敏感。

Figure 6.1　(a) Real images from Imb. CelebA (Imbalance Ratio IR = 100) and generated images from DDPM and our method. Images are randomly sampled. (b) Relative per-class loss change for a DDPM model trained on Imb. CIFAR-100 (IR = 100) when 10% of its parameters with the smallest L1-Norm are pruned.

本研究的目标是基于不平衡数据集 $\mathcal{D}$，学习一个由参数 θ 决定的生成式扩散模型 $p_\theta(\boldsymbol{x}|y)$，使其能够针对所有类别生成逼真且多样的样本。对于无条件生成任务，可以将类别条件设置为 Null，即 $p_\theta(\boldsymbol{x}) = p_\theta(\boldsymbol{x}|\text{Null})$。

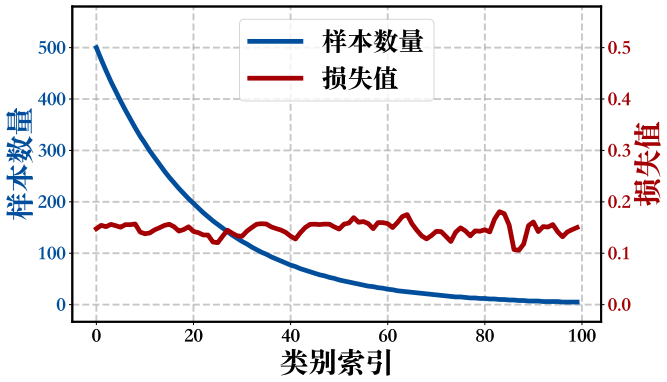


图 6.2　逐类别原始损失。实验设置与 图 6.1b 相同。

Figure 6.2　Per-class raw losses. The experimental setting is the same as in 图 6.1b.

6.2.2　实证动机：性能退化与容量敏感性

尽管扩散模型在图像生成领域表现出色，但其在面对数据不平衡时表现出显著的脆弱性。如图 6.1a 所示，本研究展示了一个在 Imb. CelebA-HQ 数据集（男女样本比率为 100:1）上训练的 DDPM 模型的效果。虽然该模型能够生成高质量的多数类（女性）图像，但在生成少数类（男性）图像时性能严重退化，这一点从视觉效果和 FID 分数上均可得到证实。作为对比，图中也展示了本研究提出的 CM 方法的生成结果。CM 方法通过操纵类间容量分配，显著提升了少数类（男性图像）的生成质量，这为解决类别不平衡问题提供了一个全新的视角。在 Imb. CIFAR-100 数据集上也观察到了类似的现象（详见图 6.1(c)）。

此外，图 6.1b 揭示了一个更为深刻的现象：尽管各类别在训练收敛时的原始损失值相近（参见图 6.2），但当剪枝掉模型中 L1 范数最小的参数时，少数类别的相对损失变化幅度远大于多数类别。从模型容量的角度来看，这一现象提供了一个有力的解释：多数类别垄断了模型的主要容量，迫使少数类别的信息只能存储在那些非关键（低 L1 范数）的参数中。这些脆弱的表征因此对剪枝操作表现出极高的敏感性。这一发现凸显了标准扩散模型在资源分配上的局限性，并激发了本研究针对性地进行模型容量分配的动机。

6.2.3　理论洞察：梯度主导与容量垄断

为了从理论层面解释上述现象，本研究提供了定理 6.1 作为一个说明性示例。该定理表明：头部类别主导了模型参数的更新方向，导致留给尾部类别的资源减少，从而造成尾部性能的下降。

定理 6.1　考虑一个二分类场景 $\mathcal{Y} = \{1, 2\}$，且训练集高度不平衡，即 $N_1 \gg N_2$。在假设 6.1 成立的条件下，网络中参数矩阵的更新方向被头部类别 $y = 1$ 主导的期望比率 Π_{maj} 为：

$$\Pi_{\text{maj}} = \Phi\left(\frac{(2a-1)\mu\sqrt{2N(1-\cos\angle(\mu_1,\mu_2))}}{2\sigma}\right), \tag{6.1}$$

其中 $a = \frac{N_1}{N_1+N_2}$ 为头部类别比率，$N = N_1 + N_2$ 为总样本数，$\Phi(\cdot)$ 为标准正态累积分布函数，μ_1 和 μ_2 分别为类别 $y = 1$ 和 $y = 2$ 的期望梯度，$\mu > 0$ 和 $\sigma > 0$ 为假设 6.1 中定义的正常数。

讨论与启示：从定理 6.1 中，我们可以得出以下关键洞察：

- 当 $a > 0.5$ 并趋近于 1 时，考虑到标准正态累积分布函数 $\Phi(\cdot)$ 是单调递增的凹函数且在正数域大于 0.5（见公式 6.10），可以推导出：(1) 在数量上占主导的类别同时也主导了模型容量；(2) 类别不平衡越严重，模型容量的不平衡就越剧烈，尽管这种影响具有边际递减效应。
- Π_{maj} 随着类间相似度的增加（即夹角 $\angle(\mu_1, \mu_2)$ 减小）而降低。这表明，较高的类间相似度有助于尾部类别从头部类别驱动的参数更新中获益，从而缓解容量垄断问题。
- Π_{maj} 与相对类内多样性 $\frac{\sigma}{\mu}$ 呈负相关。这意味着更高的类内多样性有助于缓解容量不平衡。
- Π_{maj} 随总样本量 N 的增加而增加，这表明在更大规模的数据集上，容量被头部类别主导的现象可能会进一步恶化。

6.2.4　定理 6.1 的证明

在本小节中，我们将详细给出定理 6.1 的证明过程。

6.2.4.1　问题设定

我们考虑在不平衡数据上训练扩散模型的简化版本，仅涉及两个类别 $\mathcal{Y} = \{1, 2\}$，其中 $N_1 \gg N_2$。因此，训练集上所有样本的总损失为：

$$\mathcal{L} = \sum_{i=1}^{N_1+N_2} \mathcal{L}_{\text{Diff}}(\boldsymbol{x}_i, y_i, \theta). \tag{6.2}$$

对于任意参数矩阵 $W \in \theta$，其梯度为：

$$\begin{aligned}\nabla_W \mathcal{L} &= \sum_{i=1}^{N_1+N_2} \nabla_W \mathcal{L}_{\text{Diff}}(\boldsymbol{x}_i, y_i, \theta) \\ &= \sum_{i=1}^{N_1} g_1^{(i)} + \sum_{j=1}^{N_2} g_2^{(j)},\end{aligned} \tag{6.3}$$

其中 $g_1^{(i)}$ 和 $g_2^{(j)}$ 分别表示类别 $y = 1$ 的第 i 个样本和类别 $y = 2$ 的第 j 个样本对参数 W 的梯度贡献。为简洁起见，此处省略了符号中的 W。

6.2.4.2　假设条件

假设 6.1　对于同一类别 $y \in \mathcal{Y}$ 的样本，其对 W 的梯度贡献 $g_y^{(i)}$ 服从均值为 μ_y、方差为 $\sigma_y^2 I$ 的正态分布，即 $g_y^{(i)} \sim \mathcal{N}(\mu_y, \sigma_y^2 I)$。对于不同类别的梯度，假设其高斯分布具有相同的均值模长但方向不同，且具有相同的方差大小，即：

$$\|\mu_1\| = \|\mu_2\| = \mu, \quad \mu_1 \neq \mu_2, \quad \sigma_1^2 = \sigma_2^2 = \sigma^2, \tag{6.4}$$

其中 μ 和 σ 为正常数。

6.2.4.3　详细证明

定理 6.1 的证明　根据假设 6.1，总梯度 $\nabla_W \mathcal{L}$ 服从正态分布，其参数为：

$$\begin{aligned}&\mathbb{E}[\nabla_W \mathcal{L}] = N_1\mu_1 + N_2\mu_2, \\ &\text{Var}[\nabla_W \mathcal{L}] = N_1\sigma^2 I + N_2\sigma^2 I = (N_1 + N_2)\sigma^2 I.\end{aligned} \tag{6.5}$$

如果总梯度 $\nabla_W \mathcal{L}$ 与类别 1 的期望梯度 μ_1 之间的夹角小于其与类别 2 的期望梯度 μ_2 之间的夹角，则认为更新方向是由头部类别 $y = 1$ 主导的。该条件等价于 $\nabla_W \mathcal{L} \cdot \mu_1 > \nabla_W \mathcal{L} \cdot \mu_2$，即：

$$\nabla_W \mathcal{L} \cdot (\mu_1 - \mu_2) > 0. \tag{6.6}$$

令随机变量 $Z = \nabla_W \mathcal{L} \cdot (\mu_1 - \mu_2)$。由于 $\nabla_W \mathcal{L}$ 服从多元正态分布，因此 Z 是一个一元正态随机变量。接下来计算 Z 的均值和方差：

$$\begin{aligned}\mathbb{E}[Z] &= (N_1\mu_1 + N_2\mu_2) \cdot (\mu_1 - \mu_2) \\ &= N_1\|\mu_1\|^2 - N_1\mu_1 \cdot \mu_2 + N_2\mu_2 \cdot \mu_1 - N_2\|\mu_2\|^2 \\ &= N_1\mu^2 - N_1\mu^2 \cos\angle(\mu_1, \mu_2) + N_2\mu^2 \cos\angle(\mu_1, \mu_2) - N_2\mu^2 \\ &= (N_1 - N_2)\mu^2(1 - \cos\angle(\mu_1, \mu_2)).\end{aligned} \tag{6.7}$$

$$\begin{aligned}\mathrm{Var}(Z) &= (\mu_1-\mu_2)^\top \mathrm{Var}(\nabla_W \mathcal{L})(\mu_1-\mu_2)\\ &= (\mu_1-\mu_2)^\top \left((N_1+N_2)\sigma^2 I\right)(\mu_1-\mu_2)\\ &= (N_1+N_2)\sigma^2\|\mu_1-\mu_2\|^2\\ &= 2(N_1+N_2)\sigma^2\mu^2(1-\cos\angle(\mu_1,\mu_2)).\end{aligned} \tag{6.8}$$

由于 $Z \sim \mathcal{N}(\mathbb{E}[Z], \mathrm{Var}(Z))$，更新方向由头部类别主导的概率（即 $P(Z>0)$）为：

$$\Pi_{\mathrm{maj}} = P(Z>0) = \Phi\left(\frac{\mathbb{E}[Z]}{\sqrt{\mathrm{Var}(Z)}}\right), \tag{6.9}$$

其中 $\Phi(\cdot)$ 为标准正态累积分布函数，定义为：

$$\Phi(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\, dt. \tag{6.10}$$

将 $\mathbb{E}[Z]$ 和 $\mathrm{Var}(Z)$ 的表达式代入，可得：

$$\begin{aligned}\Pi_{\mathrm{maj}} &= \Phi\left(\frac{\mathbb{E}[Z]}{\sqrt{\mathrm{Var}(Z)}}\right)\\ &= \Phi\left(\frac{(N_1-N_2)\mu^2(1-\cos\angle(\mu_1,\mu_2))}{\sqrt{2(N_1+N_2)\sigma^2\mu^2(1-\cos\angle(\mu_1,\mu_2))}}\right)\\ &= \Phi\left(\frac{(N_1-N_2)\mu\sqrt{(1-\cos\angle(\mu_1,\mu_2))}}{\sqrt{2(N_1+N_2)}\sigma}\right)\\ &= \Phi\left(\frac{(2a-1)\mu\sqrt{2N(1-\cos\angle(\mu_1,\mu_2))}}{2\sigma}\right),\end{aligned} \tag{6.11}$$

其中 $a = \frac{N_1}{N_1+N_2}$ 为头部类别比率，$N = N_1+N_2$。证毕。 ■

6.3 算法研究

基于前文对模型容量垄断现象的分析，本研究提出通过为少数类别专门分配模型容量，并预先“保留（Reserve）”这部分容量以防止多数类别侵占，从而解决长尾扩散模型中的性能退化问题。本节将详细阐述 CM 算法的具体实现，包括容量预留机制、容量分配策略及其理论分析。

6.3.1 模型容量预留

为了给少数类别分配充足的模型容量，首先需要显式地对模型参数空间进行划分。本研究采用类似于低秩适应（LoRA）[192] 的技术来实现这一目标。尽管 LoRA 主要用于高效微调，但本研究将其低秩分解的思想应用于容量划分。

对于一个由参数集 $\theta = \{W_1, W_2, \ldots\}$ 参数化的扩散模型，其中每个 $W \in \theta$ 代表网络中的一个参数矩阵。我们将任意 $W \in \mathbb{R}^{d\times k}$ 分解为两部分：

$$W = W^g + BA = W^g + W^e, \quad \forall W \in \theta, \tag{6.12}$$

其中，$W^g \in \mathbb{R}^{d\times k}$ 表示用于保留多数类别信息和通用知识（Generalized Knowledge）的部分；$W^e = BA \in \mathbb{R}^{d\times k}$ 表示专门分配给少数类别专业知识（Minority Expertise）的部分。这里 $B \in \mathbb{R}^{d\times r}$，$A \in \mathbb{R}^{r\times k}$，且秩 $r < \min(d, k)$。

基于公式 6.12，参数集 θ 被分解为 $\theta^g = \{W_1^g, W_2^g, \ldots\}$ 和 $\theta^e = \{W_1^e, W_2^e, \ldots\}$。在推理或合并时，通过逐元素相加的方式重构参数：$\theta = \theta^g \oplus \theta^e$。图 6.3(a) 直观展示了这一容量预留机制。

作为定理 6.1 的延伸，本研究提出了定理 6.2，以从理论上证明这种基于低秩分解的容量预留机制如何影响各类别间的实际容量分配。

定理 6.2　考虑二分类场景 $\mathcal{Y} = \{1, 2\}$，且训练集高度不平衡（$N_1 \gg N_2$）。假设类别 $y = 2$（少数类）同时对 W^g 和 W^e 贡献梯度，而类别 $y = 1$（多数类）仅对 W^g 贡献梯度。在满足假设 6.1 和假设 6.2 的条件下，网络参数矩阵 $W \in \theta$ 的更新方向被多数类 $y = 1$ 主导的期望比率 Π_{maj} 满足以下上界：

$$\Pi_{\text{maj}} < \Phi\left(\frac{(1-\alpha_r)\mu\sqrt{2N(1-\cos\angle(\mu_1,\mu_2))}}{2\sigma}\right), \tag{6.13}$$

其中 α_r 是关于秩 r 的单调递增函数（当 $r = 0$ 时 $\alpha_r = 0$，当 W^e 满秩时 $\alpha_r = 1$）。

在该上界中，我们通过不等式放缩略去了类间样本比率的影响，以更清晰地展示低秩分量的作用。结果表明，通过调节 W^e 的秩 r（即调节 α_r），我们可以显著控制头部和尾部类别的容量分配，从而直接缓解标准训练中出现的容量崩塌问题。定理 6.2 的详细假设与证明见下文。

6.3.1.1　定理 6.2 的证明

为了证明定理 6.2，我们需要引入关于低秩模块更新方向的简化假设。

假设 6.2 (低秩模块的简化总体更新方向)　对于公式 6.12 中的分解 $W = W^g + W^e$，其中 W^g 是满秩可学习参数，W^e 是秩为 r 的低秩模块。我们使用以下简化模型来描述 W 的总体更新方向：

$$\Delta W = \frac{\nabla_{W^g}}{\|\mathbb{E}\nabla_{W^g}\|} + \alpha_r \frac{\nabla_{W^e}}{\|\mathbb{E}\nabla_{W^e}\|}. \tag{6.14}$$

其中，归一化项源于现代优化器（如 Adam）中常用的隐式或显式梯度归一化策略。α_r 是 r 的单调递增函数，满足边界条件：$r = 0$ 时 $\alpha_r = 0$，W^e 满秩时 $\alpha_r = 1$。α_r 提供了一个简化的低秩效应模型，反映了低秩约束对参数更新幅度的影响趋势。

定理 6.2 的证明　多数类主导更新方向的概率为：

$$\begin{aligned}\Pi_{\text{maj}} &= P(\Delta W \cdot (\mu_1 - \mu_2) > 0) \\ &= P\left(\left(\frac{\nabla_{W^g}}{\|\mathbb{E}\nabla_{W^g}\|} + \alpha_r \frac{\nabla_{W^e}}{\|\mathbb{E}\nabla_{W^e}\|}\right) \cdot (\mu_1 - \mu_2) > 0\right).\end{aligned} \tag{6.15}$$

注意到 $\nabla_{W^g} = \sum_{i=1}^{N_1} g_1^{(i)} + \sum_{j=1}^{N_2} g_2^{(j)}$。定义一个辅助变量 ∇'_{W^g}，即将 ∇_{W^g} 中对应于类别 $y = 2$ 的项全部替换为类别 $y = 1$ 的项：

$$\nabla'_{W^g} = \sum_{i=1}^{N=N_1+N_2} g_1^{(i)}. \tag{6.16}$$

这一操作进一步放大了类别 $y = 1$ 主导更新的概率。因此有：

$$\Pi_{\text{maj}} < P\left(\left(\frac{\nabla'_{W^g}}{\|\mathbb{E}\nabla'_{W^g}\|} + \alpha_r \frac{\nabla_{W^e}}{\|\mathbb{E}\nabla_{W^e}\|}\right) \cdot (\mu_1 - \mu_2) > 0\right). \tag{6.17}$$

由于 $\nabla'_{W^g} \sim \mathcal{N}(N\mu_1, N\sigma^2 I)$，我们有：

$$\begin{aligned}\mathbb{E}\left[\frac{\nabla'_{W^g}}{\|\mathbb{E}\nabla'_{W^g}\|}\right] &= \frac{N\mu_1}{\|N\mu_1\|} = \frac{\mu_1}{\mu}, \\ \text{Var}\left(\frac{\nabla'_{W^g}}{\|\mathbb{E}\nabla'_{W^g}\|}\right) &= \frac{\sigma^2}{N\mu^2} I.\end{aligned} \tag{6.18}$$

类似地，$\nabla_{W^e} \sim \mathcal{N}(N_2\mu_2, N_2\sigma^2 I)$，有：

$$\begin{aligned}\mathbb{E}\left[\frac{\nabla_{W^e}}{\|\mathbb{E}\nabla_{W^e}\|}\right] &= \frac{\mu_2}{\mu}, \\ \text{Var}\left(\frac{\nabla_{W^e}}{\|\mathbb{E}\nabla_{W^e}\|}\right) &= \frac{\sigma^2}{N_2\mu^2} I.\end{aligned} \tag{6.19}$$

令随机变量 $Z = \left(\frac{\nabla'_{W^g}}{\|\mathbb{E}\nabla'_{W^g}\|} + \alpha_r \frac{\nabla_{W^e}}{\|\mathbb{E}\nabla_{W^e}\|}\right) \cdot (\mu_1 - \mu_2)$，计算其均值和方差：

$$\begin{aligned}\mathbb{E}[Z] &= \frac{\mu_1 + \alpha_r \mu_2}{\mu} \cdot (\mu_1 - \mu_2) \\ &= \mu(1 - \alpha_r)(1 - \cos\angle(\mu_1, \mu_2)), \\ \text{Var}[Z] &= (\mu_1 - \mu_2)^\top \left(\frac{\sigma^2}{N\mu^2} I + \alpha_r^2 \frac{\sigma^2}{N_2\mu^2} I\right)(\mu_1 - \mu_2) \\ &= 2\left(\frac{1}{N} + \frac{\alpha_r^2}{N_2}\right)\sigma^2(1 - \cos\angle(\mu_1, \mu_2)).\end{aligned} \tag{6.20}$$

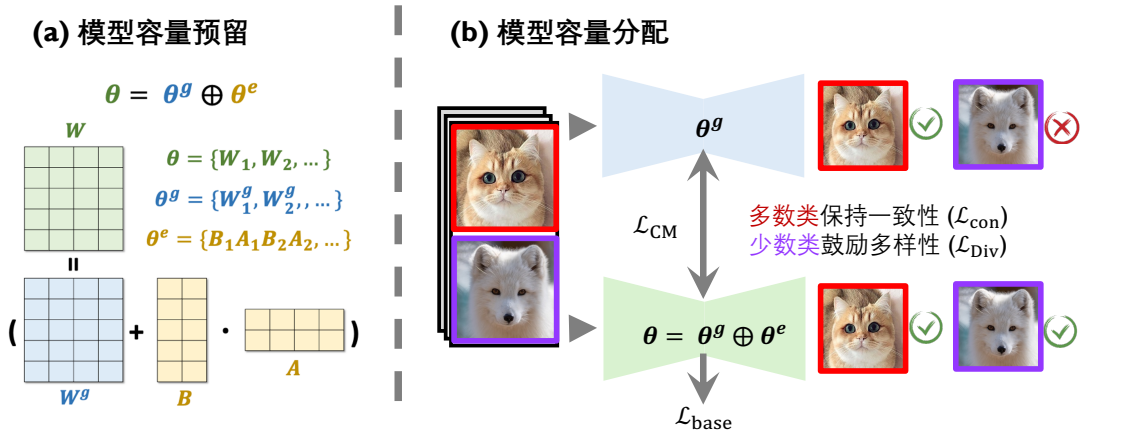


图 6.3　本研究提出的 CM 算法概览。(a) 展示了 CM 的容量预留机制，通过低秩分解将参数划分为通用部分 θ^g 和专用部分 θ^e。(b) 展示了 CM 如何在训练过程中通过容量操纵损失将相应的知识分配到预留的模型容量中。

Figure 6.3　An overview of our method, CM. (a) An illustration of the capacity reservation part of CM. (b) An illustration of how CM allocates the corresponding knowledge to the reserved model capacity during training.

由于 $Z \sim \mathcal{N}(\mathbb{E}[Z], \mathrm{Var}(Z))$，更新方向由多数类主导的概率为：

$$\begin{aligned} \Pi_{\mathrm{maj}} &< P(Z > 0) \\ &= \Phi\left(\frac{\mathbb{E}[Z]}{\sqrt{\mathrm{Var}(Z)}}\right) \\ &= \Phi\left(\frac{\mu(1-\alpha_r)(1-\cos\angle(\mu_1,\mu_2))}{\sqrt{2(\frac{1}{N}+\frac{\alpha_r^2}{N_2})\sigma^2(1-\cos\angle(\mu_1,\mu_2))}}\right) \\ &< \Phi\left(\frac{(1-\alpha_r)\mu\sqrt{2N(1-\cos\angle(\mu_1,\mu_2))}}{2\sigma}\right). \end{aligned} \tag{6.21}$$

证毕。 ■

6.3.2　模型容量分配

在完成参数分解 $\theta = \theta^g \oplus \theta^e$ 后，训练阶段的核心目标是将 θ^e 分配给少数类别的专业知识，而将 θ^g 分配给多数类别及通用知识。为了实现这一点，完整的扩散模型 $p_\theta(\boldsymbol{x}|y) = p_{\theta^g \oplus \theta^e}(\boldsymbol{x}|y)$ 应当在所有样本（无论多数还是少数）上都表现良好。同时，$p_{\theta^g}(\boldsymbol{x}|y)$ 应当仅在多数类上表现良好，而在少数类上表现较差，因为 θ^g 不应承载少数类的专业特征。

6.3.2.1　容量操纵损失

对于整体参数 $\theta = \theta^g \oplus \theta^e$，我们使用基础损失 $\mathcal{L}_{\text{base}}(\mathcal{D}, \theta)$ 在整个数据集上进行训练，覆盖所有类别。此处可以直接采用标准的扩散模型损失：

$$\mathcal{L}_{\text{base}}(\mathcal{D}, \theta) = \frac{1}{N} \sum_{\boldsymbol{x}, y \in \mathcal{D}} \mathbb{E}_{\boldsymbol{\epsilon}, t} \left[\| \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\boldsymbol{x}_t, t, y) - \boldsymbol{\epsilon} \|_2^2 \right]. \tag{6.22}$$

当然，也可以选择针对不平衡数据集设计的改进损失函数（如 CBDM[48] 或 OC[122]）作为 $\mathcal{L}_{\text{base}}$。

针对分离出的 θ^g 和 θ^e，本研究提出了一种**容量操纵损失（Capacity Manipulation Loss）**，以引导 θ^e 学习少数类知识，而 θ^g 学习通用知识：

$$\begin{aligned}
\mathcal{L}_{\text{CM}}(\boldsymbol{x}, y, \theta^g, \theta^e) &= \mathcal{L}_{\text{Con}}(\boldsymbol{x}, y, \theta^g, \theta^e) + \mathcal{L}_{\text{Div}}(\boldsymbol{x}, y, \theta^g, \theta^e), \\
\mathcal{L}_{\text{Con}}(\boldsymbol{x}, y, \theta^g, \theta^e) &= \omega_{\text{Con}}^y \mathbb{E}_t \| \boldsymbol{\epsilon}_{\theta^g \oplus \theta^e}(\boldsymbol{x}_t, t, y) - \boldsymbol{\epsilon}_{\theta^g}(\boldsymbol{x}_t, t, y) \|_2^2, \\
\mathcal{L}_{\text{Div}}(\boldsymbol{x}, y, \theta^g, \theta^e) &= -\omega_{\text{Div}}^y \mathbb{E}_t \| \boldsymbol{\epsilon}_{\theta^g \oplus \theta^e}(\boldsymbol{x}_t, t, y) - \boldsymbol{\epsilon}_{\theta^g}(\boldsymbol{x}_t, t, y) \|_2^2.
\end{aligned} \tag{6.23}$$

该损失由一致性损失 $\mathcal{L}_{\text{Con}}$ 和多样性损失 $\mathcal{L}_{\text{Div}}$ 组成。通过为不同类别设定不同的一致性权重 ω_{Con} 和多样性权重 ω_{Div}，我们可以控制容量分配的方向。

对于样本数 N_y 较大的多数类，我们赋予较大的 ω_{Con}^y，从而强制 $\boldsymbol{\epsilon}_{\theta^g \oplus \theta^e}$ 与 $\boldsymbol{\epsilon}_{\theta^g}$ 的输出保持一致。这意味着多数类的知识主要由 θ^g 承载。相反，对于样本数 N_y 较小的少数类，我们赋予较大的 ω_{Div}^y，从而鼓励 $\boldsymbol{\epsilon}_{\theta^g \oplus \theta^e}$ 与 $\boldsymbol{\epsilon}_{\theta^g}$ 的输出产生差异。这意味着 θ^g 无法很好地预测少数类，迫使模型利用 θ^e 来弥补这一差距，从而将少数类知识“挤压”进 θ^e。

具体的权重设计如下：

$$\omega_{\text{Con}}^y = \frac{C N_y}{\sum_{c=1}^{C} N_c}, \quad \omega_{\text{Div}}^y = \frac{C}{N_y \sum_{c=1}^{C} \frac{1}{N_c}}. \tag{6.24}$$

其中，ω_{Con} 与类样本数线性正相关，而 ω_{Div} 与类样本数成反比。对于平衡数据集，$\omega_{\text{Con}} = \omega_{\text{Div}} = 1$，此时 $\mathcal{L}_{\text{CM}} = 0$。这种设计使得权重能够自适应地平滑过渡，避免了人工硬性划分多数类和少数类。

注：虽然公式 *6.24* 在形式上类似于判别式模型[41]或生成式模型[123]中的重加权技术，但其机制和目的存在本质区别。传统方法通过加权样本损失来调整类别重要性，而本研究的权重用于调节不同网络参数（θ 与 θ^g）输出之间的距离，旨在实现模型容量的物理分配。

6.3.2.2　联合优化与推理

在训练过程中，我们联合优化基础损失 $\mathcal{L}_{\text{base}}$ 和容量操纵损失 $\mathcal{L}_{\text{CM}}$。总目标函数如下：

$$\min_{\theta} \mathcal{L}_{\text{Total}}(\mathcal{D}, \theta) = \mathcal{L}_{\text{base}}(\mathcal{D}, \theta) + \lambda \sum_{(\boldsymbol{x}, y) \in \mathcal{D}} \frac{1}{N} \mathcal{L}_{\text{CM}}(\boldsymbol{x}, y, \theta^g, \theta^e), \tag{6.25}$$

其中 λ 为平衡系数。$\mathcal{L}_{\text{base}}$ 负责优化整体性能，而 $\mathcal{L}_{\text{CM}}$ 作为正则项引导 θ 形成更均衡、有效的参数分布。训练过程如图 6.3(b) 所示。

在**推理阶段**，我们可以显式地计算并存储合并后的参数 $\theta = \theta^g \oplus \theta^e$，然后直接从 $p_\theta(\boldsymbol{x}|y)$ 中采样图像。得益于低秩分解和参数合并的特性，本方法**没有增加模型容量**，因此与标准模型相比**没有任何额外的推理延迟**。这对于扩散模型在实际场景中的部署至关重要。

我们在算法 算法 6.1 中总结了所提出方法 CM 的整体流程。具体而言，训练阶段以 DDPM 作为基础损失函数，并采用样本级（sample-wise）的方式进行说明；在推断阶段，同样以 DDPM 的采样过程为例进行展示。

6.3.3　讨论与分析

与现有不平衡扩散模型的对比。与 CBDM 和 OC 等专注于改进目标函数的方法不同，CM 从模型容量分配的新视角提升了扩散模型的鲁棒性。CM 与现有方法是正交的，可以与改进的目标函数结合使用，以获得进一步的性能提升。

与 LoRA 及 MoE 风格适配器的对比。虽然 CM 在结构上利用了类似于 LoRA 的低秩组件，但二者的目标截然不同：LoRA 旨在实现预训练模型的高效微调，而 CM 旨在训练前进行容量预留。表 6.1 对比了两种基于低秩组件的 CBDM 变体：(1) 使用 CM 分解但保持原始 CBDM 目标的变体；(2) 使用 LoRA 增量微调 CBDM 的变体。结果显示，这两种变体均未带来性能提升，而 CM 显著优于所有基线。这表明 CM 的收益并非源于低秩分解的形式或可训练参数的增加，而是源于容量操纵和重平衡的整体设计。此外，为了区分 CM 与混合专家（MoE）范式，我们实现了一个“分组专家 LoRA（Group-Expert LoRA）”基线（详见附录），该基线为头部、中部和尾部类别组分配不同的 LoRA 适配器。实验表明 CM（FID 7.519）显著优于该 MoE 风格基线（FID 10.06），证实了 CM 的优势源于显式的容量操纵，而非简单的参数增加或动态路由。

扩展至 LoRA 微调场景。本研究提出的 CM 方法可以无缝扩展至 LoRA 微调场景。具体而言，可将公式 6.12 修改为：$W = W^f + B^g A^g + B^e A^e$。其中，$W^f$ 为冻结的

算法 6.1 CM 算法流程

Input: 训练数据集 $\mathcal{D}$；总时间步 T；损失权重 λ；基础模型参数 θ^g 与扩展参数 θ^e 的结构定义

Output: 生成样本 $\mathbf{x}_0$

/* 训练阶段（以 DDPM 为基准，逐样本）*/

初始化：参数 $\theta^g = \{W_1^g, W_2^g, \ldots\}$，$\theta^e = \{B_1^e A_1^e, B_2^e A_2^e, \ldots\}$;

repeat

  从 $\mathcal{D}$ 中采样数据 $(\mathbf{x}, y)$;

  采样时间步 $t \sim \text{Uniform}(\{1, \ldots, T\})$;

  采样噪声 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$;

  计算基础损失：

  $\mathcal{L}_{\text{base}} = \|\boldsymbol{\epsilon}_{\theta^g \oplus \theta^e}(\sqrt{\bar{\alpha}_t}\mathbf{x} + (1-\bar{\alpha}_t)\boldsymbol{\epsilon}, t, y) - \boldsymbol{\epsilon}\|_2^2$;

  计算容量分配损失（Capacity allocation loss）：

  $\mathcal{L}_{\text{CM}} = (\omega_{\text{Con}}^y - \omega_{\text{Div}}^y)\|\boldsymbol{\epsilon}_{\theta^g \oplus \theta^e}(\mathbf{x}_t, t, y) - \boldsymbol{\epsilon}_{\theta^g}(\mathbf{x}_t, t, y)\|_2^2$;

  对 $\nabla_{\theta^g, \theta^e}(\mathcal{L}_{\text{base}} + \lambda \mathcal{L}_{\text{CM}})$ 执行梯度下降;

until 收敛 *(converged)*;

/* 采样阶段（以 DDPM 为例，逐样本）*/

合并模型参数 $\theta = \theta^g \oplus \theta^e$;

采样 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$;

for $t = T, \ldots, 1$ **do**

  if $t > 1$ **then**

    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$;

  else

    $\mathbf{z} = \mathbf{0}$;

  $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}}(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t, y)) + \sigma_t \mathbf{z}$;

return $\mathbf{x}_0$;

预训练模型参数，$\{B^g, A^g\}$ 为分配给多数类及通用知识的可训练参数，$\{B^e, A^e\}$ 为预留给少数类专业知识的可训练参数。这种扩展保留了 LoRA 的结构优势，同时通过容量操纵增强了微调过程中的平衡性。

6.4 实验验证

为了全面评估所提出的 CM 算法在解决扩散模型长尾生成问题上的有效性，本章进行了广泛的定量和定性实验。本节首先详细介绍实验的具体设置，包括数据集构建、对比基线、评价指标以及实现细节。

表 6.1　FID (↓) 指标对比：CM 与基线及低秩变体的性能。CBDM ($\theta = \theta^g \oplus \theta^e$) 表示使用 CM 分解但未应用容量操纵损失的变体；CBDM (LoRA) 表示使用 LoRA 进行微调的变体。

Table 6.1　FID (↓) comparison with baselines and low-rank variants.

数据集	DDPM	CBDM	CBDM ($\theta = \theta^g \oplus \theta^e$)	CBDM (LoRA)	CM
CIFAR-100, IR = 100	10.163	10.051	10.231	11.424	**7.519**
CIFAR-10, IR = 100	10.697	8.233	8.316	9.725	**7.727**

6.4.1　实验设置

6.4.1.1　数据集

本研究在图像合成领域常用的六个数据集的长尾版本上进行了实验，包括：CIFAR-10[160]、CIFAR-100[160]、CelebA-HQ[195]、ImageNet-LT[27]、iNaturalist[39] 以及 ArtBench-10[196]。关于图像分辨率的设置：CIFAR-10 和 CIFAR-100 使用 32×32 分辨率；CelebA-HQ 使用 64×64 版本；ImageNet-LT 和 iNaturalist 分别使用了 32×32 和 64×64 版本；ArtBench-10 则保持其原始分辨率 256×256。

为了构建长尾数据集，本研究遵循文献[84] 的方法，通过对原始数据集进行降采样（Downsampling），使得各类别样本数量随类别索引呈指数级递减。我们将这些不平衡数据集统称为 Imb. dataset（例如 Imb. CIFAR-10）。数据集的不平衡程度由不平衡比率（Imbalance Ratio, IR）控制，定义为样本数最多的类别与最少的类别的比值，即 $\mathrm{IR} = \frac{\max_{c \in \mathcal{Y}} N_c}{\min_{c \in \mathcal{Y}} N_c}$。在实验中，我们设置 $\mathrm{IR} \in \{50, 100\}$ 以模拟不同程度的长尾分布。

为了进行细粒度分析，本研究根据各类别样本数量的降序排列，将数据集划分为三个部分：

- 对于 Imb. CIFAR-10 和 Imb. ArtBench-10：**头部（Many）**（类别 0-2）、**中部（Medium）**（类别 3-5）和**尾部（Few）**（类别 6-9）。
- 对于 Imb. CIFAR-100：**头部（Many）**（类别 0-32）、**中部（Medium）**（类别 33-65）和**尾部（Few）**（类别 66-99）。

这种均匀的三分法遵循了文献[197] 的标准。

6.4.1.2　对比基线

本研究将 CM 与三类基线方法进行了对比：

1. **基础模型：**标准的去噪扩散概率模型（DDPM）。
2. **针对不平衡扩散模型的方法：**包括类别平衡扩散模型（CBDM）[48] 和定向校准（OC）[122]。

3. **迁移自判别模型或 GAN 的不平衡学习方法：**包括重采样（Re-sampling, RS）[198]、自适应判别器增强（ADA）[199] 以及 Focal Loss[79]。

需要指出的是，许多针对判别模型或生成对抗网络（GAN）的不平衡学习方法[42,119,150]严重依赖于特定的模型架构或训练范式，因此无法直接兼容或迁移到扩散模型中。

6.4.1.3　评价指标

为了全面评估生成图像的质量和多样性，本研究采用了以下四个主流评价指标：Frechet Inception Distance (FID)[200]、Kernel Inception Distance (KID)[201]、Recall[202] 以及 Inception Score (IS)[203]。所有指标均基于在 ImageNet 上预训练的 Inception-V3[204] 模型提取的特征进行计算①。

在评估过程中，对于整体性能，指标是基于类别平衡的真实图像集与 50,000 张生成图像计算得出的。对于细粒度的 $\{Many, Medium, Few\}$ 划分性能，指标则是基于相应划分下的真实图像与 20,000 张生成图像计算得出。鉴于 FID 等指标对实现细节（如样本数量、图像预处理、输入归一化及特征维度等）具有**高度敏感性**，为了消除差异并确保公平对比，本研究在统一的评估流程下对所有方法进行了基准测试。特别需要强调的是，本研究中的模型是在极具挑战性的**不平衡数据集**上训练的，这通常会导致比在平衡数据集上训练的模型更高的 FID 基线值。因此，我们的分析重点在于相比于基线方法在这些困难场景下的相对性能提升，而非追求绝对的 FID 数值。

6.4.1.4　实现细节

在网络架构方面，遵循文献[19] 的设定，本研究使用基于 Wide ResNet[205] 的 U-Net[9] 作为噪声预测网络。DDPM 的超参数设置为 $\beta_1 = 10^{-4}$，$\beta_T = 0.02$，最大时间步 $T = 1000$。训练过程中使用 Adam 优化器[206]，参数 betas $= (0.9, 0.999)$，学习率为 2×10^{-4}。Dropout 率设置为 0.1。批次大小（Batch Size）设为 64，总训练步数为 300,000 步，其中包含 5,000 步的热身（Warm-up）阶段。

对于本研究提出的 CM 方法，公式 6.12 中低秩矩阵 BA 的秩 r 固定设为 $\frac{1}{10}\min(d, k)$。考虑到 U-Net 的浅层通常倾向于捕获更通用的知识[207]，我们仅对 U-Net 的上采样部分（即模型的后半部分）应用低秩分解。公式 6.25 中的平衡超参数 λ 固定为 $\lambda = 1$。除非另有说明，公式 6.25 中的基础损失采用文献[122] 中的目标函数。在推理阶段，使用 50 步的 DDIM 采样器[208] 生成新图像。

① 使用的权重文件下载链接：https://github.com/toshas/torch-fidelity/releases/download/v0.2.0/weights-inception-2015-12-05-6726825d.pth

6.4.2　实验结果与分析

本小节将在构建的多个长尾基准数据集上，从定量指标和定性可视化两个维度，对 CM 算法的性能进行全面评估。实验涵盖了从基础生成任务到大规模数据集生成，再到基于预训练模型微调的多种场景。

6.4.2.1　Imb. CIFAR-10 和 Imb. CIFAR-100 上的总体性能

表 6.3 汇总了 CM 方法与所有基线方法在 Imb. CIFAR-10 和 Imb. CIFAR-100 数据集（不平衡比率 IR $\in \{50, 100\}$）上的 FID、KID、Recall 和 IS 指标。实验结果显示，CM 在这就四个设定下的 16 项指标中，有 14 项取得了最佳结果，仅在两项 IS 指标上略低于基线。需要指出的是，IS 指标无法有效检测模式崩塌（Mode Collapse）现象[209]。例如，如果生成的少数类样本被多数类特征所淹没（即生成了高质量但错误的类别图像），这种低质量的生成并不会导致 IS 下降，这解释了为何原始 DDPM 在部分 IS 指标上仍表现尚可。此外，IS 由于缺乏真实图像作为参考，通常被认为是一个可靠性较低的指标[210-211]。

在最广泛使用的评价指标 FID 上，CM 展现出了显著的优势。具体而言，相比于基础 DDPM 模型，CM 在四种设定下的 FID 分别提升了 2.725、2.844、2.644 和 2.571；相比于各设定下的最佳基线方法（通常是 OC 或 CBDM），CM 也分别实现了 0.506、0.561、0.790 和 0.456 的进一步提升。此外，本研究在表 6.2 中提供了与同期工作 Overlap Optimization[121] 的直接对比，结果表明 CM 同样保持了性能优势。

表 6.2　在不平衡比率 IR = 100 的 Imb. CIFAR-100 数据集上，CM 算法与 Overlap Optimization 方法的对比结果。

Table 6.2　Comparison with Overlap Optimization on Imb. CIFAR-100 (IR = 100)**.**

算法名称	FID ↓	Recall ↑
DDPM	10.16	0.46
Overlap Opt.[121]	8.98	0.48
CM (Ours)	**7.52**	**0.52**

6.4.2.2　细粒度性能分析

为了探究模型对不同频次类别的生成能力，表 6.4 展示了在 Imb. CIFAR-10 和 Imb. CIFAR-100 (IR = 100) 上，各方法在 Many（头部）、Medium（中部）和 Few（尾部）三个划分下的 FID 指标。CM 方法在所有三个划分中均取得了最佳结果，且主要的性能提升集中在 Medium 和 Few 类别上，这证明了容量分配策略在保护少数类方

表 6.3　CM 算法与基线算法在 Imb. CIFAR-10 和 Imb. CIFAR-100 上的 FID (↓)、KID (↓)、Recall (↑) 和 IS (↑) 指标对比。不平衡比率 IR = {100, 50} 的结果并列展示。粗体表示最优结果，下划线表示次优结果。

Table 6.3　FIDs (↓), KIDs (↓), Recalls (↑), and ISs (↑) of CM and various baseline methods on Imb. CIFAR-10 and Imb. CIFAR-100. Results for imbalance ratios IR = {100, 50} are shown side-by-side. Best and second-best results are highlighted.

Imb. CIFAR-10	**IR = 100**				**IR = 50**			
算法名称	FID ↓	KID ↓	Recall ↑	IS ↑	FID ↓	KID ↓	Rec ↑	IS ↑
DDPM[19]	10.697	0.0035	0.47	9.39	10.216	0.0035	0.47	9.37
+ADA[199]	9.266	0.0029	0.49	9.26	9.132	0.0030	0.51	9.28
+RS[198]	12.332	0.0037	0.45	9.25	11.231	0.0038	0.47	9.31
+Focal[79]	10.842	0.0034	0.46	9.42	10.315	0.0034	0.48	9.38
CBDM[48]	8.233	0.0026	**0.53**	9.23	7.933	0.0026	**0.54**	9.42
OC[122]	8.390	0.0027	0.52	**9.53**	8.034	0.0027	0.53	9.65
CM	**7.727**	**0.0023**	**0.53**	9.52	**7.372**	**0.0024**	**0.54**	**9.69**
Imb. CIFAR-100	**IR = 100**				**IR = 50**			
算法名称	FID ↓	KID ↓	Recall ↑	IS ↑	FID ↓	KID ↓	Rec ↑	IS ↑
DDPM[19]	10.163	0.0029	0.46	**13.45**	9.363	0.0032	0.47	**14.27**
+ADA[199]	9.482	0.0032	0.51	12.44	8.927	0.0033	0.51	12.89
+RS[198]	11.432	0.0038	0.44	12.12	10.259	0.0037	0.47	12.38
+Focal[79]	10.212	0.0032	0.47	13.07	9.477	0.0034	0.49	13.31
CBDM[48]	10.051	0.0036	0.51	12.35	8.946	0.0036	**0.55**	12.59
OC[122]	8.309	0.0026	**0.52**	13.44	7.188	0.0024	0.54	13.99
CM	**7.519**	**0.0017**	**0.52**	**13.45**	**6.732**	**0.0021**	**0.55**	14.12

面的有效性。值得注意的是，在 Imb. CIFAR-10 数据集上，Medium 类别的生成质量反而劣于 Few 类别。这一反直觉的现象在不平衡对比学习的研究中也曾被观察到[150]，其原因可能归结于类别间固有的学习难度差异（Inherent Difficulty）。这暗示了未来的研究方向可以将固有的难度不平衡与数量不平衡结合考虑，以进一步优化扩散模型的性能。

6.4.2.3　Imb. CelebA-HQ 上的性能表现

表 6.5 展示了 Imb. CelebA-HQ 数据集（IR = {100, 50}）上的 FID、KID 以及分性别 FID 指标。该数据集包含“女性（Female）”和“男性（Male）”两个类别，其中女性为多数类。实验结果表明，CM 在两个不同不平衡比率下的所有八项指标中均取得了最佳性能。具体而言，与 DDPM 相比，CM 将整体 FID 分别降低了 1.189 和 0.814；与最佳基线相比，分别降低了 0.285 和 0.230。更重要的是，在少数类（男性）的生成质量上，CM 展现了巨大的提升幅度：相比 DDPM 提升了 3.637 和 3.535，相比最佳

表 6.4　CM 算法与基线算法在 Imb. CIFAR-10 (IR = 100) 和 Imb. CIFAR-100 (IR = 100) 上的细粒度 FID (↓) 性能分析。Many/Medium/Few 分别对应头部、中部和尾部类别划分。

Table 6.4　Per-split FIDs (↓) of CM and baselines on Imb. CIFAR-10 (IR = 100) and Imb. CIFAR-100 (IR = 100) shown. Many, Medium, and Few are the three splits based on training imbalancedness.

	Imb. CIFAR-10 (IR = 100)				**Imb. CIFAR-100** (IR = 100)			
算法名称	Many FID ↓	Med. FID ↓	Few FID ↓	Overall FID ↓	Many FID ↓	Med. FID ↓	Few FID ↓	Overall FID ↓
DDPM[19]	14.203	19.714	15.869	10.697	14.068	15.660	22.188	10.163
CBDM[48]	12.222	14.465	12.230	8.2334	12.585	14.042	20.667	10.051
OC[122]	12.026	15.234	12.254	8.3896	11.731	13.133	21.053	8.309
CM	**11.705**	**14.340**	**11.218**	**7.7273**	**11.713**	**13.043**	**18.729**	**7.519**

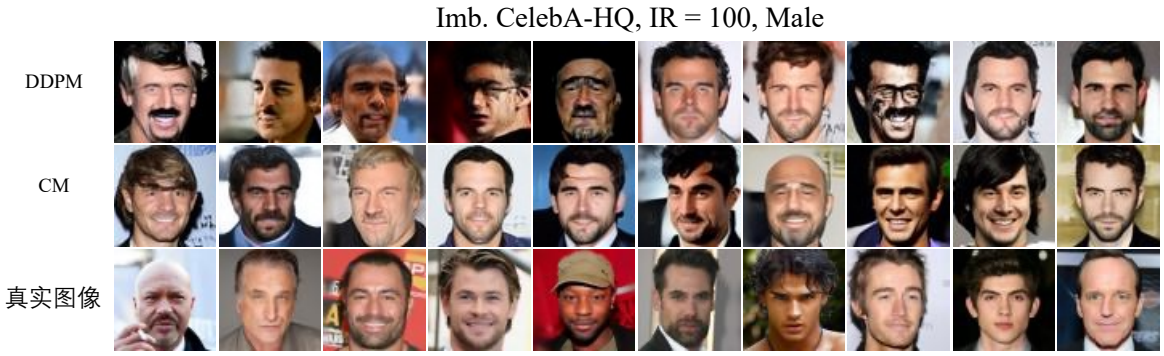


图 6.4　CM 算法与 DDPM 在 Imb. CelebA-HQ 数据集在不平衡比率 IR = 100 条件下的生成结果可视化。图中展示了少数类 “Male” 在 DDPM 与 CM 两种方法下的生成样本，最后一行为数据集中的真实图像作为参考。可以观察到，CM 生成的人脸在真实性与多样性方面均优于 DDPM。

Figure 6.4　Visualization of generated images on Imb. CelebA-HQ with an imbalance ratio of IR = 100. The figure shows generated samples of the minority class “Male” produced by DDPM and CM, with real images from the dataset shown in the last row for reference. It can be observed that CM generates faces with higher realism and greater diversity.

表 6.5　CM 算法与基线算法在 Imb. CelebA-HQ 上的 FID (↓)、KID (↓) 及分性别 FID (↓) 对比。Female 为多数类，Male 为少数类。

Table 6.5　FIDs (↓), KIDs (↓), and per-class FIDs (↓) of CM and baselines on Imb. CelebA-HQ with imbalance ratios IR = {100, 50} shown side-by-side.

Imb. CelebA-HQ	**IR = 100**				**IR = 50**			
算法名称	Female FID ↓	Male FID ↓	Overall FID ↓	KID ↓	Female FID ↓	Male FID ↓	Overall FID ↓	KID ↓
DDPM[19]	7.143	16.425	8.727	0.0037	7.348	14.808	8.007	0.0034
CBDM[48]	7.043	14.273	7.823	0.0043	7.317	12.592	7.423	0.0042
OC[122]	7.092	13.962	7.871	0.0034	7.283	12.938	7.438	0.0034
CM	**6.815**	**12.788**	**7.538**	**0.0033**	**7.147**	**11.273**	**7.193**	**0.0033**

基线提升了 1.174 和 1.319。图 6.4 的可视化结果进一步证实了这一点，CM 生成的少数类男性面部图像在真实感和多样性上均优于对比方法。

表 6.6　CM 算法与基线算法在 ImageNet-LT 和 iNaturalist 数据集，32×32 和 64×64 分辨率下的 FID (↓) 和 KID (↓) 指标对比。
Table 6.6　FIDs (↓) and KIDs (↓) on ImageNet-LT and iNaturalist at 32×32 and 64×64 resolutions.

	ImageNet-LT 32×32		ImageNet-LT 64×64		iNaturalist 32×32		iNaturalist 64×64	
算法名称	FID ↓	KID ↓	FID ↓	KID ↓	FID ↓	KID ↓	FID ↓	KID ↓
DDPM[19]	13.42	0.0082	8.84	0.0028	15.66	0.0095	7.99	0.0030
CBDM[48]	14.66	0.0096	11.71	0.0068	18.01	0.0136	10.28	0.0044
OC[122]	12.61	0.0075	8.43	0.0025	14.29	0.0092	7.67	0.0023
CM	**10.94**	**0.0056**	**7.72**	**0.0023**	**13.38**	**0.0089**	**6.82**	**0.0020**

6.4.2.4　大规模多类别数据集上的性能表现

为了验证 CM 算法在大规模、多类别场景下的可扩展性，本研究在 ImageNet-LT（1,000 类，IR = 256）和 iNaturalist（8,142 类，IR = 500）两个数据集上进行了实验，结果如表 6.6 所示。这些数据集不仅类别数量庞大，而且不平衡程度极高（远超 100:1）。实验结果显示，基线方法 CBDM 在处理数千个类别时出现了性能退化，甚至逊色于基础的 DDPM，暴露出其在大规模场景下的局限性。相比之下，本研究提出的 CM 方法在所有设定下均保持了显著且一致的性能优势，证明了其在处理极端不平衡和大规模类别时的鲁棒性。

6.4.2.5　Imb. ArtBench-10 上微调 Stable Diffusion 的性能

为了验证 CM 在大模型微调场景下的有效性，本研究在 Imb. ArtBench-10 数据集上，使用 LoRA 技术对 Stable Diffusion 模型进行了微调。实验中，通用参数部分 W^g（对应 LoRA）的秩设为 128，而预留给少数类的 W^e 的秩设为 8。训练采用简单的类条件文本提示（如 “a {class} painting”）。表 6.7 汇总了 CM 与 DDPM 以及两个最强基线（CBDM 和 OC）在 IR = $\{100, 50\}$ 下的对比结果。CM 在所有八项指标上均取得了最佳成绩。图 6.5 展示了少数类 “Realism” 的生成样本。可以看出，CM 生成的图像在多样性和风格真实度上均优于对比方法。此外，表 6.7 中更高的 Recall 分数也从定量角度证实了 CM 在提升尾部类别生成多样性方面的显著优势。

6.4.3　进一步分析

为了全面评估 CM 算法的性能、鲁棒性及通用性，本小节进行了多维度的深入分析。分析内容涵盖人类感知评估、下游任务效用评估、算法作为通用框架的兼容性、内部机制探究、超参数敏感性分析以及在更广泛模型架构和任务上的扩展性验证。

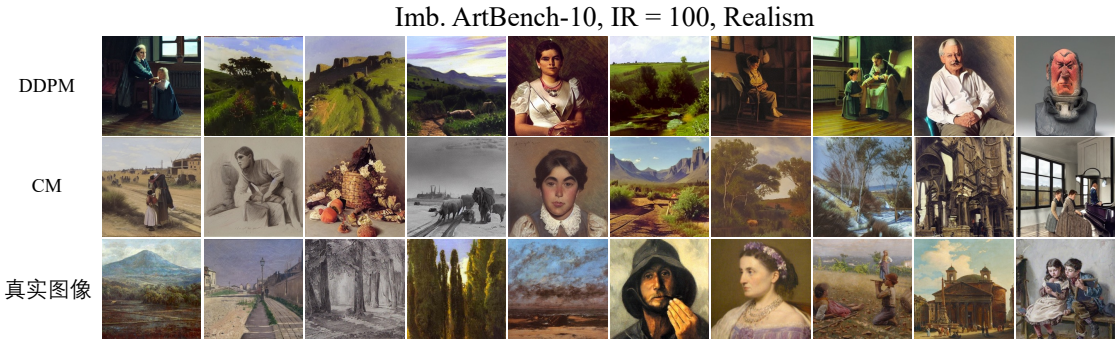


图 6.5　CM 算法与基线算法在 Imb. ArtBench-10 数据集在不平衡比率 IR = 100 条件下少数类 “Realism” 的生成结果可视化。图中展示了 DDPM 与 CM 在该类别上的生成样本，最后一行为数据集中的真实图像作为参考。可以看出，相较于 DDPM，CM 生成的结果在多样性上显著提升，且在整体风格上更接近真实图像。所有展示的图像均为随机选取。

Figure 6.5　Visualization of generated images for the minority class “Realism” on Imb. ArtBench-10 with an imbalance ratio of IR = 100. The figure compares samples generated by DDPM and CM, with real images from the dataset shown in the last row for reference. Compared to DDPM, CM produces results that are significantly more diverse and stylistically closer to real images. All images are randomly selected.

表 6.7　CM 算法与基线算法基于 LoRA 微调 Stable Diffusion 模型在 Imb. ArtBench-10 上的 FID (↓)、KID (↓)、Recall (↑) 和 IS (↑) 对比。

Table 6.7　FIDs (↓), KIDs (↓), Recalls (↑), and ISs (↑) of CM and various baselines on Imb. ArtBench-10 with IR = {100, 50} shown, using LoRA to fine-tune Stable Diffusion.

Imb. ArtBench-10	**IR = 100**				**IR = 50**			
算法名称	FID ↓	KID ↓	Recall ↑	IS ↑	FID ↓	KID ↓	Recall ↑	IS ↑
DDPM[19]	27.083	0.0142	0.39	8.47	25.557	0.0134	0.39	8.41
CBDM[48]	25.723	0.0122	0.43	7.97	24.487	0.0114	0.43	8.03
OC[122]	24.315	0.0106	0.42	**8.71**	23.287	0.0097	0.43	8.48
CM	**22.776**	**0.0087**	**0.44**	**8.71**	**21.733**	**0.0080**	**0.44**	**8.51**

6.4.3.1　人类感知与下游效用评估

除了自动评价指标外，本研究还进行了人类感知评估和下游任务效用评估，以验证生成图像的实际质量。

人类感知评估：本研究在 Imb. ArtBench-10 (IR=100) 数据集的少数类别上开展了用户偏好研究。共有 8 名评估者参与，每人评估 20 至 36 组图像。每组包含 10 张标明的真实图像作为参考，以及 2 张分别由基线（DDPM）和 CM 生成的图像（随机顺序呈现）。评估者需选择在真实感和风格一致性上表现更好的生成图像。表 6.8 的结果显示，CM 生成的图像在 70.56% 的测试中被评选为更优，表明其在视觉感知质量上具有显著优势。

表 6.8　CM 算法与基线算法在 Imb. ArtBench-10 (IR=100) 少数类上的人类感知评估结果。8 名评估者对比了基线 (DDPM) 和 CM 生成的图像。数值表示各方法被选为更优的次数。
Table 6.8　User study results on minority classes of Imb. ArtBench-10 (IR=100). Eight evaluators compared generated images from the baseline (DDPM) and our method CM. Numbers indicate the count of trials where each method was preferred.

算法名称	评估者 1	评估者 2	评估者 3	评估者 4	评估者 5	评估者 6	评估者 7	评估者 8	Overall
DDPM	10	10	4	4	6	3	14	12	**63**
CM	24	26	16	19	18	17	15	16	**151**

表 6.9　CM 算法与基线算法在 Imb. CIFAR-100 (IR=100) 上使用 ResNet-18 的下游分类性能。使用 CM 生成图像进行增强的效果显著优于基线 (DDPM) 和无增强设置。
Table 6.9　Downstream classification performance on Imb. CIFAR-100 (IR=100) using ResNet-18. Augmentation with images generated by CM leads to clear improvements over both the baseline (DDPM) and the no-augmentation setting.

算法名称	Precision	Recall
No augmentation	43.25	37.25
w/ DDPM 50k images	46.73	42.34
w/ CM 50k images	**49.23**	**46.78**

下游效用评估：为了评估生成样本的实用价值，本研究利用 Imb. CIFAR-100 (IR=100) 数据集进行了下游分类任务的数据增强实验。具体而言，我们在三种设置下训练 ResNet-18 分类器：(i) 仅使用原始不平衡数据，(ii) 使用原始数据 + DDPM 生成的 50k 张图像，(iii) 使用原始数据 + CM 生成的 50k 张图像。如表 6.9 所示，使用 CM 生成图像进行增强的分类器性能显著优于无增强及 DDPM 增强的基线，证明了 CM 生成的少数类样本具有更高的质量和多样性，能够有效辅助下游任务。

6.4.3.2　作为通用框架的验证与机制探究

CM 作为通用框架的兼容性：图 6.6a 总结了 CM 与不同基线方法（即在公式 6.25 中使用不同的 $\mathcal{L}_{\text{base}}$）集成后的性能。无论基础模型采用何种目标函数，CM 均能一致地提升其在 Imb. CIFAR-100 (IR=100) 上的生成性能。得益于 CM 与现有方法的正交性，它能够持续从目标函数的改进（包括未来潜在的进展）中获益。

θ^g 与 θ^e 之间的知识分配：为了探究 CM 对知识分配的实际影响，本研究对比了仅使用 θ^g（记为 CM (θ^g)）与使用完整参数 $\theta = \theta^g \oplus \theta^e$（即 CM）的性能。如表 6.10 所示，在 Imb. CIFAR-100 (IR=100) 上，CM (θ^g) 在 Many 和 Medium 类别上表现尚可，但在 Few 类别上性能严重下降（FID 高达 29.357）。相比之下，完整 CM 在所有划分上均保持了强劲性能。这有力地证明了 CM 成功地将少数类专业知识分配给了 θ^e，同

表 6.10　在不平衡比率 IR = 100 的 Imb. CIFAR-100 数据集上，DDPM、CM（θ^g）以及 CM 的分子集 FID 与整体 FID（↓，Mean ± Std）。Many、Medium 和 Few 分别表示根据训练数据不平衡程度划分的三类子集。加粗结果表示最优性能。

Table 6.10　Per-split and overall FIDs (↓, Mean ± Std) of DDPM, CM (θ^g), and CM on Imb. CIFAR-100 with imbalance ratio IR = 100. Many, Medium, and Few denote the three splits based on the training imbalance. Best results are highlighted.

数据集	算法名称	Many FID ↓	Med. FID ↓	Few FID ↓	Overall FID ↓
Imb. CIFAR-100 IR = 100	DDPM[19]	14.068 ± 0.193	15.660 ± 0.047	22.188 ± 0.241	10.163 ± 0.077
	CM (θ^g)	11.923 ± 0.139	14.872 ± 0.157	29.357 ± 0.318	13.712 ± 0.240
	CM ($\theta = \theta^g \oplus \theta^e$)	**11.713 ± 0.247**	**13.043 ± 0.138**	**18.729 ± 0.141**	**7.519 ± 0.132**

表 6.11　在不平衡比率 IR = 100 的 Imb. CIFAR-100 数据集上，不同方法的 FID（↓）、KID（↓）、Recall（↑）和 IS（↑）指标对比。最后两行分别给出了去除 $\mathcal{L}_{\text{Con}}$ 和 $\mathcal{L}_{\text{Div}}$ 后 CM 的实验结果。加粗和下划线结果分别表示最优和次优性能。

Table 6.11　FIDs (↓), KIDs (↓), Recalls (↑), and ISs (↑) on Imb. CIFAR-100 with imbalance ratio IR = 100. The last two rows report the results of CM after removing $\mathcal{L}_{\text{Con}}$ and $\mathcal{L}_{\text{Div}}$, respectively. Best and second-best results are highlighted.

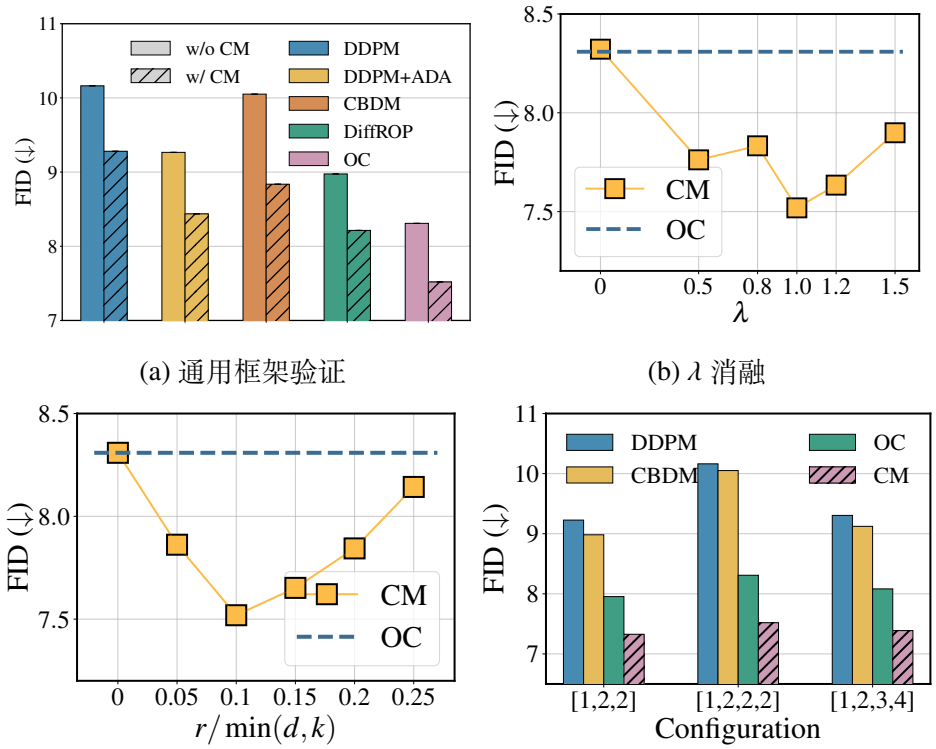
数据集	算法名称	FID ↓	KID ↓	Recall ↑	IS ↑
Imb. CIFAR-100 IR = 100	DDPM[19]	10.163 ± 0.077	0.0029 ± 0.0005	0.46 ± 0.01	**13.45 ± 0.15**
	OC[122]	8.309 ± 0.233	0.0026 ± 0.0002	**0.52 ± 0.02**	13.44 ± 0.20
	CM	**7.519 ± 0.132**	**0.0017 ± 0.0003**	**0.52 ± 0.02**	**13.45 ± 0.23**
	CM w/o $\mathcal{L}_{\text{Con}}$	8.412 ± 0.227	0.0029 ± 0.0002	0.50 ± 0.01	13.23 ± 0.22
	CM w/o $\mathcal{L}_{\text{Div}}$	8.073 ± 0.174	0.0025 ± 0.0001	0.51 ± 0.01	13.42 ± 0.16

时在 θ^g 中保留了多数类和通用知识，实现了预期的容量分配目标。

6.4.3.3　训练开销与效率分析

容量操纵损失的计算涉及泛化分支的一次额外前向传播过程。实验观测显示，该过程导致单次迭代的训练时长增加至基准方法的 1.3 至 1.4 倍。虽然引入低秩因子与额外损失函数带来了计算量的提升，但此类开销在模型训练阶段属于可接受范围，且该方法在推理阶段不引入任何额外开销。

为验证性能增益源于对模型容量的高效分配而非单纯的计算资源堆叠，本研究评估了受限计算预算条件下的模型表现。具体实验中，将采用标准训练步数（300k 步）的 CM 算法与经过更长时间训练（500k 步）的强基线方法 OC 进行对比。如表 6.12 所示，即使在计算预算受限的情况下，CM 算法依然展现出显著的性能优势。CM



(a) 通用框架验证　　(b) λ 消融

(c) 秩 r 消融　　(d) 网络结构消融

图 6.6　(a) CM 与不同基线集成后的性能。(b) 公式 6.25 中超参数 λ 的消融实验。(c) 秩 r 的消融实验。(d) 不同 UNet 配置下的消融实验。所有实验均在 Imb. CIFAR-100 (IR=100) 上进行。在 (b) 和 (c) 中，使用表现最好的基线 OC 作为参考。

Figure 6.6　(a) The performance of CM when integrated with baselines. (b) Ablation study on the hyperparameter λ in 公式 (6.25). (c) Ablation study on the rank r. (d) Ablation study on various UNet configurations. All experiments are conducted on Imb. CIFAR-100 with IR = 100**. In (b) and (c), we use OC as a reference because it shows the best overall performance among the baselines.**

算法在 300k 步时取得的 FID 指标优于经过 500k 步训练后的强基线，这充分证明了通过参数空间解耦策略优化模型容量利用率的有效性。

6.4.3.4　消融实验与超参数敏感性

超参数 λ 的消融：本研究对公式 6.25 中控制 CM 损失权重的超参数 λ 进行了消融实验。图 6.6b 展示了 FID 随 λ 变化的情况。结果表明，CM 在较宽的 λ 取值范围内均能保持对最佳基线 OC 的优势，并在 $\lambda = 1.0$ 附近达到最佳性能。

W^e 秩的消融：本研究还探究了 $W^e \in \theta^e$ 的秩比率 $\frac{r}{\min(d,k)}$ 对性能的影响。如图 6.6c 所示，CM 在广泛的秩比率范围内均优于 OC，且在 0.1 左右达到峰值。这表明适度的低秩约束有助于在保留足够容量的同时实现高效的知识分配。

表 6.12　CM 算法在受限训练预算下的性能评估
Table 6.12　Performance under Constrained Computational Budget

方法	训练步数	FID ↓
OC （最佳基线）	300k	8.31
OC （延长训练）	500k	8.15
CM （本文方法）	300k	7.52

表 6.13　CM 算法与基线算法在长尾 CIFAR-100 上的分类准确率 (%)，使用 ResNet-18。对比了交叉熵 (CE)、LDAM 和 Logit Adjustment (LA) 及其 CM 集成版本在不平衡比率 (IR) 为 200 和 100 下的表现。
Table 6.13　Classification accuracy (%) on Long-Tailed CIFAR-100 using ResNet-18. We compare Cross-Entropy (CE), LDAM, and Logit Adjustment (LA) with their CM-integrated versions under imbalance ratios (IR) of 200 and 100.

不平衡比率	算法名称	Many	Med.	Few	Overall
IR = 200	CE	**70.03**	42.13	6.38	36.56
	LDAM	62.13	43.64	16.64	38.66
	LDAM + CM	60.20	46.35	**20.69**	40.50
	LA	60.46	45.16	20.43	40.11
	LA + CM	63.73	**46.38**	20.16	**41.36**
IR = 100	CE	**70.14**	40.54	6.73	40.76
	LDAM	61.77	41.57	19.10	41.90
	LDAM + CM	62.40	44.94	21.77	44.10
	LA	57.91	45.80	23.53	43.36
	LA + CM	61.60	**46.94**	**23.80**	**45.14**

$\mathcal{L}_{\text{Con}}$ 和 $\mathcal{L}_{\text{Div}}$ 的消融：表 6.11 展示了分别移除一致性损失 $\mathcal{L}_{\text{Con}}$ 和多样性损失 $\mathcal{L}_{\text{Div}}$ 后的结果。由于 $\mathcal{L}_{\text{Con}}$ 和 $\mathcal{L}_{\text{Div}}$ 分别负责多数类知识和少数类专业知识的分配，移除任一项都会导致性能显著下降，证明了二者的必要性。

网络结构的消融：本研究通过调整 U-Net 的 channel_multipliers 参数（$[1,2,2]$, $[1,2,2,2]$, $[1,2,3,4]$）构建了不同宽度和深度的网络架构。图 6.6d 显示，CM 在所有配置下均保持了明显的性能优势，证实了其对模型结构的鲁棒性。

6.4.3.5　在更广泛场景下的验证

为了验证 CM 在不同生成模型范式下的普适性，本研究将其扩展到了更多场景，包括一致性模型（Consistency Models）、DPM-Solver 采样器以及从头训练的潜在扩散模型（Latent Diffusion Models）。此外，我们还探索了 CM 在判别式任务中的潜力。

一致性模型与 DPM-Solver：表 6.14 和表 6.15 分别展示了 CM 在一致性模型[212]

表 6.14 CM 算法与基线算法在一致性模型 (Consistency Models) 上的 FID 结果。集成 CM (+CM) 一致降低了 FID。

Table 6.14 FID results on Consistency Models. Incorporating our method (+CM) consistently reduces FID compared to the baseline.

数据集 (不平衡比率 IR = 100)	基线 FID	+CM FID
Imbalanced CIFAR-10	10.523	**9.257**
Imbalanced CIFAR-100	9.862	**8.638**

表 6.15 CM 算法与基线算法在 DPM-Solver (15 步) 上的 FID 结果。CM (+CM) 提升了生成质量。

Table 6.15 FID results on DPM-Solver (15 steps). Our method (+CM) improves generation quality over the baseline.

数据集 (不平衡比率 IR = 100)	基线 FID	+CM FID
Imbalanced CIFAR-10	10.932	**7.623**
Imbalanced CIFAR-100	11.524	**8.033**

和使用 DPM-Solver[213]（15 步采样）时的性能。结果显示，集成 CM 后，FID 分数在不同数据集上均有一致的显著降低，证明 CM 能够有效提升这些高效采样模型的生成质量。

细粒度文本到图像生成：本研究在 CUB-200 和 Oxford-102 的长尾版本上，验证了 CM 在从头训练潜在扩散模型（Latent Diffusion Models）进行细粒度文本到图像生成任务上的有效性。实验遵循 VQ-Diffusion-S[214] 的配置。如表 6.16 所示，CM 同样取得了一致的 FID 提升。

判别式任务的扩展：尽管本文主要关注生成模型，但“容量操纵”这一核心思想——即显式为少数类预留模型容量——同样适用于判别式长尾识别任务。为了验证这一点，本研究在长尾 CIFAR-100 上进行了初步实验。我们使用 ResNet-18 作为骨干网络，对其卷积层应用低秩分解（$\theta = \theta^g \oplus \theta^e$）。表 6.13 对比了标准交叉熵（CE）、LDAM 和 Logit Adjustment (LA) 及其 CM 增强版本。结果显示，CM 带来了一致的性能提升。特别是在 IR = 100 时，CM 使 LA 的整体准确率提升了 **1.78%**，且在 Medium 和 Few 类别上增益显著。这证实了防止多数类垄断共享特征提取器对于判别式任务同样具有重要价值，表明 CM 的容量预留原则具有超越生成模型的广泛适用性。

表 6.16　CM 算法与基线算法在细粒度文生图数据集上从头训练潜在扩散模型的 FID 结果。CM (+CM) 优于基线。

Table 6.16　FID results on latent diffusion models trained from scratch on fine-grained text-to-image datasets. Our method (+CM) improves generation quality over the baseline.

数据集	基线 FID	+CM FID
CUB-200	24.62	**22.64**
Oxford-102	26.47	**24.31**

6.5　本章小结

本章深入探讨了在“任务目标异构”维度下，生成式扩散模型在长尾分布数据上面临的鲁棒学习挑战。不同于判别式任务中主要关注的分类边界偏移问题，本研究通过实证观察和理论分析揭示了扩散模型在生成任务中的核心病灶：**模型容量的垄断（Model Capacity Monopoly）**。即在不平衡训练过程中，多数类别凭借其庞大的样本数量贡献了绝大部分梯度，从而主导了模型参数的更新方向，导致有限的模型容量被多数类知识所占据，而少数类因缺乏专属的表征资源而出现生成质量的严重退化。

针对这一本质问题，本章提出了一种名为 **CM（Capacity Manipulation）**的通用重平衡范式。该方法并未沿袭传统的基于损失函数加权（Loss Reweighting）的修补思路，而是从模型参数空间的底层机制入手，实施了主动的容量干预。CM 的核心贡献在于：

1. **结构化的容量预留：**创新性地利用低秩分解技术，将模型参数显式解耦为“通用/多数类参数”与“专用/少数类参数”。这种设计在不增加推理成本的前提下，为少数类开辟了独立的特征存储空间。
2. **策略性的知识分配：**设计了容量操纵损失函数，通过差异化的一致性与多样性约束，强制引导多数类知识流向通用参数，同时迫使少数类专业知识被编码进预留的专用参数中，从而实现了知识在参数空间中的有序分流。

在 CIFAR-10/100、CelebA-HQ、ImageNet-LT 等多个基准数据集上的广泛实验表明，CM 在各类不平衡比率下均能显著提升少数类的生成质量（大幅降低 FID），且未牺牲多数类的性能。此外，CM 在大模型微调（Stable Diffusion）、一致性模型加速采样以及判别式长尾分类任务中的成功应用，进一步验证了“容量解耦与预留”这一思想的普适性与扩展潜力。本章的研究成果不仅为解决生成式长尾学习问题提供了新的范式，也为理解深度神经网络在非均匀分布下的资源分配机制提供了重要的理论视角。

6.5.1 局限性与讨论

本章针对生成式长尾学习中的样本质量失衡问题，提出了一种基于容量操控的研究框架。本研究通过深入分析扩散模型在处理长尾分布时的内在机制，揭示了模型容量在头部与尾部类别间分配不均是导致生成性能差异的核心因素。虽然本章提出的方法在多个基准数据集上均取得了显著的性能提升，但仍有部分高层次的问题值得社区在未来研究中进一步探讨。

首先，本研究的实验验证主要集中于图像生成任务。在当前生成式人工智能快速发展的背景下，多模态生成以及高维视频生成等复杂任务表现出更为复杂的长尾特征。由于这些任务通常涉及更高维度的语义空间，如何在保持跨模态对齐的同时实现精细化的容量分配，依然是学术界需要攻克的难题。社区后续研究可以探索将容量操控思想扩展至更大规模的视觉语言模型中，以增强模型对互联网尺度长尾数据的理解与生成能力。

其次，虽然本章在理论与实验上证明了调整模型容量分布的有效性，但在面对超大规模参数模型时，动态干预网络结构的计算开销与推理效率仍存在优化的空间。随着基础模型规模的持续增长，如何在保障生成质量的前提下，开发更加轻量化且具有即插即用特性的容量调节模块，将成为未来长尾生成领域的一个重要课题。

最后，本研究建立的模型容量与数据分布关联模型，为理解长尾数据下的生成学习提供了新的视角。尽管本章已经在经验层面给出了合理的解释，但关于容量冗余、生成保真度与样本多样性三者之间的内在数学界限，仍需更完备的理论框架予以支撑。未来的相关工作可以尝试从信息论或流形学习的角度出发，定量描述长尾分布下模型容量的演化规律，从而为构建更稳健的通用生成系统提供理论指导。

第 7 章 总结与展望

7.1 全文总结

本研究围绕条件非完备下的长尾学习这一核心命题，针对现实世界数据中普遍存在的长尾分布与多重非理想偏倚相互耦合的严峻挑战，系统性地展开了理论分析与算法研究。

深度学习的成功很大程度上依赖于高质量且分布均衡的理想化数据。然而，现实世界的泛在数据生成过程往往呈现出显著的长尾分布特征，并伴随着标签退化以及隐式结构等条件非完备场景。理想条件下的长尾学习方法普遍建立在标注准确、结构显式以及任务单一这三大理想化假设条件之上。当面对条件非完备时，这些方法面临严峻挑战。首先，在监督信号退化的条件非完备下，传统重加权策略会错误地放大噪声信号。其次，当存在隐式结构时，粗粒度的类别监督掩盖了子群层面的失衡。最后，在生成式任务中，头部类别对模型容量的垄断导致尾部类别的生成质量严重退化。

针对上述局限，本研究打破了理想条件下仅依赖显式分布对齐的局限，构建了一套涵盖数据分布校准、隐式结构挖掘以及模型容量解耦的通用学习框架。本文的主要研究成果及创新点总结如下：

第一，针对长尾偏标签这种条件非完备中静态先验误导动态消歧的问题，本研究提出了基于动量原型的动态校准算法（RECORDS）。研究发现，理想条件下的重加权策略依赖于固定的训练集统计先验，这在标签消歧的早期阶段会导致模型产生严重的过度自信与消歧崩塌。本文通过理论推导证明了动态分布估计的必要性，并设计了一种无需预知真实分布的前提下利用动量更新的原型特征实时捕捉消歧过程中类别分布演变的机制。通过参数化的动态分解实现消歧置信度与分布偏差的协同优化，有效解决了该设定下的冷启动与分布失配难题。实验结果表明，该方法在无需任何额外先验信息的情况下，显著提升了模型在极度不平衡且高歧义场景下的判别能力。

第二，针对长尾噪声标签这种条件非完备中去偏与抗噪在优化目标上的内生冲突，本研究构建了基于双粒度最优传输的统一鲁棒蒸馏框架（D-SINK）。在长尾噪声数据中，尾部样本的高损失特性使其极易被去噪算法误删，而盲目的重加权又会放大噪声信号。本文创新性地引入最优传输理论，在分布粒度上利用长尾先验纠正全局偏差，在样本粒度上利用几何对齐过滤高损耗噪声。该框架通过双粒度机制协同整合仅具单项鲁棒性的辅助模型，成功在极低信噪比条件下恢复了模型的泛化能力，

验证了通过协同蒸馏实现条件非完备下鲁棒性的可行性。

第三，针对显式监督无法覆盖隐式子群分布失衡这一条件非完备，本研究提出了基于互信息最大化的无监督子群挖掘与平衡算法（SHE）。理想条件下的学习方法通常假设子群标签已知或依赖人工定义的属性，难以应对未知的隐式偏差。本文遵循先解耦后平衡的理念，利用信息论工具自动识别语义一致但分布各异的隐式子群。该方法摒弃了对细粒度标签的依赖，通过自适应聚合策略实现子群层面的预测平衡。研究结果不仅在理论上保证了数据划分的一致性，更在实验中显著提升了模型在弱势子群上的公平性与鲁棒性，将长尾学习的研究粒度从显式类别推进到了隐式流形。

第四，针对生成式任务中头部类别垄断模型容量导致尾部性能退化这一条件非完备，本研究提出了基于参数空间解耦的通用重平衡范式（CM）。本研究发现长尾分布导致的梯度主导效应使得有限的模型容量长期被头部特征占据。本文跳出了传统以损失函数为中心的修补思路，从模型优化的底层机制入手，将模型权重显式分解为通用共享与尾部专用模块。通过这种底层参数解耦策略，本研究不仅实现了零推理成本的分类精度提升，更从优化机制底层解决了扩散生成模型中尾部类别的模式崩塌问题，验证了通过容量重构实现跨任务通用性的可行性。

综上所述，本文系统构建了条件非完备下的长尾学习方法体系。本研究不仅在提升模型对退化监督信号容错能力的同时兼顾了隐式公平性与跨任务通用性，更为构建稳健且高效的人工智能系统奠定了理论基础。

7.2　未来工作展望

尽管本研究在条件非完备下的长尾学习方面取得了一定进展，但随着人工智能技术的快速演进，特别是在大模型与开放世界应用蓬勃发展的背景下，该领域仍面临着诸多更为深远和艰巨的挑战。基于本文的研究基础，未来的研究工作可以从以下几个维度展开：

首先，探索面向开放动态环境的持续学习机制以打破任务单一的理想化假设。本文目前的研究主要集中在静态的离线数据集上，假设训练数据一次性给定。然而在自动驾驶以及网络舆情分析等真实应用中，数据往往是以流式形式到达的，且数据分布如长尾分布的倾斜度以及标签退化的模式会随时间发生动态漂移[215-216]。如何在灾难性遗忘与非理想分布漂移的双重压力下实现模型的持续更新与鲁棒性保持是一个亟待解决的问题[217-219]。未来的研究可以结合持续学习与测试时自适应技术，探索无需重训练即可动态适应在线变化的鲁棒学习算法[220-222]。

其次，研究多模态大模型在极端非理想条件下的鲁棒对齐技术。随着以 CLIP 以及 GPT-4V 为代表的多模态基础模型的兴起，数据规模呈指数级增长，但数据质量问题也愈发凸显。网络爬取的图文对中充斥着更加复杂的非结构化噪声以及极端的语义长尾分布。本文提出的基于参数空间解耦的通用重平衡范式在扩散模型上取得了成功，但如何将其扩展到参数量千亿级别的网络架构中，特别是在参数高效微调的限制下实现对尾部概念的精准对齐与去幻觉，是未来值得深入探索的方向。此外，如何利用大模型本身强大的语义先验来辅助条件非完备下的标签清洗与分布校准也是一个充满潜力的研究点。

再次，深化隐式结构挖掘的可解释性与因果推断研究以应对结构非显式的挑战。本文提出的基于互信息最大化的无监督子群挖掘与平衡算法虽然在识别隐式子群方面表现出色，但其挖掘出的子群主要基于统计相关性，缺乏明确的因果解释。在医疗以及法律等高风险领域，理解模型判定特定隐式结构的内在逻辑至关重要。未来的研究可以引入因果推断框架，尝试区分数据中的因果特征与非因果性的偶然关联特征，从而构建在因果意义上鲁棒的不变性学习模型[223-224]。这不仅有助于提升模型在弱势子群上的泛化能力，更能从根本上解决非理想条件下的算法歧视与公平性问题[225-226]。

最后，构建理论完备的条件非完备下的长尾学习泛化界。目前关于监督信号退化与分布失衡的理论分析多独立进行，缺乏统一的理论框架来解释多重非理想偏倚耦合下的模型行为。本文虽然在各章节提供了一定的理论分析，如消歧过程的一致性证明以及分布估计的必要性推导，但距离建立一套涵盖分布偏移、标签退化及模型容量的统一泛化误差界仍有距离。未来的工作致力于利用高维概率论与统计学习理论，推导在条件非完备的耦合下深度神经网络的样本复杂度下界与泛化误差上界[227-228]，为设计更高效的针对条件非完备下的长尾学习算法提供坚实的理论指导。

参考文献

[1] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.

[2] GOODFELLOW I, BENGIO Y, COURVILLE A, et al. Deep learning: vol. 1[M]. MIT press Cambridge, 2016.

[3] BENGIO Y, LECUN Y, HINTON G. Deep learning for AI[J]. Communications of the ACM, 2021, 64(7): 58-65.

[4] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is All you Need[C]//GUYON I, von LUXBURG U, BENGIO S, et al. Conference on Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.

[5] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models [J]. arXiv preprint arXiv:2001.08361, 2020.

[6] HOFFMANN J, BORGEAUD S, MENSCH A, et al. Training compute-optimal large language models[J]. arXiv preprint arXiv:2203.15556, 2022.

[7] VOULODIMOS A, DOULAMIS N, DOULAMIS A, et al. Deep learning for computer vision: A brief review[J]. Computational intelligence and neuroscience, 2018, 2018(1): 7068349.

[8] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2016: 770-778.

[9] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//NAVAB N, HORNEGGER J, III W M W, et al. Lecture Notes in Computer Science: International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI): vol. 9351. Springer, 2015: 234-241.

[10] LIU L, CAI C, SHEN S, et al. MoA-VR: A Mixture-of-Agents System Towards All-in-One Video Restoration[J]. IEEE Journal of Selected Topics in Signal Processing, 2025.

[11] OQUAB M, DARCET T, MOUTAKANNI T, et al. DINOv2: Learning Robust Visual Features without Supervision[J]. Transactions on Machine Learning Research (TMLR), 2024, 2024.

[12] DONG C, LOY C C, HE K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2015, 38(2): 295-307.

[13] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2016, 39(6): 1137-1149.

[14] BROWN T, MANN B, RYDER N, et al. Language Models are Few-Shot Learners[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Conference on Neural Information Processing Systems (NeurIPS): vol. 33. Curran Associates, Inc., 2020: 1877-1901.

[15] DEVLIN J, CHANG M, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]//North American Chapter of the Association for Computational Linguistics (NAACL). 2019: 4171-4186.

[16] ZHAO W X, ZHOU K, LI J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223, 2023, 1(2).

[17] ZHOU C, LI Q, LI C, et al. A comprehensive survey on pretrained foundation models: A history from bert to chatgpt[J]. International Journal of Machine Learning and Cybernetics (IJMLC), 2025, 16(12): 9851-9915.

[18] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]//MEILA M, ZHANG T. Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 139. PMLR: 8748-8763.

[19] HO J, JAIN A, ABBEEL P. Denoising Diffusion Probabilistic Models[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Conference on Neural Information Processing Systems (NeurIPS). 2020.

[20] RAMESH A, PAVLOV M, GOH G, et al. Zero-Shot Text-to-Image Generation[C]//MEILA M, ZHANG T. Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 139. PMLR, 2021: 8821-8831.

[21] BOJARSKI M, DEL TESTA D, DWORAKOWSKI D, et al. End to end learning for self-driving cars[J]. arXiv preprint arXiv:1604.07316, 2016.

[22] GRIGORESCU S, TRASNEA B, COCIAS T, et al. A survey of deep learning techniques for autonomous driving[J]. Journal of field robotics, 2020, 37(3): 362-386.

[23] ESTEVA A, KUPREL B, NOVOA R A, et al. Dermatologist-level classification of skin cancer with deep neural networks[J]. Nature, 2017, 542(7639): 115-118.

[24] HOLSTE G, ZHOU Y, WANG S, et al. Towards long-tailed, multi-label disease classification from chest X-ray: Overview of the CXR-LT challenge[J]. Medical Image Analysis (MIA), 2024, 97: 103224.

[25] REDMON J, DIVVALA S K, GIRSHICK R B, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2016: 779-788.

[26] PIANTADOSI S T. Zipf's word frequency law in natural language: A critical review and future directions[J]. Psychonomic bulletin & review, 2014, 21(5): 1112-1130.

[27] LIU Z, MIAO Z, ZHAN X, et al. Large-Scale Long-Tailed Recognition in an Open World[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Computer Vision Foundation / IEEE, 2019: 2537-2546.

[28] CAO X, XU M, YU X, et al. Analytical Survey of Learning with Low-Resource Data: From Analysis to Investigation[J]. ACM Computing Surveys, 2025.

[29] BUDA M, MAKI A, MAZUROWSKI M A. A systematic study of the class imbalance problem in convolutional neural networks[J]. Neural Networks (NN), 2018, 106: 249-259.

[30] KANG B, XIE S, ROHRBACH M, et al. Decoupling Representation and Classifier for Long-Tailed Recognition[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2020.

[31] HAN X, HUANG Y, TANG S, et al. From regional to general: A vision-language model-based framework for corner cases comprehension in autonomous driving[C]//ECCV 2024 Workshop on Multimodal Perception and Comprehension of Corner Cases in Autonomous Driving: vol. 7. 2024.

[32] LIAO H, WANG B, YANG J, et al. Addressing corner cases in autonomous driving: A world model-based approach with mixture of experts and LLMs[J]. Transportation Research Part C: Emerging Technologies, 2026, 183: 105456.

[33] GUO Y, ZHANG L, HU Y, et al. MS-Celeb-1M: A Dataset and Benchmark for Large-Scale Face Recognition[C]//LEIBE B, MATAS J, SEBE N, et al. Lecture Notes in Computer Science: European Conference on Computer Vision (ECCV): vol. 9907. Springer, 2016: 87-102.

[34] CAO D, ZHU X, HUANG X, et al. Domain Balancing: Face Recognition on Long-Tailed Domains [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Computer Vision Foundation / IEEE, 2020: 5670-5678.

[35] SCHIEPPATI A, HENTER J I, DAINA E, et al. Why rare diseases are an important medical and social issue[J]. The Lancet, 2008, 371(9629): 2039-2041.

[36] MAGUERESSE A, CARLES V, HEETDERKS E. Low-resource Languages: A Review of Past Work and Future Challenges[J/OL]. CoRR, 2020, abs/2006.07264. arXiv: 2006.07264.

[37] ZHAO Z, ZHOU K, WANG X, et al. Alleviating the Long-Tail Problem in Conversational Recommender Systems[C]//ZHANG J, CHEN L, BERKOVSKY S, et al. RecSys. ACM, 2023: 374-385.

[38] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-Resolution Image Synthesis with Latent Diffusion Models[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022: 10674-10685.

[39] HORN G V, AODHA O M, SONG Y, et al. The INaturalist Species Classification and Detection Dataset[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Computer Vision Foundation / IEEE Computer Society, 2018: 8769-8778.

[40] CHAWLA N V, BOWYER K W, HALL L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of Artificial Intelligence Research (JAIR, 2002, 16: 321-357.

[41] CUI Y, JIA M, LIN T, et al. Class-Balanced Loss Based on Effective Number of Samples[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 9268-9277.

[42] MENON A K, JAYASUMANA S, RAWAT A S, et al. Long-tail learning via logit adjustment[C] //International Conference on Learning Representations (ICLR). OpenReview.net, 2021.

[43] WANG J, LUKASIEWICZ T, HU X, et al. RSG: A Simple but Effective Module for Learning Imbalanced Datasets[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Computer Vision Foundation / IEEE, 2021: 3784-3793.

[44] WANG H, XIA M, LI Y, et al. SoLar: Sinkhorn Label Refinery for Imbalanced Partial-Label Learning[C]//Conference on Neural Information Processing Systems (NeurIPS). 2022.

[45] SAGAWA S, KOH P W, HASHIMOTO T B, et al. Distributionally Robust Neural Networks for Group Shifts: On the Importance of Regularization for Worst-Case Generalization[J/OL]. CoRR, 2019, abs/1911.08731. arXiv: 1911.08731.

[46] LIU E Z, HAGHGOO B, CHEN A S, et al. Just Train Twice: Improving Group Robustness without Training Group Information[C]//MEILA M, ZHANG T. Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 139. PMLR, 2021: 6781-6792.

[47] CREAGER E, JACOBSEN J, ZEMEL R S. Environment Inference for Invariant Learning[C]// MEILA M, ZHANG T. Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 139. PMLR, 2021: 2189-2200.

[48] QIN Y, ZHENG H, YAO J, et al. Class-Balancing Diffusion Models[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2023: 18434-18443.

[49] ZHANG Y, KANG B, HOOI B, et al. Deep long-tailed learning: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2023, 45(9): 10795-10816.

[50] ZHANG C, ALMPANIDIS G, FAN G, et al. A Systematic Review on Long-Tailed Learning[J]. IEEE Transactions on Neural Networks and Learning Systems (TNNLS), 2025, 36(8): 13670-13690.

[51] HUANG C, LI Y, LOY C C, et al. Learning deep representation for imbalanced classification[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2016: 5375-5384.

[52] HE H, GARCIA E A. Learning from Imbalanced Data[J]. IEEE Transactions on Knowledge and Data Engineering (TKDE), 2009, 21(9): 1263-1284.

[53] SHI J X, WEI T, XIANG Y, et al. How re-sampling helps for long-tail learning?[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 36. 2023: 75669-75687.

[54] BUCHER M, HERBIN S, JURIE F. Hard negative mining for metric learning based zero-shot classification[C]//European Conference on Computer Vision (ECCV). 2016: 524-531.

[55] SMIRNOV E, MELNIKOV A, OLEINIK A, et al. Hard example mining with auxiliary embeddings[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2018: 37-46.

[56] SUH Y, HAN B, KIM W, et al. Stochastic class-based hard example mining for deep metric learning[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2019: 7251-7259.

[57] DONG Q, GONG S, ZHU X. Class rectification hard mining for imbalanced deep learning[C]//IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2017: 1851-1860.

[58] ZHANG H, CISSE M, DAUPHIN Y N, et al. mixup: Beyond Empirical Risk Minimization[C]//International Conference on Learning Representations (ICLR). 2018.

[59] YUN S, HAN D, OH S J, et al. Cutmix: Regularization strategy to train strong classifiers with localizable features[C]//IEEE/CVF International Conference on Computer Vision (ICCV). 2019: 6023-6032.

[60] CHOU H P, CHANG S C, PAN J Y, et al. Remix: rebalanced mixup[C]//European Conference on Computer Vision (ECCV). 2020: 95-110.

[61] XU Z, CHAI Z, YUAN C. Towards calibrated model for long-tailed visual recognition from prior perspective[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 34. 2021: 7139-7152.

[62] PARK S, HONG Y, HEO B, et al. The majority can help the minority: Context-rich minority oversampling for long-tailed classification[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 6887-6896.

[63] WANG B, WANG P, XU W, et al. Kill Two Birds with One Stone: Rethinking Data Augmentation for Deep Long-tailed Learning[C/OL]//The Twelfth International Conference on Learning Representations. 2024. https://openreview.net/forum?id=RzY9qQHUXy.

[64] LIU J, SUN Y, HAN C, et al. Deep representation learning on long-tailed data: A learnable embedding augmentation perspective[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Computer Vision Foundation / IEEE, 2020: 2970-2979.

[65] MIN B, ROSS H, SULEM E, et al. Recent advances in natural language processing via large pre-trained language models: A survey[J]. ACM Computing Surveys, 2023, 56(2): 1-40.

[66] LI J, TANG T, ZHAO W X, et al. Pre-trained language models for text generation: A survey[J]. ACM Computing Surveys, 2024, 56(9): 1-39.

[67] HU L, LIU Z, ZHAO Z, et al. A survey of knowledge enhanced pre-trained language models[J]. IEEE Transactions on Knowledge and Data Engineering (TKDE), 2023, 36(4): 1413-1430.

[68] ZHANG J, HUANG J, JIN S, et al. Vision-language models for vision tasks: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2024, 46(8): 5625-5644.

[69] ZHAO Q, DAI Y, LI H, et al. Ltgc: Long-tail recognition via leveraging llms-driven generated content[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 19510-19520.

[70] ZHOU B, CUI Q, WEI X S, et al. Bbn: Bilateral-branch network with cumulative learning for long-tailed visual recognition[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2020: 9719-9728.

[71] WANG P, HAN K, WEI X S, et al. Contrastive learning based hybrid networks for long-tailed

image classification[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2021: 943-952.

[72] WANG X, LIAN L, MIAO Z, et al. Long-tailed Recognition by Routing Diverse Distribution-Aware Experts[C]//International Conference on Learning Representations (ICLR). 2021.

[73] CAI J, WANG Y, HWANG J N. Ace: Ally complementary experts for solving long-tailed recognition in one-shot[C]//IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 112-121.

[74] LI J, TAN Z, WAN J, et al. Nested collaborative learning for long-tailed visual recognition[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2022: 6949-6958.

[75] JIN Y, LI M, LU Y, et al. Long-tailed visual recognition via self-heterogeneous integration with knowledge excavation[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2023: 23695-23704.

[76] ZHANG Y, HOOI B, HONG L, et al. Self-Supervised Aggregation of Diverse Experts for Test-Agnostic Long-Tailed Recognition[C]//KOYEJO S, MOHAMED S, AGARWAL A, et al. Conference on Neural Information Processing Systems (NeurIPS). 2022.

[77] LONG A, YIN W, AJANTHAN T, et al. Retrieval augmented classification for long-tail visual recognition[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2022: 6959-6969.

[78] TIAN C, WANG W, ZHU X, et al. Vl-ltr: Learning class-wise visual-linguistic representation for long-tailed visual recognition[C]//European Conference on Computer Vision (ECCV). 2022: 73-91.

[79] LIN T, GOYAL P, GIRSHICK R B, et al. Focal Loss for Dense Object Detection[C]//IEEE/CVF International Conference on Computer Vision (ICCV). IEEE Computer Society, 2017: 2999-3007.

[80] WANG J, ZHANG W, ZANG Y, et al. Seesaw loss for long-tailed instance segmentation[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2021: 9695-9704.

[81] LI B, YAO Y, TAN J, et al. Equalized focal loss for dense long-tailed object detection[C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2022: 6990-6999.

[82] WANG T, ZHU Y, CHEN Y, et al. C2am loss: Chasing a better decision boundary for long-tail object detection[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2022: 6980-6989.

[83] REN J, YU C, SHENG S, et al. Balanced Meta-Softmax for Long-Tailed Visual Recognition[C] //Conference on Neural Information Processing Systems (NeurIPS). 2020.

[84] CAO K, WEI C, GAIDON A, et al. Learning Imbalanced Datasets with Label-Distribution-Aware

Margin Loss[C]//Conference on Neural Information Processing Systems (NeurIPS). 2019: 1565-1576.

[85] TAN J, WANG C, LI B, et al. Equalization loss for long-tailed object recognition[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11662-11671.

[86] LI M, CHEUNG Y M, LU Y. Long-tailed visual recognition via gaussian clouded logit adjustment [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Computer Vision Foundation / IEEE, 2022: 6929-6938.

[87] TIAN Y, YU X, FU S. Partial label learning: Taxonomy, analysis and outlook[J]. Neural Networks (NN), 2023, 161: 708-734.

[88] COUR T, SAPP B, TASKAR B. Learning from Partial Labels[J]. Journal of Machine Learning Research (JMLR), 2011, 12: 1501-1536.

[89] HÜLLERMEIER E, BERINGER J. Learning from ambiguously labeled examples[J]. Intelligent Data Analysis (IDA), 2006, 10(5): 419-439.

[90] JIN R, GHAHRAMANI Z. Learning with Multiple Labels[C]//Conference on Neural Information Processing Systems (NeurIPS). MIT Press, 2002: 897-904.

[91] LIU L, DIETTERICH T G. Learnability of the Superset Label Learning Problem[C]//JMLR Workshop and Conference Proceedings: International Conference on Machine Learning (ICML): vol. 32. JMLR.org, 2014: 1629-1637.

[92] LV J, XU M, FENG L, et al. Progressive Identification of True Labels for Partial-Label Learning [C]//Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 119. PMLR, 2020: 6500-6510.

[93] WEN H, CUI J, HANG H, et al. Leveraged Weighted Loss for Partial Label Learning[C]// Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 139. PMLR, 2021: 11091-11100.

[94] WANG H, XIAO R, LI Y, et al. PiCO: Contrastive Label Disambiguation for Partial Label Learning[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2022.

[95] WANG J, ZHANG M. Towards Mitigating the Class-Imbalance Problem for Partial Label Learning[C]//GUO Y, FAROOQ F. ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD). ACM, 2018: 2427-2436.

[96] LIU W, WANG L, CHEN J, et al. A Partial Label Metric Learning Algorithm for Class Imbalanced Data[C]//BALASUBRAMANIAN V N, TSANG I W. Proceedings of Machine Learning Research: Asian Conference on Machine Learning (ACML): vol. 157. PMLR, 2021: 1413-1428.

[97] Van ROOYEN B, WILLIAMSON R C. A Theory of Learning with Corrupted Labels[J]. Journal of Machine Learning Research (JMLR), 2017, 18: 228:1-228:50.

[98] LI X, LIU T, HAN B, et al. Provably end-to-end label-noise learning without anchor points[C]// International Conference on Machine Learning (ICML). 2021: 6403-6413.

[99] LI Y, CHEN Y, YU X, et al. SURE: SUrvey REcipes for building reliable and robust deep networks[J]. CoRR, 2024, abs/2403.00543.

[100] FORET P, KLEINER A, MOBAHI H, et al. Sharpness-aware Minimization for Efficiently Improving Generalization[C]//International Conference on Learning Representations (ICLR). 2021.

[101] HAN B, YAO Q, YU X, et al. Co-teaching: Robust training of deep neural networks with extremely noisy labels[C]//Conference on Neural Information Processing Systems (NeurIPS). 2018: 8536-8546.

[102] LI J, SOCHER R, HOI S C H. DivideMix: Learning with Noisy Labels as Semi-supervised Learning[C]//International Conference on Learning Representations (ICLR). 2020.

[103] LU Y, ZHANG Y, HAN B, et al. Label-Noise Learning with Intrinsically Long-Tailed Data[C]//IEEE/CVF International Conference on Computer Vision (ICCV). 2023: 1369-1378.

[104] CAO K, CHEN Y, LU J, et al. Heteroskedastic and Imbalanced Deep Learning with Adaptive Regularization[C]//International Conference on Learning Representations (ICLR). 2021.

[105] WEI T, SHI J, TU W, et al. Robust Long-Tailed Learning under Label Noise[J]. CoRR, 2021, abs/2108.11569.

[106] SHU J, XIE Q, YI L, et al. Meta-Weight-Net: Learning an Explicit Mapping For Sample Weighting[C]//Conference on Neural Information Processing Systems (NeurIPS). 2019: 1917-1928.

[107] ZHANG M, ZHAO X, YAO J, et al. When Noisy Labels Meet Long Tail Dilemmas: A Representation Calibration Method[C]//IEEE/CVF International Conference on Computer Vision (ICCV). 2023: 15844-15854.

[108] ZHANG H, LU A X, ABDALLA M, et al. Hurtful words: quantifying biases in clinical contextual word embeddings[C]//Conference on Health, Inference, and Learning (CHIL). ACM, 2020: 110-120.

[109] IZMAILOV P, KIRICHENKO P, GRUVER N, et al. On feature learning in the presence of spurious correlations[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 35. 2022: 38516-38532.

[110] BEN-TAL A, den HERTOG D, WAEGENAERE A D, et al. Robust Solutions of Optimization Problems Affected by Uncertain Probabilities[J]. Management Science, 2013, 59(2): 341-357.

[111] DUCHI J C, GLYNN P W, NAMKOONG H. Statistics of Robust Optimization: A Generalized Empirical Likelihood Approach[J]. Mathematics of Operations Research, 2021, 46(3): 946-969.

[112] SAGAWA S, KOH P W, HASHIMOTO T B, et al. Distributionally Robust Neural Networks[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2020.

[113] NAM J H, CHA H, AHN S, et al. Learning from Failure: De-biasing Classifier from Biased Classifier[C]//Conference on Neural Information Processing Systems (NeurIPS). 2020.

[114] LAHOTI P, BEUTEL A, CHEN J, et al. Fairness without Demographics through Adversarially

Reweighted Learning[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Conference on Neural Information Processing Systems (NeurIPS). 2020.

[115] SOHONI N S, DUNNMON J, ANGUS G, et al. No Subclass Left Behind: Fine-Grained Robustness in Coarse-Grained Classification Problems[C]//Conference on Neural Information Processing Systems (NeurIPS). 2020.

[116] LIU S, ZHANG X, SEKHAR N, et al. Avoiding spurious correlations via logit correction[C]// International Conference on Learning Representations (ICLR). OpenReview.net, 2023.

[117] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative Adversarial Networks [J]. CoRR, 2014, abs/1406.2661.

[118] RANGWANI H, MOPURI K R, BABU R V. Class balancing GAN with a classifier in the loop[C]//de CAMPOS C P, MAATHUIS M H, QUAEGHEBEUR E. Proceedings of Machine Learning Research: Conference on Uncertainty in Artificial Intelligence (UAI): vol. 161. AUAI Press, 2021: 1618-1627.

[119] RANGWANI H, JASWANI N, KARMALI T, et al. Improving GANs for Long-Tailed Data Through Group Spectral Regularization[C]//AVIDAN S, BROSTOW G J, CISSÉ M, et al. Lecture Notes in Computer Science: European Conference on Computer Vision (ECCV): vol. 13675. Springer, 2022: 426-442.

[120] DHARIWAL P, NICHOL A Q. Diffusion Models Beat GANs on Image Synthesis[C]// RANZATO M, BEYGELZIMER A, DAUPHIN Y N, et al. Conference on Neural Information Processing Systems (NeurIPS). 2021: 8780-8794.

[121] YAN D, QI L, HU V T, et al. Training Class-Imbalanced Diffusion Model Via Overlap Optimization[Z/OL]. 2024. arXiv: 2402.10821.

[122] ZHANG T, ZHENG H, YAO J, et al. Long-tailed Diffusion Models with Oriented Calibration[C]//International Conference on Learning Representations (ICLR). 2024.

[123] XIE S M, PHAM H, DONG X, et al. DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining[C]//OH A, NAUMANN T, GLOBERSON A, et al. Conference on Neural Information Processing Systems (NeurIPS). 2023.

[124] LIU Q, ZHENG X, MUENNIGHOFF N, et al. RegMix: Data Mixture as Regression for Language Model Pre-training[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2025.

[125] KIM Y, NA B, PARK M, et al. Training Unbiased Diffusion Models From Biased Dataset[C]// ICLR. OpenReview.net, 2024.

[126] LI Y, ZHANG Y, LIU S, et al. Pruning then Reweighting: Towards Data-Efficient Training of Diffusion Models[C]//. IEEE, 2025: 1-5.

[127] LUO J, ORABONA F. Learning from Candidate Labeling Sets[C]//Conference on Neural Information Processing Systems (NeurIPS). Curran Associates, Inc., 2010: 1504-1512.

[128] CHEN C, PATEL V M, CHELLAPPA R. Learning from Ambiguously Labeled Face Images[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 2018, 40(7): 1653-1667.

[129] GONG C, LIU T, TANG Y, et al. A Regularization Approach for Instance-Based Superset Label Learning[J]. IEEE Transactions on Cybernetics (TCYB), 2018, 48(3): 967-978.

[130] FENG L, LV J, HAN B, et al. Provably Consistent Partial-Label Learning[C]//Conference on Neural Information Processing Systems (NeurIPS). 2020.

[131] FEI Z, LEI F, BO H, et al. Exploiting Class Activation Value for Partial-Label Learning[C]// International Conference on Learning Representations (ICLR). OpenReview.net, 2022.

[132] WU D, WANG D, ZHANG M. Revisiting Consistency Regularization for Deep Partial Label Learning[C]//Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 162. PMLR, 2022: 24212-24225.

[133] MENON A K, NARASIMHAN H, AGARWAL S, et al. On the Statistical Consistency of Algorithms for Binary Classification under Class Imbalance[C]//JMLR Workshop and Conference Proceedings: International Conference on Machine Learning (ICML): vol. 28. JMLR.org, 2013: 603-611.

[134] HONG Y, HAN S, CHOI K, et al. Disentangling Label Distribution for Long-Tailed Visual Recognition[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Computer Vision Foundation / IEEE, 2021: 6626-6636.

[135] BRODERSEN K H, ONG C S, STEPHAN K E, et al. The Balanced Accuracy and Its Posterior Distribution[C]//International Conference on Pattern Recognition (ICPR). IEEE Computer Society, 2010: 3121-3124.

[136] BALDI P, SADOWSKI P J. Understanding Dropout[C]//BURGES C J C, BOTTOU L, GHAHRAMANI Z, et al. Conference on Neural Information Processing Systems (NeurIPS). 2013: 2814-2822.

[137] COUR T, SAPP B, TASKAR B. Learning from partial labels[J]. The Journal of Machine Learning Research, 2011, 12: 1501-1536.

[138] EVERINGHAM M, VAN GOOL L, WILLIAMS C K, et al. The pascal visual object classes (voc) challenge[J]. International Journal of Computer Vision (IJCV), 2010, 88(2): 303-338.

[139] CUBUK E D, ZOPH B, SHLENS J, et al. RandAugment: Practical Automated Data Augmentation with a Reduced Search Space[C]//Conference on Neural Information Processing Systems (NeurIPS). 2020.

[140] ZHU J, WANG Z, CHEN J, et al. Balanced Contrastive Learning for Long-Tailed Visual Recognition[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022: 6898-6907.

[141] CUI J, ZHONG Z, LIU S, et al. Parametric Contrastive Learning[C]//IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2021: 695-704.

[142] Van der MAATEN L, HINTON G. Visualizing Data using t-SNE[J]. Journal of Machine Learning Research (JMLR), 2008, 9(86): 2579-2605.

[143] SONG H, KIM M, PARK D, et al. Learning From Noisy Labels With Deep Neural Networks: A Survey[J]. IEEE Transactions on Neural Networks and Learning Systems (TNNLS), 2023, 34(11): 8135-8153.

[144] DENG J, DONG W, SOCHER R, et al. ImageNet: A large-scale hierarchical image database[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2009: 248-255.

[145] LI W, WANG L, LI W, et al. WebVision Database: Visual Learning and Understanding from Web Data[J]. CoRR, 2017, abs/1708.02862.

[146] LITJENS G, KOOI T, BEJNORDI B E, et al. A survey on deep learning in medical image analysis [J]. Medical Image Analysis (MIA), 2017, 42: 60-88.

[147] DAI T, ZHANG R, HONG F, et al. UniChest: Conquer-and-Divide Pre-Training for Multi-Source Chest X-Ray Classification[J]. 2024, 43(8): 2901-2912.

[148] LUO J, HONG F, YAO J, et al. Revive Re-weighting in Imbalanced Learning by Density Ratio Estimation[C]//Conference on Neural Information Processing Systems (NeurIPS). 2024.

[149] AHN S, KO J, YUN S. CUDA: Curriculum of Data Augmentation for Long-tailed Recognition [C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2023.

[150] ZHOU Z, YAO J, HONG F, et al. Combating Representation Learning Disparity with Geometric Harmonization[C]//OH A, NAUMANN T, GLOBERSON A, et al. Conference on Neural Information Processing Systems (NeurIPS). 2023.

[151] YAO Y, SUN Z, ZHANG C, et al. Jo-SRC: A Contrastive Approach for Combating Noisy Labels [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 5192-5201.

[152] KARIM N, RIZVE M N, RAHNAVARD N, et al. UNICON: Combating Label Noise Through Uniform Selection and Contrastive Learning[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 9666-9676.

[153] HAN B, NIU G, YU X, et al. SIGUA: Forgetting May Make Learning with Noisy Labels More Robust[C]//Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 119. 2020: 4006-4016.

[154] HUANG Y, BAI B, ZHAO S, et al. Uncertainty-Aware Learning against Label Noise on Imbalanced Datasets[C]//AAAI Conference on Artificial Intelligence (AAAI). 2022: 6960-6969.

[155] LIU Y, ZHANG W, WANG J. Adaptive multi-teacher multi-level knowledge distillation[J]. Neurocomputing, 2020, 415: 106-113.

[156] TAN X, REN Y, HE D, et al. Multilingual Neural Machine Translation with Knowledge Distillation[C]//International Conference on Learning Representations (ICLR). 2019.

[157] PHAM C, HOANG T, DO T. Collaborative Multi-Teacher Knowledge Distillation for Learning Low Bit-width Deep Neural Networks[C]//IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2023: 6424-6432.

[158] WEI J, ZHU Z, NIU G, et al. Fairness Improves Learning from Noisily Labeled Long-Tailed Data [J]. CoRR, 2023, abs/2303.12291.

[159] YI X, TANG K, HUA X, et al. Identifying Hard Noise in Long-Tailed Sample Distribution[C]// European Conference on Computer Vision (ECCV): vol. 13686. 2022: 739-756.

[160] KRIZHEVSKY A. Learning Multiple Layers of Features from Tiny Images[J]. 2009.

[161] WEI J, ZHU Z, CHENG H, et al. Learning with Noisy Labels Revisited: A Study Using Real-World Human Annotations[C]//International Conference on Learning Representations (ICLR). 2022.

[162] JIANG L, HUANG D, LIU M, et al. Beyond Synthetic Noise: Deep Learning on Controlled Noisy Labels[C]//International Conference on Machine Learning (ICML): vol. 119. 2020: 4804-4815.

[163] XIAO T, XIA T, YANG Y, et al. Learning from massive noisy labeled data for image classification [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 2691-2699.

[164] PARK S, LIM J, JEON Y, et al. Influence-Balanced Loss for Imbalanced Visual Classification[C] //IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 715-724.

[165] IRVIN J, RAJPURKAR P, KO M, et al. CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison[C]//AAAI Conference on Artificial Intelligence (AAAI). AAAI Press, 2019: 590-597.

[166] PAPYAN V, HAN X, DONOHO D L. Prevalence of neural collapse during the terminal phase of deep learning training[J]. Proceedings of the National Academy of Sciences of the United States of America (PNAS), 2020, 117(40): 24652-24663.

[167] ZHANG M, SOHONI N S, ZHANG H R, et al. Correct-N-Contrast: a Contrastive Approach for Improving Robustness to Spurious Correlations[C]//Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 162. PMLR, 2022: 26484-26516.

[168] SEO S, LEE J, HAN B. Unsupervised Learning of Debiased Representations with Pseudo-Attributes[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022: 16721-16730.

[169] TAGHANAKI S A, KHANI A, KHANI F, et al. MaskTune: Mitigating Spurious Correlations by Forcing to Explore[C]//Conference on Neural Information Processing Systems (NeurIPS). 2022.

[170] HAN X Y, PAPYAN V, DONOHO D L. Neural Collapse Under MSE Loss: Proximity to and Dynamics on the Central Path[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2022.

[171] MA J, YOU C, REDDI S J, et al. Do We Need Neural Collapse? Learning Diverse Features for Fine-grained and Long-tail Classification[Z]. 2023.

[172] MCGILL W J. Multivariate information transmission[J]. Transactions of the IRE Professional Group on Information Theory (Trans. IRE Prof. Group Inf. Theory), 1954, 4: 93-111.

[173] COVER T M, THOMAS J A. Elements of information theory (2. ed.)[M]. Wiley, 2006.

[174] BARTLETT P L, MENDELSON S. Rademacher and Gaussian Complexities: Risk Bounds and Structural Results[J]. Journal of Machine Learning Research (JMLR), 2002, 3: 463-482.

[175] STREHL A, GHOSH J. Cluster Ensembles — A Knowledge Reuse Framework for Combining Multiple Partitions[J]. Journal of Machine Learning Research (JMLR), 2002, 3: 583-617.

[176] CHENG Y. Mean Shift, Mode Seeking, and Clustering[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI), 1995, 17(8): 790-799.

[177] ASANO Y M, RUPPRECHT C, VEDALDI A. Self-labelling via simultaneous clustering and representation learning[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2020.

[178] CARON M, MISRA I, MAIRAL J, et al. Unsupervised Learning of Visual Features by Contrasting Cluster Assignments[C]//Conference on Neural Information Processing Systems (NeurIPS). 2020.

[179] BROWN G, WYATT J L, HARRIS R, et al. Diversity creation methods: a survey and categorisation[J]. Inf. Fusion, 2005, 6(1): 5-20.

[180] KROGH A, VEDELSBY J. Neural Network Ensembles, Cross Validation, and Active Learning [C]//Conference on Neural Information Processing Systems (NeurIPS). MIT Press, 1994: 231-238.

[181] TANG E K, SUGANTHAN P N, YAO X. An analysis of diversity measures[J]. Machine Learning (MLJ), 2006, 65(1): 247-271.

[182] TANG K, HUANG J, ZHANG H. Long-Tailed Classification by Keeping the Good and Removing the Bad Momentum Causal Effect[C]//Conference on Neural Information Processing Systems (NeurIPS). 2020.

[183] LIN T, MAIRE M, BELONGIE S J, et al. Microsoft COCO: Common Objects in Context[C]//Lecture Notes in Computer Science: European Conference on Computer Vision (ECCV): vol. 8693. Springer, 2014: 740-755.

[184] REN M, TRIANTAFILLOU E, RAVI S, et al. Meta-Learning for Semi-Supervised Few-Shot Classification[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2018.

[185] TANG K, TAO M, QI J, et al. Invariant Feature Learning for Generalized Long-Tailed Classification[C]//Lecture Notes in Computer Science: European Conference on Computer Vision (ECCV): vol. 13684. Springer, 2022: 709-726.

[186] MA Y, JIAO L, LIU F, et al. Delving into Semantic Scale Imbalance[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2023.

[187] YANG Y, CHEN S, LI X, et al. Inducing Neural Collapse in Imbalanced Learning: Do We Really Need a Learnable Classifier at the End of Deep Neural Network?[C]//Conference on Neural Information Processing Systems (NeurIPS). 2022.

[188] ZENG Y, GREENEWALD K H, LEE K, et al. Outlier-Robust Group Inference via Gradient Space Clustering[J]. CoRR, 2022, abs/2210.06759.

[189] LIU Z, LUO P, WANG X, et al. Deep Learning Face Attributes in the Wild[C]//IEEE/CVF International Conference on Computer Vision (ICCV). IEEE Computer Society, 2015: 3730-3738.

[190] JIA C, YANG Y, XIA Y, et al. Scaling Up Visual and Vision-Language Representation Learning With Noisy Text Supervision[C]//MEILA M, ZHANG T. Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 139. PMLR, 2021: 4904-4916.

[191] CHEN Z, LIU G, ZHANG B, et al. AltCLIP: Altering the Language Encoder in CLIP for Extended Language Capabilities[J/OL]. CoRR, 2022, abs/2211.06679. arXiv: 2211.06679.

[192] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2022.

[193] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-Based Generative Modeling through Stochastic Differential Equations[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2021.

[194] RAMESH A, DHARIWAL P, NICHOL A, et al. Hierarchical Text-Conditional Image Generation with CLIP Latents[J]. CoRR, 2022, abs/2204.06125.

[195] KARRAS T, AILA T, LAINE S, et al. Progressive Growing of GANs for Improved Quality, Stability, and Variation[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2018.

[196] LIAO P, LI X, LIU X, et al. The ArtBench Dataset: Benchmarking Generative Models with Artworks[J]. CoRR, 2022, abs/2206.11404.

[197] JIANG Z, CHEN T, MORTAZAVI B J, et al. Self-Damaging Contrastive Learning[C]//MEILA M, ZHANG T. Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 139. PMLR, 2021: 4927-4939.

[198] MAHAJAN D, GIRSHICK R B, RAMANATHAN V, et al. Exploring the Limits of Weakly Supervised Pretraining[C]//FERRARI V, HEBERT M, SMINCHISESCU C, et al. European Conference on Computer Vision (ECCV): vol. 11206. Springer, 2018: 185-201.

[199] KARRAS T, AITTALA M, HELLSTEN J, et al. Training Generative Adversarial Networks with Limited Data[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Conference on Neural Information Processing Systems (NeurIPS). 2020.

[200] HEUSEL M, RAMSAUER H, UNTERTHINER T, et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium[C]//GUYON I, von LUXBURG U, BENGIO S, et al. Conference on Neural Information Processing Systems (NeurIPS). 2017: 6626-6637.

[201] BINKOWSKI M, SUTHERLAND D J, ARBEL M, et al. Demystifying MMD GANs[C]// International Conference on Learning Representations (ICLR). OpenReview.net, 2018.

[202] KYNKÄÄNNIEMI T, KARRAS T, LAINE S, et al. Improved Precision and Recall Metric for Assessing Generative Models[C]//WALLACH H M, LAROCHELLE H, BEYGELZIMER A, et al. Conference on Neural Information Processing Systems (NeurIPS). 2019: 3929-3938.

[203] SALIMANS T, GOODFELLOW I J, ZAREMBA W, et al. Improved Techniques for Training GANs[C]//LEE D D, SUGIYAMA M, von LUXBURG U, et al. Conference on Neural Information Processing Systems (NeurIPS). 2016: 2226-2234.

[204] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the Inception Architecture for Computer Vision[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2016: 2818-2826.

[205] ZAGORUYKO S, KOMODAKIS N. Wide Residual Networks[C]//WILSON R C, HANCOCK E R, SMITH W A P. British Machine Vision Conference (BMVC). BMVA Press, 2016.

[206] KINGMA D P, BA J. Adam: A Method for Stochastic Optimization[C]//BENGIO Y, LECUN Y. International Conference on Learning Representations (ICLR). 2015.

[207] ALZUBAIDI L, ZHANG J, HUMAIDI A J, et al. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions[J]. Journal of Big Data (J. Big Data), 2021, 8(1): 53.

[208] SONG J, MENG C, ERMON S. Denoising Diffusion Implicit Models[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2021.

[209] BARRATT S T, SHARMA R. A Note on the Inception Score[J]. CoRR, 2018, abs/1801.01973.

[210] BORJI A. Pros and cons of GAN evaluation measures[J]. Computer Vision and Image Understanding (CVIU), 2019, 179: 41-65.

[211] NUNN E J, KHADIVI P, SAMAVI S. Compound Frechet Inception Distance for Quality Assessment of GAN Created Images[J]. CoRR, 2021, abs/2106.08575.

[212] SONG Y, DHARIWAL P, CHEN M, et al. Consistency Models[C]//KRAUSE A, BRUNSKILL E, CHO K, et al. Proceedings of Machine Learning Research: International Conference on Machine Learning (ICML): vol. 202. PMLR, 2023: 32211-32252.

[213] LU C, ZHOU Y, BAO F, et al. DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling in Around 10 Steps[C]//KOYEJO S, MOHAMED S, AGARWAL A, et al. Conference on Neural Information Processing Systems (NeurIPS). 2022.

[214] GU S, CHEN D, BAO J, et al. Vector Quantized Diffusion Model for Text-to-Image Synthesis[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2022:

10686-10696.

[215] GAMA J, ŽLIOBAITĖ I, BIFET A, et al. A survey on concept drift adaptation[J]. ACM computing surveys (CSUR), 2014, 46(4): 1-37.

[216] WEBB G I, HYDE R, CAO H, et al. Characterizing concept drift[J]. Data Mining and Knowledge Discovery, 2016, 30(4): 964-994.

[217] KIRKPATRICK J, PASCANU R, RABINOWITZ N, et al. Overcoming catastrophic forgetting in neural networks[J]. Proceedings of the National Academy of Sciences of the United States of America (PNAS), 2017, 114(13): 3521-3526.

[218] LOPEZ-PAZ D, RANZATO M. Gradient episodic memory for continual learning[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 30. 2017.

[219] VAN DE VEN G M, TOLIAS A S. Three scenarios for continual learning[J]. arXiv preprint arXiv:1904.07734, 2019.

[220] WANG D, SHELHAMER E, LIU S, et al. Tent: Fully Test-Time Adaptation by Entropy Minimization[C]//International Conference on Learning Representations (ICLR). OpenReview.net, 2021.

[221] LIU X, HU Y S, CAO X S, et al. Long-tailed class incremental learning[C]//European Conference on Computer Vision (ECCV). 2022: 495-512.

[222] YUAN L, XIE B, LI S. Robust test-time adaptation in dynamic scenarios[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE Computer Society, 2023: 15922-15932.

[223] ARJOVSKY M, BOTTOU L, GULRAJANI I, et al. Invariant risk minimization[J]. arXiv preprint arXiv:1907.02893, 2019.

[224] TANG K, HUANG J, ZHANG H. Long-tailed classification by keeping the good and removing the bad momentum causal effect[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 33. 2020: 1513-1524.

[225] KUSNER M J, LOFTUS J, RUSSELL C, et al. Counterfactual fairness[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 30. 2017.

[226] KILBERTUS N, ROJAS CARULLA M, PARASCANDOLO G, et al. Avoiding discrimination through causal reasoning[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 30. 2017.

[227] BARTLETT P L, FOSTER D J, TELGARSKY M J. Spectrally-normalized margin bounds for neural networks[C]//Conference on Neural Information Processing Systems (NeurIPS): vol. 30. 2017.

[228] NEYSHABUR B, LI Z, BHOJANAPALLI S, et al. Towards understanding the role of over-parametrization in generalization of neural networks[J]. arXiv preprint arXiv:1805.12076, 2018.

[229] NATARAJAN B K. On Learning Sets and Functions[J]. Machine Learning (MLJ), 1989, 4: 67-97.

附录 A　引理 3.3 的证明 (Liu 等人[91])

证明　将 $\mathcal{D}_{\text{train}}$ 和 $\mathcal{D}'_{\text{train}}$ 展开为 $\mathcal{D}_{\text{train}} = (\boldsymbol{x}^N, y^N, S^N) \in (\mathcal{X}, \mathcal{Y}, \mathcal{S})^N$ 和 $\mathcal{D}'_{\text{train}} = (\boldsymbol{x}'^N, y'^N, S'^N) \in (\mathcal{X}, \mathcal{Y}, \mathcal{S})^N$。可以得到：

$$P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M) = \mathbb{E}\, P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N) \tag{A.1}$$

其中期望 $\mathbb{E}$ 是关于 $(\boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N)$ 的，概率 P 是关于给定特征和真实标签下的候选集分布 (S^N, S'^N) 的。

令 $H|(\boldsymbol{x}^N, \boldsymbol{x}'^N)$ 为在 $\mathcal{D}_{\text{train}}$ 和 $\mathcal{D}'_{\text{train}}$ 上做出不同分类的假设集合。可以得出：

$$\begin{aligned}
&P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N) \\
\leq &\sum_{h \in H|(\boldsymbol{x}^N, \boldsymbol{x}'^N)} P\left(R^{\mathcal{D}_{\text{train}}}(h) = 0, \sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4} \middle| \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N \right)
\end{aligned} \tag{A.2}$$

随机将 $\mathcal{D}_{\text{train}}$ 和 $\mathcal{D}'_{\text{train}}$ 中的实例匹配成 n 对。参照[91]，定义交换群 G。一个交换 $\sigma \in G$ 会交换索引集 $J_\sigma \subseteq \{1, 2, \ldots, n\}$ 中的实例对。$|G| = 2^N, \sigma(\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) = (\mathcal{D}^{\sigma}_{\text{train}}, \mathcal{D}'^{\sigma}_{\text{train}})$。设 a_1, a_2 分别为 h 在 $\mathcal{D}_{\text{train}}$ 和 $\mathcal{D}'_{\text{train}}$ 上分类错误的数量。设 b_1, b_2 分别为 h 在两组数据上都分类错误，以及仅在一组数据上分类错误的数量。

$$\begin{aligned}
&P\left(R^{\mathcal{D}_{\text{train}}}(h) = 0, \sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4} \middle| \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N \right) \\
=&\mathbb{1}\left(\sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4} \right) \cdot \prod_{i=1}^{N} P(h(\boldsymbol{x}_i) = \tilde{y}(\boldsymbol{x}_i, S_i) | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N) \\
=&\mathbb{1}\left(a_2 \geq \frac{\epsilon N}{4} \right) \cdot \prod_{i=1}^{N} P(h(\boldsymbol{x}_i) = \tilde{y}(\boldsymbol{x}_i, S_i) | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N)
\end{aligned} \tag{A.3}$$

接着给出概率项的上界：

$$\prod_{i=1}^{N} P(h(\boldsymbol{x}_i) = \tilde{y}(\boldsymbol{x}_i, S_i) | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N) \leq \prod_{i=1}^{N} P(h(\boldsymbol{x}_i) \in S_i | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N) \leq \eta^{a_1} \tag{A.4}$$

结合公式 (A.1) 和公式 (A.4)，可以得到：

$$
\begin{aligned}
&P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M) \\
=&\mathbb{E}\, P((\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N) \\
=&\mathbb{E}\, \frac{1}{2^N} \sum_{\sigma \in G} P(\sigma(\mathcal{D}_{\text{train}}, \mathcal{D}'_{\text{train}}) \in M | \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N) \\
\leq&\mathbb{E}\, \frac{1}{2^N} \sum_{\sigma \in G} \sum_{h \in H | \sigma(x, \boldsymbol{x}')} P\left(R^{\mathcal{D}_{\text{train}}}(h) = 0, \sum_{i=1}^{N} \mathbb{1}(h(\boldsymbol{x}') \neq y') \geq \frac{\epsilon N}{4} \middle| \boldsymbol{x}^N, y^N, \boldsymbol{x}'^N, y'^N \right) \\
\leq&\mathbb{E}\, (2N)^{d_{\mathcal{H}}} C^{2d_{\mathcal{H}}} \frac{1}{2^N} \sum_{\sigma \in G} \mathbb{1}\left(a_2^\sigma \geq \frac{\epsilon N}{4} \right) \eta^{a_1^\sigma} \\
\leq&\mathbb{E}\, (2N)^{d_{\mathcal{H}}} C^{2d_{\mathcal{H}}} \frac{1}{2^N} \sum_{a_1^\sigma = b_1}^{b_1 + b_2} \mathbb{1}\left(b_1 + b_2 \geq \frac{\epsilon N}{4} \right) C_{b_2}^{a_1^\sigma - b_1} 2^{n - b_2} \eta^{a_1^\sigma} \\
=&\mathbb{E}\, (2N)^{d_{\mathcal{H}}} C^{2d_{\mathcal{H}}} \mathbb{1}\left(b_1 + b_2 \geq \frac{\epsilon N}{4} \right) \eta^{b_1} \left(\frac{1 + \eta}{2} \right)^{b_2}
\end{aligned}
\tag{A.5}
$$

其中第三行利用了不等式 $\left|H|(\boldsymbol{x}^N, \boldsymbol{x}'^N)\right| \leq (2N)^{d_{\mathcal{H}}} C^{2d_{\mathcal{H}}}$[229]。当 $b_1 = 0, b_2 = \frac{\epsilon N}{4}$ 时，右侧达到最大值 $(2N)^{d_{\mathcal{H}}} C^{2d_{\mathcal{H}}} (\frac{1+\eta}{2})^{\frac{\epsilon N}{4}}$。 ■

学术论文和科研成果目录

以（共同）第一作者身份发表或录用的学术论文

[1] 第一作者. Long-Tailed Partial Label Learning via Dynamic Rebalancing, International Conference on Learning Representations (**ICLR, CCF-A 会议**), 2023. [对应学位论文第 3 章]

[2] 第一作者. On Harmonizing Implicit Subpopulations, International Conference on Learning Representations (**ICLR, CCF-A 会议**), 2024. [对应学位论文第 5 章]

[3] 第一作者. Diversified Batch Selection for Training Acceleration, International Conference on Machine Learning (**ICML, CCF-A 会议**), 2024.

[4] 第一作者. Improving Diffusion Models for Class-imbalanced Training Data via Capacity Manipulation, International Conference on Learning Representations (**ICLR, CCF-A 会议, Oral**), 2026. [对应学位论文第 6 章]

[5] 第一作者. Wide-In, Narrow-Out: Revokable Decoding for Efficient and Effective DLLMs International Conference on Learning Representations (**ICLR, CCF-A 会议**), 2026.

[6] 第一作者. Dual-granularity sinkhorn distillation for enhanced learning from long-tailed noisy data, Machine Learning (**MLJ, CCF-B 期刊**), 2026. [对应学位论文第 4 章]

[7] 第一作者. Bag of Tricks for Long-Tailed Multi-Label Classification on Chest X-Rays, ICCV 2023 CVAMD Workshop, 2023.

[8] 第一作者（共同一作，排序第二）. Revive Re-weighting in Imbalanced Learning by Density Ratio Estimation, Advances in Neural Information Processing Systems (**NeurIPS, CCF-A 会议**), 2024.

[9] 第一作者（共同一作，排序第二）. Learning to Instruct for Visual Instruction Tuning, Advances in Neural Information Processing Systems (**NeurIPS, CCF-A 会议**), 2025.

[10] 第一作者（共同一作，排序第二）. Long-tailed Recognition with Model Rebalancing, Advances in Neural Information Processing Systems (**NeurIPS, CCF-A 会议**), 2025.

[11] 第一作者（共同一作，排序第二）. Differential-informed Sample Selection Accelerates Multimodal Contrastive Learning, Proceedings of the IEEE/CVF International Conference on Computer Vision (**ICCV, CCF-A 会议**), 2025.

[12] 第一作者（共同一作，排序第二）. Rejection Mixing: Fast Semantic Propagation of Mask Tokens for Efficient DLLM Inference. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (**CVPR, CCF-A 会议**), 2026.

专利

[1] 第二发明人，“一种用于训练深度神经网络的在线批数据处理方法和设备”，专利申请号 CN202410699534.1

[2] 第三发明人，“基于密度比估计的数据均衡方法、电子设备、存储介质”，专利申请号 CN202411795130.9

[3] 第四发明人, “针对无监督长尾数据的几何校准方法及系统”, 专利申请号 CN202311354561.7

[4] 第四发明人，“一种多域胸片数据处理方法、设备及介质”，专利申请号 CN202311720346.4