上海交通大学博士学位论文

关联噪声下的鲁棒多模态对比学习方法研究

姓　　名:

学　　号:

导　　师:

院　　系: 集成电路学院（信息与电子工程学院）

学科/专业: 信息与通信工程专业

申请学位: 工学博士

2026 年 3 月 30 日

A Dissertation Submitted to

Shanghai Jiao Tong University for the Degree of Doctor

RESEARCH ON ROBUST MULTIMODAL CONTRASTIVE LEARNING APPROACHES UNDER NOISY CORRESPONDENCE

Author:

Supervisor:

School of Integrated Circuits (School of Information Science and Electronic Engineering)

Shanghai Jiao Tong University

Shanghai, P.R. China

March 30th, 2026

摘 要

对比学习范式通过在统一高维空间中精细化对齐不同模态的表征，已成为构建多模态预训练模型深层语义理解与推理能力的核心路径。该范式使得模型能够从图文数据中自动提炼通用的跨模态知识表示，并广泛应用于图文检索、图像描述等下游任务。然而，这一范式高度依赖大规模且精准对齐的高质量数据，而现实场景中的多模态数据却普遍存在文本描述与图像内容不匹配、语义信息不一致的关联噪声问题。此类噪声在训练中引入错误的监督信号，显著削弱了多模态模型的泛化能力与鲁棒性。因此，在不依赖昂贵人工清洗的前提下，有效识别并抑制关联噪声样本的负面影响，已成为多模态对比学习亟待突破的关键瓶颈。

本文聚焦于“关联噪声”这一核心问题，提出了一系列鲁棒对比学习方法。这些方法围绕内源结构建模、外部信息辅助与宏观训练加速三个关键方向，旨在解决由关联噪声问题导致的表征几何结构受损、语义互信息不匹配以及大规模预训练场景下鲁棒性与效率失衡三个核心挑战。本文探索的方法有效降低了多模态模型对高质量数据的强依赖，为在复杂关联噪声场景下实现鲁棒、精准且高效的对比学习提供了系统性的算法范式。具体而言，本文提出以下三项具有代表性的创新算法：

- 针对表征几何结构受损问题，提出一种基于几何结构一致性的关联噪声鲁棒算法。该算法深入剖析多模态数据在跨模态与模态内表征结构的内在联系，挖掘干净样本与噪声样本在几何结构分布上的显著差异并构建了一致性约束。利用深度神经网络的记忆效应，算法设计了自适应的关联噪声指示函数并将其内嵌于对比学习优化目标中，在样本粒度上实现了动态噪声识别与软标签修正，同时辅以动量更新与双网络协同策略以增强判别稳定性。在多个仿真与真实噪声数据集上的实验表明，该算法有效维护了特征空间的几何稳定性，在基准测试集上的检索准确率相较于现有最优基线方法提升最高可达 7.9%。
- 针对语义互信息不匹配问题，提出一种特权信息辅助的关联噪声鲁棒算法。该框架突破了仅依赖内源信息进行自我校正的局限，引入目标检测标签等外部知识作为客观语义锚点，构建了模态间的三角校验机制。通过显式建模特权信息与原始模态的关联概率，有效捕捉细粒度语义错配；并设计了基于置信度的自适应权重融合策略，以规避模型预测不确定性的干扰。在多个仿真与真实噪声数据集上的实验结果显示，该算法具备良好的架构扩展性，且在复杂噪声场景

下使基准测试集的检索准确率相较于现有最优基线方法提升最高可达 6.0%。

- 针对大规模预训练场景下鲁棒性与训练效率失衡的瓶颈，提出一种基于差分信息的样本选择多模态对比学习加速算法。该算法基于深度神经网络的记忆效应，利用模型对不同质量样本记忆趋势的时序差分规律，设计了轻量级的动态筛选策略。该策略能够实时识别高价值样本并精准滤除关联噪声数据，摒弃了对昂贵外部参考模型的依赖，实现了训练收敛加速与表征泛化性能的协同优化。在大规模预训练任务上的评估表明，算法相较于全量数据训练可节省 70% 的计算开销，且在同等训练预算下使下游基准测试集的检索准确率提升达 16.03%。

综上所述，本文系统构建了面向关联噪声场景的鲁棒多模态对比学习方法体系，在提升模型的综合容错能力的同时，兼顾了方法的普适性与高效性。研究成果有效缓解了模型对高质量对齐数据的强依赖，为真实复杂场景下的大规模多模态预训练提供了高效、鲁棒的理论依据与技术支撑。

关键词： 关联噪声，多模态学习，对比学习，鲁棒表征学习，样本选择

Abstract

The contrastive learning paradigm, by achieving fine-grained alignment of representations from different modalities in a unified high-dimensional space, has emerged as a core paradigm for building the deep semantic understanding and reasoning capabilities of multimodal pre-training models. This paradigm enables models to automatically distill universal cross-modal representations from image-text data, and is widely applied to downstream tasks such as image-text retrieval and image captioning. However, this paradigm relies heavily on large-scale and precisely aligned high-quality data, whereas real-world multimodal data inherently suffers from the noisy correspondence problem, characterized by mismatches between text descriptions and image contents, and inconsistent semantic information. Such noise introduces erroneous supervision signals during training, significantly compromising the generalization capability and robustness of multimodal models. Therefore, effectively identifying and mitigating the negative impact of noisy correspondence samples without relying on expensive manual data cleaning has become a critical bottleneck that urgently needs to be overcome in multimodal contrastive learning.

Focusing on the core issue of "noisy correspondence", this thesis proposes a series of robust contrastive learning algorithms. These algorithms revolve around three key directions: internal information structure modeling, external information assistance, and global training acceleration. They aim to resolve three core challenges induced by noisy correspondence: impaired representation geometric structures, semantic mutual information mismatch, and the imbalance between robustness and efficiency in large-scale pre-training scenarios. The methods explored in this thesis effectively reduce the strong reliance of multimodal models on high-quality data, providing a systematic algorithmic paradigm for achieving robust, accurate, and efficient contrastive learning in complex noisy correspondence scenarios. Specifically, this thesis proposes the following three representative innovative algorithms:

- To address the issue of impaired representation geometric structures, a robust noisy correspondence algorithm based on geometrical structure consistency is proposed. This method deeply analyzes the intrinsic connections of multimodal data within cross-modal and intra-modal representation structures, uncovers the significant differences

in geometric structure distributions between clean and noisy samples, and constructs consistency constraints. Leveraging the memorization effect of deep neural networks, the algorithm designs an adaptive noisy correspondence indicator function and embeds it into the contrastive learning optimization objective. This realizes dynamic noise identification and soft-label rectification at the sample level, supplemented by momentum updates and a dual-network collaborative strategy to enhance discrimination stability. Experiments on multiple synthetic and real-world noisy datasets demonstrate that this algorithm effectively maintains the geometric stability of the feature space, yielding an improvement of up to 7.9% in retrieval accuracy on benchmark datasets compared to state-of-the-art baseline methods.

- To tackle the problem of semantic mutual information mismatch, a privileged information assisted robust noisy correspondence algorithm is proposed. This framework overcomes the limitation of relying solely on internal information for self-correction. By introducing external knowledge such as object detection labels as objective semantic anchors, it constructs a triangular verification mechanism among modalities. By explicitly modeling the correspondence probability between privileged information and the original modalities, it effectively captures fine-grained semantic mismatches. Furthermore, a confidence-based adaptive weight fusion strategy is designed to circumvent the interference of model prediction uncertainty. Experimental results on multiple synthetic and real-world noisy datasets show that this algorithm possesses excellent architectural scalability and improves the retrieval accuracy on benchmark datasets by up to 6.0% under complex noisy scenarios compared to state-of-the-art baselines.
- To resolve the bottleneck of the imbalance between robustness and training efficiency in large-scale pre-training scenarios, a differential-informed sample selection multimodal contrastive learning acceleration method is proposed. Based on the memorization effect of deep neural networks, this method exploits the temporal differential patterns of the model's memorization trends for samples of varying qualities to design a lightweight dynamic filtering strategy. This strategy can identify high-value samples in real-time and precisely filter out noisy correspondence data, discarding the reliance on expensive external reference models. It achieves a joint optimization of training convergence acceleration and representation generalization performance. Evaluations on

large-scale pre-training tasks indicate that, compared to full-data training, this method saves 70% of the computational overhead and improves the retrieval accuracy on downstream benchmark datasets by up to 16.03% under the same training budget.

In conclusion, this research systematically builds a robust multimodal contrastive learning system targeting noisy correspondence scenarios, balancing broad applicability and high efficiency while boosting the models' comprehensive noise tolerance. By effectively mitigating the heavy reliance on strictly aligned high-quality data, these outcomes deliver robust theoretical foundations and practical technical support for large-scale multimodal pre-training in complex, real-world applications.

Key words: Noisy Correspondence, Multimodal Learning, Contrastive Learning, Robust Representation Learning, Sample Selection

目 录

第 1 章 绪论 1
1.1 研究背景与意义 1
1.2 研究现状与挑战 3
1.2.1 问题描述 4
1.2.2 研究现状概述 5
1.2.3 主要挑战 7
1.3 主要贡献及组织架构 8
1.3.1 本文主要贡献 9
1.3.2 本文组织结构 10
第 2 章 研究现状 13
2.1 基于噪声修正的鲁棒多模态对比学习方法 14
2.1.1 基于记忆效应的噪声标签学习 14
2.1.2 基于噪声建模的鲁棒多模态对比学习 17
2.1.3 基于特权信息辅助的鲁棒多模态对比学习 21
2.2 基于样本选择的鲁棒多模态对比学习方法 23
2.2.1 基于离线样本选择的鲁棒多模态对比学习 23
2.2.2 基于在线样本选择的鲁棒多模态对比学习 27
2.3 总结 30
第 3 章 基于几何结构一致性的关联噪声鲁棒方法 33
3.1 引言 33
3.2 算法研究 35
3.2.1 符号定义 35
3.2.2 研究动机 36
3.2.3 算法设计 37
3.2.4 讨论与分析 40
3.3 实验验证 41
3.3.1 实验设定介绍 41

3.3.2 主要实验结果 45
3.3.3 消融实验结果 52
3.4 本章小结 60
第 4 章 特权信息辅助的关联噪声鲁棒方法 61
4.1 引言 61
4.2 算法研究 63
4.2.1 符号定义 63
4.2.2 研究动机 64
4.2.3 算法设计 66
4.2.4 讨论与分析 70
4.3 实验验证 71
4.3.1 实验设定介绍 71
4.3.2 主要实验结果 73
4.3.3 消融实验结果 77
4.4 本章小结 89
第 5 章 基于差分信息的样本选择多模态对比学习加速方法 91
5.1 引言 91
5.2 算法研究 93
5.2.1 预备知识 93
5.2.2 研究动机 94
5.2.3 算法设计 98
5.2.4 讨论与分析 101
5.3 实验验证 102
5.3.1 实验设定介绍 102
5.3.2 主要实验结果 103
5.3.3 消融实验结果 109
5.4 本章小结 120
第 6 章 总结与展望 121
6.1 本文总结 121
6.2 未来工作展望 122

参考文献.....125

学术论文和科研成果目录.....143

插 图

图 1.1 关联噪声问题的成因图.....2
图 1.2 关联噪声问题的研究意义与价值.....3
图 1.3 关联噪声问题的相关工作梳理图.....6
图 1.4 关联噪声问题的主要挑战示意图.....7
图 1.5 本文组织结构梳理图..... 10
图 3.1 关联噪声问题对表征几何结构的影响示意图..... 34
图 3.2 基于几何结构一致性识别关联噪声样本..... 36
图 3.3 基于几何结构一致性的关联噪声鲁棒算法框架示意图..... 38
图 3.4 GSC 算法对超参数 γ、β_1、β_2 的敏感性分析 53
图 3.5 GSC 算法对超参数超参数 τ_1、τ_2 的敏感性分析..... 54
图 3.6 GSC 算法的训练可视化分析 57
图 3.7 GSC 算法的权重分布可视化分析 58
图 3.8 GSC 算法识别的 CC152K 数据集关联噪声样本可视化 59
图 4.1 特权信息与模态间关联关系示意图..... 62
图 4.2 特权信息辅助识别关联噪声样本..... 65
图 4.3 噪声识别与置信度融合示意图..... 68
图 4.4 特权信息辅助的关联噪声鲁棒算法框架示意图..... 70
图 4.5 PIAL 算法的训练与判别可视化分析 78
图 4.6 PIAL 算法的权重分布可视化分析 79
图 4.7 PIAL 算法在特权信息部分缺失时的性能比较 80
图 4.8 PIAL 算法对不同特权信息编码器层数的敏感性分析 81
图 4.9 PIAL 算法基于不同主干网络的性能分析 82
图 4.10 PIAL 算法对不同训练批次大小的敏感性分析..... 83
图 4.11 PIAL 算法在不同特权信息噪声水平下的性能分析..... 84
图 4.12 PIAL 算法对超参数 γ、β_1、β_2 的敏感性分析..... 84
图 4.13 PIAL 算法识别的不同数据集关联噪声样本可视化..... 87
图 4.14 PIAL 算法应用于现有鲁棒算法的通用性分析..... 88
图 5.1 关联噪声问题与基于差分信息的样本选择加速算法..... 92

图 5.2 不同的样本选择策略在不同选择比例下的性能对比..... 95
图 5.3 对比学习训练不同训练阶段的 CLIPScore 分布..... 96
图 5.4 对比学习视角下的记忆效应..... 97
图 5.5 DISSect 算法的样本选择策略可视化.....112
图 5.6 DISSect 算法的样本选择准确率可视化.....113
图 5.7 DISSect 应用于 GSC 与 PIAL 加速效果分析.....115
图 5.8 DISSect 在不同选择率下的性能分析.....116
图 5.9 DISSect 对超参数的敏感性分析.....118
图 5.10 DISSect 算法识别的 CC152K 数据集关联噪声样本可视化 119

表 格

表 3.1 关联噪声基准数据集的统计信息 43
表 3.2 GSC 与各算法在 Flickr30K 和 MS-COCO 上的检索性能比较 46
表 3.3 GSC 与各算法在 NUS-WIDE 上的检索性能比较 47
表 3.4 GSC 与各算法在 CC152K 上的检索性能比较 48
表 3.5 GSC 与现有算法在 MSR-VTT 与 MSVD 上的检索性能比较 49
表 3.6 GSC 与预训练模型 CLIP 在 MS-COCO 上的检索性能比较 50
表 3.7 GSC 与离线数据清洗方法 CapFilt 在 Flickr30K 上的检索性能比较 50
表 3.8 GSC 算法的稳定性分析 51
表 3.9 GSC 算法各部分设计的消融实验 52
表 3.10 GSC 算法对批次大小的敏感性分析 55
表 3.11 GSC 算法基于 SGRAF 主干网络实验结果 56
表 4.1 PIAL 与各算法在 MS-COCO 与 NUS-WIDE 上的检索性能比较 74
表 4.2 PIAL 与各算法在 CC152K 上的检索性能比较 75
表 4.3 PIAL 与预训练模型 CLIP 在 MS-COCO 上的检索性能比较 76
表 4.4 PIAL 与离线数据清洗方法 CapFilt 在 MS-COCO 上的检索性能比较 77
表 4.5 PIAL 算法各部分设计的消融实验 78
表 4.6 PIAL 与各算法在复杂语义关联噪声下的性能比较 86
表 4.7 PIAL 算法的计算开销分析 89
表 5.1 DISSect 与各算法在 CC3M 上预训练的检索性能比较 104
表 5.2 DISSect 与各算法在 CC12M 和 YFCC15M 上预训练的检索性能比较 106
表 5.3 DISSect 与现有算法在 MSR-VTT 与 MSVD 上的检索性能比较 107
表 5.4 DISSect 与各算法在不同下游任务上的性能比较 108
表 5.5 DISSect 算法的稳定性分析 109
表 5.6 DISSect 与各算法基于不同主干网络的性能比较 110
表 5.7 DISSect 与现有算法在仿真噪声数据集上的检索性能对比 111
表 5.8 DISSect 与各关联噪声鲁棒算法的检索性能比较 114
表 5.9 DISSect 算法的训练效率分析。 117

算 法

算法 3.1 基于几何结构一致性的关联噪声鲁棒对比学习算法..... 41
算法 4.1 特权信息辅助的关联噪声鲁棒学习算法流程..... 71
算法 5.1 基于预热策略的 DISSect 算法流程 101
算法 5.2 基于时间集成策略的 DISSect 算法流程 102

第 1 章 绪论

1.1 研究背景与意义

随着人工智能从单一感知智能向多媒体认知智能演进，多模态表征学习已成为连接视觉、语言与听觉等异构信息的关键枢纽。在此进程中，对比学习凭借其卓越的表征解耦与语义对齐能力，逐渐取代传统监督式方法，成为多模态模型预训练的主流范式[1-2]。不同于受限于预定义类别的传统监督学习，对比学习范式致力于在统一特征空间内构建视觉与语言的深层语义关联，使模型能够实现异构模态表征的精细化对齐并构建良好的跨模态通用表示。该模式赋予了模型在开放世界场景下出色的泛化能力与零样本推理能力。以 CLIP[3]为代表的里程碑式工作不仅在零样本分类[4-5]、跨模态检索[6-7]、视觉问答[8-9]等任务上取得了突破性进展，更为构建具备通用理解能力的下一代人工智能系统奠定了坚实的技术基石。

然而，多模态对比学习的卓越性能高度依赖于训练数据的规模效应。为覆盖开放世界中包罗万象的语义概念，现有的预训练模型通常需从互联网获取数以亿计的图文数据。这种对海量数据的需求迫使研究者在数据收集过程中不得不以牺牲数据质量为代价换取规模，导致现实场景下的多模态数据普遍面临“关联噪声”的严峻挑战。如图 1.1所示，受限于现实环境中各类不可控因素的干扰，异构模态间的数据关联呈现出错综复杂的噪声形态。大规模数据集往往依赖搜索引擎自动抓取或众包标注，前者基于弱相关性的关键词匹配，后者难免存在人为认知偏差，导致图像内容与文本标签频繁错配；出于隐私保护考量的模糊化或脱敏处理，常致使原始数据的语义完整性受损，引发语义断层或关联失效；在资源受限的采集环境下，受限于传输带宽与存储成本，数据常存在丢帧或时间戳对齐误差，从物理层面引发模态间的时序错位。更为根本的是，视觉模态通常包含丰富稠密的细粒度细节，而文本描述往往是稀疏抽象的概括，这种天然的信息熵差致使文本难以完全覆盖图像内容，从而在特征空间中形成固有的语义不匹配。对于依赖严格正负样本界定的对比学习而言，上述多源噪声会导致跨模态语义对齐偏差，破坏特征空间的结构分布，并引发模型对噪声模式的过拟合，严重削弱其在下游任务中的鲁棒性与泛化能力。如何在保证数据规模的前提下，有效应对复杂成因带来的关联噪声冲击，已成为该领域亟待解决的核心挑战。

面对海量且嘈杂的互联网数据，传统的离线数据清洗与基于规则的静态过滤策略日益显露出局限性。一方面，离线清洗依赖复杂的先验假设或高昂的计算开销，难

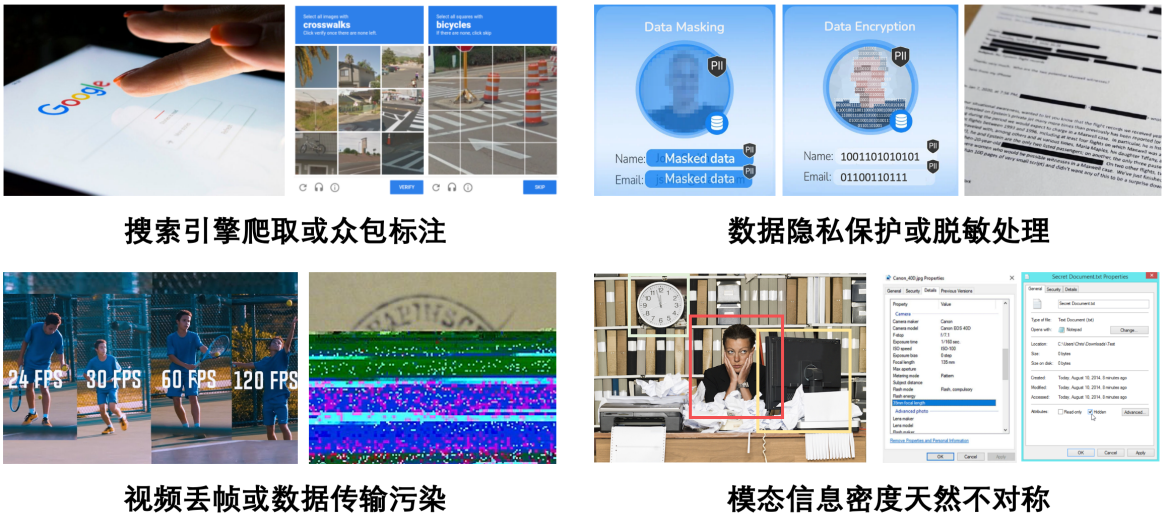

图 1.1　现实世界中导致关联噪声问题的成因展示图。关联噪声问题可能由于搜索引擎爬取或众包标注质量低下、数据隐私保护或脱敏处理、视频丢帧或数据传输污染与模态信息密度天然不对称等原因导致。

Figure 1.1　Illustration of the causes of the real-world noisy correspondence problem. The noisy correspondence problem can be caused by factors such as low-quality search engine crawling or crowdsourced annotations, data privacy protection or anonymization processes, video frame dropping or data transmission corruption, and the inherent asymmetry in information density across different modalities.

以适应数据规模的指数级增长；另一方面，静态的过滤阈值难以在去噪与保留多样性之间取得平衡，极易误删蕴含丰富语义的难样本，反而限制了模型的泛化边界[10-11]。因此，本研究聚焦于突破离线清洗的局限，核心目标旨在探索一种能够内嵌于对比学习训练全过程、自适应地识别并抑制关联噪声负面影响的端到端鲁棒学习机制，从而在无需昂贵人工标注清洗的前提下，实现从海量噪声数据中提取关联语义互信息，以构建高性能、强鲁棒的多模态预训练模型。

针对上述问题开展深入研究，不仅在理论上能够完善多模态表征学习在非理想数据条件下的鲁棒性范式，更在实际应用层面具有深远的价值与意义。如图 1.2所示，关联噪声下的鲁棒多模态对比学习的价值维度，主要体现在以下三个关键层面：

- **关键领域的可靠性保障：**在医疗影像诊断、自动驾驶感知等安全攸关的领域，训练数据中微小的噪声往往会导致模型产生灾难性的认知偏差。构建对关联噪声鲁棒的多模态模型，能够从算法底层抑制错误关联信号的干扰，确保模型在复杂开放环境中的决策准确性，是提升智能系统可信度与安全性的根本保障。
- **数据经济性的合理利用：**鲁棒的学习算法能够打破高性能模型对高质量标注数据的依赖，使得人工智能系统能够直接利用互联网上海量且低成本的原始图文

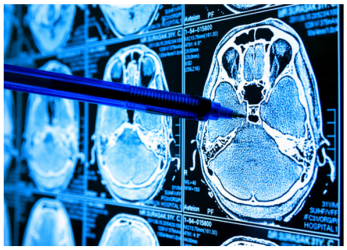

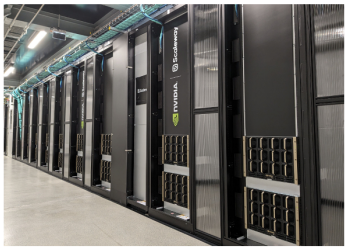

关键领域的可靠性保障 **数据经济性的合理利用** **高效训练与可持续发展**

图 1.2 关联噪声下的鲁棒多模态对比学习研究的价值与意义展示图，为关键领域可靠性保障、数据经济性合理利用、高效训练与可持续发展赋能。

Figure 1.2 Illustration of the value and significance of research on robust multimodal contrastive learning addressing noisy correspondence, which empowers reliability assurance in critical fields, rational utilization of data economy, efficient training, and sustainability.

资源。这将显著降低多模态预训练的门槛，推动 AI 技术从依赖精细化人工标注的作坊式生产，向直接利用大规模网络数据的工业化范式转变，极大程度上挖掘了海量非结构化数据的潜在价值。

- **高效训练与可持续性发展：**从算力经济的角度来看，有效地识别并剔除噪声数据能够避免模型在无效或有害样本上浪费宝贵的梯度更新与计算存储资源，突破了海量噪声数据下模型训练效率的瓶颈。这不仅契合当前绿色 AI 与高效训练的发展趋势，也为在资源受限的边缘设备上部署持续学习系统提供了理论与技术支撑。

综上所述，尽管多模态对比学习已成为连接异构数据的核心范式，但传统的主流算法在面对现实场景中广泛存在的复杂关联噪声时，仍面临着训练鲁棒性缺失与去噪效率低下的双重困境。针对这一关键技术瓶颈，本研究致力于构建一套关联噪声下的鲁棒多模态对比学习方法体系，旨在打破离线清洗的局限，从理论上解答如何在非理想数据条件下实现高效能表征学习的科学问题，更为构建低成本、高可靠、绿色高效的下一代多模态人工智能系统提供重要的理论依据与技术支撑，具有显著的学术价值与广泛的应用前景。

1.2 研究现状与挑战

关联噪声下的鲁棒多模态方法建立于经典机器学习中的一个重要研究问题，即噪声标签学习问题在多模态场景下的新形态。受到不同模态的复杂关系与噪声种类的多样性影响，该研究依然面临诸多挑战和难点。本章将首先对多模态场景下的关联

噪声问题进行形式化定义，继而回顾国内外相关研究发展现状与解决方案，最后探讨在该问题下的主要挑战。

1.2.1　问题描述

关联噪声是指多模态数据中潜在的图文不匹配问题，该问题下的鲁棒对比学习方法通常构建于双塔架构的深度神经网络之上，其核心旨在从含噪训练数据中识别并抑制噪声样本的负面干扰，从而赋予模型良好的鲁棒性与稳定的优化过程。鉴于视觉-语言（图文）模态为当前多模态大模型最核心且应用最广的模态组合，在不损害泛化性的前提下，本文的方法讨论与实验验证均将以此类多模态场景为主要切入点。本节将从以下几个层面具体展开介绍：

- **关联噪声训练数据集：**在关联噪声场景下，定义数据集为 $\mathcal{D} = \{X_1^i, X_2^i, \hat{y}^i\}_{i=1}^N$，其中 N 表示样本总数，$\{X_1^i, X_2^i\}$ 是第 i 个成对的多模态样本（如成对的图像与文本模态）。$\hat{y}^i$ 为观察到的关联指示标签，用于描述图像 X_1^i 与文本 X_2^i 之间是否相互匹配。训练数据集通常假定给定数据对的不同模态是相互匹配的，即观测到的关联标签 $\hat{y}^i$ 恒为 1。然而，受到关联噪声影响，该标签常常带噪，无法反映模态之间潜在的真实关联 y^i。一份带有关联噪声的训练数据集质量可以由噪声率（Noise Ratio, NR）反映，该噪声率的定义为：

$$\mathrm{NR} = \frac{\sum_i \mathbb{I}(\hat{y}^i \neq y^i)}{N} \tag{1.1}$$

  其中 $\mathbb{I}$ 为指示函数。该指标量化了训练数据中含有噪声数据的百分比，使用较高噪声率的训练数据集会严重影响模型的训练，导致模型预测精度下降。

- **对比学习优化目标：**在对比学习范式下，标准的多模态模型分别利用图像编码器 f 与文本编码器 g 将图像与文本模态映射到一个共享的表征空间中，得到 $x_1^i = f(X_1^i)$ 与 $x_2^i = g(X_2^i)$，并利用余弦函数或推理模块计算跨模态表征之间的相似度 $\langle x_1^i, x_2^i \rangle$。传统对比学习的优化目标可以表述为：

$$\min_{\theta_f, \theta_g} \mathbb{E}_{(X_1^i, X_2^i, \hat{y}^i) \in \mathcal{D}} [\mathcal{L}\langle x_1^i, x_2^i \rangle] \tag{1.2}$$

  其中 θ_f, θ_g 为模型图像与文本编码器的训练参数，$\mathcal{L}$ 为对比学习损失函数。

- **关联噪声优化目标：**关联噪声下的鲁棒多模态对比学习的目标为预测潜在的真实模态间关联标签 $y^i \in [0, 1]$，该标签通常被建模为连续的软标签，以精确表征模态间可能存在的细粒度关联程度。基于关联噪声标签修正后的对比学习优化

目标可以表达为：

$$\min_{\theta_f,\theta_g} \mathbb{E}_{(x_1^i,x_2^i,\hat{y}^i)\in\mathcal{D}}[\mathcal{L}\langle x_1^i, x_2^i, y^i\rangle] \tag{1.3}$$

基于预测的关联标签 y，鲁棒算法可将其作为权重作用于样本级损失函数，或作为样本筛选的依据。这一机制确保了多模态预训练模型在复杂噪声场景下的应用价值，具体体现在以下三个方面：

- 鲁棒性：抑制关联噪声样本产生的错误监督信号，提升整体泛化性能。
- 经济性：降低模型对大规模高质量标注数据的依赖，削减数据标注成本。
- 高效性：避免模型在冗余的噪声数据上浪费计算资源，提升训练收敛效率。

1.2.2 研究现状概述

近年来，对比学习技术在多模态表征学习领域取得了突破性进展。以 CLIP[3] 为代表的预训练模型证明，仅依赖自监督学习即可从海量图文数据中获取高度对齐的跨模态语义互信息。然而，该范式对数据规模的高度依赖与现实网络数据普遍存在的关联噪声问题形成了显著矛盾。面对大规模数据集中图像与文本语义错配、弱相关等挑战，现有的研究工作主要沿着基于噪声修正的鲁棒对比学习与基于样本选择的鲁棒对比学习两个方向展开，如图 1.3所示。前者侧重于在保持数据规模的前提下，通过设计鲁棒机制识别并修正错误的关联软标签，从而抑制关联噪声对模型优化的负面影响；后者则致力于从原始数据中筛选高质量样本并剔除低质量冗余数据，旨在利用更少更优的高质量数据进行训练以实现模型鲁棒性与高效性的良好平衡。

在基于噪声修正的鲁棒对比学习方面，研究者致力于设计能够识别或纠正错误标签的机制。早期的探索深受单模态领域深度神经网络记忆效应的启发[12-13]，利用模型在训练早期优先拟合干净模式的特性来区分噪声。随着研究深入，针对多模态数据的异构特性，学术界发展出了基于一致性建模与不确定性建模的主流方法。基于一致性建模的方法假设对于输入数据的微小扰动，鲁棒模型应保持具有一致性的预测，并通过多视图或多网络的预测一致性来识别关联噪声样本并修正关联标签，其中代表性的方法包括 NCR[14]、BiCro[15]、CREAM[16]等；基于不确定性建模的方法则引入证据学习或概率分布估计，通过量化样本的认知不确定性或模型的置信度来动态调整样本的学习权重，代表性方法包括 DECL[17]、UCPM[18]、CRCL[19]等。此外，为了突破仅依赖数据内部信息的局限，近期的一些研究开始探索引入特权信息辅助的策略，即利用外部知识作为语义锚点，构建模态间的校验机制以辅助噪声识别。如 MRL[20]、ELRCMR[21]等方法通过引入额外辅助标签依靠聚类信息实现鲁棒跨模态哈

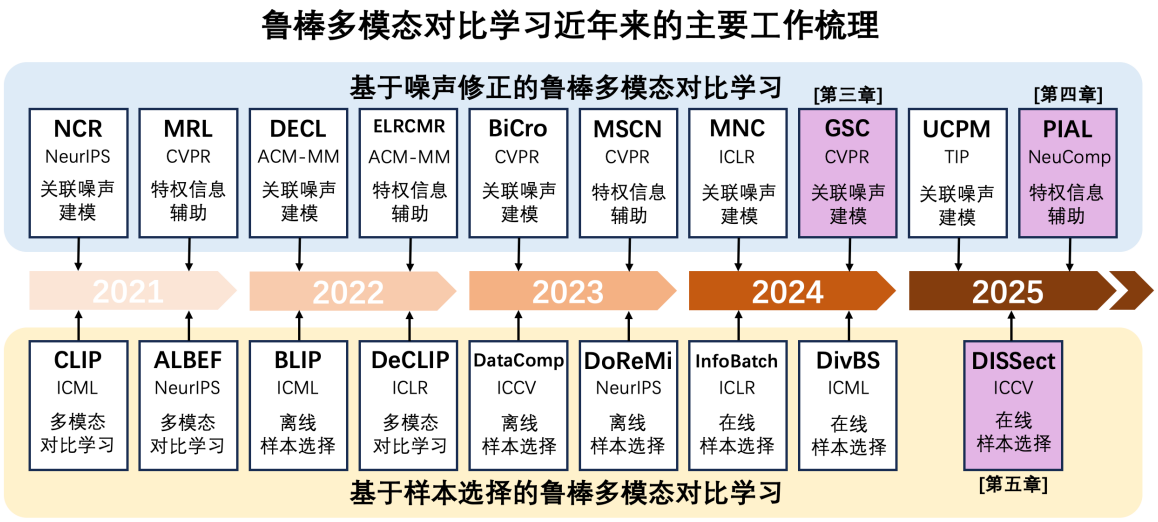

图 1.3　鲁棒多模态对比学习近年来主要的代表工作梳理时间线图。根据发展时间，从基于噪声修正与基于样本选择的鲁棒多模态对比学习方法两方面进行梳理，并介绍方法核心思想。
Figure 1.3　Timeline of representative works in robust multimodal contrastive learning in recent years. This figure chronologically reviews the methods from two main perspectives: noise correction-based and sample selection-based approaches, highlighting the core concepts of each method.

希检索；MSCN[22]、MSIAN[23]、SURE[24]等方法则利用额外的干净关联数据子集基于元学习实现对关联噪声样本的精准识别。

在基于样本选择的鲁棒对比学习方面，现有工作旨在通过优化数据输入分布，在挑选高质量数据的同时筛除低质量冗余样本，从而提升模型性能表现与训练效率，主要分为离线样本选择与在线样本选择两类。离线样本选择通常在训练前对数据进行预处理，旨在降低训练启动的门槛：其中，基于核心集裁剪的方法致力于根据几何分布、训练动力学或参考模型评分从原始数据中识别并保留具有高代表性的价值子集，代表性工作包括 DataComp[25]、SemDeDup[26]、Herding[27]等；基于数据蒸馏的方法则试图通过信息压缩合成极少量的样本以逼近全量数据的训练效果，主要工作包括 Dataset Condensation[28]、MTT[29]等。然而，离线方法难以适应模型训练过程中的状态变化，因此在线样本选择结合训练动态实时调整采样策略：基于课程学习的方法遵循固定先验的认知规律，利用损失值或密度分布动态调整样本权重以避免模型过早拟合噪声，如 SPL[30]、CurriculumNet[31]等；为了增强模型的判别能力，基于难样本挖掘的方法侧重于聚焦高预测误差样本以修正决策边界，典型方法涵盖 OHEM[32]、Focal Loss[33]、VSE++[34]等；此外，从优化理论的视角出发，基于重要性采样的方法

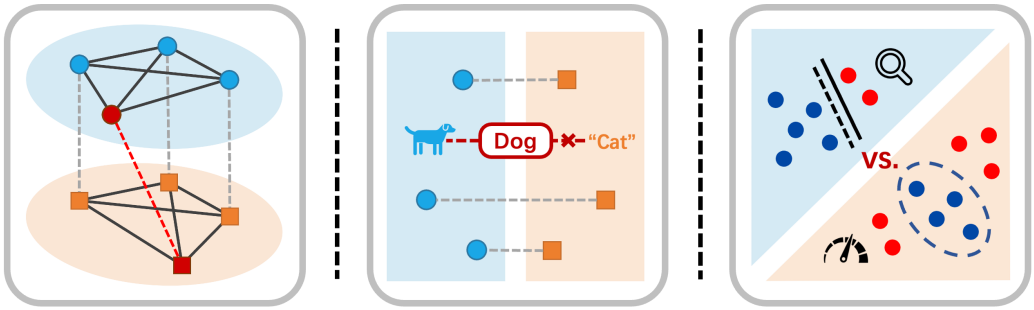

图 1.4 关联噪声下的鲁棒多模态对比学习研究面临的主要挑战示意图，分别对应表征几何结构受损、语义互信息不匹配与大规模预训练场景下的鲁棒性与效率失衡问题。

Figure 1.4 Illustration of the main challenges in robust multimodal contrastive learning addressing noisy correspondence, corresponding respectively to damaged representation geometric structures, semantic mutual information mismatch, and the imbalance between robustness and efficiency in large-scale pre-training scenarios.

则通过非均匀采样策略减小梯度估计方差以加速收敛，代表性工作包括 InfoBatch[35]、DivBS[36]等。

综上所述，当前的多模态对比学习研究，正处于从单纯追求规模转向追求质量与效率并重的转型期。虽然现有的基于噪声修正的方法在识别关联噪声方面取得了显著进展，但在处理复杂的语义混淆时仍面临挑战；而基于样本选择的方法虽能兼顾效率，但在复杂关联噪声分布下的筛选准确性仍有待提升。因此，本文将针对关联噪声问题，从噪声修正与样本选择两方面出发开展理论探索与算法创新，为关联噪声下的鲁棒多模态对比学习的研究提供新的思路。

1.2.3 主要挑战

本文探讨的关联噪声下的鲁棒多模态对比学习问题，面临多个复杂的挑战，如图 1.4所示。具体可以从以下几个方面进行分析和总结：

- 首先，是**关联噪声导致的表征几何结构受损问题**。对比学习范式依赖高质量的关联数据在高维空间中构建紧凑且具备判别性的几何结构。然而，广泛存在的关联噪声不仅引入了错误的监督信号，更对多模态表征的几何结构造成了双重破坏：在跨模态视角下，语义无关的关联噪声样本被强制拉近，导致异构特征对齐发生偏移；在模态内视角下，这种错误的对齐约束迫使原本语义相似的聚类关系发生扭曲与离散化，破坏了数据内在的邻域相似度一致性。现有的鲁棒

方法大多仅聚焦于修正跨模态的相似度分布，往往忽视了模态内结构对噪声识别的关键辅助作用。因此，如何在全局视角下挖掘并利用跨模态与模态内表征结构的不一致性，以精准识别关联噪声样本并维持特征几何的稳定性，是实现鲁棒的多模态对比学习的首要挑战。

- 其次，是**关联噪声导致的语义互信息不匹配问题**。在理想的多模态数据对中，图像与文本模态应当共享丰富的语义互信息，但在关联噪声场景下，这种语义互信息存在显著的错配。现有的鲁棒学习方法大多局限于挖掘数据的内源信息，即单纯依赖模型自身的预测分布或置信度来区分样本。这种自我监督式的判别模式极易受到模型固有认知偏差的影响：模型倾向于优先拟合简单模式，从而难以准确区分富含语义信息的难样本与真实的噪声样本，导致有价值的难样本被错误丢弃，或在简单样本上发生过拟合。在受污染的数据闭环内进行自我校正难以从根本上纠正深层的语义错配。因此，如何在内源信息不足以支撑精准判别的情况下，有效引入“特权信息”辅助建模模态间的语义互信息关联，构建独立于当前数据视角的客观校验机制，从而打破认知偏差并精准识别关联噪声样本，是提升模型鲁棒性的重要挑战。
- 最后，是**大规模训练场景下的鲁棒性与效率失衡问题**。随着预训练数据规模不断扩大，传统的鲁棒学习算法面临着严峻的效率瓶颈。现有的鲁棒方法普遍基于双网络协同训练，往往伴随着双网络维护或多次反向传播计算，导致训练时间成倍增加。另一方面，简单的随机采样或静态过滤策略虽然高效，却容易忽视噪声问题或丢弃包含重要信息的难样本，导致模型性能受限。目前领域内缺乏一种既能利用训练动态实时感知样本价值，又能高效筛除噪声与冗余样本的机制。如何在保证模型对关联噪声鲁棒性的同时，通过智能的样本选择策略大幅降低训练成本，打破鲁棒性与高效性之间的零和博弈，是推动多模态大模型走向实际应用的关键挑战。

1.3　主要贡献及组织架构

为了解决关联噪声场景下导致的表征几何结构受损、语义互信息错配以及大规模训练场景下的鲁棒性与效率失衡问题等关键问题，本文系统性地分析了问题的根源并设计了一系列算法。首先，本文提出了基于几何结构一致性的关联噪声鲁棒方法，通过识别跨模态与模态内表征几何结构不一致实现精准识别噪声样本；其次，本文提出了特权信息辅助的关联噪声识别方法，通过引入特权信息建模模态间语义互

信息辅助识别噪声样本；最后，本文提出了基于差分信息的样本选择多模态对比学习加速方法，通过判断模型对样本记忆趋势，动态挑选高质量样本进行学习。这些方法增强了多模态模型在预训练过程中对噪声匹配的鲁棒性，并进一步扩展了噪声鲁棒方法在现实大规模场景的实用性。

1.3.1 本文主要贡献

文本的主要贡献如下：

- 针对关联噪声导致的表征几何结构受损问题，提出了一种基于几何结构一致性的关联噪声鲁棒算法。该方法深入挖掘了多模态数据在特征空间中跨模态与模态内结构分布的内在联系，构建了跨模态与模态内几何结构一致性的双重约束机制。利用深度神经网络的记忆效应，该算法量化了干净样本与噪声样本在几何结构一致性上的分布差异，设计了自适应的关联噪声指示函数。通过将该指示函数内嵌于对比学习的优化目标中，实现了样本粒度的动态噪声识别与软标签修正，在不依赖额外人工标注的前提下，有效维护了特征空间的几何稳定性，显著提升了模型在高噪声率场景下的表征判别能力与鲁棒性。（第三章）
- 针对关联噪声导致的语义互信息不匹配问题，提出了一种特权信息辅助的关联噪声鲁棒算法。该框架突破了仅依赖数据内源信息进行自我校正的局限性，创新性地引入如目标检测标签或描述性文本等特权信息作为客观的语义锚点，构建了模态间的三角校验机制。通过显式建模特权信息与原始模态之间的关联概率，该方法能够辅助捕捉细粒度的语义错配。同时，为了应对关联标签预测可能存在的不确定性，设计了基于置信度的自适应权重融合策略，根据多视角的预测确定性动态调整监督信号。该机制有效填补了异构模态间的语义鸿沟，在复杂噪声场景下显著提升了对难样本与噪声样本的区分精度及模型的泛化性能。（第四章）
- 针对海量关联噪声数据下鲁棒性与训练效率失衡的瓶颈，提出了一种基于差分信息的样本选择多模态对比学习加速方法。该方法基于深度神经网络的记忆效应，揭示了模型对干净样本与噪声样本在记忆趋势上的显著差异。基于此发现，设计了一种轻量级的差分信息样本筛选策略，通过实时监测训练过程中样本拟合程度的时序差分变化，动态识别出对模型优化贡献度高的高价值样本，并高效滤除由于语义错配导致的无效数据。该算法摒弃了传统方法对昂贵外部参考模型的依赖，在保证模型对齐性能优于全量数据训练基准的同时，大幅降低了计算资源消耗，实现了样本质量筛选与模型训练加速的协同优化。（第五章）

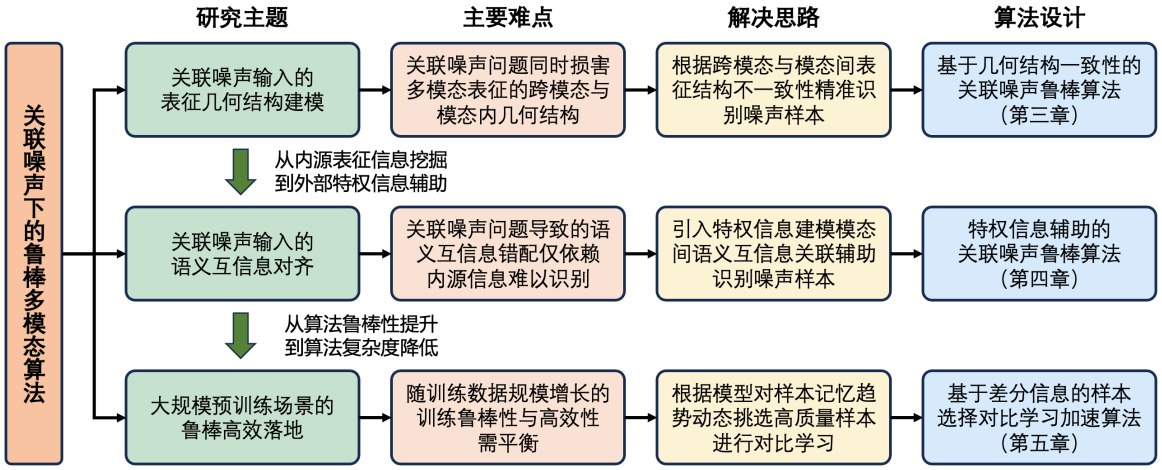

图 1.5　本文的组织结构梳理图。具体从研究主题、主要难点、解决思路与算法设计四个角度展现本文不同章节之间的逻辑结构关系。

Figure 1.5　The organizational structure of this thesis. It illustrates the logical relationships among different chapters from four perspectives: research topics, key challenges, proposed solutions, and algorithm designs.

1.3.2　本文组织结构

本文总共分为六章，整体工作的组织结构如图 1.5所示，下面对每一章的具体内容进行概括性阐述：

- 第一章为绪论部分，主要介绍了关联噪声下的鲁棒多模态对比学习的研究背景与科学意义，给出了该问题的具体定义，并讨论了该领域面临的核心问题与关键挑战。此外，本章还从整体上概述了论文的主要内容、贡献以及整体结构。
- 第二章系统回顾了关联噪声下的鲁棒多模态对比学习相关领域的最新研究进展。主要从基于噪声修正的鲁棒多模态对比学习与基于样本选择的鲁棒多模态对比学习两个方面展开，详细阐述了近年来相关工作的核心思路与方法。
- 第三章开展了基于几何结构一致性的关联噪声鲁棒算法研究。针对关联噪声导致多模态表征在跨模态与模态内几何结构受损的问题，本章提出了一种几何结构一致性驱动的鲁棒学习方法。该方法深入挖掘干净样本与噪声样本在跨模态与模态内几何结构分布上的显著差异，构建了结构一致性约束机制。通过设计自适应的关联噪声指示函数并将其内嵌于对比学习目标中，实现了对噪声样本的动态识别与软标签修正，在不依赖额外人工标注的前提下，提升了模型在仿真与真实关联噪声场景下的鲁棒性，并在一系列下游检索任务中取得显著提升。
- 第四章开展了特权信息辅助的关联噪声鲁棒算法研究。针对仅依赖数据内源信

息难以精准识别复杂语义错配及细粒度噪声的难题，本章提出了一种特权信息辅助的鲁棒学习框架。该框架引入如目标检测标签等外部知识作为客观语义锚点，通过显式建模特权信息与原始模态间的关联概率来辅助噪声判别。同时，设计了基于置信度的自适应权重融合策略，根据多视角的预测确定性动态调整监督信号，有效解决了语义鸿沟问题，在复杂关联噪声数据上实现了超越现有方法的泛化性能。

- 第五章开展了基于差分信息的样本选择多模态对比学习加速算法研究。针对大规模噪声数据预训练场景下模型鲁棒性与训练效率难以兼顾的瓶颈，本章提出了一种基于差分信息的样本选择加速算法。该方法基于深度神经网络的记忆效应，利用样本拟合程度在时序上的差分变化规律来评估数据质量。通过设计轻量级的差分信息筛选策略，在无需昂贵外部参考模型辅助的情况下，高效识别高价值样本并滤除无效关联噪声样本，实现了模型训练加速与表征对齐性能的协同优化。
- 第六章对全文的主要研究内容和创新贡献进行了系统总结，并从关联噪声问题的理论延伸、算法设计以及应用拓展三个层面，展望了未来发展方向。

第 2 章 研究现状

多模态表征学习[37-38]已成为连接视觉与语言等异构信息的关键纽带。其中，对比学习范式凭借卓越的跨模态语义对齐能力，逐渐取代传统方法[39-40]，确立了视觉语言预训练领域的主流地位，有力推动了零样本分类、跨模态检索及视觉问答等下游任务的突破性进展，并成为当前构建多模态大模型的核心基石[41-42]。然而，该范式高度依赖图文关联准确的理想化数据假设。现实应用中为满足数据规模而进行的大规模网络爬取，不可避免地引入了“关联噪声”问题，即图像内容与文本描述之间存在语义错配或弱相关现象[14]。此类噪声严重破坏了多模态表征学习的一致性，导致错误对齐并引发模型过拟合，已成为制约预训练模型性能的关键瓶颈。

针对数据含噪的现实约束，关联噪声下的鲁棒多模态对比学习旨在构建既具备抗噪鲁棒性又兼顾训练高效性的学习算法。现有的研究工作已形成多维度的技术体系，根据技术路径的不同，主要可划分为基于噪声修正的鲁棒对比学习与基于样本选择的鲁棒对比学习两类。前者侧重于在保持数据规模的前提下，通过设计鲁棒机制识别并修正错误的关联信号，旨在精准预测关联软标签以实现去噪，从而在噪声环境中学习到正确的表征对齐[43]；后者则致力于从原始数据中筛选高质量样本并剔除低质量冗余数据，旨在利用更少的数据和计算成本实现模型鲁棒性与训练效率的平衡[44]。这两类方法从不同视角解决真实世界数据关联噪声问题，共同构成了当前鲁棒多模态学习的研究主体。

在基于噪声修正的鲁棒对比学习方面，研究重点在于利用数据内在特性或外部辅助信息来纠正错误的监督信号。该类方法的理论基础多源于深度神经网络的“记忆效应”，即模型在训练初期优先拟合简单模式而非噪声的特性，这一现象在单模态噪声标签学习中已被广泛验证与应用。在此基础上，针对多模态数据的异构特性，学术界发展出了基于噪声建模的策略，通过一致性约束或不确定性建模来动态调整样本的关联目标。此外，为了突破仅依赖数据内部信息的局限，近期的研究开始探索引入特权信息辅助的策略，即利用外部知识作为语义锚点，构建模态间的校验机制以辅助噪声识别与标签修正，从而提升模型在复杂噪声环境下的判别能力。

在基于样本选择的多模态高效学习方面，现有工作旨在通过优化数据输入分布提升模型性能表现与训练效率，主要分为离线样本选择与在线样本选择两类。离线样本选择通常在训练前对数据进行预处理，利用预训练的参考模型或特定规则对原始

数据进行清洗与核心集构建，以降低训练启动的门槛与成本。然而，离线方法难以适应模型训练过程中的状态变化，因此在线样本选择结合训练动态实时调整采样策略。该类方法通过监测样本的损失值、梯度范数或拟合程度，动态识别出对模型优化贡献度高的高价值样本，并高效滤除低质量噪声样本，实现了样本质量筛选与模型训练加速的协同优化。

2.1　基于噪声修正的鲁棒多模态对比学习方法

2.1.1　基于记忆效应的噪声标签学习

2.1.1.1　深度学习模型的记忆效应

在深度学习的有监督范式[45]中，训练数据的质量对模型的泛化性能起着决定性作用。然而，现实场景中的大规模数据集往往不可避免地包含标签噪声。针对噪声标签学习（Noisy Label Learning, LNL）问题[46-47]，传统单模态领域已进行了广泛而深入的研究[48-49]。早期的解决方案主要包括设计对噪声不敏感的鲁棒损失函数[50-52]、构建噪声转移矩阵以修正损失[53-55]、以及基于正则化技术的抗噪方法[56-58]等。然而，这些方法通常依赖于对噪声率的先验假设或引入额外的超参数[49,59]，难以适应复杂多变的真实噪声环境。相比之下，基于“记忆效应”（Memorization Effect）的方法[60-61]因其无需额外干净数据且能适应不同噪声分布的特性，成为了当前处理噪声标签问题的主流且最为有效的范式。该类方法并不试图直接修改优化目标，而是利用深度神经网络内在的训练时特性，从带噪数据中区分出干净样本与噪声样本，从而实现鲁棒学习。

深度学习模型的记忆效应，通过对模型训练过程的微观观察，揭示了神经网络在拟合数据时呈现出的显著时间规律。具体而言，深度神经网络在训练初期倾向于优先学习数据集中简单、普遍且具有共享语义的模式；随着训练的深入，当模型逐渐拟合了主要的数据分布后，才会利用其余下的容量去强行记忆那些复杂的、缺乏共性的噪声或离群点[12-13]。这种现象表明，模型的学习过程并非对所有样本同步进行，而是存在着显著的阶段性差异：即由模式学习主导的早期阶段与由记忆学习主导的后期阶段[62]。这种对简单模式的优先记忆，使得在训练早期阶段，模型的预测结果往往能较好地反映数据的真实语义结构，而只有在训练后期过度拟合时，噪声标签才会被模型完全记住。

记忆效应的存在并非偶然，而是具有坚实的理论支撑。经典的学习理论如 VC-dimension[63]或 Rademacher 复杂度[64]虽然指出了过参数化模型具有拟合任意随机标

签的能力，但难以解释模型在早期表现出的泛化倾向[65]。近期的研究[66-67]从梯度动力学（Gradient Dynamics）的角度对此进行了解释：在训练初期，属于同一类别的干净样本能够产生方向一致的梯度，这些梯度相互叠加从而推动模型参数快速向最优解收敛；相反，噪声样本由于标签的随机性，其产生的梯度方向往往是杂乱无章且相互抵消的，因此在早期对模型参数更新的贡献微乎其微。只有当学习率衰减或训练进入微调阶段，模型才会利用剩余的参数空间去拟合这些具有复杂梯度的噪声样本。此外，神经坍塌理论[68-69]也指出，在训练后期模型倾向于将同类特征映射到单一的各个正交中心，这种几何结构的演变进一步证实了记忆效应在特征空间中的表现。综上所述，利用这种训练动态中的时间差，可以有效地在无监督的情况下识别并剔除噪声。

2.1.1.2 单模态噪声标签学习

基于记忆效应的理论发现，研究者们在单模态领域发展出了一系列利用训练动态（Training Dynamics）进行去噪的方法[70-71]。这些方法利用模型在训练过程中的行为差异来区分干净样本与噪声样本，主要可分为基于早停机制、基于小损失准则的样本筛选、基于训练动态统计的检测以及基于正则化约束的方法。

利用早停（Early Stopping）[72-73]机制是最直观的策略。由于深度网络倾向于在训练初期优先拟合干净样本，而在后期才拟合噪声，因此在模型记忆噪声之前停止训练是一种有效的去噪手段。Arpit 等人[60]首先通过大量实证研究指出了这一现象，证明了在噪声存在时，训练准确率会持续上升直至过拟合，而验证集准确率则呈现先升后降的趋势。Li 等人[66] 从理论上证明了对于过参数化的神经网络，通过早停策略训练得到的模型在一定条件下对标签噪声具有可证明的鲁棒性。为了进一步提升早停的有效性，PES[74] 提出了渐进式早停策略，通过将网络分层并逐步停止不同层的训练来对抗噪声影响。Huang 等人[75] 则提出了 PADDLES 方法，利用频域信息将特征解耦为幅度和相位谱，并针对不同频谱特征设计差异化的早停策略，显著提升了模型在噪声环境下的鲁棒性。

为了克服早停策略在训练周期上“一刀切”的局限性，研究者进一步提出了基于“小损失”（Small Loss）准则[76-77]的样本筛选方法。该准则假设在训练的特定阶段，具有较低损失值的样本更大概率是干净样本。MentorNet[78] 最早引入了课程学习（Curriculum Learning）的思想，通过训练一个预定义的学生网络来指导主网络的训练，优先选择损失值小的样本进行更新。然而，单网络筛选容易陷入自我确认偏差。为了解决这一问题，Co-teaching[79] 提出了双网络协同学习机制，利用两个独立初始化的网络相互筛选样本，极大地缓解了误差累积问题。在此基础上，Yu 等人[80] 提出

了 Co-teaching+，引入了分歧更新策略，仅利用两个网络预测不一致的数据进行更新，从而保持网络间的差异性并提升筛选的鲁棒性。Wei 等人[56] 则提出了 JoCoR，通过引入联合损失函数和协同正则化项，在训练过程中同时减少两个网络的预测误差并最大化它们的一致性，从而更有效地筛选出干净样本。随着半监督学习技术的发展，DivideMix[81] 提出了一种混合框架，它利用高斯混合模型（Gaussian Mixture Model, GMM）对训练损失分布进行建模，动态地将样本划分为干净集和噪声集，并将噪声集作为无标签数据结合 MixMatch[82]技术进行联合训练，成为了该方向的里程碑式工作。

除了仅关注当前时刻的损失值，另一类方法致力于挖掘样本在整个训练过程中的动态统计特性。Huang 等人[83] 提出了 O2U-Net，通过循环调整学习率使模型在过拟合和欠拟合状态间反复切换，利用噪声样本在训练后期损失波动较大的特点来识别噪声。Pleiss 等人[84] 提出了基于间隔的 AUM（Area Under the Margin）指标，发现干净样本在训练过程中通常具有更大的平均间隔，通过统计样本在训练周期内的间隔动态变化来精确区分错标数据。

此外，基于正则化的方法通过施加约束来抑制模型对噪声的记忆。Liu 等人提出的 ELR[13] 利用了模型输出的时间移动平均作为软标签目标，利用梯度的对冲机制来防止模型在训练后期对噪声标签的过拟合。SOP[85] 则进一步利用了过参数化网络[86]的隐式正则化偏差，通过引入一个稀疏的过参数化项来专门建模和吸收标签噪声，从而将干净数据的低秩结构与稀疏噪声分离开来。此外，一些通用的正则化技术也被证明对噪声具有抑制作用。例如，Mixup[87] 通过对输入样本和标签进行线性插值，引入了数据平滑的效果，有效地降低了模型对错误标签的自信度。Label Smoothing[88] 则通过将硬标签替换为软标签，直接对损失函数进行正则化，从而限制了模型对特定噪声样本的过度拟合。

尽管上述方法在单模态分类任务中取得了显著成效，但直接将其迁移至多模态关联噪声学习场景时往往面临严峻挑战，这主要归因于多模态任务独特的学习范式与噪声特性。首先，多模态预训练通常采用基于自监督的对比学习范式，旨在拉近正样本对并推远负样本对，这与传统单模态方法所依赖的有监督交叉熵损失存在本质差异，导致许多针对分类标签设计的去噪假设，如特定的损失分布假设，难以直接应用。其次，多模态场景下的噪声模式更为复杂，表现为跨模态语义的不匹配，这种结构化的关联噪声不仅包含单一模态内的错误，更涉及模态间的高维语义错位，简单的基于损失大小或梯度的去噪设计往往难以胜任如此复杂的噪声模式识别。因此，针对

多模态对比学习的特性设计专门的鲁棒学习机制显得尤为重要。

2.1.2 基于噪声建模的鲁棒多模态对比学习

2.1.2.1 多模态对比学习中的关联噪声建模

对比学习作为自监督表征学习的核心范式，其核心思想在于通过拉近正样本对在特征空间中的距离并推远负样本对来学习具备判别性的特征表示。在早期的单模态研究中，这一思想主要通过三元组损失（Triplet Loss）[89]或噪声对比估计（InfoNCE）[90]损失来实现：前者通过设定间隔阈值来约束锚点与正负样本之间的相对距离，后者则通过最大化互信息下界来区分正样本与大量负样本。当这一范式被迁移至多模态领域（如 CLIP[3]、BLIP[91]）时，模型通常采用双塔结构，将其中一个模态的数据视为锚点，将其配对的另一模态数据视为正样本，而将批次内其他非配对的文本视为负样本。多模态对比学习旨在优化这种基于实例的跨模态对齐任务，使语义一致的图文在特征空间中高度接近。然而，这种监督信号的构建高度依赖于数据的标注质量。由于对比损失函数本质上是在优化样本间的相对位置关系，它对错误的正样本信号表现出极高的敏感性。一旦训练数据中存在错误的关联，模型就会被迫强制拉近语义无关的表征，导致特征空间的几何结构发生坍塌，从而严重削弱模型的判别能力与鲁棒性[14,92]。

针对这一问题，学术界提出了“关联噪声”的概念以区别于传统的分类标签噪声。在关联噪声的研究语境下，关联噪声场景下的标签不再指代样本的类别属性，而是特指不同模态数据之间是否存在语义匹配关系的二元指示标签。具体而言，关联噪声是指数据集中观测到的匹配关系与潜在的真实语义关系不一致的现象。这种不一致性主要分为两类：一类是“假阳性”噪声，即数据集中被标记为成对的样本，在语义内容上实际上是无关或错配的；另一类是“假阴性”噪声，即在训练过程中被视作负样本的非配对数据中，实际上包含了与锚点语义高度相似的样本[93]。这种关联关系的错乱直接破坏了对比学习的基本假设，使得原本用于对齐语义的损失函数反而成为了误导模型优化的主要因素。

关联噪声问题并非局限于单一任务，而是广泛存在于依赖大规模网络数据的多模态学习场景中，具有极强的普遍性。在图像-文本检索领域，由于网络爬虫技术的广泛应用，如 CC3M 和 CC12M 等主流数据集中包含了大量图文不符的样本，据统计噪声比例可达 3% 至 20%[94-95]，这促使了大量关于鲁棒关联学习方法的研究[22,96-97]。在视频-文本检索任务[98-99]中，由于视频内容的时序冗余性与文本描述的概括性，帧与词之间的细粒度语义错位更为常见，Han 等人[100] 与 Lai 等人[101] 指出这种噪声严

重阻碍了时空表征的精确对齐。此外，在跨模态行人重识别（Re-ID）任务[102-103]中，受限于红外与可见光模态间的巨大差异及标注难度，双向的关联噪声现象同样普遍存在[104-105]。近期研究还表明，在医学影像报告匹配[106]、跨模态图匹配[107] 以及多视图聚类[24,108] 等领域，关联噪声已成为制约模型性能进一步提升的关键瓶颈。

2.1.2.2　基于一致性建模的关联噪声学习

基于一致性建模的方法是多模态关联噪声学习中的主要研究方向之一。该类方法的核心思想源于半监督学习与单模态噪声标签学习中的一致性正则化理论[109-110]，即假设对于输入数据的微小扰动或不同视图，鲁棒的模型的预测结果应当保持一致。在多模态对比学习的语境下，这种“一致性”被进一步扩展为跨模态预测的一致性、双网络协同训练的一致性以及表征空间内的相似度一致性。早期的探索主要借鉴了单模态领域的噪声标签学习方法，利用了深度神经网络的记忆效应。基于这一特性，研究者们设计了多种策略来区分干净样本与关联噪声样本，进而通过重加权或标签修正等策略抑制噪声影响。

Huang 等人提出的 NCR[14] 是该方向的奠基之作。NCR 首次将 DivideMix 的思想引入跨模态匹配任务，提出了基于噪声鲁棒对比损失的协同训练框架。该算法同时维护两个结构相同但初始化不同的网络，利用高斯混合模型对每个样本的损失分布进行拟合，从而动态地将数据划分为干净集与噪声集。两个网络相互为对方筛选出的“干净”样本及其修正后的软标签进行训练，有效地避免了单网络训练中的确认偏差（Confirmation Bias）累积问题。为了进一步提升筛选的鲁棒性，Yang 等人提出了 BiCro[15]，指出仅依赖单向损失筛选容易丢失难样本。BiCro 引入了双向跨模态相似度一致性约束，认为只有在图像检索文本和文本检索图像两个方向上均表现出高置信度的样本才是可靠的，并取两个网络筛选结果的交集进行更新。

随着研究的深入，学者们发现仅关注单一样本对的匹配分数往往不足以应对复杂的噪声模式，转而开始利用表征相似度的一致性与聚类特性来对抗噪声。CREAM[16] 提出了一种基于聚类的一致性精炼模块，通过对比跨模态检索预测与单模态特征聚类得到的伪标签之间的一致性，来挖掘潜在的噪声样本。ReCon[111] 则深入探究了关系一致性，认为真实的图文对在特征空间中的相对位置关系应当具有鲁棒性，通过构建关系图并约束其在不同增强视图下的一致性，从而有效地区分了噪声与难样本。NAC[112] 引入了近邻辅助校正器，利用特征空间中近邻样本的语义信息来辅助判断当前样本对的匹配程度，利用群体的语义共识来修正个体的噪声标签。近期，SPS[113] 提出在稳定的特征空间中寻找代理点作为参考，通过度量样本与代理点之间的距离

一致性来规避训练动态中的波动。针对多视图聚类任务中的关联噪声问题，ROLL[114] 设计了一种鲁棒的噪声伪标签学习机制，通过在聚类过程中动态生成并修正伪标签，利用聚类的一致性约束来抵抗双重关联噪声的干扰。

除了单纯地筛选或丢弃噪声样本，另一类策略尝试利用表征一致性对错误的关联进行修正或重构，以充分利用数据中的语义信息。SREM[115] 指出直接丢弃噪声可能导致数据利用率不足，因此提出了一种基于自强化误差缓解的软标签修正机制，使模型能够从噪声样本中学习到部分有用的语义信息。L2RM[116] 则提出了一种基于学习重匹配的框架，它假设一个批次内的图像和文本可能存在错位，通过优化一个重匹配矩阵，试图在批次内部寻找潜在的正确匹配关系，从而最大化数据的利用率。针对文本端的噪声，PC^2[117] 和 PCSR[118] 等方法利用了伪描述生成技术，利用预训练模型或训练过程中的中间模型为图像生成新的伪文本描述，通过计算原始文本与生成文本的一致性来判定噪声，并利用生成的伪文本作为补充监督信号进行训练。这种方法在处理文本语义缺失或完全不相关噪声时表现出了优越的性能。此外，针对红外-可见光跨模态行人重识别中的双重噪声问题，TNL[104] 提出了一种双网络协同互学习框架来解耦标签噪声与模态差异；Norton[119] 则针对长时序视频中的未对齐噪声，提出了一种基于最优传输理论[120-121]的多粒度协同关联学习方法。

尽管基于一致性建模的方法在关联噪声学习中取得了显著进展，但其仍面临着一些不容忽视的局限性。首先，以 NCR 为代表的双网络协同方法虽然能有效降低确认偏差，但同时维护两个深度神经网络带来了成倍的计算开销和显存占用，这在处理大规模预训练数据时成为了严重的效率瓶颈。其次，现有的修正策略主要依赖模型自身在当前数据上的预测来进行自我校正，当数据集整体信噪比极低或存在系统性偏差时，模型容易陷入确认偏差的自我循环，即不断强化错误的预测，缺乏外部客观信息的指引。最后，虽然部分工作开始关注聚类或近邻信息，但大多仅侧重于局部语义关系的挖掘，尚未充分利用多模态数据内在的结构一致性来对齐特征空间，导致在极高噪声率下的表征容易发生坍塌。

2.1.2.3 基于不确定性建模的关联噪声学习

不同于基于一致性建模的方法侧重于通过多视图或多网络的预测一致性来筛选样本，基于不确定性建模的方法旨在直接量化模型对样本预测的“置信度”或“可靠性”[122-123]。在关联噪声场景下，模型对干净样本的预测往往呈现出低不确定性，而对噪声或难样本则表现出高不确定性。通过引入证据理论、概率分布建模或置信度校准机制，该类方法能够更细腻地捕捉数据中的噪声信号，从而在优化过程中动态调整样

本权重或修正目标分布，为鲁棒学习提供了新的视角。

证据深度学习理论将神经网络的输出视为参数化的狄利克雷分布[124-125]，从而在预测类别的同时估计预测的不确定性，这一理论被多位学者引入到多模态噪声学习中。Qin 等人提出的 DECL[17] 是该方向的开创性工作，该方法将证据深度学习理论引入跨模态检索，通过主观逻辑判断将相似度建模为贝叶斯框架下的狄利克雷分布，利用证据不确定性来识别关联噪声，有效降低了高不确定性样本在训练中的权重。在此基础上，针对跨模态行人重识别任务，RDE[105] 利用证据学习来解耦标签噪声与模态内的困难样本，通过不确定性感知机制实现了对红外-可见光匹配中噪声的鲁棒学习。在文本行人检索领域，NCEL[126] 构建了基于证据学习的噪声对应框架，利用不确定性估计来净化文本描述与行人图像间的错误关联。此外，针对法律案例检索这一特殊领域，Qin 等人提出的不确定性感知方法[127] 结合了不确定性估计的证据学习，解决了法律文本中复杂的语义匹配与噪声干扰问题。

除了显式的证据学习，通过对损失分布、相似度分布进行建模，或引入校准机制，也是衡量样本不确定性的有效手段。Feng 等人提出的 CTPR[128] 策略利用高斯混合模型的后验概率将数据划分为干净子集、噪声子集和不确定子集三个集合，并针对不确定样本设计了基于半监督的重加权策略，从而更精细地处理处于决策边界的样本。Zhang 等人针对视频-文本检索提出了 NPC[93]，该方法通过预先感知负样本分布的不确定性，计算样本成为假阴性的概率，从而在对比学习中抑制假阴性噪声的负面影响。近期，Zha 等人设计了 UGNCL[129] 框架，通过量化样本的认知不确定性与任意不确定性来指导跨模态匹配的优化过程。其扩展工作 UCPM[18] 进一步针对部分失配问题，提出了不确定性引导的跨模态检索方法，利用不确定性来动态调节细粒度语义对齐的关注度。此外，PCD[130] 引入了共形预测理论，通过概率蒸馏的方式为缺失模态或噪声数据提供具有统计保证的不确定性边界，增强了模型的鲁棒性。

互补学习通过学习样本不属于某个类别的概率来间接逼近真实标签[131]，这种逆向思维在处理高不确定性噪声时具有天然优势。Hu 等人提出的 RCL[132] 将互补标签学习引入多模态检索，利用逆向学习策略通过最大化样本与非匹配项的距离来间接优化目标，从而避免了直接拟合噪声正样本带来的过拟合风险。CRCL[19] 则结合了主动学习与互补学习，通过主动选择高不确定性样本进行人工或自动修正，并利用互补标签进行自修正训练，实现了高效的去噪。此外，针对跨模态相似度的非对称性，Wang 等人提出了 ASL[133]，通过非对称的相似度度量来纠正关联噪声，认为噪声在不同方向上的相似度分布具有不一致性并据此进行矫正。在多模态医学诊断领域，Liu

等人提出的 MCPH[106] 在哈希学习中引入鲁棒噪声学习机制，通过对医学图像与报告间关联不确定性的建模，提升了在含噪医疗数据上的检索性能。

除了上述基于特定不确定性理论的方法外，还有一类经典方法致力于设计内在鲁棒的损失函数或正则化项来抵御噪声干扰。Chuang 等人提出的 RINCE[134] 针对标准 InfoNCE 损失在噪声环境下易过拟合的问题，推导并提出了一种具有对称性的鲁棒损失函数。该函数通过对噪声样本产生的异常梯度进行惩罚性抑制，从优化目标的根源上保证了噪声环境下的学习稳定性，无需显式的样本筛选过程。类似地，一些研究尝试将标签平滑或软标签技术引入对比学习，通过降低模型对特定关联的过度自信来缓解噪声影响。例如，SOP[85] 利用过参数化网络的隐式正则化偏差来稀疏地建模和吸收噪声，虽然其最初应用于单模态，但其思想也被后续多模态工作所借鉴。这些方法通常不依赖复杂的双网络筛选机制，具有较高的计算效率和易用性。

尽管基于不确定性建模的方法为多模态关联噪声学习提供了严谨的概率视角，但其在实际应用中仍面临诸多挑战。首先，证据学习或贝叶斯网络通常涉及复杂的理论推导和近似计算，增加了模型实现的难度和训练的不稳定性。其次，如何设定合适的不确定性阈值以区分噪声与难样本仍然是一个开放性问题；难样本往往也表现出较高的认知不确定性，简单的阈值截断容易导致有价值的难例被误删，从而损害模型的细粒度判别能力。最后，部分基于概率分布估计的方法依赖于对数据先验分布的假设，当真实数据的噪声分布偏离这些假设时，模型性能可能会显著下降。

2.1.3 基于特权信息辅助的鲁棒多模态对比学习

除了挖掘数据内部的几何结构与一致性外，引入外部的辅助知识或特权信息是解决关联噪声问题的另一重要途径。该类方法的核心逻辑在于：当原始数据的图文对应关系因高噪声而不可信时，仅依赖内部信息的自我校正容易陷入确认偏差的循环。此时，利用第三方的客观信息源，如人工标注的类别标签、少量验证集或预训练模型生成的语义描述作为参照系进行校验，能够有效打破内部信息的认知局限。现有的基于特权信息的方法主要可以分为基于显式语义标签辅助、基于元知识引导以及基于生成式语义辅助三类。

基于显式语义标签辅助的方法主要集中在多模态哈希检索领域[135-136]，该类方法利用数据集中易于获取的类别标签或哈希码作为特权信息来指导模态对齐。作为该领域的奠基性工作，DCMH[137] 首次将深度学习引入跨模态哈希，通过利用类别标签构建成对相似度矩阵，端到端地指导图像与文本特征在汉明空间中的离散编码学习。在此基础上，SSAH[138] 结合了对抗学习机制，通过两个对抗网络共同学习模态的高

层语义表达，并利用多标签语义信息监督哈希码的生成，从而在共同子空间中最大化不同模态间的语义相关性。DSMHN[139] 则构建了深度语义多模态哈希网络，利用标签信息来指导哈希码的概率分布，确保生成的二进制码能够精确保持原始数据在语义空间中的相似度结构。然而，上述方法通常假设标签是完美的。针对标签本身可能带噪或与模态内容未对齐的问题，MRL[20] 提出了一种基于原型的鲁棒框架，该方法在哈希码学习过程中引入了类别原型变量，通过约束样本与其所属类别原型的距离来修正错误的监督信号，从而减少噪声标签对优化的干扰。ELRCMR[17] 则引入了证据深度学习理论，将跨模态相似度建模为狄利克雷分布，通过量化标签的主观不确定性来动态降低高不确定性噪声样本在哈希码学习中的权重。此外，RONO[140] 设计了一个噪声容忍网络，通过自适应地调整损失函数中的样本权重来抵抗标签噪声；NRCH[141] 针对标签与模态内容语义不一致的问题，提出了一种标签修正模块，利用模态内容的视觉或文本特征反向校准错误的类别标签。这些方法证明了显式标签能有效作为语义锚点辅助模态对齐，但其高度依赖于高质量的人工标注，难以直接应用于大规模无监督图文预训练场景。

基于元知识引导的方法则试图利用少量高质量的干净数据集作为辅助信息，通过元学习（Meta Learning）范式指导模型在噪声数据上的训练[142-143]。该类方法的核心在于以小博大，即利用少量可信数据上的梯度方向作为元梯度，来评估并调整海量不可信数据的训练策略。该类方法的理论基础源于 Ren 等人提出的 L2R[144] 算法，该算法利用少量干净验证集的梯度方向作为元梯度，动态调整训练样本的权重以优化模型性能；随后，Meta-Weight-Net[145] 进一步通过训练一个多层感知机作为加权函数，自适应地学习从损失到样本权重的映射关系。MSCN[22] 将这一思想引入鲁棒多模态学习领域，其设计了一个元相似度校正网络，通过在少量干净验证集上计算元损失并反向传播元梯度，显式地学习如何生成相似度修正项，从而直接校准噪声样本的匹配分数。MSIAN[23] 则利用元学习思想进行实例级的自适应鲁棒学习，该方法根据样本在元数据上的梯度表现，动态调整对比损失函数中的间隔参数，对易错样本施加更严格的约束。近期，SURE[24] 将元学习引入对比学习框架，通过元更新步骤在特征空间中生成更可靠的伪标签及伪负样本，以此净化对比学习的正负样本对；而 Mu 等人[23] 提出的元引导自适应权重学习器进一步优化了元优化器的效率，使其能根据元数据的反馈自适应地为每个训练样本分配权重，以对抗复杂的关联噪声模式。尽管此类方法在理论上实现了较为精准的去噪，但构建分布一致且高质量的元数据集本身具有较高的收集成本，限制了其在开放世界场景中的泛化能力。

基于生成式语义辅助的方法利用强大的预训练生成模型，如图像描述生成模型或多模态大模型等来合成伪描述或伪标签，将其作为特权信息进行一致性校验[146-147]。该类方法基于一个直观假设：若原始图文匹配，则图像生成的文本应与原始文本语义高度一致，反之则存在噪声。PC^2[117] 引入了伪分类和伪描述生成的双重辅助任务，一方面利用聚类生成伪标签，另一方面利用预训练模型为图像生成伪描述，通过计算生成的伪描述与原始文本的语义一致性来判别噪声，并进而利用高质量的伪描述替换噪声文本进行修正训练。PCSR[118] 提出了一种伪标签一致性引导的样本精炼策略，通过比较生成模型产生的伪标签与原始标签在语义空间中的距离，动态筛选出高置信度的样本子集用于模型更新。此外，NIC[148] 在图像描述生成任务中，利用生成过程中的词概率分布差异来探索并修正不匹配词汇，即当原始文本中的词汇与视觉内容的生成概率严重不符时将其判定为噪声。SREM[115] 则提出了一种自强化误差缓解机制，通过生成软标签来平滑噪声带来的梯度冲击，并利用模型自身的预测进行自举修正。这类方法不依赖人工标签或额外数据集，但其性能高度依赖于生成器本身的能力，若生成内容存在幻觉偏差或特权信息本身带噪，则会引入新的噪声干扰。

综上所述，引入特权信息为打破关联噪声的闭环提供了新的视角，无论是显式的标签、少量的元数据还是生成的伪描述，均在一定程度上提升了模型的鲁棒性。然而，现有的方法大多忽略了一个关键问题，即特权信息本身也可能包含噪声或不确定性。哈希方法依赖标签质量，元学习方法依赖干净验证集，而生成式方法依赖生成器的准确性。当特权信息与原始数据同时存在噪声时，上述方法的鲁棒性往往会大打折扣。因此，如何在无需额外昂贵标注的前提下引入特权信息，并鲁棒地处理原始关联与特权信息中可能存在的双重不确定性，仍然是一个未被充分探索的难题。

2.2 基于样本选择的鲁棒多模态对比学习方法

2.2.1 基于离线样本选择的鲁棒多模态对比学习

2.2.1.1 基于规则的离线样本选择

基于规则的离线样本选择作为多模态预训练数据清洗的奠基石，旨在利用人工定义的启发式策略在模型训练前对原始采集数据进行大规模过滤[149]。该类方法的核心逻辑在于假设高质量的图文数据应当在数据属性、内容复杂度以及统计分布上满足特定的先验标准。不同于后续依赖深度神经网络进行语义判别的方法[25]，基于规则的筛选通常不涉及昂贵的模型推理计算，而是侧重于通过设定刚性的阈值或模式匹配来剔除明显的低质量样本，如损坏的图像文件、无意义的文本描述或格式异常的

数据对。由于其极低的计算开销与高度的可扩展性，该策略成为了构建大规模多模态数据集，如 SBU Captions[149]、YFCC100M[150]等，的首选预处理流水线，为后续的表征学习提供了基础的数据完整性保障。

在具体的实施层面，研究者通常从元数据质量、内容复杂度与统计特征三个维度构建级联式的过滤规则。首先，基于元数据质量的筛选主要针对数据的物理属性，例如设定图像分辨率的下限以保证视觉信息的清晰度[95,151]，设定长宽比阈值以剔除横幅广告或装饰性图片[152]，并通过语言检测工具保留特定语言的文本以维持语料的一致性[153-154]。其次，基于复杂度的筛选旨在剔除信息熵过低的样本，例如通过检测图像的边缘分布或压缩后的文件大小来过滤纯色或模糊背景图[150]，同时对文本长度进行约束，剔除过短的单词片段或过长的冗余段落，并利用正则表达式移除包含大量 HTML 标签、特殊符号或乱码的低信噪比文本[155]。最后，基于统计特征的方法进一步利用词频与模式匹配优化数据分布，例如 ALIGN[156]方法提出的剔除包含特定“黑名单”词汇的样本，利用词性标注确保文本中包含名词与动词的主谓结构，并通过统计名词的共现频率将专有名词替换为上位词以缓解长尾分布带来的稀疏性问题[157]，从而提升文本描述的通用性与可学习性。

基于上述规则策略，学术界构建了多个里程碑式的多模态数据集，其中最为典型的是 Conceptual Captions 3M（CC3M）[94] 与 Conceptual Captions 12M（CC12M）[95]。CC3M 通过极为严格的层级过滤规则，从数十亿网页图片中精选出约 330 万高质量图文对，极大地推动了早期多模态预训练的发展；而 CC12M 则通过放宽部分过滤阈值（如保留更多自然语言描述而非严格的上位词替换），在保证一定质量的前提下显著扩大了数据规模。然而，基于规则的离线选择方法存在显著的局限性：首先是语义盲区问题，刚性的规则无法感知图像与文本在深层语义上的一致性，导致大量图文不符但格式完美的噪声样本被保留；其次是规则设计的权衡困境，过于严格的阈值会大幅降低数据的多样性并丢弃有价值的长尾样本，包括艺术类图片或非标准描述，而过于宽松的规则则无法有效抑制噪声，这种对先验假设的强依赖限制了其在复杂多变的互联网数据分布中的泛化能力。

2.2.1.2　基于数据裁剪的离线样本选择

基于数据裁剪的离线样本选择方法旨在通过特定的评估指标，在模型正式训练之前从原始数据集中识别并保留高价值样本，剔除冗余或低质量样本，从而构建一个更具代表性的核心集。根据样本价值评估机制的不同，现有的研究工作主要可以归纳为基于几何分布与多样性的方法、基于训练动力学指标的方法以及基于预训练代理

模型的方法。

数据裁剪类方法侧重于从原始数据中进行筛选操作[158-159]。早期的研究主要基于几何分布与多样性特征进行无监督筛选，假设数据在特征空间中具有特定的几何结构，目标是选出的子集能在几何分布上最大程度地覆盖原始数据集。其中，Herding 方法[27]是一种经典的基于聚类中心的筛选策略，该方法在特征空间中通过迭代的方式贪心地选择样本，使得所选子集的特征均值尽可能逼近全量数据集的特征均值，从而保留数据的整体分布信息。k-中心贪心算法[160]则将样本选择建模为最小最大设施选址问题，其核心思想是选择一组样本点，使得原始数据集中剩余的所有未选中样本到最近选中样本的最大距离最小化，从而确保特征空间的几何覆盖率。此外，Agarwal 等人提出的上下文多样性方法[161]进一步强调了样本在语义空间中的多样性，利用强化学习或贪婪策略在保持特征距离的同时最大化样本的上下文差异，以避免选取过于相似的冗余样本。

除了静态的几何特征，基于训练动力学的方法利用模型在训练过程中的动态行为特征来评估样本的学习难度与价值[162-163]。Toneva 等人提出的遗忘分数[164]统计了样本在训练过程中发生预测翻转的次数，即样本从被模型正确分类转变为错误分类的频率。研究发现，发生遗忘次数较多的样本通常位于决策边界附近，属于难样本，对模型最终性能的贡献较大。Paul 等人提出的 GraNd 方法[165]通过计算样本在训练早期的梯度范数来近似其对损失函数下降的贡献，认为高梯度范数的样本包含更多信息量。为了降低计算梯度的开销，他们进一步提出了 EL2N 指标，直接利用预测误差向量的 L_2 范数来衡量样本的不确定性，在保证筛选效果的同时显著提升了计算效率。Pleiss 等人提出的 AUM 指标[84]则通过记录训练过程中样本正确类别与其他类别预测值之差的累积面积来区分数据性质，该指标能够有效区分易学样本、难样本以及标注错误的噪声样本。

在多模态学习场景下，由于跨模态数据之间存在复杂的语义对齐关系，基于预训练模型的筛选策略成为了主流。这类方法通常利用在大规模数据集上预训练的大模型作为参考模型，以计算图文对之间的语义一致性分数。例如，在构建大规模多模态数据集如 LAION-5B 时，广泛采用了基于 CLIPScore 的过滤策略[166]，即计算图像与文本嵌入向量之间的余弦相似度，并设定阈值剔除对齐度较低的样本。Gadre 等人提出的 DataComp 基准[25]进一步系统地研究了数据过滤对多模态模型性能的影响，提出了过滤扩展定律，证明了使用更优质的预训练模型进行基于一致性的筛选可以显著提升下游任务性能。除了简单的余弦相似度，Li 等人探索了利用 BLIP 等更复杂

的图像-文本匹配模型进行筛选[91]，通过计算图文匹配得分来更精准地识别细粒度的语义错配。此外，SemDeDup[26]等工作关注数据的冗余性，通过在预训练模型的嵌入空间中对数据进行聚类，识别并移除语义高度重复的图文对，从而在不损失模型性能的前提下大幅减少训练开销。

2.2.1.3　基于数据蒸馏的离线样本选择

与直接筛选原始样本不同，数据集蒸馏旨在通过优化算法合成全新的、数量极少的样本，使其在模型训练中的效能逼近全量数据。根据优化目标的不同，现有的蒸馏方法主要分为性能匹配、参数匹配与分布匹配三类。

基于性能匹配与梯度匹配的方法是该领域的奠基性工作。Wang 等人最早提出的数据集蒸馏[167]基于元学习范式，将合成图像的像素值作为超参数，通过双层优化框架进行更新，使得模型在合成数据上经过几步梯度下降后，在真实验证集上的损失最小化。为了解决双层优化计算开销过大的问题，Zhao 等人提出了数据集浓缩[28]，引入了梯度匹配的思想，直接优化合成数据，使其在网络参数更新过程中产生的梯度与真实数据产生的梯度分布尽可能一致。在此基础上，DSA 方法[168]在梯度匹配过程中引入了可微的数据增强策略，不仅扩充了合成数据的多样性，还使得合成样本能够学习到更鲁棒的特征表示，显著提升了蒸馏效果。

为了进一步提升蒸馏效率和长时训练的稳定性，相关研究提出了基于分布与轨迹匹配的方法。Zhao 等人提出的分布匹配[169]放弃了昂贵的梯度计算，转而从统计学角度出发，直接最小化合成数据与真实数据在特征空间中的最大均值差异，使得合成数据能够复现真实数据的特征分布。Cazenavette 等人提出的 MTT 方法[29]则将单步的梯度匹配扩展为多步的轨迹匹配，旨在让模型在合成数据上训练后的参数轨迹能够尽可能贴合在真实数据上的长时训练轨迹。这种方法能够让合成数据捕获更长期的训练动态信息，从而在高压缩倍率下仍能保持较高的模型性能。此外，FRePo[170]等工作通过将网络解耦为特征提取器和线性分类器，利用表征回归的闭式解来加速内层循环的优化，进一步降低了蒸馏过程的计算复杂度。

尽管上述离线样本选择方法在单模态任务中取得了显著成效，但在面对大规模多模态预训练任务时仍面临严峻挑战。首先，无论是基于训练动力学的裁剪还是数据集蒸馏，往往需要高昂的预处理成本，例如训练参考模型或进行复杂的双层优化，这在冷启动场景下是不可接受的。其次，现有的离线方法大多基于静态评估，无法适应训练过程中模型对数据需求的变化。最重要的是，在多模态关联噪声场景下，单纯基于损失或梯度的筛选指标容易将高损失的噪声样本误判为高价值的难样本，导致

模型训练崩塌。因此，探索一种高效、无需预训练模型且对噪声鲁棒的在线样本选择机制，成为了亟待解决的关键问题。

2.2.2 基于在线样本选择的鲁棒多模态对比学习

2.2.2.1 基于课程学习的在线样本选择

基于课程学习的在线样本选择方法主张模拟人类认知由易到难的学习过程，通过在训练初期引入简单样本并在后期逐步加入困难样本，以平滑非凸优化问题的解空间并加速模型收敛[171-172]。早期的研究主要集中于预定义课程学习，即依据人工先验知识设计的难度度量与训练调度器。Bengio 等人[173]最早提出了课程学习的形式化定义，利用熵值或样本特征预先计算复杂度，并在训练过程中逐步增加训练集的数据分布熵，论证了该策略能显著提升非凸优化的极小值质量。Platanios 等人[174]从连续调度的角度出发，设计了基于能力函数的动态采样机制，利用如 Root-p 等函数曲线控制训练过程中样本难度的增长速率，从而避免了离散调度带来的梯度抖动。随着深度学习的发展，课程学习被广泛拓展至更复杂的训练场景。例如，EfficientTrain++[175]提出了一种广义课程学习框架，通过动态过滤视觉主干网络训练中的冗余数据，在不损失性能的前提下大幅提升了训练效率；Liu 等人[176]则将课程学习引入大语言模型的上下文学习中，通过逐步增加示例难度的方式引导模型进行推理，有效增强了对复杂任务的解决能力。

伴随研究的深入，完全依赖人工先验的预定义课程逐渐显露出难以适应复杂数据分布的局限性，促使学术界转向数据驱动的自动课程学习，其中最具代表性的范式即为自步学习[177]。Kumar 等人[30]奠定了自步学习的数学框架，将样本选择建模为包含潜在变量的双凸优化问题，通过在损失函数中引入正则项，驱使模型在训练早期自动倾向于选择损失值较小的简单样本，随后通过松弛正则化系数逐步纳入高损失样本。Jiang 等人[178]提出了融合多样性的自步学习 SPLD，强制模型在选择简单样本的同时覆盖不同的样本簇或特征模式，从而提升了特征学习的鲁棒性。为了进一步提升自步学习在复杂分布下的鲁棒性与泛化能力，近期的研究提出了诸多改进方案。Zhao 等人[179]设计了一种对称自步学习机制，通过在域泛化任务中平衡不同域的样本选择，缓解了模型对特定简单域的过拟合倾向；Trung 等人[180]结合元学习思想提出了元自步学习框架，利用元验证集的反馈动态调整各样本的权重分配，有效解决了无监督领域自适应中的噪声伪标签干扰；此外，SPCNet[181]将自步学习与深度神经网络的归纳偏置相融合，构建了深层自步课程网络，进一步增强了模型在复杂特征空间中的模式识别与提取能力。

在多模态学习领域，课程学习的思想被进一步演化，以应对异构模态间的语义对齐与数据不平衡挑战。现有的研究不仅关注单模态内部的样本难度，更强调跨模态交互过程中的动态选择。Zhou 等人[182]提出了一种模态内与模态间联合课程机制，通过协同评估单一模态的感知难度与跨模态的对齐难度，引导模型逐步构建稳健的多模态表征；DynCIM[183]针对多模态数据的不平衡现象，设计了动态课程学习策略，实时调整不同模态组合的采样权重，从而避免主导模态对整体优化方向的过度干扰。自步学习同样在跨模态任务中展现出巨大潜力，如 Sun 等人[184]提出的双重自步跨模态哈希方法，利用双向难度评估机制剔除低质量图文对，显著提升了离散哈希的检索精度；Kumar 等人[185]则将上下文自步学习应用于时空视频定位，依据视频帧与文本查询的语义一致性逐步引入复杂样本，有效抑制了弱监督信号下的背景噪声。

尽管上述方法在多模态对齐中取得了显著成效，但课程学习在关联噪声场景下仍面临固有的局限：一方面，基于损失或置信度的难度度量在强噪声下容易失效，导致模型将语义错配的噪声样本误判为高价值难样本并强行拟合；另一方面，针对多模态极其复杂的对应关系设计自适应课程往往需要引入高昂的额外计算开销，这与大规模预训练追求高效计算的需求存在本质冲突。

2.2.2.2　基于难样本挖掘的在线样本选择

基于目标函数的显式难样本挖掘策略主张将计算资源集中于模型当前预测误差较大或损失值较高的样本，以提升梯度的有效性并修正决策边界。Shrivastava 等人[32]提出的在线难样本挖掘算法 OHEM，在目标检测训练中根据感兴趣区域的损失值进行排序，动态筛选高损失样本进行反向传播，有效缓解了正负样本极度不平衡的问题。针对单阶段检测器中简单负样本主导梯度更新的现象，Lin 等人[33]提出了 Focal Loss，通过引入调制因子重塑标准交叉熵损失函数，自动衰减简单样本的权重并聚焦于稀疏的困难样本，在不显式剔除数据的前提下实现了软化的难样本挖掘。随着该领域研究的深入，Liu 等人[186]系统性地论证了难样本挖掘在提升模型训练效率与鲁棒性方面的新范式，指出动态识别边界样本能够更精准地优化模型决策域。为进一步提升挖掘精度，PISA[187]引入了主导样本注意力机制，依据样本对评估指标的实际贡献度动态分配权重，从而在复杂分布下实现了更高效的焦点训练。此外，针对现实场景中不可避免的标注误差，HSALC[188]在医疗图像分类任务中设计了感知难样本的标签修正机制，利用预测误差有效剥离真实的困难样本与有害的噪声样本，极大拓展了难样本挖掘在含噪数据中的应用潜力。

基于特征相似度的隐式难样本挖掘策略则侧重于利用样本在嵌入空间中的几何

关系，通过识别特征距离违背相似度约束的样本来优化度量学习或对比学习的表征质量。Schroff 等人[189]在 FaceNet 中提出的半难三元组挖掘策略指出，直接选用损失最大的极端难样本极易引发模型坍塌，而聚焦于决策边界内的半难负样本则能提供更稳定的优化梯度，从而显著提升了特征的判别精度。Robinson 等人[190]针对无监督对比学习推导了硬负例采样方法，通过引入基于样本相似度的重要性采样分布，修正了标准 InfoNCE 损失中均匀随机采样的偏差，使得模型能够专注于处理语义近似但非同源的真实难负例。在监督学习场景下，Jiang 等人[191]提出了结合难负例样本的监督对比学习框架，通过精确构造类内与类间的困难负样本对，进一步增强了高维特征的类间可分性。为了突破现有数据集中难样本数量的物理限制，M-mix[192]设计了基于多样本混合的困难负例生成机制，在隐空间中通过特征插值动态合成位于决策边界附近的伪难样本，从而迫使对比学习模型捕捉更为细致的特征差异。

在多模态学习领域，难样本挖掘被广泛用于增强跨模态语义对齐的细粒度与判别力。VSE++[34]在视觉语义嵌入模型中成功引入了最大难负例挖掘机制，通过在迭代中仅针对最难区分的图文负例计算排序损失，大幅提升了图像文本的跨模态检索性能。CrossCLR[193]在多模态视频表征学习中根据样本与其他样本的互连性挖掘具有高影响力的难样本，以增强模型对语义冲突区域的敏感度。Wu 等人[194]尝试将 Focal Loss 的思想迁移至多模态检测任务，设计了渐进式难样本挖掘策略以逐步聚焦于困难的图文对齐区域。针对更复杂的多模态时序数据，Choi 等人[195]将难负例采样机制拓展至多模态对比学习中，通过挖掘模态间及时间维度上的困难负样本，显著优化了人类行为识别任务中的多模态表征对齐精度。

尽管难样本挖掘在增强模型判别力方面成效显著，但在多模态关联噪声场景下却暴露出固有的局限性。大规模网络抓取的数据中普遍存在语义匹配但被分配为负例的假负例，以及标记为匹配但语义毫无关联的噪声正例。传统的挖掘策略往往会错误地将具有高损失值的噪声样本视作高价值的难样本并施加高权重，导致模型对错误关联模式产生严重过拟合。这种判别偏差迫使学术界必须进一步探索能够有效区分高价值难样本与有害噪声样本的新型动态数据筛选机制。

2.2.2.3 基于重要性采样的在线样本选择

基于重要性采样的在线样本选择方法从优化理论的视角出发，旨在通过非均匀的采样策略来减小随机梯度估计的方差，从而在不增加迭代次数的情况下加速模型收敛[196-197]。与课程学习关注认知的由易到难不同，重要性采样更关注梯度的贡献度。Alain 等人[198]奠定了该方向的理论基础，他们证明了当采样概率分布与每个样本的

梯度范数成正比时，随机梯度下降的方差达到最小。基于此理论，Katharopoulos 和 Fleuret[199]推导了深度学习中重要性采样的方差估计器，并强调了在采样后对样本进行重加权以保持无偏估计的重要性。Johnson 和 Guestrin[200]则提出了 RVR 策略，通过维护历史梯度范数的近似值来指导采样，旨在解决深度模型训练中精确梯度计算成本过高的问题。

然而，在实际应用中，计算全量数据集的梯度范数会带来难以承受的计算开销，因此研究者转向探索基于损失函数的高效近似策略。由于梯度范数通常与预测误差的上界相关，训练损失常被用作重要性度量的廉价代理。Loshchilov 等人[201]提出了在线批次选择算法，根据样本在上一轮迭代中的损失值进行排序和分层采样，显著提升了神经网络的训练效率。Katharopoulos 等人[202]进一步分析了直接使用损失值作为采样概率可能引入的偏差，并提出了一种基于损失上界的采样方案来更稳健地近似梯度范数。Selective Backprop[203]通过在前向传播阶段利用损失值快速筛选出高误差样本进行反向传播，从而在减少计算资源消耗的同时保持了模型的泛化能力。DivBS[36]则通过度量分组的正交代表性，旨在筛选出具有更高多样性的样本子集以避免特征坍塌。

在多模态大规模预训练场景下，面对数以亿计的图文数据，基于重要性采样的加速策略变得尤为关键，近期涌现了多种改进方法以平衡效率与性能。InfoBatch 算法[35]通过动态监测样本的损失变化，以无偏的方式对拟合较好的样本进行降采样。SCAN[204]则引入了动态自举机制，通过在训练过程中逐步增加剪裁率来实现渐进式的高效数据利用。除了关注梯度贡献，样本的多样性与任务相关性也是重要的考量维度。Wu 等人[205]则关注样本对下游任务的价值，提出了 ICONs 方法，利用特定任务的影响力矩阵进行多数投票，从而识别出对下游任务最关键的样本。然而，上述方法在多模态关联噪声场景下仍面临挑战：由于噪声样本往往表现出异常高的损失值或梯度范数，基于梯度或影响力的采样策略极易给予噪声样本过高的权重[76]。这种“高重要性”的误判不仅会导致计算资源的浪费，更可能引发模型对噪声模式的过拟合，这迫使研究者探索能够有效区分“高价值难样本”与“高梯度噪声”的新型动态采样机制。

2.3　总结

本章系统回顾了关联噪声下的鲁棒多模态对比学习的研究现状，主要从基于噪声修正的鲁棒学习和基于样本选择的高效学习两个视角展开。在噪声修正方面，重点

介绍了基于记忆效应的通用去噪理论、针对多模态特性的噪声建模策略以及利用特权信息辅助的学习方法，这些方法通过挖掘深度网络的训练动态、利用一致性约束或引入外部知识，实现了对错误关联信号的识别与校正。在样本选择方面，总结了基于规则或模型的离线数据清洗，以及基于课程学习、难样本挖掘与重要性采样的在线样本选择策略，这些方法通过筛选高价值样本并剔除低质量数据，提升了模型训练的效率与数据利用率。总体而言，本章为后续研究提供了全面的理论基础和技术参考，为进一步探索关联噪声下的鲁棒多模态算法奠定了基础。

第 3 章 基于几何结构一致性的关联噪声鲁棒方法

如前文所述，现实场景中普遍存在的关联噪声问题会导致错误的语义对齐，严重损害模型的表征对齐与泛化能力。针对现有研究难以有效应对关联噪声导致的多模态表征结构受损的问题，本章提出一种基于几何结构一致性的关联噪声鲁棒方法。该方法深入挖掘关联噪声样本与干净样本在跨模态及模态内几何结构分布上的显著差异，构建了结构一致性约束机制。结合深度神经网络的记忆效应，本章设计了自适应的噪声识别与软标签修正策略，并引入双网络协同与动量更新机制以保障训练过程的稳定性。实验结果表明，该方法能无缝集成至现有框架，并在多种噪声基准上取得了优于前沿方法的鲁棒性表现。

3.1 引言

在多模态表示学习领域，对比学习范式通过在统一的高维特征空间中拉近语义相关的模态表征并推远非相关表征，成功构建了具备良好判别性的特征结构，从而在各类多模态对齐任务中取得了卓越性能[206-207]。然而，该范式的成功高度依赖于训练数据的规模与质量。现有的主流方法通常假设训练数据为海量且高质量的图文对，这一假设在实际应用场景中往往难以满足。现实世界中的大规模数据集通常依赖于非专家的众包标注或基于关键词的网络自动化采集，这种数据获取方式不可避免地引入了大量关联噪声。具体而言，图像内容与文本描述之间可能存在语义错配、弱相关甚至完全无关的现象。若缺乏针对性的鲁棒处理机制，这种异构模态间的语义偏差将严重误导模型的优化方向，导致多模态模型在特征对齐过程中出现显著的性能退化。

关联噪声问题严重制约了多模态系统在医疗诊断[208-209]、自动驾驶[210-211]等安全攸关的高精领域的可信应用。因此，提升对比学习模型在关联噪声环境下的鲁棒性已成为当前的研究热点。关联噪声学习领域下的绝大多数工作致力于解决一个核心问题：如何在噪声干扰下准确推断潜在的真实关联标签，从而为跨模态表征对齐提供可靠的监督信号。NCR[14] 率先将噪声鲁棒学习引入该领域，采用协同学习[79] 策略，基于样本损失值的相对大小进行噪声筛选。随后 BiCro[15] 与 MSCN[22] 在此基础上引入元学习机制或利用少量干净数据子集作为引导，进一步提升了去噪性能。然而，深入分析可以发现，上述方法在本质上多借鉴于单模态噪声标签学习思想[81]，难以充分捕捉异构模态间复杂的交互特性。简单的样本筛选策略往往难以捕捉深层的语义关

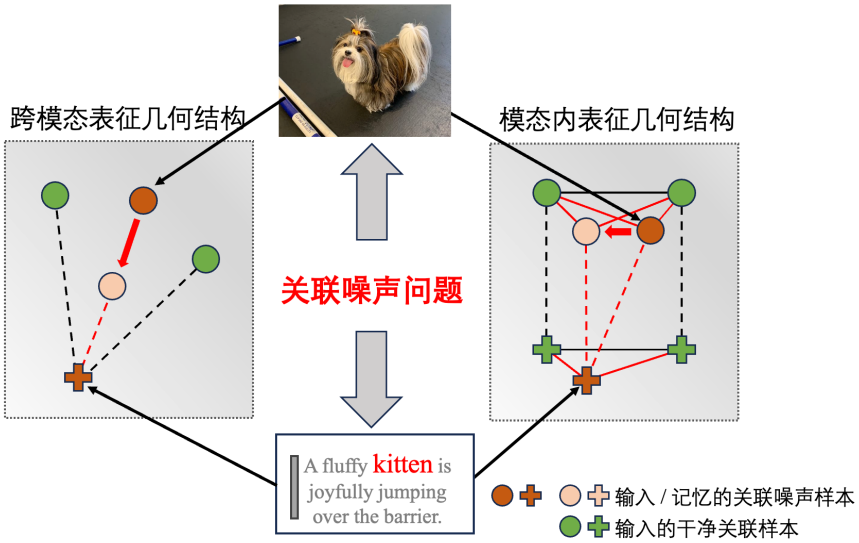

图 3.1　关联噪声问题对表征几何结构的影响示意图。关联噪声问题会同时影响多模态表征的跨模态与模态内几何结构。从跨模态视角（左图），关联噪声的图像与文本表征之间的距离被错误地拉近；从模态内视角（右图），关联噪声样本的模态内表征结构被错误地对齐，导致原本的邻域结构被破坏。

Figure 3.1　Illustration of the impact of noisy correspondence on representation geometric structures. Noisy correspondence simultaneously affects both the cross-modal and intra-modal geometric structures of multimodal representations. From the cross-modal perspective (left), the distance between image and text representations with noisy correspondence is wrongly reduced; from the intra-modal perspective (right), the intra-modal representation structures of noisy samples are incorrectly aligned, disrupting the original neighbouring relationships.

联，容易导致模型在训练后期对噪声模式产生过拟合，难以从根本上解决精确关联识别的问题。

与单模态分类任务中相对单一的标签噪声[212-213]不同，多模态场景下的关联噪声对特征表征的影响更为复杂，其同时破坏了跨模态与模态内的几何结构。如图 3.1 所示，该负面影响可从两个维度进行剖析：从跨模态几何结构的视角来看，该结构反映了不同模态表征之间的语义相似度。关联噪声的存在迫使模型错误地拉近本应远离的、语义不匹配的数据对，这不仅引入了错误的对齐信号，更破坏了原本有序的跨模态语义映射关系。从模态内几何结构的视角来看，该结构反映了同一模态内部样本间的邻域关系。对于干净关联的图像与文本数据对，不同样本在各自模态内往往呈现出对称的表征结构。当模型试图强制对齐两个含有关联噪声的异构模态时，这种错误的约束会迫使模态内的特征分布发生扭曲，导致原本语义相似的样本在特征空间中被推远，引发模态内结构坍塌，严重削弱表征的判别能力。尽管噪声造成了上述破坏，但通过分析特征空间的演化过程可以发现：在训练早期建立的几何结构中，干净

样本与噪声样本表现出显著的结构性差异。具体而言，干净样本倾向于在跨模态和模态内均保持较好的一致性与紧凑性。这种内蕴的结构差异，为设计区分噪声样本、精准预测真实关联标签的算法提供了重要的切入点。

基于上述对几何结构一致性的分析，本章提出了一种创新的基于几何结构一致性（Geometrical Structure Consistency, GSC）的多模态鲁棒对比学习框架，旨在从根源上缓解关联噪声带来的不利影响。具体而言，GSC 方法不仅依赖传统的跨模态对齐损失，更引入了模态内几何结构的一致性约束，通过联合优化维护特征空间结构的完整性。利用深度神经网络在训练初期优先记忆简单干净模式的记忆效应[60,214]，模型可在训练早期构建出相对可靠的几何结构基础。在此阶段，GSC 算法通过量化分析模态内与跨模态结构的差异性，动态评估样本的真实软关联标签：在跨模态层面，通过识别低相似度的数据对来定位显性噪声；在模态内层面，通过计算查询样本与邻域样本的相似度分布，构建模态内几何描述，并将那些在不同模态间表现出结构不一致的数据对判定为噪声。这些基于几何结构推断出的修正标签，将被以样本粒度作用于模型的损失函数，从而形成关联标签修正促进结构优化，结构优化提升标签估计的良性循环。本章的主要贡献归纳如下：

- 本章深入剖析了关联噪声对多模态对比学习的危害，即同时破坏跨模态与模态内表征几何结构，并揭示了在良好构建的几何结构下干净样本与噪声样本的显著分布差异。
- 本章提出了一种基于几何结构一致性的鲁棒学习方法。该方法突破了传统基于损失值筛选样本的局限，通过挖掘更深层的结构性差异信息来精准预测真实关联标签，并有效抑制了关联噪声的负面影响。
- 本章提出的 GSC 方法具有良好的通用性，可与现有的噪声处理基线兼容。在四个主流基准数据集上的广泛实验表明，GSC 在检索精度与鲁棒性方面均优于当前的前沿方法，提升了该任务的性能上限。

3.2 算法研究

3.2.1 符号定义

本节首先对关联噪声场景下的多模态对比学习进行形式化定义。为不失一般性并简化表述，本章以图像与文本的多模态预训练场景为例进行阐述。考虑一个包含 N 个样本的多模态数据集，记为 $\mathcal{D} = \{X_1^i, X_2^i, \hat{y}^i\}_{i=1}^N$，其中 $\{X_1^i, X_2^i\}$ 表示第 i 个多模态数据对，X_1 与 X_2 分别代表图像与文本输入。标准的多模态模型通常利用独立的编码器

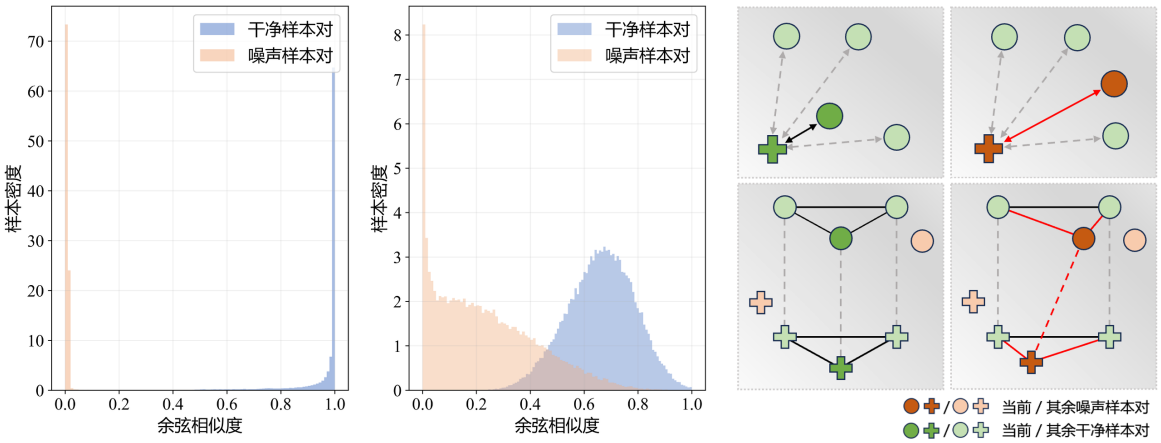

图 3.2　基于几何结构一致性识别关联噪声样本的实验动机与示意图。图一与图二：分别展示了干净与噪声样本表征在跨模态与模态内几何结构相似度上的显著分布差异，其中噪声样本的相似度分布普遍显著低于干净样本；图三：直观示意了 GSC 算法利用几何结构一致性差异识别噪声样本的原理，分别展示了跨模态（上行）与模态内（下行）视角下的判别逻辑。

Figure 3.2　Motivation and illustration for identifying noisy correspondence samples based on geometrical structure consistency. Figures 1 and 2: Respectively demonstrate the significant distributional differences between clean and noisy sample representations in terms of cross-modal and intra-modal geometrical structure similarities, where the similarity distributions of noisy samples are generally and significantly lower than those of clean samples. Figure 3: Illustrates the principle of the GSC algorithm in identifying noisy samples by utilizing differences in geometrical structure consistency, demonstrating the discrimination logic from the cross-modal (top row) and intra-modal (bottom row) perspectives, respectively.

f 和 g 将图像与文本映射到一个共享的高维表征空间，得到 $x_1^i = f(X_1^i)$ 与 $x_2^i = g(X_2^i)$，并利用余弦函数或推理模块计算跨模态表征之间的相似度 $\langle x_1^i, x_2^i \rangle$。$\hat{y}^i$ 表示观察到的的关联标签，用于描述图像 X_1^i 与文本 X_2^i 之间是否相互匹配。训练数据集通常假定给定数据对的不同模态是相互匹配的，即观测到的关联标签 $\hat{y}^i$ 恒为 1。然而，受到关联噪声影响，该标签常常带噪，无法反映模态之间潜在的真实关联 y^i。

3.2.2　研究动机

GSC 方法的核心思想在于挖掘数据的几何结构一致性，即利用跨模态与模态内表征的结构差异来精准甄别关联噪声。为验证这一假设的合理性，本节首先设计了一项先验实验，旨在探究干净样本与噪声样本在几何结构上的分布特性。如图 3.2 所示，实验首先在干净的 MS-COCO 数据集上训练标准多模态模型，利用目标函数约束模型习得一致的跨模态与模态内几何结构，随后将该模型置于引入了仿真关联噪声的数据集中进行评估。观察发现，干净样本与噪声样本在两种几何结构上均表现出显

著的分布差异。具体而言，在跨模态视角下，干净样本的相似度得分普遍高于噪声样本，两者的分布之间界限清晰；在模态内视角下，干净样本与噪声样本的几何结构相似度呈现双峰分布，其中绝大多数关联噪声样本的相似度低于 0.5，这表明其模态内几何结构发生了非对称性畸变。上述发现揭示了噪声样本破坏几何结构一致性的本质，为后续基于此特性设计噪声识别算法提供了重要的实证支撑。

3.2.3 算法设计

3.2.3.1 几何结构一致性优化

本节首先对跨模态与模态内几何结构及其相应的优化目标进行形式化定义。从跨模态视角来看，几何结构由异构模态表征间的相似度分布所定义。以给定的锚点图像 X_1^i 为例，其跨模态几何结构可表示为 $\mathcal{G}_{\text{CM}}^i = \{\langle x_1^i, x_2^j \rangle\}_{j=1}^N$。GSC 旨在通过最小化跨模态目标的期望风险来维护该结构的一致性，其目标函数形式化如下：

$$\min_{\theta_f, \theta_g} \mathbb{E}_{(X_1, X_2, \hat{y}) \sim \mathcal{D}} \left[\mathcal{L}_{\text{CM}}(\langle x_1, x_2 \rangle, \hat{y}) \right] \tag{3.1}$$

其中，θ_f 与 θ_g 分别表示编码器 f 与 g 的可学习参数，$\mathcal{L}_{\text{CM}}$ 代表跨模态损失函数，通常采用与传统检索模型一致的对比损失，如 InfoNCE 或三元组（Triplet Loss）损失函数。该优化目标依据观测到的关联标签 $\hat{y}$ 对齐跨模态表征，旨在最大化匹配数据对的相似度，同时拉开其与非匹配数据对在特征空间中的距离。

从模态内视角来看，几何结构反映了单模态内部样本间的邻域拓扑关系。对于第 i 个样本，其模态内结构表示为 $\mathcal{G}_{\text{IM}}^i = \{\langle x_1^i, x_1^j \rangle, \langle x_2^i, x_2^j \rangle\}_{j=1}^N$，其中 $\langle x_1^i, x_1^j \rangle$ 和 $\langle x_2^i, x_2^j \rangle$ 分别代表图像与文本模态内的成对相似度。为保持模态间拓扑结构的一致性，GSC 引入了如下模态内优化目标：

$$\min_{\theta_f, \theta_g} \mathbb{E}_{(X_1, X_2, y) \sim \mathcal{D}} \left[\mathcal{L}_{\text{IM}}(\langle x_1, x_1 \rangle, \langle x_2, x_2 \rangle, \hat{y}) \right] \tag{3.2}$$

在此公式中，$\mathcal{L}_{\text{IM}}$ 表示模态内损失函数。模态内目标旨在约束匹配样本在不同模态视图下呈现出相似的内部流形结构。值得注意的是，若仅进行跨模态对齐而忽视对模态内结构的拓扑优化，往往会导致推理结果的不一致性，从而限制模型的性能上限[215-216]。因此，引入模态内结构一致性约束是提升多模态表征质量的关键。如图 3.3 所示，GSC 通过联合优化上述两个目标，构建稳健的跨模态与模态内几何结构。

3.2.3.2 噪声识别与修正

深度神经网络通常表现出记忆效应，即模型对数据的拟合存在显著的时间优先级：它总是倾向于先学习数据中简单的、语义一致的规律，而后才过拟合复杂的随机

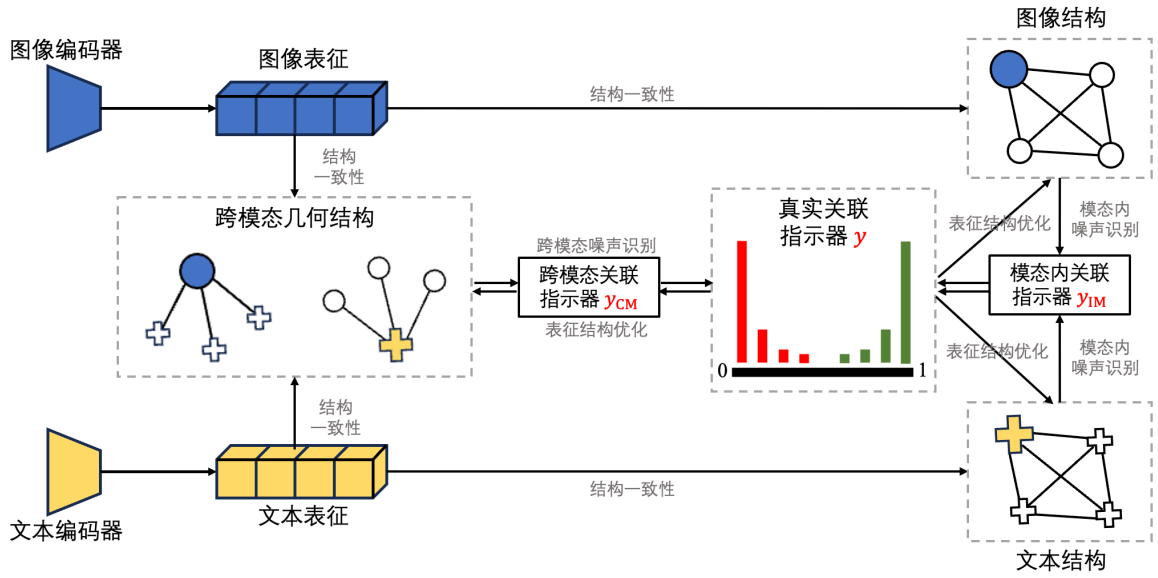

图 3.3　基于几何结构一致性的关联噪声鲁棒算法框架示意图。GSC 首先通过分别的编码器提取图像与文本表征，然后同时优化跨模态与模态内目标函数以保持几何结构一致性。随后 GSC 利用两种几何结构一致性来识别噪声样本并预测真实关联指示器 y，以抑制关联噪声的负面影响。

Figure 3.3　Illustration of the framework for Mitigating Noisy Correspondence by Geometrical Structure Consistency (GSC) Learning. GSC first extracts image and text representations via separate encoders, and then simultaneously optimizes cross-modal and intra-modal objective functions to preserve geometrical structure consistency. Subsequently, GSC utilizes both structural consistencies to identify noisy samples and predict the true correspondence indicator y, thereby mitigating the negative impact of noisy correspondence on the model.

噪声。这意味着在训练的早期阶段，模型所构建的特征空间主要由真实语义驱动，因而保持了较为完善的几何结构一致性。GSC 充分利用了这一特性，将训练早期的模态表征结构作为可靠的软监督信号，通过量化该结构下干净与噪声样本之间的差异，实现了对潜在真实关联标签的精准估计。

跨模态噪声识别。如图 3.2 右侧所示，得益于训练早期建立的可靠跨模态结构，干净数据对在特征空间中通常表现出显著优于噪声数据对的语义对齐度。基于这一结构性差异，GSC 设计了如下双向关联指示函数来量化跨模态匹配的置信度：

$$y^i_{\mathrm{CM}} = \frac{1}{2}\Big[\frac{\exp\left(\langle x^i_1, x^i_2\rangle/\tau_1\right)}{\sum_{j=1}^{N}\exp\left(\langle x^i_1, x^j_2\rangle/\tau_1\right)} + \frac{\exp\left(\langle x^i_1, x^i_2\rangle/\tau_1\right)}{\sum_{j=1}^{N}\exp\left(\langle x^j_1, x^i_2\rangle/\tau_1\right)}\Big] \tag{3.3}$$

其中 τ_1 为温度系数。该公式本质上衡量了当前样本对的相似度 $\langle x^i_1, x^i_2\rangle$ 在当前批次相似度分布中的相对占比。具体而言，以第一项为例，对于语义一致的干净样本，其配对相似度显著高于非配对样本，使得该项趋近于 1；反之，对于错误关联的噪声样本，其相似度值极低，导致指示值 y^i_{CM} 趋向于 0。通过双向计算并取均值，该指标能够更

稳健地反映跨模态语义的一致性。

模态内噪声识别。在模态内视角下，如图 3.2 右侧所示，匹配的图文对在各自的模态流形中应保持拓扑结构的一致性（即相互镜像的邻域关系）；而噪声数据对由于语义内容的偏离，往往导致其在不同模态下的领域结构出现显著差异。为捕捉这一特征，GSC 采用余弦相似度来度量模态内结构的一致性，记为 $\mathcal{S}^i_{\mathrm{IM}} = \cos(\{\langle x^i_1, x^j_1\rangle, \langle x^i_2, x^j_2\rangle\}^N_{j=1})$。实验观察表明（如图 3.2 左侧所示），干净样本的模态内结构相似度显著高于噪声样本，且整体分布呈现出典型的双峰特性。基于此，GSC 引入双分量高斯混合模型（Two-component Gaussian Mixture Model, GMM）[81] 对该分布进行拟合：

$$p(\mathcal{S}_{\mathrm{IM}}) = \sum_{k=1}^{K} \alpha_k \phi(\mathcal{S}_{\mathrm{IM}}|k),\ y^i_{\mathrm{IM}} = \frac{\alpha_{k_l}\phi(\mathcal{S}^i_{\mathrm{IM}}|k_l)}{\sum_{k=1}^{K}\alpha_k\phi(\mathcal{S}^i_{\mathrm{IM}}|k)} \tag{3.4}$$

其中 $K = 2$ 表示混合分量的数量，α_k 和 $\phi(\cdot|k)$ 分别表示第 k 个分量的混合系数与概率密度函数。通过计算观测样本属于高均值分量（即干净样本分量，记为 $k = k_l$）的后验概率，即可得到模态内关联指示标签 y^i_{IM}。对于结构一致性高的干净样本，该后验概率趋近于 1；而对于结构畸变的噪声样本，其值趋近于 0，从而实现基于模态内几何结构差异的噪声鉴别。

至此，GSC 分别从跨模态与模态内结构一致性两个维度估计了潜在的真实关联标签 y_{CM} 和 y_{IM}。考虑到单一视角可能存在的判别局限性，如某些噪声样本可能偶然具有较高的跨模态相似度但结构不一致，GSC 采用稳健的融合策略，将最终的关联标签定义为二者的最小值：

$$y^i = \min\{y^i_{\mathrm{CM}}, y^i_{\mathrm{IM}}\} \tag{3.5}$$

关联噪声样本修正。基于前述估计得到的软标签 $y^i \in [0, 1]$，GSC 通过修正优化目标函数，显式地抑制关联噪声对表征学习的负面影响。由于 y^i 直接反映了多模态样本对潜在的真实关联度，本研究将其作为样本级权重无缝集成至损失函数中，实现对噪声样本梯度的有效衰减。对于跨模态目标，GSC 采用加权形式的对比损失函数。修正后的跨模态损失定义如下：

$$\mathcal{L}_{\mathrm{CM}} = -\frac{1}{2N}\sum_{i=1}^{N} y^i \left[\log\frac{\exp\left(\langle x^i_1, x^i_2\rangle/\tau_1\right)}{\sum_{j=1}^{N}\exp\left(\langle x^i_1, x^j_2\rangle/\tau_1\right)} + \log\frac{\exp\left(\langle x^i_1, x^i_2\rangle/\tau_1\right)}{\sum_{j=1}^{N}\exp\left(\langle x^i_2, x^j_1\rangle/\tau_1\right)}\right] \tag{3.6}$$

其中，权重 y 作用于每个样本的损失项，使得模型能够自适应地关注置信干净样本。对于模态内目标，仅对最终损失进行加权是不够的。为防止噪声样本扭曲几何结构的构建，必须在计算结构相似度矩阵时就排除其干扰。具体而言，GSC 在构建模态内

拓扑关系时引入了双重加权机制。修正后的模态内损失表示为：

$$\mathcal{L}_{\mathrm{IM}} = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{\exp(\sum_{k=1}^{N} y^k\langle x_1^i, x_1^k\rangle y^k\langle x_2^i, x_2^k\rangle/\tau_2)}{\sum_{j=1}^{N}\exp\left(\sum_{k=1}^{N} y^k\langle x_1^i, x_1^k\rangle y^k\langle x_2^j, x_2^k\rangle/\tau_2\right)} \tag{3.7}$$

其中 τ_2 为温度系数。值得注意的是，在此公式中，权重 y^k 被用于调节特征相似度 $\langle x_1, x_1\rangle$ 与 $\langle x_2, x_2\rangle$ 的贡献，从而在源头上阻断噪声样本参与几何结构的构建。同理，在计算用于模态内鉴别的余弦相似度得分时，也采用了类似的加权策略以确保评估的鲁棒性：

$$\mathcal{S}_{\mathrm{IM}}^i = \frac{\sum_{j=1}^{N} y^j\langle x_1^i, x_1^j\rangle y^j\langle x_2^i, x_2^j\rangle}{\sqrt{\sum_{j=1}^{N}(y^j\langle x_1^i, x_1^j\rangle)^2}\sqrt{\sum_{j=1}^{N}(y^j\langle x_2^i, x_2^j\rangle)^2}} \tag{3.8}$$

考虑到在全量数据集上计算的高昂计算复杂度，GSC 在实际训练中采用蒙特卡洛采样策略，将计算规模从全量 N 缩减至当前批次大小 B。最终，GSC 的总体优化目标由上述两部分加权构成：

$$\mathcal{L} = \mathcal{L}_{\mathrm{CM}} + \gamma\mathcal{L}_{\mathrm{IM}} \tag{3.9}$$

其中，超参数 γ 用于平衡跨模态与模态内优化目标以达到最佳效果。

3.2.3.3　训练策略

为了实现真实关联标签估计与跨模态表征学习的协同优化，受 Liu et al.[13] 的启发，GSC 采用时间集成（Temporal Ensembling）机制对关联标签进行平滑更新。具体而言，在执行较小值融合策略之前，跨模态指示器 y_{CM} 和模态内指示器 y_{IM} 均基于动量更新策略，结合当前轮次 t 的观测值与前一个轮次 $t-1$ 的历史估计值进行迭代：

$$\begin{aligned} y_{\mathrm{CM}}^i[t] &= \beta_1 y_{\mathrm{CM}}^i[t] + (1-\beta_1) y_{\mathrm{CM}}^i[t-1], \\ y_{\mathrm{IM}}^i[t] &= \beta_2 y_{\mathrm{IM}}^i[t] + (1-\beta_2) y_{\mathrm{IM}}^i[t-1] \end{aligned} \tag{3.10}$$

其中 β_1 和 β_2 为独立的动量超参数。此外，为了进一步增强算法的鲁棒性，GSC 引入了双网络交叉监督机制，即利用两个独立初始化的网络，相互使用对方输出的关联标签作为监督信号，从而有效规避单一模型的认知偏差。第 3.3 节的消融实验结果证实了上述策略对提升模型性能的显著作用。基于几何结构一致性（GSC）的关联噪声鲁棒对比学习算法的完整算法流程总结于算法 3.1 中。

3.2.4　讨论与分析

本章提出的 GSC 方法之所以能取得显著的性能提升，核心在于其对几何结构一致性的显式维护以及优化的关联噪声标签加权策略，这种设计不仅强化了表征的鲁

算法 3.1 基于几何结构一致性的关联噪声鲁棒对比学习算法

Input: 多模态数据集 $\mathcal{D} = \{X_1^i, X_2^i, \hat{y}^i\}_{i=1}^N$，训练轮数 T 和批次大小 $\mathcal{B}$。

为多模态深度学习模型 A 与模型 B 随机初始化参数。
for 训练轮次 $t = 1, 2, \ldots, T$ **do**
  for 深度学习模型 $k = A, B$ **do**
    for 单一批次 $\mathcal{B} \sim \mathcal{D}$ **do**
      计算图像与文本模态表征 x_1, x_2；
      基于公式（3.3）预测跨模态关联噪声指示器 $y_{\mathrm{CM}}[t]$；
      基于公式（3.4）预测模态内关联噪声指示器 $y_{\mathrm{IM}}[t]$；
      使用公式（3.6）计算鲁棒优化后的跨模态损失函数；
      使用公式（3.7）计算鲁棒优化后的模态内损失函数；
      使用公式（3.9）结合两种损失并进行梯度回传优化网络参数。
    使用公式（3.10）更新关联噪声指示器 $y_{\mathrm{CM}}[t]$ 和 $y_{\mathrm{IM}}[t]$；
    更新对另一深度学习模型的关联噪声指示器 $y[t]$ 的预测。

Output: 鲁棒深度学习模型 A 与模型 B。

棒性，更使其能够无缝兼容大多数现有的多模态模型框架与算法。在计算效能方面，GSC 摒弃了复杂的辅助网络或模块设计：对于基于特征点积计算相似度的标准双塔架构，本方法几乎不引入额外开销；即便是面对包含相似度模块的复杂架构，也仅需增加两次额外的前向传播。相较于需要训练元学习网络的 MSCN[22] 或依赖于净子集检索的 BiCro[15]，GSC 在资源消耗上展现出明显的优势；而与计算成本相近的 RINCE[134] 相比，GSC 则凭借显式的去噪机制在高噪声场景下保持了更优的稳定性。此外，区别于 NCR[14] 及其衍生方法对双网络协同架构的高度依赖，GSC 的几何一致性约束在单模型架构下依然有效，这种独立工作的能力赋予了算法极佳的架构扩展性，使其更易于部署并适配大规模预训练模型。

3.3 实验验证

3.3.1 实验设定介绍

3.3.1.1 数据集与评价指标

数据集介绍。训练数据中普遍存在的关联噪声严重破坏了多模态模型的高维表征结构，进而削弱了其在跨模态检索等对齐任务中的泛化性能。为全面评估本文提出方法的有效性与鲁棒性，本章选取了四个具有不同规模与噪声分布特性的主流图文检索基准数据集进行实验。遵循 NCR[14] 的实验范式，将实验场景划分为仿真噪声设定与真实世界噪声设定：

- **Flickr30K**[217]：该数据集采集于 Flickr 平台，内容侧重于日常生活场景与人物活动的描述。作为经典的高质量数据集，其图文对应关系经过人工校验，通常被视为干净数据的基准。在实验设置上，根据 Karpathy 划分标准[218]，数据集被划分为：29,000 对图文数据用于训练集，1,000 对数据用于验证集以及 1,000 对数据用于测试集。
- **MS-COCO**[219]：该数据集是计算机视觉领域最具影响力与权威性的大规模数据集之一，以场景复杂、语义丰富著称。得益于精细的人工标注，该数据集具备极高的图文对齐质量，同样被视为理想的无噪声基准。在实验设置上，根据 Karpathy 划分标准[218]，数据集被划分为：123,287 对图文数据用于训练集，5,000 对数据用于验证集，5,000 对用于测试集。MS-COCO 的测试评估既可以使用完整的 5,000 张测试集，也可以采用 5 折交叉验证的方式，即每次在 1,000 张子集上测试并取平均值。
- **NUS-WIDE**[220]：该数据集是由新加坡国立大学发布的源自 Web 的大规模多模态数据集，包含从 Flickr 抓取的图像及其关联信息。不同于上述数据集的自然语言描述，该数据集的文本模态主要由用户上传图片时标注的松散标签组成且未经严格清洗，因此天然包含一定比例的关联噪声数据。本实验随机抽取 100,000 对图文数据作为训练集，1,000 对数据作为验证集以及 1,000 对作为测试集。
- **Conceptual Captions**[94]：该数据集是通过自动化流程从互联网大规模抓取构建的图文对集合，旨在突破人工标注成本高昂的瓶颈。由于缺乏人工清洗，研究表明该原始数据中仍有约 3%-20% 的图文对存在不匹配或弱匹配现象[94]，代表了真实的关联噪声场景。本实验使用了该数据集的一个子集 CC152K，其中包含 150,000 对图文数据作为训练集，1,000 对数据作为验证集以及 1,000 对数据作为测试集。

此外，为了进一步评估本文提出方法在除了图像-文本之外的其他模态场景的有效性与鲁棒性，本章进一步在两个不同规模的视频检索基准数据集上进行了实验：

- **MSR-VTT**[221]：该数据集是视频-文本检索领域最广泛采用的基准之一，包含 10,000 个开放领域的短视频片段，每个片段配有 20 句独立的人工标注描述。由于其涵盖了多样的视觉场景与丰富的语义表达，常被用于验证跨模态特征对齐的泛化能力。本实验遵循该领域的标准划分设定，使用 9,000 个视频的图文对作为训练集，剩余 1,000 个视频用于测试评估。
- **MSVD**[222]：该数据集由 1,970 个取自 YouTube 的短视频片段组成，每个视频包

表 3.1 关联噪声基准数据集的统计信息。具体从数据集关联噪声类型、噪声率以及训练集、验证集与测试集划分进行介绍。

Table 3.1 Statistics of the noisy correspondence benchmark datasets. Specifically, it details the types of noisy correspondence, noise ratios, and the splits of training, validation and testing sets.

数据集	关联噪声类型	噪声率	训练数据量	验证数据量	测试数据量
Flickr30K	仿真噪声	20%, 40%, 60%	29,000	1,000	1,000
MS-COCO	仿真噪声	20%, 40%, 60%	123,287	5,000	5,000
NUS-WIDE	仿真/真实噪声	20%, 40%, 60%	100,000	1,000	1,000
MSR-VTT	仿真噪声	20%, 40%	9,000	/	1,000
MSVD	仿真噪声	20%, 40%	1,200	100	670
CC152K	真实噪声	约 3% ~ 20%	150,000	1,000	1,000

含约 40 句英文标注描述。相比于 MSR-VTT，该数据集侧重于日常活动与单一动作场景。在实验设置上，本章遵循通用的标准划分，其中 1,200 个视频用于训练，100 个用于验证，剩余 670 个视频用于测试。

仿真关联噪声设定。为了模拟真实世界中复杂多变的噪声分布场景，包括从低噪声率的医疗影像分析与自动驾驶感知，到高噪声率的互联网搜索引擎与图文生成任务，本章在经过严格人工清洗且质量较高的 MS-COCO、Flickr30K、NUS-WIDE、MSR-VTT 与 MSVD 数据集上引入了不同比例的仿真关联噪声。

具体而言，对于 NUS-WIDE、MSR-VTT 与 MSVD 数据集，实验根据预设的噪声比例随机选取对应数量的样本子集，并对其关联关系进行随机打乱。而对于 MS-COCO 与 Flickr30K 数据集，鉴于其一张图像对应五条文本的特性，简单的随机打乱可能使图像仍与属于同一原始样本的另一条文本匹配，导致引入假阴性噪声。因此本研究遵循 DECL[17] 的噪声构造策略，采用基于文本的图像重排策略：确保被打乱的图像被重新分配给属于完全不同样本的文本描述，从而构建具有高难度的噪声样本。

上述数据集涵盖了从数万到数十万的不同量级与分布，结合不同强度的仿真噪声与真实噪声设定，共同构成了一个全面且多层次的测试基准，能够系统地评估多模态对比学习算法的抗噪鲁棒性。本章所使用的基准数据集统计信息汇总于表 3.1中。

评价指标。为了定量评估跨模态检索任务的性能，本章采用领域通用的 Top-K 召回率（Recall at K, R@K）作为核心评价指标。召回率 R@K 主要用于衡量模型检索结果的排序质量，具体反映了对于给定的查询样本，其匹配的真实关联项出现在模型预测的前 K 个排序结果中的比例。该指标能够直观地体现模型将语义相关的跨模态样本映射到特征空间邻近位置的能力，较高的 R@K 值意味着模型具有更优的语义对齐效果和检索准确性；实验中通常分别计算并汇报 R@1 、R@5 和 R@10 的结果及其总和

Recall Sum，以综合考察模型在精确检索场景下的表现。形式化地，给定查询集合大小为 N，R@K 的定义可以表达为如下等式：

$$\mathrm{R@}K = \frac{1}{N}\sum_{i=1}^{N}\mathbb{1}(rank_i \le K) \tag{3.11}$$

其中，$rank_i$ 表示对于第 i 个查询样本，与其匹配的真实关联项在检索列表中的预测排名，$\mathbb{1}(\cdot)$ 为指示函数。针对视频检索任务，本章进一步采用中位排名（Median Rank, MdR）与平均排名（Mean Rank, MnR），两个指标数值越低代表模型排序越精准。

3.3.1.2　实验实施细节

针对本章使用的所有图文检索数据集，实验均采用 SGR[223] 模型作为基础架构。在图像特征提取方面，选用在 Visual Genome[224] 数据集上预训练、以 ResNet-101 为骨干网络的 Faster R-CNN[225] 目标检测器；通过自底向上的注意力机制识别图像显著性内容，选取置信度最高的 36 个区域并映射为 2048 维特征向量，从而构建包含 36 个局部特征的表征序列。在文本特征提取方面，首先利用预训练的 300 维 GloVe 词向量对分词后的单词进行初始化嵌入，随后将其输入双向门控循环单元（Bi-GRU）以捕捉上下文语义依赖，最终生成包含序列信息的 1024 维词元级特征向量。针对视频检索数据集，实验均采用 CLIP4Clip[226] 模型作为基础架构，视觉与文本特征提取器分别初始化自预训练的 CLIP-ViT 模型。

所有实验均基于 PyTorch 深度学习框架实现，并在单张 NVIDIA A100 GPU 计算平台上完成端到端训练。在训练策略方面，总迭代轮数设定为 40，全程采用 Adam 优化器[227]进行参数更新；初始学习率设为 2×10^{-4}，并实施分步衰减策略，即在训练进行至第 15 轮时将学习率乘以衰减系数 0.2 以促进模型后期的稳定收敛。除非消融实验另有说明，训练批量大小统一设定为 128，多模态共享表征空间的特征映射维度固定为 1024。针对模型超参数，温度系数 τ_1 和 τ_2 分别默认设为 0.07 和 1；用于平衡跨模态损失 $\mathcal{L}_{\mathrm{CM}}$ 与模态内损失 $\mathcal{L}_{\mathrm{IM}}$ 的权重超参数 λ 设定为 0.01；涉及动量更新机制的参数 β_1 和 β_2 均经验性地设定为 0.7。在模型选择阶段，本文全程监控验证集上的检索性能，并选取 Recall Sum 指标达到最优时的模型权重作为最终测试模型，以确保评估结果的可靠性与泛化能力。

3.3.1.3　实验中涉及的算法介绍

为了确保实验对比的公平性与有效性，本章所有图文检索实验均基于统一的基准骨干网络 SGR 与 SGRAF[223] 进行实现。其中，SGR 模块通过构建包含局部视觉区

域与文本词单元的异构图结构，利用图卷积网络进行全局性的节点关系推理，以捕获深层次的结构化语义对齐；SGRAF 则采取集成策略，将 SGR 的推理能力与 SAF 模块消除无关干扰信息的能力相结合，通过融合两个分支的相似度得分来决定最终的跨模态匹配结果。视频检索实验则基于基准骨干网络 CLIP4Clip[226]。在此基础上，本章选取了两类代表性的噪声鲁棒对比学习方法作为基准进行对比，具体介绍如下：

从**基于噪声样本识别的对比学习鲁棒方法**角度出发，选择了三种当时的先进算法：

- **NCR[14]：** 该方法利用深度神经网络的记忆效应，通过高斯混合模型对损失分布进行拟合，动态地将训练数据划分为干净集与噪声集。在此基础上，采用自适应的标签校正机制与协同训练策略，有效减轻了关联噪声对模型优化的干扰。
- **MSCN[22]：** 该方法提出了一种元学习相似度校正网络。它利用元学习范式，通过在少量干净验证集上获得的梯度指导训练过程，逐步筛选并修正潜在的关联噪声，从而提升模型在含噪数据上的鲁棒性。
- **BiCro[15]：** 该方法设计了一种双向跨模态噪声清洗机制。它通过同时考量图像检索文本与文本检索图像两个方向的一致性来精准检测噪声对，并利用清洗后的高置信度样本生成伪标签，以指导后续的对比学习过程。

从**基于鲁棒损失函数的对比学习方法**角度出发，选择了两种当时的先进算法：

- **DECL[17]：** 该方法将证据深度学习理论引入跨模态检索任务，通过主观逻辑对跨模态匹配的不确定性进行显式建模。该算法能够识别并降低潜在噪声样本在优化过程中的权重，从而实现鲁棒学习。
- **RINCE[134]：** 针对标准 InfoNCE 损失函数在噪声环境下易过拟合的问题，该方法推导并提出了一种具有对称性的鲁棒损失函数。该函数能够对噪声样本产生的异常梯度进行惩罚性抑制，从理论上保证了噪声环境下的学习稳定性。

3.3.2 主要实验结果

3.3.2.1 在仿真关联噪声数据集上的鲁棒性对比

为了全面评估各方法在不同噪声强度下的鲁棒性，本节在 Flickr30K、MS-COCO 与 NUS-WIDE 三个高质量数据集上引入了 20% 至 60% 的仿真噪声，并以此为基准进行了系统性的对比实验。表 3.2 和表 3.3 汇总了 GSC 与当前最先进方法在不同噪声率下的性能表现。实验结果表明，在缺乏鲁棒机制的情况下，传统模型 SGR 与 SGRAF 的性能随噪声增加呈断崖式下跌；特别是在 40% 与 60% 的高噪声率下，两者的 Recall@1 均不足 10%，这深刻揭示了关联噪声对多模态表征学习的破坏力。在对比的鲁棒算法中，NCR 与 RINCE 在高噪声场景下均出现了明显的性能瓶颈。特别

表 3.2　GSC 与现有关联噪声鲁棒方法在 Flickr30K 与 MS-COCO 数据集上在 20%、40% 和 60% 噪声率下的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示，次优方法的结果加下划线表示。

Table 3.2　Comparison of cross-modal retrieval performance between GSC and existing noisy correspondence robust methods on the Flickr30K and MS-COCO datasets under 20%, 40%, and 60% noise rates. The experimental results respectively present the image-to-text and text-to-image retrieval recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the sum of the recall rates. The best results in the table are highlighted in bold, and the second-best results are underlined.

Noise	Methods	Flickr30K							MS-COCO						
		Image → Text			Text → Image				Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum	R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	SGR[223]	55.9	81.5	88.9	40.2	66.8	75.3	408.6	25.7	58.8	75.1	23.5	58.9	75.1	317.1
	SGRAF[223]	72.8	90.8	95.4	56.4	82.1	88.6	486.1	75.4	95.2	97.9	60.1	88.5	94.8	511.9
	NCR[14]	73.5	93.2	96.6	56.9	82.4	88.5	491.1	76.6	95.6	98.2	60.8	88.8	95.0	515.0
	DECL[17]	77.5	93.8	97.0	56.1	81.8	88.5	494.7	77.5	95.9	98.4	61.7	89.3	95.4	518.2
	RINCE[134]	72.1	92.2	95.7	54.9	79.8	85.3	480.0	73.8	95.6	98.5	61.7	89.2	94.7	513.5
	MSCN[22]	77.4	**94.9**	97.6	59.6	83.2	89.2	501.9	78.1	**97.2**	98.8	64.3	90.4	95.8	524.6
	BiCro[15]	78.1	94.4	97.5	**60.4**	84.4	89.9	504.7	78.8	96.1	98.6	63.7	90.3	95.7	523.2
	GSC	**78.3**	94.6	**97.8**	60.1	**84.5**	**90.5**	**505.8**	**79.5**	96.4	**98.9**	**64.4**	**90.6**	**95.9**	**525.7**
40%	SGR[223]	4.1	16.6	24.1	4.1	13.2	19.7	81.8	1.3	3.7	6.3	0.5	2.5	4.1	18.4
	SGRAF[223]	8.3	18.1	31.4	5.3	16.7	21.3	101.1	15.8	23.4	54.6	17.8	43.6	54.1	209.3
	NCR[14]	68.1	89.6	94.8	51.4	78.4	84.8	467.1	74.7	94.6	98.0	59.6	88.1	94.7	509.7
	DECL[17]	72.7	92.3	95.4	53.4	79.4	86.4	479.6	75.6	95.5	**98.3**	59.5	88.3	94.8	512.0
	RINCE[134]	71.2	90.7	95.6	52.7	78.5	85.6	474.3	71.2	95.8	97.9	59.1	88.6	94.3	506.9
	MSCN[22]	71.6	92.8	96.2	54.8	80.7	87.4	483.5	75.3	95.4	98.2	60.3	88.6	94.8	512.6
	BiCro[15]	74.6	92.7	96.2	55.5	81.1	87.4	487.5	77.0	**95.9**	**98.3**	61.8	89.2	94.9	517.1
	GSC	**76.5**	**94.1**	**97.6**	**57.5**	**82.7**	**88.9**	**497.3**	**78.2**	**95.9**	98.2	**62.5**	**89.7**	**95.4**	**519.9**
60%	SGR[223]	1.5	6.6	9.6	0.3	2.3	4.2	24.5	0.1	0.6	1.0	0.1	0.5	1.1	3.4
	SGRAF[223]	2.3	5.8	10.9	1.9	6.1	8.2	35.2	0.2	3.6	7.9	1.5	5.9	12.6	31.7
	NCR[14]	13.9	37.7	50.5	11.0	30.1	41.4	184.6	0.1	0.3	0.4	0.1	0.5	1.0	2.4
	DECL[17]	65.2	88.4	94.0	46.8	74.0	82.2	450.6	73.0	94.2	97.9	57.0	86.6	93.8	502.5
	RINCE[134]	64.5	86.8	92.9	46.5	72.8	79.7	443.2	72.3	94.0	97.9	58.4	86.6	92.5	501.7
	MSCN[22]	68.8	90.3	94.4	50.8	77.4	84.4	466.1	72.5	93.6	97.1	57.7	87.0	93.9	501.8
	BiCro[15]	67.6	90.8	94.4	51.2	77.6	84.7	466.3	73.9	94.4	97.8	58.3	87.2	93.9	505.5
	GSC	**70.8**	**91.1**	**95.9**	**53.6**	**79.8**	**86.8**	**478.0**	**75.6**	**95.1**	**98.0**	**60.0**	**88.3**	**94.6**	**511.7**

是 NCR，当噪声率超过 50% 时，其筛选机制趋于失效，倾向于将所有样本误判为干净样本，导致去噪能力严重退化。

相比之下，GSC 在所有测试基准上均展现出了显著的性能优势。在 Flickr30K、MS-COCO 和 NUS-WIDE 数据集上，GSC 的召回率总和相较于次优方法分别实现了 7.5%、3.4% 和 12.75% 的平均提升，充分验证了其卓越的抗噪鲁棒性。值得强调的是，即使 BiCro 和 DECL 采用了增强的 SGRAF 主干网络，GSC 依然在多种条件下表现出领先优势。此外，随着噪声比例的攀升，GSC 带来的性能增益愈发显著，尤其是在 60% 的极端噪声条件下，其表现出的稳定性进一步证实了该方法在恶劣噪声环境

表 3.3　GSC 与现有关联噪声鲁棒方法在 NUS-WIDE 数据集上在 0%、20%、40% 和 60% 噪声率下的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示，次优方法的结果加下划线表示。

Table 3.3　Comparison of cross-modal retrieval performance between GSC and existing noisy correspondence robust methods on the NUS-WIDE datasets under 0%, 20%, 40%, and 60% noise rates. The experimental results respectively present the image-to-text and text-to-image retrieval recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the sum of the recall rates. The best results in the table are highlighted in bold, and the second-best results are underlined.

Noise	Methods	Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
干净	SGR[223]	39.3	66.5	74.0	37.1	64.2	73.6	354.7
	NCR[14]	40.0	**67.3**	**74.6**	38.9	65.9	74.3	361.0
	GSC	**42.9**	65.9	74.0	**39.8**	**66.0**	**74.5**	**363.1**
20%	SGR[223]	33.4	60.7	69.8	31.1	58.7	68.2	321.9
	DECL[17]	36.1	63.0	72.5	36.4	60.6	72.0	340.6
	GSC	**37.9**	**65.2**	**73.4**	**38.3**	**63.8**	**73.1**	**351.7**
40%	SGR[223]	30.8	57.9	67.3	28.4	55.9	65.5	305.8
	DECL[17]	34.1	59.5	68.8	34.5	60.0	69.1	326.0
	GSC	**37.0**	**63.5**	**71.3**	**36.8**	**62.4**	**71.1**	**342.1**
60%	SGR[223]	25.0	50.2	59.8	25.0	49.3	60.3	269.6
	BiCro[15]	27.8	53.4	63.2	27.9	52.2	64.1	288.6
	GSC	**31.6**	**57.4**	**66.1**	**31.1**	**57.8**	**66.3**	**310.3**

下的可靠性与有效性。

3.3.2.2　在真实关联噪声数据集上的鲁棒性对比

为了验证算法在面对真实世界复杂噪声分布时的鲁棒能力，实验进一步在天然包含噪声的 NUS-WIDE 与 CC152K 数据集上进行了对比评估。表 3.3干净部分与表 3.4的结果显示，GSC 在真实场景中依然保持了领先优势。具体而言，在噪声水平相对温和的 NUS-WIDE 数据集上，GSC 的检索性能超越了次优方法 NCR 达 2.1%，并大幅提升了主干网络 SGR 的模型鲁棒性；而在噪声环境更为严苛的 CC152K 数据集上，GSC 更是取得了 375.1% 的最佳召回率总和，领先次优方法 BiCro 幅度达 4.9% 。值得强调的是，相较于 BiCro 对其骨干网络 SGRAF 带来的 46.3% 提升，GSC 为基础骨干网络 SGR 带来了高达 209.7% 的性能飞跃。这一显著的性能增益有力地证明了，GSC 不仅能有效应对分布可控的仿真噪声，在处理现实场景中结构复杂、不可预知的真实关联噪声时，同样具备卓越的适应性与鲁棒性。

表 3.4　GSC 与现有关联噪声鲁棒方法在 CC152K 数据集上的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示，次优方法的结果加下划线表示。

Table 3.4　Comparison of cross-modal retrieval performance between GSC and existing noisy correspondence robust methods on the CC152K dataset. The experimental results respectively present the image-to-text and text-to-image retrieval recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the sum of the recall rates. The best results in the table are highlighted in bold, and the second-best results are underlined.

Methods	CC152K						
	Image → Text			Text → Image			
	R@1	R@5	R@10	R@1	R@5	R@10	Sum
SGR[223]	11.3	29.7	39.6	13.1	30.1	41.6	165.4
SGRAF[223]	32.5	59.5	70.0	32.5	60.7	68.7	323.9
NCR[14]	39.5	64.5	73.5	40.3	64.6	73.2	355.6
DECL[17]	39.0	66.1	75.5	40.7	66.3	<u>76.7</u>	364.3
RINCE[134]	35.9	63.0	73.8	37.6	65.0	73.4	348.7
MSCN[22]	40.1	65.7	<u>76.6</u>	40.6	67.4	76.3	366.7
BiCro[15]	<u>40.8</u>	<u>67.2</u>	76.1	<u>42.1</u>	**67.6**	76.4	<u>370.2</u>
GSC	**42.1**	**68.4**	**77.7**	**42.2**	**67.6**	**77.1**	**375.1**

3.3.2.3　在视频检索数据集上的鲁棒性能对比

为了验证方法在图像-文本之外的其他模态的鲁棒性能，本章进一步在 MSR-VTT 与 MSVD 视频检索基准上比较 GSC 与现有鲁棒算法的性能。如表 3.5所示，实验表明在关联噪声下基础模型 CLIP4Clip 的多模态表征对齐能力受到严重干扰，检索性能出现大幅衰减。尽管前沿鲁棒方法 BiCro 展现出了较强的抗噪能力，但本文提出的 GSC 方法在两种数据集的所有噪声设定与评价指标下均取得了最优的检索表现。特别是在 40% 的高噪声比例下，GSC 在 MSR-VTT 与 MSVD 数据集上的 R@1 指标依然分别达到了 41.6% 与 45.3%，且在平均排名指标上实现了最优的一致性收敛。这一结果不仅表明 GSC 能够有效抵御高比例关联噪声对高维特征空间的破坏，也进一步验证了该方法在视频-文本跨模态检索任务中同样具备卓越的鲁棒性与泛化能力。

3.3.2.4　与预训练模型的性能对比

为了验证经过鲁棒性增强的模型在关联噪声场景下是否具备匹配甚至超越大规模预训练模型的能力，本节在 MS-COCO 数据集上将 GSC 与 CLIP[3] 进行了对比实验。作为利用约 4 亿互联网图文数据预训练的代表性模型，CLIP 的训练过程天然面临关联噪声的挑战。表 3.6 详细列出了基于 ViT-Large 的 CLIP-L（约 428M 参数）与基于 ViT-Base 的 CLIP-B（约 150M 参数）的零样本推理性能，以及它们在引入不同

表 3.5　GSC 与现有最优鲁棒算法在 MSR-VTT 与 MSVD 数据集上的视频检索性能比较。实验结果分别展示了不同方法的视频检索召回率，R@K 为 Top-K 召回率评价指标，还展示了 MdR 中位排名与 MnR 平均排名评价指标。

Table 3.5　Comparison of video retrieval performance between GSC and robust algorithm BiCro on MSR-VTT and MSVD datasets. The experimental results respectively present the video retrieval recall rates of different methods, where R@K is the Top-K recall rate evaluation metric. Additionally, the MdR median rank and MnR average rank evaluation metrics are also shown.

Datasets	Noise	Methods	R@1↑	R@5↑	R@10↑	MdR↓	MnR↓
MSR-VTT	20%	CLIP4Clip[226]	35.1	61.5	71.6	3.0	25.2
		BiCro	41.2	68.1	78.9	2.0	15.9
		GSC	**41.9**	**69.4**	**79.2**	**2.0**	**15.6**
	40%	CLIP4Clip[226]	28.7	51.9	64.7	5.0	40.3
		BiCro	40.4	66.4	77.5	2.0	19.0
		GSC	**41.6**	**67.8**	**78.4**	**2.0**	**17.9**
MSVD	20%	CLIP4Clip[226]	40.9	70.6	80.4	2.0	13.8
		BiCro	45.3	74.7	83.8	2.0	11.1
		GSC	**46.0**	**75.4**	**84.5**	**2.0**	**10.5**
	40%	CLIP4Clip[226]	35.7	65.0	75.7	3.0	20.5
		BiCro	43.6	72.9	82.2	2.0	12.0
		GSC	**45.3**	**75.0**	**83.7**	**2.0**	**10.8**

比例噪声的数据上微调后的表现，并辅以 NCR 的结果作为基准参照。实验结果显示，直接在包含 20% 和 50% 噪声的数据上进行微调会导致 CLIP 模型的性能显著退化。相比之下，GSC 展现出优异的抗噪稳定性，其在 50% 噪声水平下的检索性能甚至超越了 Zero-shot CLIP-L 约 15.9%。该实验结果有力地证实了在关联噪声场景下引入专用鲁棒算法的必要性，同时也充分彰显了 GSC 方法在实际应用中的鲁棒价值。

3.3.2.5　与离线数据清洗方法 CapFilt 的对比实验

为了进一步确立 GSC 方法的性能优势，本节选取了 BLIP[91] 中提出的 CapFilt 模块作为离线数据清洗策略的代表进行对比。CapFilt 遵循“先清洗、后训练”的两阶段范式，即依赖于在高质量外部数据集（如 MS-COCO）上预训练的参考模型来计算图文匹配度，并预先剔除低置信度样本。然而，这种基于外部先验的静态策略面临着严峻的跨域泛化挑战：当目标域（如 Flickr30K）与预训练域存在分布差异（Domain Shift）时，过滤机制的准确性往往会受到显著影响。相比之下，GSC 摒弃了对外部数据或预训练模型的依赖，转而利用训练动态中数据内在的几何结构一致性，实现了对噪声的自适应识别与鲁棒学习。

表 3.7 汇总了在 Flickr30K 数据集不同仿真噪声率下的详细对比结果。实验严格遵循 CapFilt 的原始设置，即利用 MS-COCO 预训练模型对 Flickr30K 进行离线过滤。

表 3.6　GSC 与预训练模型 CLIP 在 MS-COCO 仿真噪声数据集上的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示。

Table 3.6　Comparison of cross-modal retrieval performance between GSC and the pre-trained CLIP model on the MS-COCO dataset with simulated noise. The experimental results present the image-to-text and text-to-image recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the overall sum of recall rates. The best results are highlighted in bold.

Noise	Methods	Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
0% Zeroshot	CLIP-L[3]	58.4	81.5	88.1	37.8	62.4	72.2	400.4
	CLIP-B[3]	50.2	74.6	83.6	30.4	56.0	66.8	361.6
20% Finetune	CLIP-B[3]	21.4	49.6	63.3	14.8	37.6	49.6	236.3
	NCR[14]	56.9	83.6	91.0	40.6	69.8	80.1	422.0
	GSC	**58.9**	**84.9**	**91.7**	**42.0**	**71.4**	**81.8**	**430.8**
50% Finetune	CLIP-B[3]	10.9	27.8	38.3	7.8	19.5	26.8	131.1
	NCR[14]	53.1	80.7	88.5	37.9	66.6	77.8	404.6
	GSC	**55.5**	**81.8**	**90.1**	**40.0**	**69.1**	**79.7**	**416.3**

表 3.7　GSC 与离线数据清洗方法 CapFilt 在 Flickr30K 仿真噪声数据集上的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示。

Table 3.7　Comparison of cross-modal retrieval performance between GSC and the offline data cleaning method CapFilt on the Flickr30K dataset with simulated noisy correspondence. The experimental results present the image-to-text and text-to-image recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the overall sum of recall rates. The best results are highlighted in bold.

Noise	Method	Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	CapFilt[91]	76.9	91.8	96.0	54.8	81.5	87.8	488.8
	GSC	**78.3**	**94.6**	**97.8**	**60.1**	**84.5**	**90.5**	**505.8**
40%	CapFilt[91]	72.2	92.4	96.4	52.8	79.2	86.6	479.6
	GSC	**76.5**	**94.1**	**97.6**	**57.5**	**82.7**	**88.9**	**497.3**
60%	CapFilt[91]	68.9	89.5	94.2	49.5	76.4	84.6	463.1
	GSC	**70.8**	**91.1**	**95.9**	**53.6**	**79.8**	**86.8**	**478.0**

实验数据表明，GSC 在所有噪声设定下均展现出显著的性能优势。特别是在 20% 和 40% 的噪声水平下，GSC 的召回率总和分别超越 CapFilt 约 17.0% 和 17.7%。这一明显的性能提升有力证明相较于易受域偏移影响的静态离线过滤，挖掘数据自身几何拓扑特性的动态鲁棒学习机制在处理关联噪声问题上具备更优越的适应性与有效性。

表 3.8　GSC 方法在 Flickr30K 数据集上的稳定性分析。表中展示了三次独立重复实验的平均值与标准差。实验结果分别展示了图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。

Table 3.8　Stability analysis of the GSC method on the Flickr30K dataset. The table reports the means and standard deviations from three independent runs. The experimental results separately present the image-to-text and text-to-image retrieval recall rates, where R@K denotes the Top-K recall evaluation metric, and Sum represents the total sum of the recall rates.

Noise	Method	Flickr30K						
		Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	SGR[223]	55.9	81.5	88.9	40.2	66.8	75.3	408.6
	BiCro[15]	78.1	94.4	97.5	60.4	84.4	89.9	504.7
	GSC	77.7 ±0.6	94.8 ±0.2	97.6 ±0.2	59.7 ±0.5	84.4 ±0.3	90.4 ±0.3	504.5 ±1.6
40%	SGR[223]	4.1	16.6	24.1	4.1	13.2	19.7	81.8
	BiCro[15]	74.6	92.7	96.2	55.5	81.1	87.4	487.5
	GSC	76.4 ±0.4	93.9 ±0.5	97.2 ±0.5	57.2 ±0.5	82.8 ±0.2	89.2 ±0.1	496.6 ±1.6
60%	SGR[223]	1.5	6.6	9.6	0.3	2.3	4.2	24.5
	BiCro[15]	67.6	90.8	94.4	51.2	77.6	84.7	466.3
	GSC	72.0 ±1.1	91.4 ±0.2	95.4 ±0.5	53.3 ±0.5	79.8 ±0.4	86.7 ±0.2	478.6 ±1.0

3.3.2.6　方法稳定性分析

为了全面评估 GSC 在不同噪声强度下的收敛稳定性，本节在 Flickr30K 数据集上开展了多轮独立重复实验，涵盖 20%、40% 及 60% 三种噪声水平。表 3.8 汇总了三次实验的平均检索性能及其标准差。统计数据清晰地表明，GSC 在维持高水平检索精度的同时，展现出卓越的训练稳定性：在所有噪声设定下，召回率总和的标准差均控制在 1.6% 以内，同时 R@1 等关键检索指标的波动幅度大多低于 0.6%。这种低方差特性证实了算法对随机种子初始化具有很强的鲁棒性，能够在不同配置下稳定收敛至高性能解。更为关键的是，即便考虑实验结果的随机波动范围，GSC 的性能下界在 40% 和 60% 的高噪声场景中依然显著优于当前最佳方法 BiCro 的平均表现，充分验证了该方法在复杂噪声环境下的可靠性与优越性。

表 3.9　GSC 方法在 Flickr30K 数据集上 40% 仿真噪声率下的消融实验。分别对基于动量的参数更新策略、双网络协同学习架构与模态内几何结构损失进行了消融。实验结果分别展示了图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。

Table 3.9　Ablation study of the GSC method on the Flickr30K dataset under 40% simulated noise rate. The momentum-based parameter update strategy, dual-network collaborative learning architecture, and intra-modal geometric structure loss are ablated, respectively. The experimental results report the recall rates for image-to-text and text-to-image retrieval, where R@K indicates the Top-K recall metric, and Sum denotes the sum of the recall rates.

Momen.	Dual	$\mathcal{L}_{\text{IM}}$	Image → Text			Text → Image			
			R@1	R@5	R@10	R@1	R@5	R@10	Sum
✓	✓		72.3	92.8	96.5	56.5	82.1	88.8	489.0
✓		✓	73.0	91.5	95.9	54.5	80.4	87.6	482.9
	✓	✓	74.5	92.5	96.9	57.0	82.0	88.3	491.1
✓	✓	✓	**76.5**	**94.1**	**97.6**	**57.5**	**82.7**	**88.9**	**497.3**

3.3.3　消融实验结果

3.3.3.1　对算法各部分设计的消融实验

为了深入剖析 GSC 框架中各核心组件的有效性及其对鲁棒性的具体贡献，本节开展了详尽的消融实验。实验重点考察了三个关键设计：基于动量的时间集成策略（Momen.）、双网络协同学习架构（Dual）以及模态内几何结构一致性约束（$\mathcal{L}_{\text{IM}}$）。具体而言，实验设置包括：以 5 轮预热（Warm-up）替代动量更新以测试参数演化的稳定性、移除双网络协同机制仅保留单网络分支以评估架构依赖性、以及去除模态内优化目标仅利用跨模态结构进行判别。表 3.9 的结果揭示了清晰的性能依赖关系：移除任一组件均导致检索精度的显著下滑，证实了上述模块在维持训练稳定性和提升去噪精度方面的不可或缺性。尤为值得关注的是，即便剥离了昂贵的双网络协同架构，简化版的单模型 GSC 依然展现出优于 NCR 和 DECL 等复杂双网络基线方法的性能。这一结果强有力地证明了，GSC 的核心优势源于其对数据几何结构内在一致性的深度挖掘，而非单纯依赖模型容量的堆砌，从而验证了该方法的高效性与本质有效性。

3.3.3.2　超参数 γ、β_1 和 β_2 不同取值的消融实验

本节重点分析了 GSC 框架中三个核心超参数 γ、β_1 和 β_2 的敏感性及其对最终检索性能的影响（如图 3.4 所示）。首先，针对平衡跨模态损失 $\mathcal{L}_{\text{CM}}$ 与模态内损失 $\mathcal{L}_{\text{IM}}$ 的权重系数 γ，图 3.4 左侧的曲线揭示了模型性能随 γ 的变化呈现出先上升后下降的趋势。实验数据显示，当 γ 处于 $[0.005, 0.1]$ 区间时，模型表现出较强的鲁棒性，并在 $\gamma = 0.01$ 处达到召回率总和的峰值。这一现象表明，适度的模态内几何约束能有

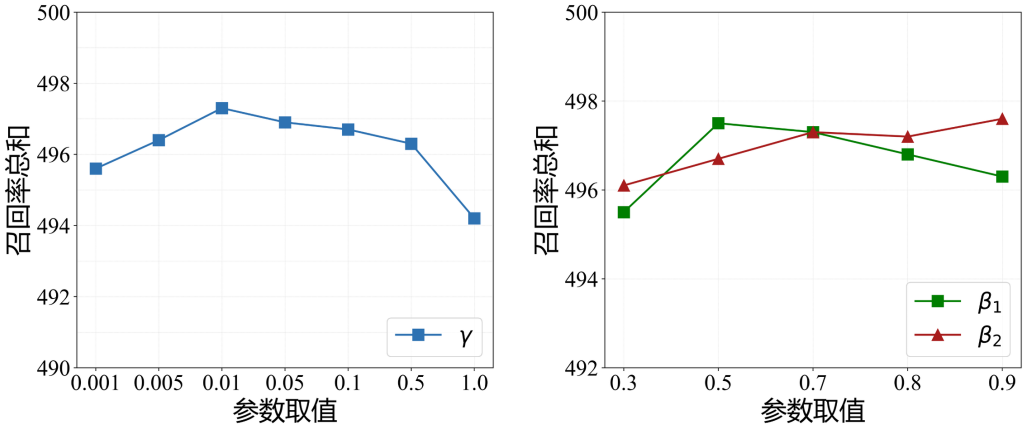

图 3.4　在 Flickr30K 数据集上 40% 关联噪声率下对超参数 γ、β_1、β_2 的消融实验。左图展示了对 γ 的消融实验，该参数是用于平衡 $\mathcal{L}_{\mathrm{CM}}$ 和 $\mathcal{L}_{\mathrm{IM}}$ 的权重参数；右图展示了对 β_1 和 β_2 的消融实验，分别为控制跨模态与模态内参数更新的动量参数。

Figure 3.4　Ablation study on hyperparameters γ, β_1, and β_2 on the Flickr30K dataset under 40% noisy ratio. Left: Ablation study on γ, which is the weight parameter used to balance $\mathcal{L}_{\mathrm{CM}}$ and $\mathcal{L}_{\mathrm{IM}}$. Right: Ablation study on β_1 and β_2, which are the momentum parameters controlling the cross-modal and intra-modal parameter updates, respectively.

效辅助表征学习，然而过高的权重（如 $\gamma > 0.1$）则可能影响主要优化目标，干扰跨模态对齐这一主导任务的优化路径。其次，对于控制时间集成过程中关联指示标签更新速率的动量参数 β_1 和 β_2，图 3.4 右侧的结果表明，较大的动量值（即 $\beta_1, \beta_2 > 0.5$）更有利于维持模型的高性能与稳定性。这种增益归因于高动量带来的平滑效应：它能有效利用历史状态信息抑制当前轮次的预测噪声与波动；反之，过小的动量会导致标签更新过于激进，增加了模型对短期噪声预测过拟合的风险，从而损害泛化性能。综合上述敏感性分析，为了在训练稳定性与性能之间取得最佳平衡，本章后续实验统一将 γ 设定为 0.01，并将动量参数 β_1 与 β_2 均固定为 0.7。

3.3.3.3　超参数 τ_1 和 τ_2 不同取值的消融实验

超参数 τ_1 和 τ_2 分别作为调节跨模态与模态内损失函数及噪声指示器的温度系数，通过控制相似度度量的尺度缩放，直接决定了特征分布的锐度与判别边界，进而显著影响模型对干净样本与噪声样本的区分能力。图 3.5 展示了这两个参数的敏感性分析结果。针对控制模态内几何结构的参数 τ_2（如图 3.5 右侧所示），实验数据显示模型在 $[0.4, 5.0]$ 的宽泛区间内性能波动微弱，展现出优异的参数鲁棒性，因此本实验将其默认值固定为 1。相比之下，主导跨模态对齐的参数 τ_1 对模型性能具有比较明显的影响。图 3.5 左侧的曲线表明，较低的 τ_1 值（即 ≤ 0.07）有利于维持高水平的

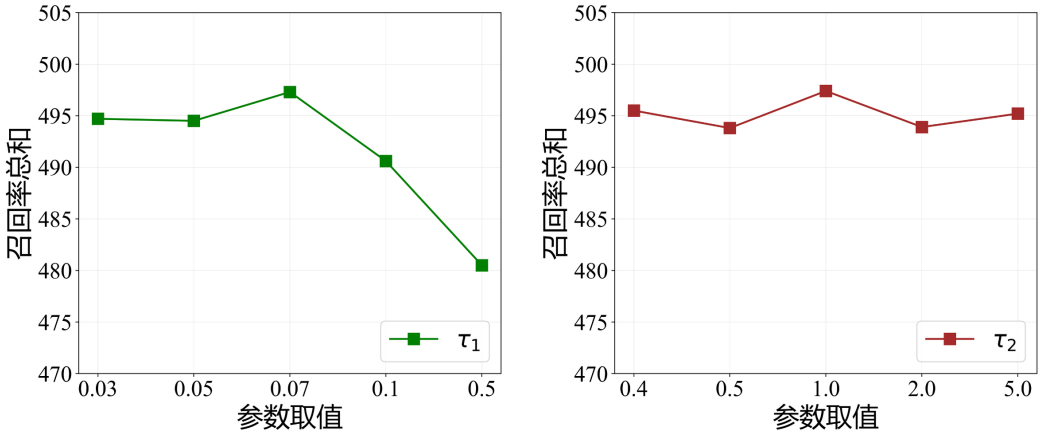

图 3.5　在 Flickr30K 数据集上 40% 关联噪声率下对超参数 τ_1、τ_2 的消融实验。左图展示了对 τ_1 的消融实验，该参数是跨模态损失函数与关联指示器的温度系数；右图展示了对 τ_2 的消融实验，该参数是模态内损失函数与关联指示器的温度系数。

Figure 3.5　Ablation study on hyperparameters τ_1 and τ_2 under a 40% noisy correspondence rate on the Flickr30K dataset. Left: Ablation study on τ_1, which is the temperature coefficient for the cross-modal loss function and the correspondence indicator. Right: Ablation study on τ_2, which is the temperature coefficient for the intra-modal loss function and the correspondence indicator.

检索精度；然而，随着 τ_1 增大至 0.5，模型性能会有比较明显的衰退。存在这种现象的原因在于：较低的温度系数能够有效放大正负样本间的相似度差异，增强模型挖掘难样本及辨识噪声的敏感度；反之，过大的温度系数会导致相似度分布过度平滑，削弱了特征空间中细粒度语义的判别能力，从而引发检索准确率的显著下降。基于此，为了确保模型具备最佳的判别效能，后续实验统一将 τ_1 设定为 0.07。

3.3.3.4　批次大小对模型性能的影响

本节深入考察了训练批次大小这一关键超参数对 GSC 算法性能的影响，Flickr30K 数据集在不同噪声率设定下的实验结果详见表 3.10。分析实验数据可知，随着批次大小的增加，模型的检索性能总体呈现出稳步提升的趋势。以 40% 噪声率的实验设置为例，当批次大小从 32 增加至 128 时，模型的召回率总和从 483.9% 显著提升至 497.3%。这种显著的性能增益主要归因于对比学习的内在特性：较大的批次大小能够在单次迭代中引入更丰富的负样本对，从而增强了模型挖掘与区分困难样本的能力，进而促进了更加稳健且具备高判别力的跨模态表征几何结构的构建。

然而，实验结果也显示这种性能增长并非是线性的。当批次大小进一步从 128 扩大至 192 时，性能提升幅度出现了明显的边际效益递减现象。在 40% 和 60% 噪声率下，召回率总和仅分别提升了 0.5% 和 1.6%，而在 20% 低噪声场景下甚至出现了轻

表 3.10　GSC 方法在 Flickr30K 数据集上不同噪声率下受到批次大小影响的实验分析，分别测试了批次大小为 32、64、128 和 192 时的模型性能。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示。

Table 3.10　Impact of batch size on the GSC method under varying noise rates on the Flickr30K dataset. The model performance is evaluated with batch sizes of 32, 64, 128, and 192, respectively. The experimental results separately present the image-to-text and text-to-image retrieval recall rates for different methods. R@K denotes the Top-K recall metric, and Sum indicates the sum of recall rates. The best results in the table are highlighted in bold.

Noise	Batch Size	Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	32	75.4	93.5	96.7	57.5	83.1	89.2	495.3
	64	77.9	94.0	97.7	57.7	84.3	90.1	501.7
	128	**78.3**	94.6	**97.8**	**60.1**	**84.5**	**90.5**	**505.8**
	192	76.8	**94.9**	97.7	59.7	84.2	90.1	503.4
40%	32	73.6	92.1	95.4	54.4	81.0	87.4	483.9
	64	75.3	94.0	96.7	55.9	81.7	88.2	491.8
	128	76.5	**94.1**	97.6	57.5	**82.7**	88.9	497.3
	192	**76.7**	94.0	**97.7**	**57.6**	**82.7**	**89.1**	**497.8**
60%	32	66.7	89.2	94.6	50.2	77.4	84.6	462.7
	64	68.7	**91.1**	94.9	51.4	79.0	86.1	471.2
	128	70.8	**91.1**	**95.9**	**53.6**	79.8	86.8	478.0
	192	**72.6**	90.7	95.8	**53.6**	**80.0**	**86.9**	**479.6**

微的性能回落（从 505.8% 降至 503.4%）。这表明当批次大小达到特定阈值（如 128）后，模型对于梯度的估计精度已趋于饱和，特征空间的结构亦达到相对稳定状态。综合权衡显存占用、训练时长等计算资源开销与模型性能收益，后续实验将批次大小统一设定为 128，以在训练效率与算法性能之间取得最佳平衡。

3.3.3.5　基于 SGRAF 主干网络的实验结果分析

现有前沿方法在主干网络架构的选择上存在差异。具体而言，NCR 与 MSCN 选用 SGR 作为基础架构，而 DECL 与 BiCro 则采用性能更优的 SGRAF（即 SGR 与 SAF 模块的集成）以追求更好的效果。在本章的前述实验中主要基于 SGR 主干网络汇报 GSC 的性能。这主要是考虑到 GSC 采用了双网络协同策略，若直接基于包含两个子模块的 SGRAF 进行训练，将导致需要同时优化四个网络分支，显著增加计算开销与训练时间，从而降低实际应用价值。此外，实验数据已证明，即便仅使用较基础的 SGR 主干，GSC 依然能够超越现有的 SOTA 方法。

为了进一步验证 GSC 方法在更强主干网络上的泛化能力与潜力，本节补充了基

表 3.11　GSC 方法基于 SGRAF 主干网络在 Flickr30K 数据集上的实验结果。表中对比了 SGR 与 SGRAF 两种主干网络下的方法性能。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示。

Table 3.11　Experimental results of the GSC method based on the SGRAF backbone network on the Flickr30K dataset. It compares the performance of methods utilizing the SGR and SGRAF backbone networks. The experimental results respectively report the image-to-text and text-to-image retrieval recall rates of different methods, where R@K denotes the Top-K recall metric, and Sum represents the sum of recalls. The best results in the table are highlighted in bold.

Noise	Method	Flickr30K						
		Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	SGR[223]	55.9	81.5	88.9	40.2	66.8	75.3	408.6
	SGRAF[223]	72.8	90.8	95.4	56.4	82.1	88.6	486.1
	DECL-SGRAF[17]	77.5	93.8	97.0	56.1	81.8	88.5	494.7
	BiCro-SGARF[15]	78.1	94.4	97.5	60.4	84.4	89.9	504.7
	GSC-SGR	78.3	94.6	97.8	60.1	84.5	90.5	505.8
	GSC-SGRAF	**78.9**	**95.5**	**98.0**	**61.0**	**85.3**	**90.9**	**509.6**
40%	SGR[223]	4.1	16.6	24.1	4.1	13.2	19.7	81.8
	SGRAF[223]	8.3	18.1	31.4	5.3	16.7	21.3	101.1
	DECL-SGRAF[17]	72.7	92.3	95.4	53.4	79.4	86.4	479.6
	BiCro-SGARF[15]	74.6	92.7	96.2	55.5	81.1	87.4	487.5
	GSC-SGR	76.5	94.1	**97.6**	57.5	82.7	88.9	497.3
	GSC-SGRAF	**78.1**	**94.6**	97.4	**59.0**	**83.5**	**90.1**	**502.7**
60%	SGR[223]	1.5	6.6	9.6	0.3	2.3	4.2	24.5
	SGRAF[223]	2.3	5.8	10.9	1.9	6.1	8.2	35.2
	DECL-SGRAF[17]	65.2	88.4	94.0	46.8	74.0	82.2	450.6
	BiCro-SGARF[15]	67.6	90.8	94.4	51.2	77.6	84.7	466.3
	GSC-SGR	70.8	91.1	**95.9**	53.6	79.8	86.8	478.0
	GSC-SGRAF	**72.9**	**92.6**	95.7	**55.7**	**81.4**	**87.7**	**486.0**

于 SGRAF 主干的实验结果，具体数据如表 3.11 所示。实验结果表明，得益于 SGRAF 更强的特征提取与对齐能力，GSC-SGRAF 在各项指标上均取得了进一步的提升。值得注意的是，相较于同样采用 SGRAF 主干的次优方法，GSC-SGRAF 展现出了显著的性能优势。具体而言，在 20%、40% 和 60% 的噪声率下，GSC-SGRAF 的召回率总和分别领先次优方法 4.9%、15.2% 和 19.7%。这一结果不仅再次印证了 GSC 方法的有效性，也表明其能够无缝适配更复杂的网络架构，在极高噪声场景下依然能够保持卓越的鲁棒性并挖掘出更高的性能上限。

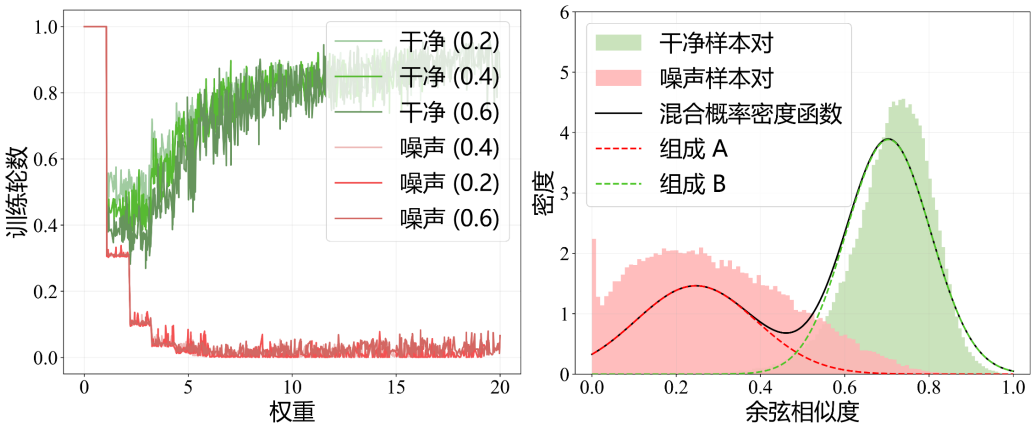

图 3.6　GSC 方法的训练可视化分析。左图展示了在不同噪声率下，干净与噪声样本的预测权重随训练轮次的变化；右图展示了模态内几何结构的余弦相似度分布，呈现出的双峰分布可以被高斯混合模型拟合。

Figure 3.6　Visualization analysis of the training process for the GSC method. The left panel illustrates the variation of predicted weights for clean and noisy samples across training epochs under different noise rates; the right panel presents the cosine similarity distribution of the intra-modal geometric structure, exhibiting a bimodal distribution that can be fitted by a Gaussian Mixture Model.

3.3.3.6　方法的可视化分析

为深入阐释 GSC 方法在关联噪声场景下的运行机理及鲁棒性成因，图 3.6 与图 3.7 展示了训练过程中的关键指标变化。通过从训练动态特性、几何结构分布规律以及最终样本筛选效能三个维度的可视化分析，有力地验证了本章所提方法的核心假设与有效性。

图 3.6 左子图描绘了在 20%、40% 及 60% 三种噪声率设定下，模型对干净样本与噪声样本的预测关联标签 y 随训练轮次的演变轨迹。图中清晰地呈现了深度神经网络的“记忆效应”与 GSC 方法的修正作用：在训练初期，模型迅速捕捉干净样本特征，使其预测权重快速攀升并稳定在 1.0 附近的高值区间；与此同时，尽管噪声样本的权重在初始阶段存在微弱波动，但在几何结构一致性约束下迅速被识别并抑制，最终收敛趋近于 0。值得注意的是，即便在 60% 的高噪声干扰场景下，干净样本与噪声样本的权重曲线之间依然保持着显著的区分界限，且震荡幅度极小，充分证明了结合动量更新与双重结构约束策略在维持训练稳定性方面的优势。

图 3.6 右子图进一步论证了模态内几何结构在噪声判别中的有效性。该图绘制的模态内余弦相似度密度直方图显示，数据分布呈现出显著的双峰特性：左侧红色区域对应模态内结构一致性较低的噪声样本对，而右侧绿色区域则对应结构相似性较

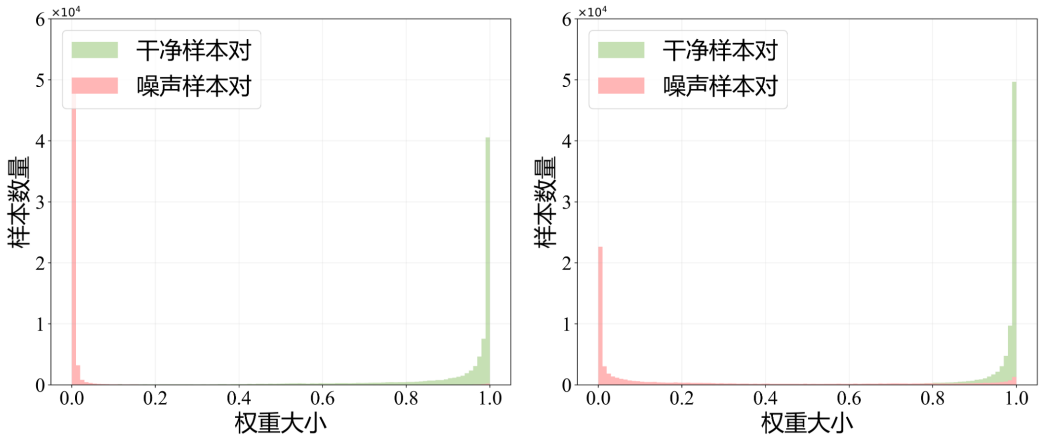

图 3.7　GSC 方法的权重分布可视化分析。左右子图分别展示了基于跨模态与模态内结构一致性预测得到的关联标签的分布直方图，表明模型能以极高的准确率区分干净与噪声样本。

Figure 3.7　The left and right panels respectively illustrate the distribution histograms of the correspondence labels predicted based on cross-modal and intra-modal structural consistency, demonstrating the model's high accuracy in distinguishing between clean and noisy samples.

高的干净样本对。图中黑色曲线表明，双高斯混合模型能够精确拟合这一分布特征，从而有效分离出两个潜在的成分。这一分布规律为公式 3.4的设计提供了坚实的实证支撑，即利用模态内几何结构的统计特征可实现对关联噪声的有效鉴别。

图 3.7 分别呈现了基于跨模态鉴别与模态内鉴别所得关联标签在训练终末阶段的分布直方图。两幅图均表现出显著的两极化分布趋势，绝大多数干净样本的权重集中于 1.0，而噪声样本则被有效压制在 0.0 附近。定量评估结果显示，跨模态鉴别的区分准确率约为 0.96，模态内鉴别的准确率约为 0.91。GSC 策略通过取最小值的操作将两者有机融合，使得最终的整体噪声识别准确率提升至 0.98。这种高精度的样本筛选机制，有效阻断了错误监督信号在后续对比学习过程中的干扰，确保模型在不同噪声水平下均能保持稳健且优异的检索性能。

3.3.3.7　真实世界噪声样本的可视化分析

与通过人工翻转标签生成的仿真噪声不同，真实世界数据集（如 CC152K）中的关联噪声表现出更为复杂多样的分布特性。作为经由网络自动抓取构建的数据集，CC152K 据估计包含约 3% 至 20% 的关联噪声样本。为直观评估 GSC 方法在处理真实复杂噪声时的鲁棒性与鉴别效能，图 3.8 对算法自动识别出的典型噪声样本实例进行了可视化展示。选取的样本均为 GSC 预测的最终关联权重 y 低于预设阈值 0.1 的数据对，表明模型将其判定为高置信度的关联噪声。

对这些被算法有效识别的噪声样本进行深入分析，可将真实场景下的关联噪声

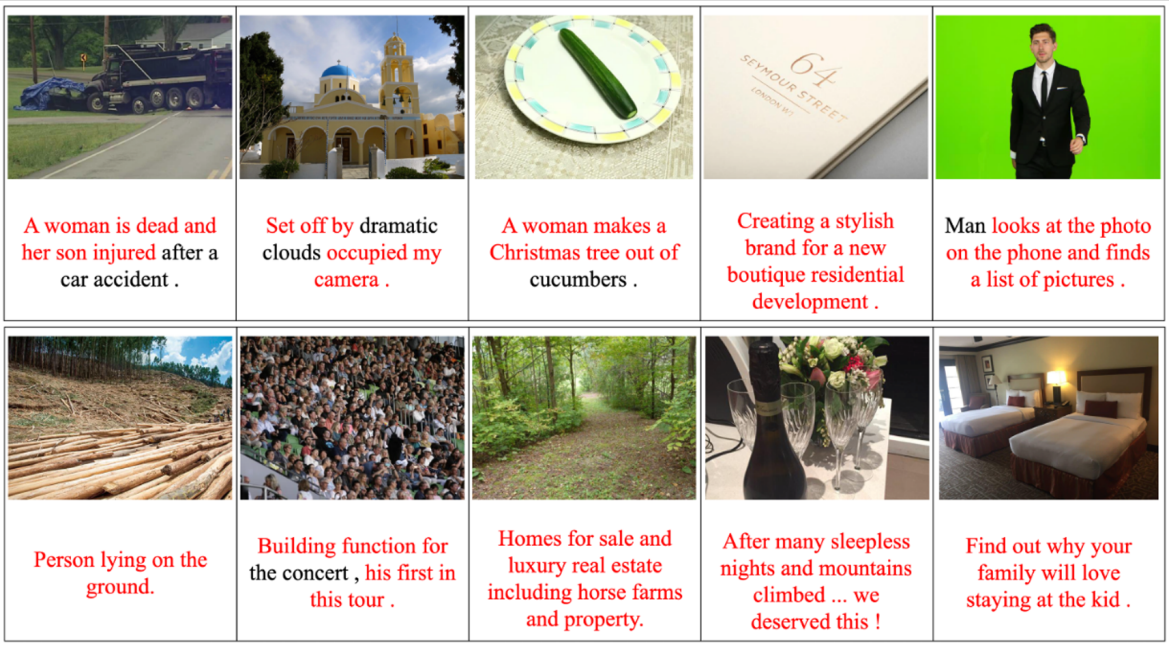

图 3.8　GSC 方法识别的 CC152K 数据集关联噪声样本可视化。展示的 10 对关联噪声样本均为 GSC 算法从原始数据集中识别的低质量样本，红色文本表示与图像内容不匹配的部分。
Figure 3.8　Visualization of noisy correspondence samples identified by the GSC method on the CC152K dataset. The displayed 10 pairs are low-quality samples identified from the original dataset using the GSC algorithm, where red text highlights the parts that do not match the image content.

现象归纳为以下三种典型类别：

- 语义完全不匹配：此类噪声最为显著，表现为图像内容与文本描述在语义对象上毫无关联。如图中所示的存在“黄瓜摆盘”的图像被错误描述为“用黄瓜制作圣诞树”，以及“堆放的木材”图像配以“人躺在地上”文本的情况。若将此类存在严重语义冲突的样本作为正样本进行训练，将对模型特征空间的对齐过程产生显著的负面干扰。
- 弱关联与上下文缺失：此类样本通常源自同一网页或新闻报道，二者虽在宏观主题上相关，但文本并未对图像的视觉内容进行直接描述。例如，针对“卡车事故现场”的图像，对应文本陈述的是“一名妇女死亡及其儿子受伤”的新闻事实，而非对车辆本身的视觉描述；同样，“香槟与酒杯”的图像配文为“度过无数不眠之夜后... 我们值得拥有”的情感表达，而非场景的客观描写。这种图文对之间存在显著的语义断层。
- 部分匹配与指代歧义：文本仅描述了图像的背景环境或非主体部分，导致语义对齐出现偏差。例如，对于“教堂建筑”的图像，文本仅强调了背景中“戏剧性

的云层”；而“林间小路”的图像对应的则是关于“房产出售”的营销性文字。此类文本往往过于宽泛或具有误导性，极易导致模型将特定的视觉特征与错误的语义概念建立关联。

上述可视化分析验证了 GSC 方法不仅能够处理简单的随机噪声，更具备深层的语义理解能力，能够从复杂的真实网络数据中精准识别并剔除上述多种类型的劣质图文对。这种在复杂噪声环境中准确区分有效信息与干扰噪声的能力，是 GSC 能够在 CC152K 等真实噪声数据集上取得优异性能的关键因素。

3.4　本章小结

本章聚焦于多模态对比学习中的关联噪声难题，针对现有方法在处理大规模真实场景噪声数据时的局限性，提出了一种基于几何结构一致性（Geometrical Structure Consistency, GSC）的鲁棒学习框架。

研究深入揭示了关联噪声对表征空间的双重破坏作用，即其不仅影响跨模态的对齐效果，更会导致模态内拓扑结构的扭曲。利用深度神经网络的记忆效应，本章通过量化分析不同性质样本在几何结构一致性上的显著分布差异，实现了对关联噪声样本的精准辨识与权重抑制。这种基于几何结构的动态筛选机制构建了标签修正促进结构优化，结构优化反哺标签估计的正反馈循环，在无需额外人工标注或外部先验知识的前提下，实现了模型的高效鲁棒训练。实验结果表明，该方法不仅能与主流检索模型无缝集成，且在多种噪声率及复杂真实场景下均取得了优于当前前沿方法的性能表现，显著提升了多模态表征的判别能力与泛化性。

尽管如此，本章的研究仍存在进一步拓展的空间。当前工作主要聚焦于图像与文本的双模态场景，而现实世界的交互往往涉及视频、音频等更多模态，关联噪声在多模态融合场景下的表现形式将更为复杂。此外，多模态数据集中往往同时存在关联噪声与分类标签噪声，这两种噪声类型的耦合效应尚未被充分研究。未来的研究工作将致力于把几何结构一致性理论扩展至多模态通用场景，并探索应对混合噪声类型的统一鲁棒学习框架，以进一步推动多模态学习在复杂现实环境中的落地应用。

第 4 章 特权信息辅助的关联噪声鲁棒方法

上一章通过挖掘数据内源的几何拓扑特征，利用结构一致性约束在一定程度上识别并抑制了关联噪声的干扰。然而，仅依赖模型在含噪数据分布上的自我校正，在面对语义高度混淆的难样本或高比例噪声时仍面临性能瓶颈，难以有效应对关联噪声导致的语义互信息不一致问题。针对单一信息源的局限性，本章提出了一种特权信息辅助的关联噪声鲁棒方法。该方法引入物体标签或描述文本等作为客观语义参照，构建模态间的联合校验机制，并设计了一种基于置信度的自适应融合策略，通过动态调整不同视角的预测权重以实现精准判别。实验验证该方法在复杂噪声场景下展现出优越的鲁棒性与通用性。

4.1 引言

多模态对比学习通过拉近语义相关的异构模态表征，旨在构建具备强泛化能力的统一特征空间。在上一章中，针对现实数据中普遍存在的关联噪声问题，提出了基于几何结构一致性的鲁棒对比学习解决方案。GSC 方法的核心在于挖掘数据内源的几何结构特征，利用干净与噪声样本在表征几何结构上的不一致性进行噪声识别。然而，这种完全依赖数据内源信息的自我监督范式在处理复杂噪声时面临着理论瓶颈[228-229]。具体而言，当噪声模式呈现出某种系统性的偏差，如错误的语义结构化，或者当数据集整体受噪声污染严重时，模型基于自身预测构建的表征结构往往会发生偏移甚至坍塌。此时，仅在受污染的数据闭环内进行自我修正难以从根本上纠正深层的语义错配。因此，如何在内源信息不足以支撑精准判别的情况下，引入外部的客观指引，成为进一步提升模型鲁棒性的关键突破口。

为了突破仅依赖内源信息的局限，相关研究开始尝试引入外部辅助信息以增强模型的判别能力。在跨模态哈希检索领域，MRL[20]与 ELRCMR[21]等方法利用类别标签作为显式监督信号，通过约束异构模态在表征空间中的聚类分布以实现语义对齐。另一方面，部分近期工作尝试引入额外的干净数据子集，通过在可信数据上训练辅助模型来识别[91]或修正[230]关联噪声样本。然而，上述方法在实际应用中往往面临严峻挑战：一方面，获取大规模的高质量类别标签或构建同分布的干净数据集成本极其高昂；另一方面，引入的外部数据与目标噪声数据之间常存在显著的分布差异[231-232]，这严重限制了辅助模型在目标域上的泛化效能与去噪准确性。与这些方法不同，本章

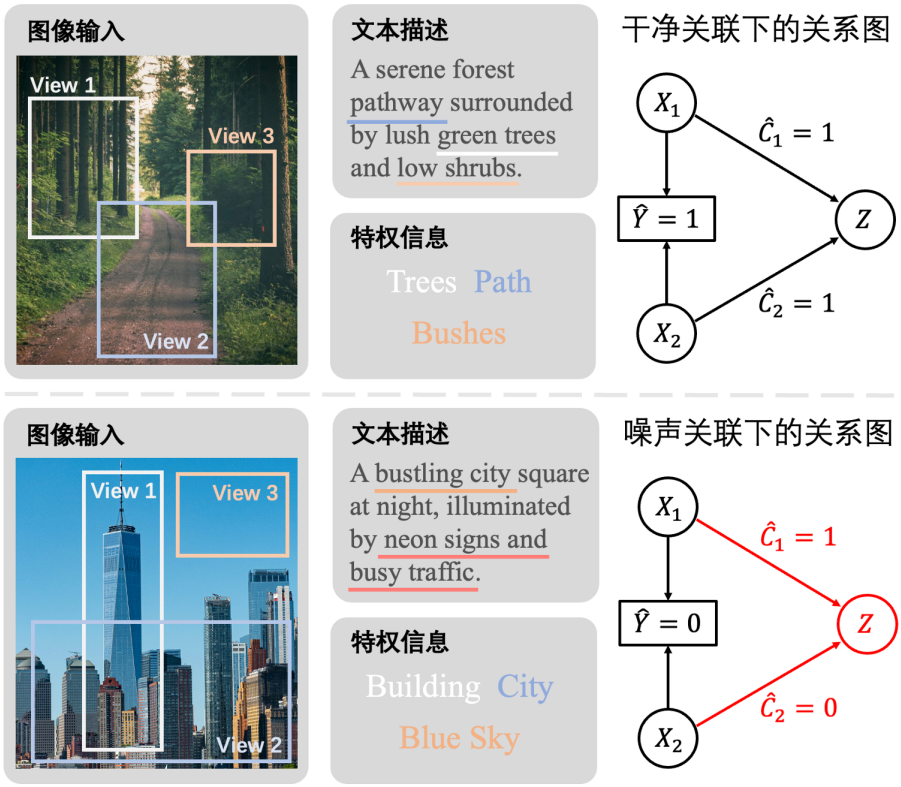

图 4.1　特权信息与模态间关联关系示意图。上图展示在干净样本中，图像、文本模态均与的特权信息保持语义互信息一致；下图展示了在噪声样本中，图像模态与特权信息语义互信息保持一致，但文本模态与特权信息不匹配。右侧分别展示了总结性的因果关系图。

Figure 4.1　Illustration of privileged information and inter-modal correspondence. The upper panel demonstrates that for clean samples, both image and text modalities maintain semantic mutual information consistency with the privileged information. The lower panel shows that for noisy samples, the image modality remains consistent with the privileged information, whereas the text modality exhibits a mismatch. Summarized conceptual relation diagrams are illustrated on the right for each scenario.

提出了一种全新的视角：引入训练阶段可获取的辅助信息，如现成的物体检测标签、来自参考模型生成的标注文本或图像自带的元数据描述等，将其定义为“特权信息”。本章并非旨在单纯通过引入更多特征来增强表征，而是利用特权信息作为独立的“语义锚点”，通过挖掘其与原始模态之间的逻辑一致性构建联合校验机制，从而辅助判断图文关联的真实性。

本章提出的核心研究动机基于一个直观且严谨的逻辑假设：真实匹配的图文对应当在语义上同时与共享的特权信息保持一致；而对于关联噪声样本，即便图像与文本在某些低级特征上存在偶然的相似，二者也很难同时与客观的特权信息建立稳固的语义映射。这一机制通过引入第三方校验来消除潜在的语义歧义。如图 4.1所示，

考虑一个包含“白天的摩天大楼”图像与“夜间的城市广场”文本的关联噪声样本。尽管两者在“城市”这一语义上保持一致，导致模型难以仅凭内部相似度判定其为负样本，但若引入包含“蓝天”等视觉概念的特权信息，文本描述中的“夜间”要素与特权信息中的“蓝天”将产生显著的逻辑冲突。这种不一致性可以进一步总结为图 4.1右侧的因果关系图。基于特权信息的辅助校验，能够有效捕捉细粒度的语义冲突，从而为模型提供超越当前数据视角的额外监督信号，在模糊的决策边界上实现更精准的噪声识别。

基于此，本章提出了一种特权信息辅助（Privileged Information Assisted Learning, PIAL）的关联噪声鲁棒方法。该方法充分考虑了特权信息本身可能存在的不确定性，而非简单地将其视为绝对真值。PIAL 首先分别建模跨模态与特权信息两个视角的潜在关联概率，推导出各自的关联指示器；随后，设计了一种基于信息熵的置信度评估机制，根据模型在不同视角下的预测确定性，动态地自适应融合多源判断。这种设计使得 PIAL 既能利用特权信息的指导作用，又能避免因特权信息质量不佳而引入新的干扰，实现了鲁棒性与准确性的协同提升。本章的主要贡献可以归纳如下：

- 不同于现有的局限于挖掘数据内源信息的方法，本章首次尝试将特权信息引入解决关联噪声问题，为对关联噪声鲁棒的多模态学习提供了新的解决思路。
- 提出了一种特权信息辅助的鲁棒多模态对比学习方法，通过分析模态与特权信息之间的语义一致性关系，设计了基于置信度自适应加权的关联指示器预测机制，有效实现了对关联噪声样本的识别与修正。
- PIAL 方法与现有的关联噪声学习方法具有良好的兼容性。在三个基准数据集上的广泛实验及综合分析表明 PIAL 能够显著提升现有主流模型的抗噪性能，验证了该方法的有效性与鲁棒性。

4.2 算法研究

4.2.1 符号定义

本节将对特权信息辅助的关联噪声学习框架进行形式化定义。本章延用第三章设定，将多模态数据集表示为 $\mathcal{D} = \{X_1^i, X_2^i, \hat{y}^i\}_{i=1}^N$。在本章的算法框架中，图像与文本模态分别通过独立编码器 $f_1(\cdot)$ 与 $f_2(\cdot)$ 映射至共享表征空间，获取特征表示 $x_1^i = f_1(X_1^i)$ 与 $x_2^i = f_2(X_2^i)$，并通过余弦相似度 $\langle x_1^i, x_2^i \rangle$ 衡量模态间的对齐程度。鉴于训练数据中观察到的关联标签 $\hat{y}^i$ 恒定为 1 但包含噪声干扰，算法的核心目标在于预测显式标签 $y^i \in [0, 1]$，以揭示潜在的真实跨模态对应关系。

为辅助噪声识别，本章引入特权信息 Z^i 以提供数据对中潜在共享语义的辅助细节。该信息形式多样，涵盖类别标签、检测物体列表或描述性标题等。为了获取丰富的语义知识，本章首先利用预训练 CLIP 模型对特权信息 Z^i 进行编码，随后通过多层感知机（MLP）投影模块 $g(\cdot)$ 提取特征，生成特权信息表征 $z^i = g(\text{CLIP}(Z^i))$。类似地，本章定义 $\hat{c}_1^i$ 与 $\hat{c}_2^i$ 分别表示观察到的特权信息与图像、文本模态间关联标签。考虑到特权信息与原始模态的对应关系同样可能存在噪声，需进一步估计潜在的真实关联指示器 $c_1^i, c_2^i \in [0,1]$，从而构建稳健的语义校验机制。

4.2.2　研究动机

本文提出的 PIAL 方法基于以下核心假设：特权信息与跨模态样本的真实关联关系之间存在内在的语义一致性，即对于干净关联的图文对，其异构模态应与共享特权信息的语义分别对齐，而对于关联噪声的图文对，至少应有一个模态与特权信息是不匹配的。为验证该假设，本节设计了以下的先验实验：首先在干净数据集上训练模型以分别对齐图像、文本与特权信息 z（即优化相似度 $\langle x_1, z\rangle$ 与 $\langle x_2, z\rangle$），然后将其迁移至仿真噪声数据集进行推理。通过计算样本模态与特权信息相似度的最小值 $\min\{\langle x_1^i, z^i\rangle, \langle x_2^i, z^i\rangle\}$ 并在不同样本集合上绘制分布。如图 4.2所示，实验结果表明干净样本与噪声样本存在显著的分布差异。具体而言，干净样本普遍表现出较高的最小相似度，意味着双模态均与特权信息实现了良好对齐；而噪声样本得分显著偏低，证实了在关联噪声数据对中，由于语义错配，至少存在单一模态无法与特权信息建立有效关联。

基于上述实验现象，本章提出引入特权信息 z 作为辅助变量，通过显式建模其与模态的关联来消除关联噪声带来的不确定性。关联标签估计问题被重构为对联合分布 $P(y, z|x_1, x_2)$ 的建模。依据概率链式法则，该分布可分解为 $P(y|x_1, x_2, z)P(z|x_1, x_2)$。鉴于直接建模 $P(z|x_1, x_2)$ 存在计算复杂性，本章引入条件独立性假设，将该项近似分解为 $P(z|x_1)P(z|x_2)$，从而允许对不同模态与特权信息的对齐程度分别进行优化。由此，最终的目标函数形式推导如下：

$$P(y, z|x_1, x_2) \approx P(z|x_1)P(z|x_2)P(y|x_1, x_2, z), \tag{4.1}$$

其中，$P(z|x_1)$ 和 $P(z|x_2)$ 项分别用于度量单一模态与特权信息的语义对齐程度，后验概率 $P(y|x_1, x_2, z)$ 则作为综合预测项，旨在融合图像、文本及特权信息三方视角的语义线索，以实现对潜在真实对应关系指示器 y 的精准估计。

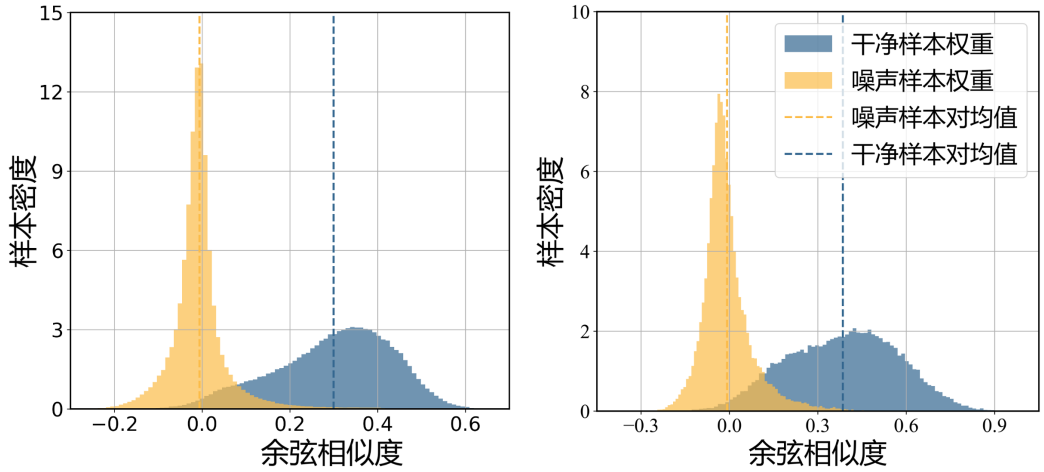

图 4.2　特权信息可用于辅助识别关联噪声。展示了模型在干净数据集上初始化训练，随后在仿真关联噪声数据集上进行推理的实验结果。计算并绘制了模态表征与特权信息表征之间的余弦相似度较小值。左图与右图分别展示了 MS-COCO 与 NUS-WIDE 数据集上的实验结果。

Figure 4.2　Privileged information assists identifying noisy correspondence. We present the inference results on synthetic noisy datasets after initial training on the clean dataset. The minimum cosine similarity between modal representations and privileged information representations is calculated and plotted. The left and right panels show the experimental results on the MS-COCO and NUS-WIDE datasets, respectively.

条件独立性假设的合理性分析：公式 4.1中将联合概率 $P(z|x_1,x_2)$ 基于条件独立性假设近似分解为 $P(z|x_1)P(z|x_2)$，不仅是为了保证模型训练时的计算可行性，其内在的合理性与适用范围也可由以下三个方面予以论证：

- **关联噪声的解耦：**尽管在理想情况下干净的数据对之间表现出固有的语义相关性，但在关联噪声的设定下，独立模态与特权信息之间的关系通常呈现条件独立性。该假设在以下条件时成立：当数据对存在关联噪声时，至少有一个模态无法与特权信息正确对齐。例如，当一张“小狗”的图像被错误地与“小猫”的文本描述配对时，该文本描述就无法与特权信息“狗”相对齐。图 4.2 中的先验实验现象有力地证明了这一点：噪声数据对的最小相似度得分呈现出显著的低值分布，即单一模态的语义错配使得联合概率的解耦近似在区分噪声时依然有效。
- **与现有研究范式的一致性：**在跨模态学习的实际应用中，独立建模各个异构模态与外部辅助信息之间的相关性是一种行之有效的常见做法。先前的工作如 MRL[20] 和 ELRCMR[21]，便利用了独立的分类网络或映射分支来建模给定特定单一模态下的语义或类别概率。遵循这一既定范式，PIAL 能够成功且高效地捕

获区分干净数据与噪声数据所需的核心信号，后续在仿真及真实世界数据集上的实验性能提升也从侧面印证了该近似分解策略的有效性。

- **假设的有效性边界：**诚然，这种理论近似在某些特定且极端的长尾场景下可能会面临失效。当提取的特权信息过于粗粒度或存在高度歧义时，图像和文本可能都会独立地与该信息产生较好的对齐，从而导致即使数据对本身是不匹配的，也会计算出较高的联合概率。例如，特权信息若仅为“体育运动”，则可能无法帮助模型敏锐区分“篮球”图像与“棒球”文本描述之间的细粒度不匹配。针对这一局限，在未来工作或更复杂的场景中，引入参数量更大的先进预训练视觉-语言大模型来生成极其细粒度的辅助描述（如具体的动作、属性细节），将是弥补该假设边界缺陷的一种极具潜力的演进方向。

4.2.3 算法设计

4.2.3.1 特权信息辅助优化

依据公式 4.1的概率分解形式，PIAL 框架的优化目标涵盖跨模态对应关系学习与特权信息关联建模两个层面。针对跨模态对齐任务，即公式中的 $P(y|x_1, x_2, z)$ 项，其优化过程可形式化为最小化以下期望风险：

$$\min_{\theta_f, \theta_g} \mathbb{E}_{(X_1, X_2)\sim\mathcal{D}} \left[\mathcal{L}_{\mathrm{CM}}(\langle x_1, x_2\rangle, y)\right]. \tag{4.2}$$

其中，$\mathcal{L}_{\mathrm{CM}}$ 表示跨模态损失函数，通常沿用对比损失或三元组损失等经典度量方式。在此过程中，估计所得的对应关系指示变量 y 被作为样本级权重引入损失函数，以自适应地抑制关联噪声对模型训练的负面干扰。

针对特权信息建模任务，即公式中的 $P(z|x_1)$ 与 $P(z|x_2)$ 项，本章通过分别对齐单一模态表征与特权信息表征来实现。该部分的期望风险函数定义如下：

$$\min_{\theta_f, \theta_g} \sum_{k=1,2} \mathbb{E}_{(X_k, Z)\sim\mathcal{D}} \left[\mathcal{L}_{\mathrm{PI}}(\langle x_k, z\rangle, c_k)\right]. \tag{4.3}$$

其中 $k \in \{1, 2\}$ 为模态索引，$\mathcal{L}_{\mathrm{PI}}$ 表示特权信息建模损失。与 y 类似，估计所得的关联指示器 c_k 作为置信度软标签，用于降低潜在噪声样本在优化过程中的贡献。至此，关联噪声场景下的鲁棒学习问题被转化为对指示变量 y、c_1 及 c_2 的显式估计问题。

4.2.3.2 噪声识别与修正

噪声识别。为实现对指示器 y、c_1 及 c_2 的精准估计，PIAL 采用了一种基于深度神经网络记忆效应的统一判别策略。记忆效应揭示了模型在训练过程中的一种固有特性，

即模型会优先拟合数据集中具有显著共性的干净样本，随后才逐渐过拟合复杂的噪声模式。利用这一时间差，模型可在训练早期构建出相对稳健的特征空间结构，进而利用样本在该结构下的分布一致性差异来甄别噪声数据。

针对跨模态关联判别任务，如图4.3左侧所示，得益于训练早期建立的稳健表征结构，干净样本对在特征空间中通常表现出显著优于噪声样本的语义对齐紧密度。基于此结构差异，本章设计了一个关联指示函数 y_{CM} 来量化双向跨模态关联指示器，其表达式如下：

$$y_{\mathrm{CM}}^{i}=\frac{1}{2}\left[\frac{e^{\langle x_1^i,x_2^i\rangle/\tau_1}}{\sum_{j=1}^{N}e^{\langle x_1^i,x_2^j\rangle/\tau_1}}+\frac{e^{\langle x_1^i,x_2^i\rangle/\tau_1}}{\sum_{j=1}^{N}e^{\langle x_1^j,x_2^i\rangle/\tau_1}}\right] \tag{4.4}$$

其中，e 代表指数函数，τ_1 为温度系数。该公式本质上衡量了当前样本对 $\langle x_1^i,x_2^i\rangle$ 的相似度在全局相似度分布中的相对显著性。具体而言，对于语义匹配的干净样本，其特征相似度将会占据主导地位，使得指示器数值趋近于 1；反之，对于错误关联的噪声样本，由于缺乏语义对齐，其相似度数值较低，导致指示函数值趋向于 0。通过融合图像检索文本与文本检索图像两个视角的计算结果，该双向函数有效提升了判别的稳定性。

鉴于模态特征与特权信息之间的对齐本质上同样遵循对比学习的优化范式，上述基于结构差异的判别策略可被推广应用于特权信息关联的噪声识别。特权信息关联指示器 c^i 的估计形式化如下：

$$c_k^{i}=\frac{1}{2}\left[\frac{e^{\langle x_k^i,z^i\rangle/\tau_2}}{\sum_{j=1}^{N}e^{\langle x_k^i,z^j\rangle/\tau_2}}+\frac{e^{\langle x_k^i,z^i\rangle/\tau_2}}{\sum_{j=1}^{N}e^{\langle x_k^j,z^i\rangle/\tau_2}}\right]_{k=1,2} \tag{4.5}$$

其中，$k\in\{1,2\}$ 为模态索引，τ_2 为特权信息分支的温度系数。计算所得的关联指示器 c_k 将被用于在损失函数中抑制关联噪声样本的梯度贡献。进一步地，依据本章提出的核心假设，对于一个真实可靠的多模态关联样本，其图像与文本模态应同时与共享的特权信息保持语义一致。为了最大程度地剔除潜在的噪声干扰，任何单一模态未能与特权信息建立有效匹配的样本均被判定为关联噪声。因此，基于特权信息辅助的最终关联噪声指示器 y_{PI} 被定义为两个单模态关联指示器的最小值：

$$y_{\mathrm{PI}}^{i}=\min\{c_1^i,c_2^i\} \tag{4.6}$$

置信度导向的加权融合。尽管跨模态关联指示器 y_{CM} 与特权信息关联指示器 y_{PI} 分别从不同视角刻画了样本的潜在关联质量，但二者在特定场景下均存在局限性。就跨模态视角而言，仅依赖单一模型预测的训练动态可能存在波动，且基于记忆效应的判

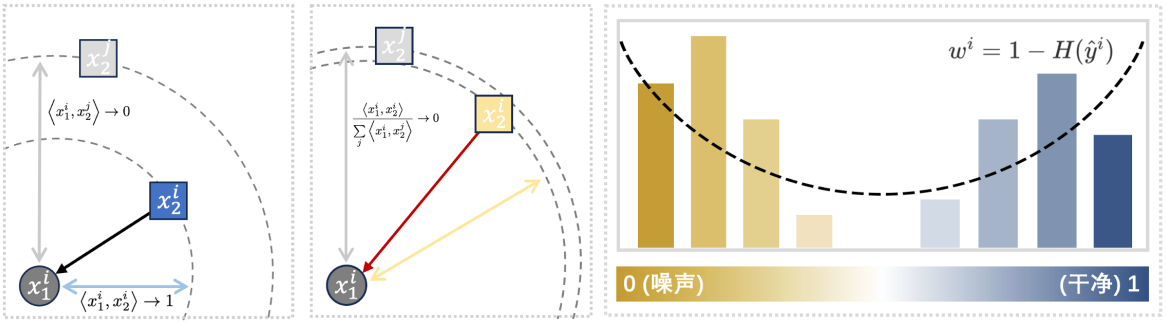

图 4.3　PIAL 算法的噪声识别与置信度融合模块示意图。左图展示了，基于深度学习模型的记忆效应，干净与噪声样本在相似度上表现出明显的分布差异。PIAL 利用这种不一致性识别噪声样本。右图展示了 PIAL 的置信度导向的加权融合模块，用于融合不同视角预测的指示器结果。
Figure 4.3　Illustration of the noise identification and confidence-oriented weighting fusion modules in the PIAL algorithm. The left panel illustrates that clean and noisy samples exhibit significant distributional differences in similarity, leveraging the memorization effect of deep learning models. PIAL exploits this inconsistency to identify noisy samples. The right panel displays the confidence-guided weighted fusion module of PIAL, which is designed to integrate the predicted indicators from diverse perspectives.

别机制容易将富含语义信息的难样本误判为噪声。就特权信息视角而言，当引入的外部信息与原始模态特征存在语义鸿沟或关联微弱时，y_{PI} 的估计准确性将受到显著影响。上述局限性均会导致指示器估计值的不稳定，即模型对样本关联状态的判定表现出较高的不确定性。为此，本章设计了一种置信度导向的自适应融合策略。一般而言，当指示器数值趋近于 0 或 1 时，意味着模型具有较高的判别置信度。基于此性质，本文利用熵函数对指示器的置信度权重 w_{CM} 与 w_{PI} 进行建模，定义如下：

$$w^i = 1 - H(y^i) = y^i \log y^i + (1 - y^i) \log (1 - y^i) + 1 \tag{4.7}$$

该函数具有以下的物理意义：当 y^i 趋向于 0.5 时，表示判别极不确定，置信度分数 w^i 降至极小值；反之，当 y^i 趋向于 0 或 1 时，w^i 达到最大值。为进一步强化高置信度指示器的贡献，引入指数系数 η 对权重进行锐化处理。最终融合后的关联指示器 y^i 通过加权平均与归一化计算得出：

$$y^i = \frac{(w^i_{\mathrm{CM}})^\eta}{r^i} y^i_{\mathrm{CM}} + \frac{(w^i_{\mathrm{PI}})^\eta}{r^i} y^i_{\mathrm{PI}}. \tag{4.8}$$

噪声修正。本章通过改进公式4.2和4.3中的学习目标来应对关联噪声问题。鉴于估计所得的指示器 $y, c_k \in [0, 1]$ 本质上是反映关联质量的软标签，本文将其作为样本级加

权项显式纳入损失函数计算。在关联学习的建模上，本章沿用了广泛适用的对比损失范式。修正后的跨模态损失 $\mathcal{L}_{\mathrm{CM}}$ 与特权信息辅助损失 $\mathcal{L}_{\mathrm{PI}}$ 定义如下：

$$\mathcal{L}_{\mathrm{CM}} = -\frac{1}{2N}\sum_{i=1}^{N} y^i \left[\log \frac{e^{\langle x_1^i, x_2^i\rangle/\tau_1}}{\sum_{j=1}^{N} e^{\langle x_1^i, x_2^j\rangle/\tau_1}} + \log \frac{e^{\langle x_1^i, x_2^i\rangle/\tau_1}}{\sum_{j=1}^{N} e^{\langle x_1^j, x_2^i\rangle/\tau_1}}\right] \tag{4.9}$$

$$\mathcal{L}_{\mathrm{PI}} = -\frac{1}{2N}\sum_{i=1}^{N}\sum_{k=1,2} c_k^i \left[\log \frac{e^{\langle x_k^i, z^i\rangle/\tau_2}}{\sum_{j=1}^{N} e^{\langle x_k^i, z^j\rangle/\tau_2}} + \log \frac{e^{\langle x_k^i, z^i\rangle/\tau_2}}{\sum_{j=1}^{N} e^{\langle x_k^j, z^i\rangle/\tau_2}}\right] \tag{4.10}$$

其中，关联指示器 y 和 c_k 直接作用于样本级损失。为降低在全量数据集上计算的高昂开销，本章采用蒙特卡洛采样策略，利用当前批次大小 B 近似替代全量 N。PIAL 的总体优化目标定义为两类损失函数的加权和，公式如下：

$$\mathcal{L} = \gamma\mathcal{L}_{\mathrm{CM}} + (1-\gamma)\mathcal{L}_{\mathrm{PI}} \tag{4.11}$$

其中 γ 为超参数，用于平衡不同损失项的权重以实现最佳优化效果。

4.2.3.3 训练策略

PIAL 的整体架构如图4.4所示。该框架包含两个模态特定编码器 f_1, f_2，用于将独立的单模态输入映射至共享特征空间；以及一个多层感知机模型 g，用于提取经 CLIP 预编码的特权信息表征。需指出的是，直接将特权信息融入检索主干特征空间的有效性尚待探究。鉴于 PIAL 的核心目标旨在利用特权信息辅助关联噪声学习，且共享空间内的强制聚类可能干扰跨模态检索的特征判别，本章实施了梯度截断策略，阻断特权信息建模对检索主干特征提取的反向传播。

为提升关联指示器预测的稳定性，本章借鉴 ELR[13]的思想，引入时间集成（Temporal Ensembling）策略，通过维护训练周期内的移动平均值来平滑化预测波动。具体而言，记 $\tilde{y}_{\mathrm{CM}}^i[t]$ 和 $\tilde{c}_k^i[t]$ 为当前轮次 t 计算所得的原始指示器预测值。更新后的集成指示器 $y_{\mathrm{CM}}^i[t]$ 和 $c_k^i[t]$ 计算公式如下：

$$\begin{aligned} y_{\mathrm{CM}}^i[t] &= \beta_1\tilde{y}_{\mathrm{CM}}^i[t] + (1-\beta_1)y_{\mathrm{CM}}^i[t-1], \\ c_k^i[t] &= \beta_2\tilde{c}_k^i[t] + (1-\beta_2)c_k^i[t-1] \end{aligned} \tag{4.12}$$

其中 β_1、β_2 为独立的动量系数。此外，真实关联指示器的预测精度可通过引入双网络协同架构[14,79,81]得到进一步提升。该策略并行训练两个结构相同的网络，利用对偶网络输出的指示器进行交叉监督。这种机制有效规避了单模型对自身噪声预测的过拟合风险。第 4.3 节的消融实验验证了上述策略对模型性能提升的显著作用。特权信息辅助的关联噪声鲁棒学习（PIAL）算法的完整流程总结于算法4.1中。

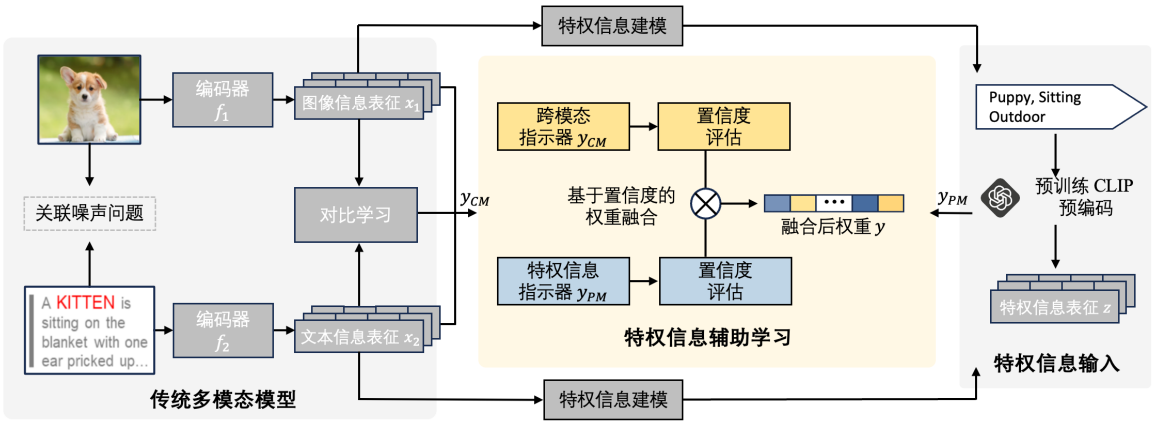

图 4.4　特权信息辅助的关联噪声鲁棒算法框架示意图。PIAL 首先通过分别的编码器提取图像与文本表征，并基于对比学习损失对齐表征。在此基础上，PIAL 引入 CLIP 编码的特权信息来辅助识别关联噪声样本。PIAL 通过噪声识别模块估计独立的指示器 y_{CM} 和 y_{PI}，然后通过置信度导向的权重融合得出最终权重。

Figure 4.4　An overview of PIAL. The framework of PIAL. Similar to typical correspondence learning methods, PIAL extracts image and text representations through separate encoders and optimizes a contrastive learning strategy for alignment. Crucially, PIAL introduces CLIP-encoded privileged information to identify and mitigate noisy correspondences. The model first estimates separate indicators y_{CM} and y_{PI} through the noise discrimination module, and then derives the final weight via confidence-oriented weight fusion.

4.2.4　讨论与分析

相较于现有的关联噪声学习工作，PIAL 方法在性能上的显著提升归因于其对引入特权信息的高效利用机制。不同于 MRL[20]与 ELRCMR[21]等方法侧重于特征层面的简单聚合，PIAL 通过对模态间关联不一致性的显式建模，实现了对关联噪声样本权重的自适应抑制，而非仅依赖特征混合。此外，该方法具备良好的通用性与扩展性，可作为独立模块无缝集成至现有的多模态关联学习框架中，以显著增强模型的抗噪鲁棒性。

在计算效率方面，PIAL 采用了轻量级的架构设计。公式4.4与公式4.5中关联指示器的计算，直接复用了主对比损失（即公式4.9与4.10）计算过程中的相似度矩阵，从而使得单次前向传播引入的额外计算开销几乎可以忽略不计。尽管 PIAL 引入了额外的多层感知机用于特权信息投影，但相较于其在关联噪声场景下带来的显著性能增益，该参数量的增加在计算成本效益上极具优势。

算法 4.1 特权信息辅助的关联噪声鲁棒学习算法流程

Input: 数据集 $\mathcal{D}:\{X_1^i, X_2^i, \hat{y}^i\}_{i=1}^N$，特权信息 Z^i。

分别为模型 A 和 B 初始化参数；
使用预训练 CLIP 模型对特权信息进行编码。
for 训练轮次 $t = 1, 2, \ldots, T$ **do**
  for 深度学习模型 $k = A, B$ **do**
    for 单一批次 $\mathcal{B} \sim \mathcal{D}$ **do**
      编码器 f_1, f_2 提取模态表征 x_1, x_2；
      编码器 g 提取特权信息表征 z；
      根据公式 4.9 计算经 y 修正的跨模态对比学习损失函数；
      根据公式 4.4 估计并记录指示器 y_{CM}；
      根据公式 4.10 计算经 c 修正的特权信息辅助损失；
      根据公式 4.5, 4.6 估计并记录指示器 c, y_{PI}；
      根据公式 4.11 计算最终总损失 $\mathcal{L}$。
    根据公式 4.7 估计指示器的不确定性分数 $w_{\mathrm{CM}}, w_{\mathrm{PI}}$；
    根据公式 4.12 更新 $y_{\mathrm{CM}}[t]$ 和 $c[t]$ 以供另一网络使用。

Output: 鲁棒深度学习模型 A 与模型 B。

4.3 实验验证

4.3.1 实验设定介绍

4.3.1.1 数据集与评价指标

为全面验证本章所提算法在特权信息辅助下的关联噪声鲁棒性，实验选取了 MS-COCO、NUS-WIDE 以及 Conceptual Captions (CC152K) 三个主流图文检索基准数据集。本章实验中关于数据集的基础划分、样本数量以及预处理流程均与第三章保持一致。在此基础上，本章额外引入了特权信息以辅助模型训练，如下具体介绍各数据集的具体特权信息配置：

- **MS-COCO**[219]：采用该数据集自带的 91 类物体检测标签作为特权信息，旨在引入细粒度的语义辅助信号。
- **NUS-WIDE**[220]：选取数据集官方提供的基于 81 个概念的图像标签作为特权信息来源。
- **Conceptual Captions (CC152K)**[94]：鉴于数据集未提供官方标签，本章采用公开可用的、由机器生成的检测标签作为特权信息。

噪声仿真与评价指标：关于仿真关联噪声的生成策略（包括噪声比率设定与负样本重排机制）以及跨模态检索任务的评价体系，本章完全沿用第三章的实验标准。具体而言，采用通用的 Top-K 召回率（Recall at K, R@K）及其总和（Recall Sum）作为核心

指标，以量化评估模型在不同噪声场景下的语义对齐性能。

4.3.1.2　实验实施细节

针对本章涉及的所有实验，均基于 PyTorch 深度学习框架实现，并在单张 NVIDIA A100 GPU 计算平台上完成端到端训练。在网络架构方面，除非在消融实验中另有说明，默认采用 SGR 作为基础骨干网络，训练批次大小统一设定为 128。对于多模态输入数据，图像与文本模态首先分别被提取为 2048 维与 300 维的特征向量，随后通过线性映射投影至 1024 维的联合嵌入空间。针对本章引入的特权信息，算法首先利用预训练的 CLIP 模型提取语义特征，继而通过一个 4 层的多层感知机模块进行编码学习，以捕捉高层语义关联。

在训练策略上，全程采用 Adam 优化器[227]进行参数更新，初始学习率设定为 1×10^{-4}，并实施分步衰减策略：每经过 10 个训练轮次将学习率乘以衰减系数 0.2，直至模型收敛。在模型选择阶段，选取在验证集上召回率总和指标达到最优时的模型权重作为最终测试模型。针对模型超参数，实验中涉及的两个温度系数 τ_1 和 τ_2 默认均设定为 0.07；用于时间集成的两个动量参数 β_1 和 β_2 均设定为 0.7。此外，用于平衡跨模态损失 $\mathcal{L}_{\mathrm{CM}}$ 与特权信息辅助损失 $\mathcal{L}_{\mathrm{PI}}$ 的权重超参数 γ 设定为 0.5；用于置信度评估的锐化系数 η 设定为 10，以作为指数衰减项增强高置信度样本的权重贡献。

4.3.1.3　实验中涉及的算法介绍

为了确保实验对比的公平性与全面性，本章实验除了沿用第三章中已介绍的 NCR、DECL、RINCE、MSCN 及 BiCro 等基准方法外，还额外选取了本文第三章提出的 GSC 方法以及近期发表的 CREAM 和 UCPM 两种前沿算法作为对比对象。新增对比方法的具体介绍如下：

- **GSC**[97]：这是本文第三章提出的基于几何结构一致性的关联噪声鲁棒方法。该方法深入挖掘了多模态数据内在的跨模态与模态内几何拓扑特征，利用干净样本与噪声样本在训练早期建立的几何结构一致性上的显著差异来实现噪声识别，并通过自适应的软标签修正机制有效抑制了关联噪声对表征学习的干扰。
- **CREAM**[16]：该方法提出了一种基于一致性精炼与挖掘的关联噪声处理框架。其核心机制在于利用跨模态预测的一致性来动态纠正错误的关联标签，同时引入了针对性的难样本挖掘策略。通过在特征空间中有效区分具有高损失值的语义难样本与真实的关联噪声样本，该方法显著提升了检索模型在噪声环境下的判别能力。
- **UCPM**[18]：该方法针对跨模态检索中普遍存在的部分错配问题，提出了一种不

确定性引导的鲁棒学习策略。通过引入证据学习理论对样本的认知不确定性进行显式建模，该算法能够自适应地感知图文对在细粒度语义上的匹配程度，并据此动态调整优化权重，从而减轻部分匹配或完全不匹配噪声带来的负面影响。

4.3.2 主要实验结果

4.3.2.1 在仿真关联噪声数据集上的鲁棒性对比

为全面评估各算法在不同噪声强度下的鲁棒性能，本实验在 MS-COCO 与 NUS-WIDE 基准数据集上分别引入了 20%、40% 和 60% 的仿真噪声。相关定量对比结果汇总于表 4.1。实验数据表明，PIAL 在各项检索指标上显著优于现有的关联噪声鲁棒方法。具体而言，在 MS-COCO 与 NUS-WIDE 数据集上，该方法的召回率总和相较于次优结果分别提升了 1.2% 与 3.8%，验证了其优越的抗噪鲁棒性。需指出的是，尽管对比方法如 DECL 和 BiCro 采用了特征交互更为复杂的 SGRAF 作为骨干网络，基于基础 SGR 架构的 PIAL 依然取得了领先的性能表现。与 GSC 及 UCPM 等近期工作相比，尽管各方法在低噪声水平下均表现出一定的竞争力，但 PIAL 随着噪声比例的攀升展现出了更为显著的性能增益。特别是在 60% 的高噪声设定下，该方法依然保持了较高的检索精度，证实了特权信息辅助机制在复杂噪声环境下的稳定性与可靠性。此外，PIAL 通过引入外部特权信息对模态间关联关系进行校验，该机制具备良好的通用性，可与现有的关联噪声鲁棒策略互补融合，以进一步提升模型性能上限。

4.3.2.2 在真实关联噪声数据集上的鲁棒性对比

为验证所提方法在真实世界复杂噪声环境下的有效性，本节进一步在 CC152K 数据集上进行了实验，详细结果如表 4.2所示。该数据集构建于互联网自动抓取数据，且未经过人工清洗，因此能够真实地反映现实场景中复杂的噪声分布形态。实验结果表明，PIAL 展现出了最优的综合检索性能，其召回率总和达到 359.2%，超越了次优算法 UCPM 约 4.0%。需要特别说明的是，由于原始 Conceptual Captions 数据集并未提供官方特权信息，本实验所引入的特权信息系由第三方预训练模型自动生成。这意味着引入的辅助信息本身可能受限于预训练模型的确认偏差而包含标签噪声。然而，即便在原始图文关联噪声与特权信息噪声的双重干扰下，PIAL 依然保持了稳健的性能表现。这一结果证实了该方法不仅能有效应对分布可控的仿真噪声，在处理现实世界中结构复杂、来源多样的关联噪声问题时，同样具备显著的适应性与鲁棒性。

表 4.1　PIAL 与现有关联噪声鲁棒方法在 MS-COCO 与 NUS-WIDE 数据集上在 20%、40% 和 60% 噪声率下的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示，次优方法的结果加下划线表示，使用特权信息的方法添加了 † 标记。

Table 4.1　Comparison of cross-modal retrieval performance between PIAL and existing noisy correspondence robust methods on the MS-COCO and NUS-WIDE datasets under 20%, 40%, and 60% noise rates. The experimental results respectively present the image-to-text and text-to-image retrieval recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the sum of the recall rates. The best results in the table are highlighted in bold, the second-best results are underlined, and methods utilizing privileged information are marked with †.

Noise	Methods	MS-COCO							NUS-WIDE						
		Image → Text			Text → Image				Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum	R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	SGR[223]	25.7	58.8	75.1	23.5	58.9	75.1	317.1	25.0	56.0	70.5	27.1	55.2	69.2	303.0
	SGRAF[223]	75.4	95.2	97.9	60.1	88.5	94.8	511.9	26.3	60.8	74.9	27.2	59.6	72.8	321.6
	NCR[14]	76.6	95.6	98.2	60.8	88.8	95.0	515.0	35.9	70.0	80.6	37.0	69.4	79.5	372.4
	DECL[17]	77.5	95.9	98.4	61.7	89.3	95.4	518.2	37.1	69.8	80.0	37.2	68.3	79.5	371.9
	RINCE[134]	73.8	95.6	98.5	61.7	89.2	94.7	513.5	26.6	64.5	75.5	26.0	63.9	73.9	330.4
	MSCN†[22]	78.1	**97.2**	98.8	64.3	90.4	95.8	524.6	37.0	67.5	76.3	36.8	69.1	78.2	364.9
	BiCro[15]	78.8	96.1	98.6	63.7	90.3	95.7	523.2	38.3	68.2	77.8	38.0	68.5	78.4	369.2
	GSC[97]	**79.5**	96.4	98.9	**64.4**	**90.6**	95.9	**525.7**	**39.6**	71.1	82.1	36.7	68.1	80.0	377.6
	CREAM[16]	78.9	96.3	98.6	63.3	90.1	95.8	523.0	38.6	71.2	82.3	37.2	70.4	80.7	380.4
	UCPM[18]	79.2	96.1	98.6	64.0	90.5	95.9	524.4	**39.6**	**71.3**	81.2	37.5	70.7	79.9	380.2
	PIAL†	79.1	96.7	**99.0**	64.3	90.4	**96.0**	525.5	39.3	70.6	**82.5**	**38.6**	**71.2**	**80.8**	**383.0**
40%	SGR[223]	1.3	3.7	6.3	0.5	2.5	4.1	18.4	20.6	49.3	63.7	19.1	48.8	62.4	263.9
	SGRAF[223]	15.8	23.4	54.6	17.8	43.6	54.1	209.3	20.7	52.0	67.7	19.0	50.0	66.9	276.3
	NCR[14]	74.7	94.6	98.0	59.6	88.1	94.7	509.7	15.6	40.2	51.9	16.1	39.2	51.2	214.2
	DECL[17]	75.6	95.5	98.3	59.5	88.3	94.8	512.0	35.1	68.0	79.8	35.8	66.4	78.7	363.8
	RINCE[134]	71.2	95.8	97.9	59.1	88.6	94.3	506.9	27.7	59.5	67.9	28.0	58.6	67.0	308.7
	MSCN†[22]	75.3	95.4	98.2	60.3	88.6	94.8	512.6	33.3	65.3	74.8	32.4	65.9	77.7	349.4
	BiCro[15]	77.0	95.9	98.3	61.8	89.2	94.9	517.1	35.7	67.8	77.2	35.0	66.6	77.4	359.7
	GSC[97]	**78.2**	95.9	98.2	62.5	89.7	**95.4**	519.9	37.7	71.0	81.2	35.9	68.4	78.8	373.0
	CREAM[16]	76.5	95.6	98.3	61.7	89.4	95.3	516.8	37.0	69.9	81.0	36.3	68.5	78.2	370.9
	UCPM[18]	78.0	95.9	98.4	62.6	89.7	**95.4**	520.0	37.5	70.8	80.3	37.1	69.8	79.2	374.7
	PIAL†	78.1	**96.0**	**98.6**	**62.7**	**89.8**	**95.4**	**520.6**	**38.2**	**71.1**	**81.6**	**37.2**	**69.9**	**79.3**	**377.3**
60%	SGR[223]	0.1	0.6	1.0	0.1	0.5	1.1	3.4	15.5	46.1	58.6	15.8	43.1	59.1	238.2
	SGRAF[223]	0.2	3.6	7.9	1.5	5.9	12.6	31.7	17.8	48.0	62.2	18.9	48.7	62.8	258.4
	NCR[14]	0.1	0.3	0.4	0.1	0.5	1.0	2.4	0.1	1.1	1.3	0.1	0.7	1.4	4.7
	DECL[17]	73.0	94.2	97.9	57.0	86.6	93.8	502.5	31.6	64.7	77.5	31.7	64.7	76.3	346.5
	RINCE[134]	72.3	94.0	97.9	58.4	86.6	92.5	501.7	27.1	55.8	62.7	26.8	54.5	61.1	288.0
	MSCN†[22]	72.5	93.6	97.1	57.7	87.0	93.9	501.8	30.3	59.9	65.5	30.1	62.4	74.4	322.6
	BiCro[15]	73.9	94.4	97.8	58.3	87.2	93.9	505.5	34.1	64.0	75.1	33.2	62.8	73.7	342.9
	GSC[97]	75.6	95.1	98.0	60.0	88.3	94.6	511.7	35.3	68.8	80.1	32.9	66.8	78.4	362.3
	CREAM[16]	74.7	94.8	98.0	59.7	88.0	94.6	509.9	35.4	68.8	80.5	33.9	67.1	78.6	364.3
	UCPM[18]	75.1	94.7	98.1	60.5	88.7	94.7	511.8	34.0	68.3	79.7	35.3	67.8	78.2	363.3
	PIAL†	**76.4**	**95.4**	**98.4**	**61.1**	**88.8**	**94.8**	**514.9**	**36.0**	**69.8**	**80.8**	**35.4**	**68.5**	**78.8**	**369.3**

表 4.2 PIAL 与现有关联噪声鲁棒方法在 CC52K 数据集上的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示，次优方法的结果加下划线表示，使用特权信息的方法添加了 † 标记。。

Table 4.2 Comparison of cross-modal retrieval performance between PIAL and existing noisy correspondence robust methods on the CC152K dataset. The experimental results respectively present the image-to-text and text-to-image retrieval recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the sum of the recall rates. The best results in the table are highlighted in bold, and the second-best results are underlined, and methods utilizing privileged information are marked with †.

Methods	CC152K						
	Image → Text			Text → Image			
	R@1	R@5	R@10	R@1	R@5	R@10	Sum
SGR[223]	33.0	62.6	71.5	33.9	61.3	72.8	335.1
SGRAF[223]	34.4	63.6	73.9	33.7	63.3	75.1	344.0
NCR[14]	34.3	64.2	75.7	35.3	64.0	75.4	348.9
DECL[17]	35.7	62.7	75.7	37.0	63.4	74.4	348.9
RINCE[134]	33.4	62.9	72.8	32.6	61.2	72.0	334.9
MSCN†[22]	32.2	61.0	72.7	34.3	61.4	71.8	333.4
BiCro[15]	32.4	61.0	68.4	35.3	60.3	70.9	328.3
GSC[97]	**37.5**	65.0	<u>76.0</u>	<u>36.5</u>	64.0	75.0	354.0
CREAM[16]	<u>37.2</u>	<u>66.5</u>	75.0	35.8	64.8	75.0	<u>354.3</u>
UCPM[18]	36.9	66.2	75.6	<u>36.5</u>	<u>65.4</u>	<u>75.6</u>	<u>355.2</u>
PIAL†	36.1	**66.7**	**78.1**	**36.9**	**65.5**	**75.9**	**359.2**

4.3.2.3 与预训练模型的性能对比

参照 NCR[14]的实验设定，本节在 MS-COCO 数据集上对比了 PIAL 与大规模预训练模型 CLIP[3]的性能。鉴于 CLIP 模型通常在大规模互联网图文数据上进行预训练，其原始训练分布中天然存在关联噪声现象。如表 4.3所示，实验首先评估了 CLIP-Large 与 CLIP-Base 模型的零样本推理性能。结果显示，即便在训练数据包含 50% 仿真噪声的条件下，PIAL 方法的检索性能仍优于零样本设置下的 CLIP-Large 模型，且在召回率总和指标上实现了提升。相比之下，直接在含有关联噪声的 MS-COCO 数据集上对 CLIP-Base 模型进行微调会导致严重的性能退化：在 20% 与 50% 噪声率下，其召回率总和分别大幅下降了 125.3 与 230.5。上述对比结果深刻揭示了关联噪声对模型鲁棒性的破坏作用，同时也充分证实了 PIAL 算法在抑制噪声干扰、维持表征稳定性方面的有效性。

表 4.3　PIAL 与预训练模型 CLIP 在 MS-COCO 仿真噪声数据集上的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示。

Table 4.3　Comparison of cross-modal retrieval performance between PIAL and the pre-trained CLIP model on the MS-COCO dataset with simulated noise. The experimental results present the image-to-text and text-to-image recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the overall sum of recall rates. The best results are highlighted in bold.

Noise	Methods	MS-COCO						
		Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
0% Zeroshot	CLIP-L	58.4	81.5	88.1	37.8	62.4	72.2	400.4
	CLIP-B	50.2	74.6	83.6	30.4	56.0	66.8	361.6
20% Finetune	CLIP-B	21.4	49.6	63.3	14.8	37.6	49.6	236.3
	NCR	56.9	83.6	91.0	40.6	69.8	80.1	422.0
	PIAL	**58.9**	**84.7**	**91.7**	**42.1**	**71.3**	**81.7**	**430.4**
50% Finetune	CLIP-B	10.9	27.8	38.3	7.8	19.5	26.8	131.1
	NCR	53.1	80.7	88.5	37.9	66.6	77.8	404.6
	PIAL	**56.6**	**82.7**	**89.9**	**40.5**	**69.2**	**79.8**	**418.7**

4.3.2.4　与离线数据清洗方法 CapFilt 的对比实验

为进一步验证 PIAL 方法的有效性，本实验将其与 BLIP[91]中提出的离线数据清洗模块 CapFilt 进行对比，详细结果见表 4.4。CapFilt 代表了一类典型的两阶段去噪策略，其核心思想是利用在 MS-COCO 等干净数据集上预训练的参考模型对目标数据进行推理，并通过筛除相似度得分较低的样本来过滤关联噪声。然而，此类基于外部静态先验的离线清洗策略存在固有的局限性：当目标数据集的数据分布与预训练数据集存在显著的域差异时，模型的清洗效能往往受限。例如，在 NUS-WIDE 数据集上，受数据分布偏移的影响，CapFilt 难以在不同噪声率设定下精准识别关联噪声样本。实验结果表明，PIAL 在各噪声设置下的性能均显著优于经 CapFilt 清洗后训练的 SGR 模型，召回率总和平均提升幅度达 11.6%。不同于 CapFilt 的离线处理范式，PIAL 通过引入特权信息将噪声识别机制内嵌于训练全过程，实现了对关联噪声的动态检测与修正，从而在应对域偏移挑战时展现出更优的鲁棒性与训练效率。

表 4.4 PIAL 与离线数据清洗方法 CapFilt 在 MS-COCO 仿真噪声数据集上的跨模态检索性能比较。实验结果分别展示了不同方法的图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示。

Table 4.4 Comparison of cross-modal retrieval performance between PIAL and the offline data cleaning method CapFilt on the MS-COCO dataset with simulated noisy correspondence. The experimental results present the image-to-text and text-to-image recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the overall sum of recall rates. The best results are highlighted in bold.

Noise	Method	Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	CapFilt	36.0	68.1	81.1	35.3	67.8	79.7	368.0
	PIAL	**38.8**	**72.8**	**81.7**	**36.5**	**69.3**	**80.2**	**379.3**
40%	CapFilt	35.9	66.8	80.0	35.7	66.9	77.2	362.5
	PIAL	**37.6**	**70.0**	**81.3**	**35.5**	**68.6**	**79.2**	**372.2**
60%	CapFilt	29.9	66.1	79.1	30.5	65.1	76.0	346.7
	PIAL	**35.3**	**68.3**	**79.8**	**33.6**	**66.2**	**77.3**	**360.5**

4.3.3 消融实验结果

4.3.3.1 对算法各部分设计的消融实验

为深入探究 PIAL 算法中各核心组件对模型鲁棒性的具体贡献，本节在 MS-COCO 与 NUS-WIDE 数据集的不同噪声率设定下开展了消融实验。实验重点考察了基于动量的时间集成策略（即表中 Mom.）、双网络协同学习架构（即表中 Dual.）以及特权信息辅助模块（即表中 $\mathcal{L}_{\text{PI}}$）这三个关键组成部分。在实验设置上，当移除时间集成策略时，实验采用 5 个轮次的预热阶段予以替代；当移除双网络协同机制时，模型仅保留单网络分支进行训练；当移除特权信息辅助模块时，则去除了相关的建模损失函数与指示器。

表 4.5 的实验结果表明，缺失任一组件均引发了模型检索性能的明显下滑，从而验证了各模块设计对于实现优异性能的必要性。具体而言，相较于基础的预热策略，时间集成机制通过平滑预测波动，显著增强了训练过程的稳定性。特权信息的引入有效强化了模型对关联噪声样本的判别能力，尤其在高噪声率场景下带来了显著的性能增益。此外，即便在仅使用单网络架构的情况下，PIAL 的性能仍优于 NCR、DECL 和 RINCE 等主流基线方法，这充分证实了特权信息辅助机制在关联噪声学习中的核心价值与有效性。

表 4.5　PIAL 方法在 MS-COCO 数据集上 40% 仿真噪声率下的消融实验。分别对基于动量的参数更新策略、双网络协同学习架构与特权信息辅助模块进行了消融。实验结果分别展示了图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。

Table 4.5　Ablation study of the PIAL method on the MS-COCO dataset under 40% simulated noise rate. The momentum-based parameter update strategy, dual-network collaborative learning architecture, and privileged information assistance module are ablated, respectively. The experimental results report the recall rates for image-to-text and text-to-image retrieval, where R@K indicates the Top-K recall metric, and Sum denotes the sum of the recall rates.

Noise	Mom.	Dual.	$\mathcal{L}_{\mathrm{PI}}$	MS-COCO							NUS-WIDE						
				Image → Text			Text → Image				Image → Text			Text → Image			
				R@1	R@5	R@10	R@1	R@5	R@10	Sum	R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	✓	✓	×	78.8	96.1	98.3	61.8	89.3	95.2	519.5	39.1	70.9	82.2	35.8	68.2	80.0	376.2
	✓	×	✓	76.9	95.7	98.4	60.2	88.5	94.9	514.6	37.8	69.4	80.1	36.2	68.5	79.7	371.7
	×	✓	✓	79.0	96.2	98.5	63.3	90.1	95.4	522.5	37.9	**71.7**	82.2	38.3	70.6	79.0	379.7
	✓	✓	✓	**79.1**	**96.7**	**99.0**	**64.3**	**90.4**	**96.0**	**525.5**	**39.3**	70.6	**82.5**	**38.6**	**71.2**	**80.8**	**383.0**
40%	✓	✓	×	77.0	95.7	98.1	60.6	88.6	94.6	514.6	37.5	70.0	80.0	34.9	67.8	78.9	369.1
	✓	×	✓	76.5	95.5	98.4	59.3	87.6	94.3	511.6	35.2	68.6	80.5	33.1	67.8	77.5	362.7
	×	✓	✓	77.1	95.4	98.0	62.2	89.4	95.0	517.1	**39.2**	70.2	79.8	36.0	68.9	78.5	372.6
	✓	✓	✓	**78.1**	**96.0**	**98.6**	**62.7**	**89.8**	**95.4**	**520.6**	38.2	**71.1**	**81.6**	**37.2**	**69.9**	**79.3**	**377.3**
60%	✓	✓	×	75.4	94.9	98.0	59.2	87.9	94.3	509.7	33.9	67.8	79.2	31.2	66.1	77.5	355.7
	✓	×	✓	74.9	94.8	97.9	58.3	86.7	93.2	505.8	33.6	66.9	80.0	33.1	65.2	78.0	356.8
	×	✓	✓	74.9	95.2	98.0	60.3	88.2	94.6	511.2	33.8	69.4	79.8	33.5	66.6	78.0	361.1
	✓	✓	✓	**76.4**	**95.4**	**98.4**	**61.1**	**88.8**	**94.8**	**514.9**	**36.0**	**69.8**	**80.8**	**35.4**	**68.5**	**78.8**	**369.3**

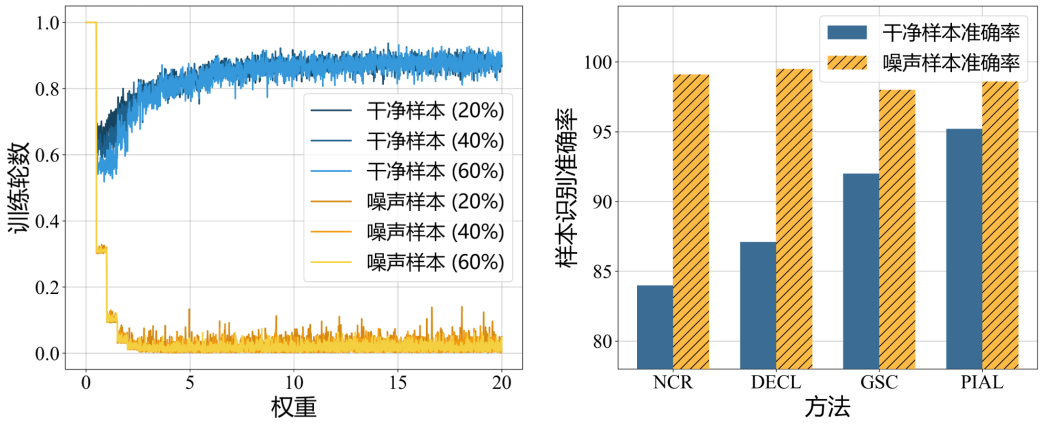

图 4.5　PIAL 算法的训练与判别可视化分析。左图展示了在不同噪声率下，PIAL 对干净与噪声样本的预测权重随训练轮次的变化趋势。右图展示了 PIAL 与不同算法在仿真噪声数据集上对干净和噪声样本的判别准确率。所有实验均在 MS-COCO 数据集上进行。

Figure 4.5　Visualization analysis of the training and discrimination processes for the PIAL method. The left plot illustrates the curves of predicted weights for clean and noisy samples across training epochs under various noise rates. The right plot compares the discrimination accuracy of PIAL and other algorithms on clean and noisy samples within simulated noisy datasets. All experiments are conducted on the MS-COCO dataset.

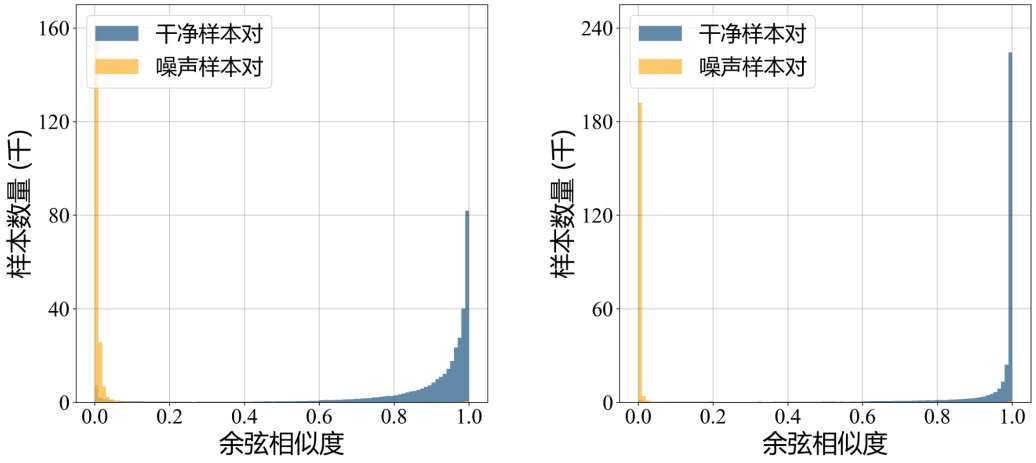

图 4.6 PIAL 算法的权重分布可视化分析。左右子图分别展示了基于跨模态与特权信息辅助预测得到的关联标签的分布直方图，表明模型能以极高的准确率区分干净与噪声样本。所有实验均在 MS-COCO 数据集上进行。

Figure 4.6 Visualization analysis of weight distributions for the PIAL algorithm. The left and right subplots illustrate the histograms of correspondence labels predicted based on cross-modal similarity and privileged information assistance, respectively. The distributions demonstrate that the model distinguishes clean samples from those with noisy correspondence with high accuracy. All experiments are conducted on the MS-COCO dataset.

4.3.3.2 权重变化与分布可视化分析

为验证 PIAL 算法在训练动态过程中的稳定性及其对噪声样本的判别效能，本节对样本权重的演变趋势及分布特性进行了可视化分析。如图 4.5 左侧所示，展示了在 20%、40% 及 60% 不同噪声率设定下，PIAL 赋予干净样本与关联噪声样本的权重随训练轮次的演变轨迹。观察可见，各噪声率下的权重演化呈现出高度的一致性：干净样本的权重迅速攀升并稳定在 0.9 附近，而关联噪声样本的权重则被有效抑制并趋近于 0。这种显著的动态差异表明 PIAL 在处理不同强度的关联噪声时具有极佳的稳定性。图 4.5 右侧进一步量化对比了不同方法区分干净与关联噪声样本的准确率。实验结果显示，PIAL 在维持高噪声识别精度的同时，对干净样本的判别准确率显著优于 NCR 与 DECL。这一结果揭示了 NCR 与 DECL 倾向于将位于决策边界的难样本错误判定为噪声，而 PIAL 凭借特权信息的辅助，能够更精准地捕捉潜在的真实关联。

图 4.6 进一步展示了模型习得的权重分布特性。其中，左图与右图分别对应基于跨模态相似度计算的指示器 y_{CM} 与引入特权信息辅助后的指示器 y_{PI} 的分布情况。直方图清晰地呈现出显著的双峰分布形态：干净样本与关联噪声样本的权重分布界限分明，且关联噪声样本的指示器数值高度集中于 0 附近。这种优异的区分度确保了该

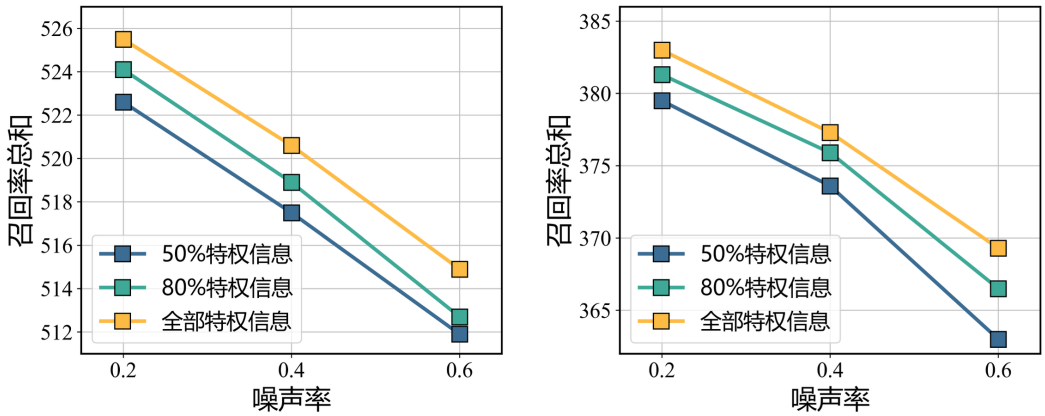

图 4.7　PIAL 算法在特权信息部分缺失时的性能比较。图中展示了 PIAL 算法在获得全部、80%、50% 数据特权信息时的检索召回率总和。左图：MS-COCO 数据集上的实验结果。右图：NUS-WIDE 数据集上的实验结果。

Figure 4.7　Performance analysis of PIAL under partially unavailable privileged information. The figure illustrates the sum of recall for cross-modal retrieval when PIAL is provided with 100%, 80%, and 50% of the privileged information from the training data, respectively. Left: Experimental results on the MS-COCO dataset. Right: Experimental results on the NUS-WIDE dataset.

权重能够作为可靠的置信度信号，直接作用于样本级对比损失函数，从而有效阻断关联噪声对表征学习的干扰。通过特权信息的有效融合，PIAL 增强了对样本本质属性的建模能力，显著提升了模型在复杂多模态对齐任务中的鲁棒性。

4.3.3.3　特权信息部分缺失时的性能分析

鉴于现实应用场景中特权信息往往难以覆盖全量数据，本节通过随机丢弃部分训练数据的特权信息，以探究 PIAL 算法在信息缺失条件下的性能表现。在该设定下，对于缺乏特权信息的样本，算法将自动退化为仅依赖跨模态指示器 y_{CM} 进行关联噪声识别。图 4.7 展示了在 100%、80% 以及 50% 三种特权信息覆盖率下的检索结果。实验数据表明，即便在仅有 50% 样本提供辅助信息的条件下，PIAL 依然保持了优异的鲁棒性，且性能显著优于传统的仅基于内部信息的判别方法。此外，模型性能随特权信息覆盖比例的提升呈现出稳定的增长态势。上述结果验证了 PIAL 方法对外部监督信号完整性的适应能力，证明其在特权信息部分缺失的挑战性场景下，仍能利用稀疏的外部语义锚点有效抑制关联噪声的干扰。

4.3.3.4　不同特权信息编码器层数对性能的影响分析

为进一步验证 PIAL 算法在不同模型配置下的泛化性与鲁棒性，本节考察了特权信息编码器（即 MLP 投影模块）的深度对最终检索性能的影响。如图 4.8 所示，实

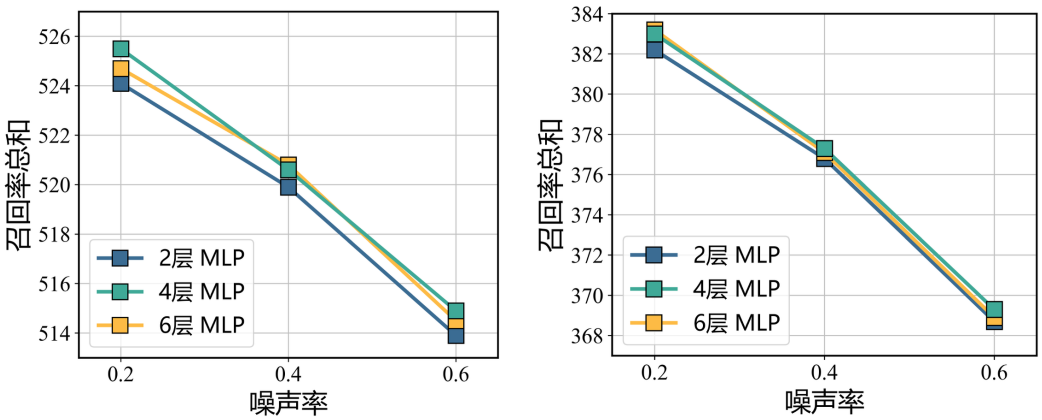

图 4.8　PIAL 算法对不同特权信息编码器层数的敏感性分析。图中展示了 PIAL 算法在 2 层、4 层、6 层特权信息编码器下的检索召回率总和。根据实验结果，本文采用 4 层特权信息编码器。左图：MS-COCO 数据集上的实验结果。右图：NUS-WIDE 数据集上的实验结果。

Figure 4.8　Performance analysis of the PIAL algorithm to the number of layers in the privileged information encoder. The figures illustrate the sum of recall for the PIAL algorithm under 2, 4, and 6 layers of the privileged information encoder. Based on the experimental results, a 4-layer privileged information encoder is adopted in this thesis. Left: Experimental results on the MS-COCO dataset. Right: Experimental results on the NUS-WIDE dataset.

验在 MS-COCO 与 NUS-WIDE 数据集上对比了 2 层、4 层及 6 层 MLP 设定下的模型表现。实验结果表明，该算法对编码器层数的变化表现出较强的适应稳定性。从理论层面分析，加深网络层数通常能增强模型的非线性表征能力，有助于更精细地建模特权信息与原始模态特征之间的语义关联。实验数据印证了这一规律，即深层架构（4 层与 6 层）的检索精度略优于浅层架构（2 层）。然而，随着层数的进一步增加，性能提升的边际效益逐渐递减并趋于饱和。综合考量特征表达能力与计算效率，本章在后续实验中统一采用 4 层 MLP 作为特权信息的投影模块。这一结果证实了 PIAL 算法无需依赖复杂的特权信息投影网络即可实现对关联噪声的有效抑制，体现了该方法在实际部署中的高效性。

4.3.3.5　基于不同检索主干网络的性能分析

为评估 PIAL 算法在不同网络架构下的普适性与兼容性，本小节探究了该方法在多种跨模态检索主干网络下的性能表现。如图 4.9 所示，实验选取了 SGR、SGRAF 以及基础的 VSE 三种主流架构作为基准，对比了引入 PIAL 算法前后的性能差异。实验数据表明，PIAL 在所有测试的主干网络上均取得了一致的性能增益，验证了其在不同架构下的鲁棒性。

SGRAF 架构因融合了 SGR 模块的图推理能力与 SAF 模块的相似度过滤机制，

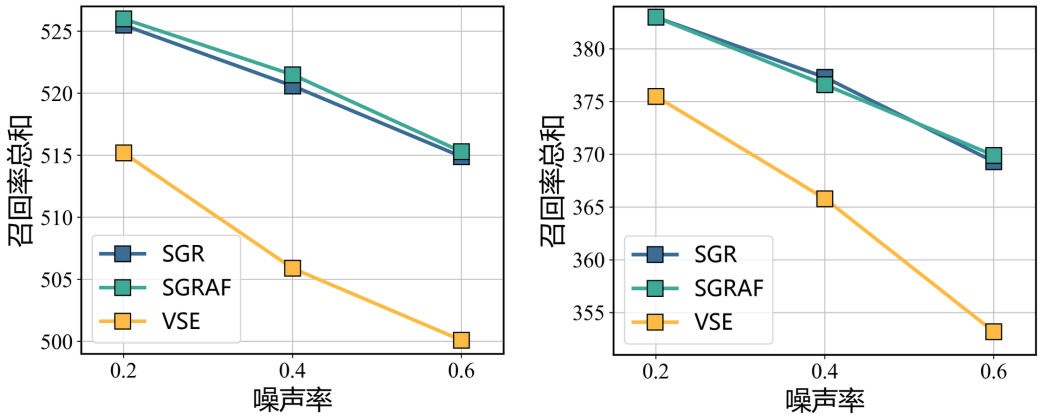

图 4.9　PIAL 算法基于不同主干网络的性能分析。图中展示了 PIAL 算法基于不同主干网络 SGR、SGRAF、VSE 的检索召回率总和。左图：MS-COCO 数据集上的实验结果。右图：NUS-WIDE 数据集上的实验结果。

Figure 4.9　Performance analysis of the PIAL algorithm across different backbone networks. The figure illustrates the recall summation of the PIAL algorithm when integrated with SGR, SGRAF, and VSE backbones. Left: Experimental results on the MS-COCO dataset. Right: Experimental results on the NUS-WIDE dataset.

在所有基准配置下均取得了最优的召回率表现。在此基础上，PIAL 依然能为 SGR 和 SGRAF 这类结构较为复杂的骨干网络带来稳定的性能提升，表明该方法能够有效适配具有深层推理机制的检索模型。值得注意的是，针对本身缺乏噪声处理机制的 VSE 架构，PIAL 带来的性能增强尤为显著。这主要归因于 PIAL 引入的外部特权信息有效弥补了基础模型在噪声判别上的局限性。上述结果充分证实了 PIAL 具备良好的通用模块特性，无论主干网络的结构复杂度如何，该算法均能通过校正不稳定的监督信号来优化表征对齐过程，从而显著提升模型在现实关联噪声场景下的泛化能力。

4.3.3.6　不同训练批次大小对性能的影响分析

本节深入考察了训练批次大小这一关键超参数对 PIAL 算法性能的影响。如图 4.10 所示，实验在 MS-COCO 和 NUS-WIDE 数据集上分别测试了批次大小为 64、96 和 128 时的模型检索性能。结果显示，随着批次大小的增加，模型性能总体呈现出上升趋势，并逐渐趋于收敛。

从对比学习的内在机制分析，损失函数的优化依赖于正样本与同批次内负样本的差异化对比。较大的批次能够在单次迭代中引入更丰富的负样本，从而增强模型挖掘难样本的能力，有助于构建更加稳健且具备高判别力的跨模态表征结构。实验数据印证了这一分析，当批次大小设定为 128 时，模型在不同关联噪声率下均取得了最优的召回率总和。相比之下，较小的批次大小由于负样本采样范围受限，往往导致梯度

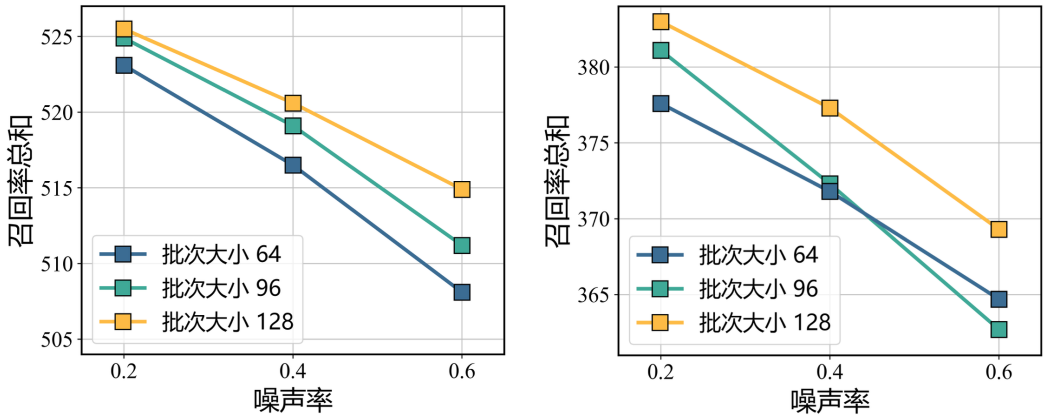

图 4.10　PIAL 算法对不同训练批次大小的敏感性分析。图中展示了 PIAL 算法基于 64、96、128 批次大小的检索召回率总和。左图：MS-COCO 数据集上的实验结果。右图：NUS-WIDE 数据集上的实验结果。

Figure 4.10　Sensitivity analysis of the PIAL algorithm to different training batch sizes. The figure illustrates the sum of recall (RSUM) for the PIAL algorithm with batch sizes of 64, 96, and 128. Left: Experimental results on the MS-COCO dataset. Right: Experimental results on the NUS-WIDE dataset.

估计的方差增大，进而引发优化过程中的震荡与性能波动。综合考量计算资源开销与模型性能收益，本章后续实验统一将批次大小设定为 128，以在训练效率与算法鲁棒性之间取得最佳平衡。

4.3.3.7　不同特权信息噪声水平下的性能分析

在真实应用场景中，外部特权信息往往不可避免地包含固有噪声（如机器生成标签的错误），从而构成了更为严峻的“双重噪声”挑战。为验证 PIAL 算法在此类复杂场景下的鲁棒性，实验在特权信息中分别引入了 10%、20% 及 40% 的噪声比例。如图 4.11 所示，PIAL 在不同强度的特权信息噪声干扰下均展现出优异的稳定性。

分析性能曲线可知，即便特权信息包含高达 40% 的噪声，模型的检索性能衰减依然非常轻微，整体趋势紧贴无特权信息噪声的基准曲线，仅呈现出轻微波动。这种稳健性主要得益于算法内置的置信度导向融合机制：当特权信息质量下降导致预测指示器的不确定性升高时，模型能够利用熵函数量化该不确定性，并自适应地降低该视角的判别权重。实验结果表明，PIAL 并不过度依赖外部辅助信息的质量，而是通过多视角交叉校验机制有效抵消低质量特权信息的负面影响，从而在复杂的现实关联噪声环境中维持稳健的语义对齐性能。

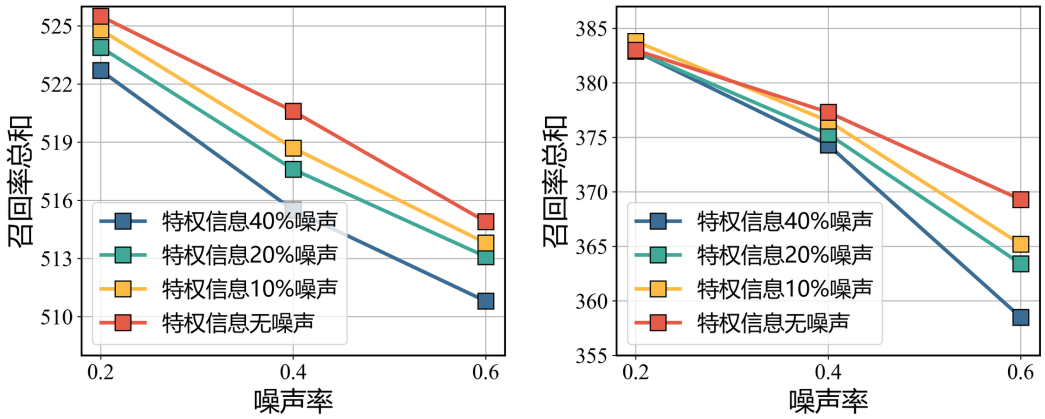

图 4.11　PIAL 算法在不同特权信息噪声水平下的性能分析。实验分别模拟了 10%、20%、40% 的特权信息噪声比率。左图：MS-COCO 数据集上的实验结果。右图：NUS-WIDE 数据集上的实验结果。

Figure 4.11　Performance analysis of the PIAL algorithm under different noise levels of privileged information. The experiments simulate privileged information noise ratios of 10%, 20%, and 40%, respectively. Left: Experimental results on the MS-COCO dataset. Right: Experimental results on the NUS-WIDE dataset.

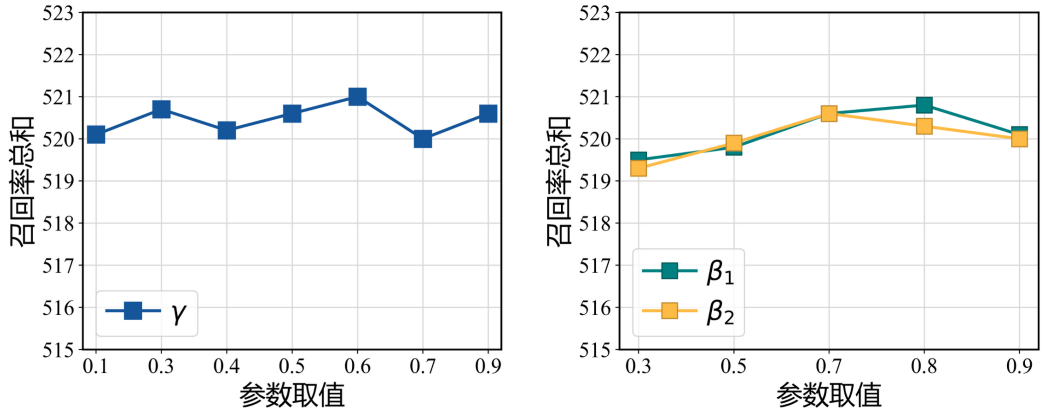

图 4.12　在 MS-COCO 数据集上 40% 关联噪声率下对超参数 γ、β_1、β_2 的消融实验。左图展示了对 γ 的消融实验，该参数是用于平衡 $\mathcal{L}_{\mathrm{CM}}$ 和 $\mathcal{L}_{\mathrm{PM}}$ 的权重参数；右图展示了对 β_1 和 β_2 的消融实验，分别为控制跨模态与模态内参数更新的动量参数。

Figure 4.12　Ablation study on hyperparameters γ, β_1, and β_2 on the MS-COCO dataset under 40% noisy ratio. Left: Ablation study on γ, which is the weight parameter used to balance $\mathcal{L}_{\mathrm{CM}}$ and $\mathcal{L}_{\mathrm{PM}}$. Right: Ablation study on β_1 and β_2, which are the momentum parameters controlling the cross-modal and intra-modal parameter updates, respectively.

4.3.3.8　超参数 γ、β_1 和 β_2 的敏感性分析

PIAL 框架包含三个核心超参数：用于平衡跨模态对比损失与特权信息辅助损失的权重系数 γ，以及控制时间集成更新速率的动量系数 β_1 与 β_2。图 4.12 展示了不同

参数取值对模型最终检索性能的影响。针对权重系数 γ，实验在 $[0.1, 0.9]$ 区间内进行了敏感性分析，如图 4.12 左图所示。结果显示，当 γ 设定为 0.5 附近的中值时，模型在不同任务间取得了最佳的优化平衡。过小或过大的权重均可能导致模型偏向单一任务，从而引发过拟合或导致主要跨模态对齐任务的优化不足。基于此分析，后续所有主实验均将 γ 固定为 0.5，以确保多任务间的协同优化效果。

对于动量系数 β_1 和 β_2，其分别调控跨模态与特权信息关联指示器在时间集成过程中的更新平滑度。如图 4.12 右图所示，当动量系数取值在 0.7 附近时，模型展现出最优且稳定的检索性能。这一经验取值与 ELR 及 GSC 等鲁棒学习算法的设置保持一致。较高的动量值能够有效利用历史状态的稳定性平滑指示器的更新轨迹，从而抑制当前批次中因关联噪声样本引发的预测波动。相反，过低的动量系数会导致指示器更新过于剧烈，增加了模型在训练早期对关联噪声模式过拟合的风险，进而损害泛化性能。综合上述分析，本章实验将 β_1 和 β_2 统一设定为 0.7，以保障训练过程的稳定性与鲁棒性。

4.3.3.9 复杂语义关联噪声下的性能分析

为进一步探究模型在高度拟真噪声环境下的鲁棒性，本节构建了基于复杂语义混淆的关联噪声评估基准，以替代传统的随机标签置换策略。具体来说，实验利用 MS-COCO 数据集包含的 11 个超类标注信息，将关联噪声的生成过程严格约束在同一语义超类内部。该策略旨在合成具备高语义相似度的“难负样本”型噪声：即图像与文本虽在细粒度内容上互不匹配，但在高维语义范畴上保持高度一致。这种构造方式显著提升了关联噪声样本的隐蔽性与识别难度，对模型的细粒度语义判别能力提出了更高要求。

实验结果汇总于表 4.6。数据表明，在 20%、40% 及 60% 的语义关联噪声率设定下，PIAL 方法均保持了最优的跨模态检索性能。即便面临高度混淆语义的干扰，得益于特权信息的引入，该方法仍能有效辅助模型捕捉并识别细粒度的语义失配。相较于 MSCN、BiCro 以及 GSC 等基准算法，PIAL 在召回率总和指标上展现出显著优势。上述结果证实了该算法在应对结构化、高难度关联噪声时的鲁棒性，也验证了其在复杂实际应用场景中的潜在价值。

4.3.3.10 不同数据集关联噪声样本可视化分析

为直观验证 PIAL 算法在多源噪声场景下的判别性能，图 4.13 可视化展示了从仿真噪声数据集（MS-COCO 与 NUS-WIDE）及真实世界噪声数据集（CC152K）中选取的代表性样本及其对应的指示器估值。其中，前三行样本源自仿真噪声数据集，

表 4.6　PIAL 与各噪声鲁棒算法在复杂语义关联噪声下的性能比较。实验在 MS-COCO 数据集上仿真了不同噪声率的复杂语义噪声，并测试了不同鲁棒方法的检索性能。实验结果分别展示了图像检索文本与文本检索图像召回率，R@K 为 Top-K 召回率评价指标，Sum 表示召回率总和。表格中最优方法的结果使用加粗表示，次优方法的结果加下划线表示。

Table 4.6　Performance comparison between PIAL and existing noisy correspondence robust methods under complex semantic noisy correspondence. The experiments simulate complex semantic noise at various noise rates on the MS-COCO dataset and evaluate the retrieval performance of different robust methods. The experimental results respectively present the image-to-text and text-to-image retrieval recall rates of different methods. R@K denotes the Top-K recall evaluation metric, and Sum represents the sum of the recall rates. The best results in the table are highlighted in bold, and the second-best results are underlined.

Noise	Methods	MS-COCO						
		Image → Text			Text → Image			
		R@1	R@5	R@10	R@1	R@5	R@10	Sum
20%	MSCN	77.9	96.0	98.5	62.2	89.7	95.4	519.7
	BiCro	77.6	95.9	98.4	61.7	89.4	95.2	518.2
	GSC	77.8	96.2	98.5	62.6	**90.0**	**95.6**	520.8
	PIAL	**78.4**	**96.3**	**98.6**	**62.9**	89.6	95.2	**521.1**
40%	MSCN	75.5	94.9	98.0	60.2	88.3	94.5	511.4
	BiCro	75.7	95.7	98.1	61.6	88.7	94.7	514.5
	GSC	76.4	**95.9**	98.3	61.3	89.0	**95.1**	516.0
	PIAL	**77.0**	95.7	**98.4**	**62.1**	**89.1**	94.7	**517.1**
60%	MSCN	71.9	93.6	97.1	57.1	87.0	93.9	500.6
	BiCro	73.8	94.2	97.7	57.8	87.0	93.8	504.3
	GSC	74.3	94.7	98.1	59.6	87.7	**94.3**	508.7
	PIAL	**75.7**	**95.1**	**98.2**	**60.4**	**87.9**	93.7	**511.1**

第四行样本则选自真实世界噪声数据集。可视化结果表明，对于大部分样本，跨模态关联指示器 y_{CM} 与特权信息辅助指示器 y_{PI} 均能准确识别真实的语义关联，并有效甄别语义错配的关联噪声样本。以第四行第二列来自 CC152K 的样本为例，两项指标均正确地将该严重失配的图文关联判定为噪声类别。

针对位于决策边界附近的困难样本，仅依赖单一视角的判别策略往往难以输出可靠的预测结果。在此类情境下，跨模态信息与特权信息展现出了显著的互补性与纠错能力。以图 4.13 第一行第二列的样本为例，图像中的火车与文本描述的卡车在视觉特征上存在一定的相似性，导致仅凭跨模态对齐难以完全排除其关联可能性。引入特权信息进行校验后，这种类别层面的语义不匹配被显著放大，促使模型精准识别出该关联噪声。这种多视角的交叉判别机制验证了 PIAL 算法的核心思想，体现了该方法在处理复杂及细粒度关联噪声样本时的鲁棒性与优越性。

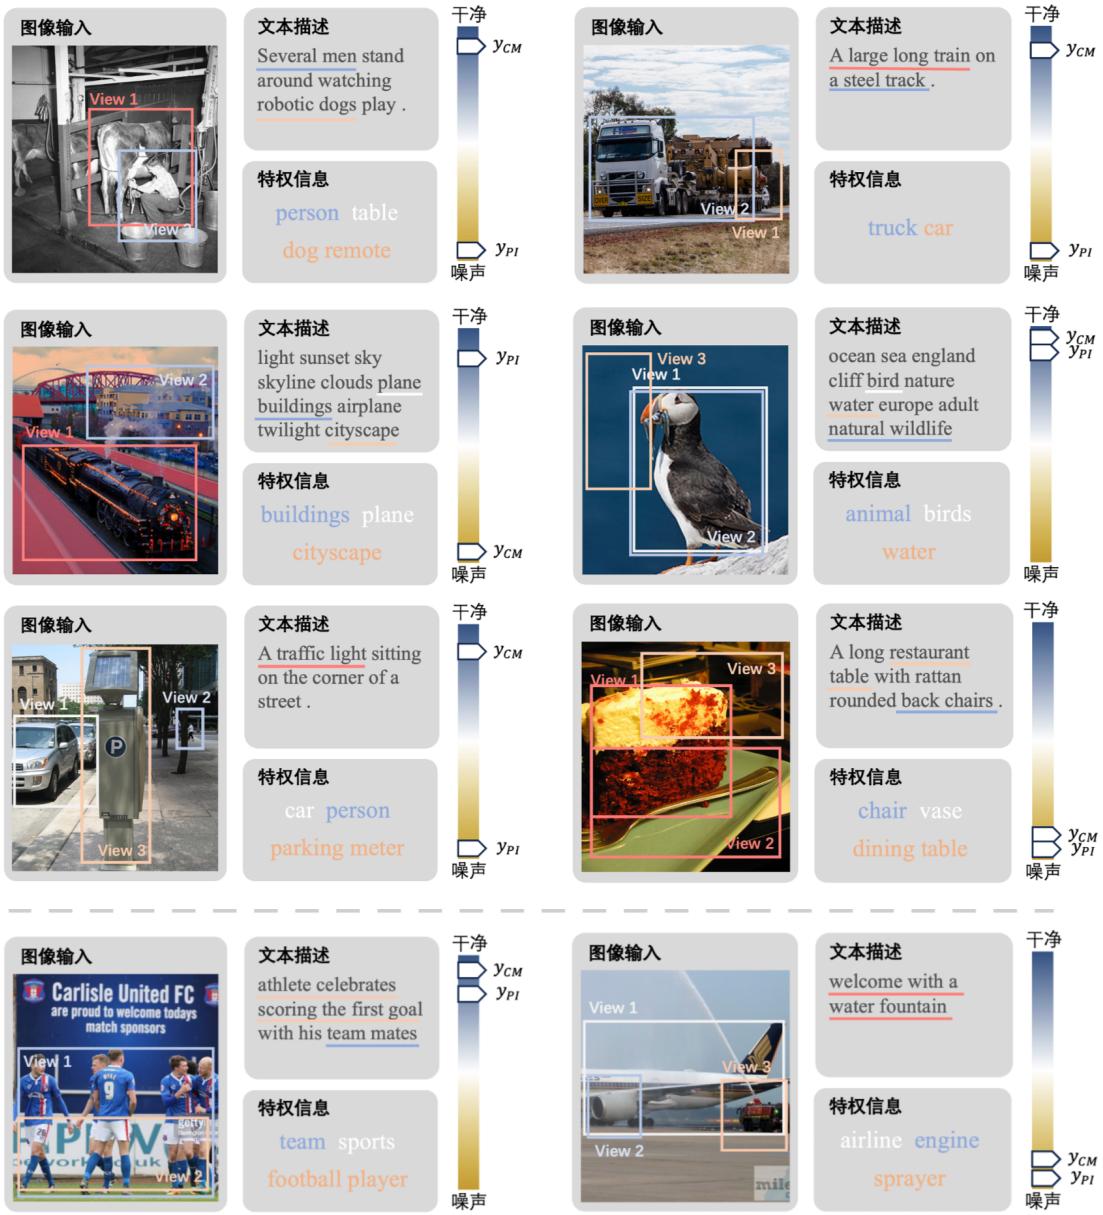

图 4.13 PIAL 算法识别的不同数据集关联噪声样本可视化。前三行展示了仿真噪声数据集 MS-COCO 和 NUS-WIDE 中的识别出的关联噪声样本。最后一行是真实世界数据集 CC152K 中识别出的噪声样本。图像与文本中与特权信息匹配的语义信息被标记为对应的颜色，红色则表示不匹配。示例右侧展示了跨模态关联指示器 y_{CM} 和特权信息关联指示器 y_{PI} 的预测值。

Figure 4.13 Visualization of noisy correspondence samples identified by the PIAL algorithm across different datasets. The first three rows display the identified noisy samples from the synthetic noisy MS-COCO and NUS-WIDE, and the last row show samples from the real-world dataset CC152K. Semantic information in images and text that matches the privileged information is highlighted in corresponding colors, while red indicates a mismatch. The predicted values of the cross-modal and privileged information correspondence indicator are presented on the right.

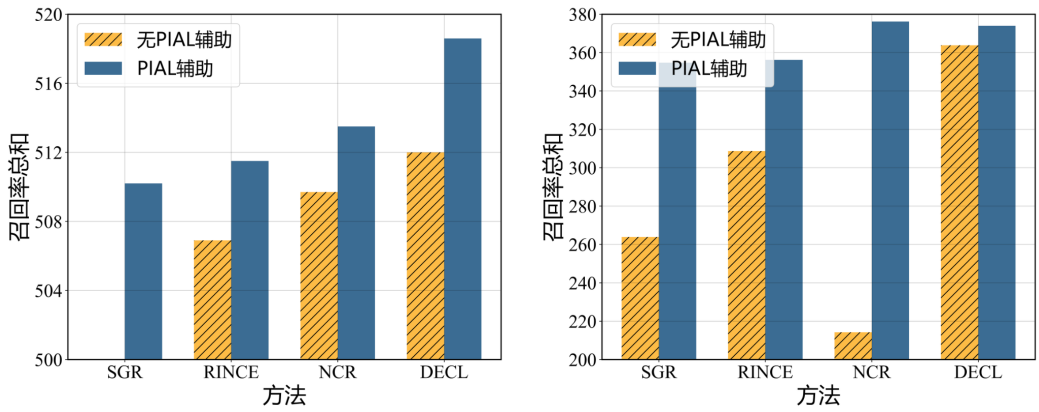

图 4.14　PIAL 算法应用于现有鲁棒算法的通用性分析。实验记录了在鲁棒算法 SGR、RINCE、NCR、DECL 上应用 PIAL 的性能对比。实验在 40% 噪声对应关系下进行。左图：MS-COCO 数据集上的实验结果。右图：NUS-WIDE 数据集上的实验结果。

Figure 4.14　Generality analysis of the PIAL algorithm applied to existing robust methods. Performance comparison of SGR, RINCE, NCR, and DECL with the integration of PIAL under 40% noisy correspondence. Left: Experimental results on the MS-COCO dataset. Right: Experimental results on the NUS-WIDE dataset.

4.3.3.11　特权信息辅助的通用性分析

本节重点评估特权信息辅助机制在不同算法框架下的通用性与兼容性。分析表明，NCR 和 DECL 等方法在处理高噪声率数据时表现受限，主要归因于其仅依赖数据内部信息，难以精准甄别复杂的关联噪声样本；即便是基于鲁棒损失函数的 RINCE 方法，在面对极端噪声水平时其性能亦存在瓶颈。鉴于 PIAL 算法架构良好的模块化特性，其核心的特权信息辅助模块可作为一种通用的增强组件，无缝集成至现有的鲁棒学习框架中。

为了验证这一特性，图 4.14 展示了将特权信息建模分别集成至 RINCE、NCR 和 DECL 三种代表性方法后的性能对比结果。实验数据显示，在 40% 关联噪声率的设定下，引入特权信息辅助后，上述所有基线方法的跨模态检索性能均实现了显著提升。这一现象有力地证实了引入外部特权信息作为客观语义锚点辅助，能够有效弥补现有鲁棒算法在关联噪声判别上的局限性，并为表征学习提供更为精准的监督信号。此外，尽管集成特权信息后各基线模型的性能均有大幅改善，PIAL 方法依然在整体指标上保持领先，这进一步佐证了本章提出的置信度导向融合机制与双重视角判别策略在解决关联噪声问题上的有效性与优越性。

表 4.7 PIAL 算法的计算开销分析。实验展示了不同算法在 NUS-WIDE 数据集上使用单张 A100 GPU 训练至收敛的计算开销对比，分别统计了算法的预热阶段用时、训练阶段用时以及总用时。
Table 4.7 Computational overhead analysis of the PIAL algorithm. The experiment presents a comparison of the computational costs for different algorithms on the NUS-WIDE dataset using a single NVIDIA A100 GPU to reach convergence, detailing the durations of the warm-up phase, training phase, and total training time.

Method	Warm-up (Mins)	Train (Mins)	Total (Hours)
SGR	/	11.2	7.5
NCR	17.7	37.0	26.1
MSCN	19.7	94.3	80.2
BiCro	16.3	18.0	14.7
GSC	/	27.4	18.3
PIAL	**/**	**17.8**	**11.9**

4.3.3.12 计算开销分析

为评估 PIAL 算法在实际部署中的运行效率，本节定量分析了不同关联噪声鲁棒学习方法的计算开销。表 4.7 详细列出了各方法在 NUS-WIDE 数据集上基于单张 NVIDIA A100 GPU 的训练耗时统计，涵盖预热阶段、正式训练阶段及总训练时长。实验结果表明，相较于 NCR、MSCN 和 BiCro 等依赖多阶段训练或复杂预热策略的方法，PIAL 摒弃了额外的预热过程，能够直接启动鲁棒训练，从而显著缩短了整体优化周期。在正式训练阶段，PIAL 表现出较高的单轮迭代效率，其单轮耗时约为 17.8 分钟，与基础模型 SGR 的 11.2 分钟处于同一量级，且大幅优于 MSCN 的 94.3 分钟。就总训练时长而言，PIAL 完成全过程训练仅耗时 11.9 小时，在所有对比的关联噪声鲁棒方法中表现最优。该效率优势主要归因于 PIAL 采用了轻量化的指示器计算机制，通过复用特征空间内的相似度计算结果，在未显著增加计算负载的前提下实现了鲁棒性提升。上述结果证实了 PIAL 在处理大规模多模态数据时具备良好的计算经济性与扩展潜力。

4.4 本章小结

本章针对仅依赖数据内部信息进行噪声识别的局限性，提出了一种特权信息辅助的关联噪声鲁棒学习框架（PIAL）。该方法基于“真实关联样本应与共享的特权信息保持语义一致”的假设，引入外部知识作为客观参照，构建了模态间的“三角校验”机制，旨在打破模型自我校正过程中的认知局限。

在方法设计上，本章提出了双视角噪声指示器生成策略，分别从跨模态对齐与特权信息关联两个维度评估样本的可靠性；结合基于熵的置信度自适应融合算法，根据模型在不同视角下的预测确定性动态调整权重，从而在有效利用外部知识辅助去噪的同时，抑制了特权信息自身不确定性带来的干扰。在多个基准数据集及真实噪声场景下的实验结果验证了该方法的有效性，特别是在特权信息部分缺失或自身含噪的挑战性条件下，模型仍表现出优异的鲁棒性。此外，实验亦证明该框架具备良好的通用性，可作为独立模块集成至现有的多模态网络中，有效提升表征质量。

尽管本章提出的方法在引入外部知识辅助去噪方面取得了进展，但仍存在进一步探索的空间。一方面，高质量特权信息的获取在实际应用中可能面临稀疏性或域偏移的挑战，限制了辅助效果的上限。另一方面，现有的标签或简短描述等特权信息在语义粒度上可能较为粗糙，难以应对细粒度的图文错配。未来的研究可探索利用多模态大模型生成更丰富、细致的辅助描述以提升校验精度。此外，关联噪声对多模态分类、生成等任务的影响同样深远，将特权信息辅助机制扩展至更广泛的多模态学习任务，构建通用的鲁棒表征学习框架，是后续研究的重要方向。

第 5 章　基于差分信息的样本选择多模态对比学习加速方法

前文分别从表征几何结构一致性与特权信息辅助两个维度，探讨了关联噪声场景下的鲁棒多模态对比学习。尽管上述方法有效精准识别了关联噪声样本并有效增强了表征质量，但引入的双网络架构或辅助模块在大规模预训练场景下面临着计算效率的瓶颈。针对海量数据下训练的鲁棒性与效率失衡的难题，本章提出一种基于差分信息的样本选择多模态对比学习加速方法。该算法摒弃了对外部参考模型的依赖，利用深度神经网络训练动态中样本拟合程度的时序特性，动态筛选高价值样本并滤除噪声。该机制在大幅缩减训练开销的同时保障了特征对齐质量，实现了高效性与鲁棒性的协同优化。

5.1　引言

如前文中所介绍，以 CLIP[3]为代表的多模态对比学习模型在零样本分类[233-234]、跨模态检索[235-236]等下游任务中展现了卓越的性能。这一范式的成功在很大程度上归功于在大规模图像-文本数据集上的预训练过程。然而，这种对数据规模的高度依赖不可避免地导致了高昂的计算成本与巨大的资源消耗[237]。为了缓解大规模预训练带来的算力负担，样本选择（Sample Selection）作为一种高效的替代范式，逐渐成为了研究热点[238-239]。该范式的核心理念在于从海量数据中精准识别并利用最具信息量与多样性的子集进行训练，旨在减少数据吞吐量的同时加速模型收敛并维持表征质量。

现有的面向加速的样本选择方法主要可划分为基于核心集的离线样本选择与基于训练动态的在线样本选择两类。离线核心集选择方法[240]致力于在训练前对原始数据进行裁剪以构建高质量子集，但此类方法通常依赖于一个性能强大的预训练参考模型（Reference Model）进行样本评分[241-242]。例如，利用 CLIPScore[166]进行数据过滤已成为业界通用的预处理手段。然而，在冷启动场景或特定领域任务中，获取高质量的参考模型往往面临困难，且针对海量数据的离线推理过程本身也存在高昂的计算开销。相比之下，在线样本选择方法[35]侧重于根据训练过程中的实时反馈动态筛选数据。然而，现有的在线选择策略大多未能充分考量现实数据中普遍存在的关联噪声问题。传统的基于梯度范数或损失函数值的筛选策略在噪声环境下容易失效：高梯度的样本可能为噪声，而低损失的样本可能缺乏信息量。尽管 NCR[14]等方法针对关联噪声问题进行了探索，但其普遍采用的双网络交叉筛选架构引入了倍增的计算成

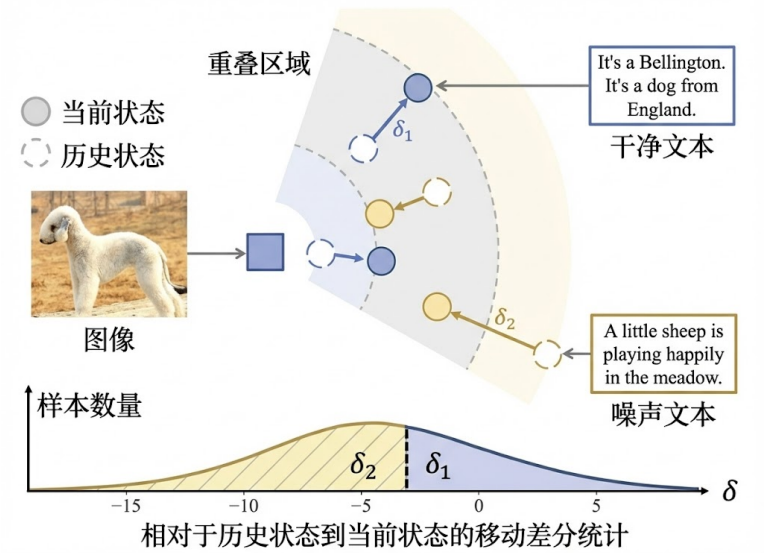

图 5.1　关联噪声问题与基于差分信息的样本选择加速算法。上图展示了学习具有关联噪声的样本，例如错误地将 Bellington 狗与绵羊联系起来，会损害多模态对比学习的效果。干净样本和噪声样本随着训练进行均被记忆，使模型失去样本辨别的能力。下图展示了基于差分信息的样本选择加速算法利用样本历史状态与当前状态之间的差分信息 δ，有效地鉴别出噪声对应关系。

Figure 5.1　Noisy correspondence problem and the differential-informed sample selection algorithm. The upper panel illustrates that learning from samples with noisy correspondence (e.g., incorrectly associating a Bedlington Terrier with a sheep) impairs the performance of multimodal contrastive learning. Both clean and noisy samples are memorized as training progresses, leading to a degradation in the model's discriminative capability. The lower panel demonstrates that the differential-informed sample selection acceleration algorithm effectively identifies noisy correspondences by leveraging the differential information δ between the historical and current states of the samples.

本，这与样本选择旨在加速训练的初衷相悖。

为了突破上述效率与鲁棒性难以兼顾的瓶颈，本章提出了一种无需参考模型辅助的高效在线样本选择方法，旨在在关联噪声场景下实现对多模态对比学习的加速。本章重新审视了关联噪声对对比学习训练动态的影响。如图 5.1所示，在多模态对比学习过程中，仅依据模型当前的预测置信度难以精确区分干净样本与噪声样本。随着训练的深入，模型逐渐发生对噪声的记忆，导致两类样本的分布出现重叠，致使基于静态损失阈值的筛选策略失效。然而，从时序演化的维度分析，模型在当前时刻的预测与历史状态之间的差分蕴含了关键的判别信息。具体而言，干净样本通常在训练早期被快速拟合，其得分变化随后趋于平稳或呈现特定的遗忘模式；反之，噪声样本在训练后期才被逐渐记忆，其得分呈现出显著的上升趋势。这种训练动态上的显著差异为区分样本质量提供了新的理论视角。

基于上述分析，本章提出了一种基于差分信息的样本选择多模态对比学习加速方法（Differential-Informed Sample Selection, DISSect）。该方法构建了一个样本粒度的差分信息指标，用于量化模型当前预测的相关性与历史状态之间的差异。通过捕捉模型对每个样本的记忆趋势，即判别样本处于被遗忘还是被错误记忆的阶段，DISSect 能够精准地评估样本质量。为确保计算的高效性，该差分函数基于 CLIPScore 的动态变化构建，并可以通过预热阶段或时间集成策略低成本地维护历史状态，避免了双网络架构带来的额外开销。最终，结合基于排序的动态采样策略，本章提出的方法优先选择具有高信息量的样本参与训练，在有效屏蔽噪声干扰的同时显著加速模型收敛。本章的主要贡献总结如下：

- 深入剖析了面向加速的多模态样本选择问题，指出了现有方法在处理关联噪声时的局限性，并揭示了在无参考模型场景下利用记忆效应的时序特征进行样本筛选的可行性。
- 提出了一种基于差分信息的样本选择多模态对比学习加速算法。该算法利用模型在历史与当前状态下相似度预测的差分变化，捕捉了干净样本与噪声样本在记忆效应上的显著差异，在不增加显著计算成本的前提下，实现了对关联噪声样本的精准筛除。
- 在三个基准数据集及多个下游任务上的广泛实验表明，DISSect 在训练效率与模型性能上均优于当前主流算法。特别是在 CC3M 数据集上，该方法在仅使用 30% 训练数据的情况下，达到了与全量数据训练相当的性能，显著降低了训练时间与算力消耗。

5.2 算法研究

5.2.1 预备知识

本节对多模态对比学习及其样本选择问题进行形式化定义。给定包含 N 个样本的多模态数据集 $\mathcal{D} = \{X_1^i, X_2^i\}_{i=1}^N$，其中 $\{X_1^i, X_2^i\}$ 代表第 i 对图像文本输入，N 为数据集大小。为便于阐述且不失一般性，本章以 CLIP[237] 确立的对比学习范式为基础展开讨论。该范式利用独立编码器 f_{θ_1} 与 g_{θ_2} 将图像 X_1 和文本 X_2 映射至共享特征空间，获取高维表征 $x_1 = f(X_1)$ 及 $x_2 = g(X_2)$。其中 θ_1 与 θ_2 分别表示图像与文本编码器的模型参数。为捕获模态间互信息，模型训练旨在拉近特征空间中正样本对的距离，同时推远当前批次内的非匹配负样本对。给定训练批次 $\mathcal{D}_b$，图像至文本方向的

InfoNCE 损失函数[243] 定义如下：

$$\mathcal{L}_{f\to g} = \frac{-1}{|\mathcal{D}_b|}\sum_{i=1}^{|\mathcal{D}_b|}\log\frac{\exp\left(\langle x_1^i, x_2^i\rangle/\tau\right)}{\sum_{j=1}^{|\mathcal{D}_b|}\exp\left(\langle x_1^i, x_2^j\rangle/\tau\right)}, \tag{5.1}$$

其中 τ 为可学习的温度系数，用于调节特征分布平滑度，$\langle\cdot,\cdot\rangle$ 为余弦相似度函数用于计算表征之间距离。模型总体优化目标通常计算为双向损失 $\mathcal{L}_{f\to g}$ 与 $\mathcal{L}_{g\to f}$ 的均值。

在此框架下，样本选择方法通过对数据集进行裁剪以加速训练。依据筛选机制差异，现有方法主要划分为核心集选择与在线样本选择两类。核心集选择在训练前从原始数据集 $\mathcal{D}$ 中筛选出高价值子集 $\mathcal{D}' \subset \mathcal{D}$，后续训练过程仅基于 $\mathcal{D}'$ 进行。在线样本选择则在训练过程中，依据模型实时状态，动态地从当前批次 $\mathcal{D}_b$ 中筛选出高信息量子集 $\mathcal{D}_b'(f,g) \subset \mathcal{D}_b$。本章提出的 DISSect 方法属于在线样本选择范畴。

5.2.2　研究动机

5.2.2.1　多模态样本选择的启发式探究

尽管单模态领域的样本选择方法多聚焦于过滤简单或冗余样本，但在多模态场景中，构建高效的样本选择策略仍面临诸多未解难题。为明确加速多模态对比学习的关键驱动因素，本章在 CC3M 数据集上开展了启发式对比实验，对不同选择基线的性能进行了系统评估。根据图 5.2所示，实验结果表明了以下三个核心结论：

- 在线样本选择范式优于离线核心集选择。从训练动力学角度分析，在相同的随机采样策略下，在线样本选择范式的性能显著优于离线核心集选择。这是因为在线选择允许模型在训练过程中接触到数据集中更广泛的数据分布，而非局限于预先固定的子集。这种动态的数据访问机制增加了数据的多样性，有助于模型规避局部最优解，从而获得更好的泛化能力。
- 基于损失值的传统样本选择策略在多模态场景下失效。尽管“大损失”（即选择损失值较大的难样本）或“小损失”（即选择损失值较小的高置信度样本）策略在单模态分类任务中应用广泛，但在多模态对比学习任务中均未能超越随机选择的基线。根本原因在于，多模态模型在训练初期的预测存在较大偏差，单纯依赖损失函数的数值无法准确反映表征样本的真实学习价值。高损失值样本往往混杂大量关联噪声，而仅保留低损失值样本则可能导致模型陷入对简单模式的过拟合，丧失对难样本的挖掘能力。
- 精确筛除关联噪声样本是提升训练效能的关键。实验对比显示，利用预训练模型进行筛选的 CLIPScore 方法在大幅降低计算开销的同时，性能优于全量数据

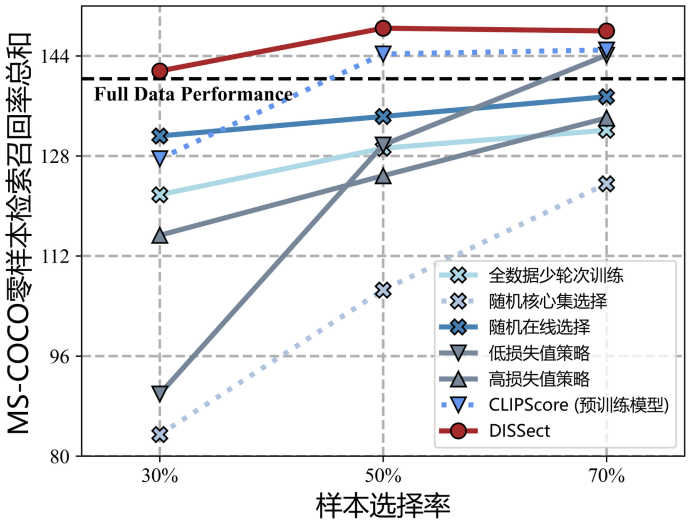

图 5.2　不同的样本选择策略在不同选择比例下的性能对比。展示了在 CC3M 数据集上预训练并在 MS-COCO 零样本检索任务上进行测试时，不同选择比例下各种样本选择方法的零样本检索召回率总和，其中在线选择方法和离线选择方法分别以实线和虚线标出。

Figure 5.2　Performance of various sample selection methods under different selection ratios pre-trained on CC3M dataset and tested on MS-COCO zero-shot retrieval task. Online and coreset selection methods are separately marked with full and dotted lines.

训练，且显著超越了旨在过滤低质量数据的“小损失”策略。这一结果有力地证明，在多模态预训练中，相较于单纯的数据规模堆叠，数据的信噪比与高质量对模型最终性能起着决定性作用。

深入剖析 CLIPScore 的有效性机制，其本质在于利用参考模型对数据对的相似性进行判断并以此作为筛选依据。具体而言，CLIPScore 的计算形式定义如下：

$$\text{CLIPScore}(x_1^i, x_2^i) = w \cdot \max(\langle x_1^i, x_2^i \rangle, 0) \tag{5.2}$$

其中，w 为缩放常数（本文中设置为 100），x_1 与 x_2 分别为图像和文本的特征表示。CLIPScore 之所以能取得优异表现，主要归因于其引入了在大规模数据集（如 LAION-400M[151]）上预训练的 CLIP-L 模型作为参考模型（Oracle Model）。该参考模型能够提供相对可靠的样本质量评估：经其筛选出的高分样本通常具有较高的语义一致性，而被过滤的低分样本则多为弱匹配或错配的关联噪声样本。相比之下，“小损失”策略在低保留率下的性能显著下降，揭示了其在缺乏外部先验知识引导时，无法有效区分噪声与难样本的内在缺陷。

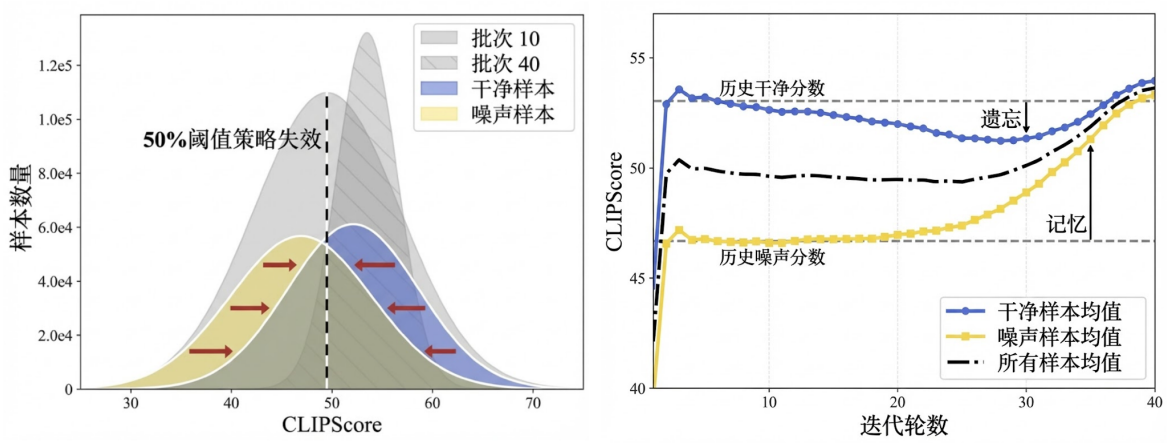

图 5.3　对比学习训练不同训练阶段的 CLIPScore 分布，其中干净与噪声样本由参考模型进行划分。左图分别展示了第 10 轮次与 40 轮次时干净与噪声样本的 CLIPScore 分布，这有效证明了基于损失阈值的样本选择策略失效的原因。右图展示了随着训练进行，干净样本与噪声样本的 CLIPScore 均值的变化趋势，其中干净样本展现出了明显的遗忘现象，而噪声样本则在训练后期被快速记忆。实验在 CC3M 数据集上进行。

Figure 5.3　Distributions of CLIPScore at different training stages of contrastive learning. Clean and noisy samples are partitioned by a reference model. The left figure shows the CLIPScore distributions of clean and noisy samples at epoch 10 and epoch 40, which effectively demonstrates why the loss threshold-based sample selection strategy fails. The right figure illustrates the trend of mean CLIPScores for clean and noisy samples as training progresses, where clean samples exhibit a distinct forgetting phenomenon, while noisy samples are rapidly memorized in the later stages of training. Experiments are conducted on the CC3M dataset.

5.2.2.2　记忆效应的再审视

尽管基于参考模型的 CLIPScore 机制能够提供有效的数据清洗方案，但在冷启动等现实场景中，获取一个高质量的参考模型往往不切实际。此外，正如前文实验所证实的，单纯依赖损失较小的简单样本并不能满足模型在整个预训练周期的优化需求。因此，本章致力于设计一种无参考模型辅助的在线样本选择方法，该方法仅依据当前正在训练的模型预测结果来动态定制样本批次，旨在达到与拥有参考模型时相当的关联噪声阻断效果。

为了探究这一机制的设计依据，本节深入剖析模型训练过程中的记忆效应及其对分布特性的具体影响。通过观察基准模型在全量数据训练过程中不同阶段（如第 10 轮与第 40 轮）的 CLIPScore 分布演变，如图 5.3所示，可以发现关联噪声直接影响了跨模态相似度学习的发散性：随着训练的深入，CLIPScore 的方差呈现显著收缩的趋势。这一现象归因于深度学习模型的记忆效应[13,244]，即模型倾向于优先拟合数据集中的干净模式，随后才开始强行记忆噪声样本。然而，当利用参考模型作为辅

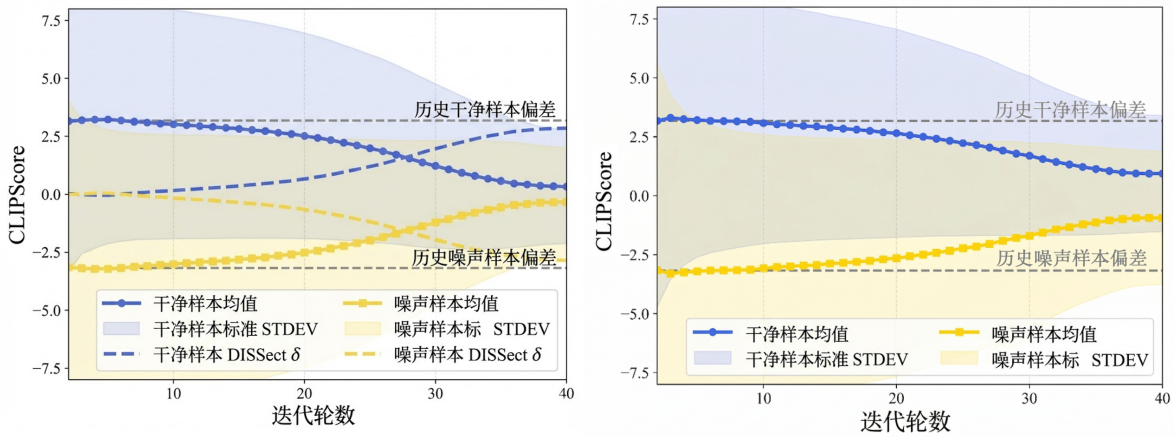

图 5.4　对比学习视角下的记忆效应。展示了干净与噪声样本在消除均值变化后的 CLIPScore 随训练进行的相对变化趋势。左图与右图分别对应使用 DISSect 方法前后的实验结果。可以发现在作用 DISSect 之后，干净样本的遗忘现象与噪声样本的记忆现象均有明显改观。

Figure 5.4　Memorization effect from the perspective of contrastive learning. It shows the relative variation trends of CLIPScores for clean and noisy samples as training progresses, after eliminating mean variations. The left and right figures correspond to the experimental results before and after applying the DISSect method, respectively. It can be observed that after applying DISSect, both the forgetting phenomenon of clean samples and the memorization phenomenon of noisy samples are significantly mitigated.

助，将训练数据划分为相对干净和噪声的子集进行观察时，揭示了一个更为关键的现象：随着训练进行，干净数据与噪声数据的相似度分布之间存在着不断扩大的重叠区域。这一分布层面的混淆解释了“小损失”策略失效的根本原因——在训练后期，简单的损失阈值截断[204]或高斯混合模型[81]已无法在重叠区域内精确分离干净样本与噪声样本。尽管早停策略[245]可以在模型大规模记忆噪声之前中止训练，但这本质上是一种妥协，因为它同时也限制了模型在干净数据上的性能增长，导致模型未能充分收敛。

进一步从 CLIPScore 均值的演变轨迹进行分析，可以更清晰地捕捉模型对不同性质样本的学习趋势差异。模型在训练的首个轮次能够迅速捕捉正样本对之间的相似性，此时干净数据表现出显著高于噪声数据的平均 CLIPScore。然而，随着训练的持续推进，模型开始出现对干净数据高相似特征的“遗忘”现象，表现为 CLIPScore 从早期的峰值出现回落；与此形成鲜明对比的是，关联噪声样本正在被模型逐渐“记忆”，导致其 CLIPScore 呈现快速上升的趋势。这种此消彼长的动态变化最终导致了两类样本在得分空间上的塌陷与混淆，表明仅凭当前的静态预测值已难以区分样本质量。这一观察结果为后续利用训练动态的差分信息来区分样本提供了直接的理论

启发。

5.2.3　算法设计

5.2.3.1　基于差分信息的动态样本选择

为深入剖析记忆效应对模型判别能力的影响，本章通过减去 CLIPScore 均值的波动，对训练过程中的得分演变趋势进行了可视化分析。如图 5.4所示，随着训练的深入，干净样本与噪声样本的相对 CLIPScore 呈现出相互趋近的态势。该现象表明，仅依赖模型当前的预测状态已难以有效区分样本质量；受关联噪声干扰，模型的判别边界逐渐模糊。这意味着在噪声环境下的持续学习过程中存在一种权衡：模型在拟合更多数据的同时，牺牲了对样本质量的辨别能力。针对这一挑战，本章提出了一种基于差分信息的样本选择多模态对比学习加速方法（DISSect），旨在通过量化这种辨别能力损失来恢复对噪声的敏感度。具体而言，DISSect 计算模型在历史状态与当前状态下对样本预测得分的时序差分 δ，定义如下：

$$\delta = \text{CLIPScore}_{\text{hist}} - \text{CLIPScore}_{\text{curr}} \tag{5.3}$$

在实践中，历史状态 $\text{CLIPScore}_{\text{hist}}$ 可通过训练早期的模型快照获取，例如在若干轮次的预热阶段结束后进行记录。该差分指标 δ 能够有效捕捉模型对不同样本的动态学习趋势，从而区分样本是处于被“遗忘”还是被“错误记忆”的过程。基于前文对记忆效应的分析，对于关联噪声样本，随着模型逐渐过拟合错误的语义关联，其当前预测得分 $\text{CLIPScore}_{\text{curr}}$ 相较于历史状态通常表现出显著增长，导致 δ 呈现较小数值甚至负值。相反，对于干净样本，由于模型在早期已充分学习其特征，随着后续对难样本和噪声的拟合，其相对得分往往保持稳定或出现轻微下降，即出现“遗忘”现象，从而产生较大的正向差分值。

与原始 CLIPScore 分布中干净与噪声样本严重重叠的现象不同，这种基于时间维度的差分指标 δ 在两类样本间构建了清晰且随训练进行不断扩大的判别边界。鉴于算法目标在于保留可能被遗忘的高质量干净样本，同时阻断对关联噪声的进一步学习，DISSect 采取了基于差分排序的采样策略。在每一轮训练迭代中，根据 δ 值对当前批次内的样本进行降序排列，并筛选出 δ 最大的前 r 比例样本参与参数更新，即构建筛选后的批次 $\mathcal{D}'_b(f,g) = \text{topk}_r(\delta)$，其中 r 为预设的选择比例。通过该机制，算法能够自适应地聚焦于对模型优化价值更高的样本，从而实现高效且鲁棒的对比学习。

5.2.3.2　理论分析

本节旨在深入分析 DISSect 算法能够有效鉴别关联噪声样本的理论依据。基于深度神经网络的记忆效应理论[13]，噪声数据在优化过程中对梯度的贡献呈现出显著的阶段性差异。本节合理地将讨论范围限定在干净关联样本占据主导或关联噪声样本不属于完全相同模式的训练数据集下（对于更高噪声率或噪声样本趋同的数据集，可以通过适当的数据预处理将过滤出质量较高的样本以符合此限定范围）。在此条件下，损失函数的梯度下降方向 $-\nabla\mathcal{L}$ 在训练初期主要由干净样本的梯度方向决定。在模型训练抵达早期学习阶段的转折点（Early-learning Point，记为 e）之前，大部分干净样本已被充分拟合，其对应的梯度模长趋近于零；与此同时，关联噪声尚未被模型记忆，仍产生较大的梯度值。随着训练进程的深入，过参数化的模型开始强行拟合噪声模式，最终导致所有样本的梯度均趋向于零。

为量化这一动态过程，本节定义数据集中干净数据对为 $\{x_1^i, x_2^i\}$，噪声数据对为 $\{\tilde{x}_1^i, \tilde{x}_2^i\}$。则模型整体训练过程可划分为以下三个阶段：

- *早期学习阶段 ($t < e$)*：此时梯度 $-\nabla\mathcal{L}(\theta_1^t, \theta_2^t)$ 与干净样本的优化方向高度一致。至 $t = e$ 时刻，模型对干净样本的学习程度显著优于噪声样本。
- *中期转折阶段 ($t = e$)*：干净样本的梯度分量 $\frac{\partial\mathcal{L}}{\partial\langle x_1^i, x_2^i\rangle}$ 逐渐衰减并趋近于零，而噪声样本的梯度分量 $\frac{\partial\mathcal{L}}{\partial\langle \tilde{x}_1^i, \tilde{x}_2^i\rangle}$ 仍维持较大数值。此时，整体梯度方向开始与干净样本的优化方向正交，模型开始利用剩余的参数容量记忆噪声。
- *后期拟合阶段 ($t > e \to T$)*：模型逐渐完成对所有样本的记忆，导致包括噪声样本在内的所有梯度分量 $\frac{\partial\mathcal{L}}{\partial\langle x_1^i, x_2^i\rangle}$ 均收敛至零。

基于上述阶段性特征，通过分析对比损失函数相对于相似度分数的偏导数，可以证明 CLIPScore 的时序差分本质上反映了训练过程中的梯度演变趋势。基于公式 5.1 所定义的 InfoNCE 损失函数 $\mathcal{L}_{f\to g}$，其关于相似度得分 $\langle x_1^i, x_2^i\rangle$ 的偏导数推导如下：

$$\begin{aligned}\frac{\partial\mathcal{L}_{f\to g}}{\partial\langle x_1^i, x_2^i\rangle} &= \frac{\partial}{\partial\langle x_1^i, x_2^i\rangle}\left(-\frac{1}{|\mathcal{D}_b|}\sum_{k=1}^{|\mathcal{D}_b|}\log\frac{\exp\left(\langle x_1^k, x_2^k\rangle/\tau\right)}{\sum_{j=1}^{|\mathcal{D}_b|}\exp\left(\langle x_1^k, x_2^j\rangle/\tau\right)}\right)\\ &\propto \frac{1}{|\mathcal{D}_b|}\sum_{i=1}^{|\mathcal{D}_b|}\left(1-\frac{\exp\left(\langle x_1^i, x_2^i\rangle/\tau\right)}{\sum_{j=1}^{|\mathcal{D}_b|}\exp\left(\langle x_1^i, x_2^j\rangle/\tau\right)}\right)\end{aligned} \tag{5.4}$$

在训练的早期阶段，鉴于正样本对已被较好地学习并与负样本拉开距离，CLIPScore 根据定义 $w\cdot\max(\langle x_1^i, x_2^i\rangle, 0)$ 恒大于 0，即可视为等同于 $w\cdot\langle x_1^i, x_2^i\rangle$。假设负样本对的相似度总和在 $t\in[e,T]$ 区间内保持相对稳定，即 $\sum_{j\neq i}^{|\mathcal{D}_b|}\exp\left(\langle x_1^i, x_2^j\rangle/\tau\right)\approx C$。据

此，对比损失相对于相似度的偏梯度与 CLIPScore 的指数项呈现负相关关系：

$$\begin{aligned}\frac{\partial \mathcal{L}_{f\to g}}{\partial\langle x_1^i, x_2^i\rangle} &\approx \frac{1}{|\mathcal{D}_b|}\sum_{i=1}^{|\mathcal{D}_b|}\frac{C}{\exp\left(\langle x_1^i, x_2^i\rangle/\tau\right)+C} \\ &\propto \frac{1}{|\mathcal{D}_b|}\sum_{i=1}^{|\mathcal{D}_b|}\exp\left(\text{CLIPScore}\right)^{-1}\end{aligned} \tag{5.5}$$

上述推导揭示了 CLIPScore 的倒数不仅衡量了样本的拟合程度，更直接表征了梯度的幅值。进一步地，通过计算早期学习点 $t = e$ 与当前时刻 $t = T$ 之间的梯度差值，可量化该阶段内的梯度变化动态：

$$\begin{aligned}\Delta\text{Grad}_{e\to T} &= \left.\frac{\partial \mathcal{L}}{\partial\langle x_1^i, x_2^i\rangle}\right|_{t=e} - \left.\frac{\partial \mathcal{L}}{\partial\langle x_1^i, x_2^i\rangle}\right|_{t=T} \\ &\approx \frac{k}{|\mathcal{D}_b|}\sum_{i=1}^{|\mathcal{D}_b|}\left(\exp(\text{CLIPScore}[e])^{-1} - \exp(\text{CLIPScore}[T])^{-1}\right)\end{aligned} \tag{5.6}$$

其中 k 为负相关系数。公式 5.6 从理论上建立了 CLIPScore 的时序差分 δ 与梯度变化趋势之间的内在映射。对于干净样本，由于其特征模式在 $t = e$ 时已被学习，其梯度在此区间内始终维持在接近零的水平，梯度变化量极小，导致 δ 表现为数值较小的波动或正向偏移（对应遗忘现象）。相反，对于噪声样本，其在 $t = e$ 时尚未被记忆，梯度值较大，而在 $t = T$ 时被错误记忆导致梯度趋零，因此产生了显著的梯度下降。这导致噪声样本的 CLIPScore 在该阶段显著攀升，从而产生较小甚至负值的差分 δ（对应记忆现象）。综上所述，DISSect 正是利用了 CLIPScore 差分所捕捉到的这种梯度动力学差异，实现了对关联噪声样本的精准识别与高效过滤。

5.2.3.3　历史状态的自适应估计

前节所述的固定预热策略虽然能够捕捉早期学习特征，但其依赖于先验经验来划定早期学习阶段的截止轮次，在一定程度上限制了算法的灵活性。为进一步降低模型对超参数设定的依赖并增强方法的自适应性，本文引入时间集成技术[246]，实现对历史状态 $\text{CLIPScore}_{\text{hist}}$ 的动态平滑估计。具体而言，第 t 轮的历史状态通过如下动量更新机制进行迭代演化：

$$\text{CLIPScore}_{\text{hist}}^{[t]} = \beta\cdot\text{CLIPScore}_{\text{hist}}^{[t-1]} + (1-\beta)\cdot\text{CLIPScore}_{\text{curr}}^{[t]} \tag{5.7}$$

其中 $\beta \in (0, 1)$ 为控制历史信息保留程度的动量参数。实验结果证实，该时间集成策略不仅能够取得与固定预热策略相当的检索性能，且模型对动量参数 β 的变化表现

算法 5.1 基于预热策略的 DISSect 算法流程

Input: 数据集 $\mathcal{D}$，热身轮数 T_w，选择比例 r。

for 训练轮次 $t = 1, 2, \ldots, T_w$ **do**
    基于公式 5.1计算损失并优化编码器 $f_{\theta_1}, g_{\theta_2}$。
基于公式 5.2预测并记录历史状态 $\text{CLIPScore}_{\text{hist}}$。
for 训练轮次 $t = T_w, \ldots, T$ **do**
    for 单一批次 $\mathcal{D}_b \sim \mathcal{D}$ **do**
        前向传播获取特征 x_1, x_2；
        基于公式 5.2预测当前状态 $\text{CLIPScore}_{\text{curr}}$；
        基于公式 5.3计算差分分数 δ；
        根据 $\text{topk}_r\delta$ 策略从 $\mathcal{D}_b$ 中筛选子批次 $\mathcal{D}'_b$；
        在 $\mathcal{D}'_b$ 上计算公式 5.1所示损失，并进行反向传播优化。

Output: 预训练加速后的编码器 $f_{\theta_1}, g_{\theta_2}$。

出较低的敏感度，具备优异的参数鲁棒性。为清晰展示两种策略的实现细节，基于固定预热策略与基于时间集成策略的 DISSect 算法流程分别详细描述于算法 5.1 与算法 5.2 中。

5.2.4　讨论与分析

本节旨在阐明 DISSect 方法的设计理念及其在多模态对比学习中的独特优势。本文提出的 DISSect 方法通过构建高效的动态样本筛选机制，致力于在训练批次内部实时识别并筛除关联噪声数据。基于对深度神经网络训练动力学的深入洞察，该方法利用 CLIPScore 的时序差分特征有效量化了样本的潜在质量与学习价值。相较于现有的样本选择策略，DISSect 的核心优势在于其完全摒弃了对昂贵外部参考模型的依赖，在显著降低计算资源消耗的同时实现了训练过程的加速。此外，与 ELR[13] 等通过修正优化目标或损失函数来应对噪声标签的学习方法不同，DISSect 侧重于从数据输入层面直接挑选训练样本以解决关联噪声问题。实证结果表明，通过这种高效的样本选择策略，该方法在确保模型性能不逊于全量数据训练的前提下，提供了更为显著的训练加速效果，实现了算法鲁棒性与计算效率的协同提升。

算法 5.2 基于时间集成策略的 DISSect 算法流程

Input: 数据集 $\mathcal{D}$，动量参数 β，选择比例 r。

初始化 $\text{CLIPScore}_{\text{hist}}$ 为字典结构以存储历史状态。
for 训练轮次 $t = 1, \ldots, T$ **do**
  for 单一批次 $\mathcal{D}_b \sim \mathcal{D}$ **do**
    前向传播获取特征 x_1, x_2；
    检索字典获取当前批次样本的历史状态 $\text{CLIPScore}_{\text{hist}}$；
    基于公式 (5.2) 预测当前状态 $\text{CLIPScore}_{\text{curr}}$；
    基于公式 (5.3) 计算差分分数 δ；
    基于公式 (5.4) 更新历史状态 $\text{CLIPScore}_{\text{hist}}$；
    根据 $\text{topk}_r\delta$ 策略从 $\mathcal{D}_b$ 中筛选子批次 $\mathcal{D}'_b$；
    在 $\mathcal{D}'_b$ 上计算公式 (5.1) 所示损失，并进行反向传播优化。

Output: 预训练加速后的编码器 $f_{\theta_1}, g_{\theta_2}$。

5.3 实验验证

5.3.1 实验设定介绍

5.3.1.1 数据集与评价指标

为全面评估算法在不同数据规模与噪声分布下的性能及泛化能力，实验选取了三个广泛使用的视觉-语言预训练数据集，分别为 CC3M[94]、CC12M[95] 以及 YFCC15M[150]。

- **CC3M**：该数据集包含约 330 万个经过严格过滤与清洗的高质量图文对，因其相对可靠的数据质量，常被作为多模态预训练的标准基准。
- **CC12M**：该数据集包含约 1200 万个图文对，相较于 CC3M 采用了更为松散的收集策略，因而涵盖了更多样化的视觉概念，但也引入了更高比例的关联噪声。
- **YFCC15M**：该数据集包含从 YFCC100M 中筛选出的 1500 万张图像及其对应的英文描述子集。由于直接源自 Flickr 用户的原始上传数据且未经过深度清洗，该数据集具有极高的噪声率与复杂的数据分布，能够有效检验算法在真实大规模噪声场景下的鲁棒性。

为验证预训练模型在不同下游任务中的迁移泛化能力，实验在多个经典的跨模态任务上进行了零样本或微调评估，涵盖图文检索、视频文本检索、视觉推理以及图像描述生成。

- **图文检索任务**：采用 MS-COCO[219] 和 Flickr30K[217] 作为评估基准。评价指标采用标准的 Top-K 召回率（Recall@K, K=1, 10），分别计算图像检索文本（TR）与文本检索图像（IR）的召回率，并报告其总和（Recall Sum）以衡量整体性能。
- **视频文本检索任务**：与第三章一致，本章选取 MSR-VTT[221] 与 MSVD[222] 两个

广泛应用的视频检索基准数据集进行评估。评价指标同样采用 Top-K 召回率。实验还报告了中位排名（Median Rank, MdR）与平均排名（Mean Rank, MnR），这两个指标数值越低代表模型排序越精准。

- **视觉推理任务**：基于 NLVR^2[247] 数据集进行评估。该任务旨在判断给定的自然语言描述与一对图像的视觉内容是否语义一致。评价指标为分类准确率。
- **图像描述生成任务**：基于 MS-COCO 数据集评估模型的生成性能。该任务要求模型依据输入图像生成相应的文本描述。评价指标采用自然语言生成领域的通用标准，包括 BLEU@4[248]、METEOR[249]、CIDEr[250]以及 SPICE[251]，以综合衡量生成文本的质量与多样性。

5.3.1.2　实验实施细节

本章算法基于 PyTorch 深度学习框架[252] 实现，所有大规模预训练实验均在搭载 8 块 NVIDIA A100 GPU（80GB 显存）的高性能计算节点上并行开展。除特殊说明外，实验默认采用 CLIP-ResNet50 架构作为视觉-语言预训练的主干网络，训练策略严格遵循 OpenCLIP[237,253] 的推荐配置以确保对比实验的公平性。单 GPU 批次大小设定为 1024，并利用数据并行技术加速训练。针对不同规模的数据集，训练轮次设定有所差异：CC3M 数据集训练 40 轮，而规模更大的 CC12M 和 YFCC15M 数据集则训练 20 轮。

模型参数更新采用 AdamW 优化器[254]，并配合余弦退火学习率调度策略以优化收敛过程。数据预处理阶段，输入图像经随机裁剪后调整分辨率至 224×224 像素。针对下游任务的评估，CLIP 模型相关任务基于 LAION-AI 提供的 CLIP-Benchmark 框架[255] 进行测试，BLIP 架构相关任务则基于官方 BLIP 评估代码[91] 执行。这种标准化的评估流程确保了实验结果与现有最先进方法的可比性。

5.3.2　主要实验结果

5.3.2.1　在 CC3M 数据集上的预训练图文检索性能

下游图文检索任务的性能能够直接反映模型在特征空间中精准识别真实跨模态正样本对的能力，是衡量预训练模型泛化水平的关键指标。表 5.1 展示了使用不同样本选择方法在 CC3M 数据集上预训练 CLIP 模型，并在下游 MS-COCO 和 Flickr30K 数据集上进行零样本检索评估的对比结果。

实验数据表明，在较低的样本选择比例下，在线样本选择方法普遍优于离线核心集选择方法。这种性能优势主要归因于在线选择策略在训练过程中具有动态的数据

表 5.1　DISSect 与现有样本选择方法在 CC3M 数据集上预训练后，基于 30%、50% 和 70% 筛选比例下的零样本检索性能比较。表格的上半部分和下半部分分别记录了在 5K MS-COCO 和 1K Flickr30K 测试集上的结果。实验结果分别展示了不同方法的图像检索文本 Image Retrieval（IR）与文本检索图像 Text Retrieval（TR）召回率，R@K 为 Top-K 召回率评价指标，R@Sum 表示召回率总和。全量数据训练的结果显示为灰色，样本选择后的最佳结果以粗体标出。CLIPScore 和 CLIPLoss 均基于参考模型进行训练。

Table 5.1　Zero-shot retrieval performance comparison between DISSect and existing sample selection methods on the CC3M dataset under 30%, 50%, and 70% selection ratios. The upper and lower parts of the table report results on the 5K MS-COCO and 1K Flickr30K test sets, respectively. Image Retrieval (IR) and Text Retrieval (TR) recall rates are presented, with R@K denoting the Top-K recall metric and R@Sum representing the total recall. Results of full-data training are shown in gray, while the best results after selection are highlighted in bold. Both CLIPScore and CLIPLoss are trained based on an oracle model.

ZS MS-COCO (5K Test Set)		30% Selection Ratio				50% Selection Ratio				70% Selection Ratio			
Methods		IR@1	IR@10	TR@1	TR@10	IR@1	IR@10	TR@1	TR@10	IR@1	IR@10	TR@1	TR@10
Full Data	CLIP[237]					21.42	56.92	15.38	46.65				
Coreset Selection	Random	10.32	36.48	7.66	28.99	14.00	45.42	10.57	36.55	17.54	51.36	12.89	41.77
	Forgetting[164]	12.18	40.08	8.74	32.78	14.92	45.86	10.92	37.65	17.76	51.92	12.60	41.63
	CLIPScore[166]	18.88	52.50	13.51	42.65	22.54	58.14	15.88	47.28	**23.74**	59.74	16.51	48.36
	CLIPLoss[256]	19.26	53.02	13.41	42.53	21.86	58.26	15.75	46.97	23.40	**60.00**	16.66	48.41
Online Selection	Random	19.36	53.50	14.08	44.24	19.70	55.14	14.33	45.13	21.08	56.20	14.56	45.64
	Big Loss	15.54	48.50	11.56	39.70	18.14	51.74	13.06	41.91	20.04	55.46	14.17	44.42
	Small Loss	11.74	38.08	8.70	31.40	20.05	53.64	13.26	42.81	22.18	57.68	16.42	47.85
	CLIPScore*[166]	11.08	40.00	8.90	33.48	17.96	50.54	13.22	42.01	20.82	56.18	15.24	45.71
	DivBS[36]	19.26	53.70	13.93	43.93	18.76	53.79	14.19	45.25	20.21	54.56	14.90	45.64
	InfoBatch[35]	19.60	54.98	13.80	44.80	20.58	54.92	14.36	45.22	20.96	56.68	15.28	45.77
	SCAN[204]	19.30	53.90	14.20	44.92	20.64	56.40	15.27	46.54	21.44	56.40	15.42	47.09
Ours	DISSect-Mome.	20.62	55.20	15.63	47.63	22.60	57.94	**16.96**	**49.81**	22.46	58.66	**16.71**	49.38
	DISSect-Warmup	**21.34**	**56.40**	**15.90**	**47.95**	**23.58**	**58.44**	16.76	49.66	22.74	58.92	16.65	**49.70**

ZS Flickr30K (1K Test Set)		30% Selection Ratio				50% Selection Ratio				70% Selection Ratio			
Methods		IR@1	IR@10	TR@1	TR@10	IR@1	IR@10	TR@1	TR@10	IR@1	IR@10	TR@1	TR@10
Full Data	CLIP[237]					39.10	78.30	29.38	67.66				
Coreset Selection	Random	17.00	52.50	14.30	43.06	29.80	66.50	21.42	55.46	35.40	74.40	25.54	62.06
	Forgetting[164]	21.30	59.30	16.46	21.30	28.00	68.40	21.20	55.34	31.40	72.40	24.60	60.90
	CLIPScore[166]	33.40	74.90	25.50	62.54	39.50	77.00	30.18	65.98	41.70	**81.30**	31.68	69.02
	CLIPLoss[256]	34.10	72.30	26.48	60.68	39.60	77.60	29.38	66.20	**43.00**	81.10	32.12	68.74
Online Selection	Random	35.10	76.20	28.90	65.34	39.50	76.90	28.12	66.56	38.80	76.20	28.50	64.72
	Big Loss	28.00	72.10	21.64	58.98	33.90	74.30	25.92	61.90	37.10	75.10	27.44	63.12
	Small Loss	25.00	57.40	16.50	47.34	33.90	73.40	27.18	61.86	38.50	78.60	30.96	67.22
	CLIPScore*[166]	21.90	55.40	16.26	46.68	31.70	68.40	23.94	59.16	40.10	76.60	28.30	64.74
	DivBS[36]	35.60	73.00	26.72	64.92	36.20	77.20	27.52	66.78	36.60	77.20	28.20	67.20
	InfoBatch[35]	36.90	76.20	26.82	65.20	37.00	75.30	28.20	65.12	37.80	76.50	29.14	66.90
	SCAN[204]	36.50	75.40	26.70	64.80	38.30	76.20	28.68	65.92	38.50	78.40	29.68	66.98
Ours	DISSect-Mome.	37.10	**76.70**	29.80	**68.01**	**42.70**	78.10	30.92	**70.28**	39.00	78.80	**32.73**	69.20
	DISSect-Warmup	**40.50**	76.00	**30.40**	67.72	39.40	**79.20**	**32.52**	69.98	40.60	80.00	32.58	**70.70**

覆盖能力，使得模型能够接触到比静态子集更为广泛的数据分布。因此，随机在线选择凭借其与原始数据集分布的统计一致性，构建了具有竞争力的性能基线。随着样本选择比例的提升，引入参考模型辅助的 CLIPScore 和 CLIPLoss 方法逐渐展现出优

势，性能超越了随机在线选择。这一现象揭示了在保留更多样本的设定下，单纯增加数据吞吐量已不足以持续提升模型性能，精准筛除关联噪声样本对于优化表征质量至关重要。

本章提出的 DISSect 方法在所有设定的选择比例下均取得了一致的最优性能，显著超越了包括依赖外部参考模型在内的所有基线方法，充分验证了基于差分信息的筛选策略的有效性。实验结果显示，DISSect 在仅使用 30% 训练数据的情况下，其检索性能已能与全量数据训练相媲美，甚至在部分指标上实现了超越，体现了极高的数据利用效率。此外，对比 DISSect 的两种实现变体，基于预热策略的 DISSect-Warmup 在绝对性能上略优于基于时间集成策略的 DISSect-Mome.，而后者则在超参数的精简性与配置便捷性上更具优势。

5.3.2.2　在大规模数据集上的预训练效果分析

为验证 DISSect 方法在大规模预训练场景下的泛化能力与训练效率，本节实验将预训练数据集扩展至千万量级的 CC12M 与 YFCC15M。其中，CC12M 数据集包含约 1200 万个经过初步筛选的图文样本，数据质量相对较高但采集策略较为宽松；YFCC15M 则是从 YFCC100M 中选取的 1500 万样本子集，包含大量未经人工清洗的原始数据，旨在模拟真实世界中高噪声、大规模的复杂数据分布。实验设定样本选择比例为 50%，主要评估模型在下游 MS-COCO 与 Flickr30K 数据集上的零样本检索性能，具体定量结果汇总于表 5.2。

实验结果表明，DISSect 方法在两个大规模数据集上均取得了优异的性能表现。在数据质量相对较好的 CC12M 数据集上，DISSect 不仅显著优于随机采样策略与主要对比方法 SCAN，还在各项关键检索指标上逼近甚至部分超越了全量数据训练的基准，如 MS-COCO 的 IR@1 指标。这一现象揭示了大规模数据集中存在信息冗余性，表明通过 DISSect 筛选出的高价值样本子集足以支撑模型学习到鲁棒的特征表示，从而在节省约 50% 计算开销的前提下保持了具有竞争力的模型性能。

在噪声比例极高的 YFCC15M 数据集上，DISSect 带来的性能增益更为显著。如表 5.2 所示，仅利用 50% 数据量训练的 DISSect 模型，其零样本检索性能反而显著优于使用全量 1500 万数据训练的模型。具体而言，在 MS-COCO 测试集上，DISSect 的召回率总和达到 167.79，相较于全量数据训练的 162.43 提升了 5.36；在 Flickr30K 测试集上，DISSect 同样取得了 243.68 的成绩，大幅超越全量数据的 229.70。这一结果有力地证实了在极高关联噪声场景下，单纯增加数据规模并不能保证性能提升，过多的关联噪声反而会破坏特征空间的几何结构。DISSect 通过基于差分信息的动态筛选

表 5.2　DISSect 与现有样本选择方法在 CC12M 和 YFCC15M 数据集上预训练后，基于 50% 筛选比例的零样本检索性能比较。表格的上半部分和下半部分分别记录了在 5K MS-COCO 和 1K Flickr30K 测试集上的结果。实验结果分别展示了不同方法的图像检索文本 Image Retrieval（IR）与文本检索图像 Text Retrieval（TR）召回率，R@K 为 Top-K 召回率评价指标，R@Sum 表示召回率总和。全量数据训练的结果显示为灰色，样本选择后的最佳结果以粗体标出。

Table 5.2　Zero-shot retrieval performance comparison between DISSect and existing sample selection methods on the CC12M and YFCC15M dataset under 50% selection ratios. The upper and lower parts of the table report results on the 5K MS-COCO and 1K Flickr30K test sets, respectively. Image Retrieval (IR) and Text Retrieval (TR) recall rates are presented, with R@K denoting the Top-K recall metric and R@Sum representing the total recall. Results of full-data training are shown in gray, while the best results after selection are highlighted in bold.

Datasets	Methods	IR@1	IR@10	TR@1	TR@10	R@Sum
Train: 50% Selection Ratio, Eval: MS-COCO (5K Test Set)						
CC12M	Full Data	33.40	71.88	23.49	59.39	188.16
	Random	32.56	69.60	20.52	56.11	178.79
	SCAN	33.50	71.04	22.10	58.10	184.74
	DISSect	**34.10**	**71.94**	**22.52**	**59.05**	**187.61**
YFCC15M	Full Data	28.24	65.42	18.03	50.74	162.43
	Random	29.04	66.44	17.98	51.52	164.98
	SCAN	28.06	65.10	17.27	50.66	161.09
	DISSect	**30.16**	**67.80**	**18.05**	**51.78**	**167.79**
Train: 50% Selection Ratio, Eval: Flickr30K (1K Test Set)						
CC12M	Full Data	57.50	89.70	44.28	81.58	273.06
	Random	54.30	86.70	40.66	78.00	259.66
	SCAN	55.40	87.00	42.68	79.38	264.46
	DISSect	**56.30**	**87.10**	**43.94**	**80.18**	**267.52**
YFCC15M	Full Data	46.30	86.10	30.26	67.04	229.70
	Random	48.00	85.50	31.48	68.72	233.70
	SCAN	49.10	86.90	31.90	70.98	238.88
	DISSect	**50.90**	**87.50**	**33.82**	**71.46**	**243.68**

机制，有效地识别并筛除了由于语义错配导致的无效样本，在大幅降低训练成本的同时显著提升了模型的表征能力，充分验证了该方法在处理真实世界大规模关联噪声数据时的有效性与鲁棒性。

5.3.2.3　在视频-文本检索任务上的泛化性能分析

为进一步验证 DISSect 算法在多模态领域的泛化能力，本节将实验场景从静态图像-文本检索拓展至动态视频-文本检索任务。实验选用 MSR-VTT 与 MSVD 两个主流视频检索基准数据集，并参照 CLIP4Clip 的实验配置，在引入 20% 与 40% 仿真关联噪声的条件下开展零样本视频检索测试。本节选取在图像任务中表现优异的 InfoBatch

表 5.3　DISSect 与现有最优样本选择算法在 MSR-VTT 与 MSVD 数据集上的视频检索性能比较。实验结果分别展示了不同方法的视频检索召回率，R@K 为 Top-K 召回率评价指标，还展示了 MdR 中位排名与 MnR 平均排名评价指标。

Table 5.3　Comparison of video retrieval performance between DISSect and sample selection algorithm InfoBatch on MSR-VTT and MSVD datasets. The experimental results respectively present the video retrieval recall rates of different methods, where R@K is the Top-K recall rate evaluation metric. Additionally, the MdR median rank and MnR average rank evaluation metrics are also shown.

Datasets	Noise	Methods	R@1↑	R@5↑	R@10↑	MdR↓	MnR↓
MSR-VTT	20%	InfoBatch	37.20	62.00	72.70	3.00	23.00
		DISSect	**40.80**	**67.90**	**77.90**	**2.00**	**16.60**
	40%	InfoBatch	28.60	54.50	64.30	4.00	33.80
		DISSect	**39.50**	**67.00**	**77.70**	**2.00**	**16.60**
MSVD	20%	InfoBatch	41.70	71.60	81.30	2.00	13.00
		DISSect	**45.20**	**74.40**	**83.40**	**2.00**	**10.90**
	40%	InfoBatch	36.30	65.90	75.90	3.00	19.70
		DISSect	**43.50**	**74.50**	**83.40**	**2.00**	**10.90**

作为基准方法进行对比，具体实验结果汇总于表5.3。

实验数据表明，DISSect 在视频-文本检索任务中依然保持了显著的性能优势。在 MSR-VTT 与 MSVD 数据集上，该方法在各项召回率指标上均优于 InfoBatch。特别是在高噪声率场景下，DISSect 展现出了更优的抗噪鲁棒性。例如，在 MSR-VTT 数据集存在 40% 关联噪声时，DISSect 将 R@1 指标从 InfoBatch 的 28.60% 提升至 39.50%，实现了 10.9% 的性能增益；在 MSVD 数据集的同等噪声条件下，R@1 指标亦提升了 7.2%。此外，在衡量整体排序质量的 MdR 与 MnR 指标上，DISSect 同样取得了更低的数值，表明该方法能够更准确地将关联的视频样本排在检索列表前列。

上述结果验证了基于差分信息的样本选择机制具有良好的跨模态泛化性。通过捕捉模型训练过程中对样本拟合状态的动态变化，DISSect 不仅能够有效识别图像模态中的关联噪声，同样能够适应视频模态的训练特性，通过精准筛除噪声样本提升模型在复杂多模态场景下的表征学习能力。

5.3.2.4　其他下游任务的性能对比

为进一步探究 DISSect 算法在更广泛多模态任务中的泛化边界，本节将评估范围从判别式的跨模态检索扩展至更具挑战性的视觉推理与图像描述生成任务。具体而言，实验分别选用 NLVR^2 数据集与 MS-COCO 数据集来考察模型在自然语言视觉推理及图像描述生成方面的性能。这两类任务要求模型具备更深层次的跨模态语义理

表 5.4　DISSect 与不同样本选择算法在 CC3M 数据集上预训练后，在 NLVR^2 数据集上视觉推理与 MS-COCO 数据集上图像描述生成的性能比较。全量数据训练的结果以灰色显示，最佳样本选择结果通过加粗标记。

Table 5.4　Performance comparison of visual reasoning on NLVR^2 and image captioning on MS-COCO for models pre-trained on the CC3M dataset using DISSect and various sample selection algorithms. Results obtained using the full dataset are shown in gray, while the best results among sample selection methods are highlighted in bold.

Methods	NLVR^2 Reasoning		COCO Captioning			
	dev	test-P	B@4	METEOR	CIDEr	SPICE
Train: 50% Selection Ratio on BLIP-Base						
Full Data	76.09	76.44	37.11	29.49	123.36	22.52
Random	68.46	68.85	36.04	28.58	119.65	21.74
SCAN	72.19	72.59	36.04	29.02	120.44	22.07
DISSect	**73.99**	**75.07**	**37.16**	**29.37**	**123.91**	**22.46**

解与生成能力。实验基于 BLIP[91] 架构进行，该模型通过优化图像描述损失进行训练，在多模态生成式任务中具有显著的代表性。

如表 5.4 所示，在视觉推理任务中，NLVR^2 要求模型依据图像对来判别自然语言描述的真伪。在 50% 的采样比例设定下，DISSect 在开发集（即表格中 dev）和测试集（即表格中 test-P）上均取得了显著优于随机采样与 SCAN 方法的性能表现。特别是在 test-P 测试集上，DISSect 达到了 75.07% 的准确率，逼近全量数据训练的 76.44%。该结果表明，通过差分信息筛选出的高价值样本足以支撑模型构建复杂的逻辑推理能力，并未因数据规模的缩减而导致表征能力的显著缺失。

在图像描述生成任务中，模型需将视觉信息转化为连贯且准确的文本描述。实验结果显示，DISSect 在 BLEU@4、METEOR、CIDEr 及 SPICE 等各项自然语言生成评价指标上全面超越了对比方法。值得注意的是，在衡量生成文本与参考文本相似度的 BLEU@4 和 CIDEr 指标上，DISSect 的性能甚至微弱优于全量数据训练的结果。这一现象表明，原始大规模数据集中存在的关联噪声可能对生成模型的语言建模产生干扰，而 DISSect 有效过滤了这部分低质量样本，有助于提升生成文本的质量与准确性。综上，DISSect 不仅适用于 CLIP 等双塔检索模型，同样能够有效迁移至生成式的 BLIP 架构，在大幅降低训练成本的同时，依然保持了模型在复杂下游任务中的鲁棒性与高性能。

表 5.5　DISSect 方法在 MS-COCO 数据集上的稳定性分析。表中展示了三次独立重复实验的平均值与标准差。实验结果分别展示了不同方法的图像检索文本 Image Retrieval（IR）与文本检索图像 Text Retrieval（TR）召回率，R@K 为 Top-K 召回率评价指标，R@Sum 表示召回率总和。
Table 5.5　Stability analysis of the DISSect method on the MS-COCO dataset. The table reports the mean and standard deviation of three independent experiments. Image Retrieval (IR) and Text Retrieval (TR) recall rates are presented, with R@K denoting the Top-K recall metric.

Datasets	Eval: MS-COCO (5K Test Set)				Eval: Flickr30K (1K Test Set)			
Methods	IR@1	IR@10	TR@1	TR@10	IR@1	IR@10	TR@1	TR@10
SCAN	20.64	56.40	15.27	46.54	38.30	76.20	28.68	65.92
Mome.	22.39 ±0.35	58.01 ±0.56	16.64 ±0.27	49.34 ±0.41	**42.33** ±0.55	78.17 ±0.21	30.16 ±0.36	69.53 ±0.65
Warmup	**22.75** ±0.55	**58.49** ±0.22	**16.85** ±0.08	**49.61** ±0.08	41.50 ±0.90	**79.07** ±0.23	**32.39** ±0.21	**70.27** ±0.37

5.3.2.5　方法稳定性分析

为验证 DISSect 算法在随机初始化设定下的训练稳定性，本节在 MS-COCO 与 Flickr30K 数据集上开展了独立重复实验。相关实验结果如表 5.5 所示，其中汇总了三次实验的平均检索性能与标准差，并选取 SCAN 方法作为基准进行对比。

实验统计数据表明，DISSect 基于动量更新与基于预热策略的两种变体在各项检索指标上均表现出较低的性能波动。具体而言，在 MS-COCO 数据集上，预热策略版本的 IR@1 平均召回率达到 22.75%，标准差仅为 0.55%；在 Flickr30K 数据集上，TR@1 与 TR@10 等关键指标的标准差更是低于 0.21%。这种低方差特性表明该算法对随机种子初始化不敏感，具备良好的收敛稳定性。与基准方法相比，即便考虑实验结果的随机波动范围，DISSect 的性能下界仍显著优于 SCAN 方法的固定结果。以 Flickr30K 的 IR@1 指标为例，动量更新版本的平均性能为 42.33%，明显高于 SCAN 的 38.30%。上述结果证实，利用差分信息挖掘高质量样本的机制不仅实现了训练加速，更能在复杂的训练动态中维持模型性能的稳健性，有效规避了传统在线采样策略可能引发的优化震荡。

5.3.3　消融实验结果

5.3.3.1　基于不同骨干网络的适应性分析

本节旨在验证 DISSect 算法在不同视觉-语言预训练骨干网络中的泛化能力与架构适应性。在前文基于 CLIP-ResNet50 架构的实验基础上，进一步将实验范围扩展至基于卷积神经网络的 CLIP-ResNet101 以及基于 Transformer 架构的 BLIP-ViT-B 模型。

表 5.6　DISSect 与不同样本选择算法基于 CLIP/ResNet101 和 BLIP/ViT-B 主干网络的零样本检索性能比较。实验结果分别展示了不同方法的图像检索文本 Image Retrieval（IR）与文本检索图像 Text Retrieval（TR）召回率，R@K 为 Top-K 召回率评价指标，R@Sum 表示召回率总和。全量数据训练的结果显示为灰色，样本选择后的最佳结果以粗体标出。

Table 5.6　Comparison of zero-shot retrieval performance between DISSect and various sample selection algorithms based on CLIP/ResNet101 and BLIP/ViT-B backbones. Image Retrieval (IR) and Text Retrieval (TR) recall rates are presented, with R@K denoting the Top-K recall metric and R@Sum representing the total recall. Results of full-data training are shown in gray, while the best results after selection are highlighted in bold.

Backbones	Methods	IR@1	IR@10	TR@1	TR@10	R@Sum
Train: 50% Selection Ratio, Eval: MS-COCO (5K Test Set)						
CLIP/ ResNet101	Full Data	23.20	60.22	17.05	49.55	150.02
	Random	20.74	57.26	15.12	47.00	140.12
	SCAN	21.56	57.92	15.85	48.19	143.52
	DISSect	**23.54**	**59.86**	**16.87**	**49.91**	**150.18**
BLIP/ ViT-B	Full Data	38.48	73.74	30.15	64.83	207.20
	Random	36.88	71.20	28.98	63.70	200.76
	SCAN	37.44	72.24	28.86	63.70	202.24
	DISSect	**38.42**	**73.72**	**29.84**	**64.40**	**206.38**
Train: 50% Selection Ratio, Eval: Flickr30K (1K Test Set)						
CLIP/ ResNet101	Full Data	43.30	82.10	33.26	72.30	230.96
	Random	40.50	78.40	29.24	67.56	215.70
	SCAN	40.60	79.50	30.04	68.48	218.62
	DISSect	**41.00**	**79.40**	**32.30**	**71.16**	**223.86**
BLIP/ ViT-B	Full Data	69.80	94.20	54.62	85.10	303.72
	Random	62.20	92.20	50.18	84.56	289.14
	SCAN	63.30	92.60	50.92	84.42	291.24
	DISSect	**65.70**	**93.80**	**51.26**	**84.68**	**295.44**

针对 BLIP 模型，DISSect 策略利用其特有的图像-文本对齐模块计算差分分数以执行样本筛选，以此验证该方法对不同模型内部机制的适配能力。

实验结果如表5.6所示，DISSect 在不同架构下均展现出了优异的性能表现。在 50% 样本选择比例的设定下，无论采用 ResNet101 还是 ViT-B 作为骨干网络，DISSect 在 MS-COCO 与 Flickr30K 数据集上的零样本检索性能均优于随机采样与 SCAN 方法。具体分析数据可知，在 CLIP-ResNet101 架构下，DISSect 在 MS-COCO 测试集上的召回率总和达到 150.18，超越了全量数据训练的基准结果 150.02。而在 BLIP-ViT-B 架构下，DISSect 同样取得了逼近全量数据训练的性能表现，例如在 MS-COCO 上达到 206.38，与全量数据的 207.20 仅有细微差距，且显著优于 SCAN 方法的 202.24。

上述实验证实，DISSect 算法不仅适用于标准的 CLIP 双塔架构，同样能够有效

表 5.7　DISSect 算法与 InfoBatch 在仿真关联噪声数据集的零样本检索性能对比。实验结果分别展示了不同方法的图像检索文本 Image Retrieval（IR）与文本检索图像 Text Retrieval（TR）召回率，R@K 为 Top-K 召回率评价指标，R@Sum 表示召回率总和。

Table 5.7　Retrieval performance comparison between DISSect and InfoBatch on the NUS-WIDE dataset under different simulated noise rates. Image Retrieval (IR) and Text Retrieval (TR) recall rates are presented, with R@K denoting the Top-K recall metric and R@Sum representing the total recall.

Methods	IR@1	IR@10	TR@1	TR@10	IR@1	IR@10	TR@1	TR@10
Applied Backbone: SGR[2], Train & Eval Dataset: Flickr30K								
	Noise Ratio: 5%				Noise Ratio: 10%			
InfoBatch	73.80	96.00	56.08	87.90	72.90	95.90	52.06	87.04
DISSect	**74.70**	**97.20**	**57.24**	**88.84**	**73.70**	**96.90**	**55.78**	**88.98**
	Noise Ratio: 20%				Noise Ratio: 40%			
InfoBatch	71.90	95.10	51.10	83.44	68.70	93.10	48.88	75.54
DISSect	**74.60**	**96.00**	**55.16**	**85.98**	**69.90**	**94.30**	**52.34**	**84.88**

迁移至包含复杂交互机制的 BLIP 架构。这种跨架构的稳定性表明基于差分信息的样本选择机制能够敏锐捕捉不同模型训练动态中的共性特征，通过筛除关联噪声并保留高价值样本，在大幅降低训练成本的同时保障了模型在下游任务中的泛化能力。这一特性赋予了 DISSect 良好的扩展性，使其能够作为一种通用的加速模块集成到现有的多模态预训练框架中。

5.3.3.2　仿真噪声下的鲁棒性分析

为探究 DISSect 策略在不同关联噪声强度下的鲁棒性边界，本节在 Flickr30K 数据集上开展了对比实验。不同于前述基于大规模自然噪声数据集的预训练设定，本实验通过在干净数据集中注入 5% 至 40% 比例的对称关联噪声，构建了分布可控的噪声测试环境。实验选取了当前先进的在线样本选择方法 InfoBatch 作为基准进行对比，详细量化结果汇总于表 5.7。

实验数据表明，DISSect 在所有设定的关联噪声率下均展现出了优于 InfoBatch 的检索性能。在 5% 和 10% 的低噪声区间，该方法通过对样本价值的精准评估取得了稳定的性能增益。以 5% 关联噪声率为例，DISSect 的图像检索 R@1 达到 74.7%，超越基准方法 0.9%。随着关联噪声比例的提升，两种方法的性能差距呈现出扩大趋势。在 20% 关联噪声率设定下，DISSect 的图像检索 R@1 保持在 74.6%，而 InfoBatch 则下滑至 71.9%，差距扩大至 2.7%。即便在 40% 的高关联噪声场景下，本章提出的方法依然维持了较高的检索精度，其文本检索 R@1 达到 52.34%，显著优于基准方法的 48.88%。

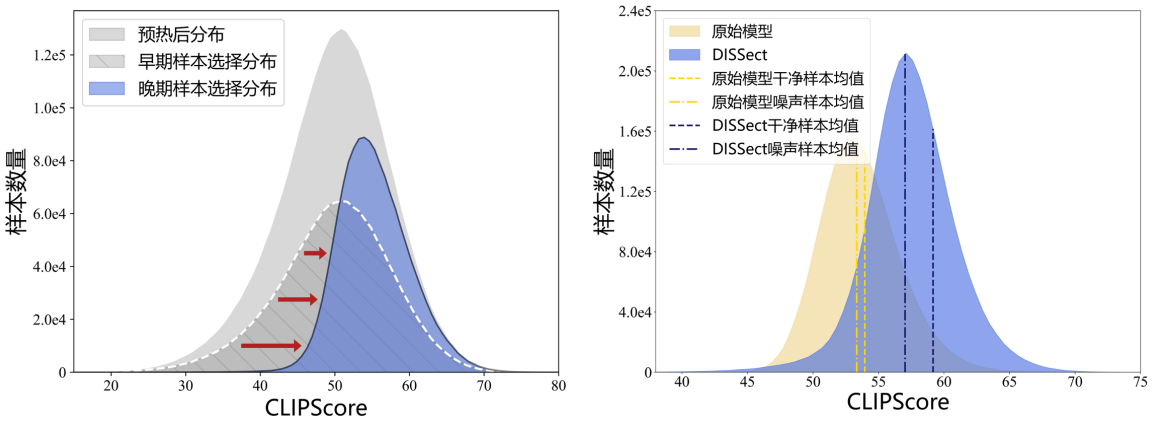

图 5.5　DISSect 算法的样本选择策略可视化。左图展示了 DISSect 在不同训练阶段所选数据的 CLIPScore 分布，DISSect 在训练初期均匀选择数据，在训练后期则选择干净数据学习。右图展示了与原始模型相比，DISSect 学习到了样本质量更高且更多样化的样本。

Figure 5.5　Visualization of the sample selection strategy in DISSect. Left: The CLIPScore distributions of samples selected by DISSect at different training stages; DISSect performs uniform selection in the early stage and transitions to selecting clean data in the late stage. Right: Comparison showing that DISSect learns from samples with higher quality and greater diversity than the baseline model.

上述现象反映了不同样本选择机制在应对关联噪声时的内在差异。InfoBatch 主要依赖损失分布或梯度范数进行剪裁，该策略在高关联噪声环境下易将高损失的噪声样本误判为高价值的难样本并加以保留，从而导致模型对关联噪声的过拟合。相比之下，DISSect 利用训练动态中的差分信息，捕捉了关联噪声样本在记忆阶段的异常增长趋势。通过动态筛除具有错误记忆特征的样本，该算法在加速训练的同时构建了有效的关联噪声抑制机制，验证了其在不同数据噪声分布环境下的适用性。

5.3.3.3　选择策略分析

为了揭示 DISSect 的采样机制及其对训练动态的影响，图 5.5 左图展示了不同训练阶段被选样本的 CLIPScore 分布相对于全量分布的演变轨迹。观察表明，该方法并未在全训练周期内单纯依赖高置信度的干净样本。训练初期，算法采用了近似随机采样的策略，使被选样本覆盖较宽的得分区间，从而接触多样化的数据模式。随训练深入，采样分布逐渐收敛至高 CLIPScore 区域，即逐步聚焦于更可靠的干净样本。此类动态收敛策略对多模态学习至关重要：早期的广泛采样允许模型在记忆效应发生前，充分学习数据集中丰富的视觉-语义概念，奠定泛化基础；后期的精准筛选则有效阻断了关联噪声的梯度回传，抑制模型对错误关联的过拟合。

图 5.5 右图进一步对比了 DISSect 与基准模型最终习得的 CLIPScore 分布特性。

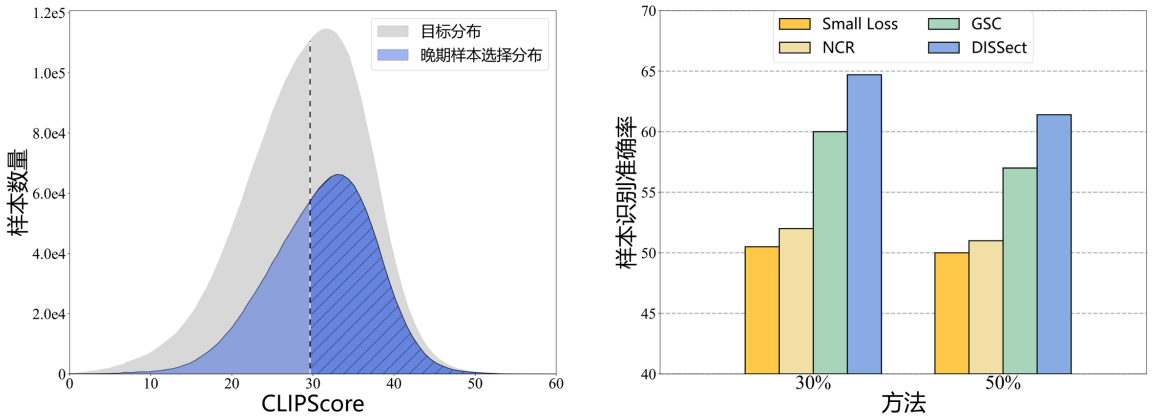

图 5.6　DISSect 算法的样本选择准确率可视化。左图展示了 DISSect 所选择样本的 CLIPScore 分布与参考模型分布比较结果。右图展示了不同关联噪声方法在不同噪声率下对干净样本的识别准确率。

Figure 5.6　Visualization of the sample selection accuracy of the DISSect algorithm. Left: Comparison between the CLIPScore distribution of samples selected by DISSect and the distribution from the reference model. Right: The identification accuracy of clean samples by different noisy correspondence methods under various noise rates.

相较于基准模型，DISSect 习得的相似度分布展现出更高的均值与更显著的区分度。定量分析显示，受关联噪声干扰，基准模型的干净数据与噪声数据在特征空间中分布重叠严重，均值差异仅为 0.65。相比之下，DISSect 显著扩大了两类数据的间距，将分布差异提升至 2.14。该分布分离现象证实，DISSect 能在特征空间中有效分离关联噪声与干净样本，构建出更鲁棒且结构清晰的跨模态表征。

5.3.3.4　与关联噪声方法的对比分析

为定量评估 DISSect 在关联噪声识别任务上的有效性，本节引入一种基于参考模型的评估指标进行定量分析。如图 5.6 左图所示，该指标利用在干净数据上预训练的参考模型作为基准，通过计算样本的 CLIPScore 分布以界定潜在的真实关联。具体而言，设定阈值 $\tau = 50\%$（如图中虚线所示）将参考模型评分空间划分为代表高质量关联的置信区与代表关联噪声的非置信区。对于任意样本选择算法筛选出的子集 $\mathcal{D}'$，其真阳性样本定义为筛选集中评分高于阈值 τ 的部分，计算公式如下：

$$TP = \{x \in \mathcal{D}' \mid S_{oracle}(x) > \tau\} \tag{5.8}$$

在此基础上，真阳性准确率定义为真阳性样本在筛选子集中的占比，即：

$$Accuracy = \frac{|TP|}{|\mathcal{D}'|} \tag{5.9}$$

表 5.8　DISSect 与不同关联噪声策略的零样本检索性能对比。实验展示了 DISSect 与关联噪声鲁棒算法在 CC3M 数据集上预训练后，在 MS-COCO 与 Flickr30K 上的零样本检索性能比较。实验结果分别展示了不同方法的图像检索文本 Image Retrieval（IR）与文本检索图像 Text Retrieval（TR）召回率，R@K 为 Top-K 召回率评价指标，R@Sum 表示召回率总和。

Table 5.8　Comparison of zero-shot retrieval performance between DISSect and various noisy correspondence strategies. This experiment presents the zero-shot retrieval performance comparison on the MS-COCO and Flickr30K datasets between DISSect and other robust noisy correspondence algorithms after pre-training on the CC3M dataset. The experimental results separately report the Image Retrieval (IR) and Text Retrieval (TR) recall rates for different methods, where R@K denotes the Top-K recall evaluation metric, and R@Sum represents the total sum of the recall rates.

Methods	Dual Net.	IR@1	IR@10	TR@1	TR@10	R@Sum
MS-COCO (5K Test Set)						
Small Loss	×	20.05	53.64	13.26	42.81	129.76
NCR[14]	✓	20.90	56.14	15.16	45.79	137.99
GSC[97]	✓	22.26	57.56	16.21	48.69	144.72
DISSect	×	**23.58**	**58.44**	**16.76**	**49.66**	**148.44**
Flickr30K (1K Test Set)						
Small Loss	×	33.90	73.40	27.18	61.86	196.34
NCR[14]	✓	**40.00**	77.20	30.46	68.28	215.94
GSC[97]	✓	39.50	**80.40**	29.18	67.30	216.38
DISSect	×	39.40	79.20	**32.52**	**69.98**	**221.10**

该指标直观量化了所选样本分布与真实干净样本分布的重合程度，即图中蓝色阴影区域（筛选分布）与虚线右侧区域（目标分布）的交集比例。实验结果显示，DISSect 在 30% 和 50% 的选择比例下鉴别准确率分别达到 65% 和 61%。如图 5.6 右图所示，这一结果优于传统的“小损失”策略，且超越了 NCR[14] 和 GSC[97] 等现有先进的关联噪声处理方法。结果表明，基于差分信息的动态筛选机制相较于单纯的损失值或几何一致性指标，能更有效地捕捉样本的学习趋势，从而实现对关联噪声的精准筛除。

此外，表 5.8 汇总了各方法在下游零样本检索任务上的性能表现。值得注意的是，为了缓解噪声干扰，NCR 和 GSC 等方法通常采用双网络架构，试图通过协同训练增强鲁棒性，但这不可避免地导致了计算资源消耗和训练时间的成倍增加。相比之下，DISSect 仅需维护单一网络架构，在显著降低计算开销的同时，取得了更优的检索性能。具体而言，在 MS-COCO 和 Flickr30K 数据集上，DISSect 的召回率总和分别达到 148.44% 和 221.10%，优于依赖双网络结构的基线方法。该结果证明了 DISSect 在保证高效性的前提下，通过高质量的样本筛选机制，实现了计算效率与抗噪鲁棒性的双重提升。

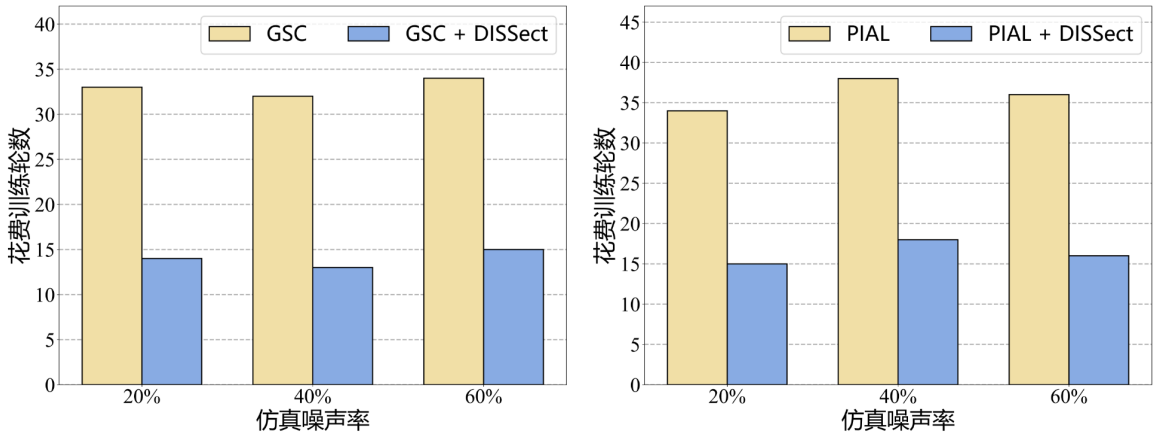

图 5.7　DISSect 应用于 GSC 与 PIAL 加速效果分析。左图：在 MS-COCO 数据集上不同噪声率下将 DISSect 应用于 GSC 花费训练轮数对比；右图：在 MS-COCO 数据集上不同噪声率下将 DISSect 应用于 PIAL 花费训练轮数对比

Figure 5.7　The analysis of the acceleration effect of DISSect on GSC and PIAL. Left figure: The comparison of the number of training rounds spent when applying DISSect to GSC at different noise rates on the MS-COCO dataset; Right figure: The comparison of the number of training rounds spent when applying DISSect to PIAL at different noise rates on the MS-COCO dataset.

5.3.3.5　DISSect 在现有鲁棒方法上的通用性与加速分析

前文提出的基于几何结构一致性的 GSC 方法与基于特权信息辅助的 PIAL 方法虽显著提升了模型在关联噪声场景下的抗噪性能，但其复杂的优化目标不可避免地引入了高昂的计算成本与漫长的收敛周期。为验证 DISSect 算法在不同鲁棒学习框架下的通用性与加速潜力，本实验将其分别集成至 GSC 与 PIAL 算法中，并在 MS-COCO 数据集上基于多种关联噪声环境展开对比分析。实验重点考察在达到相同收敛性能的前提下，集成样本选择策略前后模型所需训练轮数的差异，以此量化评估其对计算开销的节省效果。

如图 5.7 所示，在 20%、40% 及 60% 的仿真关联噪声设定下，集成 DISSect 后的 GSC 与 PIAL 方法均展现出显著的训练效率提升。原始 GSC 与 PIAL 方法通常需经历 30 至 38 个训练轮次，方能达到最优的噪声识别效果与特征对齐状态。而在引入 DISSect 进行动态样本筛选后，模型仅需约 13 至 18 个轮次即可完成收敛，平均训练时间缩短约 50% 至 60%。此加速效果归因于 DISSect 利用差分信息高效识别并筛除了由关联噪声引发的无效梯度更新，同时减少了模型在简单干净样本上的冗余计算。实验结果表明，DISSect 不仅具备独立的高效学习能力，更可作为通用的即插即用加速模块，无缝集成至现有的复杂鲁棒学习框架中，在维持模型去噪能力的同时大幅降

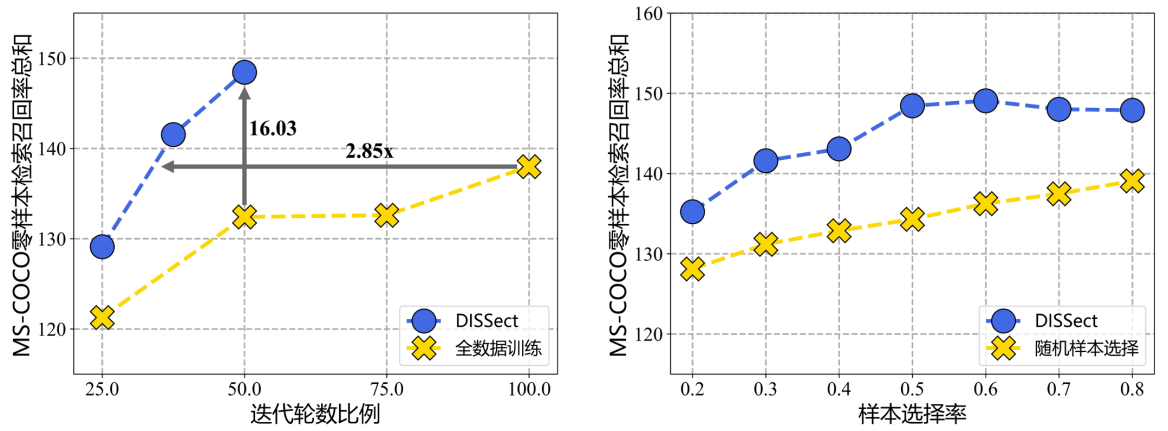

图 5.8　DISSect 在不同选择率下的性能分析。左图展示了在 MS-COCO 检索任务上与全量数据训练的训练效率对比。右图展示了在不同样本选择比例下，与随机采样相比的零样本召回率总和。两个实验均在 CC3M 数据集上进行预训练。

Figure 5.8　Performance analysis of DISSect under various selection ratios. The left subplot illustrates the training efficiency comparison against full-data training on the MS-COCO retrieval task. The right subplot presents the sum of zero-shot recall rates compared to random sampling across different sample selection ratios. Both experiments are conducted on the CC3M dataset.

低算法部署的算力门槛。

5.3.3.6　加速性能与计算开销分析

本节通过分析收敛曲线与实际物理运行时间，定量评估 DISSect 算法在训练加速收益与时间成本方面的表现。如图 5.8左图所示，DISSect 在 MS-COCO 零样本检索任务中表现出显著的收敛加速特性。具体而言，为达到全量数据训练的同等性能基准，该方法实现了约 2.85 倍的训练加速。若对比在相同迭代步数下的性能表现，DISSect 的召回率总和指标超越全量数据基线达 16.03%。实验结果表明，通过有效剔除冗余与关联噪声样本，算法能够引导模型聚焦于高价值数据的学习，从而显著提升优化效率。

表 5.9 进一步展示了模型在 CC3M 和 CC12M 数据集上训练至收敛所需的实际墙钟时间。相较于均匀采样，各类在线样本选择方法通常需要在每个训练批次中执行额外的前向传播以评估样本价值。虽然引入了额外的计算步骤，DISSect 的两种变体所增加的计算开销极低，在总训练时间上仍保持显著优势。此外，样本筛选阶段的前向传播过程可进一步通过低精度计算核心[257]或异步执行策略[198]进行优化，从而最大限度地降低额外开销对训练流水线的影响。

表 5.9　DISSect 算法在 CC3M 和 CC12M 数据集上的单 GPU 训练时间效率分析。实验统计了在 CC3M 和 CC12M 数据集上，不同方法在单 GPU 上的实际计算时间（↓）。“To Rand. Best” 指达到与随机采样相同性能所需的时间成本，同理，“To DISSect Best” 表示相对于全数据训练所节省的时间百分比。

Table 5.9　Wall-clock computation time (↓) of different methods training on single GPU on CC3M and CC12M datasets. “To Rand. Best” refers to the time cost to reach same performance as random sampling, as well as “To DISSect Best”. The subscript indicates the percentage of time saved compared to full data training.

Full Data Training	Selection Ratio	Random	DISSect	
		To Rand. Best	To Rand. Best	To DISSect Best
CC3M Dataset (40 epochs)				
58.3 h	30%	17.8 h $_{\downarrow 69\%}$	15.3 h $_{\downarrow 74\%}$	21.8 h $_{\downarrow 63\%}$
	50%	30.2 h $_{\downarrow 49\%}$	21.8 h $_{\downarrow 63\%}$	36.4 h $_{\downarrow 38\%}$
	70%	41.1 h $_{\downarrow 29\%}$	29.3 h $_{\downarrow 50\%}$	50.9 h $_{\downarrow 13\%}$
CC12M Dataset (20 epochs)				
116.1 h	30%	35.5 h $_{\downarrow 69\%}$	32.5 h $_{\downarrow 72\%}$	43.4 h $_{\downarrow 63\%}$
	50%	60.2 h $_{\downarrow 49\%}$	50.7 h $_{\downarrow 56\%}$	72.5 h $_{\downarrow 38\%}$
	70%	82.5 h $_{\downarrow 29\%}$	62.3 h $_{\downarrow 46\%}$	101.3 h $_{\downarrow 13\%}$

5.3.3.7　样本选择比例的消融实验

样本选择比例 r 作为平衡训练效率与信息保留量的核心超参数，直接决定了模型训练过程中的数据吞吐规模。图 5.8右图展示了在不同选择比例设定下，DISSect 算法的性能演变趋势。实验数据表明，在全测试区间内，DISSect 的检索性能均显著优于随机采样策略，这有力验证了基于差分信息的筛选机制在不同数据保留率下均具备优异的鲁棒性。在高选择比例区间（即保留超过 50% 数据），该方法表现出高度的稳定性，并在 60% 比例处达到性能峰值。这一现象揭示了原始数据集中普遍存在冗余或关联噪声样本，适度的样本裁剪不仅未损害模型表现，反而通过滤除干扰增强了模型的泛化能力。值得注意的是，即使在仅保留 30% 训练数据的低资源设定下，DISSect 依然取得了与全量数据训练相当的性能，充分证实了该方法在低数据预算场景下的训练高效性与应用价值。

5.3.3.8　超参数敏感性与训练稳定性分析

为全面评估 DISSect 算法在不同训练配置下的鲁棒性，本小节针对关键超参数进行了消融分析。如图 5.9左图所示，随着训练轮数从 20 增至 60，模型的检索召回率总和呈现持续上升趋势，表明该方法能有效利用长周期训练精细化特征对齐，且未出现因过拟合关联噪声而导致的性能退化。在批次大小方面，模型在 1024 时达到最优

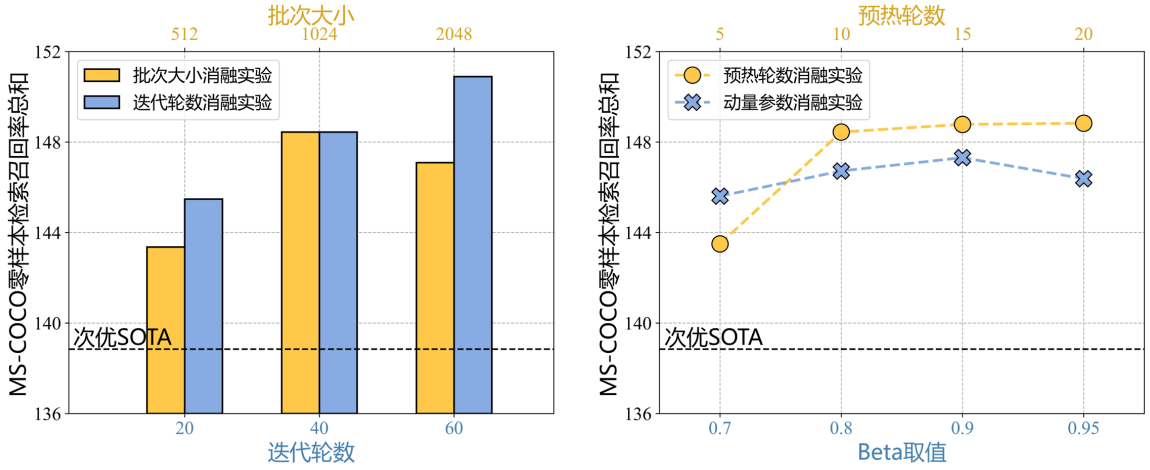

图 5.9　DISSect 对超参数的敏感性分析。左图展示了 DISSect 对不同批次大小的敏感度分析，右图则展示了 DISSect 对超参数 β 与预热轮次数的敏感度分析。

Figure 5.9　Sensitivity analysis of DISSect to hyper-parameters. The left figure shows the sensitivity analysis of DISSect to different batch sizes, and the right figure illustrates the sensitivity analysis of DISSect to the hyper-parameter β and the number of warm-up epochs.

性能；尽管较小的批次可能引入梯度估计方差，而过大的批次略微影响泛化能力，但 DISSect 在不同设置下均保持了超越次优基准方法的性能，体现了对硬件环境的良好适应性。

图 5.9右图进一步分析了算法内部超参数的敏感性。对于基于时间集成策略的变体，动量参数 β 取值为 0.9 时模型性能达到峰值。适度的 β 值有效平衡了历史信息的保留与当前状态的更新，构建了稳定的差分信号；过小或过大的取值则分别导致历史基准波动剧烈或更新滞后，干扰对关联噪声的精准判别。对于基于预热策略的变体，性能随预热轮数增加并在 15 轮左右趋于平稳，验证了训练初期建立相对干净收敛的历史参考状态对于准确计算差分分数 δ 的必要性。综合考虑计算效率与稳定性，本研究在通用场景下推荐采用 β 为 0.9 的动量更新策略。

5.3.3.9　DISSect 筛选样本的可视化分析

Conceptual Captions 数据集作为真实世界数据的典型代表，包含了约 3% 至 20% 的关联噪声样本。本章提出的 DISSect 方法在此类真实噪声场景下表现出显著的鲁棒性，前文定量实验已验证其对 CC3M、CC12M 预训练性能的提升。图 5.10 展示了 DISSect 在训练过程中识别并滤除的典型低质量样本。观察表明，这些被判定为噪声的图文对主要表现为完全或部分语义错配。

真实关联噪声的成因呈现多样化特征。部分噪声样本的图像与文本虽源自同一网

图 5.10　DISSect 算法识别的 CC152K 数据集关联噪声样本可视化。展示的 10 对关联噪声样本均为 DISSect 算法从原始数据集中识别的低质量样本，红色文本表示与图像内容不匹配的部分。
Figure 5.10　Visualization of noisy correspondence samples identified by the DISSect method on the CC152K dataset. The displayed 10 pairs are low-quality samples identified from the original dataset using the DISSect algorithm, where red text highlights the parts that do not match the image content.

页或新闻源，但文本未直接描述图像视觉内容，而是提供背景信息、情感表达或相关统计数据。例如，展示燃烧雨伞与人物的图像被配以关于 “Dante’s Inferno” 的文学引用；描绘沙漠油田的图像则对应关于巴林石油产量排名的陈述而非场景本身。另一类关联噪声源于数据集中为隐私保护而进行的脱敏处理，如文本中出现的“<PERSON>”标记破坏了原有指代关系，导致文本无法准确对应图像中的具体人物。此外，部分关联噪声源于细粒度的局部关联问题，即文本仅描述了图像中的次要细节（如仅描述沙丘上的 “Marram grass”），这种部分对应关系引入了语义歧义，导致同一文本可能对应多张图像。DISSect 通过捕捉训练动态中的差分信息，能够有效鉴别并过滤上述复杂的真实噪声，确保模型专注于高质量语义对齐的学习。

5.4　本章小结

本章针对多模态对比学习中普遍存在的关联噪声问题，提出了一种 DISSect 在线样本选择方法，旨在加速大规模多模态预训练进程。该方法揭示了过滤噪声样本对于提升对比学习效率的关键作用，并利用模型在当前与历史状态下预测相关性的差异，动态量化样本的干净程度。与依赖双网络结构导致计算成本显著增加的主流去噪方案不同，DISSect 能够在不引入外部参考模型的前提下，通过高效的在线批次选择策略实现对关联噪声的有效筛除。大量实验结果表明，该方法在保证模型性能优于当前最先进技术的同时，显著降低了计算资源消耗，验证了差分信息在样本筛选中的有效性与鲁棒性。

本章提出的加速策略不仅对于视觉-语言预训练具有重要的理论与应用价值，其核心思想同样适用于视频、音频以及医疗影像分析等广泛的多模态领域，能够有效缓解在真实世界大规模数据集上训练时面临的时间与算力约束。然而，当前的 DISSect 方法主要在双模态场景下进行实现与评估，这构成了本研究的一个主要局限。在更为复杂的真实应用中，数据往往涉及图像、文本、音频和视频等两种以上模态的交互，这不仅引入了更高维度的计算开销，也使得关联噪声的分布呈现出更加复杂和难以解耦的特性。

未来的研究工作可致力于将基于差分信息的筛选机制扩展至更多模态的复杂场景中，设计适应性更强的去噪策略以应对高维噪声挑战。同时，考虑到困难样本在训练早期对于模型收敛具有积极的加速作用，后续工作可尝试将困难样本挖掘与噪声过滤相结合，构建更加精细化的动态课程学习策略。针对在线选择范式所需的额外前向传播开销，未来的研究还可以结合底层的系统级优化技术，进一步挖掘算法的计算效率潜力，从而为多模态对比学习提供更为全面和高效的解决方案。

第 6 章 总结与展望

6.1 本文总结

近年来，得益于硬件算力规模的提升与模型参数量的持续增长，基于对比学习的多模态表征学习取得了长足的发展。然而，该范式对大规模高质量训练数据的高度依赖，与现实场景中数据获取质量难以保障的客观约束产生了显著矛盾，导致原始数据中普遍存在的关联噪声问题日益凸显，这对现有模型与算法的鲁棒性形成挑战。本文针对该关联噪声问题展开深入研究，提出了一套创新性的鲁棒对比学习方法体系，以显著增强模型对复杂噪声数据的适应能力与训练效率，从而推动多模态技术向真实开放场景的可靠落地。具体而言，本文的主要工作总结如下：

- 第三章针对表征几何结构受损问题，提出了一种基于几何结构一致性的鲁棒学习算法。本章深入剖析了关联噪声对跨模态与模态内几何结构的负面影响，揭示了干净样本与噪声样本在几何结构一致性上的显著分布差异。利用深度神经网络的记忆效应，本章创新地设计了自适应的关联噪声指示函数，通过联合优化几何结构的一致性约束，在样本粒度上实现了动态噪声识别与软标签修正。实验结果表明，该算法有效维护了特征空间的几何稳定性，显著提升了模型在高噪声场景下的鲁棒能力。
- 第四章针对语义互信息不匹配问题，提出了一种特权信息辅助的关联噪声鲁棒算法。本章突破了仅依赖内源信息进行自我校正的局限，引入外部特权信息作为客观语义锚点，构建了模态间的三角校验机制。通过显式建模特权信息与原始模态的关联概率，该框架有效捕捉了细粒度的语义错配问题。在此基础上，算法设计了基于置信度的自适应权重融合策略，以规避模型预测不确定性的干扰。在复杂噪声场景下的广泛实验证实该方法具备良好的架构扩展性，能够有效应对细粒度关联噪声挑战。
- 第五章针对大规模场景下鲁棒性与训练效率失衡问题，提出了一种基于差分信息的样本选择多模态对比学习加速方法。本章基于深度学习模型的记忆效应，揭示了模型对不同质量样本在记忆趋势上的时序差分规律。基于这一发现，本工作设计了轻量级的动态筛选策略，通过实时监测样本拟合程度的差分变化，准确识别高价值样本并滤除关联噪声数据。该机制在无需额外参考模型辅助的前提下，大幅降低了训练算力消耗，并保障了下游任务的特征对齐质量，实现

了样本质量筛选与模型收敛加速的协同优化。

6.2　未来工作展望

随着多模态学习的飞速发展，对比学习在真实场景下的鲁棒性已经逐渐成为研究的重点。在此背景下，关联噪声作为多模态对比学习领域独有的重要问题，其解决方案在近年来已经在理论与应用取得了显著的进展。本文针对关联噪声问题导致的表征几何结构受损、语义互信息不一致以及大规模预训练场景下鲁棒性与训练效率失衡等关键挑战提出了相应的解决方案。尽管本文的研究取得了一定的成果，但关联噪声问题仍存在诸多难点，未来工作的发展方向可以从理论延伸、算法设计与应用拓展三个维度进行进一步探索。

- **理论延伸：**目前多模态场景下的关联噪声问题仍缺少系统性的理论框架，现有基于记忆效应的鲁棒算法设计大多停留在经验性观察层面，亟需严谨的理论证明作为支撑。例如，本文第三章虽然利用表征几何结构的不一致性实现了对关联噪声样本的精准甄别，并通过大量实验论证了算法的有效性，但尚未在理论层面给出严格的数学推导；第四章引入特权信息辅助噪声识别，同样有待对特权信息与模态间关联的耦合机制进行深入的理论建模；第五章虽然从理论的角度论证了基于差分信息的样本选择方法符合深度学习模型记忆效应的拟合趋势，但仍缺少对多模态数据复杂性的理论探讨。探究上述经验性方法背后的数理基础，将是未来构建具有理论保证的鲁棒算法的重要突破口。此外，现有的理论探究大多局限于图文对比学习场景，而关联噪声问题的本质实际上与通用多模态表征学习有着更为广泛的内在联系。从深层机制考量，两者的核心目标均在于学习并构建一个高度结构化且稳定的表征空间。在该空间内的有效学习不仅能够赋予模型抵御噪声干扰的鲁棒性，更是保障其在各类下游任务中优异泛化能力的关键；反之，表征能力薄弱的模型在面对关联噪声时往往会暴露出脆弱性。因此，未来的研究工作可从理论深度与理论广度两个维度推进，致力于建立更加稳定、可靠且具有完备依据的鲁棒多模态对比学习理论体系。
- **算法设计：**随着多模态表征学习不断向海量数据与超大规模计算演进，现有的鲁棒学习范式亟需从单纯追求极高精度的噪声识别，逐步向兼顾高效率与高鲁棒性的方向转型。本文第五章提出的基于差分信息的样本选择加速算法在该方向上进行了有益探索，通过筛除冗余噪声样本的同时保留高质量样本训练显著加速了模型收敛，减少了计算开销。但该机制仍依赖于多轮迭代以累积样本的

历史状态特征，在应对当今大规模预训练时代对训练效率的严苛要求时，其计算效能与灵活性仍有进一步提升的空间。另一方面，当前基于自回归范式的多模态大模型正逐渐成为主流，而本文所构建的鲁棒算法体系主要局限于对比学习范式，尚未实现对自回归架构的有效适配。在自回归建模过程中，图文间的关联噪声同样会引发严重的语义对齐偏差。探索在该范式下如何精准识别噪声样本，进而通过高效的样本选择机制保障模型训练的鲁棒性，是当前亟待攻克的技术难点。因此，从算法设计的长远演进视角来看，未来的研究工作可深度聚焦于大规模预训练场景的高效适配，以及面向自回归生成范式的底层机理扩展这两个核心维度，致力于构建一套不受限于特定网络架构、具备高度普适性与计算经济性的高效鲁棒多模态算法。

- **应用拓展：**目前，本文探讨的应用场景主要聚焦于图像与文本的多模态领域，下游验证工作也集中在跨模态检索、视觉推理与图像描述生成等基础任务。然而，在更广泛的多模态交互场景中，仍存在诸多亟待解决的关联噪声问题。例如，长视频序列与文本字幕之间的时序错配、跨模态人脸识别中的身份信息冲突，以及具身智能领域中多源传感器的标定误差等。本文所提的鲁棒学习机制在经过针对性的优化与领域适配后，具备向上述复杂多模态任务拓展的潜力。另一方面，所提的噪声鲁棒算法在医疗影像辅助诊断、自动驾驶等安全攸关的垂直领域具有广阔的应用前景。在将模型迁移至此类高风险场景时，提升算法应对数据噪声的鲁棒性固然重要，但进一步完善其安全保障机制亦是不可或缺的关键环节。以智慧医疗为例，在处理医学影像与放射科报告之间普遍存在的细粒度语义错位及非结构化描述时，不仅需要保证算法具备极高的甄别精度，还应引入基于模型预测置信度的安全预警机制。对于安全攸关的应用场景，模型优化的核心目标应超越对常规基准测试中平均性能指标的追求，转而更加深入地关注其在极端噪声或长尾分布下的最坏情况表现与系统级的可靠性验证。未来的应用拓展研究将致力于把鲁棒多模态表征机制与严谨的系统安全边界相融合，构建兼具强抗噪能力与极高可信度的多模态人工智能决策系统。

参考文献

[1] MANZOOR M A, ALBARRI S, XIAN Z, et al. Multimodality representation learning: A survey on evolution, pretraining and its applications[J]. ACM Transactions on Multimedia Computing, Communications and Applications, 2023, 20(3): 1-34.

[2] XU P, ZHU X, CLIFTON D A. Multimodal learning with transformers: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(10): 12113-12132.

[3] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. 2021: 8748-8763.

[4] SLEEMAN IV W C, KAPOOR R, GHOSH P. Multimodal classification: Current landscape, taxonomy and future directions[J]. ACM Computing Surveys, 2022, 55(7): 1-31.

[5] HAN Z, YANG F, HUANG J, et al. Multimodal dynamics: Dynamical fusion for trustworthy multimodal classification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 20707-20717.

[6] WANG T, LI F, ZHU L, et al. Cross-modal retrieval: a systematic review of methods and future directions[J]. Proceedings of the IEEE, 2025, 112(11): 1716-1754.

[7] HAN Z, AZMAN A B, MUSTAFFA M R B, et al. Cross-modal retrieval: A review of methodologies, datasets, and future perspectives[J]. IEEE Access, 2024, 12: 115716-115741.

[8] LU S, LIU M, YIN L, et al. The multi-modal fusion in visual question answering: a review of attention mechanisms[J]. PeerJ Computer Science, 2023, 9: e1400.

[9] YAN H, LIU L, FENG X, et al. Overcoming language priors with self-contrastive learning for visual question answering[J]. Multimedia Tools and Applications, 2023, 82(11): 16343-16358.

[10] HUANG Z, YANG M, XIAO X, et al. Noise-robust vision-language pre-training with positive-negative learning[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 47(1): 338-350.

[11] TAO Y, WANG Z, ZHANG H, et al. Nevlp: Noise-robust framework for efficient vision-language pre-training[C]//International Conference on Intelligent Computing. 2025: 74-85.

[12] ZHANG C, BENGIO S, HARDT M, et al. Understanding deep learning (still) requires rethinking generalization[J]. Communications of the ACM, 2021, 64(3): 107-115.

[13] LIU S, NILES-WEED J, RAZAVIAN N, et al. Early-learning regularization prevents memorization of noisy labels[J]. Advances in neural information processing systems, 2020, 33: 20331-20342.

[14] HUANG Z, NIU G, LIU X, et al. Learning with noisy correspondence for cross-modal matching [J]. Advances in Neural Information Processing Systems, 2021, 34: 29406-29419.

[15] YANG S, XU Z, WANG K, et al. Bicro: Noisy correspondence rectification for multi-modality data via bi-directional cross-modal similarity consistency[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 19883-19892.

[16] MA X, YANG M, LI Y, et al. Cross-modal retrieval with noisy correspondence via consistency refining and mining[J]. IEEE transactions on image processing, 2024, 33: 2587-2598.

[17] QIN Y, PENG D, PENG X, et al. Deep evidential learning with noisy correspondence for cross-modal retrieval[C]//Proceedings of the 30th ACM International Conference on Multimedia. 2022: 4948-4956.

[18] ZHA Q, LIU X, CHEUNG Y M, et al. UCPM: Uncertainty-Guided Cross-Modal Retrieval with Partially Mismatched Pairs[J]. IEEE Transactions on Image Processing, 2025.

[19] QIN Y, SUN Y, PENG D, et al. Cross-modal active complementary learning with self-refining correspondence[J]. Advances in neural information processing systems, 2023, 36: 24829-24840.

[20] HU P, PENG X, ZHU H, et al. Learning cross-modal retrieval with noisy labels[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 5403-5413.

[21] XU T, LIU X, HUANG Z, et al. Early-learning regularized contrastive learning for cross-modal retrieval with noisy labels[C]//Proceedings of the 30th ACM International Conference on Multimedia. 2022: 629-637.

[22] HAN H, MIAO K, ZHENG Q, et al. Noisy correspondence learning with meta similarity correction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7517-7526.

[23] MU C, YANG E, DENG C. Meta-guided adaptive weight learner for noisy correspondence[C]// Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2025: 968-978.

[24] YANG M, LI Y, HU P, et al. Robust multi-view clustering with incomplete information[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(1): 1055-1069.

[25] GADRE S Y, ILHARCO G, FANG A, et al. Datacomp: In search of the next generation of multimodal datasets[J]. Advances in Neural Information Processing Systems, 2023, 36: 27092-27112.

[26] ABBAS A, TIRUMALA K, SIMIG D, et al. Semdedup: Data-efficient learning at web-scale through semantic deduplication[J]. arXiv preprint arXiv:2303.09540, 2023.

[27] WELLING M. Herding dynamical weights to learn[C]//Proceedings of the 26th annual international conference on machine learning. 2009: 1121-1128.

[28] ZHAO B, MOPURI K R, BILEN H. Dataset condensation with gradient matching[J]. arXiv preprint arXiv:2006.05929, 2020.

[29] CAZENAVETTE G, WANG T, TORRALBA A, et al. Dataset distillation by matching training trajectories[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 4750-4759.

[30] KUMAR A. Self-selection and the forecasting abilities of female equity analysts[J]. Journal of Accounting Research, 2010, 48(2): 393-435.

[31] GUO S, HUANG W, ZHANG H, et al. Curriculumnet: Weakly supervised learning from large-scale web images[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 135-150.

[32] SHRIVASTAVA A, GUPTA A, GIRSHICK R. Training region-based object detectors with online hard example mining[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 761-769.

[33] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.

[34] FAGHRI F, FLEET D J, KIROS J R, et al. Vse++: Improving visual-semantic embeddings with hard negatives[J]. arXiv preprint arXiv:1707.05612, 2017.

[35] QIN Z, WANG K, ZHENG Z, et al. Infobatch: Lossless training speed up by unbiased dynamic data pruning[J]. arXiv preprint arXiv:2303.04947, 2023.

[36] HONG F, LYU Y, YAO J, et al. Diversified Batch Selection for Training Acceleration[J]. arXiv preprint arXiv:2406.04872, 2024.

[37] GUO W, WANG J, WANG S. Deep multimodal representation learning: A survey[J]. Ieee Access, 2019, 7: 63373-63394.

[38] ZHANG S F, ZHAI J H, XIE B J, et al. Multimodal representation learning: Advances, trends and challenges[C]//2019 International Conference on Machine Learning and Cybernetics (ICMLC). 2019: 1-6.

[39] ATREY P K, HOSSAIN M A, EL SADDIK A, et al. Multimodal fusion for multimedia analysis: a survey[J]. Multimedia systems, 2010, 16(6): 345-379.

[40] KIELA D, BHOOSHAN S, FIROOZ H, et al. Supervised multimodal bitransformers for classifying images and text[J]. arXiv preprint arXiv:1909.02950, 2019.

[41] YIN S, FU C, ZHAO S, et al. A survey on multimodal large language models[J]. National Science Review, 2024, 11(12): nwae403.

[42] ZHANG D, YU Y, DONG J, et al. Mm-llms: Recent advances in multimodal large language models[J]. Findings of the Association for Computational Linguistics: ACL 2024, 2024: 12401-12430.

[43] HUANG Z, HU P, NIU G, et al. Learning with noisy correspondence[J]. International Journal of Computer Vision, 2024, 132(9): 3656-3677.

[44] YANG S, LI P, LIU Y, et al. Multimodal-Guided Dynamic Dataset Pruning for Robust and Efficient Data-Centric Learning[J]. arXiv preprint arXiv:2507.12750, 2025.

[45] NASTESKI V. An overview of the supervised machine learning methods[J]. Horizons. b, 2017, 4(51-62): 56.

[46] FRÉNAY B, VERLEYSEN M. Classification in the presence of label noise: a survey[J]. IEEE transactions on neural networks and learning systems, 2013, 25(5): 845-869.

[47] KARIMI D, DOU H, WARFIELD S K, et al. Deep learning with noisy labels: Exploring techniques and remedies in medical image analysis[J]. Medical image analysis, 2020, 65: 101759.

[48] SONG H, KIM M, PARK D, et al. Learning from noisy labels with deep neural networks: A survey[J]. IEEE transactions on neural networks and learning systems, 2022, 34(11): 8135-8153.

[49] HAN B, YAO Q, LIU T, et al. A survey of label-noise representation learning: Past, present and future[J]. arXiv preprint arXiv:2011.04406, 2020.

[50] GHOSH A, KUMAR H, SASTRY P S. Robust loss functions under label noise for deep neural networks[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 31: 1. 2017.

[51] ZHANG Z, SABUNCU M. Generalized cross entropy loss for training deep neural networks with noisy labels[J]. Advances in neural information processing systems, 2018, 31.

[52] HENDRYCKS D, MAZEIKA M, WILSON D, et al. Using trusted data to train deep networks on labels corrupted by severe noise[J]. Advances in neural information processing systems, 2018, 31.

[53] PATRINI G, ROZZA A, KRISHNA MENON A, et al. Making deep neural networks robust to label noise: A loss correction approach[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1944-1952.

[54] XIA X, LIU T, WANG N, et al. Are anchor points really indispensable in label-noise learning? [J]. Advances in neural information processing systems, 2019, 32.

[55] VAN ROOYEN B, WILLIAMSON R C. A theory of learning with corrupted labels[J]. Journal of Machine Learning Research, 2018, 18(228): 1-50.

[56] WEI H, FENG L, CHEN X, et al. Combating noisy labels by agreement: A joint training method with co-regularization[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 13726-13735.

[57] MENON A K, RAWAT A S, REDDI S J, et al. Can gradient clipping mitigate label noise?[C]// International conference on learning representations. 2020.

[58] LYU Y, TSANG I W. Curriculum loss: Robust learning and generalization against label corruption [J]. arXiv preprint arXiv:1905.10045, 2019.

[59] WEI J, ZHANG Y, ZHANG L Y, et al. Memorization in deep learning: A survey[J]. ACM Computing Surveys, 2025, 58(4): 1-35.

[60] ARPIT D, JASTRZĘBSKI S, BALLAS N, et al. A closer look at memorization in deep networks [C]//International conference on machine learning. 2017: 233-242.

[61] YAO Q, YANG H, HAN B, et al. Searching to exploit memorization effect in learning with noisy labels[C]//International Conference on Machine Learning. 2020: 10789-10798.

[62] HOQUE E. Memorization: a proven method of learning[J]. International Journal of Applied Re-

search, 2018, 22(3): 142-150.

[63] VARDI G, YEHUDAI G, SHAMIR O. On the optimal memorization power of relu neural networks[J]. arXiv preprint arXiv:2110.03187, 2021.

[64] CHATTERJEE S. Learning and memorization[C]//International conference on machine learning. 2018: 755-763.

[65] ZHANG C, BENGIO S, HARDT M, et al. Understanding deep learning requires rethinking generalization[J]. arXiv preprint arXiv:1611.03530, 2016.

[66] LI M, SOLTANOLKOTABI M, OYMAK S. Gradient descent with early stopping is provably robust to label noise for overparameterized neural networks[C]//International conference on artificial intelligence and statistics. 2020: 4313-4324.

[67] MAINI P, MOZER M C, SEDGHI H, et al. Can neural network memorization be localized?[J]. arXiv preprint arXiv:2307.09542, 2023.

[68] PAPYAN V, HAN X, DONOHO D L. Prevalence of neural collapse during the terminal phase of deep learning training[J]. Proceedings of the National Academy of Sciences, 2020, 117(40): 24652-24663.

[69] NGUYEN D A, LEVIE R, LIENEN J, et al. Memorization-dilation: Modeling neural collapse under noise[J]. 2023.

[70] HUANG Z, ZHANG J, SHAN H. Twin contrastive learning with noisy labels[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 11661-11670.

[71] ISCEN A, VALMADRE J, ARNAB A, et al. Learning with neighbor consistency for noisy labels[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 4672-4681.

[72] SHEN R, GAO L, MA Y A. On optimal early stopping: Over-informative versus under-informative parametrization[J]. arXiv preprint arXiv:2202.09885, 2022.

[73] WU J, BARTLETT P, TELGARSKY M, et al. Benefits of early stopping in gradient descent for overparameterized logistic regression[J]. arXiv preprint arXiv:2502.13283, 2025.

[74] BAI Y, YANG E, HAN B, et al. Understanding and improving early stopping for learning with noisy labels[J]. Advances in Neural Information Processing Systems, 2021, 34: 24392-24403.

[75] HUANG H, KANG H, LIU S, et al. Paddles: Phase-amplitude spectrum disentangled early stopping for learning with noisy labels[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 16719-16730.

[76] GUI X J, WANG W, TIAN Z H. Towards understanding deep learning from noisy labels with small-loss criterion[J]. arXiv preprint arXiv:2106.09291, 2021.

[77] XIA X, LIU T, HAN B, et al. Sample selection with uncertainty of losses for learning with noisy labels[J]. arXiv preprint arXiv:2106.00445, 2021.

[78] JIANG L, ZHOU Z, LEUNG T, et al. Mentornet: Learning data-driven curriculum for very deep

neural networks on corrupted labels[C]//International conference on machine learning. 2018: 2304-2313.

[79] HAN B, YAO Q, YU X, et al. Co-teaching: Robust training of deep neural networks with extremely noisy labels[J]. Advances in neural information processing systems, 2018, 31.

[80] YU X, HAN B, YAO J, et al. How does disagreement help generalization against label corruption? [C]//International conference on machine learning. 2019: 7164-7173.

[81] LI J, SOCHER R, HOI S C. Dividemix: Learning with noisy labels as semi-supervised learning [J]. arXiv preprint arXiv:2002.07394, 2020.

[82] BERTHELOT D, CARLINI N, GOODFELLOW I, et al. Mixmatch: A holistic approach to semi-supervised learning[J]. Advances in neural information processing systems, 2019, 32.

[83] HUANG J, QU L, JIA R, et al. O2u-net: A simple noisy label detection approach for deep neural networks[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 3326-3334.

[84] PLEISS G, ZHANG T, ELENBERG E, et al. Identifying mislabeled data using the area under the margin ranking[J]. Advances in Neural Information Processing Systems, 2020, 33: 17044-17056.

[85] LIU S, ZHU Z, QU Q, et al. Robust training under label noise by over-parameterization[C]// International Conference on Machine Learning. 2022: 14153-14172.

[86] ALLEN-ZHU Z, LI Y, LIANG Y. Learning and generalization in overparameterized neural networks, going beyond two layers[J]. Advances in neural information processing systems, 2019, 32.

[87] ZHANG H, CISSE M, DAUPHIN Y N, et al. mixup: Beyond empirical risk minimization[J]. arXiv preprint arXiv:1710.09412, 2017.

[88] LUKASIK M, BHOJANAPALLI S, MENON A, et al. Does label smoothing mitigate label noise? [C]//International Conference on Machine Learning. 2020: 6448-6458.

[89] HERMANS A, BEYER L, LEIBE B. In defense of the triplet loss for person re-identification[J]. arXiv preprint arXiv:1703.07737, 2017.

[90] HE K, FAN H, WU Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 9729-9738.

[91] LI J, LI D, XIONG C, et al. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation[C]//International conference on machine learning. 2022: 12888-12900.

[92] YANG M, LI Y, HUANG Z, et al. Partially view-aligned representation learning with noise-robust contrastive loss[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1134-1143.

[93] ZHANG X, LI H, YE M. Negative pre-aware for noisy cross-modal matching[C]//Proceedings

of the AAAI Conference on Artificial Intelligence: vol. 38: 7. 2024: 7341-7349.

[94] SHARMA P, DING N, GOODMAN S, et al. Conceptual captions: A cleaned, hypernymed, image alt-text dataset for automatic image captioning[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018: 2556-2565.

[95] CHANGPINYO S, SHARMA P, DING N, et al. Conceptual 12m: Pushing web-scale image-text pre-training to recognize long-tail visual concepts[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 3558-3568.

[96] SHI H, LIU M, MU X, et al. Breaking through the noisy correspondence: A robust model for image-text matching[J]. ACM Transactions on Information Systems, 2024, 42(6): 1-26.

[97] ZHAO Z, CHEN M, DAI T, et al. Mitigating Noisy Correspondence by Geometrical Structure Consistency Learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 27381-27390.

[98] WU W, LUO H, FANG B, et al. Cap4video: What can auxiliary captions do for text-video retrieval?[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 10704-10713.

[99] FANG B, WU W, LIU C, et al. Uatvr: Uncertainty-adaptive text-video retrieval[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 13723-13733.

[100] HAN T, XIE W, ZISSERMAN A. Temporal alignment networks for long-term video[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 2906-2916.

[101] LAI H, XIONG G, MAI H, et al. Rethinking Noisy Video-Text Retrieval via Relation-aware Alignment[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 9231-9241.

[102] YE M, CHEN S, LI C, et al. Transformer for object re-identification: A survey[J]. International Journal of Computer Vision, 2025, 133(5): 2410-2440.

[103] SARKER P K, ZHAO Q, UDDIN M K. Transformer-based person re-identification: a comprehensive review[J]. IEEE Transactions on Intelligent Vehicles, 2024, 9(7): 5222-5239.

[104] YANG M, HUANG Z, HU P, et al. Learning with twin noisy labels for visible-infrared person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 14308-14317.

[105] QIN Y, CHEN Y, PENG D, et al. Noisy-correspondence learning for text-to-image person re-identification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 27197-27206.

[106] LIU Y, WU Z, CHEN B, et al. Medical Cross-Modal Prompt Hashing with Robust Noisy Correspondence Learning[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2024: 250-261.

[107] LIN Y, YANG M, YU J, et al. Graph matching with bi-level noisy correspondence[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 23362-23371.

[108] GUO R, YANG M, LIN Y, et al. Robust contrastive multi-view clustering against dual noisy correspondence[J]. Advances in Neural Information Processing Systems, 2024, 37: 121401-121421.

[109] FAN Y, KUKLEVA A, DAI D, et al. Revisiting consistency regularization for semi-supervised learning[J]. International Journal of Computer Vision, 2023, 131(3): 626-643.

[110] ZHANG H, ZHANG Z, ODENA A, et al. Consistency regularization for generative adversarial networks[J]. arXiv preprint arXiv:1910.12027, 2019.

[111] ZHA Q, LIU X, PENG S J, et al. ReCon: Enhancing True Correspondence Discrimination through Relation Consistency for Robust Noisy Correspondence Learning[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 29680-29689.

[112] LI Y, HUANG H, XU J, et al. NAC: Mitigating Noisy Correspondence in Cross-Modal Matching Via Neighbor Auxiliary Corrector[C]//ICASSP 2024-2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2024: 6815-6819.

[113] XIE Y, CAI S, TONG T, et al. Seeking proxy point via stable feature space for noisy correspondence learning[C]//Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence. 2025: 2072-2080.

[114] SUN Y, LI Y, REN Z, et al. ROLL: Robust Noisy Pseudo-label Learning for Multi-View Clustering with Noisy Correspondence[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 30732-30741.

[115] DANG Z, LUO M, JIA C, et al. Noisy correspondence learning with self-reinforcing errors mitigation[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 38: 2. 2024: 1463-1471.

[116] HAN H, ZHENG Q, DAI G, et al. Learning to rematch mismatched pairs for robust cross-modal retrieval[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 26679-26688.

[117] DUAN Y, GU Z, YING Z, et al. Pc2: Pseudo-classification based pseudo-captioning for noisy correspondence learning in cross-modal retrieval[C]//Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 9397-9406.

[118] LIU Z, LIU Y, FENG W, et al. PCSR: Pseudo-label Consistency-Guided Sample Refinement for Noisy Correspondence Learning[J]. arXiv preprint arXiv:2509.15623, 2025.

[119] LIN Y, ZHANG J, HUANG Z, et al. Multi-granularity correspondence learning from long-term noisy videos[J]. arXiv preprint arXiv:2401.16702, 2024.

[120] PEYRÉ G, CUTURI M. Computational optimal transport: With applications to data science[M]. Now Foundations, 2019.

[121] MONTESUMA E F, MBOULA F M N, SOULOUMIAC A. Recent advances in optimal transport

for machine learning[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 47(2): 1161-1180.

[122] LOQUERCIO A, SEGU M, SCARAMUZZA D. A general framework for uncertainty estimation in deep learning[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 3153-3160.

[123] TYRALIS H, PAPACHARALAMPOUS G. A review of predictive uncertainty estimation with machine learning[J]. Artificial Intelligence Review, 2024, 57(4): 94.

[124] SENSOY M, KAPLAN L, KANDEMIR M. Evidential deep learning to quantify classification uncertainty[J]. Advances in neural information processing systems, 2018, 31.

[125] GAO J, CHEN M, XIANG L, et al. A comprehensive survey on evidential deep learning and its applications[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025.

[126] XIE Y, ZHANG B, LI Y, et al. Noise correspondence with evidence learning for text-based person search[J]. The Journal of Supercomputing, 2025, 81(5): 1-26.

[127] QIN W, YU W, ZHANG K, et al. Uncertainty-aware evidential learning for legal case retrieval with noisy correspondence[J]. Information Sciences, 2025, 702: 121915.

[128] FENG Z, ZENG Z, GUO C, et al. Learning from noisy correspondence with tri-partition for cross-modal matching[J]. IEEE Transactions on Multimedia, 2023, 26: 3884-3896.

[129] ZHA Q, LIU X, CHEUNG Y M, et al. Ugncl: Uncertainty-guided noisy correspondence learning for efficient cross-modal matching[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 852-861.

[130] CHEN M, ZHANG F, ZHAO Z, et al. Probabilistic conformal distillation for enhancing missing modality robustness[J]. Advances in Neural Information Processing Systems, 2024, 37: 36218-36242.

[131] ZHANG X, WEI Y, FENG J, et al. Adversarial complementary learning for weakly supervised object localization[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 1325-1334.

[132] HU P, HUANG Z, PENG D, et al. Cross-modal retrieval with partially mismatched pairs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(8): 9595-9610.

[133] WANG Y, WU Y, DAI Z, et al. Noisy Correspondence Rectification via Asymmetric Similarity Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 39: 20. 2025: 21384-21392.

[134] CHUANG C Y, HJELM R D, WANG X, et al. Robust contrastive learning against noisy views[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 16670-16681.

[135] LUO X, WANG H, WU D, et al. A survey on deep hashing methods[J]. ACM Transactions on Knowledge Discovery from Data, 2023, 17(1): 1-50.

[136] RODRIGUES J, CRISTO M, COLONNA J G. Deep hashing for multi-label image retrieval: a

survey[J]. Artificial Intelligence Review, 2020, 53(7): 5261-5307.

[137] JIANG Q Y, LI W J. Deep cross-modal hashing[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 3232-3240.

[138] JIN S, ZHOU S, LIU Y, et al. SSAH: Semi-supervised adversarial deep hashing with self-paced hard sample generation[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 34: 07. 2020: 11157-11164.

[139] JIN L, LI Z, TANG J. Deep semantic multimodal hashing network for scalable image-text and video-text retrievals[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 34(4): 1838-1851.

[140] FENG Y, ZHU H, PENG D, et al. RONO: robust discriminative learning with noisy labels for 2D-3D cross-modal retrieval[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 11610-11619.

[141] WANG L, QIN Y, SUN Y, et al. Robust contrastive cross-modal hashing with noisy labels[C]// Proceedings of the 32nd ACM International Conference on Multimedia. 2024: 5752-5760.

[142] HOSPEDALES T, ANTONIOU A, MICAELLI P, et al. Meta-learning in neural networks: A survey[J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(9): 5149-5169.

[143] VETTORUZZO A, BOUGUELIA M R, VANSCHOREN J, et al. Advances and challenges in meta-learning: A technical review[J]. IEEE transactions on pattern analysis and machine intelligence, 2024, 46(7): 4763-4779.

[144] WANG Z, LIN Z, WEN J, et al. Learning to detect noisy labels using model-based features[C]// Findings of the Association for Computational Linguistics: EMNLP 2022. 2022: 5796-5808.

[145] SHU J, XIE Q, YI L, et al. Meta-weight-net: Learning an explicit mapping for sample weighting [J]. Advances in neural information processing systems, 2019, 32.

[146] MIAO X, OLIARO G, ZHANG Z, et al. Towards efficient generative large language model serving: A survey from algorithms to systems[J]. ACM Computing Surveys, 2025, 58(1): 1-37.

[147] HAGOS D H, BATTLE R, RAWAT D B. Recent advances in generative ai and large language models: Current status, challenges, and perspectives[J]. IEEE transactions on artificial intelligence, 2024, 5(12): 5873-5893.

[148] FU Z, SONG K, ZHOU L, et al. Noise-aware image captioning with progressively exploring mismatched words[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 38: 11. 2024: 12091-12099.

[149] ORDONEZ V, KULKARNI G, BERG T. Im2text: Describing images using 1 million captioned photographs[J]. Advances in neural information processing systems, 2011, 24.

[150] THOMEE B, SHAMMA D A, FRIEDLAND G, et al. Yfcc100m: The new data in multimedia research[J]. Communications of the ACM, 2016, 59(2): 64-73.

[151] SCHUHMANN C, VENCU R, BEAUMONT R, et al. Laion-400m: Open dataset of clip-filtered

400 million image-text pairs[J]. arXiv preprint arXiv:2111.02114, 2021.

[152] DESAI K, KAUL G, AYSOLA Z, et al. Redcaps: Web-curated image-text data created by the people, for the people[J]. arXiv preprint arXiv:2111.11431, 2021.

[153] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of machine learning research, 2020, 21(140): 1-67.

[154] SCHUHMANN C, BEAUMONT R, VENCU R, et al. Laion-5b: An open large-scale dataset for training next generation image-text models[J]. Advances in neural information processing systems, 2022, 35: 25278-25294.

[155] SRINIVASAN K, RAMAN K, CHEN J, et al. Wit: Wikipedia-based image text dataset for multimodal multilingual machine learning[C]//Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval. 2021: 2443-2449.

[156] JIA C, YANG Y, XIA Y, et al. Scaling up visual and vision-language representation learning with noisy text supervision[C]//International conference on machine learning. 2021: 4904-4916.

[157] DESAI K, JOHNSON J. Virtex: Learning visual representations from textual annotations[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 11162-11173.

[158] GUO C, ZHAO B, BAI Y. Deepcore: A comprehensive library for coreset selection in deep learning[C]//International Conference on Database and Expert Systems Applications. 2022: 181-195.

[159] MOSER B B, SHANBHAG A S, FROLOV S, et al. A coreset selection of coreset selection literature: Introduction and recent advances[J]. arXiv preprint arXiv:2505.17799, 2025.

[160] SENER O, SAVARESE S. Active learning for convolutional neural networks: A core-set approach [J]. arXiv preprint arXiv:1708.00489, 2017.

[161] AGARWAL S, ARORA H, ANAND S, et al. Contextual diversity for active learning[C]// European Conference on Computer Vision. 2020: 137-153.

[162] WANG H, HUANG W, WU Z, et al. Deep active learning by leveraging training dynamics[J]. Advances in Neural Information Processing Systems, 2022, 35: 25171-25184.

[163] TIRUMALA K, MARKOSYAN A, ZETTLEMOYER L, et al. Memorization without overfitting: Analyzing the training dynamics of large language models[J]. Advances in Neural Information Processing Systems, 2022, 35: 38274-38290.

[164] TONEVA M, SORDONI A, COMBES R T D, et al. An empirical study of example forgetting during deep neural network learning[J]. arXiv preprint arXiv:1812.05159, 2018.

[165] PAUL M, GANGULI S, DZIUGAITE G K. Deep learning on a data diet: Finding important examples early in training[J]. Advances in neural information processing systems, 2021, 34: 20596-20607.

[166] HESSEL J, HOLTZMAN A, FORBES M, et al. Clipscore: A reference-free evaluation metric for image captioning[J]. arXiv preprint arXiv:2104.08718, 2021.

[167] WANG T, ZHU J Y, TORRALBA A, et al. Dataset distillation[J]. arXiv preprint arXiv:1811.10959, 2018.

[168] ZHAO B, BILEN H. Dataset condensation with differentiable siamese augmentation[C]//International Conference on Machine Learning. 2021: 12674-12685.

[169] ZHAO B, BILEN H. Dataset condensation with distribution matching[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2023: 6514-6523.

[170] ZHOU Y, NEZHADARYA E, BA J. Dataset distillation using neural feature regression[J]. Advances in Neural Information Processing Systems, 2022, 35: 9813-9827.

[171] SOVIANY P, IONESCU R T, ROTA P, et al. Curriculum learning: A survey[J]. International Journal of Computer Vision, 2022, 130(6): 1526-1565.

[172] WANG X, CHEN Y, ZHU W. A survey on curriculum learning[J]. IEEE transactions on pattern analysis and machine intelligence, 2021, 44(9): 4555-4576.

[173] BENGIO Y, LOURADOUR J, COLLOBERT R, et al. Curriculum learning[C]//Proceedings of the 26th annual international conference on machine learning. 2009: 41-48.

[174] PLATANIOS E A, STRETCU O, NEUBIG G, et al. Competence-based curriculum learning for neural machine translation[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 1162-1172.

[175] WANG Y, YUE Y, LU R, et al. Efficienttrain++: Generalized curriculum learning for efficient visual backbone training[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 8036-8055.

[176] LIU Y, LIU J, SHI X, et al. Let's learn step by step: Enhancing in-context learning ability with curriculum learning[J]. arXiv preprint arXiv:2402.10738, 2024.

[177] JIANG L, MENG D, ZHAO Q, et al. Self-paced curriculum learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 29: 1. 2015.

[178] JIANG L, MENG D, YU S I, et al. Self-paced learning with diversity[J]. Advances in neural information processing systems, 2014, 27.

[179] ZHAO D, KOH Y S, DOBBIE G, et al. Symmetric self-paced learning for domain generalization [C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 38: 15. 2024: 16961-16969.

[180] TRUNG N N, VAN L N, NGUYEN T H. Unsupervised domain adaptation for text classification via meta self-paced learning[C]//Proceedings of the 29th International Conference on computational linguistics. 2022: 4741-4752.

[181] ZHAO Y, GONG M, ZHANG M, et al. SPCNet: Deep self-paced curriculum network incorporated with inductive bias[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025.

[182] ZHOU Y, WANG X, CHEN H, et al. Intra-and inter-modal curriculum for multimodal learning

[C]//Proceedings of the 31st ACM International Conference on Multimedia. 2023: 3724-3735.

[183] QIAN C, HAN K, LIU J, et al. Dyncim: Dynamic curriculum for imbalanced multimodal learning [J]. arXiv preprint arXiv:2503.06456, 2025.

[184] SUN Y, DAI J, REN Z, et al. Dual self-paced cross-modal hashing[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 38: 14. 2024: 15184-15192.

[185] KUMAR A, KIRA Z, RAWAT Y S. Contextual self-paced learning for weakly supervised spatio-temporal video grounding[J]. arXiv preprint arXiv:2501.17053, 2025.

[186] LIU L, LIANG Y, YAN X, et al. Hard Sample Mining: A New Paradigm of Efficient and Robust Model Training[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025.

[187] CAO Y, CHEN K, LOY C C, et al. Prime sample attention in object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11583-11591.

[188] WANG Y, YE Y, XIE Y, et al. Hsalc: Hard sample aware label correction for medical image classification[J]. Multimedia Tools and Applications, 2025, 84(22): 25639-25659.

[189] SCHROFF F, KALENICHENKO D, PHILBIN J. Facenet: A unified embedding for face recognition and clustering[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 815-823.

[190] ROBINSON J, CHUANG C Y, SRA S, et al. Contrastive learning with hard negative samples[J]. arXiv preprint arXiv:2010.04592, 2020.

[191] JIANG R, NGUYEN T, ISHWAR P, et al. Supervised contrastive learning with hard negative samples[C]//2024 International Joint Conference on Neural Networks (IJCNN). 2024: 1-8.

[192] ZHANG S, LIU M, YAN J, et al. M-mix: Generating hard negatives via multi-sample mixing for contrastive learning[C]//Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining. 2022: 2461-2470.

[193] ZOLFAGHARI M, ZHU Y, GEHLER P, et al. Crossclr: Cross-modal contrastive learning for multi-modal video representations[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 1450-1459.

[194] WU Q, WAN J, CHAN A B. Progressive unsupervised learning for visual object tracking[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 2993-3002.

[195] CHOI H, BEEDU A, ESSA I. Multimodal contrastive learning with hard negative sampling for human activity recognition[J]. arXiv preprint arXiv:2309.01262, 2023.

[196] XU L, LIAN J, ZHAO W X, et al. Negative sampling for contrastive representation learning: A review[J]. arXiv preprint arXiv:2206.00212, 2022.

[197] ELVIRA V, MARTINO L. Advances in importance sampling[J]. arXiv preprint arXiv:2102.05407, 2021.

[198] ALAIN G, LAMB A, SANKAR C, et al. Variance reduction in sgd by distributed importance

sampling[J]. arXiv preprint arXiv:1511.06481, 2015.

[199] KATHAROPOULOS A, FLEURET F. Not all samples are created equal: Deep learning with importance sampling[C]//International conference on machine learning. 2018: 2525-2534.

[200] JOHNSON T B, GUESTRIN C. Training deep models faster with robust, approximate importance sampling[J]. Advances in Neural Information Processing Systems, 2018, 31.

[201] LOSHCHILOV I, HUTTER F. Online batch selection for faster training of neural networks[J]. arXiv preprint arXiv:1511.06343, 2015.

[202] KATHAROPOULOS A, FLEURET F. Biased importance sampling for deep neural network training[J]. arXiv preprint arXiv:1706.00043, 2017.

[203] JIANG A H, WONG D L K, ZHOU G, et al. Accelerating deep learning by focusing on the biggest losers[J]. arXiv preprint arXiv:1910.00762, 2019.

[204] GUO Y, KANKANHALLI M. SCAN: Bootstrapping Contrastive Pre-training for Data Efficiency [J]. arXiv preprint arXiv:2411.09126, 2024.

[205] WU X, XIA M, SHAO R, et al. Icons: Influence consensus for vision-language data selection[J]. arXiv preprint arXiv:2501.00654, 2024.

[206] ZHANG C, YANG Z, HE X, et al. Multimodal intelligence: Representation learning, information fusion, and applications[J]. IEEE Journal of Selected Topics in Signal Processing, 2020, 14(3): 478-493.

[207] LIU X, XIA X, NG S K, et al. Principled multimodal representation learning[J]. arXiv preprint arXiv:2507.17343, 2025.

[208] WANG F, ZHOU Y, WANG S, et al. Multi-granularity cross-modal alignment for generalized medical visual representation learning[J]. Advances in neural information processing systems, 2022, 35: 33536-33549.

[209] ZHANG X, STENDAHL J C, STAIB L H, et al. Adaptive correspondence scoring for unsupervised medical image registration[C]//European Conference on Computer Vision. 2024: 76-92.

[210] BEHL A, CHITTA K, PRAKASH A, et al. Label efficient visual abstractions for autonomous driving[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2020: 2338-2345.

[211] LI S, FAN Y, MA Y, et al. Evaluation of dataset distribution and label quality for autonomous driving system[C]//2021 IEEE 21st International Conference on Software Quality, Reliability and Security Companion (QRS-C). 2021: 196-200.

[212] IBRAHIM S, TRAGANITIS P A, FU X, et al. Learning from crowdsourced noisy labels: A signal processing perspective[J]. IEEE Signal Processing Magazine, 2025, 42(3): 84-106.

[213] LI M, ZHU C. Noisy label processing for classification: A survey[J]. arXiv preprint arXiv:2404.04159, 2024.

[214] XIA X, LIU T, HAN B, et al. Robust early-learning: Hindering the memorization of noisy labels

[C]//International conference on learning representations. 2020.

[215] GOEL S, BANSAL H, BHATIA S, et al. Cyclip: Cyclic contrastive language-image pretraining [J]. Advances in Neural Information Processing Systems, 2022, 35: 6704-6719.

[216] JIANG Q, CHEN C, ZHAO H, et al. Understanding and constructing latent modality structures in multi-modal representation learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7661-7671.

[217] YOUNG P, LAI A, HODOSH M, et al. From image descriptions to visual denotations: New similarity metrics for semantic inference over event descriptions[J]. Transactions of the Association for Computational Linguistics, 2014, 2: 67-78.

[218] KARPATHY A, FEI-FEI L. Deep visual-semantic alignments for generating image descriptions [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3128-3137.

[219] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft coco: Common objects in context[C]// Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part V 13. 2014: 740-755.

[220] CHUA T S, TANG J, HONG R, et al. Nus-wide: a real-world web image database from national university of singapore[C]//Proceedings of the ACM international conference on image and video retrieval. 2009: 1-9.

[221] XU J, MEI T, YAO T, et al. Msr-vtt: A large video description dataset for bridging video and language[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 5288-5296.

[222] CHEN D, DOLAN W B. Collecting highly parallel data for paraphrase evaluation[C]// Proceedings of the Annual Meeting of the Association for Computational Linguistics (ACL). 2011.

[223] DIAO H, ZHANG Y, MA L, et al. Similarity reasoning and filtration for image-text matching[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 35: 2. 2021: 1218-1226.

[224] KRISHNA R, ZHU Y, GROTH O, et al. Visual genome: Connecting language and vision using crowdsourced dense image annotations[J]. International journal of computer vision, 2017, 123(1): 32-73.

[225] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.

[226] LUO H, JI L, ZHONG M, et al. Clip4clip: An empirical study of clip for end to end video clip retrieval[J]. arXiv preprint arXiv:2104.08860, 2021.

[227] KINGMA D P. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.

[228] CHEN M, CHENG H, DU Y, et al. Two wrongs don't make a right: Combating confirmation bias in learning with label noise[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 37: 12. 2023: 14765-14773.

[229] XU C, SONG P, TANG S, et al. Alleviating Confirmation Bias in Learning with Noisy Labels via Two-Network Collaboration[J]. ACM Transactions on Intelligent Systems and Technology, 2025, 16(4): 1-21.

[230] WANG A J, LIN K Q, ZHANG D J, et al. Too large; data reduction for vision-language pre-training [C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 3147-3157.

[231] LUO Y, ZHENG L, GUAN T, et al. Taking a closer look at domain shift: Category-level adversaries for semantics consistent domain adaptation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 2507-2516.

[232] ZHANG M, MARKLUND H, DHAWAN N, et al. Adaptive risk minimization: Learning to adapt to domain shift[J]. Advances in neural information processing systems, 2021, 34: 23664-23678.

[233] CAO W, WU Y, SUN Y, et al. A review on multimodal zero-shot learning[J]. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 2023, 13(2): e1488.

[234] ABDELHAMED A, AFIFI M, GO A. What do you see? enhancing zero-shot image classification with multimodal large language models[J]. arXiv preprint arXiv:2405.15668, 2024.

[235] ZHOU K, HASSAN F H, HOON G K. The state of the art for cross-modal retrieval: A survey[J]. IEEE Access, 2023, 11: 138568-138589.

[236] WANG Z, GAO Z, YANG Y, et al. Geometric matching for cross-modal retrieval[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 36(3): 5509-5521.

[237] CHERTI M, BEAUMONT R, WIGHTMAN R, et al. Reproducible scaling laws for contrastive language-image learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 2818-2829.

[238] MAKWANA D, ENGINEER P, DABHI A, et al. Sampling methods in research: A review[J]. International Journal of Trend in Scientific Research and Development, 2023, 7(3): 762-768.

[239] KARIM N, RIZVE M N, RAHNAVARD N, et al. Unicon: Combating label noise through uniform selection and contrastive learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 9676-9686.

[240] MINDERMANN S, BRAUNER J M, RAZZAK M T, et al. Prioritized training on points that are learnable, worth learning, and not yet learnt[C]//International Conference on Machine Learning. 2022: 15630-15649.

[241] WANG H, LI J, WU H, et al. Pre-trained language models and their applications[J]. Engineering, 2023, 25: 51-65.

[242] WANG X, CHEN G, QIAN G, et al. Large-scale multi-modal pre-trained models: A comprehen-

sive survey[J]. Machine Intelligence Research, 2023, 20(4): 447-482.

[243] OORD A V D, LI Y, VINYALS O. Representation learning with contrastive predictive coding [J]. arXiv preprint arXiv:1807.03748, 2018.

[244] WEI J, ZHANG Y, ZHANG L Y, et al. Memorization in deep learning: A survey[J]. arXiv preprint arXiv:2406.03880, 2024.

[245] YAO Y, ROSASCO L, CAPONNETTO A. On early stopping in gradient descent learning[J]. Constructive approximation, 2007, 26(2): 289-315.

[246] LAINE S, AILA T. Temporal ensembling for semi-supervised learning[J]. arXiv preprint arXiv:1610.02242, 2016.

[247] SUHR A, ZHOU S, ZHANG A, et al. A corpus for reasoning about natural language grounded in photographs[J]. arXiv preprint arXiv:1811.00491, 2018.

[248] PAPINENI K, ROUKOS S, WARD T, et al. Bleu: a method for automatic evaluation of machine translation[C]//Proceedings of the 40th annual meeting of the Association for Computational Linguistics. 2002: 311-318.

[249] BANERJEE S, LAVIE A. METEOR: An automatic metric for MT evaluation with improved correlation with human judgments[C]//Proceedings of the acl workshop on intrinsic and extrinsic evaluation measures for machine translation and/or summarization. 2005: 65-72.

[250] VEDANTAM R, LAWRENCE ZITNICK C, PARIKH D. Cider: Consensus-based image description evaluation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 4566-4575.

[251] ANDERSON P, FERNANDO B, JOHNSON M, et al. Spice: Semantic propositional image caption evaluation[C]//European conference on computer vision. 2016: 382-398.

[252] PASZKE A, GROSS S, MASSA F, et al. Pytorch: An imperative style, high-performance deep learning library[J]. Advances in neural information processing systems, 2019, 32.

[253] ILHARCO G, WORTSMAN M, WIGHTMAN R, et al. OpenCLIP[CP/OL]. 0.1. Zenodo. 2021. https://doi.org/10.5281/zenodo.5143773.

[254] LOSHCHILOV I. Decoupled weight decay regularization[J]. arXiv preprint arXiv:1711.05101, 2017.

[255] LAION-AI. CLIP Benchmark[EB/OL]. 2023. https://github.com/LAION-AI/CLIP_benchmark.

[256] WANG Y, CHEN Y, YAN W, et al. Cliploss and norm-based data selection methods for multimodal contrastive learning[J]. Advances in Neural Information Processing Systems, 2025, 37: 15028-15069.

[257] JOUPPI N P, YOUNG C, PATIL N, et al. In-datacenter performance analysis of a tensor processing unit[C]//Proceedings of the 44th annual international symposium on computer architecture. 2017: 1-12.

学术论文和科研成果目录

学术论文

[1] 第一作者. Mitigating Noisy Correspondence by Geometrical Structure Consistency Learning (CVPR). 2024. [对应学位论文第三章]

[2] 第一作者. Privileged Information Assisted Learning from Noisy Correspondence (NeuroComputing). 2025. [对应学位论文第四章]

[3] 第一作者. Differential-informed Sample Selection Accelerates Multimodal Contrastive Learning (ICCV). 2025. [对应学位论文第五章]

[4] 共同一作. Multimodal Medical Diagnosis via Large-small Model Collaboration (CVPR). 2025.

[5] 共同一作. Co-Reward: Self-supervised Reinforcement Learning for Large Language Model Reasoning via Contrastive Agreement (ICLR). 2026.

[6] 第二作者. Exploring Training on Heterogeneous Data with Mixture of Low-rank Adaptors (ICML). 2024.

[7] 第三作者. Probabilistic Conformal Distillation for Enhancing Missing Modality Robustness (NeurIPS). 2024.

[8] 第三作者. Dual-granularity sinkhorn distillation for enhanced learning from long-tailed noisy data (Machine Learning Journal). 2025.

[9] 第二作者. Privileged Prompt Customization for Multimodal Medical Diagnosis with Inconsistent Modalities (Neural Networks Under Review). 2026

专利

[1] 第二发明人。基于几何结构一致性的鲁棒跨模态检索方法、设备及介质，专利申请号2024106241289。

[2] 第三发明人。一种基于混合低秩适配器的异构数据训练方法和系统，专利申请号2024107223911。